

队伍编号	MC2312146
题号	D

航空安全风险分析和飞行技术评估问题

摘要

飞行安全是民航运输业赖以生存和发展的基础，也与每一位乘客的生命安全息息相关，因此，驾驶员的飞行技术评估也十分重要。本文依靠快速存取记录器(*Quick Access Recorder, QAR*)和飞行员运行表现，进行了航空安全风险分析和飞行员飞行的技术评估两个问题，并建立了实时自动化预警模型，为航空公司提供方案参考。

针对问题一，首先在飞机本身存在多个飞行阶段的基础上，采用分治思想，运用 ***K-Means* 聚类算法**将附件一中的 *QAR* 数据分为 4 个阶段，即地面滑行、起飞离场、加速爬升、巡航（将落地减速阶段等同于起飞加速阶段）；其次依据**变异系数法**对数据进行可靠性研究，发现坡度 (*ROLL ATT*)、航向道偏差 (*LOCALIZER DEV Dots*)、下降率 (*Inertial Vertical Speed*) 的变异系数权重较大，比较不可靠；然后用箱型图查找和删除异常值并用插值法填补，最后用**主成分分析法**提取关键数据，重要程度依次为姿态（俯仰角）、着陆 *G* 值、盘量、杆量、坡度、无线电高度。

针对问题二，首先确定量化的对象，用杆量和盘量的变化来反映“重着陆”等现象；其次用 ***ADF* 检验**发现着陆 *G* 值、杆量、盘量为弱稳定序列；然后建立**差分数学模型**，最后观察对比发现杆量增大或盘量减小时，着陆 *G* 值偏大，易造成“重着陆”。

针对问题三，首先对附件二进行数据预处理；其次将超限的不同情况分为特定机场或特点天气进行基于频数的**统计分析**，最后发现飞机在机场 68 或春冬季的大风天气与积雪天气出现超限情况。

针对问题四，首先对附件三进行整体的数据清洗；其次用主成分分析对数据进行**降维处理**，方便后续的预测；最后建立 ***XGBoost* 回归预测模型**，并运用 ***PSO* 粒子群优化算法**；最终的 $R^2=0.89$ ，预测效果良好。

针对问题五，首先将杆量与盘量作为自变量反映 *G* 值，通过 ***PSO* 算法**优化后的 ***BP* 神经网络回归模型**构建相关性，并将与预测偏差 5% 以外的真实值视为超限数据，然后设计具体流程完善**自动化预警机制**；最后对附件一进行仿真分析。

【关键词】*PSO*； *K-Means*； *XGBoost*； *PCA*； 变异系数； *ADF* 检验

目 录

一、 问题重述	1
1.1 问题背景	1
1.2 问题提出	1
二、 问题分析	2
2.1 问题 1 的分析	2
2.2 问题 2 的分析	3
2.3 问题 3 的分析	3
2.4 问题 4 的分析	3
2.5 问题 5 的分析	4
三、 模型假设	4
四、 符号说明	5
五、 问题一模型的建立与求解	6
5.1 <i>K-Means</i> 聚类算法的运用	6
5.1.1 聚类的必要性说明	6
5.1.2 <i>K-Means</i> 聚类原理	6
5.1.3 分析步骤及结果	7
5.2 变异系数检验可靠性	9
5.2.1 变异系数原理	9
5.2.2 权重计算结果	9
5.3 箱型图去异常值及插值法填补	11
5.3.1 箱型图原理及特点	11
5.3.2 箱型图去除异常值	12
5.4 分段插值法填补异常值	12
5.4.1 分段插值法的原理及实现	12
5.5 主成分分析模型提取关键参数	13
5.5.1 插值法的选择	13
5.5.2 主成分分析模型 (<i>PCA</i>) 的建立	13
5.5.3 主成分分析模型 (<i>PCA</i>) 的求解	14

六、 问题二模型的建立与求解	17
6.1 量化对象的确立	17
6.2 单位根 (ADF) 检验原理	17
6.3 差分模型的建立	18
6.4 ADF 检验及差分结果	18
6.5 量化描述飞行操纵	19
七、 问题三模型的建立与求解	22
7.1 数据预处理	22
7.2 描述性统计分析	22
7.3 针对特定机场分析	22
八、 问题四模型的建立与求解	27
8.1 数据预处理	27
8.1.1 数据清洗	27
8.1.2 主成分降维	27
8.2 XGBoost 回归模型的建立	27
8.3 粒子群优化算法 (PSO) 的建立	29
8.3.1 模型初始化	29
8.3.2 算法步骤	29
8.4 模型结果分析	30
九、 问题五模型的建立与求解	32
9.1 自动化预警机制的构建	32
9.1.1 实时预警模型的构建	32
9.1.2 总体流程设计	33
9.2 仿真分析结果	34
十、 模型的优缺点和推广	35
10.1 模型的优点	35
10.2 模型的缺点	35
10.3 模型的改进与推广	35
十一、 参考文献	36
附录	37

一、 问题重述

1.1 问题背景

飞行安全是民航运输业赖以生存和发展的基础。随着我国民航业的快速发展，针对飞行安全问题的研究显得越来越重要。航空安全大数据主要包括快速存取记录器 (*Quick Access Recorder, QAR*) 数据, 该数据主要记录飞机在飞行过程中的各项飞行参数; *QAR* 中超出人为设定限制值的数据记为超限数据。 G 值是飞机飞行过程中过载情况的直接反应, 在着陆安全分析中, G 值通常是描述落地瞬间安全性的重要指标。着陆瞬间 G 值指的是飞机接地瞬间前 2 秒和后 5 秒数据的最大 G 值。

1.2 问题提出

问题 1: 有些 *QAR* 数据存在错误, 需要对数据进行预处理, 去伪存真, 以减少错误数据对研究分析带来的影响。请你们的队伍对附件 1 的数据质量开展可靠性研究, 提取与飞行安全相关的部分关键数据项, 并对其重要程度进行分析。

问题 2: 飞机在从起飞到着陆的整个飞行过程中, 通过一系列的飞行操纵确保飞行安全, 这些操纵主要包括横滚操纵、俯仰操纵等。目前, 国内航空公司通过超限监控飞行操纵动作, 这种监控方法虽然能够快速分辨出飞机的状态偏差, 但是只能告诉安全管理人员发生了什么, 而不能立刻得出发生这种偏差的原因。为此, 可以通过操纵杆的过程变化情况分析产生这种偏差的原因。根据附件 1, 请你们对飞行操纵进行合理量化描述。下图为 3 次着陆过程中的杆位变化曲线, 其中红色曲线描述了一次重着陆 (着陆 G 值超过给定限制值) 过程, 该重着陆主要是由于飞行机组在低空有一次不当松杆操纵所致, 红色曲线中的接地前 5 秒有一个明显下凸, 这就是需要进行量化描述的一次松杆操纵。




图 1.1 杆位随时间变化曲线图

问题 3: 导致不同超限发生的原因各不相同,有时是特定机场容易出现特定的超限,有时是特定的天气容易出现特定的超限,有时是特定的飞行员容易出现特定的超限。请研究附件 2 的数据,对超限的不同情况进行分析,研究不同超限的基本特征,如分析飞机在哪些航线或者在哪些机场容易出现何种超限等。

问题 4: 飞机运行数据的研究一般分为两大类,一类是通过航线运行安全检查(*Line Operations Safety Audit, LOSA*)获取的飞行员的运行表现,另外一类是根据相关学者建议,基于飞行参数开展飞行技术评估。根据附件 3,请你们建立数学模型,探讨一种基于飞行参数的飞行技术评估方法,分析飞行员的飞行技术,数据表中的“不同资质”代表飞行员的不同技术级别。

问题 5: 随着技术的进步,未来在民航客机上安装实时传输的 *QAR* 数据记录系统已成为可能,这种“实时飞行数据”技术,可以在接近实时的情况下把航班飞行数据传输到地面分析系统,极大地提高风险识别能力和预防水平。假设飞行数据已能实现陆空实时传输,如果你是该航空公司的安全管理人员,请建立航空公司实时自动化预警机制,预防可能的安全事故发生,结合附件 1 的数据,给出仿真结果。

二、 问题分析

2.1 问题 1 的分析

(1) 数据预处理。包括缺失值的填补、重复值的删除、定类数据是否需要进亚量化等。观察和分析表中数据,在数据预处理时对表中的定类数据如: *DOWN*、*TURE*、*FALSE* 做删除处理。

(2) 采用聚类算法和箱型图。数据预处理中的异常值处理还没有进行,由于箱型图可以以一种相对稳定的方式描述数据的离散分布情况,直观明了地识别异常数据。故选用箱型图来进行异常值的查找。但由于飞机加速极快,箱型图处理后出现大量异常值(如空速、地速),这显然不适用于之后的问题处理。故采用分治的思想,利用 *K-Means* 聚类算法,通过数据之间的内在关系把样本划分为若干类别,使得同类别样本之间的相似度高,不同类别之间的样本相似度低。聚类后再利用箱型图,找出异常数据并利用插值法进行填补。

(3) 用变异系数进行可信度研究。变异系数可以比较两组数据离散程度,如果两组数据的测量尺度相差太大,或者数据量纲的不同,直接来进行比较不合适,此时就应

当消除测量尺度和量纲的影响。变异系数是原始数据标准差与原始数据平均数的比，越大，稳定性越差，越不可靠，如果变异系数大于 15%，则要考虑该数据可能不正常，应该剔除。

(4) 用主成分分析法进行降维，提取关键数据并分析重要程度。主成分分析是对于原先提出的所有变量，将重复的变量关系紧密的变量删去多余，建立尽可能少的新变量，使得这些新变量两两不相关，而且这些新变量在反映课题的信息方面尽可能保持原有的信息。

2.2 问题 2 的分析

(1) 确定量化对象。本小问的主要任务是将操纵杆的变化过程和发生这种偏差的原因联系起来。即当飞行员操纵飞机出现偏差时，不仅能知道发生了偏差，还能知道是什么操作引起了偏差。

(2) 单位根检验。如果飞机的飞行数据总体平稳，即代表没有发生太大的偏差。故对 G 值、杆量、盘量等数据进行单位根检验，若不平稳或平稳性较弱，则分析量化他们之间的联系。

(3) 建立差分模型。利用差分模型过滤掉数据噪声，分析是什么操作影响了 G 值。

2.3 问题 3 的分析

(1) 数据清洗。清洗附件二数据，查找是否包含缺失值、异常值或无效数据，针对问题数据进行分析，判断是否可删除或者插补。

(2) 描述性统计分析。根据题目与数据的分析，将对超限的不同情况分为 1、针对特定机场分析，2、针对特定天气分析。分别对上述两种情况进行基于频数的统计分析。

2.4 问题 4 的分析

(1) 数据预处理。运用 *python* 对附件三整体数据进行预处理，运用 *Pandas* 库中的函数进行查重去重，查缺补缺，查找并删除异常值并用插值法处理。

(2) 主成分降维。由于附件三数据过于庞大，易对后续分析产生较大误差，故将清洗后的数据作主成分降维处理，方便后续的预测。

(3) 建立 *XGBoost* 回归预测模型，并运用启发式算法。通过粒子群优化算法 (*PSO*) 对 *XGBoost* 回归预测模型进行参数优化，将原始数据按 7: 3 划分为训练集与测试集，

并进行交叉验证，从而得到拟合图像和模型指标。

2.5 问题 5 的分析

(1) 构建自动化预警机制，将杆量与盘量作为自变量反映 G 值，通过 PSO 算法优化后的 BP 神经网络回归模型构建相关性，并将与预测偏差 5% 以外的真实值视为超限数据。

(2) 设计具体流程完善自动化预警机制，并对附件一进行仿真分析。

三、 模型假设

1、假设飞机不遭受突然的恶劣天气等环境因素影响

2、独立性假设：模型假设不同样本之间相互独立，即模型对一个样本的预测不会受到其他样本的影响。

3、群体假设：算法将问题看作是一个群体，群体中每个个体（粒子）都可以通过群体中其他个体的信息来改变自己的行为。

4、簇的形状是球形的：K-means 算法假设每个簇的形状是球形的，并且每个簇具有相等的方差。

5、簇之间是独立的：K-means 算法假设每个簇之间是独立的，即簇之间的分离是相互独立的。

四、 符号说明

符号	意义	单位
x_{ij}	第 <i>i</i> 个评价对象的第 <i>j</i> 个指标的取值	\
$\widetilde{x}_{ij}$	各指标值 x_{ij} 标准化指标	\
r_{ij}	第 <i>i</i> 个指标与第 <i>j</i> 个指标的相关系数	\
y_m	第 <i>m</i> 主成分	\
λ_j	主成分分析特征值	\
b_j	主成分 y_j 的信息贡献率	\
α_p	前 <i>p</i> 个指标变量 $y_1, y_2, \dots, y_p$ 的累计贡献率	\
Δx_k	函数 x_k 的一阶差分	\
$y_i^{(t-1)}$	<i>t</i> -1个学习器对 <i>i</i> 样本的预测值	\
X_{id}	第 <i>i</i> 个粒子的位置	\
V_{id}	第 <i>i</i> 个粒子的速度	\
$P_{id,pbest}$	第 <i>i</i> 个粒子搜索到的最优位置	\
$P_{id,gbest}$	群体中搜索到的最优位置	\
f_p	个体历史最优适应值	
f_g	群体历史最优适应值	\

五、 问题一模型的建立与求解

5.1 *K-Means*聚类算法的运用

5.1.1 聚类的必要性说明

在未聚类前对计算空速绘制箱型图，对计算空速和地速做箱型图，其绘制结果如图 5.1 所示。




图 5.1 不合理的箱型图

观察上图，可以明显发现计算空速和地速的箱型图不合理，离群点太多。结合计算空速的散点图可发现，由于飞机的加速很快，状态很快发生变化，故需要采取聚类算法，通过对一组对象进行分组的任务，使得同一组中的对象与组中的其他对象在某种意义上更相似。便于我们找出合理的、正确的离群点。




图 5.2 计算空速散点图

5.1.2 *K-Means*聚类原理

K-Means 的核心目标是将给定的数据集划分成 K 个簇（ K 是超参），并给出每个样本数据对应的中心点。具体步骤非常简单，可以分为 4 步：

随机选取 K 个中心，记为 $\mu_1^{(0)}, \mu_2^{(0)}, \dots, \mu_k^{(0)}$

定义损失函数： $J(c, \mu) = \min \sum_{i=1}^M \|x_i - \mu_{c_i}\|^2$

令 $t=0,1,2,\dots$ 为迭代步数，重复如下过程直到 J 收敛

1、对于每一个样本 x_i ，将其分配到距离最近的中心

$$c_i^t \leftarrow \operatorname{argmin}_k \|x_i - \mu_k^t\|^2$$

2、对于每一个类中心 k ，重新计算该类的中心

$$\mu_k^{t+1} \leftarrow \operatorname{argmin}_\mu \sum_{i:c_i^t=k}^b \|x_i - \mu_k^t\|^2$$

5.1.3 分析步骤及结果

通过查找文献和数据，我们将飞机从起飞到降落大致分为 4 个阶段，即地面滑行、起飞离场、加速爬升、巡航（将落地减速阶段等同于起飞加速阶段）。下面以计算空速这列数据为例，对其进行聚类。

（1）根据字段进行聚类类别差异性分析。

表 5.1 字段差异性分析表

	聚类类别（平均值±标准差）				F	P
	类别 3(n=21868)	类别 1(n=15022)	类别 2(n=1324)	类别 4(n=458)		
计算空速	287.423±8.428	304.162±4.832	31.445±7.638	178.924±29.172	521419.73	0.000386

上表展示了定量字段差异性分析的结果，包括均值±标准差的结果、F 检验结果、显著性 P 值。

若 $P < 0.05$ ，呈显著性，拒绝原假设。则对于变量计算空速，显著性 P 值为 0.000386，水平上呈现显著性，拒绝原假设，说明变量计算空速在聚类分析划分的类别之间存在显著性差异。

（2）聚类结果。

表 5.2 聚类汇总表

聚类类别	频数	百分比%
聚类类别_1	15022	38.845
聚类类别_2	1324	3.424
聚类类别_3	21868	56.547
聚类类别_4	458	1.184
合计	38672	100.0




图 5.3 聚类分布图

其聚类中心坐标可以用于分析各样本与中心点的距离如下图。

表 5.3 聚类种类中心值

聚类种类	中心值_计算空速	飞行阶段
1	304.16188756490163	巡航
2	31.44524169184018	地面滑行
3	287.4226952624851	起飞离场
4	178.92412663755437	加速爬升

结合飞机实际飞行情况，本划分方式比较合理。

(1) 评价指标分析

表 5.4 评价指标数值表

轮廓系数	DBI	CH
0.642	0.402	521419.73

各评价指标含义如下：

1、轮廓系数：对于一个样本集合，它的轮廓系数是所有样本轮廓系数的平均值。轮廓系数的取值范围是 $[-1,1]$ ，同类别样本距离越相近不同类别样本距离越远，分数越高，聚类效果越好。

2、DBI (Davies-bouldin)：该指标用来衡量任意两个簇的簇内距离之后与簇间距离之比。该指标越小表示聚类效果越好。

3、CH(Calinski-Harbasz Score)：通过计算类内各点与类中心的距离平方和来度量类内的紧密度（分母），通过计算类间中心点与数据集中心点距离平方和来度量数据集的分离度（分子），CH 指标由分离度与紧密度的比值得到，CH 越大表示聚类效果越好。

DBI=0.42,数值较小；CH=521419.73，数值很大。综上，K-Means 聚类效果较好。

5.2 变异系数检验可靠性

5.2.1 变异系数原理

$$(CV)_I = \frac{\delta_i}{\bar{x}_i}$$

其中， δ 为标准差， $\bar{x}$ 为平均数

从公式可以发现，CV 代表数据沿着平均值波动的幅度比例，该值越大意味着波动性越大，而且该种波动性是以平均值作为标准，也就解决掉了量纲化问题。并不会因为某些数据特别大，变异系数就失去意义。简而言之，即变异系数 CV 值是一种相对波动的衡量指标。如果变异系数越大，说明其携带的信息越大，因而权重也会越大，评价差异越大。

5.2.2 权重计算结果

表 5.5 权重计算结果表

项	平均值	标准差	CV 系数	权重(%)
ALTITUDE (1013)	32824.084	1715.377	0.052	-0.044
Inertial Vertical Speed	-28.71	267.227	-9.308	7.816
RADIO ALT	866.629	1005.835	1.161	-0.975
COMPUTED AIR SPD	297.944	7.061	0.024	-0.02
GROUNDSPEED	449.02	18.108	0.04	-0.034
COG NORM ACCEL	0.999	0.014	0.014	-0.012
COG NORM ACCEL	0.999	0.014	0.014	-0.011
COG NORM ACCEL	0.999	0.014	0.014	-0.012
COG NORM ACCEL	0.999	0.014	0.014	-0.012
COG NORM ACCEL	0.999	0.014	0.014	-0.012
COG NORM ACCEL	0.999	0.014	0.014	-0.012
COG NORM ACCEL	0.999	0.014	0.014	-0.011
COG NORM ACCEL	0.999	0.014	0.014	-0.012
COG NORM ACCEL	0.999	0.014	0.014	-0.012
COG NORM ACCEL	0.999	0.014	0.014	-0.011
PITCH ATT	2.443	0.41	0.168	-0.141
PITCH ATT	2.443	0.41	0.168	-0.141

PITCH ATT	2.443	0.41	0.168	-0.141
PITCH ATT	2.443	0.41	0.168	-0.141
PITCH ATT	2.443	0.41	0.168	-0.141
CAP CLM 1 POSN	-0.001	0.001	-0.995	0.836
CAP CLM 1 POSN	-0.001	0.001	-0.997	0.837
CAP CLM 1 POSN	-0.001	0.001	-1.006	0.845
CAP CLM 1 POSN	-0.001	0.001	-1.015	0.852
CAP CLM 1 POSN	-0.001	0.001	-1.02	0.856
ROLL ATT	-0.11	1.691	-15.361	12.899
ROLL ATT	-0.11	1.69	-15.391	12.924
CAP WHL 1 POSN	-0.003	0.013	-5.056	4.246
CAP WHL 1 POSN	-0.003	0.013	-5.06	4.249
CAP WHL 1 POSN	-0.003	0.013	-5.047	4.238
CAP WHL 1 POSN	-0.003	0.013	-5.04	4.232
CAP WHL 1 POSN	-0.003	0.013	-5.053	4.243
N1 SELTED-L	83.506	2.892	0.035	-0.029
N1 SELTED-R	83.507	2.892	0.035	-0.029
MAGNETIC HEADING	275.05	38.873	0.141	-0.119
WIND DIR(ADIRU)	262.063	63.27	0.241	-0.203
WIND SPD(ADIRU)	46.898	22.382	0.477	-0.401
TRA-L	59.2	2.288	0.039	-0.032
TRA-L	59.2	2.288	0.039	-0.032
TRA-R	59.2	2.291	0.039	-0.032
TRA-R	59.2	2.291	0.039	-0.032
RUDD POSN	-0.267	0.011	-0.043	0.036
GLIDESLOPE DEV Dots (C)	-0.117	0.527	-4.496	3.775
GLIDESLOPE DEV Dots (L)	-0.097	0.411	-4.245	3.565
GLIDESLOPE DEV Dots	-0.106	0.459	-4.311	3.62

(R)				
LOCALIZER DEV Dots (C)	-0.082	0.932	-11.434	9.602
LOCALIZER DEV Dots (L)	-0.085	0.934	-11.012	9.247
LOCALIZER DEV Dots (R)	-0.073	0.917	-12.509	10.504
PITCH ATT RATE	-0.028	0.057	-2.049	1.721
PITCH ATT RATE	-0.028	0.057	-2.049	1.721
FMF GROSS WEIGHT	303822.014	21847.66 9	0.072	-0.06

上表展示了变异系数法的权重计算结果，根据结果对各个指标的权重进行分析。变异系数是相对数形式表示的变异指标。它是通过变异指标中的全距、平均差或标准差与平均数对比得到的，权重是信息量的归一化。

由上表可以明显看出，坡度（ROLL ATT）、航向道偏差（LOCALIZER DEV Dots）、下降率（Inertial Vertical Speed）的权重较大，比较不可靠。

5.3 箱型图去异常值及插值法填补

5.3.1 箱型图原理及特点

箱形图又称为盒须图、盒式图、盒状图或箱线图，是一种用作显示一组数据分散情况资料的统计图。常用于品质管理，快速识别异常值。箱形图最大的优点就是不受异常值的影响，能够准确稳定地描绘出数据的离散分布情况，同时也利于数据的清洗。其原理示意图如下。




图 5.4 箱型图原理示意图

箱线图判断异常值的标准以四分位数和四分位距为基础，四分位数具有一定的耐抗性，多达 25% 的数据可以变得任意远而不会很大地扰动四分位数，所以异常值不会影响箱形图的数据形状，箱线图识别异常值的结果比较客观。由此可见，箱线图在识别异常

值方面有一定的优越性。

5.3.2 箱型图去除异常值

将附件一中的数据通过 K-Means 聚类算法划分出四个阶段,再用箱型图进行异常值的查找及删除。下面以着陆 G 值为例,箱型图处理结果如下:




表 5.5 箱型图处理效果图

如上图所示,箱型图处理结果良好,可以直观明了地识别数据中的异常值。

5.4 分段插值法填补异常值

5.4.1 分段插值法的原理及实现

Hermite 插值是指对于一个 $n+1$ 个节点的插值问题,要求在给定的节点处,插值多项式的函数值与节点的函数值相等。同时插值多项式的一阶甚至到指定高阶的导数值,也与该节点相应阶导数值相同。

插值多项式应满足:

$$\begin{cases} H(x_i) = y_i \\ H'(x_i) = y'_i \end{cases}$$

其中, $i = 0, 1, 2, \dots, n$ 且在每个子区间 $[x_{i-1}, x_i]$ 上, $H_{(x)}$ 均是三次多项式,可分段表示为;

$$\begin{cases} s_1(x) & x \in [x_0, x_1] \\ s_2(x) & x \in [x_1, x_2] \\ \dots & \dots \\ s_k(x) & x \in [x_{k-1}, x_k] \end{cases}$$

其中 $s_{k(x)}$ 是关于节点 x_{k-1}, x_k , 且满足插值条件 (两节点处的函数值以及导数值均与

原函数对应相等)的三次代数多项式。

运用上述方法补全删掉的异常值即可。

5.5 主成分分析模型提取关键参数

5.5.1 插值法的选择

高次插值会产生龙格现象,即在两端处波动极大,产生明显的震荡。龙格现象是指在计算方法中,有利用多项式对某一函数的近似逼近,计算相应的函数值。一般情况下,多项式的次数越多,需要的数据就越多,而预测也就越准确。插值次数越高,插值结果越偏离原函数的现象称为龙格现象。

拉格朗日插值、牛顿插值、Hermite 插值都会存在龙格现象的问题,所以采用分段插值来避免这种现象。

5.5.2 主成分分析模型 (PCA) 的建立

主成分分析法是利用降维的思想,在损失很少信息的前提下把多个指标转换为几个综合指标的多元统计方法。转换成的综合指标被称为主成分,其中每个主成分都是原始变量的线性组合,且各个主成分之间互不相关,这就使得主成分比原始变量具有某些更优越的性能。下面通过 SPSS 数据分析软件对数据预处理后的附件一和附件二进行主成分分析。

(1) 原始数据标准化

在进行主成分分析前,需要将原始数据标准化,以消除量纲的影响。

假设进行主成分分析的指标变量有 m 个: $x_1, x_2, \dots, x_m$, 共有 n 个评价对象,第 i 个评价对象的第 j 个指标的取值为 x_{ij} 。将各指标值 x_{ij} 转换成标准化指标 $\widetilde{x}_{ij}$:

$$x_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j} \quad (i=1,2, \dots, n; j=1,2, \dots, m)$$

其中

$$\bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}$$

$$s_j = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2 \quad (j=1,2, \dots, m)$$

即 $\bar{x}_j, s_j$ 为第 j 个指标的样本均值和样本标准差。

对应的,称 $\widetilde{x}_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$, $(i=1,2, \dots, n)$ 为标准化指标变量。

(2) 建立相关系数矩阵 R

表 5.6 KMO 检验和 Bartlett 的检验表

KMO 检验和 Bartlett 的检验		
KMO 值		0.823
	近似卡方	3468930.3
Bartlett 球形度检验	df	703
	P	0.000241

上表展示了 KMO 检验和 Bartlett 球形检验的结果,用来分析是否可以进行分析。

若通过 KMO 检验 ($KMO>0.6$) , 说明了题项变量之间是存在相关性的, 符合主成分分析要求。若通过 Bartlett 检验: $P<0.05$, 呈显著性, 则可以进行主成分分析。

KMO 检验的结果显示, KMO 的值为 0.823, 同时, Bartlett 球形检验的结果显示, 显著性 P 值为 0.000241, 水平上呈现显著性, 拒绝原假设, 各变量间具有相关性, 主成分分析有效, 程度为适合。

2、主成分分析过程

(1) 从相关矩阵出发求解主成分

表 5.7 主成分结果

总方差解释			
成分	特征根		
	特征根	方差解释率(%)	累积方差解释率(%)
1	8.109	21.34	21.34
2	6.041	15.897	37.237
3	4.638	12.204	49.441
4	3.865	10.17	59.611
5	3.178	8.363	67.974
6	2.022	5.322	73.295
7	1.381	3.633	76.928
8	0.913	2.404	79.332
9	0.827	2.176	81.508
10	0.8	2.106	83.614

由表 5.7 可知, 在主成分 8 时, 总方差解释的特征根低于 1.0, 变量解释的贡献率达

到 79.332%，说明提取的 8 个主成分能够代表原来 51 个财务指标信息的 79.332%，所提取的主成分评价飞行安全已有一定的把握。因此，提取 8 个主成分，分别为 $y_1, y_2, \dots, y_8$ 。

(2) 计算主成分系数及提取关键数据项

根据 8 个主成分系数，得到 $y_1, y_2, \dots, y_8$ 的线性组合。

由于变量太多，线性组合中所有其他系数较小的用“+其它”来表示，下面直接对每个主成分进行分析。

在主成分 Y_1 中， $Y_1 = 0.10743754447881014 \times \text{PITCH ATT} + 0.10730547493734104 \times \text{PITCH ATT.1} + 0.10716532582942141 \times \text{PITCH ATT.2} + 0.10703840378692402 \times \text{PITCH ATT.3} + 0.10691139765412298 \times \text{PITCH ATT.4} + 0.10493073807334709 \times \text{N1 SELTED-L} + 0.10491694572977019 \times \text{N1 SELTED-R} + \text{其它}$

姿态（俯仰角）（一秒记录五次，分别记为 PITCH ATT 0、PITCH ATT 1、PITCH ATT 3、PITCH ATT 4）和 左、右侧发动机油门 N1 值（N1 SELTED-L、N1 SELTED-R）的系数绝对值大于其他变量的系数绝对值，所以主成分 Y_1 是对姿态、发动机油门 N1 值指标的综合反映，姿态（俯仰、滚转和偏航）代表飞机的控制能力。通过改变姿态，飞行员可以控制飞机的方向、高度和速度等参数；

发动机油门值代表飞机的动力能力。通过调整油门值，飞行员可以控制飞机的速度和爬升或下降的能力。发动机油门值还可以影响飞机的燃油消耗和航程等因素。它代表飞行的控制能力，是考察飞机安全的重要指标，姿态控制越好，爬升下降控制越稳定，安全性越高。

同理，在主成分 Y_2 中，着陆 G 值 0.1 秒（一秒记录 10 次，分别记为 COG NORM ACCEL、COG NORM ACCEL1、...、COG NORM ACCEL9）的系数绝对值大于其他变量的系数绝对值，所以主成分 Y_2 是对着陆 G 值的综合反应，着陆 G 值是指飞机在着陆过程中所承受的重力加速度，反映了飞机的承载能力以及降落的平稳性。承载能力越高、降落越平稳，安全性越高。

同理，在 Y_3 中，盘量（CAP WHL 1 POSN）的系数绝对值大于其他变量的系数绝对值，盘量是飞机在水平面内向左或向右倾斜的角度，反映了飞机的转弯能力。

同理，在 Y_4 中，杆量（CAP CLM 1 POSN）的系数绝对值大于其他变量的系数绝对值，杆量是飞机在垂直于地面的平面内向上或向下倾斜的角度，反映了飞机的攀升和下

降能力。

同理，在 Y_5 中，海拔高度（ALTITUDE (1013)）、下降率（Inertial Vertical Speed）、计算空速（COMPUTED AIR SPD）、地速（GROUNDSPEED）的系数绝对值大于其他变量的系数绝对值，海拔高度反映了飞机的飞行高度以及对于氧气供应的需求，下降率反映了飞机在下降过程中的控制能力，计算空速及地速反映了飞机的飞行速度以及空气动力学的影响以及飞机的实际飞行速度以及气流对飞机的影响。

同理，在 Y_6 中，坡度（ROLL ATT）的系数绝对值大于其他变量的系数绝对值，反映了飞机的平稳性和转弯半径。

同理，在 Y_7 中，无线电高度（RADIO ALT）的系数绝对值大于其他变量的系数绝对值，反映了飞机在着陆过程中离地面的高度，以及是否满足安全的着陆标准。

同理，在 Y_8 中，着陆 G 值（COG NORM ACCEL）的系数绝对值大于其他变量的系数绝对值，上面已经分析，不在赘述。

六、 问题二模型的建立与求解

6.1 量化对象的确立

飞行员通过一系列的飞行操纵确保飞行安全，这些操纵主要包括横滚操纵、俯仰操纵等。通过观察附件一中的数据，发现杆量辩护可以反映俯仰操纵，盘量变化可以反映横滚操纵。

在着陆安全分析中，G 值通常是描述落地瞬间安全性的重要指标。着陆瞬间 G 值指的是飞机接地瞬间前 2 秒和后 5 秒数据的最大 G 值。所以下面我们结合杆量，盘量，着陆 G 值做量化分析。时间跨度为飞机放下起落架后至落地时间段的 15 秒。

6.2 单位根（ADF）检验原理

很多变量之所以难以估计，是因为这些变量经常发生突变，不是平稳的时间序列。通过单位根检验法判断是否为平稳序列。如果序列平稳，就不存在单位根；否则，就会存在单位根。ADF 检验的 H_0 假设就是存在单位根，如果得到的显著性检验统计量小于三个置信度（10%，5%，1%），则对应有（90%，95，99%）的把握来拒绝原假设。

$$\begin{cases} H_0: \text{数据不平稳} \\ H_1: \text{数据平稳} \end{cases}$$

6.3 差分模型的建立

设函数 $x_k = x_{(k)}$, k 取非负整数, 称改变量 $x_{(k)} - x_k$ 为函数 x_k 的差分, 也称函数 x_k 的一阶差分, 记 Δx_k

一阶差分的差分称二阶差分, $\Delta^2 x_k$, 即

$$\Delta^2 x_k = \Delta x_{k+1} - \Delta x_k = x_{k+2} - 2x_{k+1} + x_k$$

含有未知函数 x_k 的差分的方程称差分方程, 差分方程中所含未知函数差分的最高阶数称差分方程的阶, 如 n 阶差分方程形式为

$$F(k, x_k, \Delta x_k, \Delta^2 x_k, \dots, \Delta^n x_k) = 0$$

6.4 ADF检验及差分结果

下面以附件一表 1 “201404070532.xls”为例, 对盘量、杆量、G 值。ADF 检验如下图。

表 6.1 ADF 检验表

变量	差分阶数	t	P	AIC	临界值		
					1%	5%	10%
盘量	0	-8.362	0.000314	-2869.497	-3.438	-2.865	-2.569
	1	-10.14	0.000543	-2824.685	-3.438	-2.865	-2.569
	2	-13.171	0.000652	-2743.664	-3.438	-2.865	-2.569

上表格为 ADF 检验的结果, 包括变量、差分阶数、T 检验结果、AIC 值等, 用于检验时间序列是否平稳

临界值 1%、5%、10%不同程度拒绝原假设的统计值和 ADF Test result 的比较, ADF Test result 同时小于 1%、5%、10%即说明非常好地拒绝该假设。若 $P < 0.05$, 则说明拒绝原假设, 该序列为一个平稳的时间序列, 反之则说明该序列为一个不平稳的时间序列。AIC 值是衡量统计模型拟合优良性的一种标准, 数值越小越好。

由上表可知, 盘量属于弱平稳序列, 同样的, 经过 ADF 检验, 发现杆量和着陆 G 值也是弱平稳序列。从起飞到降落的时间段里, 它们的原始图、一阶差分图、二阶差分

图如下：




图 a 盘量差分图




图 b 杆量差分图




图 c 着陆 G 值差分图

图 6.1 差分图

6.5 量化描述飞行操纵

观察上述变量的差分图，发现绝大部分波动都靠近尾部即降落阶段。同时依据题意，在着陆时，容易产生重着陆，造成着陆 G 值过大的现象，故下面仍以表 1 为例，节选着陆前的 5 秒，着陆后的 2 秒进行对比观察分析。下面仍以表 1 做例分析，着陆 G 值（COGNORMACCEL）、杆量（CAPCLM1 POSN）、盘量（CAPWHL1 POSN）的变化情况如下：




图 6.2 着陆 G 值差分图

通过观察可以发现，A 处 G 值过大的同时杆量变化较大，同样的 B 出，G 值过小的同时杆量变化很大，故可得出结论，此两处的操纵原因分别是松杆过快和推杆过快。

同样的，另外 7 个表的变化情况如下：




图 a 盘量差分图




图 b 杆量差分图




图 c 盘量差分图




图 d 杆量差分图




图 e 盘量差分图




图 f 杆量差分图




图 g 着陆 G 值差分图

图 6.3 放大差分图

通过观察分析，发现 *C*、*E*、*G*、*I*、*L* 着陆 *G* 值一般大于等于 1.05,且此时杆量增加，盘量减小，对应描述了一次重着陆（着陆 *G* 值超过给定限制值）过程，该重着陆主要是由于飞行机组在低空有一次不当松杆操纵所致。

D、*F*、*H*、*J*、*K* 处 *G* 值减小，着陆 *G* 值一般小于等于 -0.95，且此时杆量减小，盘量增大对应原因主要是由于有一次不当推杆操纵。

七、 问题三模型的建立与求解

7.1 数据预处理

飞行阶段无效数据占总体数据比例 1.9%，而超限名称无效数据占总体数据的 1.2%，远小于 3%。故为避免对后续研究产生影响且方便数据处理与分析，本文在考虑飞行阶段与超限名称时，将无效数据删除。

7.2 描述性统计分析

根据问题描述与所给数据，将超限原因分为以下两种：

- (1) 特定机场容易出现特定的超限；
- (2) 特定天气容易出现特定的超限。

7.3 针对特定机场分析

(1) 机场分析

单独分析起飞机场与目的机场，如图 3 所示，接近 50%超限情况机场 68。具体情况如下：

- 1. 起飞机场为机场 68 时，目的机场为机场 89 最容易出现超限情况；
- 2. 目的机场为机场 68 时，起飞机场为机场 89 最容易出现超限情况。




图 a 起飞机场分析




图 b 目的机场分析

图 7.1 机场频率统计分析

(2) 超限情况

分别对起飞机场为机场 68，目的机场为机场 68 作统计频率分析，分析结果如下图：




图 7.2 起飞机场 68 超限情况频率统计分析




图 7.3 目的机场 68 超限情况频率统计分析

由图可知，“50 英尺至接地距离远”“爬升速度大 35-1000ft”“接地速度小”三种超限情况分别占总数的 83.51%、84.65。其中“50 英尺至接地距离远”占比最大，分别为 39.96%、36.02%；在目的机场为机场 68 时，“爬升速度大 36-1000ft”占比为 26.36%，大于起飞机场与总体占比。

(3) 飞行阶段

如图 4，不论起飞机场或者目的机场，在机场 68 时，“着陆”“空中”“进近”飞行阶段下出现超限情况较多，分别占总数的 98.27%、97.72%。而在“50 英尺至接地距离远”情况下，超限情况基本完全出现在着陆过程中，如图 5。




图 a 目标机场 68 飞行阶段分析




图 b 起飞机场 68 飞行阶段分析

图 7.4 飞行阶段频率统计分析




图 7.5 “50 英尺至接地距离远” 超限情况下飞行阶段

(4) 机号分析

通过图 6 可以看出，出现超限的飞机超过了总体的 50%，而这 50%的飞机承担超限总数超 90%.故可得出，超限情况与机号相关性不高。




图 a 总体机号超限情况矩形树图




图 b 总体机号超限情况帕累托图

图 7.6 总体机号统计分析

（5）结论

通过上述分析可得，大多数飞机均会出现超限情况，且若飞机的起飞或目标机场为机场 68，则极其容易在着陆过程中出现“50 英尺至接地距离远”“爬升速度大 35-1000ft”“接地速度小”的超限问题。

3.2.2 针对特定天气分析

将月份按季节划分为四个区间：

- (1) 3、4、5 月：春季；
- (2) 6、7、8 月：夏季；
- (3) 9、10、11 月：秋季；
- (4) 12、1、2 月：冬季。

不同季节出现超限情况频率如图：




图 7.7 不同季节出现超限情况频率

如图 5，春季与冬季出现超限情况较夏季与秋季较多，而春季多风，冬季多雪，故大风天气与积雪天气容易出现超限情况。由图 6 可知，春冬季节容易出现“50 英尺至接地距离远”、“爬升速度大 35-1000ft”或“接地速度小”。




图 7.8 春冬容易出现的超限情况

3.2.3 分析结论

通过上述分析可得

- 1、大多数飞机均会出现超限情况；
- 2、若飞机的起飞或目标机场为机场 68，则极其容易在“着陆”“空中”“进近”飞行阶段出现“50 英尺至接地距离远”“爬升速度大 35-1000ft”“接地速度小”的超限问题；
- 3、“50 英尺至接地距离远”超限情况基本上出现在“着陆”飞行阶段；
- 4、春冬季的大风天气与积雪天气更容易出现“50 英尺至接地距离远”、“爬升速度大 35-1000ft”或“接地速度小”的超限情况。

八、 问题四模型的建立与求解

8.1 数据预处理

8.1.1 数据清洗

为保证样本数据的可用性和合理性，对附件 3 进行如下处理：

- (1) 查询重复值，利用 python 的 pandas 库 `drop_duplicates` 方法进行数据去重。
- (2) 查询缺失值与异常值，对于异常值进行删除，后寻找含缺失值的数据项，并将该数据项与删除异常值后的数据项进行 Hermite（埃尔米特）插值。
- (3) 剔除与研究分析飞行员飞行技术无关的相关变量，以及相关性较小的变量。
- (4) 在保证不影响研究分析飞行员飞行技术的前提下，剔除不利于模型构建与分析的数据项。
- (5) 剔除相关数据缺失过多（约 20%或 $\geq 20\%$ ）的数据列。
- (6) 在保证不影响研究分析飞行员飞行技术的前提下，剔除相关数据缺失并且不全数据较多的飞行员数据。

8.1.2 主成分降维

由于影响飞行员飞行技术的因素过多且数据量过于庞大，易对后续分析产生较大误差，故将清洗后的数据作主成分降维处理。

将总方差解释率设定为 85%，利用 SPSS26.0 进行数据降维，最终得出 4 个主成分。

8.2 XGBoost回归模型的建立

XGBoost 是一个隶属于集成学习模型的 Boosting 算法，在分类、回归和排名等监督学习任务上拥有最高效的性能，该算法已成为机器学习一个首选工具，其原因首当其冲的就是其出色的预测性能，高度优化的多核处理和分布式的机器实现，以及处理稀疏数据的能力。它本质上是一类提升树模型，集成许多弱分类器，以迭代的方式形成一个强分类器。其中 XGBoost 的决策树训练过程如图所示。




图 8.1 XGBoost 的决策树训练过程

通过构建多棵 *CART* 决策树来提供预测模型的准确性，最后将每轮训练得到决策树的预测结果求和得到最终的预测值。其第 t 棵 *CART* 决策树的目标函数定义如下^[3]:

$$L(x) = \sum_{i=1}^n l(y_i, y_i^{(t-1)} + f_t(x_i)) + \Omega(f_t)$$

其中:

$$\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \|w\|^2$$

n 为样本总数, $y_i^{(t-1)}$ 为 $t-1$ 个学习器对 i 样本的预测值, $f_t(x_i)$ 为新加入的第 t 个学习器, $\Omega(f_t)$ 为正则项。

运用泰勒公式对目标函数进行展开

$$f(x + \Delta x) = f(x) + f'(x)\Delta x + \frac{1}{2} f''(x)\Delta x^2$$

损失函数的二阶泰勒展开结果为

$$\sum_i L(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) = \sum_i L(y_i, \hat{y}_i^{(t-1)}) + L'(y_i, \hat{y}_i^{(t-1)}) f_t(x_i) + \frac{1}{2} L''(y_i, \hat{y}_i^{(t-1)}) f_t^2(x_i)$$

将 g_i 记为第 i 个样本损失函数的一阶导数, h_i 记为第 i 个样本损失函数的二阶导数

$$g_i = L'(y_i, \hat{y}_i^{(t-1)})$$

$$h_i = L''(y_i, \hat{y}_i^{(t-1)})$$

在进行特征节点选择时, 遍历训练集所有特征变量的取值, 用节点分裂前的目标函数值减去分裂后 2 个叶子节点的目标函数值之和, 计算增益值, 得到树模型最优的切分点, 其中增益值计算式为:

$$L_{split} = \frac{1}{2} \left[\frac{(\sum_{i \in I_L} g_i)^2}{\sum_{i \in I_L} h_i + \lambda} + \frac{(\sum_{i \in I_R} g_i)^2}{\sum_{i \in I_R} h_i + \lambda} + \frac{(\sum_{i \in I} g_i)^2}{\sum_{i \in I} h_i + \lambda} \right] - \gamma$$

分别将附件三主成分降维后的数据，按照 7: 3 的比例划分为训练集与测试集，交叉验证 K 值取 5 折，导入 *XGBoost* 模型，从而完成模型的构建。

8.3 粒子群优化算法（PSO）的建立

8.3.1 模型初始化

设置最大迭代次数，目标函数的自变量个数，粒子的最大速度，位置信息为整个搜索空间，我们在速度区间和搜索空间上随机初始化速度和位置，设置粒子群规模为 N，每个粒子随机初始化一个飞翔速度。

假设在 D 维空间中：

- (1) 第 i 个粒子的位置为： $X_{id}=(X_{i1},X_{i2},\dots,X_{iD})$
- (2) 第 i 个粒子的速度（粒子移动的方向）为： $V_{id}=(V_{i1},V_{i2},\dots,V_{iD})$
- (3) 第 i 个粒子搜索到的最优位置（个体最优解）为： $P_{id,pbest}=(p_{i1},p_{i2},\dots,p_{iD})$ ，其中 p 指的是 Particle（粒子）
- (4) 群体中搜索到的最优位置（群体最优解）为： $P_{id,gbest}=(p1,gbest, p2,gbest,\dots,pD,gbest)$ ，其中 g 指的是 Group（群体）
- (5) 第 i 个粒子搜索到的最优位置的适应值（优化目标函数的值）为： fp ——个体历史最优适应值
- (6) 群体中搜索到的最优位置的适应值为： fg ——群体历史最优适应值

定义适应度函数

需要优化的目标函数为：

$$L(x) = \sum_{i=1}^n l(y_i, y_i^{(t-1)} + f_t(x_i)) + \Omega(f_t)$$

8.3.2 算法步骤

- (1) 更新速度公式如下：
- (2) $v_{id}^{k+1} = wv_{id}^k + c_1r_1(p_{id,gbest}^k - x_{id}^k) + c_2r_2(p_{d,gbest}^k - x_{id}^k)$
- (3) 惯性权重：由惯性权重和粒子自身速度构成，表示粒子对先前自身运动状态的信任。
- (4) 认知部分：表示粒子本身的思考，即粒子自己经验的部分，可理解为粒子当

前位置与自身历史最优位置之间的距离和方向。

(5) 社会部分：表示粒子之间的信息共享与合作，即来源于群体中其他优秀粒子的经验，可理解为粒子当前位置与群体历史最优位置之间的距离和方向。

(6) 更新位置公式：

(7)
$$x_{id}^{k+1} = x_{id}^k + v_{id}^{k+1}$$

(8) 终止条件：当观察到超过一定次数且算法结果不再提升时。即粒子的平均位置变化很小时；粒子平均速度趋近于 0 时终止。

8.4 模型结果分析

通过基于粒子群优化算法优化后的 XGBoost 预测模型所得的预测结果如下表：

表. 8.1 粒子群优化后的预测表

预测结果 Y	落地主操控人员资质	预测结果概	预测结果概率	预测结果概	预测结果概	预测结果概率	预测结果概率
		率_A	_C	率_F	率_J	_M	_T
A	A	0.9022	0.0013	0.0245	0.0447	0.0261	0.0012
A	A	0.9424	0.0013	0.0262	0.0242	0.0053	0.0006
M	M	0.4235	0.0014	0.0533	0.0336	0.4870	0.0014
A	M	0.7531	0.0009	0.1735	0.0609	0.0107	0.0009
M	M	0.0920	0.0024	0.0274	0.0188	0.8582	0.0012
F	M	0.0524	0.0072	0.5382	0.3052	0.0933	0.0037
M	M	0.0174	0.0019	0.3874	0.0103	0.5820	0.0010
M	M	0.0500	0.0003	0.0333	0.0026	0.9136	0.0003
M	M	0.0039	0.0002	0.0637	0.0050	0.9269	0.0002
M	M	0.1308	0.0009	0.1753	0.0054	0.6867	0.0009
J	A	0.0093	0.0009	0.1384	0.8204	0.0301	0.0009
A	A	0.4331	0.0046	0.4174	0.1275	0.0151	0.0023
A	A	0.5479	0.0008	0.3408	0.0793	0.0304	0.0008
M	M	0.0527	0.0021	0.3062	0.0151	0.6230	0.0010

将 A、C、F、J、M、T 分别转化为 12、10、8、6、4、2，其可视化图形为：



R_Square	0.896984294
MAE	0.392573638
MSE	0.715361704
$RMSE$	0.845790579

图 8.2 粒子群优化后的预测图

其中 R^2 介于 0-1 之间，越接近 1，回归拟合效果越好； MAE 为平均绝对误差，能更好地反映预测值误差的实际情况； MSE 为均方误差，观测值与真值偏差的平方和，反应预测结果的精确度； $RMSE$ 为 MSE 的算术平方根，用来衡量观测值和真值之间的偏差。

此粒子群优化后的 $XGBoost$ 预测模型的 $R^2 = 0.897$ ， MAE 、 MSE 均较小，拟合效果良好，精确度较高。

九、 问题五模型的建立与求解

9.1 自动化预警机制的构建

9.1.1 实时预警模型的构建

1、BP 神经网络回归模型的建立

将杆量与盘量作为自变量，将 G 值作为因变量，本文用杆量与盘量反映 G 值。利用 SPSS 中 BP 神经网络工具包，并进行启发式算法寻优，将数据进行洗牌，训练集占比设置 70%，交叉验证为 5 折，如图。

模型参数设置

启用启发式算法寻优 ☒

选择寻优算法

PSO

PSO算法参数设置

初始粒子数

50

?

最大迭代次数

150

?

惯性权重

0.9

?

个体学习因子

2

?

社会学习因子

2

?

图 9.1 利用 PSO 对 BP 神经网络回归模型参数寻优
拟合结果图如下




图 9.2 利用杆量与盘量构建函数拟合 G 值

由下图可知， $R^2 > 0.85$ ，拟合效果良好，故模型建立有效。




图 9.3 BP 神经网络回归拟合结果

2、超限阈值的设定

将预测结果偏差 5% 范围内的值视为正常值，偏差大于 5% 的值视为超限操作。

9.1.2 总体流程设计

- 1、首先从飞机运行参数中获取 QAR 数据，筛选出关键参数；
- 2、将 QAR 数据进行 K-Means 聚类，分为不同阶段单独进行异常值筛查，若出现异常值，则进行预警；
- 3、从 QAR 数据中提取杆量与盘量进行 G 值预测，分析原本数据是否超过设定阈值；
- 4、若超过阈值，判断是否有松杆等操作，进行安全性判断，并进行预警。




图 9.4 总体流程设计

9.2 仿真分析结果

结合附件 1 进行仿真分析，部分结果如图所示，在点 11 位置，真实值超过预测值 5%，将该值视为超限数据。




图 9.5 仿真分析部分结果

十、模型的优缺点和推广

10.1 模型的优点

1.XGBoost 回归预测模型具有高度正确性，和对异常值和噪声数据具有较高的鲁棒性，可以很好的解决实际问题。

2.PSO 粒子群优化算法，具有高效性，全局搜索能力强，可以更好的进行模型调优，对初始值不敏感具有较好的鲁棒性。

3.变异系数可以快速比较数据集的离散性，高效了解数据的分布情况，并且无单位标准，便于数据分析和比较。

4.K-Means 聚类算法具有较好的可扩展性，适用于不同形态的数据。

5.PCA 模型通过降维减少特征数量，提高模型的效率和准确性，同时可以减少数据噪声的影响。

10.2 模型的缺点

1、XGBoost 模型比较复杂，参数过多，需要调整参数来获得最佳效果。

2、.K-Means 聚类算法对初始中心点的选择较为敏感，不同的初始点可能会得到不同的聚类结果。

3、PCA 模型在处理数据过程中，可能会损失一些数据信息，降低模型的准确性。

10.3 模型的改进与推广

自动化预警模型可以在多个领域进行推广，包括但不限于以下几个方面：

1、交通运输领域：自动化预警模型可以应用于航空、铁路、公路等交通运输领域，实时监测车辆或飞机等交通工具的运行状态，预测可能出现的安全风险并进行预警，以提高交通运输的安全性和效率。

2、金融领域：自动化预警模型可以应用于金融风险管理领域，对金融市场的波动、股票价格的变化、货币汇率的波动等进行实时监测，并预测可能出现的风险，为金融机构提供决策支持。

基于 PSO 优化的 XGBoost 回归预测模型可以通过以下方式进行推广：

1、商业合作：与相关企业或机构合作，将该模型应用于实际业务场景中。通过在实际应用中验证模型的可靠性和实用性，增加模型的可信度，同时也为商业合作提供了

新的机会。

2、教育培训：通过向学生、研究人员或从业人员提供相关的教育和培训课程，推广该模型的应用和发展，同时也为教育培训提供了新的案例和素材。

3、宣传推广：通过各种媒体、社交平台和宣传活动，向公众宣传和推广该模型，提高其知名度和影响力，同时也为科学普及做出贡献。

十一、 参考文献

[1] Saroj,Kavita.Review:study on simple k mean and modified K mean clustering technique[J].International Journal of Computer Science Engineering and Technology,2016,6(7): 279-281.

[2] 曹晓俊.对我国上市银行经营业绩的分析——基于主成分分析、因子分析和聚类分析的方法[J].宿州学院学报,2016,31(7):25-29.

[3] 刘盼盼,任广跃,段续,李琳琳,赵路洁,任星,苗峻伟.基于变异系数法对不同干燥方式白萝卜品质及风味的评价[J/OL].食品与发酵工业:1-11.

[4] 王燕. 应用时间序列分析[M]. 北京：中国人民大学出版社 2005.

[5] 王坤章,蒋书波,张豪,晁征.基于 XGBoost 的回归-分类-回归寿命预测模型[J/OL].中国测试:1-8[2023-04-17]

.

附录

附录 1

介绍：支撑材料的文件列表

差分处理.py
附件 1（2）.xlsx
附件 1 合集.xlsx
附件 1 数据预处理.py
平稳性检验.py
问题 2.xlsx
问题 2 具体分析.xlsx
问题 2 量化分析.py
箱型图.py

附录 2

介绍：附件 1 数据预处理

```
# 1.调包

import pandas as pd

import xlrd

import numpy as np


# 2.读取文件

df = pd.read_excel('附件 1 合集.xlsx')


# 3.查找有无缺失值并去除重复值

print(df.isna().sum())

print(df.duplicated())

df = df.drop_duplicates()
```

```
# 4.将处理后的数据导出
```

```
df.to_excel('附件 1 合集终版.xlsx')
```

附录 3

介绍：箱型图

```
# 提前导入各种软件包
```

```
import pandas as pd
```

```
import matplotlib.pyplot as plt
```

```
# 读取 excel 文件
```

```
file_01 = pd.read_excel("附件 1（2）.xlsx")
```

```
fig = plt.figure(figsize=(16, 8))
```

```
d1 = file_01['GEES1']
```

```
d2 = file_01['GEES2']
```

```
d3 = file_01['GEES3']
```

```
d4 = file_01['GEES4']
```

```
d5 = file_01['GEES5']
```

```
d6 = file_01['GEES6']
```

```
d7 = file_01['GEES7']
```

```
d8 = file_01['GEES8']
```

```
d9 = file_01['GEES9']
```

```

d10 = file_01['GEES10']

label = 'G1', 'G2', 'G3', 'G4', 'G5', 'G6', 'G7', 'G8', 'G9', 'G10'

plt.boxplot([d1, d2, d3, d4, d5, d6, d7, d8, d9, d10], labels=label) # label 设置横轴每个
箱图对应的横坐标
plt.xticks(fontproperties='KaiTi')

plt.show()

```

附录 4

介绍：ADF 平稳性检验

```

import numpy as np

import pandas as pd

import matplotlib.pyplot as plt

import seaborn as sns

import warnings

import random

import csv

from sklearn.impute import SimpleImputer

from sklearn.ensemble import RandomForestRegressor

import statsmodels.api as sm

from statsmodels.graphics.tsaplots import plot_acf, plot_pacf, plot_predict

from statsmodels.tsa.arima_model import ARIMA

```

```

import pmdarima as pm

from arch.unitroot import ADF

from statsmodels.stats.diagnostic import acorr_ljungbox

from statsmodels.tsa.stattools import adfuller


# ADF 平稳性检验


# 1.导入 excel 文件

data = pd.read_excel('问题 2.xlsx')

data1 = data['着陆 G 值']

data2 = data['杆量']

data3 = data['盘量']

data.head()


# 2.用差分的数据： 进行平稳性检验

data1["diff1"] = data1.diff(1).dropna()

data1["diff2"] = data1["diff1"].diff(1).dropna()

data2["diff1"] = data2.diff(1).dropna()

data2["diff2"] = data2["diff1"].diff(1).dropna()

data3["diff1"] = data3.diff(1).dropna()

data3["diff2"] = data3["diff1"].diff(1).dropna()

```

```
# 3.ADF 平稳性检验(一阶差分，二阶差分)

print(ADF(data1.diff1.dropna()), end='\n\n')

print(ADF(data1.diff2.dropna()), end='\n\n')

print(ADF(data2.diff1.dropna()), end='\n\n')

print(ADF(data2.diff2.dropna()), end='\n\n')

print(ADF(data3.diff1.dropna()), end='\n\n')

print(ADF(data3.diff2.dropna()), end='\n\n')
```

附录 5

介绍：差分处理

```
# 提前导入各种软件包

import numpy as np

import pandas as pd

import matplotlib.pyplot as plt

import seaborn as sns

import warnings

import random

import csv

from sklearn.impute import SimpleImputer

from sklearn.ensemble import RandomForestRegressor
```

```

import statsmodels.api as sm

from statsmodels.graphics.tsaplots import plot_acf, plot_pacf, plot_predict

from statsmodels.tsa.arima_model import ARIMA

import pmdarima as pm

from arch.unitroot import ADF

from matplotlib.ticker import MultipleLocator

from statsmodels.stats.diagnostic import acorr_ljungbox

# 1.原数据图像生成 and 差分处理（一阶，二阶差分），解决题目时需要更换数据

plt.rcParams.update({'figure.figsize': (9, 7), 'figure.dpi': 100})

# 1.导入 excel 文件

df = pd.read_excel('问题 2.xlsx')

# 2.原始数据的图像

# Original Series

fig, axes = plt.subplots(3, 1, sharex=True)

# 设置标题'Original Series'

axes[0].plot(df, color='green'); axes[0].set_title('Original Series')

# 3. 1st Differencing （一阶差分）

```

```

# 设置标题'1st Order Differencing'

axes[1].plot(df.diff(), color='green'); axes[1].set_title('1st Order Differencing')


# 4. 2nd Differencing（二阶差分）

# 设置标题'2nd Order Differencing'

axes[2].plot(df.diff().diff(), color='green'); axes[2].set_title('2nd Order Differencing')


# 5.生成图像

x_major_locator=MultipleLocator(25)

ax = plt.gca()

ax.xaxis.set_major_locator(x_major_locator)

plt.xticks([])

plt.show()

```

附录 6

介绍：问题 2 量化分析

```

# 提前导入各种软件包

import numpy as np

import pandas as pd

import matplotlib.pyplot as plt

import seaborn as sns

```

```
import warnings

import random

import csv

from sklearn.impute import SimpleImputer

from sklearn.ensemble import RandomForestRegressor

import statsmodels.api as sm

from statsmodels.graphics.tsaplots import plot_acf, plot_pacf, plot_predict

from statsmodels.tsa.arima_model import ARIMA

import pmdarima as pm

from arch.unitroot import ADF

from matplotlib.ticker import MultipleLocator

from statsmodels.stats.diagnostic import acorr_ljungbox


# 为方便测试注意文件中只为一次航班的数据


# 将着陆 G 值，杆量，盘量展示到一张图像上


plt.rcParams.update({'figure.figsize': (9, 7), 'figure.dpi': 100})


# 1.导入 excel 文件


df = pd.read_excel('问题 2 具体分析.xlsx')
```

```
# 2.着陆 G 值图像展示
```

```
fig, axes = plt.subplots(3, 1, sharex=True)
```

```
# 设置标题'着陆 G 值'
```

```
axes[0].plot(df.着陆 G 值, color='dodgerblue'); axes[0].set_title('COG NORM ACCEL')
```

```
# 3.杆量图像展示
```

```
# 设置标题'杆量'
```

```
axes[1].plot(df.杆量, color='dodgerblue'); axes[1].set_title('CAP CLM 1 POSN')
```

```
# 4.盘量图像展示
```

```
# 设置标题'盘量'
```

```
axes[2].plot(df.盘量, color='dodgerblue'); axes[2].set_title('CAP WHL 1 POSN')
```

```
# 5.生成图像
```

```
x_major_locator=MultipleLocator(25)
```

```
ax = plt.gca()
```

```
ax.xaxis.set_major_locator(x_major_locator)
```

```
plt.xticks([])
```

```
plt.show()
```