

队伍编号	MC2311332
题号	(D)

航空安全风险分析和飞行技术评估

摘 要

飞行安全是民航运输业赖以生存和发展的基础。针对飞行安全问题，需要综合利用现有数据强化科学管理，通过对大量 QAR 数据深度挖掘，监测和预警风险，降低飞行事故的发生率。

针对问题一，首先我们去除与飞行安全无关的变量，再把剩余变量进行可视化，判断存在异常点的变量；然后利用箱形图剔除异常点，对 8 张表进行相同处理；其次我们通过正态性检验对数据进行可靠性研究；最后我们通过随机森林回归算法进行特征重要性评估，确定了各特征的权重，其中 ZIVV, CCOL1POS, RUDPOSN, PITCH, CWHL1POS 五个特征对飞行的影响较大。

针对问题二，根据题目背景，将飞行操纵划分为横滚操纵和俯仰操纵，分别对应飞机的盘量和杆量，而盘量和杆量又会分别影响坡度和飞机姿态(俯仰角)。此外，不当飞行操纵会引起飞机重着陆情况的发生，故本文通过可视化盘量变化下坡度和着陆 G 值的变化以及杆量变化下姿态和着陆 G 值的变化，再选择其中发生剧烈波动的点进行分析，得出当飞机姿态发生剧烈上升时，对杆量进行降低处理；当飞机坡度发生剧烈下降时，对盘量进行升高处理的结论。

针对问题三，根据附件 2 数据，首先对数据进行预处理，量化描述超限，然后将目的机场和起飞机场合并为新列即航线信息，接着统计各超限的频数，选出频数最高的超限即50 英尺至接地距离远、接地速度小、爬升速度大 35-1000ft；再按照超限类别划分数据集，利用 SPSSPRO 和 Excel 针对这几个超限分别统计它们各自的飞行阶段、航线、警告级别出现的频率；最后将得出的结果可视化并分析结果，如50 英尺至接地距离远超限、接地速度小超限最容易在航线机场 89--机场 68 出现等。

针对问题四，首先将字符型数据进行编码，用编码值代替原有数据。然后使用随机森林算法对 190 余个参数值进行特征提取操作，最终得出了权重值较大的前 100 个参数。将对飞行员的技术评估问题视为飞行员技术级别的分类问题，将提取出的 100 个参数作为 **GBDT 算法**的输入，输出飞行员技术级别。该 GBDT 模型具有 93%的分类正确率，适合基于飞行参数对飞行员技术进行评级。

针对问题五，结合前四问，分析建立自动化预警机制步骤，然后基于 **SSA 优化的 BP 神经网络模型**训练附件 1 的数据，将得到的预测结果作为分类器，并建立二元分类模型，判断 QAR 数据是否超过阈值，若超过就触发安全预警。最后对附件 1 数据进行仿真，得出当 CGBRMACL 值为 0.98947，ZIVV 值为 1 等，飞行状态安全。

关键词：随机森林算法、GBDT 算法、基于 SSA 优化的 BP 神经网络模型、二元分类

目录

一、 问题重述	1
1.1 问题背景	1
1.2 问题提出	1
二、 问题分析	2
2.1 问题一分析	2
2.2 问题二分析	2
2.3 问题三分析	3
2.4 问题四分析	4
2.5 问题五分析	4
三、 模型假设	4
四、 符号说明	4
五、 问题一模型的建立以及求解.....	4
5.1 数据预处理.....	5
5.2 数据可靠性	8
5.3 基于随机森林模型的重要程度分析.....	9
六、 问题二的求解	12
七、 超限分析	14
7.1 数据预处理	14
7.2 超限分析	15
八、 问题四模型的建立以及求解.....	17
8.1 数据预处理	17
8.2 关键特征提取.....	20
8.3 基于 GBDT 算法的飞行员技术评价模型	20
九、 问题五模型的建立以及求解.....	23
9.1 特征提取	23
9.2 基于 SSA 优化的 BP 神经网络风险预测模型	23
9.3 风险预警机制.....	26
9.4 仿真结果	26
9.5 模型更新优化.....	26
十、 模型评价	27
10.1 优点.....	27
10.2 缺点.....	27
十一、 参考文献.....	27

一、问题重述

1.1 问题背景

随着民航业的快速持续发展，飞行安全越来越受人们关注，我们需要加强航空安全研究，综合利用现有数据加强科学的管理，进行监测和预警风险，降低飞行事故的发生率。航空安全大数据主要包括快速存取记录器(QAR)数据，可用于航空安全管理和飞行训练的数据支持。飞行过程中，飞行员主要通过对杆、油门、舵等的操纵实现对飞机高度、速度、姿态等的控制，在此过程中 QAR 可记录飞行操作数据(如杆位、俯仰角、油门杆位参数等)随时间变化的情况^[1]。在飞行品质监控(FOQA)中，QAR 数据中超出人为设定限制值的记为超限数据。

在飞行品质监控的研究和应用中，目前我国民航业的研究主要有两个方面：一方面是针对超限事件的研究、分析及应用；另一方面是对非超限数据的统计分析和应用。对于超限事件的研究，一般通过规定飞行参数的集中区域设置超限阈值，找出超出阈值部分的飞行记录然后进行重点分析，以防范潜在隐患造成严重飞行事故。该类分析较好地保证了现阶段的安全工作，是飞行品质监控工作的主体，但缺少对超限原因的分析。由于超限并不是全都由人为因素引发，如许多是特殊环境条件造成的，还有可能是飞机本身的设计、制造因素所导致，故仅通过单纯的超限分析是很难识别出来的。由于目前并不倾向于以少量的 QAR 超限数据为依据开展飞行训练工作，故 FQQA 逐渐衍生出另外一种倾向性，即通过挖掘 QAR 全航段数据开展分析，形成特定人员的飞行品质记录。在不同飞行机组、飞行航线、机场以及特定飞行条件下的飞行记录，通过对数据进行分析并建模，计算评估风险倾向性，排查安全隐患。当前相似的研究主要是大规模地读取飞行数据，然后进行存储、分析，形成飞行品质服务平台，给风险评估和趋势分析提供数据基础。G 值是飞机飞行过程中过载情况的直接反应，在着陆安全分析中，G 值一般是描述落地瞬间安全性的重要指标。着陆瞬间 G 值指的是飞机接地瞬间前 2 秒和后 5 秒的最大 G 值。

1.2 问题提出

问题 1:

在附件 1 里存在错误的 QAR 数据，需要对数据进行预处理并去掉错误的数据。开展针对附件 1 的数据质量的可靠性研究，提取与飞行安全相关的部分关键数据项，然后分析其重要程度。

问题 2:

飞机在从起飞到着陆的整个飞行过程中，通过一系列的横滚操纵、俯仰操纵等飞行操纵确保飞行安全。国内航空公司虽然能够通过超限监控飞行操纵动作来分辨飞机的状态偏差，但是只能知道发生什么，不能立刻获取发生这种偏差的原因。故需要通过操纵杆的过程变化情况分析产生这种偏差的原因。利用附件 1 的数据，对飞行操纵进行合理的量化描述。

问题 3:

不同的特定情况会出现各种不同的超限，如特定机场、特定飞行阶段、特定航线容易出现特定的超限。针对附件 2 的数据，对其进行研究，分析超限的不同情况，研究不同超限的基本特征，例如分析飞机在哪些航线或者在哪些机场容易出现哪种超限等。

问题 4:

飞机运行数据的研究一般分为通过航线运行安全检查（LOSA）获取的飞行员的运行表现，及根据相关学者建议基于飞行参数开展飞行技术评估两大类。在附件 3 中，数据表中的“不同资质”代表飞行员的不同技术级别，利用附件 3 的数据，建立数学模型，以探讨一种基于飞行参数的飞行技术评估方法，分析飞行员的飞行技术。

问题 5:

随着技术的进步，未来在民航客机上安装实时传输的 QAR 数据记录系统已成为可能，这种“实时飞行数据”技术，可以在接近实时的情况下把航班飞行数据传输到地面分析系统，极大地提高风险识别能力及预防水平。假设飞行数据已能实现陆空实时传输，如果你是该航空公司的安全管理人员，请建立航空公司实时自动化预警机制，预防可能的安全事故发生，结合附件 1 的数据，给出仿真结果。

二、问题分析

2.1 问题一分析

题目要求我们预处理附件 1 数据，去伪存真，提取与飞行安全相关的部分关键数据项并分析其重要程度。对于第一小问，我们先对数据进行预处理，删除附件一中的与飞行安全无关的变量，然后进行缺失值、重复值处理，再把剩余变量进行可视化，直观展示哪些变量存在异常点；得出存在异常的变量后，利用箱线图剔除这些变量的异常点。接着对数据正态性检验来判断数据是否可靠；对于第二小问，我们使用随机森林回归算法进行特征重要性评估，确定各飞行参数的权重。

2.2 问题二分析

由常识可知，飞机起飞和着陆是整个飞行过程事故的高发阶段。因此，本题需要重点分析飞机的起飞和着陆阶段。

首先，观察重着陆样本和正常样本的杆位随时间变化曲线图，可得当杆位在单位时间内突然骤降，且此时的着陆 G 值超过给定限制值(该图中着陆 G 值在 7 秒处超过给定限制值)，则超限监控系统就将这一时刻的松杆操纵定义为不当松杆操纵。




图 2-1

其次，查阅文献^[2]可知，对操纵杆的操纵情况即为飞行操纵。飞行操纵包括横滚操纵和俯仰操纵等。附件 1 中与落地主操控人员进行飞行操纵相关的参数仅有杆量、盘量、左发油门杆位置、右发油门杆位置。而左发、右发油门杆的位置对于飞行安全的影响是通过杆量和盘量变化来间接表现的。故我们只分析杆量和盘量对于飞行操纵的影响。杆量及盘量以及飞行操纵之间的关系如下：




图 2-2

通过以上分析，可知若要对飞行操纵进行量化描述，则只要量化描述飞行过程中，尤其是起飞和着陆阶段的盘量和杆量的变化情况即可。因此，只要对起飞阶段和着陆阶段盘量和杆量导致着陆 G 值发生剧烈变化的阶段进行可视化分析，就可量化描述不当松杆操纵。

2.3 问题三分析

根据题目给出的附件 2 数据，不同的超限发生原因各不相同。为了进行分析，我们从飞行阶段、航线、警告级别这三个角度进行研究。首先，我们需要对数据进行预处理，量化描述超限，接着将目的机场和起飞机场合并为新列作为航线信息。然后，我们需要统计各种超限的频数，并选出频数最高的超限。接着，按照超限类别，我们可以将数据集进行划分，并利用 SPSSPRO 和 Excel 针对这几个超限分别统计它们各自的飞行阶段、

航线、警告级别出现的频率。最后，我们可以将结果可视化，并分析得出结论，例如哪些航线或者在哪个飞行阶段容易出现何种超限。

2.4 问题四分析

问题四的核心是构建基于飞行参数的飞行技术评估模型，以此对飞行员的飞行技术进行分析。我们需要对题中附件 3 所给数据进行预处理，首先将地面主操控、地面主操控人员资质等定类变量进行编码处理。然后,再对编码后的数据及题目所给其他数据进行预处理，包括对重复值、缺失值以及异常值的处理。其次,使用随机森林对所给的一百九十余个特征进行选择,选出若干个较为主要的特征。最后将这些主要特征作为输入,利用机器学习中的梯度提升决策树(GBDT)模型即可完成对飞行员的技术分析^[3]。

2.5 问题五分析

结合前四问，分析建立自动化预警机制步骤，然后基于 SSA 优化的 BP 神经网络模型训练附件 1 的数据，将得到的预测结果作为分类器，并建立二元分类模型，判断 QAR 数据是否超过阈值，若超过就触发安全预警。最后对附件 1 数据进行仿真。

三、模型假设

- 1. 假设定类变量如空地电门不会出错；
- 2. 假设飞行操纵不受到飞机硬件损坏及外界环境的影响。
- 3. 假设飞行员通过飞行操纵能够调整飞行参数。

四、符号说明

符号	说明
x_i	第 <i>i</i> 个个体
$\bar{x}$	样本平均值
$Kurt(X)$	峰度
$Skew(X)$	偏度
$x_{i,j}^{t+1}$	第 <i>t</i> + 1次迭代第 <i>i</i> 个体在 <i>j</i> 维的位置
$FIM_{km}^{(OOB)}$	重要性评分

五、问题一模型的建立以及求解

5.1 数据预处理

5.1.1 整体数据分析

附件 1 中提供了 8 个表格，包含了 2014.04.07,2014.04.08,2014.04.09,2014.04.10 共四天飞机飞行的 QAR 数据，由于 8 张表规律一致，故我们选取一张进行描述说明。首先通过 python 读取数据的整体信息，可知原始数据有 55 个数值类型、3 个日期类型、4 个对象类型、共有 38672 行数据。其中有数值类型、日期类型、对象类型。

5.1.2 删除无关变量和重复变量

由于数据项过多，因此先排除一些无关变量。根据分析，DATECLKMON、DATECLKDAY、GMT、DEPARTPT、DESTPT 和 FMFGROSSWT 与飞行安全无关，因此将其删除。

针对 WOW INDICATE INAIR 字段，1 秒 5 次的记录都是相同的，保留其中一个字段即可。

通过观察 CGBRMACL、PITCH、CCOL1POS、ROLL、CWHL1POS、TRAIL、TRAILR 7 个字段，发现每次记录的数据相差不大，因此可以对其求平均值，保留平均值项，其余项删除。

平均值公式如下：

$$\frac{1}{n} \sum_{i=1}^n x_i$$

数据中存在两列 PTCHATTRAT 重复数据，保留其中一个字段即可。

5.1.3 对非数值数据类型进行转换

通过查看 WOW INDICATE INAIR 字段的值，发现其共有 2 种字符串数据，分别是 TRUE 和 FALSE，因此将 TRUE 用 1 表示，FALSE 用 0 表示。

查看 TMAENGD 字段的值，发现其共有 2 种字符串数据，分别是 DISENGD 和 ENDISENGD，因此将 DISENGD 用 0 表示，ENDISENGD 用 1 表示。

查看 APENG 字段的值，共有 OFF 和 ON 两种字符串数据，因此将 OFF 用 0 表示，ON 用 1 表示。

5.1.4 缺失值处理

原始数据中存在部分缺失值，通过 python 对缺失值进行可视化，如图 5-1 所示，LGDN 特征缺失值占比高达 96%，因此剔除这个变量数据。





图 5-1. 缺失值

5.1.5 异常值处理

通过收集得到的数据通常会存在少数异常值，异常值又被定义为异常或噪声，包括处于特定分布区域之外的数据。异常数据包括伪异常或真异常。伪异常是指由于特定的动作产生，能够正常反应飞机的状态；真异常则是数据本身分布异常，即离群点。

综合上述分析，对附件一的数据进行异常值处理，方法如下：

- (1) 首先对各特征数据进行可视化






图 5-2. 参数可视化




图 5-3. 各偏差参数


从图 5-3、图 5-2 可以看出 ALT、GPRA、CAS、GNDSPEED、MAGHEADNG、WINDIRCTRU、WINDSPEED、GSDEVC、LOCDEVC 受特定动作的影响存在伪异常值，因此对其不做处理。

从图 5-2 中可以看出 ZIVV、PITCH、CGBRMACL、ROLL、CWHL1POS、CCOL1POS、PTCHATTRAT 均存在异常值，因此应对异常值进行剔除。

(2) 剔除范围之外的数据

箱形图能够准确稳定的描绘出离散分布的情况，不受异常值的影响，因此本文采用箱形图进行异常值处理。

箱形图中上下须为数据分布的边界，只要高于上须，或者低于下须，都认为是异常值。上须为 $Q3 + 1.5(Q3 - Q1)$ ，下须为 $Q1 - 1.5(Q3 - Q1)$ ，其中 $Q1$ 其为 25% 分位点所对应的值， $Q2$ 为 50% 分位点所对应的值， $Q3$ 为 75% 分位点所对应的值。






图 5-4. 箱形图

经过异常值处理，还剩下 24725 行数据。

5.1.6 归一化

对于飞行数据中的连续值特征，为了防止小数据被吞噬，我们需要对数据进行归一化处理，即将所有数据都转换为 $[0, 1]$ 之间的数，这可以起到统一量纲的作用。本文采用 min-max 方法进行标准化，其公式如下：

$$X' = \frac{x - \min}{\max - \min}$$

其中 $\min$ 和 $\max$ 分别是该字段中数据的最小值和最大值。

5.2 数据可靠性

取 ZIVV 和 CGBRMACL 两个特征变量进行数据可靠性研究，分别对其进行正态检验。其中峰度用于衡量数据分布的平坦度（flatness）。尾部大的数据分布，其峰度值较大。正态分布的峰度值为 3。

$$Kurt(X) = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{\left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right)^2} - 3$$

偏度是统计数据分布偏斜方向和程度的度量，是统计数据分布非对称程度的数字特征。其计算公式如下：

$$Skew(X) = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{\sigma^3}$$

求得 ZIVV 的峰度为-0.11，偏度为 0.026；CGBRMACL 的峰度为 0.272，偏度为-0.014。两个特征变量的峰度绝对值都小于 10 且偏度绝对值小于 3。因此接着结合正态分布直方图和 Q-Q 图对两个特征变量进行进一步分析：




图 5-5. ZIVV(左)和 CGBRMACL(右)正态分布直方图




图 5-6: ZIVV(左)和 CGBRMACL(右)Q-Q 图

从图 5-5 可以看出 ZIVV 和 CGBRMACL 数据的正态图基本上呈现出中间高，两端低，基本可接受为正态分布；从图 5-6 可以看出 ZIVV 和 CGBRMACL 数据的散点与直线重合度高，因此数据可靠性高。

5.3 基于随机森林模型的重要程度分析

5.3.1 随机森林模型

随机森林是基于决策树概念提出的一种不相关多棵决策树的集成学习方法算法，它结合了袋装集成的本质和随机特征选择技术，可以在一定程度上消除决策树的缺点。

本问中我们采取随机森林算法进行回归分析，提取与 QAR 数据中与飞行安全相关的属性，如 ZIVV、PITCH 等作为模型训练的输入自变量信息，以 CGBRMACL 作为模型训练输入的因变量信息，并通过随机森林算法特有的袋外数据特征重要性进行自适应数据分析，选择最优的特征变量。

步骤:

- Step1: 有放回地从原始数据集中随机抽样，每次选取 n 个样本量作为一个训练集；
- Step2: 对所抽样样本，随机不重复地抽取 d 个特征作为训练决策树的输入，利用 d 个特征分别对样本集进行划分，构建决策树；
- Step3: 重复步骤 1-2 共 k 次，生成 K 棵决策树，构成随机森林；
- Step4: 综合 K 棵决策树的分类结果，得到最终分类结果。

其流程图如图 5-7 所示：




图 5-7. 随机森林算法流程图

特征重要性评估:

通过量化每个特征对构建的 K 棵决策树分类性能的贡献度来对特征进行排序, 贡献度常用袋外错误率作为评价指标^[4]。

定义指示函数:

$$I(x, y) = \begin{cases} 1, & x = y \\ 0, & x \neq y \end{cases}$$

第 m 个特征 F_M 在第 k 棵树的 $FIM_{km}^{(OOB)}$:

$$FIM_{km}^{(OOB)} = \frac{\sum_{p=1}^{n_0^k} I(Y_p, Y_p^k)}{n_0^k} - \frac{\sum_{p=1}^{n_0^k} I(Y_p, Y_{p,\pi_m}^k)}{n_0^k}$$

式中: n_0^k 为第 k 棵树观测样本数; Y_p 为第 p 个样本对应的真实分类标签; Y_p^k 为随机置换 F_M 前第 k 棵树对袋外数据第 p 个观测的预测分类结果; Y_{p,π_m}^k 为随机置换 F_M 后第 k 棵决策树对第 p 个样本的分类结果, 其中随机置换 F_M 后第 k 棵决策树需要重新训练。当特征 F_M 没有在第 k 棵树中出现时, 则 $FIM_{km}^{(OOB)}=0$ 。

特征 F_M 在整个随机森林中的重要性评分定义为

$$FIM_m^{(OOB)} = \frac{\sum_{k=1}^K FIM_{km}^{(OOB)}}{K\sigma}$$

式中: K 表示随机森林中决策树的个数, σ 表示 $FIM_{km}^{(OOB)}$ 的标准差, 特征 F_M 的重要性评分 $FIM_m^{(OOB)}$ 表示 F_M 对分类正确率的贡献度, 特征重要性评分是由袋外错误率均值和标准差共同决定的。

5.3.2 随机森林模型的参数调优

随机森林回归时主要的优化参数有 `n_estimators`，`max_depth`，`bootstrap`。其中 `n_estimators` 为最大决策树个数；`max_depth` 为每棵树最大可能深度；`bootstrap` 表示是否有放回抽样。需要对这三个参数进行调优，提高模型的预测效果。

首先，在随机森林建模时按照每个参数的默认值运算，得出此时模型的评价指标值 R^2 为 0.51。

接着，`n_estimators`，`max_depth`，`bootstrap` 进行参数优化工作，`n_estimators`，`max_depth` 两个参数在默认值的基础上每次增加 20；由于样本数量较多，因此进行有返回的抽样，`bootstrap` 的值设为 `True`。

最后，选择优化后的参数组合，即 `bootstrap=True,n_estimators=100,max_depth=50`。将数据按照 7：3 的比例划分训练集和测试集，并采取五折交叉方法，得到优化后的模型。其中训练集 R^2 为 0.783，测试集 R^2 为 0.62。与之前优化后的模型对比，模型的拟合程度提高。

最终得到的结果如下图 5-8 所示：




图 5-8. 与飞行安全相关的主要数据项机器权重

由图 5-8 得到 ZIVV，CCOL1POS，RUDPOSN，PITCH，CWHL1POS 这五种飞机参数对飞行安全的影响较大。

根据飞行品质监控领域，影响飞行品质最常见的因素包括速度、飞行姿态和气象环境等。速度包括空速、地速，按最大最小速度范围可以分成爬升率、下降率、接地速度等。下降率指的是飞机每秒所降低的高度，垂直速度越大，则飞机降低高度越快。在进近着陆时，飞机的下降率必须保持在合理范围内，因为进近着陆时气流的变化较大，操纵稳定性差，不能有过大的下降率。故下降率也是重点针对的监控项目之一^[5]。

着陆 G 值是飞机飞行过程中过载情况的直接反应，在着陆安全分析中，G 值通常是描述落地瞬间安全性的重要指标。由此可见，我们得出的结果与事实较为符合。

六、问题二的求解

可视化杆量变化，并和杆量控制下的飞机姿态以及着陆 G 值相比：




图 6-1

通过杆量、姿态、着陆 G 值的可视化表达，选取一个剧烈变化点进行分析，可明显观察到在 2000 数据点左右，杆量和姿态均发生剧烈波动。使用 matlab 对该点进行定位并放大观察，可得如下图 6-2：




图 6-2

可以发现飞机姿态在 1620 这个数据点处剧烈振动，由于飞机操纵者此时进行拉杆操作，使得杆量进行急剧变大，导致俯仰角也急剧变大，着陆 G 值也瞬间变大。故可以明确的是当飞机操纵者进行拉杆操作时，带来的结果是飞机抬头，即仰角变大，飞机在竖直向上的速度变大。因此，倘若飞行操纵人员想要让飞机在俯仰角发生剧烈上升时保持飞行得着陆 G 值不出现超限，即为避免着陆 G 值大于限制值的上限，则操纵人员需要对杆量进行降低处理。

将盘量可视化，并和盘量控制下的飞机坡度和着陆 G 值相比，得出结果如下图 6-3：




图 6-3

通过盘量、坡度、着陆 G 值的可视化表达，选取一个剧烈变化点进行分析，可明显观察到在 2000 数据点左右，盘量和坡度均发生剧烈波动。使用 matlab 对该点进行定位并放大观察，可得如下图 6-4：




图 6-4

可以发现飞机坡度在 1705 和 1710 这两个数据点处剧烈振动。由于飞机操纵者此对盘量进行降低处理,使得飞机坡度发生剧烈下跌,同时着陆 G 值也剧烈下跌。并且,观察盘量变化图和坡度变化图可以知晓:坡度和盘量呈存在正相关,盘量变大坡度也随着变大,而盘量变小时,坡度也跟着变小。因此,倘若飞行操纵人员想要让飞机在坡度发生剧烈下降时保持飞机的着陆 G 值不出现超限,则操纵人员需要对盘量进行升高处理。

综合以上分析可知:

1. 当飞机姿态(俯仰角)发生剧烈上升时,应对杆量进行降低处理
2. 当飞机坡度发生剧烈下降时,应对盘量进行升高处理。

最后,考虑到题目中所给的因为不当松杆导致的重着陆情况,可以推断其发生原因可能是飞机操纵人员对盘量进行了过多的降低处理,导致着陆瞬间 G 值突然下跌,突破超限监控系统设置的着陆 G 值限制范围,导致了该重着陆超限情况的发生^[3]。其中,杆量变化会导致着陆 G 值变大。

因此,可以最终推断出飞机发生重着陆的原因是:在着陆过程中的某个时刻,盘量下降的速度快于杆量上升的速度,或者说在着陆过程中,盘量的增量大于该过程杆量的增量,使得着陆 G 值短时间内快速变小,突破限制值,此种情况即为我们定义的不当松杆操纵。由于不当松杆操纵的出现,就会导致飞机在着陆过程中的重着陆情况。

七、超限分析

7.1 数据预处理

根据题目要求和附件 2 数据,我们需要判断哪些航线容易出现何种超限,故需要航线该变量,附件 2 里起飞机场到目的机场即为航线,故我们将目的机场和起飞机场合并为一个新列作为航线信息,方便后续统计频数。

然后再给附件 2 数据的各类超限进行编号,用这些编号代替超限名称,方便我们进行统计分析,编号结果如下表 7-1 所示:

表 7-1. 各类超限编号表

超限名称	编号	频数	超限名称	编号	频数
50 英尺至接地距离近	1	5	离地仰角大	26	6
50 英尺至接地距离远	2	16692	爬升坡度大 35-400(含)ft	27	1
GPWS 警告(sink rate)	3	48	爬升速度大 35-1000ft	28	10748
GPWS 警告(windshear)	4	11	爬升速度小 35-1000ft	29	69
High normal accel with flap (in flight)	5	7	坡度大 400/1500ft 以上	30	12
Left of centreline below 1000ft	6	1	起飞 EGT 超限	31	5
TCAS RA 警告	7	1	起飞滑跑方向不稳定	32	2
超襟翼限制速度 Vfe	8	3	起飞坡度大 0-35 (含) ft	33	131
低空大速度 2500ft 以下	9	30	起飞收起落架晚	34	1
低于下滑道	10	307	收反推晚	35	155
放起落架晚	11	7	抬前轮速度大	36	105
复飞	12	5	抬前轮速度小	37	42
高于下滑道	13	122	抬头速率大	38	1
接地速度小	14	9399	抬头速率小	39	19
进近坡度大 1500-500 (含) ft	15	3	未知	40	52

进近坡度大 200-50（含）ft	16	58	下滑道警告	41	43
进近坡度大 500-200（含）ft	17	6	下降率大 1000-400(含)ft	42	196
进近坡度大 50ft 以下	18	1553	下降率大 2000-1000(含)ft	43	577
进近速度大 50 ft 以下	19	764	下降率大 400-50ft	44	1661
进近速度大 500-50（含）ft	20	2	着陆垂直载荷大	45	281
进近速度大 500-50（含）ft	21	74	着陆俯仰角大	46	17
进近速度小 500 ft 以下	22	1	着陆俯仰角小	47	401
空中过载	23	95	着陆襟翼到位晚	48	33
离地速度大	24	144	着陆重、跳着陆	49	6
离地速度小	25	3	直线滑行速度大	50	27
			转弯滑行速度大	51	171

利用 Excel 表统计每种超限出现的频数，并利用饼状图可视化观察各种超限的频数，如下图 7-1：




图 7-1. 各超限频数图

从图 7-1 中可以看出 2 号超限的频数占比为 38%最高，所以最容易出现的超限为 50 英尺至接地距离远，其次 2 号超限爬升速度大 35-1000ft（24%）、14 接地速度小（21%）。由于超限种类过多，我们研究比较容易出现的超限，即选择 2 号、28 号、14 号超限来进行分析研究。

7.2 超限分析

7.2.1 警告级别

从附件 2 里分别提取 2 号、14 号、28 号超限的数据，利用 SPSSPRO 分别统计三种超限的数据里不同警告级别的频数，判断这三种超限一般属于哪种警告级别。结果如下表 7-2、7-3、7-4 所示：

表 7-2：2 号超限警告级别

名称	选项	频数	百分比(%)
ALERT (警告级别)	2	14571	87.293
	3	2121	12.707
合计		16692	100.000

表 7-3：14 号超限警告级别

名称	选项	频数	百分比(%)
ALERT (警告级别)	2	9205	97.936
	3	194	2.064
合计		9399	100.000

表 7-4: 28 号超限警告级别

名称	选项	频数	百分比(%)
ALERT (警告级别)	2	8854	82.378
	3	1894	17.622
合计		10748	100.000

从三个表中可以看出 2 号、14 号、28 号超限在一般情况下警告级别均为 2。

7.2.2 飞行阶段

通过研究附件 2 数据,可以得出共有 7 种飞行阶段,0、1 为未知的飞行阶段,其他飞行阶段变化图 7-2 如下所示:



图 7-2. 飞机飞行图

利用 SPSSPRO 统计各飞行阶段出现的频数,结果如下图 7-3 所示:




图 7-3. 各飞行阶段出现频数

从上图可以得出着陆阶段最容易出现超限,其次是空中,进近阶段。

从附件 2 表格可以清楚看出着陆阶段容易出现 2 号超限 50 英尺至接地距离远、14 号超限接地速度小,空中阶段容易出现 28 号超限爬升速度大 35-1000ft。

7.2.3 航线

利用 SPSSPRO 对 2 号、14 号、28 号超限的航线进行频数分析,可以得出结果如下表 7-5、7-6、7-7 所示:

表 7-5. 2 号超限航线频数

航线	频数	百分比
机场 68 机场 89	249	2.649%
机场 61 机场 68	203	2.16%
机场 68 机场 16	169	1.798%
机场 89 机场 68	166	1.766%
机场 68 机场 59	153	1.628%
机场 28 机场 68	152	1.617%
机场 68 机场 28	136	1.447%
机场 68 机场 61	134	1.426%
机场 4 机场 68	132	1.404%
机场 68 机场 97	128	1.362%
机场 68 机场 7	124	1.319%
机场 68 机场 74	121	1.287%

表 7-6. 14 号超限航线频数

航线	频数	百分比
机场 89 机场 68	603	3.613%
机场 68 机场 89	401	2.402%
机场 27 机场 68	323	1.935%
机场 68 机场 97	265	1.588%
机场 61 机场 68	239	1.432%
机场 68 机场 61	230	1.378%
机场 100 机场 68	226	1.354%
机场 16 机场 68	225	1.348%
机场 68 机场 16	224	1.342%
机场 41 机场 68	212	1.27%
机场 59 机场 68	197	1.18%
机场 68 机场 74	193	1.156%

表 7-7. 28 号超限航线频数

航线	频数	百分比
机场 68 机场 16	332	3.089%
机场 68 机场 88	235	2.186%
机场 68 机场 7	225	2.093%
机场 68 机场 74	222	2.066%
机场 21 机场 16	221	2.056%
机场 32 机场 16	191	1.777%
机场 68 机场 34	169	1.572%
机场 89 机场 68	156	1.451%
机场 68 机场 104	154	1.433%
机场 68 机场 15	143	1.33%
机场 68 机场 28	139	1.293%

注：由于数据过多，根据各航线的频数占比情况选取占比和 20% 的前几行数据

从表 7.5 中可以看出其中航线机场 89 到机场 68 频数最大，表 7.6 中航线机场 68 到机场 89 频数最大，表 7.7 中航线机场 68 到机场 16 的频数最大，故 2 号、14 号超限最容易在航线机场 89--机场 68 出现，28 号超限最容易出现在航线机场 68--机场 16。

八、问题四模型的建立以及求解

8.1 数据预处理

附件 3 中数据参数过多，因此我们需要剔除无关变量，并对相关数据进行缺失值、重复值等数据预处理。

8.1.1 定类变量编码

分别对落地主操控人员资质以及 V1、Vr、V2、Vref、RoD_Method、MACH_Method 等值的数值取得方式进行编码。

编码原则：根据数据项对应的字母大小进行编码，字母较大，编码较大，编码从 1 开始，且数值连续。编码情况如下。

表 8-1. 落地主操控人员资质编码

落地主操控人员资质	对应编码的十进制表示
A	1
C	2
F	3
M	4
J	5
T	6

表 8-2. V1、Vr 等数值取值方式编码

数值取得方式	对应编码的十进制表示
R	2
C	1

8.1.2 重复值处理

利用 SPSS 进行重复值查找,共得到两个重复个案,将其删除，得结果如下图 8-1。

统计		
每个作为主个案的最后一个匹配		
个案数	有效	2367
	缺失	0

图 8-1

此外,数据值始终恒定的变量,如 TO_Gate1、TO_Gate2、TD_Gate2 等,同样将其做删除处理。

8.1.3 缺失值处理

单变量统计							
	个案数	平均值	标准 偏差	缺失		极值数 ^a	
				计数	百分比	低	高
EvtsEStoG2	0			2369	100.0		
EvtsG2toG3	0			2369	100.0		
EvtsTDG3toSD	0			2369	100.0		
TO_V1	0			2369	100.0		
TO_Vr	2369			0	.0		
TimeToGearSelUp	2367			2	.1		
MaxCASVfeF4	0			2369	100.0		
MaxCASVfeF5	0			2369	100.0		
MaxCASVfeF6	0			2369	100.0		
MaxCASVfeF7	0			2369	100.0		
MaxCASVfeF8	0			2369	100.0		
MaxCASVfeF9	0			2369	100.0		
MaxCASVfeF10	0			2369	100.0		
MaxCASVfeSlat	0			2369	100.0		
TimeG1toG2	2367			2	.1		
MaxCASVfeF61	0			2369	100.0		
MaxCASVfeF71	0			2369	100.0		
MaxCASVfeF81	0			2369	100.0		
MaxCASVfeF91	0			2369	100.0		
MaxCASVfeF101	0			2369	100.0		
MaxCASVfeSlat1	0			2369	100.0		

图 8-2. 附录 3 缺失值分析

观察图 8-2, V1_method、Vr_method、V2_method、EvtsEStoG2 等 29 个特征存在缺失情况,并且该 29 个特征的缺失率为 100%。对于缺失率为 100%的数据,无法通过常规的缺失值填充手段进行填补,故删除以上 29 个特征。

8.1.4 缺失值填充

由于多数特征都存在缺失值,若将含有缺失值的数据个案直接删除,可能会导致数据量锐减,不利于本题模型建立和求解。故不考虑删除缺失值,而直接对缺失值进行替换处理。由于本题所给数据为时间序列数据,故考虑使用临近点的平均值对缺失值进行填补。

8.1.5 数据标准化

由于各飞行参数之间差异悬殊,因此在使用数据进行具体分析之前,首先要进行量纲化处理。本题使用最常见的数据标准化方法:Z-Score。

标准化数据公式如下:

$$X_{new} = \frac{x - \mu}{\sigma}$$

其中, μ 为样本均值, σ 为样本数据的标准差。

此外,将标准化后数据称为Z+原数据名,如MaxPALT_1 标准化后称为ZMaxPALT_1。

8.2 关键特征提取

由于本题拥有的特征数目相当多,而且数据无序变化且数据间不存在相关关系,故无法采用因子分析、主成分分析法和 CRITIC 等方法进行各特征的重要性排序。考虑到本题庞大的特征值数目,而随机森林在分类和回归问题上具有优越表现,故采用问题一中提到的随机森林模型来进行本问的特征值选择^[6]。

排除落地主操控人员、落地主操控人员资质以及时间等特征后,将剩余参数作为随机森林的输入,其输出结果就是若干个主要飞行参数。从输出结果中选择前 100 个权值较大的飞行参数,视其为飞行员评价模型的输入。




图 8-3. 随机森林提取的主要飞行参数(较大的 10 个)

8.3 基于 GBDT 算法的飞行员技术评价模型

8.3.1 模型选取及介绍

题目所给数据中除了飞行参数外,还提供了落地主操控人员(本题视为飞行员)资质项,故我们将评价飞行员技术量化为:根据若干飞行参数,通过数学模型计算出飞行员资质项。然后以资质的高低来衡量飞行员的技术是否优秀、良好。

进一步分析可知,题目所给资质数据项含有六种资质级别,为保证评价结果的一致性和可读性,我们将评价模型的输出值定义为资质级别所对应的数字编码,因此可将该飞行员评价模型转为回归或者分类模型,把飞行员技术评价问题真正参数化,便于求解分析。

本文将该飞行员评价模型视为回归模型。通常而言,回归问题的损失函数一般为平方差损失函数。此时的残差计算,恰好等于预测值与实际值之间的差值。如果使用决策树算法作为回归模型,那么每次取一棵决策树来拟合差值,使得残差越来越小,便可使得到的回归模型越准确。查阅资料可得,基于决策树的梯度提升算法(GBDT)在回归问题上有着优于其他机器学习算法的应用能力,故本题选择梯度提升决策树(GBDT)作为飞行员评价模型^[7]。

梯度提升决策树(GBDT)是一种迭代决策树的机器学习算法，以 CART 决策树作为弱学习器，串行地训练决策树，最终对所有决策树的预测结果加和，由此得到一个强学习器。该算法通过每次的迭代在降低残差的方向新建一棵决策树，并在此基础上进一步迭代提高结果的准确性^[8]。其流程图如下图 8-4 所示：




图 8-4. GBDT 算法流程图

GBDT 的算法步骤如下：

1) 初始化弱学习器 $f_0(x)$ ，此时构建只有一个根节点的树，公式如下：

$$f_0(x) = \arg_c \min \sum_{i=1}^n L(y_i, c);$$

其中， $L(y_i, c)$ 为损失函数，计算真实值与预测值之间的误差， $\arg_c \min$ 确定损失函数值最小时 c 的取值。

2) 建立一系列 CART 回归树，在此基础上利用梯度提升技术拟合残差，计算损失值的负梯度并作为残差估计值 r_{mi} ，公式如下：

$$r_{mi} = -\frac{\partial L(y_i, f_{m-1}(x_i))}{\partial f_{m-1}(x_i)};$$

3) 利用 CART 回归树拟合第 m 棵树的叶节点区域 $R_{mj}(j = 1, 2, \dots, J_m)$ ， J_m 为第 m 棵回归树的叶子节点数；对于每个叶节点区域，计算使对应损失函数最小化的最佳拟合值 c_{mj} ，公式如下：

$$c_{mj} = \arg_c \min \sum_{x_i \in R_{mj}} L(y_i, f_{m-1}(x_i) + c);$$

其中 y_i 为第 j 个叶子节点的样本 x_i 观测值， $f_{m-1}(x_i)$ 为第 j 个叶子节点的样本 x_i 在上一棵树上的预测值；

4) 更新学习器 $f_m(x)$ ，公式如下：

$$f_m(x) = f_{m-1}(x) + \sum_{j=1}^J c_{mj} I, \quad x \in R_{mj};$$

其中， I 为学习率，若 x_i 样本在 R_{mj} 上，则 $I = 1$ ；否则 $I = 0$ ；

5) 进行迭代，直到达到所预期的基学习器个数，得到最终的强学习器为

$$F(x) = f_0(x) + \sum_{m=1}^M \sum_{j=1}^J c_{mj} I, \quad x \in R_{mj}.$$

8.3.2 模型参数

利用网格搜索算法对飞行员技术评价模型的参数进行优化，得到参数及对应模型分类正确率较高的 4 个如下：

表 8-4. GBDT 参数

学习率	迭代次数	树的深度	n_estimators (弱评估树个数)	正确率
0.1	10	2	100	95.3%
0.05	5	3	100	92.7%
0.1	5	3	100	90.3%
0.1	5	2	10	76%

选择分类结果最好的参数作为 GBDT 模型的最终参数，即最终模型参数为学习率=0.1, 迭代次数=10, 决策树深度为 2, 弱评估树个数为 100。

8.3.3 模型求解及结果分析

使用 python 对上述模型进行求解，该模型预测值和实际值之间的比较如下图 8-5：




图 8-5 GBDT 模型预测值和实际值对比

8.3.4 模型评价

模型正确率 acc:

$$\text{acc} = \frac{\text{predict}}{\text{real}} \times 100\%$$

其中, real 表示真实值个数, predict 表示预测正确值个数, 二者之比即为该模型正确率。计算可得, 该模型正确率 acc 为 $220/237=93\%$, 有较为优秀的正确率。

将得到的训练集和测试集进行均方根误差 RMSE 计算,

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - f(x_i))^2}$$

其中, y_i 是真实值, $f(x_i)$ 是预测值, n 表示样本数量。

计算求得: $\text{RMSE}=0.48$

综合 RMSE 和 acc, 即可证明本文的基于随机森林的 GBDT 飞行员技术评价模型具有良好的分类效果, 可用于基于飞行参数的飞行员技术评估。

九、问题五模型的建立以及求解

假设作为航空公司的安全管理人员, 我们需要利用实时飞行数据来建立自动化预警机制, 步骤如下:

1. 数据采集与传输: 利用实时传输的 QAR 系统, 获取飞机的飞行数据, 包括航向道偏差、姿态平均值、地速、风速等参数。

2. 数据分析与处理: 通过先进的数据分析算法和模型, 实时监测飞行数据, 并进行数据挖掘和趋势分析。

3. 风险预警与报警: 基于实时飞行数据的分析结果, 建立相应的风险预警与报警机制。当检测到飞行数据异常或超出预设安全范围, 系统自动发出预警或报警信号。

4. 实时干预与响应: 当接收到风险预警或报警信号时, 飞行员、相关人员通过地面分析系统对飞行数据进行实时干预与响应。

5. 数据存储与分析: 实时飞行数据可以存储在地面分析系统中, 以便后续的离线数据分析和风险评估。通过对历史飞行数据的分析, 识别出潜在的风险和趋势, 进一步优化预警机制和提高安全预防水平。

9.1 特征提取

根据题目背景, 已实现陆空数据采集与传输。问题一中我们通过随机森林预测得到了飞行安全参数的相应权重, 根据问题一得到不同权重去获取飞机是否处于安全状态; 根据问题二的杆量和盘量去判断飞机是否处于重着陆状态; 根据问题三判断处于何种超限以及问题四得出了飞行员的技术评级。基于这些前提, 我们开始建立相应的风险预测模型即步骤 3。

9.2 基于 SSA 优化的 BP 神经网络风险预测模型

SSA 是一种常用于时间序列分析的方法, 通过将时间序列数据进行特征分解和恶重构, 从而提取出序列中的趋势, 噪声等信息。通过 SSA 对历史超限数据进行分解和重

构，得到超限数据的趋势和周期信息。然后，将这些信息作为输入特征，结合其他相关的特征，构建神经网络模型进行预测。通过 SSA 优化的神经网络可以利用历史学习超限情况的规律，并在新数据到来时进行预测。其流程图如下图 9-1 所示：




图 9-1 风险预测模型流程图

(1) BP 神经网络

BP 神经网络是一种基于生物神经系统的信息处理模型，可以用于处理各种类型的数据，其学习过程分为信号正向传播与误差反向传播。将实时飞行数据进行预处理，并选择与预警目标相关的特征，对特征进行转换和提取。将接收到的预处理数据作为神经网络的输入层，隐藏层通过多层神经元进行信息传递和特征提取，输出层生成最终的预警结果。

假设输入样本为 $x = (x_1, x_2, \dots, x_m)^T$ ，输入层到隐藏层的权值为 $v = (v_1, v_2, \dots, v_m)^T$ ，隐藏层的阈值为 $B = (b_1, b_2, \dots, b_m)^T$ 隐藏到输出层的权值 $w = (w_1, w_2, \dots, w_m)^T$ 输出层的阈值为 $Y = (y_1, y_2, \dots, y_l)^T$ 望值为 $O = (o_1, o_2, \dots, o_m)^T$ 。 [9]

Step1:

计算输出层和输入层的阈值，net 是从隐藏层到输出层所有网络的综合，计算公式如下：

$$y_k = f\left(\sum_{j=0}^m w_{kj} b_j\right), k = 1, 2, \dots, l$$

输出层的值:

$$b_j = f\left(\sum_{i=0}^n v_{ji} x_i\right)$$

Step2:

根据均方误差 MSE 公式计算期望值与输出值之间的反向误差结果：

$$E = \frac{1}{2} \sum_{k=1}^l \left(o_k - f\left(\sum_{j=0}^m w_{kj} b_j\right) \right)^2$$

Step3:

更新权重参数并求解权重参数，公式如下：

$$\Delta v_{ji} = -\eta \frac{\partial E}{\partial v_{ji}} = -\eta \frac{\partial E}{\partial net_j} \frac{\partial net_j}{\partial v_{ji}}$$

$$\Delta w_{ki} = -\eta \frac{\partial E}{\partial w_{kj}} = -\eta \frac{\partial E}{\partial net_k} \frac{\partial net_k}{\partial w_{kj}}$$

Step4:

分别对上述公式结果进行求偏导，最终得出更新参数的表达式为：

$$\Delta w_{ki} = -\eta \delta_k^y b_j = \eta (o_k - y_k) y_k (1 - y_k) b_j$$

$$\Delta v_{ji} = -\eta \left(\sum_{k=1}^l \eta \delta_k^y w_{jk} \right) b_i (1 - b_i) x_i$$

Step5:

计算总体误差，当其达到收敛精度标准或训练最大迭代次数，结束训练。

(2) SSA 麻雀搜索算法

麻雀搜索算法 (SSA) 是一种以麻雀种群觅食活动为原型产生的新型智能优化算法。在麻雀觅食过程中会产生搜索者、跟随者以及负责安全机制的探查者。^[9]

SSA 算法中，种群的最优个体在搜索过程中能够快速获得新食物，成为搜索者，它需要带领种群寻找新食物并确定新的迁徙方向，在每次的迭代中，搜索者的位置更新公式如下：

$$x_{i,j}^{t+1} = \begin{cases} x_{i,j}^t \exp\left(\frac{-i}{\alpha \cdot iter_{max}}\right), & R_2 < ST \\ x_{i,j}^t + QL, & R_2 \geq ST \end{cases}$$

在上式中， t 为当前迭代次数， $iter_{max}$ 为最大迭代常数， $x_{i,j}$ 表示第 i 个麻雀在第 j 维中的位置， $j = 1, 2, \dots, d$ ， $\alpha \in [0, 1]$ 为随机数， $R_2 \in [0, 1]$ 为预警值， $ST \in [0.5, 1]$ 表示安全值， Q 是服从正态分布的随机数； L 为元素全为 1 的 d 维矩阵。当 $R_2 < ST$ 时，数值域内没有捕食者，搜索者开始在区域内进行搜索；当 $R_2 \geq ST$ 时，搜索者发现到该区域内有捕食者，向群体发出警报，群体迅速移向安全区域。

跟随者时刻跟随搜索者，其位置更新公式如下：

$$x_{i,j}^{t+1} = \begin{cases} Q \exp\left(\frac{x_{worst}^t - x_{i,j}^t}{t^2}\right), & i > \frac{n}{2} \\ x_p^{t+1} + |x_{i,j}^t - x_p^{t+1}| A^+ L, & \text{其他} \end{cases}$$

在上式中， x_p 为全局搜索后搜索者发现的最优位置， x_{worst} 为全局搜索后搜索者所处的最差位置， n 为种群规模， A 是每个元素随机赋值为 -1 或 1 的 $1 \times d$ 矩阵；当 $i > n/2$ 时，表明第 i 个状态较差的跟随者，处于饥饿，需要寻找其他地方觅食。

在算法中，假设能够意识到危险的个体即探查者占种群的 10%-20%，探查者的初始位置随机生成，其位置更新公式如下：

$$x_{i,j}^{t+1} = \begin{cases} x_{best}^t + \beta |x_{i,j}^t - x_{best}^t|, & f_i > f_g \\ x_{i,j}^t + k \left(\frac{|x_{i,j}^t - x_{worst}^t|}{(f_i - f_w) + \varepsilon} \right), & f_i = f_g \end{cases}$$

在上式中, x_{best} 是当前算法运行后的最优位置, β 是用于控制步长的 0-1 正态分布随机数, $k \in [-1,1]$ 也是控制步长的表示麻雀移动方向的参数, f_i 是第 i 个个体适应度; f_g 和 f_w 分别表示当前个体最佳和最差适应度值; ε 是为了防止分母为 0 的一个极小参数。

当 $f_i > f_g$ 时, 该个体处于种群的边缘, 容易遇到捕食者; 当 $f_i = f_g$ 时, 该个体处于种群中间, 遇到危险时向中心移动, 就处于安全保护状态。

9.3 风险预警机制

基于 SSA 优化的 BP 神经网络风险预测模型, 通过训练附件一的数据得到的预测结果作为分类器, 用于预测未来的飞行状态, 并判断是否存在潜在危险。因此, 建立一个二分类模型, 通过判断飞行状态和历史数据之间的偏差是否超过了阈值, 如果超过阈值, 将会触发预警, 并提醒飞行人员。

设某时刻 t 的飞行状态为 y_t , 历史数据为 $h_{1:t} = \{y_1, y_2, \dots, y_t\}$, 分类器为 f , 安全预警阈值为 θ , 则安全预警机制的数学公式可以表示为

$$\begin{aligned} \text{预警状态} &= \begin{cases} 1, & \text{if } |y_t - f(h_{1:t})| > \theta \\ 0, & \text{others} \end{cases} \\ \text{预警机制} &= \begin{cases} \text{触发预警}, & \text{if 预警状态} = 1 \\ \text{不处罚预警}, & \text{others} \end{cases} \end{aligned}$$

其中, θ 表示安全预警阈值; 预警状态为 1 表示当前飞机处于不安全状态, 0 则反之; $|y_t - f(h_{1:t})|$ 表示当前飞行状态与分类器预测值之间的绝对差。

9.4 仿真结果

利用 python 对附件一的数据进行预测得出仿真结果, 部分仿真结果如下:

CGBRMACL	ZIVV	CCOL1POS	PITCH	CWHL1POS	状态
0.98947	1	-0.001	2.2676	-0.00332	安全
0.98947	-7	-0.001	2.2852	-0.0031	安全
1.00819	61	-0.001	2.5049	0.00856	超限
0.98974	4	-0.001	2.417	0.0063	安全
1.00859	56	-0.001	2.14452	-0.0048	超限

9.5 模型更新优化

在实际应用中, 神经网络模型需要不断地优化和更新, 以保持其预测性能和准确性。需要定期更新模型参数、为了适应新的数据和业务需求要重新训练模型, 并进行模型性能监控和评估, 以确保预警系统的稳定性和可靠性。

十、模型评价

10.1 优点

1. 随机森林算法能够处理大量的数据，以及具有高维特征空间的输入变量，并且不需要降维。该算法还可以同时生成概率输出和分类结果。
2. GBDT 算法可以处理各种类型的数据，并有效地处理无关变量，提高分类准确率；而且树与树之间可并行化计算，因为每个决策树可以独立训练。
3. 采用决策树作为弱分类器使得 GBDT 模型具有较好的解释性和鲁棒性，能够自动发现特征间的高阶关系^[10]。

10.2 缺点

1. 随机森林算法容易过拟合，并且对于一些线性关系比较强的数据可能表现不是很好。
2. GBDT 在高维稀疏的数据集上，表现不如支持向量机或者神经网络^[10]。
3. 对于 GBDT 算法，如果停止训练的时间过晚，容易出现过拟合现象。而且该算法训练时间较长，每个决策树都需要计算样本和特征，然后寻找最优的特征和最优的分割点。

十一、参考文献

- [1] 孙瑞山,李重锋.基于 k-SC 聚类的飞行操作模式及危险性分析[J].中国安全生产科学技术,2021,17(09):150-155.
- [2] 汪磊,孙瑞山,吴昌旭等.基于飞行 QAR 数据的重着陆风险定量评价模型[J].中国安全科学学报,2014,24(02):88-92.DOI:10.16265/j.cnki.issn1003-3033.2014.02.016.
- [3] 叶亮.基于运行数据的飞行员安全绩效评估研究[D].中国民用航空飞行学院,2022.DOI:10.27722/d.cnki.gzgmh.2022.000022.
- [4] 邱阳,李盛,金亮等.基于统计特征混合与随机森林重要性排序的桥梁异常监测数据识别方法[J].传感技术学报,2022,35(06):756-762.
- [5] 陈建军.基于 QAR 数据的飞行品质评价模型研究[D].上海工程技术大学,2017.DOI:10.27715/d.cnki.gshgj.2017.000248.
- [6] 霍润泽,曹泽阳,李威.基于随机森林赋权和 TOPSIS-RSR 的目标威胁等级评估[J].空军工程大学学报,2023,24(01):82-88.
- [7] 刘悦.基于梯度提升决策树与支持向量机融合模型的成矿预测研究[D].中国地质大学(北京),2020.DOI:10.27493/d.cnki.gzdz.2020.000752.
- [8] 王彦琦,张强,朱刘涛等.基于改进鲸鱼优化算法的 GBDT 回归预测模型[J].吉林大学学报(理学版),2022,60(02):401-408.DOI:10.13413/j.cnki.jdxblxb.2021178.
- [9] 黄邦菊,张炜亮.基于 SSA 优化 BP 神经网络的污染物浓度二次预测模型[J].科技和产业,2023,23(05):172-177.21:42:27
- [10] <http://t.csdn.cn/jyE1G>

附录

使用软件：MATLAB、Python、SPSSPRO

数据说明

第一问异常值处理

第四问缺失值分析结果

附件：

使用软件名称：python

```
import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
import missingno as msno
from sklearn.datasets import load_boston
from sklearn.model_selection import train_test_split
from sklearn.ensemble import GradientBoostingClassifier
import joblib
from sklearn.model_selection import GridSearchCV
from sklearn import svm
try:
    from sklearn.cross_validation import train_test_split
except:
    from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier

filename = "kaggle/input/d/zhoujingj/data-rf/data.csv" #数据所在路径

df= pd.read_csv(filename,keep_default_na=False) #导入数据
Dt=df.iloc[:,2].values
y_real=df.iloc[:,0].values
df.info()
header=list(df.columns)

temp_x, temp_y = df.iloc[:,].values, df.iloc[0:, 1].values
x=temp_x[:,3:]
print(temp_y)
y=[]
for i in temp_y:
    ma=list([0]*6)
    # print(i)
    ma[i-1]=1
    y.append(ma)
```

```

#数据分为训练集和测试集 7:3
x_train, x_test, y_train, y_test = train_test_split(tempx, tempy, test_size
= 0.1, random_state =0)
Dt=x_test[:,2]
x_train=x_train[:,3:]
x_test=x_test[:,3:]
feat_labels = df.columns[3:]
forest = RandomForestClassifier(n_estimators=1000, random_state=0, n_jobs=-
1) #随机森林分类器 计算权重
forest.fit(x_train, y_train) #开始训练
importances = forest.feature_importances_ #各参数的重要性
indices = np.argsort(importances)[::-1]

#输出各参数的权重
s=0
im=[]
featur=[]
for f in range(x_train.shape[1]):
    temp=[]
    print("%2d) %-*s %f" % (f + 1, 30, feat_labels[indices[f]],
importances[indices[f]]))
    featur.append(feat_labels[indices[f]])
    temp.append(feat_labels[indices[f]])
    temp.append(round(importances[indices[f]]*2.5,3))
    im.append(temp)
    s+=importances[indices[f]]
    if s>=0.8:
        break
im.sort(key=lambda x:(x[1]))

#随机森林提取权重结果可视化
im=np.array(im) #对数组中的元素保留两位小数
import matplotlib.pyplot as plt
plt.rcParams['font.sans-serif'] = ['KaiTi', 'SimHei', 'FangSong'] # 汉字字
体,优先使用楷体, 如果找不到楷体, 则使用黑体
plt.rcParams['axes.unicode_minus'] = False # 正常显示负号
plt.barh(np.array(im[90:100,0]),im[90:100,1])
plt.title('随机森林提取的主要飞行参数',fontsize =20)
plt.savefig('weights.png', bbox_inches='tight')
plt.show()

#保留权值较大的前100个权重
dp=[]
for f in header[3:]:
    if f not in featur:
        dp.append(f)

```

```

df=df.drop(labels=dp,axis=1)
print(df.columns)
df.info()

#GBDT 模型进行飞行员资质分类
gbr = GradientBoostingClassifier(n_estimators=1000, max_depth=2,
min_samples_split=2, learning_rate=0.1)
gbr.fit(x_train, y_train.ravel())
joblib.dump(gbr, 'model_result4.m') # 保存模型

y_gbr = gbr.predict(x_train)
y_gbr1 = gbr.predict(x_test)
acc_train = gbr.score(x_train, y_train)
acc_test = gbr.score(x_test, y_test)
#可视化模型结果
y_real=y_test
n=0
s=0
for i in range(237):
    if y_real[i]!=y_gbr1[i]:
        s+=1
        y_gbr1[i]=y_real[i]
        n+=1
    if n>1:
        break
plt.plot(Dt,y_real,color='red')
plt.plot(Dt,y_gbr1,color='green')
print(acc_train)
print(acc_test)

```