

队伍编号	MC2211750
题号	A

大规模指纹图像检索的模型与实现

摘要

生物识别领域中，指纹识别被广泛应用，指纹筛选和识别的问题受到广泛关注。对于指纹的筛选过程，筛选算法的设定尤为重要。

针对问题 1，本文利用指纹图像的特征点坐标，将指纹图像进行分割为多个子空间。统计每个子空间内的特征点坐标，用来计算该子空间下的特征，并将所有子空间的坐标信息组合为该指纹的**特征向量**，利用 **K-mean 聚类法**，以特征向量为聚类标准，使用**欧氏距离**对指纹数据集进行聚类。在查询过程中，计算查询指纹的特征值，再与数据库中不同的子类中心坐标进行比对，确定距离最小的几个子类作为该查询指纹在数据库筛选的结果。在只使用特征向量进行检索的情况下，在 **80%，90%，95%，97%** 筛选的条件下，**穿透率**分别为 80%、76%、64%和 36%。当需要筛选掉较多的指纹数据时，针对上述方法快速但容易泄露“同一”指纹的情况，本题利用特征向量预先筛选出一定的指纹，并对筛选出的指纹一一对比，确定相似程度最高的部分指纹作为筛选结果。通过引入**第二次筛选**，可以极大提升检索结果，同时避免遍历数据库的问题。

将问题 1 中的算法应用于问题 2，并考虑到指纹数据收集的不稳定性，在二次筛选前进行指纹图片的校正。对于筛选算法，我们比较了利用欧氏距离、利用 **BP 神经网络**以及使用极坐标下增设**自适应误差窗口**判断不同图像中任意两个特征点的**相似度**。结果表明，对于本文的数据，使用简单的欧氏距离可以达到较好的效果，在 **80%，90%，95%，97%**筛选量的情况下，结果分别为 **93.7%、88.7%、84%、和 80.3%**。而利用 BP 神经网络和自适应误差窗口较差且需要较大的计算量。再将问题 2 的方法应用于问题 3 得出问题 3 的检索结果。

提出的**二次检索模型**可以兼顾时间和检索效率，首先快速筛选掉大量不相关的样本，再通过逐一匹配得到高质量的筛选数据。对于 97%即以上的筛选量，单一的筛选方式几乎无法满足要求，因此需要不同的检索方式进行**组合**：先进行大量样本的筛除，之后利用精确度较高的算法进行继续筛选，直至达到要求。对于每一个步骤中的筛选，可以结合多个筛选方式，以**集成学习投票**的方式筛选目标样本，避免单一因素的影响。

关键词：指纹匹配；K-means 聚类；欧氏距离；特征向量；图像分割；二次检索

目录

第 1 章 问题重述	1
1.1 问题背景	1
1.2 问题描述	1
1.3 总体思路分析	2
第 2 章 符号说明与基本假设	3
2.1 符号说明	3
2.2 基本假设	3
第 3 章 问题 1 的建模与求解	4
3.1 指纹图像的细节点特征	4
3.2 指纹快速检索实现方法	4
3.3 避免筛除掉“同一”指纹的机制	5
3.4 指纹快速检索实现模型及方法	6
3.5 时间复杂度与空间复杂度分析	11
第 4 章 问题 2 的建模与求解	12
4.1 数据预处理	12
4.2 指纹细节点特征检索匹配求解	14
第 5 章 关于问题 3 的求解	17
5.1 问题 3 分析	17
5.2 问题 3 求解	17
第 6 章 关于问题 4 的求解	19
6.1 完成本题尝试的模型及技术线路	19
6.1.1 BP 神经网络算法	19
6.1.2 自适应误差窗口	21
6.2 结果对比分析	22
6.3 模型改进策略	23
第 7 章 模型的评价与推广	25
7.1 模型评价	25
7.1.1 模型的优点	25
7.1.2 模型的不足之处	25
7.2 模型推广	25
第 8 章 参考文献	26
附录	27

第1章 问题重述

1.1 问题背景

在生物特征识别领域，指纹作为最具独特性与持久性的生物特征之一，被广泛应用于身份识别。指纹识别过程分为特征提取和比对两个环节。其中特征提取环节会提取用于指纹识别的指纹特征，一般国际上最为常见的指纹特征为“细节点”特征。指纹识别分为指纹匹配环节和指纹图像匹配环节。

在指纹匹配环节，需要对两幅指纹图像的“同一性”进行定量评价，通常采用相似度指标。常见的两枚指纹之间的相似度评价主要依据每枚指纹图像中各个细节点之间的匹配关系。

在指纹图像匹配环节，常需要考虑如下的情况：（1）考虑到在采集指纹图像时，手指按压图像采集设备的角度、轻重及位置各不相同，因此两幅指纹图像需要做图像的旋转、平移后才能相互对准。（2）由于手指皮肤较为柔软，通过按压方式采集到的指纹图像会发生一定程度的不规则弹性形变。（3）考虑到手指可能存在临时性蜕皮、褶皱等因素，且空气中的湿度及皮肤表面的干燥程度或粘附在皮肤上的异物等都会导致采集到的指纹图像存在纹线模糊、遮挡等现象，最终导致某些原本应该提取到的特征没有提取到，或者提取了一定数量的伪特征。（4）随着社会上指纹识别应用的普及，用于识别人员身份的指纹数据库规模也迅速上升，居民身份证指纹库容甚至达到了亿人级别。

这也会导致“逐一”遍历全库的查找方式因每次遍历时间过长而无法具有实际应用价值，必须引入图像检索技术，缩短数据库的每次遍历时间。指纹图像的检索原理可以形象的看成：用若干大筛子快速、精准地筛除掉数据库中绝大多数与查询指纹图像明确不具有“同一”关系的图像。检索过程完成后，留下的少量图像和查询指纹具有高度相似性，需要进一步利用指纹识别算法做“逐一”识别。一般而言，图像检索过程筛选掉的指纹图像少，则在检索过程完成后保留下来“同一”关系指纹图像的可能性大，但是整个识别过程的耗时较长；反之，检索算法筛选掉的指纹图像多，则在筛选后保留下来“同一”关系指纹图像的可能性相对变小，但是整个识别过程的耗时较短。若检索过程中筛选掉了“同一”关系的指纹，则后续“逐一”比对算法无论怎么改进都无法再找到这枚“同一”关系的指纹。因此如何设计高效精准的搜索算法是大规模指纹图像检索的关键问题。

1.2 问题描述

问题 1：分析指纹图像的细节点特征给出可用于指纹快速检索的检索方法，请

阐述该检索方法的原理。重点说明：（1）检索过程中避免筛除掉“同一”指纹的机制；（2）完整、清晰的图像检索模型框架及实现方法；（3）给出该检索方法的时间复杂度、空间复杂度分析。估算检索方法自身占用的内存空间规模及由于采用该检索方法，每一枚指纹图像需要承担的内存空间大小。

问题 2：针对提出的检索方法：将数据文件中提供的具有“同一”关系的全部指纹对子（TZ_同指.txt）作为查询图像在指纹数据集中进行检索方法验证。

问题 3：针对 TZ_同指 200_乱序后_Data.txt 数据文件采用和问题 2 相同的方式进行检索，给出检索结果。

问题 4：（1）在完成本赛题时可能尝试了不同类型的数学模型及技术路线，并利用问题 2 的数据验证、优选出最佳的检索方法。请介绍并评价所考虑过的模型及技术路线的优缺点；（2）本赛题最高的筛选量为 97%，针对 97% 以上的筛选量，在检索精度、检索时间及内存占用等方面有什么更好的改进策略或者会尝试什么新的检索方法？

1.3 总体思路分析




图 1： 总体流程图

第 2 章 符号说明与基本假设

2.1 符号说明

表 1 符号说明

符号	说明
ρ	欧式距离
F_p	细节点向量
M_p	特征向量
D_{pq}	距离矩阵
D_{pq}^*	最小距离矩阵
g_{pq}	指纹匹配相似度
g_{pq}^*	最小指纹匹配相似度

*其他未标明符号在文中说明

2.2 基本假设

假设 1：所有数据来源于附件，TZ_同指.txt 全部 500 个匹配对子（合计 1000 行）的数据均为真实的采样数据，且三组数据符合相同或者相似的分布，数据之间没有较大的差别。

假设 2：数据部分受脱皮等其他情况的影响，但不损坏整体的指纹特征或整体指纹特征受异常情况的影响的数据量很少。

假设 3：所有来自文件的指纹特征点能反映指纹的大部分特征，彼此之间相互分散。

第3章 问题1的建模与求解

3.1 指纹图像的细节点特征

指纹图像的细节点特征[1]的形成主要与局部纹线相关。主要包含纹线的端点、分叉点、断点、桥点、环点、岛、孤点。各种细节特征点的定义如下：

端点：一条纹线的起点或终点。

分叉点：两条纹线的汇合点，形如“Y”。

断点：一条纹线断裂形成的点。

交叉点：两条纹线的汇合点，形如“X”。

桥点：两条相近纹线由一条额外线段横跨连接后形成的连接点

环点：一条纹线经历短暂分叉，又迅速汇合形成的点。

岛：存在两条纹线之间的非常短的纹线。

孤点：孤立的点状纹线。



图 2：指纹细节点特征示意图

在以上七种细节点特征中，端点和分叉点出现的概率达 80%以上，这两类特征具有易提取、对噪声不敏感的特点，在提取细节点时是主要提取的对象。

从附件中的文件来看，每个指纹数据中包含若干特征点，每个特征点由 x , y 坐标以及响应的 θ 组成。在一组对应的指纹数据中，两者对应位置上的 θ 值大致相近，但是也有部分缺失的情况。

3.2 指纹快速检索实现方法

在对指纹进行匹配时，可以引入预筛选技术缩小指纹匹配空间以提高指纹

识别效率。预筛选技术通常可以分为两类：指纹分类、指纹检索。在指纹分类中，指纹数据库被划分为固定类别，将输入指纹与同一分类的指纹进行匹配即可。指纹分类最大缺点是指纹类别有限且分布非常不均，在 Galton-Henry 分类方案中，右环型、左环型和漩涡型 3 类大约占 93% [2]，因此指纹分类并不能有效缩小匹配空间；此外，对于残缺和高质量指纹图像，指纹分类无法准确判断其类型，导致该类指纹识别成功率较低。指纹检索首先提取稳定的特征向量，通过寻找与其特征向量相似度较高的一批指纹作为候选指纹模版，然后一对一进行精细匹配。指纹检索很好地避免了指纹分类中对于残缺和高质量指纹类别无法判断的问题，而且该技术的检索性能远远优于指纹分类技术。

本文拟通过指纹图像特征点进行分割，提取特征向量，之后对特征向量的聚类构建数据库，来进行指纹快速检索。

3.3 避免筛除掉“同一”指纹的机制

指纹检索的过程中首先需要提取稳定的特征向量，通过寻找与其特征向量相似度较高的一批指纹作为候选指纹模版，然后一对一进行精细匹配。常见的指纹检索方法基于特征匹配的尺度不变特征变换（scale invariant feature transform, SIFT）算法，因其优越的性能在指纹匹配算法中得到广泛应用，在 SIFT 算法应用中，特征向量匹配是其中的一个重要环节，决定图像配准算法的最终配准结果。SIFT-like 方法中的邻近距离比值 (nearest neighbor distance ratio, NNDR) 匹配策略，采用最邻近距离的比值作为判断两个特征向量是否为匹配特征点的依据。虽然该方法中引入距离比值消除了许多无匹配，但如果图像中有较多相似局部区域，会造成一对多的匹配结果。在筛除指纹图像时也容易筛除掉“同一”指纹。同时，同一指纹的不同图像会发生不同程度的平移、旋转以及局部失真，使得无法匹配到“同一”指纹。

为解决以上问题，首先尝试对指纹图像进行校正处理。利用指纹图像特征点的分布特征，对数据进行距平，并利用主轴方向调整数据的角度。之后为了解决边缘的误差问题，在后续的处理过程中删除部分靠近边缘的特征点数据。

由于对特征点的每个主方向的特征描述进行单独匹配的传统方式并不可靠，因此，需要直接对特征点的所有主方向的特征描述，计算其综合最相似距离，消除干扰和冗余，以提高正确匹配对数。

3.4 指纹快速检索实现模型及方法

3.4.1 模型准备

(1) K-means 聚类法

K-means 聚类算法[3]是一种迭代重定位的算法，该算法一般分为两个步骤：第一步是迭代，计算每个样本点之间的距离，再将相应的样本点划分到距离最近的簇中，完成初始聚类；第二步是重定位，重新计算每个簇的聚类中心，并且将距离最近的样本点划分到相应的簇中，重复这个操作，直到聚类中心不再发生变化。该算法是通过多次迭代方式获得聚类结果。其基本思想为：首先在给定的数据集合中随机选取 K 个初始聚类中心；然后计算所有样本点的距离，按照距离最近原则，将样本点划分到相应的簇中；在每次迭代的过程中重新计算各簇的聚类中心；当聚类中心不再变化或者达到指定条件时，不再进行聚类，至此聚类结束；输出聚类结果。为了更好地理解 K-means 聚类算法的过程，给出其流程图，如图 3 所示。聚类结果应使同一个簇中的样本点距离尽可能的近，而不同簇的样本点之间的距离尽可能的远。




图 3： K-means 聚类算法流程图

传统 K-means 聚类算法的初始聚类中心是随机选择的，而且聚类数目 K 也是人为确定的，初始聚类中心以及 K 一旦确定，则整个聚类算法的迭代过程就由算法自行计算。每次选取不同的初始聚类中心和 K，使得聚类结果也不同，所以这在很大程度上影响了聚类的稳定性。另外，K-means 聚类算法仅仅适用于数值型数据且聚类结果为球形的数据集，不适合于发现非凸形状的簇或者差别很大的簇；数据集中的噪声点和离群点也会对聚类结果产生一定的影响；同时聚类常常以局部最优结束。为此，本模型采用区域分割处理，根据指纹特征点的坐标位置不同划分指纹区域，确定中心点，设定阈值，进行聚类。

(2) 欧式距离

欧氏距离（Euclid Distance）也称欧几里得度量、欧几里得距离，是一个通常采用的距离定义，它是在 m 维空间中两个点之间的真实距离。

二维空间的欧式距离计算公式：

$$\rho = \sqrt{(x_1 - x_2)^2 - (y_2 - y_1)^2} \quad (1)$$

其中， ρ 为点 (x_1, y_1) 和点 (x_2, y_2) 之间的欧式距离。

三维空间的欧式距离计算公式：

$$\rho = \sqrt{(x_1 - x_2)^2 - (y_1 - y_2)^2 - (z_1 - z_2)^2} \quad (2)$$

n 维空间的欧式距离计算公式：

$$\rho(x, y) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + (x_3 - y_3)^2 + \cdots + (x_n - y_n)^2} \quad (3)$$

本次模型采用 n 维空间的欧式距离计算方法。

3.4.2 检索方法

(1) 初匹配

在初匹配阶段，利用相邻点间的结构关系建立局部特征向量进行初步匹配。初匹配不但可以减少拒判时间，而且可以准确获得对点集进行重新定位的校准参考点，该环节分两步实现。首先对数据库中的每一张指纹图像进行单独处理，进行聚类便于检索。对于任一张指纹图像的特征点：

$$F_p = \begin{bmatrix} (x_1, y_1, \theta_1) \\ (x_2, y_2, \theta_2) \\ \vdots \\ (x_m, y_m, \theta_m) \end{bmatrix} \quad (4)$$

其数据为 x, y, θ 三个维度。在指纹图像发生平移、旋转或局部变形时，特征

点的绝对位置信息会有很大变化。但相邻点间的距离和相对角度等却不会有太大的改变。因此，对指纹特征点进行区域分割处理，以下图 4 为演示。基于特征点欧式距离建立局部特征向量，可以很好的解决平移及旋转问题。对每一个维度进行 s 等分，特征点被划分到 s^3 个子空间内。




图 4： 指纹细节点区域分割示意图

在每一个子空间内，分别计算这个子空间内包含特征点的 $\bar{x}, \bar{y}, \bar{\theta}$ 。之后这些特征点按照顺序排列，组成这个指纹图像的特征向量

$$M_p = (\overline{x_1}, \overline{y_1}, \overline{\theta_1}, \overline{x_2}, \overline{y_2}, \overline{\theta_2}, \dots, \overline{x_s}, \overline{y_s}, \overline{\theta_s}) \quad (5)$$

为了消除边缘特征点对形变的影响，删除靠近边缘的子空间的特征点，得到指纹的特征向量 M_p^* 。这样每一张指纹图像可以计算出一个特征向量。对数据库中所有指纹图像的特征向量进行 k-mean 聚类，得到 k 个子类，以及每一个子类的中心特征向量。

对于任一张需要检索的图像，计算该图像的特征向量，之后分别与这 k 个子集的中心点计算欧氏距离，并进行排序。选择欧氏距离最小的几组子集中的所有指纹图像，作为检索的返回结果。

我们提取 TZ_同指.txt 的数据和 TZ_异指.txt 的数据组成比对的数据集，将 TZ_同指.txt 的数据在这个数据集内进行匹配验证，数据中过滤的比例与同一指纹未被筛选掉的比例（穿透率）如下图 5 所示：




图 5: k 中等样本数据中筛选的比例与匹配指纹的穿透率

对中等数量样本的数据进行比对筛选，得到小样本数据。中等样本数据分别在保留 10% (3 groups)、20% (6 groups)、30% (10 groups)的情况下，穿透率为 64%、80%和 91%，而在保留 3% (1 group)的情况下，穿透率下降为 36%。在保留 20%样本的情况下，可以使用该方法进行初匹配，但是对于筛选较少的样本，需要考虑额外的匹配增加穿透率。

(2) 二次匹配

如果检索筛选出数量较多的样本，那么对于任一个需要比对的指纹数据，比较该指纹数据与 k 类中心的距离，选取距离较小的若干组作为筛选出的数据。如果筛选出数量较少的样本，通过比较该指纹数据与 k 类中心的距离直接筛选，会有较大的误差。我们先选取距离较小的若干组作为筛选出的数据，然后将这些中的所有指纹数据组成中等的数据库，然后对数据库中的指纹数据一一遍历比较，筛选出最相似的小数量样本，返回较少但是较优的检索结果。

经过上述初步筛选出一个较大的样本之后，我们利用如下的方法比较两个指纹的相似程度，选取相似程度较小的一个小样本作为最终筛选得到的样本。记分别含有 m, n 个特征点的 p, q 两个指纹为

$$F_p = \begin{bmatrix} (x_1, y_1, \theta_1) \\ (x_2, y_2, \theta_2) \\ \vdots \\ (x_m, y_m, \theta_m) \end{bmatrix}, \quad F_q = \begin{bmatrix} (x_1, y_1, \theta_1) \\ (x_2, y_2, \theta_2) \\ \vdots \\ (x_n, y_n, \theta_n) \end{bmatrix} \quad (6)$$

计算两个指纹的相似度，两个指纹中的特征点两两之间进行一一对比。 F_p 中第 i 个特征点与 F_q 中第 j 个特征点之间的距离使用欧氏距离衡量， θ 转化为直角坐标系下的 z 坐标

$$z = \sqrt{x^2 + y^2} (\sin \theta) \quad (7)$$

$$d_{ij} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2 + (z_i - z_j)^2} \quad (8)$$

两个指纹之间的距离矩阵可以表示为

$$D_{pq} = \begin{pmatrix} d_{11}, d_{12}, \dots, d_{1n} \\ d_{21}, d_{22}, \dots, d_{2n} \\ \vdots \\ d_{m1}, d_{m2}, \dots, d_{mn} \end{pmatrix} \quad (9)$$

根据对应关系， $D_{pq} \neq D_{qp}$ 。我们将两个图像中欧式距离最近的一对点对作为一对可能的匹配细节点，即以 F_p 指纹为标准， F_q 中与 F_p 第 i 个特征点的最近点记为 p_i ，则可以得到 F_q 指纹在 F_p 指纹中相匹配细节点的位置与距离

$$p = (p_1, p_2, \dots, p_m) \quad (10)$$

$$D_{pq}^* = (d_{1p_1}, d_{2p_2}, \dots, d_{mp_m})^T \quad (11)$$

考虑到同指指纹的少部分特征点的由于采样的影响，导致匹配会有较大的偏差，而异指的指纹偏差都会比较大，为了进行更好地区分，取 D_{pq}^* 的前 95% 成功匹配的结果，即

$$P^* = (P_1, \dots, P_{[m*0.95]}) \quad (12)$$

$$D_{pq}^{**} = (d_{1p_1}, \dots, d_{[m*0.95]p_{[m*0.95]}})^T \quad (13)$$

将距离转化为相似度指标，对相似度指标取倒数，为了避免距离极小而导致的除零操作，对距离进行了加 1。指纹的采样过程中可能位置整体偏移，或者部分缺失，导致匹配点两两之间的距离保持在一个相对平均的水平，因此在相似度指标中考虑了方差的影响。

$$g_{pq} = \frac{1}{1 + D_{pq}^{**}} + \frac{1}{1 + Var(D_{pq}^{**})} \quad (14)$$

由于 $D_{pq} \neq D_{qp}$ ，因此一般 $g_{pq} \neq g_{qp}$ 为了更好地保留匹配点的特征，在 F_p 指纹匹配 F_q 指纹的指标中，取

$$g_{pq}^* = \min(g_{pq}, g_{qp}) \quad (15)$$

利用上述算法，可以在保证运算速度的情况下，迅速从中等数量的样本中筛选出小样本，并可以利用相似度指标对小样本进行初步排序。

3.5 时间复杂度与空间复杂度分析

筛选出数量较多的指纹数据，只考虑指纹所属的聚类类别，因此对于每一张指纹数据的处理，只需要分别计算与 k 个聚类中心的距离，即需要进行 k 步操作，即时间复杂度为 $O(n)$ ；当需要筛选出数量较少的数据时，需要先从数据库中筛选出中等数量的数据，之后再从中等数量样本的数据中进一步比对。在图像的两两对比过程中，需要对两个指纹的特征点分别进行比较，即指纹图像与 $\sum_{i \in s} N_i$ 个指纹数据分别计算，每一次计算中需要进行 $m \times n$ 次的特征点计算，因此时间复杂度为 $O(n + n^2)$ 。

在聚类的过程中，我们需要按照指纹特征点的 (x, y, θ) 坐标，对指纹进行分割为若干部分，因此在分割图像、划分聚类坐标的过程中，考虑到坐标是三维。如果将每个坐标分为 s 个部分，则所有的划分空间数量为 s^3 ，去除掉靠近边缘的子空间，则子空间数量为 $(s-1)^2$ ，因此空间复杂度为 $O(n^3)$ ；在中等数量样本筛选小部分数量样本的过程中，涉及到图像特征点计算的部分，需要生成特征点两两间的距离矩阵，这个空间复杂度为 $O(n^2)$ 。

表 2 时间复杂度与空间复杂度总结

名称	指纹/空间数量	本文运行结果
时间复杂度	$\sum_{i \in s} N_i$	$O(n + n^2)$
空间复杂度	s^3	$O(n^3)$
	$(s-1)^2$	$O(n^2)$

在内存占用上，快速检索需占用的内存空间除了指纹图像特征点之外，还有自身的特征向量；而在进一步的筛选上，内存占用包括两幅指纹图像间的距离矩阵。因此相对来说，该方法简单在选取的参数不大的情况下，内存占用小。

第 4 章 问题 2 的建模与求解

4.1 数据预处理

考虑到在采集指纹图像时，手指按压图像采集设备的角度、轻重及位置各不相同，因此两幅指纹图像需要做图像的旋转、平移后才能相互对准。由于手指皮肤较为柔软，通过按压方式采集到的指纹图像会发生一定程度的不规则弹性形变，处理的图像中也都会发现两幅指纹图像中，某些相互匹配的细节点在对准时，不能完全“重叠”，有一定幅度的位置及角度的偏差。基于上述问题，本文通过对指纹细节点平移和旋转进行一定的处理来消除这些偏差，并取得了一定的效果。

指纹细节点平移公式：

$$\begin{cases} \Delta x_i = x_i - \bar{x} \\ \Delta y_i = y_i - \bar{y} \end{cases} \quad (16)$$

指纹细节点旋转公式：

$$\begin{cases} x^* = \text{mean}(\text{sign}(\Delta x)\Delta x^2) \\ y^* = \text{mean}(\text{sign}(\Delta y)\Delta y^2) \\ \theta = \arctan \frac{y^*}{x^*} \end{cases} \quad (17)$$

θ 记为指纹图像的主轴，对于两个指纹的图像，它们之间的主轴夹角记为 $\Delta\theta$ ，则 (x_r, y_r) 处理后坐标公式为：

$$\begin{cases} y_r = -x^* \sin(\Delta\theta) + y^* \cos(\Delta\theta) \\ x_r = x^* \cos(\Delta\theta) + y^* \sin(\Delta\theta) \end{cases} \quad (18)$$

处理示意过程以 TZ_同指.txt 中第 3 对指纹为例，蓝色细节点表示指纹 A，红色细节点表示指纹 B，绿色指纹细节点连线表示具有同一性，如下图 6-9 所示。




图 6: 平移处理示意图




图 7: 旋转处理示意图




图 8: 原始指纹




图 9: 处理后指纹

从上图 6-9 中可以分析出，分布在中央区域的大部分指纹细节点，通过平移处理后，即可具有同一性；分布在边缘区域的大部分指纹细节点，通过旋转处理后，即可具有同一性，从图 9 中可对比出处理后的指纹细节点整体上有明显调整并具有较高同一性。

得到数据处理前后对比结果如下表 3 及下图 10 所示。

表 3 处理前后穿透率			
穿透率	未处理	平移处理	旋转处理
筛除 80%	91.7%	93.7%	93.8%
筛除 90%	86.9%	89.3%	89.9%
筛除 95%	83.1%	84%	85.1%
筛除 97%	79.5%	80.3%	80.3%




图 10: 数据处理前后对比曲线

从上图 10 中可看出，数据处理之后指纹穿透率有着明显提高，说明本模型指纹调整方案的可行性，为下文优化指纹匹配策略提供较优数据集。

4.2 指纹细节点特征检索匹配求解

经过图像分割并与数据库中的子类匹配后，得到了一个中等数量的子集。之后利用上述方法分别比较两个指纹的相似程度，选取相似程度较小的一个小样本作为最终筛选得到的样本。

图像分割 K-均值聚类指纹检索与匹配方法在数据库（TZ_异指.txt 和 TZ_同指.txt 数据文件）中进行检索，当检索方法分别过滤掉数据集中 80% 图像后，在剩下的小规模子集中，进行两两比对筛选，计算含有“同一”指纹匹配对子的数量占总指纹“同一”匹配对子数量的比例。对文本集做数据可视化分析，以

只保留 3%数据为例，10000_0--10049_1 相似度匹配热力图如下图 11-14 所示，10050_0--10249_1 相似度匹配热力图详见附件。




图 11: 10000_0 相似度匹配热力图




图 12: 10049_1 相似度匹配热力图




图 13: 10050_0 相似度匹配热力图




图 14: 10049_1 相似度匹配热力图

从上图 11-14 中可快速且清晰地看出 10000_0--10049_1 相似度匹配结果，例如以 10004_0 作为目标指纹，查找相似度匹配最高的前 4 个指纹 10004_1、6215_0、4761_0、10017_0，现通过指纹图像溯源，分别画出查找指纹与相似指纹细节点图像，如下图 15 所示。




图 15：指纹与相似指纹细节点

从以上匹配查找指纹与相似指纹细节点图像可得，所用图像分割 K-均值聚类指纹检索，之后再比对筛选的方法是完全可行的。

第 5 章 关于问题 3 的求解

5.1 问题 3 分析

按照问题二的求解思路，对问题三进行求解。对于每一个需要检索的指纹，对指纹图像进行区域分割，计算其指纹的特征向量。之后利用指纹图像的特征向量，在数据库中的子集中进行初筛选，分别计算与检索图像最近的几个子集，得到 40% 的初步筛选结果，这些结果作为下一步的匹配指纹数据集；之后对这些指纹数据集进行二次匹配，分别计算与检索指纹图像的相似度。对相似度的大小进行排序，分别选取相似度前 10%，5% 和 3% 的数据，建立名称为“result_90”、“result_95”、“result_97”的文件夹，将得到的结果写入 txt 文档中。

5.2 问题 3 求解

在上述三个目录中分别保存过滤掉 90%，95%，97% 的指纹图像后，保存 200 枚图像的检索结果。对文本集做数据可视化分析，以“result_97”的文件夹为例，A1--A100 相似度匹配热力图如下图 16-19 所示，A100--A200 相似度匹配热力图详见附件。




图 16: A1--A100 相似度匹配热力图




图 17: A1--A100 相似度匹配热力图




图 18: A1--A100 相似度匹配热力图




图 19: A1--A100 相似度匹配热力图

从上图 16-19 中可快速且清晰地看出 A1--A100 相似度匹配结果，每个目标指纹展示前 4 个相似度最大的指纹序号。例如与 A1 相似度匹配最高的前 4 个指纹 A146、A356、5880_0、3634_0，满足检索要求。

第 6 章 关于问题 4 的求解

6.1 完成本题尝试的模型及技术线路

在赛题期间，我们考虑到了用 BP 神经网络进行快速检索。对指纹图像特征点按照区域进行分割，提取特征向量，从数据库中匹配一定数量的匹配数据。对于提取较少数量的数据，我们可以在第一次提取的基础上增加了数据的比对，使得难以在大型数据库中进行的步骤得以进行。同时，对于比对的步骤，我们尝试了利用神经网络比较特征点以及最邻近两个点的特征，区分两个特征点是否为对应的点。结果表明神经网络与转化极坐标窗口的效果并不好。对于后者，我们认为的原因是神经网络的规模不够大无法提取更多的细节特征，而引入大规模的神经网络会加大计算时间与步骤，导致比对过程的耗时明显增加；也部分由于部分的特征值点的缺失导致，导致该利用最邻近三角形的特征值识别过程并不准确。因此我们使用的时基于距离的方法，一方面该方法简单，对内存和时间的要求小；另一方面，神经网络的使用可以基于深度学习对整个指纹图像进行分类，而本题中提供数据无法支持高效率的网络训练。

6.1.1 BP 神经网络算法

早在 20 世纪 80 年代，随着误差反向传播算法（Error Back Propagation Training）被发明，BP 神经网络正式进入人们的视线。作为人工神经网络的一种，其神经网络映射不需要预先给出，而是通过输入输出数据对其训练，从而建立一种输入输出的关系，得到期望的输出值。

利用 BP 神经网络结构筛选数据集的步骤：

1) 网络结构：

BP 算法包括两个反向的传播过程，计算误差输出是向着输出端进行，而在调整权值和阈值时则向着前向进行。一次训练过程可以表示为，信号从输入端输入，经过隐含层作用于输出节点，产生输出的信号，若此时与所期望的输出信号不相符，此时将误差从输出端输入，通过层层隐含层像输入端传递，在此过程中误差被分配给各层所有单元，而该误差就会作为各单元权值调整的依据。

2) 模型建立：

BP 神经网络旨在建立一套训练系统，通过对输入输出数据的监督训练来优化未知黑箱中的机制、结构。对 BP 神经网络的任意神经元 i ，正向传播途中，隐节点输出模型表示为

$$O_j = f(\sum w_{ij} X_i - q_j) \quad (19)$$

输出节点模型:

$$Y_k = f(\sum T_{jk} O_j - q_k) \quad (20)$$

F 表示非线性作用函数, O 表示计算输出, W 表示两节点之间的权值, q 表示阈值。其算法流程如图 20 所示。




图 20 BP 网络算法图

3) 网络训练

BP 神经网络结构如图所示, 训练前, 首先将数据集按照特定比例分为训练、验证与测试集。用训练集训练 BP 网络。




图 21 BP 神经网络结构

6.1.2 自适应误差窗口

使用自适应窗口对特征的两两进行匹配，首先需要特征点的坐标系转换为极坐标系：

$$\begin{pmatrix} r_i \\ e_i \\ \theta_i \end{pmatrix} = \begin{pmatrix} \sqrt{x_i^2 + y_i^2} \\ \tan^{-1} \frac{y_i}{x_i} \\ \theta_i \end{pmatrix} \quad (21)$$

这样特征点的空间坐标转化为 (r, e, θ) ，检索的空间可以表示为

$$\omega = \begin{cases} \alpha |r_i - r_j| + \beta \Delta e + \gamma \Delta \theta, \delta_l < r_i - r_j < \delta_h \text{ and } \Delta e < \varepsilon \text{ and } \Delta \theta < \varepsilon \\ \Omega, \text{otherwise} \end{cases} \quad (22)$$

$$\Delta e = \text{mod}(e_i - e_j, 360) \quad (23)$$

$$\Delta \theta = \text{mod}(\theta_i - \theta_j, 360) \quad (24)$$

在搜索过程中，搜索窗口自动调整[6]，如下图 22 所示。自适应误差窗口中的限界盒就如同放在指纹特征点上的一个盒子，限界盒大小限着指纹特征点的极角与极半径动态变化。从图中可以明显看出，限界盒的大小取决于当前细节点与原点距离，距离原点越近，极半径变小极角变大；相反，细节点距离原点越远，极半径变大极角变小。当两个指纹图像中的特征点落在同一个限界盒中时，则认为这两个特征点匹配成功。




图 22 自适应误差窗口示意图

针对我们的两两匹配问题，窗口边界的调整梯度为

$$\dot{\delta}_l = \eta \Delta r_a, \dot{\delta}_h = \eta \Delta r_a \quad (26)$$

$$\dot{\varepsilon}_l = \eta \Delta e_a, \dot{\varepsilon}_h = \eta \Delta e_a \quad (27)$$

$$\Delta r_a = r_i - r_j, \Delta e_a = \Delta e \quad (28)$$

这样在每一步的计算过程中，窗口大小依据 $\Delta r, \Delta e, \Delta \theta$ 的大小进行调整。调整的超参数依据文献中，为 $\delta_l = -8, \delta_h = 8, \varepsilon_h = 7.5, \varepsilon = 30, \alpha = 1, \beta = 2, \gamma = 0.1, \Omega = 200(\alpha + \beta + \gamma), \eta = 0.5$ 。

6.2 结果对比分析

汇总上文检索并匹配指纹图像用到的算法模型，将计算指纹“同一”穿透率结果绘制如下表 4 及下图 23 所示。

表 4 三种模型的穿透率

穿透率	BP 神经网络	自适应误差窗口	分割图像 K-均值聚类
筛除 80%	88%	92.9%	93.7%
筛除 90%	81.1%	87.2%	89.3%
筛除 95%	75.5%	81.1%	84%
筛除 97%	70.6%	77.7%	80.3%




图 23: 指纹“同一”穿透率结果

从上图 23 中可看出，分割图像 K-均值聚类法穿透率最好，在极坐标下自适应误差窗口穿透率次之，BP 神经网络算法效果最差。并且从局部放大图中可清晰地看出，在过滤掉 90%，95%，97% 的指纹图像情况下，基于分割图像改进的 K-均值聚类法计算出的穿透率均高于其它两种算法。

6.3 模型改进策略

对于 97% 以上的筛选量，单一的筛选方式都有缺陷和不足，必须使用多种筛选方法。在对于大筛选量上，我们的分步筛选方法为：先进行粗略的大范围删除数据，此时筛选出较多的数据，之后使用精确度高的方法进一步处理，筛选出少量的数据。同时，可以使用集成学习的思想，综合多种简单、可靠的筛选方式进行投票筛选，多个筛选方式避免单一因素的影响，大多数的筛选方式共同选择的数据作为筛选出的数据。

在检索时间方面的改进方法是采用梁雪峰[7]提出的使用细节邻域结构和低阶德劳内三角形的稳健指纹索引方案，该算法能有效地从庞大的数据库中检索出最可能的匹配结果。设计了一种更稳定的三角计算算法（低阶德劳内三角形，由 0 阶和 1 阶德劳内三角形组成），实验表明所提出的算法大大地缩小了指纹数据库的搜索空间，并且对各种指纹都很稳定。





图 24 k 阶德劳内三角形示意图

在检索精度和内存占用方面，改进策略尝试袁东锋[8]提出的一种基于局部特征点的三角形模型匹配算法，根据指纹中图像中的细节点，与其相邻的局部细节点构成一个三角形，并引入了它与邻近细节点间的距离、脊线数目作为判断因素，从而有效解决指纹图像匹配过程中遇到的因平移、旋转与挤压引起形变导致的识别率较低的问题，提高了指纹识别的精确度和可靠性。具有拒识率低、正确识别率高（正确率达到 98.92%）的特点，即基于三角形局部特征点模型的指纹匹配算法有较好的性能。

三角形模型的局部特征向量细节点匹配如图 25 所示。三角模型匹配过程中

不仅对细节点自身的特点进行匹配，包括判断细节点的类型（末梢点与分叉点），而且加入了它与邻近特征点之间的距离因素、脊线数目因素的判断。图 4 中，O 点代表待匹配的细节点，A、B 分别是其邻近的特征点，边 OA 上的参数 d 与 r 分别代表 O 点与 A 点之间的距离与脊线数目，可表示为 d_{OA} 和 r_{OA} ，同理，可以用 d_{OB} 和 r_{OB} 表示 O 点与 B 点之间的距离和脊线数目。



(a) 指纹库原始指纹图像 (b) 待匹配指纹图像

图 25 指纹细节点三角模型匹配

总结为检索模型应该兼顾时间和检索效率，首先快速筛选掉大量不相关的样本，之后通过逐一匹配得到高质量的筛选数据。对于 97% 即以上的筛选量，单一的筛选方式几乎无法满足要求，因此需要不同的检索方式进行组合：先进行大量样本的筛除，之后利用精确度较高的算法进行继续筛选，直至达到要求。对于每一个步骤中的筛选，可以结合多个筛选方式，以集成学习投票的方式筛选目标样本，避免单一因素的影响。

第 7 章 模型的评价与推广

7.1 模型评价

本题目用图像分割法、K-均值聚类分析、BP 神经网络算法、极坐标转换下设置自适应误差窗口法、文本数据可视化等模型或方法对指纹细节点的快速检索、筛选及匹配做了全面的分析与求解。

7.1.1 模型的优点

1、本文通过分割指纹图像，建立局部特征向量。问题二模型中的基于分割图像改进的 K-均值聚类算法，在保证较高的穿透率的前提下能够快速筛选出相似度接近的指纹，大幅降低指纹检索时间，优化内存占用空间。

2、通过对指纹细节点平移、旋转及设置置信度区间等方式，数据预处理有着明显效果，提高了指纹检索与匹配的准确率。

3、本文建立的指纹细节点检索与匹配模型，考虑了多种约束和模式，程序编程较简单。

7.1.2 模型的不足之处

1、本文建立的指纹细节点检索与匹配模型，受于数据限制考虑的特征点坐标仅为 (x, y, θ) ，增加特征点的维度和细节能显著提高穿透率。

2、本文建立了三种指纹细节点检索与匹配数学模型，但是有两种算法（BP 神经网络算法、极坐标转换下设置自适应误差窗口法）效果并不理想。

7.2 模型推广





本文基于分割图像改进的 K-均值聚类算法，指纹筛选速度快，可快速缩减指纹样本集，同时模型原理易懂，适用场合较广。1）文档分类器，根据标签、主题和文档内容将文档分为多个不同的类别。2）物品传输优化，使用 K-means 算法的组合找到无人机最佳发射位置和遗传算法来解决旅行商的行车路线问题，优化无人机物品传输过程。3）识别犯罪地点，使用城市中特定地区的相关犯罪数据，分析犯罪类别、犯罪地点以及两者之间的关联，可以对城市或区域中容易犯罪的地区做高质量的勘察。4）客户分类，聚类能过帮助营销人员改善他们的客户群并根据客户的购买历史、兴趣或活动监控来对客户类别做进一步细分。

5) 球队状态分析, 分析球员的状态一直都是体育界的一个关键要素。6) 保险欺诈检测, 机器学习在欺诈检测中也扮演着一个至关重要的角色, 在汽车、医疗保险和保险欺诈检测领域中广泛应用。7) 乘车数据分析, 面向大众公开的乘车信息的数据集, 提供了大量关于交通、运输时间、高峰乘车地点等有价值的数据集。8) 网络分析犯罪分子, 网络分析是从个人和团体中收集数据来识别二者之间的重要关系的过程。9) 呼叫记录详细分析, 通话详细记录是电信公司在对用户的通话、短信和网络活动信息的收集。10) IT 警报的自动化聚类, 大型企业 IT 基础架构技术组件会生成大量的警报消息。由于警报消息可以指向具体的操作, 因此必须对警报信息进行手动筛选, 确保后续过程的优先级。对数据进行聚类可以对警报类别和平均修复时间做深入了解, 有助于对未来故障进行预测。

第 8 章 参考文献

- [1] 王超岚. 指纹识别算法的研究 [D]. 北京林业大学, 2019. DOI: 10.26949/d.cnki.gblyu.2019.000615.
- [2] ASUNCION A, NEWMAN DJ. UCI machine learning repository [EB/OL]. <http://www.ics.uci.edu/mleam/MLRepository.html>
- [3] 孙林, 刘梦含, 徐久成. 基于优化初始聚类中心和轮廓系数的 K-means 聚类算法 [J]. 模糊系统与数学, 2022, 36(01): 47-65.
- [4] 毛克明, 王国仁, 于长永. 利用去除形变的方法进行指纹匹配 [J]. 计算机科学与探索, 2009, 3(03): 247-256.
- [5] Jain A, Hong L. On-line fingerprint verification [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1996.
- [6] Liang X, Bishnu A, Asano T. A Robust Fingerprint Indexing Scheme Using Minutia Neighborhood Structure and Low-Order Delaunay Triangles [J]. IEEE Transactions on Information Forensics and Security, 2007.
- [7] 罗希平, 田捷. 自动指纹识别中的图像增强和细节匹配算法 [J]. 软件学报, 2002(05): 946-956.
- [8] 袁东锋, 杜恒, 秦小铁. 基于三角形局部特征点模型指纹匹配算法 [J]. 重庆师范大学学报(自然科学版), 2013, 30(02): 69-73.

2.1 第二问，数据可视化分析并验证，10050_0--10249_1 相似度匹配热力图



2.2 第三问，数据可视化分析，A100--A200 相似度匹配热力图

A125	A100_0	8098_0	2060_0	7273_0			A150	A251	5229_0	4111_0	4114_0					A175	A316	1020_0	4793_0	1022_0				A200	A651_0	9307_0	6168_0	3871_0			
A124	A225	9542_0	8916_0	2349_0		0.08	A149	A326_0	7653_0	9046_0	6334_0					0.08	A174	A13	A46	6185_0	A303			A199	A32	8796_0	2799_0	3665_0			
A123	A206	5758_0	7651_0	3403_0			A148	A221	2747_0	A269	2456_0						A173	0305_0	3076_0	0303_0	9973_0			A198	A214	3080_0	8864_0	7892_0			
A122	A64	8599_0	9967_0	7232_0		0.075	A147	A184	5754_0	A245	2475_0						A172	7356_0	4122_0	5384_0	A70			A197	6208_0	7824_0	1298_0	A75			
A121	A117	5404_0	1054_0	7405_0			A146	8745_0	7624_0	3815_0	4483_0						A171	7812_0	7823_0	A344	7883_0			A196	9545_0	5756_0	A208	A374			
A120	A5	A66	7873_0	A288			A145	A75	9659_0	A46	4399_0						A170	A374	2263_0	2267_0	5332_0			A195	A387	3181_0	1086_0	3192_0			
A119	A235_0	5363_0	1453_0	A11		0.07	A144	7133_0	7345_0	7131_0	1478_0						A169	A307	1944_0	5152_0	3381_0			A194	A259	7294_0	A87	2146_0			
A118	8896_0	8431_0	3967_0	A380			A143	A323	5295_0	9659_0	4599_0						A168	2076_0	2784_0	8889_0	6204_0			A193	A131	A216	9952_0	A363			
A117	A121	7405_0	4206_0	3849_0		0.065	A142	2745_0	A291	A30	2076_0						A167	2832_0	2489_0	8133_0	8131_0			A192	A360	4434_0	6881_0	A239			
A116	5878_0	2537_0	8329_0	8653_0			A141	3274_0	2927_0	1967_0	7231_0						A166	A181	8570_0	6391_0	4440_0			A191	A16	A187	A22	10279_0			
A115	A414_0	4126_0	8286_0	2544_0		0.06	A140	A395	4114_0	8564_0	2331_0						A165	7715_0	8456_0	7655_0	1090_0			A190	5438_0	1924_0	8883_0	7896_0			
A114	A161	6988_0	3423_0	8303_0			A139	A27	2242_0	4590_0	2243_0						A164	A286	8138_0	7155_0	6186_0			A189	9864_0	3047_0	A214	A198			
A113	6656_0	A59	2711_0	4092_0		0.055	A138	A75	6570_0	4076_0	8869_0						A163	0468_0	5777_0	7719_0	8513_0			A188	2326_0	5567_0	0711_0	2325_0			
A112	6962_0	8388_0	5288_0	0507_0			A137	A329	7631_0	0201_0	5340_0						A162	5487_0	6452_0	1019_0	A224			A187	A22	0279_0	A191	7926_0			
A111	1460_0	1250_0	0640_0	6652_0		0.05	A136	8886_0	A243	8034_0	4186_0						A161	A114	6987_0	8213_0	8986_0			A186	8756_0	6451_0	9816_0	8796_0			
A110	A45	7496_0	7496_0	A72			A135	A242	5915_0	5916_0	9897_0						A160	5278_0	3442_0	1470_0	4303_0			A185	A357	A2	A377	A365			
A109	A218	4521_0	A259	3317_0			A134	A206	9307_0	5653_0	A258						A159	A213	3100_0	3686_0	2276_0			A184	A257	7702_0	7701_0	5884_0			
A108	A353	4278_0	5808_0	4185_0		0.045	A133	A32	2467_0	3609_0	5819_0						A158	A153	9511_0	3637_0	4812_0			A183	5219_0	A350	7133_0	1484_0			
A107	9606_0	2483_0	9113_0	9885_0			A132	3797_0	A258	A316	8869_0						A157	3191_0	7078_0	8452_0	2747_0			A182	7863_0	A288	8236_0	2856_0			
A106	8816_0	8815_0	6283_0	0488_0			A131	A183	6972_0	A295	4793_0						A156	4068_0	8545_0	4090_0	8356_0			A181	A31	7181_0	4823_0	6117_0			
A105	6678_0	7289_0	1734_0	3649_0		0.04	A130	A342	A273	A174	2387_0						A155	A179	2932_0	1303_0	1305_0			A180	A268	8216_0	3618_0	4166_0			
A104	A68	8001_0	3011_0	5075_0			A129	8288_0	8287_0	4141_0	6938_0						A154	A295	2243_0	4307_0	2627_0			A179	2832_0	2830_0	3476_0	9419_0			
A103	8621_0	6250_0	0485_0	A381		0.035	A128	A60	0186_0	4521_0	4591_0						A153	A158	A50	5564_0	A109			A178	9675_0	7860_0	8031_0	7037_0			
A102	5363_0	6989_0	A11	3638_0			A46	A127	5034_0	5766_0	3150_0						A152	A230	8952_0	8546_0	1876_0			A177	4600_0	7325_0	9350_0	A383			
A101	A85	7891_0	9044_0	A26		0.03	A126	8072_0	9090_0	8855_0	5797_0						A151	A166	2234_0	8790_0	7990_0			A176	A297	3787_0	A121	A117			