

队伍编号	MC25005313
题号	(A)

基于几何信息与自适应傅里叶神经算子汽车风阻预测模型

摘要

空气阻力对汽车及航空航天工业中载具的性能和效率至关重要，传统的空气阻力预测方法复杂、依赖工程经验和高性能计算集群且耗时。因此，通过纯数据驱动的方法实现对任意三维形状汽车阻力实现快速预测至关重要。在此背景下，本文提出了一种基于几何信息与自适应傅里叶神经算子（Geometry-informed Adaptive Fourier Neural Operator, G-AFNO）的汽车风阻预测模型。

针对问题一，为实现对目标损失函数 $G(\theta) = e^\theta - \ln \theta$ ，从自适应动量估计的优化算法（Adam Optimizer, Adam）与梯度下降法两方面对进行目标函数的优化。为避免目标损失函数一阶导数在某些区域出现剧烈波动甚至数值爆炸的问题，在梯度下降法中对目标损失函数取对数的策略。Adam 与梯度下降法在参数值初始值为 100，初始学习率为 0.0001，收敛容差 $1e-6$ 时，通过迭代使得目标函数最小的参数值分别为 **0.567345** 和 **0.834436**，函数值分别为 **2.330366**、**2.484514**，从而可以得出 Adam 结果优于梯度下降法，且收敛更快。

针对问题二，为实现给定的高雷诺数湍流下汽车风阻压力数据和简化汽车模型的几何表面进行数据读取和处理，首先在飞桨深度学习框架下通过 Meshio 获取汽车表面几何与物理信息；其次将顶点坐标和单元数据作为输入特征 x ，压力数据作为标签 y ，并转换为飞桨框架支持的张量格式；最后构造数据加载器并实现 **24 个 worker 进程** 实现数据的并行加载。

针对问题三，通过搭建几何信息与自适应傅里叶神经算子融合框架（G-AFNO），该框架包括两个图神经算子（GNO）与一个自适应傅里叶神经算子（AFNO），实现将点云数据映射与反映射、动态调整频域基函数权重、几何特征与频域信息的协同建模。模型通过 100 轮的迭代，在验证集上的评价指标 Score、Mean relative l2 p error 和 Mean relative Cd error 分别为 **0.90233**、**0.075281** 和 **0.14121**，在报名团队数 700 的榜单中**排名第五**。

针对问题四，为进一步提升汽车风阻预测模型的性能，在保证全量非稀疏测试数据集上的精度要求下，本文在模型结构上引进 GeoCA3D 与自适应半径近邻图，并从稀疏采样率、训练集数量、不同模型架构下开展消融实验得出：稀疏采样是有效避免信息的冗余同时保存关键信息策略；少样本学习（Few-shot learning）是模型性能改进的一个有效途径；模型架构为 4 x transformer Block、激活函数为 Gelu 时模型性能最佳，显存需求 0.6484GB，权重大小 2MB，L2 相对平均误差 **0.06**，Cd（阻力系数）误差 **42 个 counts**。

针对问题五，为探讨注意力机制与神经算子之间的内在联系，本文通过构建神经算子定义下的变换关系，重写 Transformer 中的注意力机制的核函数加权积分的形式，引入积分逼近、嵌入映射与特征权重映射，推导出注意力机制在满足嵌入维度及权重核函数可学习的条件下，可视为一种神经算子的特例，具备对输入函数分布建模的能力。

关键词：G-AFNO；汽车风阻预测模型；GeoCA3D；基于半径的近邻图；少样本学习

目录

一、问题重述	1
1.1 问题背景	1
1.2 问题提出	1
二、问题分析	2
2.1 问题 1 的分析	2
2.2 问题 2 的分析	2
2.3 问题 3 的分析	3
2.4 问题 4 的分析	4
2.5 问题 5 的分析	5
三、模型假设	6
四、符号说明	7
五、问题一的建立与求解	8
5.1 自适应动量估计的优化算法	8
5.2 目标函数取对数策略的梯度下降法	9
5.3 目标函数最小的参数值的求解	10
六、问题二的建立与求解	11
6.1 汽车表面几何与物理信息处理与加载	11
6.2 文献调研	12
七、问题三的建立与求解	14
7.1 几何映射	14
7.2 频域自适应学习	15
7.3 逆映射	17
7.4 数据增强	17
7.5 损失函数设计	17
7.6 优化器选择	17
7.7 监督约束	18
7.8 模型的训练	18
7.9 实验结果	18
八、问题四的建立与求解	21
8.1 基于半径的近邻图	21
8.2 结合几何感知与计算流体力学 (CFD) 的 GeoCA3D	22
8.3 消融实验	22
九、问题五的建立与求解	24
9.1 神经算子形式化定义	24
9.2 注意力机制的结构	24
9.3 注意力机制为神经算子的推理与证明	24
十、模型的评价与推广	26
10.1 模型的优缺点	26
10.2 模型的评价	26
10.3 模型推广	27

一、问题重述

1.1 问题背景

空气阻力是影响汽车及航空航天等交通工具性能与能源效率的关键因素之一。在复杂的空气动力学条件下，传统的风阻预测方法依赖高精度的流体力学仿真计算，虽然能获得较准确结果，但也存在计算复杂、成本高、耗时长等显著缺点，难以满足快速迭代设计与实时性能优化的需求。近年来，深度学习技术，尤其是科学机器学习（SciML）领域的发展，为复杂流体问题的高效求解提供了全新路径。

与传统方法相比，深度学习不仅具备快速预测能力，还展现出跨学科广泛应用的潜力，尤其在汽车、无人机、建筑、风能等领域具有重要意义。然而，当前模型在面对未见几何形状时的泛化能力仍较弱，难以适应多样化的实际设计场景，限制了其在工业场景中的广泛部署。因此，研究具有良好泛化能力和高预测精度的空气动力学深度学习模型，具有重要的现实意义与工程价值。

1.2 问题提出

结合问题背景与实际问题分析，需解决以下问题：

问题 1: 假设神经网络用于预测汽车风阻的算子学习任务，其本质是优化一个目标损失函数。在给定初始参数的前提下，目标是通过梯度优化方法求解使目标函数 $g(\theta) = e^\theta - \log \theta$ 取得最小值的最优参数，从而实现模型性能最优化，要求给出求解过程或代码。

问题 2: 假设汽车几何结构在高雷诺数湍流环境下进行空气动力学仿真，目标是从仿真文件中提取关键几何特征和物理信息，通过数据清洗与结构化处理，构建符合飞桨深度学习框架的数据加载流程，实现多进程异步加载以支撑高效训练，并且阅读文献完成文献调研。

问题 3: 假设具备多种神经网络结构可选，包括 KAN、Diffusion、Transformer、Fourier-Neural-Network 和 PINN 等，目标是构建基于深度学习的偏微分方程求解器，实现从几何输入到物理预测的算子映射，并借助飞桨平台完成代码实现与实验验证。

问题 4: 假设模型需在非稀疏测试数据集上达到较高预测精度，目标是通过调节输入采样率、训练集数量以及网络结构等关键参数，系统评估模型在计算复杂度、参数量、显存占用和精度表现之间的平衡，从而优化其整体性能。

问题 5: 探讨 Transformer 模型中注意力机制与神经算子结构之间的关系，通过理论分析证明其可视为神经算子的一种特例。

二、问题分析

2.1 问题 1 的分析

针对问题 1，经过查阅相关优化算法与算子学习相关文献，神经网络模型性能的提升依赖于对目标损失函数的有效最小化。具体而言，通过构建一个合理的损失函数，并使用梯度下降等优化算法对参数进行更新，可以使模型逐步逼近最优解，从而提升预测精度。本问题所提出的目标函数 $g(\theta) = e^\theta - \log \theta$ 在定义域 $\theta > 0$ 上具备唯一的极小值点，表示在此点处模型的损失最小，性能最优。因此，本文通过对该函数求导并结合数值方法，找到使得目标函数最小的参数值 θ ，作为模型最优状态的理论依据。问题分析思路如图 2-1 所示：




图 2-1 ： 问题 1 分析思路

2.2 问题 2 的分析

针对问题 2，核心任务是对高雷诺数湍流条件下的汽车表面风阻压力数据进行处理与建模，旨在实现几何特征到压力分布的有效映射。首先，通过对赛题提供的仿真数据进行结构化处理，提取汽车表面的几何拓扑与物理压力信息，为后续建模提供高质量数据基础。考虑到汽车表面数据具有大规模和复杂结构的特点，直接加载将严重影响训练效率，因此采用飞桨框架构建多进程异步数据加载器，结合共享内存与预取机制，能够显著提升数据处理性能与模型训练效率。此外，为适配图结构特征与不规则几何分布，构建了张量格式的数据结构输入深度模型。




图 2-2: 问题 2 分析思路

2.3 问题 3 的分析

针对问题三，要求构建一类能够对不规则点云几何与风阻物理场进行端到端映射的神经算子网络，既要突破 CNN/FNO 对规则网格输入的依赖，又要动态捕捉非均匀压力分布特征。因此本文提出基于几何信息与自适应傅里叶神经算子融合的 G-AFNO 框架：首先用图神经算子（GNO）将点云映射到规则网格，再由 AFNO 在频域内自适应调整基函数权重，最后逆向 GNO 恢复物理场预测。整个模型在飞桨平台上完成从 baseline 复现、改造到训练推理的闭环验证，G-AFNO 在复杂几何场景下的预测精度和效率显著优于传统方法。




图 2-3: 问题 3 分析思路

2.4 问题 4 的分析

针对问题四，需系统评估模型在计算资源(复杂度、显存、参数量)与预测精度之间的权衡，并验证其在多种数据稀疏度和训练集规模下的稳定性。为此，本文分别在非稀疏与稀疏(10%、50%、100%)输入采样率，以及 100、200、全量三种训练集规模下，调整网络层数、参数量和激活函数等超参数，考察压力场 L_2 相对平均误差低于 0.4 及阻力系数误差小于 80counts 的达成情况。通过横向对比实验，量化了不同配置对模型收敛速度和资源占用的影响，为实际部署提供了最优方案。




图 2-4: 问题 4 分析思路

2.5 问题 5 的分析

针对问题 5，结合当前神经算子理论与 Transformer 结构相关文献可知，神经算子旨在学习从函数到函数的映射关系，而 Transformer 中的注意力机制本质上也是一种输入到输出的映射操作，能够捕捉全局依赖特征。具体而言，注意力机制通过查询（Query）、键（Key）和值（Value）的加权组合实现特征重构，这种机制与算子中对函数空间上全局信息的整合过程具有高度一致性。因此，Transformer 中的注意力机制可被看作是一类具有特殊核函数形式的神经算子层，其在特定结构和条件下满足神经算子映射的数学定义。本文尝试从理论推导角度论证该观点，为 Transformer 模型的结构设计提供新的神经算子视角。




图 2-5：问题 5 分析思路

三、模型假设

- 1.假设汽车外表面点云数据能够完整、准确表达其几何形状特征，点的分布密度和质量足以支撑 GNO 对局部几何特征(如曲率、法线)的提取与编码。
- 2.假设 GNO 所构建的图结构可以高效、无损地将不规则点云数据映射至规则网格空间，同时保留关键几何和空间分布信息，不影响后续 AFNO 频域建模的准确性。
- 3.假设 AFNO 在频域中能够通过自适应傅里叶基函数捕捉风阻压力分布的非均匀性特征（如车头、车尾扰流板等区域），并有效还原物理场特征。
- 4.假设 G-AFNO 中的逆向图神经算子(GNO-2)能够将频域学习结果准确映射回原始几何空间，实现三维空间任意点上的风阻压力估计。

样本分布与泛化假设

- 5.假设训练集中的样本具有代表性，覆盖足够多样的汽车几何和风阻特性，使模型在测试集上的泛化性能可靠，且误差控制在可接受范围。
- 6.假设风阻压力场在汽车表面连续分布，局部变化可由网络平滑逼近，不存在剧烈不连续或不可导区域，符合偏微分方程求解的前提。
- 7.假设所设计的绝对误差与相对误差评价指标能够稳定、准确反映模型预测性能，并对模型优化具有有效指导意义。
- 8.假设在 AI Studio 和星河社区平台上完成的模型训练和部署流程，与本地实验环境（PaddlePaddle GPU + ShapeNet 数据）具有一致性，不会因平台差异影响模型性能评估。

四、符号说明

符号	符号含义	符号说明
θ	神经网络中所有可学习参数	训练过程中通过优化器不断更新的权重与偏置
gt	参数梯度	损失函数关于参数 θ 的梯度
α	学习率	控制每次参数更新的步长
β_1, β_2	Adam 优化器中的动量参数	控制梯度一阶和二阶动量估计的指数衰减率
ϵ	数值稳定项	Adam 优化器中使用，防止数值不稳定
mt	一阶动量估计值	当前时刻的一阶动量 (即梯度的指数加权平均)
vt	二阶动量估计值	当前时刻的梯度平方的 指数加权平均
T	最大迭代次数	模型训练中设置的最大步数
abs	绝对误差	衡量预测值与真实值的 L2 距离
rel	相对误差	衡量预测误差相对于真实值大小的比例
n_hidden	隐藏层维度	表示特征向量的维度
n_layers	网络层数	表示堆叠的 AFNO 层数
$space_dim$	空间维度	输入数据的空间维度
fun_dim	功能维度	表示输入数据是否携带额外功能维度，如速度、温度等
n_head	注意力头数	多头注意力机制中的头数

五、问题一的建立与求解

神经网络中的参数优化是算子学习模型性能提升的核心步骤，其准确性直接影响模型的拟合能力与泛化表现。然而，在面对复杂非线性目标函数时，传统解析求导方法或数值近似手段往往难以有效求得全局最优解。一方面，非凸函数结构导致解析法难以处理全局极小值的识别问题，优化路径容易陷入局部极小；另一方面，穷举或离散搜索在连续参数空间中效率低下，无法满足高维参数优化场景对计算效率的要求。

解决汽车风阻预测中神经网络中目标损失函数的优化，就是找到一个参数 θ ，使得目标函数 $G(\theta) = e^\theta - \ln \theta$ 最小化。为解决这一问题，本文采用自适应动量估计的优化算法（Adam Optimizer, Adam）与梯度下降法（目标函数取对数）进行目标函数的优化。

自适应动量估计的优化算法通过对梯度一阶与二阶矩的估计，实现每一参数维度的自适应学习率更新机制，从而提升参数在高维非凸空间中的优化效率与稳定性。Adam 优化器每轮迭代同时维护梯度的一阶动量（均值）与二阶动量（未中心化的方差），并进行偏差校正，最终以动态步长对参数进行更新，避免了传统梯度下降在训练初期震荡较大或收敛速度缓慢的问题。

梯度下降法的核心思想就是不断沿着梯度的反方向调整参数，从而逐步逼近最小值点，为保证数值稳定性的角度出发，采取对目标函数取对数的策略。针对目标函数一阶导数在某些区域可能出现剧烈波动甚至数值爆炸的问题，本文对梯度值取对数后再进行参数更新，从而压缩梯度的变化范围。该方法在梯度较大或变化剧烈的区域内显著提高了数值稳定性，有助于参数在优化过程中维持合理的更新步幅，避免步长过大导致的发散问题或步长过小造成的收敛缓慢问题，方法 1 与方法 2 具体建模过程如下：

5.1 自适应动量估计的优化算法

对目标函数 $g(\theta) = e^\theta - \log \theta$ 求一阶导数为：

$$g'(\theta) = \frac{d}{d\theta}(e^\theta - \log \theta) = e^\theta - \frac{1}{\theta} \quad \text{式 5-1}$$

基于上述梯度信息，Adam 优化器的更新策略如下：

1) 初始化参数：设定初始值 θ_0 ，动量估计 $m_0 = 0$ ，二阶动量 $v_0 = 0$ ，学习率 α ，动量因子 β_1 ，二阶动量因子 β_2 ，以及稳定项 ε ；

2) 每一轮迭代 $t = 1, 2, \dots$ 执行如下操作：

①计算当前梯度：

$$g_t = e^{\theta_t} - \frac{1}{\theta_t} \quad \text{式 5-2}$$

②更新一阶动量和二阶动量：

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad \text{式 5-3}$$

③偏差修正：

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad \text{式 5-4}$$

④更新参数：

$$\theta_{t+1} = \theta_t - \alpha \cdot \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon} \quad \text{式 5-5}$$

该更新过程持续进行，直至满足以下任意收敛条件之一：

1. 梯度模长足够小： $|g'(\theta_k)| < \varepsilon$
2. 参数变化趋于稳定： $|\theta_{k+1} - \theta_k| < \varepsilon$
3. 达到最大迭代次数 T

Adam 优化器在面对 $g(\theta) = e^\theta - \log \theta$ 这样梯度剧烈变化的目标函数时，展现出更好的收敛性与数值稳定性，能够有效避免陷入局部震荡或梯度爆炸的困境，为神经网络模型提供更加稳健的参数优化路径。Adam 优化器实现梯度优化伪代码见下图：

Algorithm 1 $\arg \min_{\theta} (e^\theta - \log \theta)$

```

1: :
    $\theta_0 \leftarrow 100.0$  ()
    $\alpha \leftarrow 0.0001$  ()
    $T \leftarrow 1000$ 
    $\epsilon \leftarrow 10^{-8}$ 
2: :  $\theta^*$ 
3: function GRADIENTDESCENT( $\theta_0, \alpha, T, \epsilon$ )
4:    $\theta \leftarrow \theta_0$ 
5:   for  $t = 1$  to  $T$  do
6:     :  $g \leftarrow e^\theta - \frac{1}{\theta}$  ▷  $\nabla_{\theta} f(\theta)$ 
7:     :  $\theta \leftarrow \theta - \alpha \cdot g$ 
8:     if  $|\alpha \cdot g| < \epsilon$  then ▷
9:       break
10:    end if
11:    if  $\theta \leq 0$  then ▷  $\theta > 0$ 
12:       $\theta \leftarrow 10^{-6}$  ▷
13:    end if
14:  end for
15:  return  $\theta$ 
16: end function
17: :
18:  $\theta^* \leftarrow \text{GRADIENTDESCENT}(\theta_0, \alpha, T, \epsilon)$ 
19:  $\theta^*$  ▷ 0.567

```

$e^\theta = \frac{1}{\theta}$

图 5-1：Adam 优化器实现梯度优化伪代码

5.2 目标函数取对数策略的梯度下降法

在常规的梯度下降法中，使用该导数直接更新参数可能会由于 e^θ 在 θ 较大时迅速增大，导致数值发散。因此我们引入对数变换后的梯度为：

$$g'_i = \log(|g'(\theta)| + \sigma) \quad \text{式 5-6}$$

其中 σ 为防止 $\log(\theta)$ 的极小常数，该变换通过压缩梯度幅度，使得更新过程更具稳定性，同时保留下降方向。

在完成梯度对数变换后，优化过程使用以下迭代公式对参数进行更新：

$$\theta_{t+1} = \theta_t - \alpha \cdot \text{sign}(g'(\theta_t)) \cdot \log(|g'(\theta_t)| + \sigma) \quad \text{式 5-7}$$

其中 α 为学习率， $\text{sign}(g'(\theta_t))$ 用于保持原梯度方向不变，避免对数运算改变更新方向。

该方法的迭代过程在满足以下任一条件时终止：

- 1) 梯度模长足够小： $|g'_i(\theta_k)| < \varepsilon$
- 2) 参数变化趋于稳定： $|\theta_{k+1} - \theta_k| < \varepsilon$

3) 达到最大迭代次数 T

5.3 目标函数最小的参数值的求解

Adam 与梯度下降法（取对数的策略）在参数值初始值为 100，初始学习率为 0.0001，收敛容差 $1e-6$ 时，通过迭代使得目标函数最小的参数值分别为 0.567345 和 0.834436，函数值分别为 2.330366、2.484514。Adam 结果优于梯度下降法（目标函数取对数），且收敛更快。

表 5-1：梯度优化方法优化目标损失

方法	θ	$g(\theta)$
Adam	0.567345	2.330366
梯度下降法	0.834436	2.484514




图 5-2：梯度下降法求解目标函数最小参数值




图 5-3：Adam 求解目标函数最小参数值

六、问题二的建立与求解

6.1 汽车表面几何与物理信息处理与加载

为从给定的高雷诺数湍流下汽车风阻压力数据和简化汽车模型的几何表面进行数据读取和处理，使用飞桨深度学习框架对数据进行处理与加载，首先通过 Meshio 获取汽车表面几何与物理信息，其次将顶点坐标和单元数据作为输入特征 x ，压力数据作为标签 y ，并转换为飞桨框架支持的张量格式，最后构造数据加载器与多进程异步加载，具体建模过程如下：




图 6-1：汽车表面几何与物理信息处理与加载示意图

6.1.1 数据提取

在汽车表面几何与物理信息的处理过程中，我们采用网格数据表示汽车表面的几何特征，并通过专业化的数据结构进行存储与分析。利用 Meshio 库读取汽车表面的几何信息后，得到一个包含顶点坐标与单元信息的网格对象。其中，`Mesh.points` 为一个形状为 $(3568, 3)$ 的 NumPy 数组，用于存储所有顶点的空间坐标信息；`Mesh.cells` 则为一个形状为 $(7168, 3)$ 的三角形单元数据数组，用于描述汽车表面的拓扑连接关系。

对于汽车表面的物理信息，我们通过 NumPy 加载得到一个形状为 $(3568, 3)$ 的数组，该数组的每一行对应一个顶点的压力向量，包含了汽车表面在各顶点处的压力分布信息。

6.1.2 数据集构建

在获取汽车表面的何与物理信息后，将顶点坐标和单元数据作为输入特征 x ，压力数据作为标签 y ，将数据读取之后利用 `Paddle.to_tensor` 函数将数据转换为飞桨框架支持的张量格式。

6.1.3 构造数据加载器与多进程异步加载

在处理大规模数据的汽车表面的几何与物理信息时，数据加载的效率直接影响后续计算与仿真的性能。通过构造数据加载器并引入多进程异步加载机制，可以显著提升数

据处理效率。DataLoader 配置中使用 24 个 CPU 核心进行多进程数据加载，关键参数说明如下：

- 1) `batch_size`: 设置为 2，平衡内存使用和训练效率；
- 2) `shuffle`: 启用数据打乱，提高训练效果；
- 3) `num_workers`: 24 个进程并行加载数据；
- 4) `prefetch_factor`: 每个 worker 预取 2 个 batch，减少等待时间；
- 5) `use_shared_memory`: 使用共享内存加速进程间数据传输。

所构造的数据加载器采用了多进程异步加载技术，其核心实现要点包括：多进程加速，通过配置 24 个 worker 进程实现数据的并行加载，有效利用多核 CPU 的计算能力，显著提升数据加载效率；内存优化，引入共享内存机制以减少数据在进程间传递时的拷贝开销，从而降低内存占用；流水线处理，结合预取机制，使数据加载过程与后续计算任务重叠执行，进一步优化整体处理流程；稳定性保障，通过设置 `timeout=0` 避免因超时导致的意外中断，确保数据加载过程的可靠性。

综上，完成通过数据加载与预处理、创建 Paddle 数据集、配置 DataLoaderMesh 三个这步骤数据的处理流程，伪代码实现如图 6-2 所示：

Algorithm 1 Mesh 数据处理流程

输入: 网格文件 `mesh_file`, 压力数据 `press_file`, 数据迭代器配置文件 `config`

输出: Paddle.Io.DataLoader

步骤 1: 数据加载与预处理

加载网格数据: `mesh ← meshio.read(mesh_file)`

加载压力数据: `press ← np.load(press_file)`

提取顶点坐标: `points ← mesh.points.astype(float32)`

验证数据: `assert points.shape[0] == press.shape[0]`

步骤 2: 创建 Paddle 数据集

定义数据集类:

`points_tensor ← paddle.to_tensor(points)`

`press_tensor ← paddle.to_tensor(press)`

实现 `__getitem__` 方法: 返回 `(points[i], press[i])`

实现 `__len__` 方法: 返回 `len(points)`

实例化: `dataset ← MeshDataset(points, press)`

步骤 3: 配置 DataLoader

设置参数:

`batch_size ← config.batch_size`

`shuffle ← config.shuffle`

`num_workers ← config.num_workers`

`use_shared_memory ← config.share_memory`

实例化: `dataloader ← DataLoader(dataset, ...)`

返回: Paddle.Io.DataLoader

图 6-2: Mesh 数据处理流程伪代码

6.2 文献调研

风洞试验和计算流体力学(CFD)仿真是研究汽车风阻系数两种常见方法，然而风洞试验准备周期长，试验成本高，且高度依赖设计人员经验，CFD 仿真不需要大规模的试验设施，但在汽车造型设计初始阶段，外造型方案的快速迭代仍需花费大量时间进行验证。

解决上述问题,风阻系数快速预测研究开始引起部分学者关注,相比于 CFD 仿真风洞试验基于数据驱动的深度学习方法可以精确捕捉复杂的几何特征,学习数据中的潜在规律。在深度模型流体动力学中,目前的研究主要分为两类,一类是融入物理知识的神经网络,一类是融入物理知识的神经网络,如物理信息神经网络^[1](PhysicsInformed Neural Networks,PINNs),然而 PINNs 受限于微分方程的形式,且存在梯度病态问题,可能导致训练不稳定,无法找到最优解。另一类是基于算子学习的方法,如 Deep ONet 和傅立叶神经算子(Fourier Neural Operators,FNO)。Deep ONet^[2]依据扩展的通用近似定理理念,即单隐含层神经网络可有效逼近非线性连续泛函及算子,运用深度网络捕捉函数间的映射关系,进而解决偏微分方程问题。为捕获长距离依赖关系,Li 等人^[3]结合自注意力机制、交叉注意力机制,以及多层感知器,构建了神经算子学习架构 Oformer,实现性能的增强。Li 等人^[4]进一步拓展了傅立叶神经算子,该算子通过傅立叶变换将空间数据转换到频域进行处理,可以实现风阻系数更精确的预测。Guibas 等人^[5]提出自适应傅里叶神经算子(Adaptive Fourier Neural Operators, AFNO),AFNO 是算子学习范式在视觉 Transformer 中的具体实现,它通过改进 FNO 架构,将算子学习的思想应用于 token 混合任务,从而在保持泛化能力的同时提升了计算效率。

另外,图卷积网络^[6](Graph Convolutional Network, GCNs)将卷积神经网络推广至图结构领域,在处理图结构数据的建模与分析中显示出独特优势。图神经算子^[7](Geometry neural operator, GNO)是 GNN 的一种扩展形式,旨在解决传统 GNN 在处理大规模、不规则几何数据时的局限性。GNO 通过引入算子学习的方法,将物理定律与深度学习相结合,能够更好地适应汽车等复杂物体的气动外形。基于几何信息神经算子^[8](Geometry-informed neural operator,GINO)由图神经算子(GNO)和傅立叶神经算子(FNO)组合构成,能够解决以往单纯卷积神经网络(CNN)和傅立叶神经算子(FNO)难以适应大规模汽车不规则几何外形的难题。

目前,工业和学者已将神经算子运用到汽车风阻的预测中。百度飞桨与 NVIDIA 合作开发的 DNNFluid-Car 模型是一个典型的基于 GNO 的汽车风阻预测模型,该模型的计算速度比传统数值计算的速度快至少 2 到 3 个数量级,有效减少了对数以千计的 CPU 计算资源的依赖;王刚等人^[9]提出的基于稀疏八叉树与卷积神经网络的融合模型为一种特殊的 GNO 应用;陈凯等人^[10]实现基于几何信息神经算子的参数化汽车几何风阻预测模型。

七、问题三的建立与求解

汽车风阻预测作为汽车气动结构优化的核心环节，其准确性直接关系到车辆的燃油效率与行驶稳定性。然而，传统方法在处理复杂汽车几何外形时面临显著挑战：一方面，卷积神经网络（Convolutional Neural Network, CNN）和标准傅里叶神经算子（Adaptive Fourier Neural Operator, FNO）依赖规则网格化输入，难以直接适配汽车表面不规则的点云数据，导致几何信息丢失；另一方面，传统 FNO 的固定频域基函数无法动态捕捉汽车压力分布中的非均匀特征（如曲率变化、边缘效应），在复杂几何区域（如车头、扰流板）的预测精度受限。

为解决这一问题，本研究提出几何信息与自适应傅里叶神经算子融合框架（Geometry-informed Adaptive Fourier Neural Operator, G-AFNO），该框架通过图神经算子（GNO）将点云数据映射至规则网格后，利用自适应傅里叶神经算子（AFNO）动态调整频域基函数权重，实现几何特征与频域信息的协同建模。AFNO 不仅突破了传统 FNO 对固定频域的依赖，还能高效学习复杂几何区域的压力分布特征，显著提升预测精度与计算效率，通过纯数据驱动的方法实现对汽车压力分布的预测模型。




图 7-1: 基于几何信息神经算子（G-AFNO）的汽车外流场预测模型

第一个图神经算子层（GNO-1）接收汽车外表面点云坐标数据与风阻压力作为联合输入，通过空间特征融合机制将坐标数据与风阻压力耦合为统一的多模态特征映射到规则网格空间并将映射结果作为 AFNO 层的输入；AFNO 层将输入数据变换到频域，通过自适应傅里叶变换机制（Adaptive Fourier Transform, AFT）在频域对数据进行高效学习，其输出将传递给第二个图神经算子层（GNO-2）；第二个 GNO 层将 AFNO 层的输出映射回实际汽车几何体上，实现汽车几何体物理场任意空间分辨率的推理计算。

G-AFNO 网络算法可以在复杂几何形状下的物理场建模，实现汽车压力分布预测，具体建立步骤如下：

7.1 几何映射

几何数据通常以点云或网格的形式存在，点云由三维空间中的点集合组成，每个点可能包含坐标、法线、颜色等属性，网格由顶点、边和面构成，常用于表示三维物体的表面。在 GNO 中，几何数据首先需要被表示为图结构，其中节点对应几何数据中的点或顶点，边连接相邻的节点，表示点之间的空间关系。

GNO 是一种用于处理图结构数据的神经网络算子，其核心目标是通过学习图上的映射关系，将几何数据从原始空间映射到规则网格空间。具体步骤如下：

(1) 局部特征提取：提取每个节点的局部特征，例如点的坐标、法线、局部曲率等，提取边的特征，例如两点之间的距离、方向等；

(2) 通过图卷积操作，节点之间传递信息，更新节点的特征表示，使用聚合函数将邻居节点的信息聚合到当前节点；

(3) 对聚合后的特征进行非线性变换，增强模型的表达能力，本文使用 ReLU 激活函数进行非线性的变换；

(4) 重复上述步骤多次（即多层图卷积），逐步提取更高层次的特征；

(5) 经过图神经算子的处理后，几何数据被表示为高维特征图，将这些特征图通过投影变换映射到规则网格空间。

7.2 频域自适应学习

傅里叶神经算子（FNO）通过傅里叶变换将偏微分方程（PDE）的解映射到频域，利用分数阶傅里叶变换捕捉全局依赖性，再通过逆变换返回空间域，实现高效求解，其网络结构可以表示为：

$$\mu(x) = F^{-1}(F(f(x)) \cdot W(k)) \quad \text{式 7-1}$$

其中， F 和 F^{-1} 分别是傅里叶变换和逆傅里叶变换， $W(k)$ 是频域中的可学习权重矩阵， $f(x)$ 是输入， $\mu(x)$ 是输出。

自适应傅里叶神经算子（AFNO）在 FNO 基础上引入自适应权重共享和块对角结构，解决 Transformer 在高分辨率输入下的计算瓶颈，同时保持高并行性和线性内存增长。AFNO 核心思想是通过傅里叶变换将令牌混合操作从空间域转移到频域，从而实现高效的自适应全局卷积。AFNO 通过频域变换、通道混合以及空间域还原进而实现频域自适应学习，过程可以表示为：

$$y_{m,n} = IDFT(\text{Softshrink}(W_{m,n} \cdot DFT(X)_{m,n})) \quad \text{式 7-2}$$

其中 X 表示原始输入； (m,n) 是将 X 划分为不重叠的 $m \times n$ 大小的 Patches 的位置；DFT 是离散傅里叶变换，将其从空间域转换到频域；IDFT 是逆离散傅里叶变换将稀疏化后的频域表示转换回空间域；Softshrink 是软阈值化，通过引入非线性 Lasso 正则化，使用 Softshrink 激活函数对频率模式进行稀疏化； $W_{m,n}$ 为权重矩阵。

AFNO 算法流程主要包括数据的输入、多层感知机（MLP）、Transformer 块以及最后输出的压力特征。

（1）数据输入阶段：将汽车的几何信息通过网格化的特征映射转化为高维特征向量，将离散几何数据转化为连续特征表示，作为 AFNO 的初始输入；

（2）多层感知机（MLP）阶段：由多个线性层+激活函数（如 ReLU）组成，用于对输入特征进行非线性变换，通过权重矩阵调整特征维度，学习几何信息中的关键模式；

（3）Transformer 块阶段：通过计算特征间的全局相关性，捕获几何信息中的长程依赖，并对注意力输出进行进一步非线性变换，增强特征表达能力。

（4）输出阶段：最终输出一个低维特征向量，表示汽车在特定工况下的压力分布特性。

AFNO 算法流程见图 7-2，具有以下优势：

（1）全局建模能力：Transformer 块可捕获复杂几何信息中的非局部依赖。

（2）模块化设计：MLP 与 Transformer 结合，兼顾特征提取与全局关系建模。

（3）可扩展性：适用于不同尺度的几何数据




图 7-2: 自适应傅里叶神经算子算法流程图

为适应三维空间数据的特征学习需求，本文设计的 AFNO 模型包含以下关键参数：

表 7-1: AFNO 模型关键参数配置

参数	n_hidden	n_layers	space_dim	fun_dim	n_head
设定	128	4	3	0	8
参数	mlp_ratio	out_dim	slice_num	unified_pos	
设定	2	1	32	0	

隐藏层维度（n_hidden=128）定义了每个空间点或 token 的特征表示维度，为后续的多头注意力与多层感知机（MLP）层提供基础特征空间；网络层数（n_layers=4）通过堆叠 4 层 AFNO 模块增强模型的表征能力；空间维度（space_dim=3）明确输入数据为三维空间数据（如点云的 x, y, z 坐标）；功能维度（fun_dim=0）暂未启用额外功能维度，为未来扩展保留接口；多头注意力头数（n_head=8）在多头注意力机制中引入 8 个注意力头以捕捉不同空间位置间的复杂关系；MLP 层比例（mlp_ratio=2）将 MLP 层的隐藏维度设置为输入维度的 2 倍，以增强非线性表达能力；输出维度（out_dim=1）确保最终输出为单值特征，适用于回归任务或全局特征提取；切片数量（slice_num=32）将三维数据分块为 32 个切片，以降低计算复杂度并增强局部特征捕捉能力；统一位置编码（unified_pos=0）关闭统一位置编码，转而采用局部位置编码或数据自带的空间信息。

7.3 逆映射

GNO 的逆映射即将将规则网格上的结果逆映射回原始几何空间，其关键在于建立网格单元与几何元素（点/顶点）的对应关系，本文通过深度学习模型实现特征或标签的平滑传递。

7.4 数据增强

由于点云数据的稀缺性，难以覆盖所有可能的汽车的几何形态，通过数据增强，模型可以学习到点云在不同变换下的不变性，且现实中的点云数据可能包含噪声、遮挡或部分缺失，数据增强可以模拟这些情况，使模型更鲁棒。

本文对点云进行随机变换，包括平移、加噪声和随机丢点，以提升模型的泛化能力。

- (1) 平移：将点云整体沿某个方向随机平移一定距离；
- (2) 加噪声：在点云中每个点的坐标上添加随机噪声；
- (3) 随机丢点：随机移除点云中的部分点。

7.5 损失函数设计

为衡量汽车风阻预测模型预测结果与真实结果之间的差异，并通过优化这一差异来指导模型参数的更新，提升预测性能，本文实现了绝对误差（abs）和相对误差（rel）两种误差计算。

1) 绝对误差

对于每个样本，计算离散解的连续空间 L_p 范数近似误差，公式为：

$$L_{abs} = \frac{1}{N} \sum_{i=1}^N (h^{\frac{d}{p}} \|x^{(i)} - y^{(i)}\|_p) \quad \text{式 7-3}$$

其中， h 表示网格间距， d 表示问题的空间维度（在本研究中为三维问题，即 $d=3$ ）， P 表示所采用的范数阶数（在本研究中取 $P=2$ ，即采用二阶范数）， N 表示样本数量。

2) 相对误差

计算预测值与真实值的 L_2 范数相对误差，公式为：

$$L_{rel} = \frac{1}{N} \sum_{i=1}^N \left(\frac{\|x^{(i)} - y^{(i)}\|_2}{\|y^{(i)}\|_p} \right) \quad \text{式 7-4}$$

其中，分子为预测值与真实值的 L_2 范数，分母为真实值的 L_p 范数（在本研究中取 $P=2$ ）。

7.6 优化器选择

优化器用于最小化损失函数，本文采用 Adam（Adaptive Moment Estimation）是一种自适应学习率优化算法，结合了动量和 RMSProp 的优点，其更新规则为：

$$\begin{aligned} m_t &= \beta_1 m_{t-1} + (1 - \beta_1) \nabla_{\theta} L, \\ v_t &= \beta_2 v_{t-1} + (1 - \beta_2) (\nabla_{\theta} L)^2, \\ \hat{m}_t &= \frac{m_t}{1 - \beta_1^t}, \hat{v}_t = \frac{v_t}{1 - \beta_2^t}, \\ \theta_{t+1} &= \theta_t - \alpha \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} \end{aligned} \quad \text{式 7-5}$$

其中， α 是学习率； β_1 和 β_2 是动量超参数； ε 是防止除零的小常数。

7.7 监督约束

监督学习通过输入-输出数据对训练模型，使其能够学习输入特征（汽车几何信息）与目标变量（风阻系数）之间的映射关系。此外，将创建的约束对象存储在一个字典中，键是约束名称，值是约束对象本身，方便地管理多个约束，并在训练时统一调用。

最终，本文将数据加载、损失计算和约束定义集成在一起，便于在框架中进行训练和优化。

7.8 模型的训练

本文所有试验均在 Linux 系统下，PaddlePaddle GPU 版本 3.0，CUDA 12.6 框架下完成,所用的 Python 和 pip 版本分别为 3.10 和 20.2.2,所用名称以及内存为 NVIDIA GeForce RTX 4080, 16375MiB，使用 Pycharm 编译器。

实验在 ShapeNet 数据集上进行，该数据集包含 3D 点云数据及其对应的类别标签，将数据按照 8:2 划分为训练集、测试集。模型训练采用 Adam 优化器，学习率、批量批大小、训练次数分别设置为为 1e-4、2、100。

7.9 实验结果

通过 100 轮的迭代，最终模型在评价指标 Score、Mean relative l2 p error 和 Mean relative Cd error 分别为 0.90233、0.075281 和 0.14121；对 50 个数据预测的汽车风阻系数结果见表格，在星河社区跑通训练推理流程，完成评分榜单提交，并在报名团队数 700 的榜单中排名第五，与名次第一的团队 Score、和 Mean relative Cd error 仅差距 0.01763、0.0082 和 0.09808，Mean relative l2 p error 名次第一的团队 0.05427，通过 Paraview 软件对验证集数据的预测进行可视化见图 7-4、7-5、7-6。

排名	参赛团队	所属组织	score	mean relative l2 p error	mean relative Cd error	提交时间
	翻斗花园	翻斗花园	0.91966	0.13158	0.04313	2025-04-21 02:18
	MC25001293	厦门大学	0.90893	0.07157	0.12882	2025-04-21 16:36
	aaaa11112的团队	西藏大学	0.90743	0.13679	0.06725	2025-04-21 12:00
4	晨星8540的团队	郑州大学	0.90504	0.07731	0.13254	2025-04-21 15:01
5	MC25005313		0.90233	0.07528	0.14121	2025-04-21 17:36

图 7-3: MathorCup 数学应用挑战赛-赛道 A: 汽车风阻预测排行榜

表 7-2：模型评价指标与榜单名次

Score	Mean relative l2 p error	Mean relative Cd error	rank
0.90233	0.075281	0.14121	5/700

表 7-3：50 个数据预测的汽车风阻系数预测

NO	Cd	NO	Cd	NO	Cd	NO	Cd	NO	Cd
0	0.326707	10	0.444326	20	0.392133	30	0.401681	40	0.346441
1	0.415134	11	0.395663	21	0.365266	31	0.419448	41	0.502675
2	0.394755	12	0.356761	22	0.394381	32	0.422151	42	0.498489
3	0.350322	13	0.400717	23	0.390724	33	0.385041	43	0.414712
4	0.356548	14	0.394704	24	0.370765	34	0.402142	44	0.375787
5	0.369893	15	0.358815	25	0.368755	35	0.442359	45	0.379151
6	0.352546	16	0.369518	26	0.379924	36	0.432342	46	0.379902
7	0.460546	17	0.367703	27	0.385451	37	0.376709	47	0.366956
8	0.436381	18	0.389252	28	0.366873	38	0.379937	48	0.364541
9	0.465623	19	0.403251	29	0.386284	39	0.350014	49	0.400262




图 7-4：验证集数据可视化结果图 1




图 7-5: 验证集数据可视化结果图 2




图 7-6: 验证集数据可视化结果图 3

八、问题四的建立与求解

汽车风阻预测涉及流体力学、几何建模与机器学习的交叉领域，往往模型越复杂，模型性能越好，在考虑计算模型的计算复杂度和占用的物理空间、计算模型的模型参数量和计算模型的显存占用情况下，计算复杂度越低，占用的物理空间越少，计算模型的模型参数量和计算模型的显存占用情况越低的情况下，还能保持模型的性能，这样的模型实用性才更好。为进一步提升汽车风阻预测模型的性能，在保证全量非稀疏测试数据集上的精度要求下，问题四的算法在问题三的基础上引进 GeoCA3D 与自适应半径近邻图，算法流程图见图 8-1：




图 8-1：引入 GeoCA3D 与自适应半径近邻图算法流程图

8.1 基于半径的近邻图

由于汽车表面点云具有非均匀密度，汽车风阻预测模型使用卷积神经网络（CNN）或全连接网络（FCN），依赖固定拓扑结构，难以捕捉局部几何依赖。因此本文引入基于半径的近邻图（Radius Graph）有以下几个优势：

- （1）自适应邻域范围，适应不同密度区域（如车头 vs 车尾），减少远距离点的干扰，提升局部特征提取能力；
- （2）结合多尺度半径图，从局部到全局逐步聚合信息，小半径图捕捉局部曲面细节，大半径图建模整体气动外形；
- （3）轻量化图模型，通过半径约束和邻居数量限制，显著降低计算开销，半径图构

建复杂度 $O(N)$ (优化后), 而全连接图为 $O(N*N)$, 限制每个节点的最大邻居数 (32 个), 减少冗余计算。

8.2 结合几何感知与计算流体力学 (CFD) 的 GeoCA3D

结合 GeoCA3D 高精度三维建模能力几何特征提取优势、多尺度分析能力可以进一步提升风阻预测模型性能。

(1) 高精度三维建模能力: GeoCA3D 能够处理汽车复杂的曲面和细节结构, 生成高精度的三维模型; 支持参数化建模, 允许快速调整设计变量, 实现多方案对比分析;

(2) 几何特征提取与降维: GeoCA3D 可以将三维模型体素化, 提取出非空体素和空体素的体素特征。这些特征包含了丰富的几何信息, 能够作为风阻预测模型的输入, 替代传统方法中需要手动选取的外造型参数。

(3) 多尺度分析能力: GeoCA3D 能够同时捕捉到汽车表面的局部细节和整体形状对风阻的影响, 使得风阻预测模型能够更全面地理解几何形状与空气动力学性能之间的关系。

此外, GeoCA3D 能够与深度学习技术进行很好的结合:

(1) 稀疏卷积神经网络: GeoCA3D 提取的体素特征可以作为稀疏卷积神经网络 (SCNN) 的输入。SCNN 通过稀疏卷积操作, 能够在保持计算效率的同时, 有效处理三维数据, 提取出更深层次的几何特征。

(2) 端到端预测: 结合深度学习模型, GeoCA3D 能够实现从三维模型到风阻系数的端到端预测。这种预测方式避免了传统方法中需要依赖流体力学仿真的繁琐步骤, 大大缩短了预测时间, 同时保持了较高的预测精度。

8.3 消融实验

通过对算法的进一步创新后, 本文从稀疏采样率、训练集数量、不同模型架构下开展消融实验, 试验结果见表 8-1、表 8-2 和表 8-3:

表 8-1: 不同稀疏采样率下的评价指标

稀疏采样率	L2 相对平均误差	Cd (阻力系数) 误差
10%	0.25	50
50%	0.12	44
100%	0.06	42

在某些情况下, 高采样率可能导致数据冗余, 即采集到的数据中包含大量重复或无关的信息, 增加了计算成本和时间, 稀疏采样可以有效的降维, 减少存储和计算开销。然而过低的采样率会导致关键信息丢失, 从而影响模型的性能。因此, 需要设定合适的采样率既能避免信息的冗余也能保存关键信息。

从表格中可以看出, 随着稀疏采样率的增加, 模型性能下降, 但是其下降幅度小, 因此可以得出稀疏采样可以有效减小计算的开销。

表-8-2: 不同训练集数量下的评价指标

训练集数量	L2 相对平均误差	Cd (阻力系数) 误差
100	0.195	49
200	0.173	43
全量	0.060	42

从表格中可以看出, 随着训练集数量的下降, 模型的性能也开始下降, 较多的训练数据可以提升模型的预测精度。在模型训练中, 可以通过增加数据集的样本以及数据增强等策略提升模型的; 数据集的获取是耗时且不易的, 且数据集的增加必然会给数据的标记带来更好的工作量, 模型的训练也会更加的复杂。

在实际应用场景中, 少样本学习 (Few-shot learning) 是一种重要的解决方案, 本文

构建的模型随着训练集数据量的减少,模型下降幅度小,模型具有一定的 Few-shot 能力。

表 8-3: 不同模型架构下的评价指标

层数	参数量	激活函数	显存需求 (GB)	权重大小 (MB)	L2 相对平均误差	Cd (阻力系数) 误差
2x transformer Block	0.26M	ReLu	0.2684	1.11	0.29	56
3x transformer Block	0.38M	ReLu	0.5574	1.62	0.27	57
4x transformer Block	0.50M	ReLu	0.6899	2.21	0.09	43
2x transformer Block	0.26M	Gelu	0.2676	1.07	0.28	53
3x transformer Block	0.38M	Gelu	0.5078	1.54	0.26	45
4x transformer Block	0.50M	Gelu	0.6484	2.00	0.06	42

从表格中可以看出,模型架构为 4x transformer Block,且激活函数为 Gelu 时模型性能最佳,显存需求 0.6484GB,权重大小 2MB,L2 相对平均误差 0.06,Cd (阻力系数) 误差 42 个 counts。

九、问题五的建立与求解

在现代神经算子理论框架中，算子泛函的近似能力是其建模物理场函数间映射的基础。本文进一步探讨注意力机制 (Attention Mechanism) 是否可视为一种特定形式的神经算子 (Neural Operator)，以此为支撑，构建基于注意力的神经算子框架。

9.1 神经算子形式化定义

设 $f: \Omega \rightarrow R^d$ 为定义在空间域 $\Omega \subset R^n$ 上的输入函数，神经算子的目标是学习从函数空间到函数空间的映射：

$$G: f(x) \mapsto u(x) \quad \text{式 9-1}$$

其中 $u(x)$ 表示物理场输出，最常见的一类神经算子结构可以写成积分形式：

$$u(x) = \int_{\Omega} K(x, y) f(y) dy \quad \text{式 9-2}$$

其中 $K(x, y)$ 是核函数，通常通过神经网络进行参数化学习。该结构本质上是对连续核算子的近似，其优势在于能够建模任意空间位置之间的非局部依赖关系。

9.2 注意力机制的结构

以自注意力 (Self-Attention) 为例，对于一组输入序列 $X = \{x_i\}_{i=1}^n \in R^{n \times d}$ ，首先通过三组可学习参数 W^Q, W^K, W^V 构造查询 (Query)、键 (Key)、值 (Value) 向量：

$$Q = XW^Q, K = XW^K, V = XW^V \quad \text{式 9-3}$$

接着通过注意力权重计算：

$$\alpha_{ij} = \frac{\exp(Q_i \cdot K_j)}{\sum_k \exp(Q_i \cdot K_k)} \quad \text{式 9-4}$$

输出结果为：

$$y_i = \sum_j \alpha_{ij} V_j \quad \text{式 9-5}$$

由此可见，注意力机制本质上对输入特征 V_j 加权求和，权重由 Q, K 的相似度动态生成。进一步推广至连续形式，可得：

$$u(x) = \int_{\Omega} \alpha(x, y) f(y) dy \quad \text{式 9-6}$$

其中 $\alpha(x, y) = \frac{\exp(q(x)^T k(y))}{\int_{\Omega} \exp(q(x)^T k(y)) dy}$ 为由 $q(x), k(y)$ 学习到的核函数，这一形式正与神经算子的核积分表达式一致。

9.3 注意力机制为神经算子的推理与证明

设注意力机制在输入点集 $\{x_i\}_{i=1}^n$ 上构造映射 $f(x_i) \mapsto u(x_i)$ ，其计算过程如下：

$$u(x_i) = \sum_j \frac{\exp(q(x_i)^T k(x_j))}{\sum_k \frac{\exp(q(x_i)^T k(x_k))}{\alpha(x_i, x_j)}} f(x_j) \quad \text{式 9-7}$$

随着 $n \rightarrow \infty$ 且点集在 Ω 上均匀分布，该离散求和形式趋于积分表达：

$$u(x) = \int_{\Omega} \alpha(x, y) f(y) dy \quad \text{式 9-8}$$

其中核函数 $\alpha(x, y)$ 是通过神经网络学习得到的自适应非线性核。显然该结构完全符合神经算子的定义。因此，注意力机制构成了一种数据驱动的、非参数的神经算子形式。

进一步地，多头注意力 (Multi-Head Attention, MHA) 将多个子空间注意力机制并行处理，其结构形式为：

$$MHA(x) = \text{Concat}(u_1(x), u_2(x), \dots, u_h(x)) W^O \quad \text{式 9-9}$$

其中每个 $u_k(x)$ 为一个独立的神经算子，实现了多个不同核函数下的函数映射，并通过输出线性层融合不同空间特征，有效提升了表达能力。

根据神经算子逼近定理，当核函数 $K(x, y)$ 是连续且参数化可学习时，任意核积分算子均可被神经网络以任意精度逼近。而注意力机制中 $\alpha(x, y)$ 完全由可学习参数构建，满足连续性与可微性条件，因此具有与神经算子等价的函数逼近能力。

综上所述，注意力机制在结构形式、表达能力与理论上均满足神经算子的核心定义。因此认为注意力机制是一种特殊形式的神经算子，具备从输入函数空间到输出函数空间的映射能力，并在多头注意力框架下实现了多核算子的集成学习，适用于构建物理场建模中的神经算子网络结构。

十、模型的评价与推广

10.1 模型的优缺点

(1) 问题 1 模型的优点

1.加速收敛过程: Adam 优化器集成了动量和自适应学习率机制,能有效提升训练效率,加快模型收敛速度,尤其适用于神经算子这类高维映射问题。

2.抑制梯度震荡:相较于 SGD 等方法,Adam 更稳定,能在初始训练阶段减少损失震荡,提高拟合平稳性。

3.对数转换增强数值稳定性:通过对梯度取对数的方式,压缩数值范围,有助于参数在优化过程中维持合理的更新步幅,避免步长过大导致的发散问题或步长过小造成的收敛缓慢问题

(2) 问题 2 方法的优点

1.大规模数据处理效率高:构建了支持 24 核并行加载的 DataLoader,采用了共享内存机制与预取策略,大幅减少了训练等待时间,有效解决了海量复杂结构数据加载瓶颈。

2.模型训练流畅性与稳定性提升:异步加载与 shuffle 策略提升了模型训练过程中样本分布的均匀性与收敛速度。

(3) 问题 3 模型的优点

1.融合几何与频域信息,提升预测精度: G-AFNO 框架将图神经算子 (GNO) 和傅里叶神经算子 (AFNO) 有效结合,前者处理局部几何与拓扑结构,后者建模整体频域特征,实现对复杂流场中全局与局部特征的协同建模。

2.具备频域自适应能力:相较于固定频域变换,AFNO 能够自动调整不同频率分量的权重分配,使模型在处理湍流等高频扰动场景时具有更强的适应能力。

3.多尺度建模能力强:通过两级 GNO 结构对不同层级的几何信息进行编码解码,使得模型具备较强的多尺度特征提取与还原能力,提升了点云到压力分布之间的映射能力。

(4) 问题 4 模型的优点

1.半径邻图增强局部几何感知能力:引入半径邻图 (Radius Graph) 构建局部连接结构,能够提升模型对复杂汽车曲面细节的捕捉能力,减少信息遗漏。

2.与 GeoCA3D 的融合提升结构建模与物理一致性: GeoCA3D 能从三维网格生成物理场信息,结合 CFD 数据增强风阻建模物理合理性。该框架可自动提取结构信息并分析形变区域,有助于模型学习对几何变化的敏感性。

(5) 模型的不足

对初始超参数敏感: Adam 中 β_1 , β_2 , ε 等参数设置不当,可能影响最终训练效果;

几何与物理特征融合有限: .当前仅使用顶点坐标作为输入,未进一步融合单元拓扑信息、法向量、曲率等几何高阶特征,可能限制了模型对复杂流动特征的表达能力;

受输入几何信息影响: 几何信息的精度对 GNO 的编码性能影响较大,若输入数据存在扰动或噪声,可能导致几何-频域融合效果下降。

10.2 模型的评价

(1) 动态学习率调整: 可考虑使用 Cyclical Learning Rate 或学习率热重启 (Cosine Annealing), 避免 Adam 在中后期陷入局部最优, 提升目标函数整体收敛质量。

(2) 端到端的预处理流水线集成: 当前 Meshio 加载与 DataLoader 分离, 可尝试构建端到端的数据预处理流水线, 结合 Paddle 的异步管道机制, 提高整体效率与可维护性。

(3) 混合算子架构探索: 探索引入更多类型的神经算子 (如 U-NO、Graphormer)

与 AFNO 联合建模，设计“混合神经算子”（Hybrid Neural Operator）架构以进一步增强模型泛化与拟合能力。

（4）优化半径邻图构造方式以降低计算开销：当前半径邻图在构建局部结构时需进行多次距离计算，计算复杂度较高。可考虑引入 K 近邻（KNN）加速搜索算法或基于空间划分的近似邻域搜索方法（如 Ball Tree、Octree）以减少计算时间，提高处理大规模点云数据时的效率。

10.3 模型推广

（1）所采用的目标函数优化方法不仅适用于当前高维复杂空间中函数值优化的问题，也可推广至其他需要数值最优解的工程或科研领域中，如参数调优、机器学习中的超参数搜索等。特别是带有爆炸梯度风险的优化问题中，通过引入对数变换策略和自适应动量估计（Adam）优化算法，有效提升了收敛速度与稳定性，适用于大多数非凸目标函数的优化场景。

（2）数据预处理与异步加载机制可应用于处理其他具有复杂几何结构的仿真数据，如航空航天器表面气动载荷、船体水动力模拟等。

（3）几何感知自适应傅里叶神经算子（G-AFNO）融合图神经算子与频域建模思想，具有良好的可迁移性。该框架可应用于其他涉及空间几何结构与物理场预测任务中，如建筑结构应力分析、电磁场建模、环境模拟等。此外，G-AFNO 结构对多源异构数据具备较强兼容能力，适合推广至多模态信息融合领域，提升不同物理模态间的建模能力。

（4）基于 GeoCA3D 与半径邻图的风阻建模方法可推广至其他复杂流体-几何交互系统中，如高铁外形风噪预测、飞机表面气动分析等。GeoCA3D 具备自动生成高精度表面结构的能力，可适配各类 3D CAD 模型，具有良好的可扩展性。

参考文献

- [1] RAISSI M, PERDIKARIS P, KARNIADAKIS G E. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations [J]. *Journal of Computational Physics*, 2019, 378: 686-707.
- [2] LU L, JIN P, PANG G, et al. Learning nonlinear operators via DeepONet based on the universal approximation theorem of operators [J]. 2019, 3: 218 - 29.
- [3] LI Z, MEIDANI K, FARIMANI A B J T M L R. Transformer for Partial Differential Equations' Operator Learning [J]. 2022, 2023.
- [4] LI Z-Y, KOVACHKI N B, AZIZZADENESHELI K, et al. Fourier Neural Operator for Parametric Partial Differential Equations [J]. 2020, abs/2010.08895.
- [5] GUIBAS J, MARDANI M, LI Z-Y, et al. Adaptive Fourier Neural Operators: Efficient Token Mixers for Transformers [J]. 2021, abs/2111.13587.
- [6] ZHANG S, TONG H, XU J, et al. Graph convolutional networks: a comprehensive review [J]. *Computational Social Networks*, 2019, 6(1): 11.
- [7] LU L, JIN P, PANG G, et al. Learning nonlinear operators via DeepONet based on the universal approximation theorem of operators [J]. *Nature Machine Intelligence*, 2021, 3(3): 218-29.
- [8] LI Z-Y, HUANG D Z, LIU B, et al. Fourier Neural Operator with Learned Deformations for PDEs on General Geometries [J]. 2022, 24: 388:1-:26.
- [9] 王刚, 张瑞昊, 刘学龙, 等. 融合稀疏八叉树与卷积神经网络的汽车风阻系数预测 %J *计算力学学报* [J]. 2024, 41(01): 58-65.
- [10] 陈凯, 李佳琳, 王朋波,等. 基于几何信息神经算子的参数化汽车几何风阻预测模型; *proceedings of the 2024 中国汽车工程学会汽车空气动力学分会学术年会*, 中国重庆, F, 2024 [C].