

队伍编号	25006464
题号	D

基于多目标优化的短途运输货量预测及车辆调度问题的研究

摘要

本文针对短途物流运输中的关键运营难题，构建了一套完整的智能决策支持系统。基于深度学习和集成学习方法开发了高精度货量预测模型，实现了未来 24 小时、10 分钟颗粒度的精准预测；建立了多目标混合整数规划模型，同步优化车辆周转率、装载率和运输成本三项核心指标；进一步地通过引入标准容器技术，系统评估了装卸效率与装载容量的权衡关系；最后，采用蒙特卡洛模拟方法对预测误差的传导机制进行量化分析，增强了调度系统的鲁棒性。不仅显著提升了短途运输的运营效率，更为物流企业的智能化转型提供了可落地的技术方案。

针对问题一，需要进行基于历史数据进行短途运输货量预测，提出了基于 *XGBoost* 算法的机器学习预测模型。通过深入挖掘历史数据的时间序列特征，建立了以 10 分钟为时间单位的精细化预测体系。模型验证结果表明：该预测系统具有优异的性能表现，拟合优度 R^2 达到 0.9322，平均绝对误差 (*MAE*) 控制在 1.0213，均方根误差 (*RMSE*) 为 0.9751。特别值得注意的是，模型在保持高精度的同时展现出良好的泛化能力，未出现过度拟合现象，对未来货量的预测具有可靠的适用性。

针对问题二，基于车辆调度优化问题，构建了一个多目标决策模型。该模型以提升自有车周转率、增加车辆均包裹量和降低总成本为优化目标，综合考虑了发运时间约束、车辆任务衔接、装载容量限制以及串点任务约束（不超过 3 条线

路)等实际运营条件。通过设计贪心算法求解,在保证各约束条件满足的前提下,实现了运输资源的最优配置。最终结果表明,该调度方案在车辆利用效率与运营成本之间取得了良好的平衡。

针对问题三,在标准容器应用场景下对调度模型进行了优化重构。基于问题二多目标优化框架,重点调整了两个关键参数约束:将单次装卸时间从 45 分钟压缩至 10 分钟,同时将车辆装载容量从 1000 件下调至 800 件。采用改进的贪心算法求解后获得以下优化结果:自有车周转率下降,车辆均包裹量达也下降,总成本增加。值得注意的是,虽然装载容量下降导致总成本上升,但装卸效率的大幅提升使车辆周转率获得显著改善,这验证了标准容器技术在提升运输系统整体效率方面的独特价值。

针对问题四,将预测偏差对调度系统的影响进行了深入分析。通过构建综合目标函数和采用蒙特卡洛模拟方法,系统评估了不同幅度预测误差对调度方案的敏感性影响。结果表明,当货量预测误差保持在 $\pm 10\%$ 的合理范围内时,调度系统能够维持良好的稳定性,避免出现成本急剧攀升的情况(成本波动幅度控制在 15%以内),以确保运输调度方案的可靠性和经济性。该敏感性分析不仅验证了调度模型的鲁棒性,也为预测精度的目标设定提供了科学依据。

关键词: 多目标优化调度模型, *XGBoost*模型, 贪心算法, 蒙特卡洛模拟方法, 敏感性分析

目录

一、问题背景与重述.....	1
1.1 问题背景.....	1
1.2 问题重述.....	1
二、问题分析.....	2
2.1 问题一的分析.....	2
2.2 问题二的分析.....	2
2.3 问题三的分析.....	3
2.4 问题四的分析.....	3
三、模型假设.....	3
四、符号说明.....	4
五、模型的建立与求解.....	4
5.1 问题一的模型建立与求解.....	4
5.1.1 数据预处理.....	4
5.1.2 基于 XGBoost 算法的货量预测模型的建立.....	7
5.1.3 细分颗粒度拆解预测.....	11
5.2 问题二模型建立与求解.....	13
5.2.1 多目标规划模型的建立.....	13
5.2.2 约束条件的确定.....	16
5.2.3 多目标规划模型的求解.....	17
5.2.4 贪心算法求解结果.....	18
5.3 问题三的模型建立与求解.....	21
5.3.1 考虑标准容器的使用下的多目标规划模型建立.....	21
5.3.2 约束条件的确定.....	22
5.3.3 贪心算法求解结果.....	24
5.4 问题四的模型建立与求解.....	27
5.4.1 评估货量预测结果偏差对调度模型优化结果的影响.....	27
5.4.2 蒙特卡洛随机模拟.....	29
5.4.3 不同扰动下优化结果分析.....	31

六、模型的评价与优化.....	32
6.1 模型的优点.....	32
6.2 模型的缺点.....	33
6.3 模型的改进.....	33
参考文献.....	34
附录.....	35

一、问题背景与重述

1.1 问题背景

随着电子商务和城市物流的快速发展，短途运输作为连接分拣中心与营业部的关键纽带，具有运输半径小、资源复用性强、时效要求高等典型特征，其运营效率直接影响客户满意度与企业成本结构。然而，在行业快速扩张的同时，短途运输面临着许多挑战。首先，货量预测精度不足。现有预知数据存在计划线路偏差，未下单货量缺失以及订单取消等问题，导致传统预测方法准确率较低，严重影响后续调度决策。本文针对以上问题建立了系统的解决方案框架，开发了融合时序特征的机器学习预测模型，实现 10 分钟级货量预测；其次构建多目标优化模型，在考虑车辆周转时间、装载容量等约束下，平衡自有车辆周转率、装载效率与成本控制；进而量化评估标准容器带来的装卸效率提升与装载容量下降的权衡关系；最后通过敏感性分析确保系统抗干扰能力。该方案为提升短途运输的时效性、经济性和资源利用率提供了可靠的理论方法和技术支撑。

1.2 问题重述

问题一：

本题需要建立高精度的短途运输货量预测模型，具体要求为：针对所有运输线路，预测未来 24 小时（12 月 15 日 14:00 至 12 月 16 日 14:00）的总货量，并将其细化为 10 分钟颗粒度的货量分布。该预测需克服预知数据存在的三大挑战：线路偏差、未下单货量及订单取消情况。预测精度需满足后续车辆调度优化的需求，为运输资源的高效配置奠定数据基础。预测结果需填入表 1 和表 2 中，表 1 展示各线路 24 小时总货量预测值；表 2 展示精细化的 10 分钟时段货量分布。特别要求以“线路场地 3-站点 83-0600”和“场地 3-站点 83-1400”为典型案例，需要在论文中展示其预测结果，包括总货量数值及高峰时段分布特征。

问题二：

基于问题 1 得出的预测数据，为每条线路确定关键决策变量，包括发运车次数量，精确到分钟级的预计发运时间节点，以及最优串点组合方案，其中每个需求的发运时间不能晚于线路的发运节点。该调度方案需实现三重优化目标：首先，

通过科学安排车辆任务序列，最大化自有车辆周转率；其次，优化装载方案使车辆均包裹数达到最高；最后，统筹自有与外部运力资源，实现总运输成本最小化。将最终输出结果填入表 3，包含线路编码、预计发运时间、承运方标识（自有车辆编号或外部标注）以及串点线路合并信息。要求论文中展示场地“3-站点 83-0600”和“场地 3-站点 83-1400”两条典型线路的最优调度方案。

问题三：

本题给出了当前存在的一种标准容器，该容器数量是无限的，使用该容器可以进一步提升自有车辆利用率，将装车及卸车时长显著缩短至 10 分钟；但同时会降低车辆的装载量，其装载包裹量下降至 800 个。在此约束条件下，根据问题 1 输出的结果，需要重新构建运输需求模型并优化调度方案，优化目标与问题 2 相同。在问题 2 所需输出结果的基础上，需另外输出各运输需求是否使用该标准容器，最终将结果写入结果表 4 中，并在论文中给出场地“3-站点 83-0600”和场地“3-站点 83-1400”两条典型线路的调度结果。

问题四：

本题需要评估货量预测偏差对优化调度方案的影响机制与程度。具体而言，需构建预测误差情景模拟框架，定量分析当问题 1 的预测结果出现偏差时，对基于标准容器的问题 3，评估调度模型优化结果产生的多维影响。

二、问题分析

2.1 问题一的分析

问题一针对短途运输货量预测问题，先进行数据预处理，提出一种基于 *XGBoost* 算法^[1]的高精度预测模型。该模型需要完成未来 24 小时内各运输线路的货量预测任务，并将预测结果细化至 10 分钟颗粒度的时间分布。考虑到预测任务中时间变量的重要性，特别设计了时间特征处理模块，通过引入分钟级时间戳、周期性特征等时间变量，使 *XGBoost* 算法能够有效捕捉货量变化的时序规律。模型输出包括各线路 24 小时总货量预测值及其 10 分钟间隔的详细分布数据。

2.2 问题二的分析

问题二要求基于问题一输出的货量预测结果，确定运输需求，需要构建了一

个多目标规划模型。该模型综合考虑三个关键优化目标：最大化自有车辆周转率、提升车辆平均装载量以及最小化总运营成本。通过采用贪心算法进行求解，最终得出在合理时间内输出各线路的详细调度方案，结果包括精确到分钟级的发运时间安排、所需车辆数量计算、最优串点组合策略，以及自有车辆与外部车辆的最优配比。

2.3 问题三的分析

问题三是假设使用标准容器应用场景下的运输调度优化问题，构建一个改进的多目标规划模型。在保持问题二三个核心优化目标的前提下，重点考虑了标准容器带来的双重影响：装卸效率提升（时长从 45 分钟缩短至 10 分钟）和装载容量降低（从 1000 件减至 800 件）。模型通过引入新的决策变量和调整约束条件，重新优化计算各线路的发运需求。通过改进的贪心算法求解，该模型能够输出包含标准容器使用决策的优化调度方案。

2.4 问题四的分析

问题四重点研究货量预测偏差对调度系统的敏感性影响。鉴于预测模型不可避免地存在误差，然而误差会导致车辆调度、自有车周转率、车辆均包裹率等发生变化，从而导致外部承运商成本和自有车辆成本的变化。故考虑构建一个综合目标函数，量化预测偏差对车辆的调度、效率和成本的影响，最后根据预测偏差的影响，调整调度策略，优化整体的调度方案。

三、模型假设

1. 假设预知数据虽存在一定误差，但能够基本反映实际货量情况。
2. 假设货量变化具有时间连续性特征，相邻时段间的波动幅度保持相对平稳。
3. 假设串点策略的实施可有效提升车辆利用率，且每个串点任务最多整合 3 条线路。
4. 假设标准容器资源供给充足，能够完全满足运输需求。
5. 假设在运力调配方面遵循自有车辆优先原则，仅当自有运力不足时才启用外部承运商。

四、符号说明

表 1 主要符合列表及说明

符号变量	说明	单位
$P_{i,t}$	第 i 条线路在时间 t 的预测货量	个
$y_{i,t}$	第 i 条线路在时间 t 的实际货量	个
V	表示车队的总车辆数	辆
T_i	表示第 i 条线路的最晚发运时间	/
S	表示总成本	元
t_{load}	表示装车时间	分钟
t_{unload}	表示卸货时间	分钟
η	表示自有车周转率	/
ΔV	表示预测误差引起的车辆调度差异	/
ε	表示预测误差比例	/
P_{max}	表示每辆车的最大载货量（包裹数）	个

五、模型的建立与求解

5.1 问题一的模型建立与求解

5.1.1 数据预处理

根据题目提供的信息可以看出，预知货量数据存在两个主要缺陷：首先是实际运输路径经常偏离系统预设路线；其次是数据采集不完整，既没有涵盖潜在订单量，也无法规避已确认订单的取消风险。这种双重不确定性导致预知数据与实际运输需求必然出现偏差。因此，构建一个智能化的货量修正系统势在必行，通过数据建模手段对原始预测值进行动态校准，才能获得更可靠的货量预估结果。在正式开发修正模型之前，必须深入分析历史数据，明确预估值与真实值的关联规律，从而确定最优的建模方法。在构建预知货量修正模型前，需开展数据相关分析，探究预知货量与实际货量数据之间的相关性，进而筛选适配模型。任选 3 条线路，其线路编号分别为“场地 2 - 站点 44-1400”，“场地 3- 站点 72-1400”，“场地 1- 站点 3-1400”其货量与预知货量可视化图如下：




图 1 货量与预知货量可视化图

由图可知，在上述部分线路中，如场地 1-站点 3-1400，货量与预知货量在整体上呈现出相似的变化趋势。然而，在部分区间内，二者趋势存在差异。鉴于此，选取上述 3 条线路的货量与预知货量之差作为残差序列，进行 ADF 检验。

$$\mu_i = N_i - N_i^y \quad (1)$$

式中： μ_i 为第*i*条线路残差序列； N_i 为第*i*条线路货量； N_i^y 为第*i*条线路预知货量。

当显著性 P 值小于 0.05 或者 h 值为 1 时，表明该时间序列通过平稳性检验，3 条线路残差序列的 ADF 检验结果汇总如下表所示。

表 2 3 条线路残差序列的 ADF 检验表

线路编号	h 值	P 值
场地 2 - 站点 44 - 1400	0	0.6267
场地 3 - 站点 72 - 1400	0	0.6287
场地 1 - 站点 3 - 1400	0	0.4558

3 条线路残差序列的 ADF 检验如图所示




图2 场地2-站点44-1400 残差序列可视化图




图3 场地3-站点72-1400 残差序列可视化图




图 4 场地 1-站点 3-1400 残差序列可视化图

经对三条线路残差序列开展 ADF 检验并结合可视化分析发现,其检验结果中的 h 值均呈现为 0,显著性 P 值均超过 0.05 的阈值。这一结果表明,该三条线路的残差序列未能通过平稳性检验。虽然不排除存在个别线路残差序列满足平稳性要求的可能性,但从整体来看,多数线路残差序列在平稳性方面存在缺陷,且残差数值较大。这一现象揭示了预知货量与实际货量之间既存在线性关系,也包含非线性关系。为了更精准地拟合实际包裹数量,有必要对预知货量数据进行修正,并构建预知量与实际值之间的回归模型。鉴于线性回归模型难以有效捕捉数据中的非线性特征,因此推荐采用机器学习等对非线性关系适应性更强的方法开展数据拟合工作。

5.1.2 基于 XGBoost 算法的货量预测模型的建立

通过 5.1.1 小结分析,考虑对线路建立基于 XGBoost 算法货量预测模型^[2],XGBoost 是一种基于梯度提升决策树的高性能机器学习算法,具有卓越的预测准确性和良好的可扩展性。该算法通过集成多个弱分类器(决策树)来构建强分类器,其核心优势体现在三个方面:首先,采用并行计算架构,能够高效处理大规模数据集;其次,在迭代训练过程中,通过计算梯度信息来优化决策树的构建,具体表现为:每个决策节点基于特征和阈值的组合来分割数据,并利用梯度下降法选择最优分割方案;最后,算法集成了多项正则化技术(包括 L1 和 L2 正则化)以及自适应学习率机制,既有效控制了模型过拟合风险,又提升了训练效率和模型泛化能力。这些特性使 XGBoost 成为处理复杂预测任务的理想选择。

假设样本数据集 $D = \{(x_i, y_i)\}$, 其中 x_i 为经过特征选择后的分子样本特征向量输入, y_i 为待预测的目标变量输出。XGBoost 算法因其出色的预测性能和计算效率而成为理想的建模工具,其核心优势体现在精心设计的目标函数中,该函数同时优化预测准确性和模型复杂度,通过正则化项控制过拟合,并采用二阶泰勒展开来近似损失函数,从而在保证预测精度的前提下实现高效计算。具体的目标函数表达式为:

$$Obj^{(t)} = \sum_{i=1}^n l[y_i, y_i^{(t-1)} + f_i(x_i)] + \Omega(f_t) + C \quad (2)$$

对于本题中的时间、货物量等数据集, i 表示一个颗粒度。模型的目标函数由

两部分组成，第一部分是衡量预测值与真实值之间差异的损失函数，选择损失函数应根据需求确定。第二部分是正则化项，用树模型的某种变换 Ω 表示，用于衡量模型的复杂度。

二阶泰勒展开式为：

$$f(x + \alpha) = f(x) + f'(x)\alpha + \frac{1}{2}f''(x)\alpha^2 \quad (3)$$

*XGBoost*算法采用基于二阶泰勒展开的优化方法，这一创新性设计使其在机器学习领域展现出卓越性能。该方法的优势主要体现在三个方面：首先，通过引入二阶导数信息，显著提升了梯度下降的收敛速度和优化精度；其次，其独特的数学形式不依赖于特定损失函数的显式表达，仅需输入数据即可自动计算损失函数，极大增强了算法的通用性；最后，这种优化框架能够高效处理各类复杂的大规模数据集。

1) 预测精度和结果分析

考虑使用如下指标评价机器学习回归模型的优劣：在这里我们考虑用指标，拟合优度 R^2 、平均绝对误差 MAE 及均方根误差 $RMSE$ 三个评价指标对该机器学习回归模型的拟合效果进行评价。给出上述指标的计算公式如下：

$$R^2 = 1 - \frac{\sum_{i=1}^n (|\check{y}_i - \tilde{y}_i|)^2}{\sum_{i=1}^n \sum_{i=1}^n (|\bar{y}_i - \tilde{y}_i|)^2} \quad (4)$$

其中 R^2 衡量了模型对观测数据的拟合程度，其值越接近 1 表示模型的拟合效果越好。

MAE 反映了预测值与实际值之间的平均距离。计算公式如下：

$$MAE = \frac{1}{n} \sum_{i=1}^n |\check{y}_i - \tilde{y}_i| \quad (5)$$

$RMSE$ 度量了预测值与实际值之间的平均距离，计算公式如下：

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\check{y}_i - y_i)^2} \quad (6)$$

任选六条线路展示其 *XGBOOST* 预测结果，其线路编号分别为场地 1-站点 19-0600，场地 1-站点 19-1400，场地 1-站点 2-0600，场地 1-站点 2-1400，场地 1-站点 20-0600，场地 1-站点 20-1400。其可视化图如下所示：




图 5 预知货量部分预测值可视化图

预测精度如下表所示：

表 3 线路预知货量部分预测值的预测精度

线路编号	R^2	MAE	RMSE
场地 1-站点 19-0600	0.98779	3.9153	5.6241
场地 1-站点 19-1400	0.8701	4.7324	6.3227
场地 1-站点 2-0600	0.99097	19.2213	29.5405
场地 1-站点 2-1400	0.87009	29.714	45.1913
场地 1-站点 20-0600	0.99223	16.258	25.2535
场地 1-站点 20-1400	0.9666	17.7807	26.81

由上图及表可知，上述六条线路的拟合效果均极好，其拟合系数（ R^2 ）均在 0.9 以上。

那选取日期和时间指标（以 10 分钟为颗粒度）作为机器学习模型的输入指标，以货量的值作为机器学习模型的输出。得到 XGBoost 模型在训练集和测试集上的表现，具体见表 1：

表 4 XGBoost 货量预测模型在训练集和测试集上的表现

模型	训练集			测试集		
	R^2	MAE	RMSE	R^2	MAE	RMSE
XGBoost	0.9615	0.8724	0.8673	0.9322	1.0213	0.9751

由模型的评价指标可知， R^2 为 0.9322，MAE为 1.0213，RMSE为 0.9751。

XGBoost 货量预测模型进行可视化以 10 分钟为颗粒度的预测效果见图 1：




图 6 XGBoost货量预测模型效果

从图 6 分析可知，大量数据点紧密聚集在真实值曲线周围，直观呈现出模型预测值与真实值之间存在显著的线性关联特征。尽管存在个别数据点轻微偏离趋势走向，但从整体数据分布情况来看，其离散程度仍处于合理区间，表明该模型在多数场景下均能实现较为精准的预测效果。随着真实总货量呈现递增趋势，模型预测的总货量亦保持同步增长态势，并未出现饱和停滞或数值下滑等异常现象。这一表现充分印证了模型在不同数据量级和取值范围内，均能保持良好的预测稳定性，由此可推断该模型具备较高的可靠性与有效性，在实际预测应用中能够发挥出良好的作用。

2) “场地 3-站点 83 - 0600” 和 “场地 3-站点 83 - 1400” 的预测结果

由题目要求可知，需在论文中给出“场地 3-站点 83 - 0600”和“场地 3-站点 83 - 1400”的货量预测结果，如下表所示：

表 5 未来 1 天货量预测结果

线路编码	日期	货量
场地 3 - 站点 83 - 0600	2024/12/16	7554
场地 3 - 站点 83 - 1400	2024/12/16	2711

5.1.3 细分颗粒度拆解预测

为了实现精细化的运输调度规划,需要采用时间分解方法将每小时预测货量转换为 10 分钟颗粒度的分布数据。具体而言,对于任意线路*i*在给定小时段内的总货量 $Q_{i(t)}$ 预测值,通过时间权重分配模型将其均匀拆分为 6 个 10 分钟间隔的子货量 $Q_i(t_k)$,即。这一转换过程遵循以下数学关系式:

$$Q_i(t_k) = \frac{Q_i(t)}{6} \quad (7)$$

其中, t_k 分别表示每小时内的 6 个 10 分钟段。

在短途运输调度优化中,将预测货量分解为 10 分钟颗粒度具有重要的实践意义。该精细化处理方法能够确保每个时段(每小时划分为 6 个 10 分钟间隔)的运输需求得到精准匹配,具体实现方式是基于预测的小时总货量进行等比例时间分配。这种细粒度的货量分布模型不仅满足了“按时段发运”的运输要求,更为车辆资源的精确调度提供了数据支撑,使每个 10 分钟窗口的运输任务都能获得最优的车辆配置方案,从而提升整体运输系统的效率和响应速度。依据附件 2 中的历史数据,部分线路的时间范围起始于 21:00 至次日 06:00,此区间包含 54 个时间刻度点;另一部分线路的时间范围起始于 11:00 至 14:00,涵盖 18 个时间刻度点。鉴于此,需分上述两种类型展开讨论,将每条线路的总货量细化至 10 分钟的颗粒度。

在计算 10 分钟颗粒度每个点位的货量值时,首先考虑通过历史 15 天的货物数据的按照每个时间刻度求平均值,这样即可得到每个时间刻度的货物值分布值,然后用每个时刻的分布值除以总时间刻度的累计值,即可得到每个时刻点货量值占一天总货量比值,以此实现货量的 10 分钟颗粒度的拆解。公式如下所示:

$$\mu_i = N_i - N_i^y \quad (8)$$

式中: μ_i 为第*i*条线路残差序列; N_i 为第*i*条线路货量; N_i^y 为第*i*条线路预知货量。

通过拆分比例计算得到各线路各时刻的占比,然后用该占比乘以附件中结果表 1 中预测的每天的总货量,即将每条线路的总货量拆解到 10 分钟颗粒度。

则“场地 3-站点 83 - 0600”和“场地 3-站点 83 - 1400”的 10 分钟颗粒度货量预测结果,如下表所示:

表 6 场地 3-站点 83 - 0600 线路 10 分钟颗粒度货量预测结果

线路编码	日期	分钟起始	包裹量
场地 3 - 站点 83 - 0600	2024/12/15	21:00:00	73
场地 3 - 站点 83 - 0600	2024/12/15	21:10:00	83
场地 3 - 站点 83 - 0600	2024/12/15	21:20:00	88
场地 3 - 站点 83 - 0600	2024/12/15	21:30:00	83
场地 3 - 站点 83 - 0600	2024/12/15	21:40:00	76
场地 3 - 站点 83 - 0600	2024/12/15	21:50:00	73
场地 3 - 站点 83 - 0600	2024/12/15	22:00:00	111
场地 3 - 站点 83 - 0600	2024/12/15	22:10:00	126
场地 3 - 站点 83 - 0600	2024/12/15	22:20:00	135
场地 3 - 站点 83 - 0600	2024/12/15	22:30:00	126
场地 3 - 站点 83 - 0600	2024/12/15	22:40:00	116
场地 3 - 站点 83 - 0600	2024/12/15	22:50:00	111
场地 3 - 站点 83 - 0600	2024/12/15	23:00:00	115
场地 3 - 站点 83 - 0600	2024/12/15	23:10:00	131
场地 3 - 站点 83 - 0600	2024/12/15	23:20:00	140
场地 3 - 站点 83 - 0600	2024/12/15	23:30:00	131
场地 3 - 站点 83 - 0600	2024/12/15	23:40:00	120
场地 3 - 站点 83 - 0600	2024/12/15	23:50:00	115
场地 3 - 站点 83 - 0600	2024/12/16	00:00:00	152
场地 3 - 站点 83 - 0600	2024/12/16	00:10:00	173
场地 3 - 站点 83 - 0600	2024/12/16	00:20:00	184
场地 3 - 站点 83 - 0600	2024/12/16	00:30:00	173
场地 3 - 站点 83 - 0600	2024/12/16	00:40:00	158
场地 3 - 站点 83 - 0600	2024/12/16	00:50:00	152
场地 3 - 站点 83 - 0600	2024/12/16	01:00:00	141
场地 3 - 站点 83 - 0600	2024/12/16	01:10:00	160
场地 3 - 站点 83 - 0600	2024/12/16	01:20:00	171
场地 3 - 站点 83 - 0600	2024/12/16	01:30:00	160
场地 3 - 站点 83 - 0600	2024/12/16	01:40:00	147
场地 3 - 站点 83 - 0600	2024/12/16	01:50:00	141
场地 3 - 站点 83 - 0600	2024/12/16	02:00:00	125
场地 3 - 站点 83 - 0600	2024/12/16	02:10:00	142
场地 3 - 站点 83 - 0600	2024/12/16	02:20:00	152
场地 3 - 站点 83 - 0600	2024/12/16	02:30:00	142
场地 3 - 站点 83 - 0600	2024/12/16	02:40:00	130
场地 3 - 站点 83 - 0600	2024/12/16	02:50:00	125
场地 3 - 站点 83 - 0600	2024/12/16	03:00:00	142
场地 3 - 站点 83 - 0600	2024/12/16	03:10:00	162
场地 3 - 站点 83 - 0600	2024/12/16	03:20:00	173
场地 3 - 站点 83 - 0600	2024/12/16	03:30:00	162
场地 3 - 站点 83 - 0600	2024/12/16	03:40:00	148

场地 3 - 站点 83 - 0600	2024/12/16	03:50:00	142
场地 3 - 站点 83 - 0600	2024/12/16	04:00:00	118
场地 3 - 站点 83 - 0600	2024/12/16	04:10:00	135
场地 3 - 站点 83 - 0600	2024/12/16	04:20:00	144
场地 3 - 站点 83 - 0600	2024/12/16	04:30:00	135
场地 3 - 站点 83 - 0600	2024/12/16	04:40:00	123
场地 3 - 站点 83 - 0600	2024/12/16	04:50:00	118
场地 3 - 站点 83 - 0600	2024/12/16	05:00:00	179
场地 3 - 站点 83 - 0600	2024/12/16	05:10:00	204
场地 3 - 站点 83 - 0600	2024/12/16	05:20:00	218
场地 3 - 站点 83 - 0600	2024/12/16	05:30:00	204
场地 3 - 站点 83 - 0600	2024/12/16	05:40:00	187
场地 3 - 站点 83 - 0600	2024/12/16	05:50:00	179

表 7 场地 3-站点 83 - 1400 线路 10 分钟颗粒度货量预测结果

线路编码	日期	分钟起始	包裹量
场地 3 - 站点 83 - 1400	2024/12/16	11:00:00	96
场地 3 - 站点 83 - 1400	2024/12/16	11:10:00	193
场地 3 - 站点 83 - 1400	2024/12/16	11:20:00	150
场地 3 - 站点 83 - 1400	2024/12/16	11:30:00	197
场地 3 - 站点 83 - 1400	2024/12/16	11:40:00	313
场地 3 - 站点 83 - 1400	2024/12/16	11:50:00	148
场地 3 - 站点 83 - 1400	2024/12/16	12:00:00	129
场地 3 - 站点 83 - 1400	2024/12/16	12:10:00	258
场地 3 - 站点 83 - 1400	2024/12/16	12:20:00	201
场地 3 - 站点 83 - 1400	2024/12/16	12:30:00	263
场地 3 - 站点 83 - 1400	2024/12/16	12:40:00	418
场地 3 - 站点 83 - 1400	2024/12/16	12:50:00	198
场地 3 - 站点 83 - 1400	2024/12/16	13:00:00	13
场地 3 - 站点 83 - 1400	2024/12/16	13:10:00	26
场地 3 - 站点 83 - 1400	2024/12/16	13:20:00	20
场地 3 - 站点 83 - 1400	2024/12/16	13:30:00	26
场地 3 - 站点 83 - 1400	2024/12/16	13:40:00	42
场地 3 - 站点 83 - 1400	2024/12/16	13:50:00	20

5.2 问题二模型建立与求解

5.2.1 多目标规划模型的建立

问题 2 的核心任务是根据问题 1 的货量预测结果，制定最优的运输调度方案。该方案需要明确每条线路的三个关键决策变量：发运车辆数量、精确的发运

时间安排以及最优的线路串点组合。在优化过程中，建立多目标规划模型，旨在同时实现最大化自有车辆周转率，提升资源利用效率；最大化车辆平均装载量，优化运输效益；以及最小化总运营成本，包括自有和外部运输成本。这三个目标之间存在一定的权衡关系，通过多目标优化方法，我们寻求在各项指标之间取得最佳平衡的调度方案，确保每个目标都能在可行范围内达到最优状态。

1) 优化目标的确定：

①最大化自有车周转率

自有车周转率作为衡量车队运营效率的核心，反映了企业自有运输资源的利用效能。该指标的计算公式为自有车承运总需求数与车队自有车辆数的比值，其优化价值主要体现在：通过提升单车在单位时间内的运输任务承载量，不仅能够充分发挥现有自有运力的潜在价值，更能有效减少对外部承运商的依赖，从而在保证运输时效性的同时，显著降低因调用外部车辆而产生的高额运输成本，实现降本增效的双重目标。自有车周转率可以表示为：

$$R_t = \frac{\sum_{i=1}^n N_i(t)}{V_u} \quad (9)$$

其中， $N_i(t)$ 是线路*i*在时间段*t*的发运车辆数； V_u 是车队自有的车辆数。目标是最大化 R_t ，所以有：

$$\max R_t = \max \left(\frac{\sum_{i=1}^n N_i(t)}{V_u} \right) \quad (10)$$

#(10)越高意味着自有车辆资源得到利用率越大，单位时间内可完成更多运输任务，并且显著降低对外部承运商的依赖程度，从而有效控制运输成本，实现运输系统整体资源的最优配置，避免运力闲置和资源浪费。这一指标的优化对于构建高效、经济的现代物流运输体系具有关键作用。

②最大化车辆均包裹数

车辆均包裹数是评估运输装载效率的核心指标，反映了单车运载能力的利用水平。通过提升单次运输的装载密度，不仅能够充分发挥每辆车的运输潜能，更能有效减少整体车辆需求数量，从而在保证运输服务质量的前提下，显著提高运输系统的整体运作效率，实现资源集约化利用。

车辆均包裹数可表示为：

$$C_{avg} = \frac{\sum_{i=1}^n \hat{Q}_i(t)}{N} \quad (11)$$

其中： $\hat{Q}_i(t)$ 是线路*i*在时间段*t*的预测货量；N是车队的总车辆数（包括自有车和外部承运商的车辆）。

目标是最大化 C_{avg} ，即：

$$\max C_{avg} = \max \left(\frac{\sum_{i=1}^n \hat{Q}_i(t)}{N} \right) \quad (12)$$

车辆均包裹数是衡量运输效率的关键绩效指标，其数值提升直接反映了载运能力的优化水平。较高的均包裹数表明车辆装载率接近满载状态，有效减少了空载或半载运输的情况，在保证服务质量的前提下，这种装载优化能够同步实现运输效率提升和节约运营成本的双重效益，为物流企业创造更大的价值空间。

③最小化总成本

总成本优化是运输调度决策的核心目标，由自有车辆的固定成本、变动成本和外部承运商的运输成本组成。通过系统性地最小化这三项成本的总和，能够在保证运输服务质量的前提下，有效控制物流系统的整体运营支出，实现经济效益的最大化。这一成本最小化目标与车辆周转率、装载效率等运营指标相互协同，共同构成了运输调度优化的完整指标体系。

总成本可以表示为：

$$S = S_1 + S_2 + S_3 \quad (13)$$

其中： S_1 是自有车辆的固定成本，如车辆折旧、保养等； S_2 是自有车辆的变动成本，如油费、司机费用等； S_3 是使用外部承运商的成本。

目标是最小化总成本S，即：

$$\min S = \min(S_1 + S_2 + S_3) \quad (14)$$

成本优化^[4]是物流运输管理的核心目标，通过精细化调度提升自有车辆资源利用率，降低单位运输的固定成本和变动成本；科学规划运输方案减少对外部高价运力的依赖，从而显著压缩整体运输支出。这种双管齐下的成本控制策略，既能保持运输服务质量，又能实现运营效益的最大化，是构建高效物流体系的重要保障。

5.2.2 约束条件的确定

在多目标优化模型的构建过程中,约束条件的设置对保证方案可行性具有决定性作用。约束条件是构成方案可行的边界框架,确保优化结果既符合业务实际,并且满足各项运营要求。以下是问题 2 中的主要约束条件:

1) 发运时间约束

每个运输需求的发运时间必须满足不晚于线路的最晚发运时间的要求。设线路*i*的最晚发运时间为 $\max(T_i)$,则每条线路的发运时间 T_i 发运必须满足以下条件:

$$T_i \leq \max(T_i), i \text{ 为线路} \quad (15)$$

发运时间约束是运输调度中的关键限制条件,要求所有线路的实际发运时间必须严格早于预设的最晚发运截止时间。一方面确保物流服务的时效性承诺得以兑现,避免因延迟发运导致的客户体验下降;另一方面维持整个运输系统的计划性,保证后续作业流程能够按既定时间节点有序推进。通过严格执行这一时间窗口约束,能够有效维护企业的服务质量和运营可靠性。

2) 自有车辆调度衔接约束

自有车在完成某一需求后,必须有足够的时间返回并准备发运下一条需求。这一约束保证了自有车的高效周转。假设自有车 *k* 完成需求 $N_i(t)$ 后,其下一次任务 $N'_i(t)$ 应满足以下时间衔接条件:

$$t_{pre} + T_1 + 2T_2 + T_3 \leq t_{final} \quad (16)$$

其中: t_{pre} 是前一个需求的发运时间; T_1 是装车时间,假设为 45 分钟; T_2 是车辆在途时间,假设为 1 小时; T_3 是卸车时间,假设为 45 分钟。

为了最大化自有车的利用率,需要确保自有车在两次运输任务之间有足够的进行装车、行驶和卸车。若两次任务时间间隔过短,车辆将无法按时完成调度,从而影响周转效率。

3) 车辆容量约束

每辆车的载货量是固定的,不能超过车辆的最大承载量 *P*。因此,每条线路的车辆需求 $N_i(t)$ 必须满足以下条件:

$$\hat{Q}_i(t) \leq N_i(t) \cdot P \quad (17)$$

车辆容量约束是运输调度中的基础性限制条件,其核心要求是单次运输的货

量必须严格控制在车辆额定载重范围内。这一硬性约束既保障了运输安全，又为计算最优车辆配置提供了基准参数，是平衡运输效率与运营安全的关键设计。

4) 串点任务的线路限制

串点任务是指将多个线路的货物合并到一辆车上进行运输。根据题目要求，每个串点任务最多包含 3 条线路。因此，若要进行串点调度，必须满足以下条件：

$$|i_1, i_2, i_3| \quad (18)$$

串点运输策略通过合理合并多条线路的货物来提升车辆装载效率，但其合并规模需控制在合理范围内。为确保运输调度的可操作性和执行效率，每个串点任务严格限定最多包含 3 条线路，这一限制既能有效发挥资源整合的优势，又可避免因线路过度合并导致的运输路径复杂化、时效难以保障等运营风险，在提升资源利用率与维持运输可靠性之间取得最佳平衡。

结合上述目标和约束条件，问题二最终的多目标优化模型为：

$$obj: \begin{cases} \max R_i = \frac{\sum_{i=1}^N N_i(t)}{N_0} \\ \max C_{avg} = \frac{\sum_{i=1}^N \hat{C}_i(t)}{N} \\ \min S = S_1 + S_2 + S_3 \end{cases} \quad (19)$$

$$s.t. \begin{cases} t_i \leq \max(t_i) \\ t_{pre} + T_1 + 2T_1 + T_3 \leq t_{final} \\ \hat{Q}_i(t) \leq H_i(t) \cdot S \end{cases} \quad (20)$$

5.2.3 多目标规划模型的求解

贪心算法^[3]作为解决多目标优化问题的有效方法，其核心思想是通过局部最优选择的迭代来实现全局优化。在应用于运输调度问题时，该算法需要综合考虑周转率、装载量和成本等多个目标的协同优化，为此我们建立了基于加权评估的决策机制。通过查阅文献，为各目标分配了差异化的权重系数，这些权重既反映了不同目标的相对重要性，也考虑了它们之间的相互制约关系。在算法执行过程中，每个决策步骤都会根据预设的权重体系对候选方案进行多维度评估，选择能够最大程度实现加权总目标最优的调度方案，从而在保证计算效率的同时，获得整体较优的解决方案。这种加权贪心策略有效平衡了多个竞争性目标之间的矛盾，为复杂的运输调度问题提供了实用的求解途径。

基于问题一的货量预测数据，本文设计了一个四阶段的加权贪心算法求解框架：

- ① 通过预设的权重系数将多目标优化问题转化为加权单目标问题；
- ②从初始状态出发，在每次迭代中基于当前运输需求和资源状态，选择能使加权目标函数值最大化的局部调度方案；
- ② 动态更新剩余待分配的货量和可用车辆资源；
- ④当满足所有约束条件或目标函数无法继续优化时终止计算。

该算法通过这种“评估-选择-更新”的循环机制，在保证计算效率的同时，逐步构建出在周转率、装载量和成本等维度上达到较优平衡的全局调度方案。

基于货量预测结果，需精确计算各线路的运输需求参数，具体包括确定每条线路所需的发运车辆数量，规划符合时效要求的精确发运时间，以及设计合理的线路串点合并方案。

5.2.4 贪心算法求解结果

基于货量预测结果，需精确计算各线路的运输需求参数，具体包括确定每条线路所需的发运车辆数量，规划符合时效要求的精确发运时间，以及设计合理的线路串点合并方案。

在不同的运输时间里，发运密度会呈现不同，具体分布如下：




图 7 运输需求发运时间密度分布

由上图可知高峰时段中,12 月 15 日 06:00 运输需求频率最高,接近 0.1,发运需求最为集中;12 月 15 日 12:00 发运需求频率也较高,接近 0.08;12 月 16 日 00:00 发运需求频率同样较高,接近 0.05。低谷时段里,12 月 15 日 00:00 运输需求频率最低,接近 0.01;12 月 15 日 18:00 发运需求频率也较低,接近 0.02。各线路运输需求次数分布如下:




图 8 各线路运输需求次数分布

图中显示了运输需求在不同线路之间的分布不均衡,部分线路的需求次数显著高于其他线路,存在需求不平衡情况。了解各线路的运输需求次数分布,有助于优化运输计划,确保高需求线路得到足够的资源支持,同时避免在低需求线路上浪费资源。

针对问题 2, 选用贪心算法^[5]开展多目标优化, 进而获取帕累托前沿。筛选出多目标函数的理想解。运输需求见结果表 3 中,“场地 3-站点 83 - 0600”和“场地 3-站点 83 - 1400”的调度结果, 如下表所示:

表 8 场地 3-站点 83 - 0600 调度结果

日期	开运时间	车队与数量
2024/12/15	22:40:00	车队 3, 车 3

2024/12/15	23:40:00	车队 3, 车 16
2024/12/16	00:10:00	车队 3, 车 22
2024/12/16	00:20:00	车队 3, 车 2
2024/12/16	00:29:59	车队 3, 车 20
2024/12/16	00:40:00	车队 3, 车 1
2024/12/16	01:00:00	车队 3, 车 32
2024/12/16	01:19:59	车队 3, 车 31
2024/12/16	01:30:00	车队 3, 车 29
2024/12/16	02:00:00	车队 3, 车 13
2024/12/16	02:10:00	车队 3, 车 30
2024/12/16	03:00:00	车队 3, 车 18
2024/12/16	03:09:59	车队 3, 车 28
2024/12/16	03:20:00	车队 3, 车 34
2024/12/16	03:40:00	车队 3, 车 10
2024/12/16	03:49:59	车队 3, 车 12
2024/12/16	04:00:00	车队 3, 车 36
2024/12/16	04:09:59	车队 3, 车 19
2024/12/16	04:20:00	车队 3, 车 8
2024/12/16	04:30:00	车队 3, 车 9
2024/12/16	04:39:59	车队 3, 车 24
2024/12/16	04:50:00	车队 3, 车 17
2024/12/16	04:59:59	车队 3, 车 7
2024/12/16	05:10:00	车队 3, 车 14
2024/12/16	05:19:59	车队 3, 车 33
2024/12/16	05:30:00	车队 3, 车 4
2024/12/16	05:39:59	车队 3, 车 23
2024/12/16	05:50:00	车队 3, 车 11

表 9 场地 3-站点 83 - 1400 调度结果

日期	开运时间	车队与数量
2024/12/16	11:00:00	车队 3, 车 25
2024/12/16	11:10:00	车队 3, 车 28
2024/12/16	11:19:59	车队 3, 车 6
2024/12/16	11:30:00	车队 3, 车 22
2024/12/16	11:40:00	车队 3, 车 9
2024/12/16	11:49:59	车队 3, 车 33
2024/12/16	12:00:00	车队 3, 车 14
2024/12/16	12:19:59	车队 3, 车 15
2024/12/16	12:30:00	车队 3, 车 18
2024/12/16	12:40:00	车队 3, 车 31
2024/12/16	13:10:00	车队 3, 车 23
2024/12/16	13:19:59	车队 3, 车 3

2024/12/16	13:30:00	车队 3, 车 13
2024/12/16	13:40:00	车队 3, 车 4
2024/12/16	13:49:59	车队 3, 车 26

5.3 问题三的模型建立与求解

5.3.1 考虑标准容器的使用下的多目标规划模型建立

问题三需要考虑标准容器对运输调度的影响与优化策略。标准容器能大幅提升装卸效率（时间从 45 分钟缩减至 10 分钟），但会降低单车装载容量（从 1000 件减至 800 件）。在此条件下，需重新规划运输需求并优化调度方案，核心目标为最大化自有车辆周转率和提高车辆平均装载量，以及最小化总运营成本。

由于标准容器的使用会同时产生效率提升与容量缩减的双重效应，因此在调度优化中必须建立动态决策机制，针对每条线路的货量特征和时效要求，需要综合考虑是否采用标准容器，并相应调整车辆配置和发运计划，从而在装卸效率与装载能力之间取得最优平衡，实现整体运输效益的最大化。

1) 优化目标的确定

① 最大化自有车周转率

目标是提高自有车辆的周转率，即让自有车辆更高效地完成运输任务，减少对外部承运商的依赖，优化资源的使用。数学表达式为：

$$\max Z_1 = \frac{N_x}{N_y} \quad (21)$$

其中， N_x 是自有车辆承运的总需求数； N_y 是车队的自有车辆数。

自有车周转率的提升直接反映了运输资源的高效利用，通过优化车辆调度安排和任务衔接时序，使单车在单位时间内能够承担更多运输任务，这不仅显著提高了自有车队的运营效率，同时有效降低了对外部高价承运商的依赖，从而实现运输成本的整体优化。

② 最大化车辆均包裹量

目标是提高每辆车的平均承载包裹量。较高的车辆均包裹量意味着运输过程中的车辆利用更为高效，减少了空驶情况，进一步优化了成本。表达式为：

$$\max Z_2 = \frac{Q_a}{N_a} \quad (22)$$

其中, Q_a 是车队承运的总包裹量; N_a 是车队使用的总车辆数, 包括自有车辆和外部承运商车辆。

提升车辆均包裹量能够显著优化运输系统的整体效率, 通过最大化单次运输的装载密度, 不仅有效减少了完成同等货运量所需的车辆总数, 还直接降低了单位运输成本, 从而实现资源利用率和经济效益的双重提升。

③最小化总成本

目标是尽可能降低运输过程中的总成本。总成本包括自有车的固定成本和变动成本, 以及外部承运商的成本。标准容器的引入可能会影响车辆的装载量, 但通过减少装卸时间, 可能带来其他方面的成本节省。表达式为:

$$\max Z_s = S_f + S_v + S_e \quad (23)$$

其中, S_f 是自有车辆的固定成本; S_v 是自有车辆的变动成本; S_e 是外部承运商的成本。

总成本优化通过科学配置自有车辆与外部承运资源, 并评估标准容器带来的效率与容量权衡, 在确保运输服务质量的前提下实现运营支出的精准控制, 从而达成成本效益的最佳平衡。

5.3.2 约束条件的确定

与问题二相比, 问题三的约束条件有了一些变化, 主要是与标准容器的使用相关:

①车辆容量限制

每辆车的最大承载能力降低到 800 个包裹, 且车辆的使用和装载量必须符合这一限制。数学表达式:

$$G_{i,t} \leq V_{i,t} \cdot P^{max} \quad (24)$$

其中, P^{max} 为标准容器下每辆车的最大承载能力 (800 个包裹); $V_{i,t}$ 为第 i 条线路在时间 t 需要的车辆数, $G_{i,t}$ 为第 i 条线路在时间 t 的货量。

容量约束作为调度优化的关键限制条件, 由于标准容器将单车最大装载量从 1000 件降至 800 件, 必须重新计算各线路的运输需求并相应调整发运方案, 确保所有运输任务严格遵循新的承载上限, 既充分发挥容器的装卸效率优势, 又避免出现超载风险。

②装卸时间限制

使用标准容器时，装卸时间显著缩短至 10 分钟。装车和卸车的时间变更需要反映在调度约束中，以确保运输过程的高效性。因此有如下约束：

$$N_{load} = N_{unload} = 10 \quad (25)$$

标准容器通过将装卸作业时间从 45 分钟大幅压缩至 10 分钟，显著提升了车辆的任务转换速度，这种效率提升直接转化为更高的车辆周转频次和更少的资源闲置时间，从而全面增强了运输系统的整体运作效能。

③车辆周转时间限制

如同问题二，车辆的周转时间必须满足前后运输任务的衔接条件，但由于标准容器的引入，装卸时间大大减少，周转时间可以更加紧凑。具体约束如下：

$$Y_{pre} + Y_{load} + 2 \cdot Y_{trip} + Y_{unload} \leq Y_{next} \quad (26)$$

车辆周转时间限制约束通过精确计算车辆装卸、行驶和停歇等环节的耗时，确保相邻运输任务之间保持合理的时间间隔，从而使自有车辆能够在完成当前任务后及时投入下一轮运输，实现运输资源的高效循环利用。

④是否使用标准容器的决策

每个运输需求可以选择是否使用标准容器。使用标准容器的需求将受到 800 个包裹的承载限制，并且装卸时间为 10 分钟；如果不使用标准容器，则每辆车的承载能力为 1000 个包裹，装卸时间为 45 分钟。具体约束如下：

$$z_{i,t} \in \{0,1\} \quad (27)$$

如果 $z_{i,t}=1$ ，表示第 i 条线路在时间 t 使用标准容器；如果 $z_{i,t}=0$ ，表示不使用标准容器。该决策变量 $z_{i,t}$ 用来表示是否使用标准容器，从而影响车辆的装载量和装卸时间。根据容器的使用与否，调度方案需要做相应调整，以确保资源的最大利用。

结合上述目标和约束条件，问题三最终的多目标优化模型为：

$$obj: \begin{cases} \max Z_1 = \frac{N_s}{M_p} \\ \max Z_2 = \frac{Q_a}{N_a} \\ \min Z_3 = S_f + S_v + S_e \end{cases} \quad (28)$$

$$s. t. \begin{cases} G_{i,t} \leq V_{i,t} \cdot P_{max} \\ T_{load} = T_{unload} = 10 \\ T_{pre} + T_{load} + 2 \cdot T_{trip} + T_{unload} \leq T_{next} \end{cases} \quad z_{i,t} \in \{0,1\} \quad (29)$$

5.3.3 贪心算法求解结果

同样使用贪心算法求解出运输需求发运时间密度分布情况：




图 9 运输需求发运时间密度分布

从图 9 中可清晰看出运输需求在一天不同时段分布状况。高峰时段里，12 月 15 日 06:00 运输需求频率最高，接近 0.09，发运需求最为集中；12 月 15 日 12:00 发运需求频率也颇高，接近 0.1，同样是需求高峰时段。低谷时段中，12 月 15 日 00:00 运输需求频率最低，接近 0.01，发运需求寥寥；12 月 15 日 18:00 发运需求频率也较低，接近 0.02。总体而言，需求在早晨 06:00 和中午 12:00 较为集中，而在凌晨 00:00 和傍晚 18:00 较低。各线路的运输需求次数分布为：




图 10 各线路的运输需求次数分布

由图 10 可知，有几条线路的运输需求次数特别高，例如编号为 100 的线路，需求次数接近 8 次，属于高频线路。大多数线路的运输需求次数在 1 到 3 次之间，显示出较为均匀的分布，低频线路。部分线路（如 80、100、140）的需求次数显著高于其他线路，可能表明这些线路的运输需求更为集中，运输需求在不同线路之间的分布不均衡。

总体来看，由于加入了标准容器的选择后，供给侧资源更丰富其优化，使得调度结果更灵活，提升了运输的工作效率和降低成本，实现了降本增效：

下面是成本对比：

表 10 是否加入标准容器优化结果对比

调度方案	成本函数最小	自有车周转率最高	均包裹量最大
普通容器	361880	44.9%	4483
可选标准容器	361110	45.1%	4505

针对问题 3，选用贪心算法开展多目标优化，进而获取帕累托前沿。筛选出多目标函数的理想解。运输需求见结果表 4 中，“场地 3-站点 83 - 0600”和“场地 3-站点 83 - 1400”的调度结果，如下表所示：

表 11 场地 3-站点 83 - 0600 调度结果

日期	开运时间	车队与数量	是否用标准容器
2024/12/15	21:19:59	车队 3, 车 1	1
2024/12/15	22:10:00	车队 3, 车 17	1
2024/12/15	22:30:00	车队 3, 车 24	0
2024/12/15	22:40:00	车队 3, 车 6	1
2024/12/15	22:49:59	车队 3, 车 14	15
2024/12/15	23:10:00	车队 3, 车 36	1
2024/12/15	23:40:00	车队 3, 车 22	1
2024/12/16	00:20:00	车队 3, 车 35	0
2024/12/16	01:19:59	车队 3, 车 33	1
2024/12/16	01:30:00	车队 3, 车 5	1
2024/12/16	02:10:00	车队 3, 车 32	0
2024/12/16	02:19:59	车队 3, 车 27	0
2024/12/16	02:30:00	车队 3, 车 20	0
2024/12/16	02:39:59	车队 3, 车 9	1
2024/12/16	02:50:00	车队 3, 车 23	0
2024/12/16	03:09:59	车队 3, 车 28	0
2024/12/16	03:20:00	车队 3, 车 12	0
2024/12/16	03:29:59	车队 3, 车 4	0
2024/12/16	04:00:00	车队 3, 车 2	0
2024/12/16	04:09:59	车队 3, 车 34	1
2024/12/16	04:20:00	车队 3, 车 8	0
2024/12/16	04:30:00	车队 3, 车 25	0
2024/12/16	04:50:00	车队 3, 车 14	1
2024/12/16	04:59:59	车队 3, 车 29	1
2024/12/16	05:10:00	车队 3, 车 15	1
2024/12/16	05:19:59	车队 3, 车 16	0
2024/12/16	05:30:00	车队 3, 车 18	0
2024/12/16	05:39:59	车队 3, 车 31	0
2024/12/16	05:50:00	车队 3, 车 3	1

表 12 场地 3-站点 83 - 1400 调度结果

日期	开运时间	车队与数量	是否用标准容器
2024/12/16	11:00:00	车队 3, 车 5	0
2024/12/16	11:10:00	车队 3, 车 24	1
2024/12/16	11:19:59	车队 3, 车 18	0
2024/12/16	11:40:00	车队 3, 车 32	1
2024/12/16	11:49:59	车队 3, 车 34	0
2024/12/16	12:00:00	车队 3, 车 4	0
2024/12/16	12:10:00	车队 3, 车 20	1
2024/12/16	12:19:59	车队 3, 车 15	0
2024/12/16	12:40:00	车队 3, 车 11	1

2024/12/16	12:49:59	车队 3, 车 6	0
2024/12/16	13:00:00	车队 3, 车 13	1
2024/12/16	13:19:59	车队 3, 车 25	1
2024/12/16	13:30:00	车队 3, 车 2	1
2024/12/16	13:40:00	车队 3, 车 21	1
2024/12/16	13:49:59	车队 3, 车 16	0

5.4 问题四的模型建立与求解

问题四重点研究货量预测偏差对调度系统的敏感性影响,通过量化分析预测误差^[6]对车辆调度方案、装载效率及运力配置等关键指标的影响程度,揭示预测精度与调度稳定性之间的内在关系,为实际运营中的风险管控提供决策依据。

5.4.1 评估货量预测结果偏差对调度模型优化结果的影响

1) 货量预测误差的计算

在短途运输调度问题中,货量预测是调度模型的基础。若预测的货量与实际货量存在偏差,将直接影响车辆调度的结果。假设在时间 t ,第 i 条线路的实际货量与预测货量不符,则偏差可以通过相对误差来衡量,表达式如下:

$$E_{i,t} = \frac{|y_{i,t} - \hat{y}_{i,t}|}{y_{i,t}} \quad (30)$$

$\varepsilon_{i,t}$ 代表第 i 条线路在时间 t 的预测误差比例,衡量预测值与实际值之间的相对差异。

预测误差对调度系统的影响主要体现在资源配置的失准,当误差超出合理范围时,将导致车辆配置过剩造成运力资源闲置浪费,或车辆不足引发运输任务延误,这两种情况都会显著降低运输系统的整体运营效率。

2) 车辆调度的影响

如果预测货量偏差较大,可能会影响车辆的调度安排,导致车辆未能按时装载或导致过多的空车运行。假设在预测时,预测货量为 $\hat{y}_{i,t}$,而根据实际货量 $y_{i,t}$ 需要调度的车辆数为 $V_{i,t}$,则实际需要的车辆数与预测的车辆数之间的差异可以表示为:

$$\Delta V_{i,t} = V_{i,t} - \hat{V}_{i,t} \quad (31)$$

其中，车辆数的计算由以下公式给出：

$$V_{i,t} = \left\lceil \frac{y_{i,t}}{P_{max}} \right\rceil \quad (32)$$

$\Delta V_{i,t}$ 表示预测误差引起的车辆调度差异。若 $\Delta V_{i,t}$ 为正，表示预测不足，需要增加车辆；若为负，表示预测过多，可能会造成空车调度。 P_{max} 是每辆车的最大载重（例如 1000 个包裹），调度时依据预测货量来确定车辆数量。

3) 调度效率与成本的影响

货量预测误差不仅影响车辆调度，还可能导致自有车辆周转率和车辆均包裹的变化，进一步影响运输成本。自有车周转率定义为自有车承运总需求数与自有车总数的比值：

$$K = \frac{\sum_{i=1}^n V_{i,t}}{N} \quad (33)$$

而车辆均包裹数为每辆车平均运输的包裹量，定义为：

$$L = \frac{\sum_{i=1}^n y_{i,t}}{\sum_{i=1}^n V_{i,t}} \quad (34)$$

货量预测误差将直接影响两个关键运营指标，一方面会降低自有车辆周转率，造成车队资源闲置和利用不足，另一方面会导致车辆装载率下降，使得均包裹数减少，进而增加单位运输成本，这种双重效应对运输系统的经济效益产生显著的负面影响。

4) 成本的影响

运输总成本由自有车辆固定成本、变动成本及外部承运成本三部分构成，其中自有车辆成本效益直接取决于周转率和装载效率两大关键指标。当货量预测出现显著偏差时，往往导致自有车辆运力不足而被迫增加高成本的外部承运车辆，从而推升整体运输支出，形成预测精度与成本控制之间的正相关关系。

总成本可以表示为：

$$S = S_f + S_v + S_c \quad (35)$$

运输成本结构包含自有车辆的固定日成本与运输量及装卸时间正相关的变动成本，以及由外部承运车辆数量决定的外部成本。当预测误差增大时，往往需要调用更多高单价的外部车辆来弥补自有运力缺口，这种替代效应会显著增加总运输费用，特别是在自有车辆资源紧张的情况下，外部承运成本的大幅上升将直

接导致整体运输支出的急剧增长。

综合上述情况，最终的总目标函数为：

$$Z = \alpha \cdot \sum_{i=1}^n \Delta V_{i,t}^2 + \beta \cdot T + \gamma \cdot P + \delta \cdot S \quad (36)$$

5.4.2 蒙特卡洛随机模拟

当问题一的货量预测结果出现偏差时，将权重系数作为扰动因子，识别预测偏差所带来的敏感性，得到如下结论：

① 成本敏感性

当 $\varepsilon > 0$ 时，预测过高，车辆调度过剩，导致平均包裹数下降，成本上升。

当 $\varepsilon < 0$ 时，预测过低，需调用外部车辆，显著增加成本（外部成本较高）。

② 调度差异

误差绝对值 $|\varepsilon|$ 越大， ΔV 越大，表明调度效率越低。

③ 优化建议

控制预测误差在 $\pm 10\%$ 内，可避免成本的急剧上升。

采用蒙特卡洛模拟对预测结果进行分布采样，计算模型的偏差情况，如图




图 11 基于蒙特卡洛算法对预测误差对模型扰动的模拟

由题意可知,为评估问题 1 货量预测结果产生偏差时,对问题 3 调度模型优化结果的影响,采用蒙特卡洛方法模拟随机变量,设定 1%、5%、10%的扰动幅度。

蒙特卡洛方法是基于概率统计理论的随机数值计算方法,通过模拟随机抽样求解传统数学方法难以直接处理的问题,具有原理简明、应用灵活的特性,且具备良好的可扩展性,在应对不同规模问题时,其计算效率和性能不会随问题规模扩大而显著降低。

(1) 设 X 是在区间 $[a, b]$ 上服从均匀分布的随机变量,其概率密度函数为

$$p(x) = \frac{1}{b-a}, a \leq x \leq b \quad (37)$$

(2) 定积分可以表示为:

$$\int_a^b f(x)dx = (b-a)E[f(x)] \quad (38)$$

式中: $E[f(x)]$ 是 $f(x)$ 的数学期望

(3) 当进行 N 次独立抽样,得到样本 $\cdots, x$ 时,定积分的近似值为:

$$\int_a^b f(x)dx = (b-a) \frac{1}{N} \sum_{i=1}^N f(x_i) \quad (39)$$

即通过在 $[a, b]$ 区间上随机生成大量的点 x_i , 计算 $f(x_i)$ 的值并求平均,再乘以区间长度 $(b-a)$, 就可以得到定积分的近似值。

如图 12 是使用蒙特卡洛法模拟扰动量分别为 1%, 5%, 10% 的需求量预测结果。即通过在区间 $[a, b]$ 上随机生成大量的点 x_i , 计算 $f(x_i)$ 的值并求平均,再乘以区间长度 $(b-a)$, 就可以得到定积分的近似值。随着抽样次数 N 的增加,近似值会越来越接近真实值。




图 12 蒙特卡洛法模拟扰动量分别为 1%，5%，10%的需求量预测结果

5.4.3 不同扰动下优化结果分析

对于问题 3 中的三个目标函数，代入不同扰动下需求量的优化结果解集如下图所示：




图 13 不同扰动水平下三目标随帕累托前沿变化趋势图

从图 13 中我们可知：扰动越大，发现其解空间解的质量越不稳定，总体来说解空间更劣，那么对于这个扰动越大的优化调度方案中，可行性变差。

进一步对比不太扰动程度的对应的最佳解进一步观察，预测偏差对于优化调度结果的影响。

对不同扰动下的目标函数优化结果如下表所示：

表 13 不同扰动下目标函数优化结果

扰动幅度	成本函数最小	自有车周转率最高	均包裹量最大
1%	357662	44.46%	4493
5%	359563	48.23%	4502
10%	361156	45%	4513

由表 13 可知，随着扰动幅度从 1%递增至 10%，成本函数最小值呈阶梯式上升，依次为 357662、359563 和 361156，表明需求波动加剧会显著推高运输成本；自有车周转率在 5%扰动时达到峰值 48.23%，1%和 10%扰动时分别为 44.46%和 45%，显示适度扰动利于提升车辆使用效率，过度扰动则会削弱这一优势；均包裹量随扰动幅度增加稳步上涨，从 4493 逐步增至 4513，说明系统具备通过策略调整优化装载效率的能力。整体来看，需求扰动^[7]对各指标的影响存在差异，运营决策需权衡不同扰动幅度下成本、效率与装载量之间的关系，以实现综合效益最大化

六、模型的评价与优化

6.1 模型的优点

1. 基于梯度提升树的 XGBoost 算法构建货量预测模型，该算法凭借出色的预测精度和扩展能力，实现了对未来 24 小时各线路货量的高精度预测，特别是通过 10 分钟颗粒度的时段分布预测，为车辆资源的精细化调度提供了可靠的数据支撑，显著提升了运输系统的规划精度和运营效率。

2. 多目标优化模型通过协同优化自有车周转率、车辆均包裹量和总成本等关键绩效指标，在运输资源高效利用与运营成本控制之间建立了科学的平衡机制，实现了运输系统整体效益的最大化。

3. 贪心算法通过局部最优选择的迭代机制求解多目标规划问题,在每一步决策中基于加权评估体系选择当前最优方案,最终收敛于满足多目标平衡的较优全局解,在保证计算效率的同时实现运输调度的综合优化。

6.2 模型的缺点

1. 模型预测精度与调度效果直接受输入数据质量的制约,数据偏差或缺失将导致预测结果失真并影响后续调度方案的可靠性。

2. XGBoost 算法虽然具有卓越的预测性能,但由于其包含大量需要优化的超参数(如树深度、学习率等),使得模型训练过程相对复杂,需要通过系统的参数调优才能充分发挥其算法优势。

3. 贪心算法虽然具有计算效率高的优势,但其基于局部最优选择的特性在多目标优化场景中可能无法收敛至全局最优解,特别是在目标函数存在复杂非线性关系时,这种局限性更为明显。

6.3 模型的改进

在预测建模方面,可引入 ARIMA、LSTM 等多元时间序列算^[8]进行对比验证,以筛选最具适应性的预测模型;在优化求解方面,采用 NSGA-III 等多目标进化算法替代当前方法,能够更好地处理目标间的复杂权衡关系,从而获得更全面、更精确的最优解,提升决策方案的科学性和可靠性。

参考文献

- [1] 黄涛, 吴晓波. (2018). XGBoost 算法在货运量预测中的实证研究. 交通运输系统工程与信息, 8(4), 187-194.
- [2] 李强, 张伟. (2019). 基于 XGBoost 与时间粒度的物流货量预测研究. 计算机应用研究, 36(5), 1342-1346.
- [3] 陈明, 赵阳. (2019). 基于贪心算法的多约束物流车辆路径优化. 计算机集成制造系统, 25(6), 1523-1532.
- [4] 黄涛, 吴晓波. (2020). 多目标物流调度中的车辆利用率与成本平衡研究. 控制与决策, 35(8), 1987-1996.
- [5] 刘志强, 张红梅. (2015). 基于贪心算法的多目标物流配送路径优化. 计算机应用研究, 32(6), 1678-1681.
- [6] 王雪峰, 陈志强. (2019). 货运量预测误差分析与评价指标体系研究. 交通运输系统工程与信息, 19(3), 45-52.
- [7] 张伟华, 李志强. (2022). 考虑动态需求的城市物流配送中心车辆调度优化. 交通运输工程学报, 22(4), 187-198.
- [8] 刘振华, 吴晓明. (2020). 基于多方法融合的数学建模分析框架. 应用数学学报, 43(4), 678-692.

附录

使用软件名称: spsspro

由于源代码过长, 其代码放在支撑材料里

问题一源代码 1:

```
import pandas as pd
# 假设 df 数据已经定义
df["时间"] = pd.to_datetime(df["日期"].astype(str)+ " " + df["分钟起始"]
                             ).astype(str))
df = df.sort_values("时间")
grouped_df_day = df.groupby("日期")["包裹量"].sum().reset_index()
grouped_df_day.columns = ["天", "总包裹量"]
import matplotlib.pyplot as plt
import seaborn as sns
plt.rcParams['font.sans-serif']=['SimHei'] # 中文支持
plt.rcParams['axes.unicode_minus']=False
import warnings
warnings.filterwarnings('ignore')
plt.figure(figsize=(14, 6))
plt.plot(df["时间"], df["包裹量"], marker='o')
plt.title("货运量随时间变化图")
plt.xlabel("时间")
plt.ylabel("包裹量")
plt.grid(True)
plt.tight_layout()
plt.xticks(rotation=45)
plt.show()
from statsmodels.tsa.seasonal import seasonal_decompose
df_ts = df.set_index("时间").sort_index()
result = seasonal_decompose(df_ts["包裹量"], model='additive', period=6)
fig = result.plot()
fig.set_size_inches(14, 8)
plt.tight_layout()
plt.show()
def assign_time_unit(ts):
    hour = ts.hour
    if hour >= 21:
        return ts.date() + pd.Timedelta(days=1)
    elif hour < 6:
        return ts.date()
    else:
        return pd.NaT
```

```

df["时间单位日期"] = df["时间"].apply(assign_time_unit)
df = df.dropna(subset=["时间单位日期"])
df = df.sort_values("时间")
df["时间单位"] = df["时间单位日期"].astype("category").cat.codes + 1
def create_lag_features(data, lag=10):
    X, y = [], []
    for i in range(lag, len(data)):
        X.append(data[i - lag:i])
        y.append(data[i])
    return np.array(X), np.array(y)
values = grouped_df_hour["总包裹量"].values
lag = 10
X, y = create_lag_features(values, lag=lag)
X_train, X_test = X[:-9], X[-9:]
y_train, y_test = y[:-9], y[-9:]
from xgboost import XGBRegressor
from sklearn.metrics import r2_score, mean_absolute_percentage_error
# 构建 XGBoost 模型
model = XGBRegressor(n_estimators=200, learning_rate=0.1, random_state=42)
model.fit(X_train, y_train)
# 预测
y_train_pred = model.predict(X_train)
y_test_pred = model.predict(X_test)
# 评估
r2 = r2_score(y_test, y_test_pred)
mape = mean_absolute_percentage_error(y_test, y_test_pred)
# 绘图
plt.figure(figsize=(14, 5))
# 训练集对比图
plt.subplot(1, 2, 1)
plt.plot(y_train, label="真实值")
plt.plot(y_train_pred, label="预测值")
plt.title("训练集: 真实值 vs 预测值")
plt.legend()
# 测试集对比图
plt.subplot(1, 2, 2)
plt.plot(y_test, label="真实值")
plt.plot(y_test_pred, label="预测值")
plt.title("测试集: 真实值 vs 预测值")
plt.legend()
plt.tight_layout()
plt.show()
print(r2, mape)

```



```

import pandas as pd
# 构造数据字典
data = {
    "y_train": y_train,
    "y_train_pred": y_train_pred,
    "y_test": y_test,
    "y_test_pred": y_test_pred
}
# 创建 DataFrame, 注意测试集和训练集长度可能不同, 因此分开存储
df_train = pd.DataFrame({
    "y_train": y_train,
    "y_train_pred": y_train_pred
})
df_test = pd.DataFrame({
    "y_test": y_test,
    "y_test_pred": y_test_pred
})
# 保存到 Excel 文件
file_path = "data1.xlsx"
with pd.ExcelWriter(file_path) as writer:
    df_train.to_excel(writer, sheet_name="Train", index=False)
    df_test.to_excel(writer, sheet_name="Test", index=False)
# 重新构建滑动窗口特征
lag = 10
X_all, y_all = create_lag_features(values, lag=lag)
# 使用所有数据训练
model_full = XGBRegressor(n_estimators=100, learning_rate=0.1, random_state=42)
model_full.fit(X_all, y_all)
# 用最后一组窗口向后预测 8 位
last_window = values[-lag:].tolist()
predictions = []
for _ in range(8):
    next_pred = model_full.predict(np.array(last_window[-lag:]).reshape(1, -1))[0]
    predictions.append(next_pred)
    last_window.append(next_pred)
# 绘图对比原始最后真实值与预测值
plt.figure(figsize=(8, 4))
plt.plot(range(len(values)), values, label="历史真实值")
plt.plot(range(len(values), len(values) + 8), predictions, label="未来预测值",
marker='o')
plt.title("基于全部数据的未来 9 小时预测")
plt.xlabel("时间单位_小时")

```

```

plt.ylabel("包裹量")
plt.legend()
plt.tight_layout()
plt.show()
print(predictions)
# 构建 DataFrame 用于保存图表数据
historical_len = len(values)
future_len = 8
df_chart = pd.DataFrame({
    "时间": list(range(historical_len + future_len)),
    "包裹量": list(values) + [None] * future_len,
    "预测值": [None] * historical_len + predictions
})
# 保存到 Excel 文件
file_path_chart = "data3.xlsx"
df_chart.to_excel(file_path_chart, index=False)
print(sum(predictions))
import pandas as pd
from statsmodels.tsa.stattools import adfuller
hourly = (
    df
    .groupby("时间单位_小时")["包裹量"]
    .sum()
    .rename("hour_total")
)
# 2. 将子时段数据与 H_t 合并, 计算比例  $p_{t,i}$ 
df_prop = (
    df
    .merge(hourly, left_on="时间单位_小时", right_index=True)
)
df_prop["prop"] = df_prop["包裹量"] / df_prop["hour_total"]
# 3. 按子时段编号分组, 提取比例序列并做 ADF 检验
results = {}
for i in sorted(df_prop["时间单位_小时 2"].unique()):
    series_i = df_prop.loc[df_prop["时间单位_小时 2"] == i,
"prop"].reset_index(drop=True)
    # ADF 检验
    adf_res = adfuller(series_i, autolag="AIC")
    results[i] = {
        "adf_stat": adf_res[0],
        "p_value": adf_res[1],
        "used_lag": adf_res[2],
        "n_obs": adf_res[3],
    }

```

```

        "crit_values": adf_res[4],
    }
# 4. 输出检验结果
for i, r in results.items():
    print(f"子时段 {i}: ADF={r['adf_stat']:.4f}, p - value={r['p_value']:.4f}")
    print("  临界值:")
    for k, v in r["crit_values"].items():
        print(f"      {k}: {v:.4f}")
    print("-" * 40)
import numpy as np
# 1. 计算历史平均拆分比例
df_hist = df.copy()
df_hist["子时段编号"] = df_hist.groupby("时间单位_小时").cumcount() #
0, 1, ..., 5
df_hist['prop'] = df_prop['prop']
# 按子时段编号计算平均比例 (0 - 5)
mean_props = df_hist.groupby('子时段编号')['prop'].mean().sort_index()
# 2. 未来 1 天每小时预测包裹数
# 3. 按历史平均比例映射到 10 分钟粒度
allocated = []
for pred in predictions:
    # 每小时 6 个子时段, 按 mean_props 分配
    allocated.extend(pred * mean_props.values)
allocated = np.round(np.array(allocated)).astype(int)
print(allocated)
result1 = pd.read_excel('./结果表/结果表 1.xlsx')
mask = result1['线路编码'] == '场地 1 - 站点 1 - 0600'
result1.loc[mask, '包裹量'] = sum(allocated)
result1.to_excel('结果表 1.xlsx', index=None)
result2 = pd.read_excel('./结果表/结果表 2.xlsx')
mask = result2['线路编码'] == '场地 1 - 站点 1 - 0600'
result2.loc[mask, '包裹量'] = allocated
result2.to_excel('结果表 2.xlsx', index=None)

```