

队伍编号	MC2406982
题号	B

基于深度学习的甲骨文图像分割与文字识别模型

摘要

本文研究了甲骨文图像的自动分割与识别问题，采用了先进的计算机视觉技术和深度学习框架，以提高其分割与识别的准确率和效率。

针对问题一，本文建立了图像预处理模型。通过采用二值化、形态学去噪、滤波器去噪等方法，处理了干扰元素。首先，使用 Otsu 算法进行二值化，自动确定阈值以区分前景和背景，简化图像结构。接着，通过闭运算填补图像中的小洞和缝隙，同时消除小的噪声，并通过开运算去除小的突出物，进一步清理图像。随后，应用高斯滤波器平滑图像，减少高频噪声，同时保留边缘信息。最后，使用中值滤波器用于消除椒盐噪声，保护图像细节和边缘不被模糊。

针对问题二和问题三，本文建立了单字分割模型。基于 YOLOV5 模型进行了深入的研究和改进，实现了对甲骨文图像的准确分割。首先引入了 PP-LC 主干网络，通过减少参数和计算量，提升了模型在资源有限设备上的推理效率。此外，通过引入 SE 注意力机制和空间金字塔池化（GSPPF）模块，增强了模型对关键区域的显著性，提高了对不同尺寸和形状甲骨文字的适应性和鲁棒性。在颈部网络的改进中，引入了 CA 注意力机制，通过识别和加权重要的特征通道，减少了背景噪声和冗余信息的干扰，提高了分割的精确度和效率。同时，针对样本不平衡问题，采用了 Focal CIOU 损失函数，它结合了 Focal Loss 和 CIOU 的特点，通过为难以分类的正样本分配更高权重，提高了模型对甲骨文字的敏感性，平衡了正负样本的影响。通过一系列消融实验，验证了引入 PP-LC 主干网络、GSPPF 模块和 CA 注意力机制的有效性。

针对问题四，本文建立了文字识别模型。通过采用 CNN 和 MobileNetV2 两种不同的深度学习架构，实现了对甲骨文图像的精确识别。CNN 模型通过输入层、卷积层、池化层和全连接层的协同工作，有效地提取了图像的关键特征，并在训练集和验证集上分别达到了 0.963 和 0.898 的准确率。为了提高模型的性能，研究引入了 MobileNetV2 模型，该模型利用深度可分离卷积和倒残差结构，在减少计算量的同时，保持了高准确度。在训练过程中，Adam 优化器的使用进一步提升了模型的收敛速度和分类准确率，使得 MobileNetV2 在训练集上达到了完美的准确率，并在验证集上取得了 0.983 的高准确率。模型评估显示，MobileNetV2 的 AUC 值为 0.99，显著优于 CNN 模型的 0.94，证明了其在甲骨文图像识别任务中的优越性。为了进一步验证这一结论，经过成对 t 检验的统计学分析，MobileNetV2 模型在各项性能指标上均显著优于 CNN 模型。

关键词：形态学去噪; 滤波器去噪; 改进的 YOLOV5; 注意力机制; CNN; MobileNetV2

目录

一、问题重述	3
1.1 问题背景	3
1.2 目标任务	3
二、模型假设及符号说明	4
2.1 模型假设	4
2.2 主要的符号说明	4
三、问题分析	5
3.1 数据特征分析	5
3.2 模型选择分析	5
3.3 评估指标分析	5
3.4 问题整体分析	5
四、图像数据预处理	6
4.1 二值化	7
4.2 闭运算	8
4.3 开运算	8
4.4 高斯滤波器	8
4.5 中值滤波器	9
五、基于 YOLO 的自动单字分割模型	11
5.1 模型的建立	11
5.1.1 基本概念	11
5.1.2 输入端	12
5.1.3 Backbone 层	13
5.1.4 Neck 网络	15
5.1.5 输出端	16
5.2 模型的评估	17
5.2.1 交并比	17
5.2.2 查准率	18
5.2.3 查全率	18
5.2.4 平均准确率	18
5.2.5 平均准确率均值	18
5.3 模型的训练	18
5.3.1 数据集预处理	20
5.3.2 YOLOv5 模型训练	20
5.4 模型求解	21
六、自动单字分割模型的改进	22
6.1 YOLOv5 主干网络的改进	22

6.1.1	PP-LC 主干网络的引入	22
6.2	空间金字塔池化 GSPPF 的引入	23
6.3	YOLOv5 颈部网络的改进	24
6.3.1	CA 注意力机制的引入	24
6.3.2	损失函数的改进	25
6.3.3	改进后的网络模型架构	26
6.4	模块消融实验结果与分析	26
6.4.1	参数设置	26
6.4.2	引入 PP-LC 主干网络消融实验	27
6.4.3	引入空间金字塔池化消融实验	27
6.4.4	引入注意力机制消融实验	28
6.4.5	改进损失函数消融实验	28
七、	基于 CNN 的文字识别模型	29
7.1	模型的建立	29
7.1.1	输入层	29
7.1.2	卷积层	29
7.1.3	池化层	30
7.1.4	全连接层	31
7.2	模型的训练	32
7.3	模型的评估	34
八、	基于 MobileNet 的文字识别模型	37
8.1	模型的建立	37
8.1.1	深度可分离卷积	38
8.1.2	MobileNetV2	40
8.1.3	Adam 优化器	40
8.2	模型的训练	41
8.3	模型的评估	43
九、	测试集的图像识别预测	45
9.1	模型选择	45
9.2	预测结果	46
十、	模型的评价与推广	46
10.1	模型的优点	46
10.2	模型的缺点	46
10.3	模型的推广	46
	参考文献	47
	附录 1: 图像预处理模型代码	48
	附录 2: YOLOv5 模型代码	49
	附录 3: CNN 模型和 MobileNetV2 模型的代码	66

一、问题重述

1.1 问题背景

甲骨文，中国最古老的文字系统之一，因其在龟甲兽骨上的刻写而闻名，对研究中国及全球文明起源具有重要意义。在政府支持下，甲骨文研究进入新阶段，人工智能和大数据技术的应用推动了甲骨文数字化和信息处理的研究热潮。甲骨文拓片图像分割是数字化基础，目的是通过图像处理和计算机视觉技术，从复杂的背景中准确提取独立的文字区域，为文字修复、复原和识别提供技术基础。然而，分割工作面临点状噪声、人为和自然纹理等干扰因素的挑战，且不同来源的图像受干扰程度不一，增加了传统图像分割技术的难度。因此，开发能够准确识别并分割复杂背景中文字的技术，是甲骨文数字化工程的关键任务。

1.2 目标任务

（1）问题 1：图像预处理与干扰元素判别模型的建立

甲骨文拓片图像分割面临着点状噪声、人工纹理和固有纹理等干扰因素。为了解决这一问题，需要建立一个图像预处理模型，能够对甲骨文图像进行去噪、灰度化、二值化等预处理操作，提取图像特征，并进一步判别干扰元素。该模型的建立旨在减少干扰因素对图像分割的影响，为后续的图像分割模型提供干净的输入图像。

（2）问题 2：甲骨文图像分割模型的建立与评估

针对甲骨文拓片图像分割的复杂性，需要建立一个快速准确的图像分割模型，能够自动对不同的甲骨文原始拓片图像进行单字分割。这涉及选择合适的图像分割算法或深度学习模型，并进行模型训练和评估。在建立模型后，需要从不同的维度对其进行评估，如准确率、召回率、F1 值等，以验证其性能和有效性。

（3）问题 3：甲骨文图像分割模型的应用与结果输出

基于建立的甲骨文图像分割模型，需要对测试集中的 200 张甲骨文原始拓片图像进行自动单字分割。分割结果需要整理成 Excel 格式。这一步是将模型应用于实际数据并输出结果的过程，对模型的有效性进行验证。

（4）问题 4：甲骨文文字识别模型的建立与测试

基于前三问对甲骨文原始拓片图像的单字分割研究，需要采用合适的方法进行甲骨文原始拓片的文字识别。给定了部分已标注的甲骨文字形，需要利用这些数据或其他资料建立文字识别模型，并对测试集中的 50 张甲骨文原始拓片图像进行文字自动识别。最终需要将识别结果以适当的形式呈现，以验证模型的准确性和可靠性。

二、模型假设及符号说明

2.1 模型假设

(1) 图像预处理模型假设

- 假设甲骨文拓片图像中的干扰元素有一定的特征，如点状噪声、人工纹理和固有纹理等。
- 假设通过适当的图像预处理操作，如去噪、灰度化、二值化等，可以有效地减少干扰元素对图像分割的影响，提高图像的质量和清晰度
- 假设通过特征提取和判别方法，可以将文字区域与干扰元素进行有效区分，为后续的图像分割提供准备。

(2) 图像分割模型假设

- 假设甲骨文图像中的文字区域具有一定的形态特征，如连续性、紧密性等。
- 假设图像分割模型能够准确地识别并分割出文字区域，且能够处理不同来源和不同类型的甲骨文图像
- 假设所建立的图像分割模型具有一定的泛化能力, 即在未见过的数据集上也能产生较好的分割效果。

(3) 文字识别模型假设

- 假设甲骨文图像中的文字具有一定的形态和结构特征，如笔画组成、笔画顺序等。
- 假设建立的文字识别模型能够准确地识别甲骨文图像中的文字，并输出相应的文字序列
- 假设建立的文字识别模型能够处理不同字体、不同字形和不同大小的文字，并具有一定的鲁棒性和泛化能力

2.2 主要的符号说明

符号	符号说明
$I(x, y)$	图像
$I'(x, y)$	预处理后的图像
AP	平均准确率
IOU	交并比
P	查准率
R	召回率
TP	真正例
TN	真负例
FP	假正例
FN	假负例

三、问题分析

3.1 数据特征分析

本题数据集共包括四个文件夹。其中，1_*Pre_test* 文件夹中共包括 3 张甲骨文图像，需要对其进行图像去噪，建立甲骨文的图像预处理模型。2_*Train* 文件夹中共包括 6150 张甲骨文图像和对应的标注文件，需要对其进行分析，训练甲骨文原始拓片图像的自动单字分割模型。3_*Test* 文件夹中共包括 200 张未标注甲骨文图像，需要利用自动单字分割模型对其进行测试。4_*Recognize* 文件夹中包括甲骨文识别训练集和测试集，训练集中有 76 个常见甲骨文，测试集中有 50 张甲骨文原始拓片，需要利用自动单字分割模型对测试集中的甲骨文原始拓片进行单字分割，然后利用训练集中的数据训练出甲骨文原始拓片图像的文字识别模型，最后利用文字识别模型对测试集中的单字进行识别。

3.2 模型选择分析

对于图像预处理模型，这是一个图像去噪任务。通常，图像去噪由二值化、形态学去噪和滤波器去噪等步骤相结合完成，以恢复出清晰、高质量的图像。对于单字分割模型，这是一个图像分割任务。在众多图像分割算法中，YOLOv5 凭借其出色的性能和广泛的应用场景，逐渐受到了业界的关注和认可。对于文字识别模型，这是图像识别任务。卷积神经网络（CNN）在图像识别领域具有广泛的应用，能够自动提取图像中的局部特征，并具有很好的空间不变性。考虑到数据集数据量小的特点，轻量级神经网络 MobileNetv2 是一个合适的选择。MobileNetv2 在图像识别领域具有良好的表现，具有小规模、低延迟、低功耗的特点，能够解锁不同用例中的资源限制。在模型选择阶段，可以通过评估指标对比 CNN 与 MobileNetv2 的性能，并通过统计学方法进一步判断二者的性能差异，择优选择模型。

3.3 评估指标分析

对于图像分割和图像识别任务而言，通用的评价指标有准确率、精确率、召回率和 F1 值。准确率（Accuracy）是最常用的评估指标之一，它衡量了模型正确预测的样本在所有样本中的比例。为了解决类别不平衡问题，常采用精确率（Precision）和召回率（Recall）。为了协调精确率和召回率，常将二者的调和平均数 F1 值作为度量指标。对于目标检测任务而言，并交比（IOU）和平均准确率（AP）也是衡量模型性能的常用评价指标。对于图像识别任务而言，ROC - AUC 值也是衡量模型优劣的一种常用评价指标。

3.4 问题整体分析

首先，对所给图像集进行图片预处理，经二值化、形态学去噪和滤波器去噪后，再统一图片大小及像素。针对单字分割任务，使用 YOLOv5 模型，需先将标注文件格式转换为 YOLOv5 的标准格式，然后将训练集图像依次经输入端、主干网络、颈部网络、

头部网站、输出端，得到能够检测文字位置的 *YOLOv5* 模型。针对文字识别任务，引入 *CNN* 模型将图片转换为对应的二维矩阵，将原始拓片轮廓、纹理、形态等作为卷积核，卷积完后得到新的特征图。利用 *Padding* 和 *Relu* 激活函数更快速高效识别文字特征，运用池化层减小过拟合和降低维度，引入 *SGD* 做梯度处理获取最优解。之后为获取更高效更准确的结果，运用 *MobileNetv2* 模型中引入的倒置残差块，对图片转换后的二维矩阵进行卷积，输出得到图像特征。我们再运用 *Adam* 优化器对 *MobileNetv2* 模型进行训练，之后分别调用 *tensorflow* 对两个模型进行训练，选用准确率、查准率、召回率、*F1* 分数以及 *ROC - AUC* 值等指标对两个模型进行评估。最后对比 *CNN* 和 *MobileNetv2* 做 *t* 检验，选取更能够高效准确地适应与甲骨文图像检测的模型。下图为问题分析的流程图。




图 1 问题分析流程图

四、图像数据预处理

图像预处理是图像分析的基础，它通过一系列步骤来优化图像数据，以便于后续处理。首先，本文使用 *Otsu* 算法对图像进行二值化，自动确定阈值以区分前景和背景，简化图像结构。接着，通过闭运算填补图像中的小洞和缝隙，同时消除小的噪声，并通过开运算去除小的突出物，进一步清理图像。随后，应用高斯滤波器平滑图像，减少高频噪声，同时保留边缘信息。最后，使用中值滤波器用于消除椒盐噪声，保护图像细节和边缘不被模糊。




图 2 图像预处理流程图

4.1 二值化

图像二值化是图像处理中的一种基本技术，它通过将一幅具有多个灰度级的图像转换为仅包含两个灰度级的图像，从而简化图像的表达形式。为了避免手动设置阈值，本文选择用自适应确定图像二值化阈值 *Otsu* 算法。该方法通过最大化类间方差来确定最佳阈值，使得分割后的前景和背景之间的差异最大化。

首先，计算图像的灰度直方图，即统计每个灰度级像素的数量。设图像的灰度级为 L ，灰度直方图为 $h(k)$ ，表示灰度级为 k 的像素数量。对于一个给定的阈值 T ，将图像分为两部分：前景 ($k \leq T$) 和背景 ($k > T$)。

前景和背景的像素比例分别为：

$$\omega_1 = \sum_{k=0}^T h(k) \quad (1)$$

$$\omega_2 = \sum_{k=T+1}^{L-1} h(k) \quad (2)$$

前景和背景的灰度平均值分别为：

$$\mu_1 = \frac{\sum_{k=0}^T k \cdot h(k)}{\omega_1} \quad (3)$$

$$\mu_2 = \frac{\sum_{k=T+1}^{L-1} k \cdot h(k)}{\omega_2} \quad (4)$$

然后，根据直方图计算类间方差。类间方差是衡量两个类别（前景和背景）之间差异的指标。在 *Otsu* 方法中，类间方差定义为前景像素的灰度平均值与背景像素的灰度平均值之差的平方，乘以前景和背景像素的比例。类间方差为：

$$\sigma^2(T) = \omega_1 \omega_2 \left(\frac{\mu_1 - \mu_2}{\omega_1 + \omega_2} \right)^2 \quad (5)$$

最后，遍历所有可能的阈值，计算每个阈值对应的类间方差，并选择使类间方差最大化的阈值作为最佳阈值。最佳阈值 T 是使 $\sigma^2(T)$ 最大化的值：

$$T = \arg \max_{0 \leq T \leq L-1} \sigma^2(T) \quad (6)$$

4.2 闭运算

闭运算是图像处理中的一种基本形态学操作，它结合了膨胀和腐蚀操作。闭运算的主要目的是去除小的物体或细节（如噪声），同时保持较大物体的结构不变。闭运算通常用于图像预处理，特别是在二值图像分析中，它可以有效地填补小的空洞和缝隙，消除小的突出物。闭运算的操作可以分为两个步骤：首先是对图像进行膨胀操作，然后是对膨胀后的图像进行腐蚀操作。闭运算的符号表示为 $B(X, Y)$ ，其中 X 是原始图像， Y 是结构元素。膨胀操作是将图像中的前景像素按照结构元素的形状向外扩展。如果结构元素中的任何一个点是前景像素，那么对应的膨胀图像中的该点也将是前景像素。膨胀操作可以增大物体的面积，填补物体中的小洞，以及连接相邻的物体。腐蚀操作与膨胀相反，它是将图像中的前景像素向内收缩。结构元素依次覆盖在图像上，如果结构元素完全包含在前景像素中，则腐蚀图像中对应的点为前景像素。腐蚀操作可以去除小的突出物和噪声，同时保持较大物体的基本形状。闭运算的效果相当于先让物体“膨胀”以填补小洞和缝隙，然后再“收缩”以去除小的突出物和噪声。这个过程可以用下面的公式表示：

$$B(X, Y) = D(E(X, Y)) \quad (7)$$

其中， $D(.)$ 表示膨胀操作， $E(.)$ 表示腐蚀操作。

4.3 开运算

开运算是形态学操作中的一种基本操作，与闭运算相对应，它结合了腐蚀和膨胀操作，但是顺序与闭运算相反。开运算的主要目的是去除小的物体或细节（如噪声），同时保持较大物体的结构基本不变。开运算的效果相当于先让物体“收缩”以去除小的突出物和噪声，然后再“膨胀”以填补小洞和缝隙，但不会影响物体的面积。这个过程可以用下面的公式表示：

$$O(X, Y) = D(E(X, Y)) \quad (8)$$

其中， $D(.)$ 表示膨胀操作， $E(.)$ 表示腐蚀操作。

4.4 高斯滤波器

高斯滤波器是一种常用的图像平滑处理技术，用于去除图像中的高频噪声。它通过对图像进行加权平均来实现平滑效果，权重由高斯函数定义，这是一种钟形的概率分布函数。高斯滤波器在图像处理中被广泛应用，因为它能够有效地保留图像的边缘信息，同时减少噪声。高斯滤波器的工作原理是基于高斯分布的特性。在图像处理中，高斯滤波器使用一个高斯函数作为权重，对图像中的每个像素及其邻域像素进行加权平均。这

个加权平均的过程可以看作是一个卷积操作，其中高斯函数作为卷积核。高斯函数的公式为：

$$G(x, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}} \quad (9)$$

其中， x 是距离中心点的位置， σ 是高斯分布的标准差，决定了分布的宽度，即权重的快速下降速率。对于图像 $I(x, y)$ 上的每个像素点 $I(x, y)$ ，高斯滤波后的像素值 $I'(x, y)$ 可以通过以下公式计算：

$$I'(x, y) = \sum_{i=-\infty}^{+\infty} \sum_{j=-\infty}^{+\infty} I(i, j) \cdot G((i-x), (j-y), \sigma) \quad (10)$$

其中， $G((i-x), (j-y), \sigma)$ 是高斯函数， (i, j) 是图像上的点， (x, y) 是当前处理的中心点， σ 是高斯分布的标准差。

4.5 中值滤波器

中值滤波器是一种非线性的数字滤波器，主要用于去除图像中的噪声，尤其是椒盐噪声。与高斯滤波器等线性滤波器不同，中值滤波器在平滑图像的同时能够更好地保留图像的边缘和细节特征。中值滤波器的工作原理是对图像中的每个像素点，取其邻域内的像素值，然后计算这些像素值的中值，并用这个中值替换当前像素点的值。这里的“中值”是指将所有像素值排序后位于中间位置的值。中值滤波器的关键在于它不是基于像素值的平均或加权平均，而是基于排序统计量，因此它对极端值（噪声）不敏感，而对图像中的中间灰度值有更大的影响。这种特性使得中值滤波器在去除随机噪声的同时，能够保持图像的结构和边缘信息。对于图像 $I(x, y)$ 上的每个像素点 (x, y) ，中值滤波后的像素值 $I'(x, y)$ 可以通过以下步骤计算：

(1) 定义一个 $N \times N$ 的窗口（或称为核），其中 N 是奇数，以确保窗口有一个中心点。

(2) 将窗口移动到像素点 (x, y) 上，并包含该点及其 N^2 个邻域像素。

(3) 将这 N^2 个像素值进行排序。

(4) 选择排序后的中值作为新像素值 $I'(x, y)$ 。

数学上，如果 S 是窗口内像素值的集合，则中值滤波器可以表示为：

$$I'(x, y) = \text{median}(S) \quad (11)$$

其中， $S = \{I(i, j) \mid i \in [x - [(N-1)/2], x + [(N-1)/2]], j \in [y - [(N-1)/2], y + [(N-1)/2]]\}$

我们利用以上建立的甲骨文图像预处理模型对于附件一给定的三张甲骨文原始拓片图片进行操作，实现了对甲骨文图像干扰元素的初步判别和处理，处理过程如图所示：




图 3 h02060 的图像预处理




图 4 w01637 的图像预处理




图 5 w01870 的图像预处理

五、基于 YOLO 的自动单字分割模型

5.1 模型的建立




图 6 文字分割流程图

5.1.1 基本概念

YOLOv5 (You Only Look Once version 5) 是一个高效且强大的目标检测模型，它是 YOLO 系列的最新迭代之一。YOLOv5 在设计上旨在实现更快的速度和更高的准确性，同时保持模型的轻量化，使其适用于各种计算能力和资源受限的环境。其模型结构主要包括以下组成部分：

输入端：接收原始图像数据，并进行预处理以适应模型的输入要求。.. **Backbone 网络：**用于特征提取，从输入图像中提取有用的视觉信息。

Neck 网络：对 Backbone 网络提取的特征进行进一步的处理和融合，为检测头提供合适的特征表示。

输出端：根据 Neck 网络提供的特征表示，预测目标的类别和位置。




图 7 YOLOv5 架构图

5.1.2 输入端

YOLOv5 的输入端设计考虑了多种图像预处理和增强技术，以提高模型的泛化能力和检测性能。输入端主要由 Mosaic 图像增强、自适应锚框计算以及自适应图片缩放组成。

Mosaic 图像增强。 Mosaic 是一种数据增强技术，它将四张不同的图像拼接成一个大的图像，以此来增加模型训练时的多样性。通过 Mosaic 增强，模型可以在一个批次中看到多种不同的场景和对象，这有助于提高模型对不同环境和条件下目标的识别能力。Mosaic 增强可以增加模型对复杂背景和多样目标的鲁棒性，从而提高检测的准确性。




图 8 Mosaic 图像增强概念图

自适应锚框计算. 锚框是预定义的边界框, 用于为目标检测提供一个初始的位置和尺寸估计. YOLOv5 通过自适应锚框计算来调整锚框的大小和比例, 使其更好地匹配训练数据中的目标. 这种自适应机制使得模型能够更好地理解和适应不同目标的形状和尺寸, 从而提高目标检测的精度.

自适应图片缩放. 自适应图片缩放是指根据输入图像的内容和模型的要求, 动态调整图像的大小. 通过自适应图片缩放, 模型可以处理不同分辨率的输入图像, 同时保持特征提取的有效性. 这种缩放机制有助于模型在不同尺寸的图像上都能保持稳定的检测性能, 并且可以减少因固定尺寸输入限制而导致的信息损失.

这些输入端的处理技术共同作用, 使得 YOLOv5 在面对多样化的图像数据时能够更好地进行目标检测. Mosaic 图像增强提供了丰富的训练样本, 自适应锚框计算优化了模型对目标尺寸的预测, 自适应图片缩放则确保了模型对不同分辨率图像的适应性. 这些技术的结合显著提升了 YOLOv5 在实际应用中的性能和适用性.

5.1.3 Backbone 层

YOLOv5 的 Backbone 层是其特征提取的核心部分, 由 Focus 结构和 CSP (Cross Stage Partial) 结构组成, 这两种结构共同工作以提高模型的性能和效率.

Focus 结构. Focus 结构是 YOLOv5 中用于增强模型对图像中目标的感知能力的一种特殊结构. 它通过对输入图像进行切片和重组, 以更有效地捕捉目标的特征. Focus 结构首先将输入图像分成四个不同的部分, 并将这些部分分别进行卷积操作. 然后, 它将这些经过卷积的特征图重组, 以形成一个更大的特征图. 这种方法有助于模型在初始阶段就能够捕捉到目标的细节信息, 从而为后续的特征提取打下良好的基础.




图 9 Focus 结构概念图

CSP 结构. CSP 结构是一种改进的残差网络结构，它通过将特征图分割并在不同的阶段进行融合，以减少梯度消失和梯度爆炸的问题，提高模型的训练稳定性和效率。CSP 结构通过将输入特征图分成两部分，一部分直接传递到下一个阶段，另一部分则通过一系列卷积层进行处理。在下一个阶段，这两部分再次合并。这种设计使得模型能够在保持特征图的完整性的同时，增加网络的深度和复杂度，从而提高特征提取的能力和模型的表达能力。




图 10 残差结构概念图

Focus 结构和 CSP 结构的结合使得 YOLOv5 的 Backbone 层不仅能够有效地捕捉图像中的详细信息，还能够在保持计算效率的同时增加模型的深度。这种设计有助于提高模型对各种目标的检测精度，尤其是在处理小目标和模糊目标时。通过这种方式，YOLOv5 能够在保持实时检测能力的同时，实现高精度的目标检测。

5.1.4 Neck 网络

在 YOLOv5 中，Neck 层是负责进一步处理 Backbone 层提取的特征，并为输出层提供合适特征表示的关键部分。YOLOv5 采用了两种不同的 Neck 结构：SPP（Spatial Pyramid Pooling）和 PAN（Path Aggregation Network）。

SPP 结构。 SPP 结构通过在特征图上应用多尺度的空间金字塔池化操作，来整合不同区域和尺度的特征信息。SPP 层首先在特征图的每个位置上应用 1×1 的卷积核，以降低特征图的深度并提取局部特征。接着，它使用不同大小的池化区域（例如， 3×3 、 5×5 等）对特征图进行池化，生成多个不同尺度的特征图。这些特征图随后被上采样到相同的尺寸并合并，形成一个综合了多尺度信息的特征图。SPP 结构有助于模型捕捉目标的不同尺寸和形状，提高对小目标的检测能力。




图 11 卷积层操作概念图




图 12 池化层操作概念图

PAN 结构。 PAN 结构旨在通过在网络的不同层级之间进行特征融合，来增强模型对多尺度目标的检测能力。PAN 层通过设计特定的路径连接，将浅层的特征图（富含细节信息）与深层的特征图（富含语义信息）进行融合。这种融合策略有助于克服单一特征层的局限性，使得模型能够同时利用到细节和语义信息，从而提高对不同尺度目标的

检测性能。PAN 结构通常包括自下而上的特征传递路径和自上而下的特征传递路径，通过这种方式实现跨层级的特征整合。




图 13 PAN 结构概念图

在 YOLOv5 中，SPP 和 PAN 结构可以单独使用，也可以结合使用，以适应不同的检测需求和优化目标。通过合理设计 Neck 层，YOLOv5 能够有效地处理图像中的多尺度目标，提高目标检测的准确性和鲁棒性。

5.1.5 输出端

YOLOv5 的输出端不仅包括损失函数和 NMS（Non-Max Suppression）机制，还包括用于预测目标类别和边界框的位置的一系列卷积层。

损失函数。损失函数用于量化模型预测与真实标签之间的差异，是训练过程中优化模型的关键部分。在 YOLOv5 中，损失函数通常包括三部分：分类损失（用于评估预测类别与实际类别之间的差异）、定位损失（用于评估预测的边界框与真实边界框之间的差异）和置信度损失（用于评估目标存在的置信度）。通过最小化这个总体损失，模型在训练过程中会逐渐提高其预测的准确性。

NMS 机制。NMS 是一种后处理技术，用于在目标检测任务中消除重叠的检测框，保留最佳的检测结果。在目标检测过程中，同一个目标可能被模型多次检测，并且产生多个重叠的边界框。NMS 通过计算边界框之间的交并比（IoU）来识别这些重叠的框，并抑制那些较低置信度的框，最终只保留每个目标的最佳检测框。这样可以提高模型的检测精度和输出的整洁性。




图 14 IOU 构概念图

预测层. 预测层由一系列卷积层组成, 负责生成目标的类别预测和边界框位置. 这些卷积层通常包括多个输出通道, 每个通道分别用于预测不同类别的概率、边界框的偏移量以及目标存在的置信度. 通过这些预测, 模型可以为每个检测到的目标提供一个具体的类别标签和精确的边界框位置.

YOLOv5 的输出端通过损失函数来指导模型训练, 通过 NMS 机制来优化检测结果, 并通过预测层来输出目标的类别和位置信息. 这些组成部分共同确保了 YOLOv5 能够在目标检测任务中提供高质量的结果.

5.2 模型的评估

为了验证本文基于 YOLOv5 改进的轻量化网络的性能, 在深度学习目标检测中使用的评价指标主要包括交并比、准确率、查全率、平均准确率、平均准确率均值. 上述部分参数需要以模型预测类别和实际类别比较的形式来表达预测样本结果好坏, 其主要形式有以下几种.

- (1)TP(True Positive): 真正例, 模型预测为正, 实际也为正的样本数.
- (2)TN(True Negative): 真负例, 模型预测为负, 实际也为负的样本数.
- (3)FP(FalsePositive): 假正例, 模型预测为正, 实际为负的样本数.
- (4)FN(False Negative): 假负例, 模型预测为负, 实际为正的样本数.

5.2.1 交并比

交并比 IoU 是预测边界框和真实边界框交集面积与并集面积的比值. 由图 xx 可知, 蓝色区域 A 表示预测的边界框, 黄色区域 B 表示真实的边界框, 其中, “ $\cap$ ” 表示两个框的交集部分, 即两个框重叠的绿色区域, “ $\cup$ ” 表示两个框的并集部分, 即两个框的总面积去掉了重叠的部分.




图 15 交并比

由式 12 可知, IoU 值介于 0 和 1 之间, IoU 值越大, 证明预测框与真实框的匹配度越高, 即模型预测的准确度越高. 一般情况下, 如果 IoU 大于 0.5, 就认为检测是正确的, 但具体的阈值会根据应用需求和具体情况进行设定.

$$IoU = \frac{A \cap B}{A \cup B} \quad (12)$$

5.2.2 查准率

查准率 P 是指在所有被模型预测为正例的样本中，真正是正例的样本比例。查准率主要用于二分类问题，其数学公式如式 13 所示。它是一种关注模型预测正例结果准确性的指标，尤其是在正负样本不均衡的情况下，查准率可以帮助我们检验模型在预测正例上的性能。

$$P = \frac{TP}{TP + FP} \quad (13)$$

5.2.3 查全率

查全率 R 是指在所有真实的正例样本中，被模型正确预测为正例的样本的比例，数学公式如式 14 所示。查全率衡量的是检测算法对目标的覆盖能力，对于接触网异物检测而言，更希望模型具有较高的查全率，即使会增加一些错误判断，但可以找出所有的正例。查全率并不能反映模型对于负例的识别能力，因此往往需要和查准率等其他性能指标一起使用。

$$R = \frac{TP}{TP + FN} \quad (14)$$

5.2.4 平均准确率

平均准确率 (Average Precision, AP): AP 是准确率-查全率曲线下的面积，面积越大性能越好，它可以衡量检测算法在不同阈值下的整体性能。其对应的数学公式如式 15 所示。

$$AP = \int_0^1 P(R) dR \quad (15)$$

5.2.5 平均准确率均值

平均准确率均值 (Mean Average Precision, AP) 计算过程是先计算每个类别的平均准确率，然后对所有类别的 AP 进行平均，最终得到的结果就是 mAP，其数学公式如式 16 所示。

$$mAP = \frac{\sum_{i=1}^m AP_m}{m} \quad (16)$$

mAP 的取值范围在 $[0, 1]$ 之间，值越大代表模型的性能越好，mAP 能够反映模型对所有类别的整体性能，因此常被用于检测任务的模型性能评估。

5.3 模型的训练

本文通过调用 PyTorch 实现了 YOLOv5，其对数据集的训练过程如下：

表 1 YOLOv5 对数据集的训练过程

算法: <i>YOLOv5</i>
Input: 训练集数据
Step0: 数据预处理, 去除不完整或损坏的图像, 消除无关信息 (如噪声、背景干扰等), 清理标注错误
Step1: 参数配置, 通过解析命令行参数和配置文件来设置训练所需的基本参数
Step2: 模型初始化, 根据提供的配置文件和预训练权重来构建和初始化 YOLOv5 模型
Step3: 数据加载, 创建数据加载器, 用于在训练过程中提供批量的图像和标签数据
Step4: 训练循环, 遍历数据集中的每个批次, 执行模型的训练和优化
Step5: 损失计算, 使用损失函数计算模型预测和真实标签之间的差异
Step6: 权重更新, 根据损失值更新模型的权重, 以减少预测误差
Step7: 学习率调整, 动态调整学习率, 以优化训练过程
Step8: 模型评估, 在每个训练周期结束时, 使用验证集评估模型性能
Step9: 结果记录, 保存模型权重、训练指标和验证结果
Step10: 训练结束, 完成所有训练周期后, 输出最终模型性能并结束训练
Output: 一个 YOLOv5 模型

与此同时, 我们使用 Netron 软件实现对 YOLOv5 模型的可视化, 因篇幅问题仅展示部分架构, 如下图所示:




图 16 训练得到的 YOLOv5 网络架构图

5.3.1 数据集预处理

在 YOLOv5 训练前，首先要对数据集进行如下流程的处理




图 17 YOLOv5 训练过程数据集处理流程图

5.3.2 YOLOv5 模型训练

在 YOLOv5 的训练过程中，我们分别记录了训练集（train）和验证集（val）在每一个 Epoch 中的 RMSE 以及 LOSS，如下表所示：

表 2 YOLOv5 训练过程展示表

Epoch	Training RMSE	Training LOSS	Validation RMSE	Validation LOSS
1	3.1864	0.3714	3.1890	0.3634
2	1.3548	0.0421	1.4789	0.0501
3	1.1586	0.0546	1.1437	0.0494
4	0.9909	0.0319	0.9884	0.0487
5	0.8862	0.0457	0.8736	0.0480
...	...	...	...	...
26	0.2057	0.0205	0.2275	0.0213
27	0.1983	0.0213	0.2074	0.0206
28	0.1912	0.0145	0.1986	0.0158
29	0.1896	0.0131	0.1942	0.0140
30	0.1871	0.0129	0.1935	0.0132

与此同时，为了进一步探究 YOLOV5 模型的详细训练过程，我们分别训练集（train）和验证集（val）的相关指标做了如下图所示的可视化：




图 18 YOLOv5 训练过程 RSME 曲线图




图 19 YOLOv5 训练过程 LOSS 曲线图

由上图可知，随着训练轮数 Epoch 的增加，尽管有少许波动，但不论是训练集还是验证集，大体上来看，其 RSME 都呈现着减少的趋势，Loss 都呈现着减少的趋势，说明着 YOLOV5 模型在不断地进行着优化。当训练轮数 Epoch=30 时，训练效果达到了最佳，在训练集上其 RMSE=0.1871，Loss=0.0129，在验证集上其 RSME=0.1935，Loss=0.0132。都足以说明该模型的训练效果优异。

5.4 模型求解

本文利用上述建立的甲骨文图像分割模型对附件 3(Test 文件夹) 中的 200 张甲骨文原始拓片图像进行自动单字分割，并将结果放在“Test results.xlsx”中。因篇幅限制，在此仅以 w01833 为例展示部分单字分割结果，如下图所示




图 20 单字分割结果图

六、自动单字分割模型的改进

在甲骨文图像分割任务中，基准的 YOLOv5 模型可能在核心网络设计上存在一些局限性，特别是在特征提取方面。由于甲骨文字的大小和形状多变，以及背景的复杂性，YOLOv5 可能难以捕捉到所有的细节和环境信息。这可能导致模型对于小的或者与背景相似的甲骨文字的检测性能下降。因此，本文通过一系列改进和优化措施来降低这些问题对检测效果的影响。

6.1 YOLOv5 主干网络的改进

6.1.1 PP-LC 主干网络的引入

PP-LC-Net 是一个为 CPU 优化的轻量化卷积神经网络，通过减少参数和计算量来提升在资源有限设备上的推理效率。相较于复杂的网络如 YOLOv5，*PP-LC-Net* 在甲骨文图像分割任务中能更充分发挥 CPU 性能，实现快速推理和高效率运算。其轻量化设计使其适合在计算资源受限的环境中使用，如考古现场快速处理甲骨文图像。研究者通过简化网络结构，如减少 *DepthSepConv* 模块数量，进一步降低了计算需求，增强了模型在甲骨文分割任务中的性能。如图所示：




图 21 PP-LC 精简图

上图中虚线框表示可选的模块，*DepthSepConv* 代表深度可分离卷积，*DW* 代表深度卷积，*PW* 代表逐点卷积，*GAP* 代表全局平均池化，*FC* 代表全连接层，*relu* 代表 *ReLU* 激活函数。此外，还使用了 *SE* 注意力机制，通过自适应调整特征图的权重，加强了关键区域的显著性，进而更准确地识别接触网中的异物。*SE* 注意力机制的结构如下图所示：




图 22 SE 注意力机制

6.2 空间金字塔池化 GSPPF 的引入

SiLU 激活函数是一种基于 *Sigmoid* 函数的激活函数，其公式定义如下：

$$f(x) = x \cdot \sigma(x) \quad (17)$$

其中， σ 是 *Sigmoid* 函数：

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (18)$$

所以，将 Sigmoid 函数代入到 SiLU 的定义中，我们得到：

$$f(x) = x \cdot \frac{1}{1 + e^{-x}} \quad (19)$$

因此 SiLU 函数可以看作是输入 x 与一个缩放的 Sigmoid 函数相乘，从而允许梯度在正区间内流动，这有助于缓解梯度消失问题，并在训练深度神经网络时提供一定的优势。GeLU 激活函数是一种基于高斯分布的非线性激活函数，其公式定义如下：

$$f(x) = x\Phi(x) \quad (20)$$

其中， $\Phi(x)$ 是标准正态分布的累积分布函数，表示为：

$$\Phi(x) = \frac{1}{2} \left[1 + \operatorname{erf} \left(\frac{x}{\sqrt{2}} \right) \right] \quad (21)$$

而 $\operatorname{erf}(z)$ 是误差函数，它是高斯函数的积分形式，定义为：

$$\operatorname{erf}(z) = \frac{2}{\sqrt{\pi}} \int_0^z e^{-t^2} dt \quad (22)$$

因此，GeLU 激活函数可以看作是输入值 x 与高斯分布累积分布的乘积。这种激活函数在一定程度上模拟了神经元的激活概率，其中较小的输入值有较小的输出，而较大的输入值则有较大的输出，且输出的分布接近于高斯分布。在甲骨文图像分割任务中，处理边界条件是确保分割精确性的关键。虽然 SiLU 激活函数因其输出范围限制在 $[0, 1]$ 内而在边界处理方面表现良好，但在甲骨文字与背景对比度较低的场景中，其表达能力可能不足。为了提升分割准确度，GeLU 激活函数因其强大的非线性特性和对不同图像条件的适应性，被选用以替代 SiLU。采用 GeLU 的改进空间金字塔模块（GSPPF）包含两个卷积模块和三个最大池化模块，这些模块串联连接，提升了模型对各种尺寸和形状甲骨文字的适应性和鲁棒性。




图 23 GSPPF 结构图

6.3 YOLOv5 颈部网络的改进

6.3.1 CA 注意力机制的引入

为了提高甲骨文图像分割的准确性，引入了 CA 注意力机制来增强模型对甲骨文字特征的区分能力。CA 注意力机制通过识别和加权重要的特征通道，使模型专注于与甲

骨文字直接相关的特征，从而减少背景噪声和冗余信息的干扰。这种机制强化了模型对关键特征的识别，提高了分割的精确度和效率，特别是在处理具有复杂背景和多样形态的甲骨文图像时。通过自适应关注重要的特征，CA 注意力机制确保了模型能够更准确地进行甲骨文的分割。




图 24 CA 注意力机制

6.3.2 损失函数的改进

在甲骨文图像分割中，背景与甲骨文字的比例失衡可能导致模型偏向于识别背景，忽略重要的甲骨文字样本。传统损失函数，如 CIOU，可能因忽视甲骨文字的多样性和与背景的复杂关系而限制分割性能。因此，需要更适应甲骨文特点的损失函数来提高分割的准确性和鲁棒性。CIOU 函数的公式如下：

$$L_{CIOU} = 1 - IoU + \frac{\rho^2(b, b^{gt})}{c^2}av \quad (23)$$

L_{CIOU} 是 CIOU 损失函数的值, $\rho^2(b, b^{gt})$ 是边界框 b 和真实框 b^{gt} 之间的欧式距离, c 是一个常数, 用于缩放欧式距离的值, a 是一个权重参数, v 是一个辅助变量。为了解决甲骨文图像分割中的样本不平衡问题，本文采用了 *Focal CIOU* 损失函数，它结合了 *Focal Loss* 和 *CIOU* 的特点。*Focal CIOU* 通过为难以分类的正样本分配更高权重，帮助模型更加关注并准确定位关键的甲骨文字目标。这种损失函数提高了模型对甲骨文字的敏感性，平衡了正负样本的影响，降低了漏分割风险，从而提升了分割的准确性。*Focal CIOU* 相比原始 *CIOU* 更重视难以识别的文字样本，增强了模型对关键特征的识别能力，优化了甲骨文图像分割的整体性能。*Focal CIOU* 函数的公式如下：

$$L_{FocalCIOU} = \left(1 - IoU + \frac{\rho^2(b, b^{gt})}{c^2}av\right)^\gamma \quad (24)$$

γ 是 *Focal CIoU* 损失函数的一个调节因子, 使得模型更加注重难以分类的正样本, 从而改善类别不平衡问题对目标检测的影响.

Focal Loss 权重系数的参数可以灵活调节, 用于控制正负样本之间的平衡, 本文系数设置为 1.5 . 通过调整参数, 可以增加或减少困难样本的权重, 从而影响模型对正样本的关注程度. 这样的机制使得 *Focal CIoU* 能够针对具体任务的正负样本不平衡情况进行优化, 提高对重要目标的检测能力.

6.3.3 改进后的网络模型架构

本文提出了一种适合甲骨文图像分割的轻量化算法, 旨在应对复杂场景下的甲骨文准确分割问题, 改进后的网络结构如图 5 所示. 其主干网络用改进的轻量化 *PP-LC* 架构, 该架构在保持高性能的同时, 大大减少了网络的参数量和计算量, 使其能够在资源有限的情况下实现高效的分割. 此外, 本文还使用了 *GeLU* 激活函数来增加网络的非线性能力, 并引入了 *CA* 注意力机制来增强网络对重要特征的关注和区分能力. 这些技术的引入使得本轻量化模型能够更好地捕获接触网异物的细节和上下文信息. 最后, 本文采用了 *Focal CIoU* 作为损失函数训练目标, 该损失函数在处理正负样本不平衡问题时具有良好的效果, 能够提高图像分割的准确性和鲁棒性, 为甲骨文图像分割任务提供了有力的保障.




图 25 改进后的网络架构图

6.4 模块消融实验结果与分析

6.4.1 参数设置

本实验的参数设置如下表所示:

表 3 参数设置

相关参数	参数值
Batch-size	128
Epochs	200
学习率的初始值	0.01
权重衰减	0.0005

6.4.2 引入 PP-LC 主干网络消融实验

为了保证轻量化原则，力求在降低计算复杂度的前提下提升精度，所以在主干部分引入了 $PP-LC$ 网络，考虑到卷积层过多会导致特征提取不明显，本小节在对主干网络部分进行了替换的同时移除了一些冗余的层和通道数，并对 $DepthSepConv$ 模块进行了相应的精简，其实验后的具体性能表现如下表所示。

表 4 $PP-LC$ 主干网络消融实验

主干网络	P	R	mAP @ 0.5	模型容量/Mb	Inference/ms	参数量	计算量
YOLOv5s	0.938	0.902	0.942	14.4	9.9	7012822	15.8
PP-LC	0.902	0.813	0.869	5.9	6.6	2791382	5.3

在轻量化 $PP-LC$ 网络引入的同时，将其原有的 $DepthSepConv$ 模块进行缩减，因此模型的容量、参数量、计算量都下降的非常明显，推理速度也随之加快。由表可以得出，虽然满足了轻量化网络设置的前提，但模型在精度方面也随之下降了，查准率由 93.8% 下降到 90.2%，查全率由 90.2% 下降 81.3%，准确率由 94.2% 下降到 86.9%，所以，接下来的任务就是在模型继续轻量化的前提下提升模型的查准率、查全率、准确率等性能评价参数指标。

6.4.3 引入空间金字塔池化消融实验

为了处理任意大小的输入、保留更多空间信息、提高计算效率、改善异物检测的性能，在主干网络中引入改进后的空间金字塔池化 $GSPPF$ 模块，将其定义为 $YOLOv5s-PG$ ($YOLOv5s-PPLC-GSPPF$)，并进行消融实验，其性能表现如下表所示。

表 5 空间金字塔池化消融实验结果

主干网络	P	R	mAP@0.5	模型容量 Mb	Inference /ms	参数量	计算量
PP-LC	0.902	0.813	0.869	5.9	6.6	2791382	5.3
YOLOv5s-PG	0.946	0.801	0.878	6.6	8.8	3152470	5.6

空间金字塔池化的多尺度特征捕捉有助于模型更好的检测和识别不同大小的目标，而且 $GeLU$ 在激活函数的区域内提供了更平滑的梯度，便于模型在训练期间的收敛，进

而提高其查准率和准确率。由表 3 可以得出，查准率由 90.2% 上升到 94.6%，准确率由 86.9% 上升到 87.8%。由于在原有的主干网络中引入了金字塔池化模块 *GSPPF*，所以在模型容量、推理速度、参数量、计算量方面均会导致数值提升。

6.4.4 引入注意力机制消融实验

为了在众多的输入信息中聚焦于对当前任务更为关键的信息，降低对其他信息的关注度，解决信息过载问题的同时提高任务处理的效率和准确性，在网络的颈部相同位置引入 CBAM、CA 两种不同的注意力机制，将此网络分别定义为 *YOLOv5s-PGGGC1* (*YOLOv5s-PGGGC-CBAM*) 和 *YOLOv5s-PGGGC2* (*YOLOv5s-PGGGC-CA*)，并进行消融实验，其性能表现如下表所示。

表 6 注意力机制消融实验结果

颈部	P	R	mAP@0.5	模型容量/Mb	Inference /ms	参数量	计算量
YOLOv5s-PGGGC	0.941	0.869	0.921	3.7	10.3	1750758	0.9
YOLOv5s-PGGGC1	0.939	0.883	0.925	3.8	10.6	1791914	0.9
YOLOv5s-PGGGC2	0.976	0.843	0.925	3.8	10	1783086	0.9

CA 注意力通过引入坐标信息，能够更好地捕获长程依赖性，对于视觉任务中捕获对象结构至关重要，而 *CBAM* 注意力机制在这方面却有所欠缺。*CA* 注意力机制通过引入坐标信息，使模型能够更好地理解不同位置之间的关系，从而加强深度学习模型对输入数据的空间结构理解，所以在查准率和准确率方面会有提升。由表 4 三组实验对比数据可以得出，在模型容量、参数量、计算量方面，三种模型基本上在同一水准，在推理速度和查准率方面，引入 *CA* 注意力机制的模型效果是最好的，比 *YOLOv5s-PGGGC* 模型查准率高出 3.5%，比 *YOLOv5s-PGGGC1* 模型查准率高出 3.7%，在准确率方面，比 *YOLOv5s-PGGGC* 模型查准率高出 0.4%，与 *YOLOv5s-PGGGC1* 模型持平，虽然查全率方面欠佳，但是综合来看，引入 *CA* 注意力机制是有绝对优势的，因此，在本章中选择 *CA* 注意力机制。

6.4.5 改进损失函数消融实验

YOLOv5s 原始的损失函数为 *CIoU*，分别替换为 *FocalCIoU*、*WIoU*、*SIoU* 进行对比实验，并将其定义为 *YOLOv5s-Light* (*YOLOv5s-PGGGC2-FocalCIoU*)、*YOLOv5s-Light2* (*YOLOv5s-PGGGC2-WIoU*)、*YOLOv5s-Light3* (*YOLOv5s-PGGGC2-SIoU*)，消融结果如下表所示：

表 7 损失函数消融实验结果

损失函数	P	R	mAP@0.5	模型容量/Mb	Inference /ms	参数量	计算量
YOLOv5s-PGGGC2	0.976	0.843	0.925	3.8	10	1783086	0.9
YOLOv5s-Light2	0.935	0.864	0.922	3.8	10.1	1783086	0.9
YOLOv5s-Light3	0.944	0.851	0.91	3.8	9.7	1783086	0.9
YOLOv5s-Light	0.957	0.886	0.93	3.8	9.7	1783086	0.9

Focal CIoU 损失函数特别关注难分类的样本，在甲骨文图像分割任务中，由于背景样本数量通常远大于甲骨文字样本，这种损失函数通过为难以分类的样本分配更多权重，有助于提高模型对甲骨文字的检测效果，从而提升分割的查全率和准确率。根据实验结果，使用 *Focal CIoU* 损失函数的模型在模型容量、参数量和计算量方面与其他模型保持一致，但在推理速度上表现最佳，仅需 $9.7ms$ ，比使用原始 *CIoU* 损失函数的模型快 $0.3ms$ 。在分割性能方面，采用 *Focal CIoU* 损失函数的模型在查全率和准确率上均有显著提升，分别达到了 88.6% 和 93%，与 *YOLOv5s-PGGGC2* 模型相比分别提高了 4.3% 和 0.5%，与 *YOLOv5s-Light2* 模型相比分别提高了 2.2% 和 0.8%，与 *YOLOv5s-Light3* 模型相比分别提高了 3.5% 和 2%。这些结果表明，用 *Focal CIoU* 损失函数在甲骨文图像分割任务中能够有效地提升模型性能，特别是在处理正负样本不平衡的情况时。综上所述，在模型轻量化前提下，以查全率和准确率为主，可以得出 *YOLOv5s-Light* 模型的性能更好，更适合工程上应用和部署。因此选用 *YOLOv5s-Light* 作为最终的轻量化模型。

七、基于 CNN 的文字识别模型

7.1 模型的建立

7.1.1 输入层

输入图像，先将其转换为对应的二维矩阵（由每一个像素的像素值大小组成），计算机读取后是以像素值大小组成的二维矩阵存储的图像（灰度图像：每一个像素值的范围是 0-255）。本题中，为了减小图片尺度对图像识别的影响，先将对模型做归一化的处理，将 0-255 之间的数字统一处理到 0 到 1 之间，方便后续计算。

7.1.2 卷积层

得到图片的二维矩阵后，利用卷积提取特征，存在特征的区域确定一个高值，否则确定一个低值，这个过程通过计算其与卷积核的乘积来确定。结合本题，我们输入甲骨文原始拓片的图像，而甲骨文原始拓片的轮廓、纹理、形态等作为卷积核，通过在甲骨文原始拓片的图像上移动来确定哪里有文字。卷积完后得到新的二维矩阵（特征图）。卷积核的二维矩阵在输入图像的二维矩阵上不停移动，每移动一次进行一次求和得到新

的值，经过降维，提取图像中最有用的特征。同时，利用 **Padding**（在原始输入图像的二维矩阵周围进行拓展去解决特征值丢失的方法），去除每次计算中间被多次计算而周围只计算一次的误差。本题两次卷积过程中还运用到 **Relu** 激活函数，能够提高运算效率，快速识别图像中的道路是否正常或者坑洼。在神经网络中使用 **Relu** 激活函数作为非线性变换得到的输出结果是：

$$Relu = \max(0, x) = \begin{cases} 0, & x < 0 \\ x, & x \geq 0 \end{cases} \quad (25)$$

其中， x 表示输入信号。




图 26 *Relu* 函数曲线图

7.1.3 池化层

为了减小过拟合和降低维度的问题同时为卷积神经网络带来平移不变性，利用池化层（下采样），进行卷积操作后，再将得到的特征图进行特征提取，将最有代表的特征提取出来。这里运用最大池化方法，每次取正方形中所有值的最大值作当前位置最具代表性的特征。




图 27 最大池化过程示意图

其中, $kernel_size = 2$ 表示池化过程使用的正方形尺寸是 $2 * 2$, 如果是在卷积的过程中就说明卷积核的大小是 $3 * 3$; $stride = 2$ 表示每次正方形移动两个位置 (从左到右, 从上到下), 这个过程其实和卷积的操作过程一样; $padding = 0$ 说明没有进行拓展. 接着进行全连接, 将卷积和池化提取的甲骨文原始拓片的轮廓、纹理、形态等特征图展平, 将维度变为 $1 * x$, 通过计算得到概率值, 判断输入图片是哪种文字的概率.

7.1.4 全连接层

经过两次卷积和最大池化之后, 得到最后的具有代表性的特征图, 再通过全连接层, 展开为一维的向量, 计算后得到最终的识别概率, 这就是卷积神经网络的整个过程原理. 在模型训练中我们结合运用到 SGD 优化器, SGD 在每轮更新参数时, 仅随机抽取一个样本计算其梯度, 并以此梯度为全局梯度的估计值. SGD 的参数更新公式为

$$\theta_{t+1} = \theta_t - \alpha_t \nabla f_{i_t}(\theta_t) \quad (26)$$

$$\nabla f = \frac{\partial f}{\partial x} \vec{i} + \frac{\partial f}{\partial y} \vec{j} + \frac{\partial f}{\partial z} \vec{k} = \frac{\partial f}{\partial x_i} \vec{e}_i \quad (27)$$

$$\nabla \vec{f} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_2}{\partial x_1} & \frac{\partial f_3}{\partial x_1} \\ \frac{\partial f_1}{\partial x_2} & \frac{\partial f_2}{\partial x_2} & \frac{\partial f_3}{\partial x_2} \\ \frac{\partial f_1}{\partial x_3} & \frac{\partial f_2}{\partial x_3} & \frac{\partial f_3}{\partial x_3} \end{bmatrix} \quad (28)$$

其中, θ_{t+1} 代表第 $t + 1$ 轮参数, θ_t 代表第 t 轮参数, α_t 表示第 t 轮学习率, $\nabla f_{i_t}(\theta_t)$ 表示梯度.




图 28 SGD 的优化轨道示意图

7.2 模型的训练

本文通过调用 *tensorflow* 实现了卷积神经网络 *CNN*，其对数据集的训练过程如下：

表 8 CNN 对数据集的训练过程

算法: <i>CNN</i>
Input: 训练集数据
Step1: 对数据做归一化的处理，将 0-255 之间的数字统一处理到 0 到 1 之间
Step2: 设置卷积层，该卷积层的输出为 32 个通道，卷积核的大小是 3*3，激活函数为 <i>relu</i>
Step3: 添加池化层，池化的 <i>kernel</i> 大小是 2 * 2
Step4: 添加另外一个卷积层，输出为 64 个通道，卷积核大小为 3 * 3，激活函数为 <i>relu</i>
Step5: 添加池化层，最大池化，对 2 * 2 的区域进行池化操作
Step6: 将二维的输出转化为一维
Step7: 设置与预卷积示例相同的 128 个全连接层和 10 个输出层
Step8: 通过 <i>softmax</i> 函数将模型输出为类名长度的神经元上，激活函数采用 <i>softmax</i> 对应概率值
Step9: 指明模型的训练参数，优化器为 <i>sgd</i> 优化器，损失函数为交叉熵损失函数
Step10: 设置训练轮数 <i>Epoch</i> = 30
Output: 一个卷积神经网络 (<i>CNN</i>)

与此同时，我们使用 *Netron* 软件实现对 *CNN* 模型的可视化，如下图所示：




图 29 训练得到的 CNN 网络架构图

在 CNN 的训练过程中，我们分别记录了训练集 (*train*) 和验证集 (*val*) 在每一个 *Epoch* 中的 *Loss* 以及 *Accuracy*，如下表所示：

表 9 CNN 训练过程展示表

Epoch	Training Accuracy	Validation Accuracy	Training Loss	Validation Loss
1	0.831	0.898	0.489	0.402
2	0.880	0.898	0.378	0.342
3	0.880	0.898	0.354	0.313
4	0.880	0.898	0.339	0.300
5	0.880	0.898	0.320	0.326
...	...	...	...	...
26	0.884	0.915	0.244	0.269
27	0.926	0.746	0.178	0.447
28	0.930	0.797	0.168	0.363
29	0.926	0.915	0.182	0.181
30	0.963	0.898	0.129	0.230

与此同时，为了进一步探究 CNN 模型的详细训练过程，我们分别训练集 (*train*) 和验证集 (*val*) 的相关指标做了如下图所示的可视化：




图 30 CNN 训练过程曲线图

由上图可知,随着训练轮数 $Epoch$ 的增加,尽管有少许波动,但不论是训练集还是验证集,大体上来看,其 $Accuracy$ 都呈现着增加的趋势, $Loss$ 都呈现着减少的趋势,说明着 CNN 模型在不断地进行着优化. 当训练轮数 $Epoch = 30$ 时,训练效果达到了最佳,在训练集上其 $Accuracy = 0.963$ $Loss = 0.129$ 在验证集上其 $Accuracy = 0.898$ $Loss = 0.230$. 都足以说明该模型的训练效果优异.

7.3 模型的评估

为了更加准确、全面地对模型进行评估,我们选用了准确率 ($Accuracy$)、查准率 ($Precision$)、召回率 ($Recall$)、 $F1$ 分数以及 $ROC - AUC$ 值等指标.




图 31 指标体系图

（1）准确率（Accuracy）准确率是分类模型评估指标的一种，它表示的是分类模型正确预测的样本数与总样本数的比例。具体来说，如果我们有一个分类模型，它需要对 n 个样本进行分类，其中 m 个样本被正确分类，那么准确率公式就是：

$$\text{Accuracy} = \frac{m}{n} \quad (29)$$

准确率是一个简单的评估指标，但是它有一些局限性。它不能很好地处理类别不平衡的问题，也就是说，如果某个类别的样本数量远大于其他类别，那么准确率可能会给出误导性的结果。此外，准确率也不能反映出模型在不同类别上的性能，只能给出总体性能。

（2）查准率（Precision）和召回率（Recall）查准率和召回率是更适用信息检索需求的性能度量。对二分类问题可将样例依据真实类别与学习器预测类别的组合划分为真正例、假正例、真反例、假反例四种情形。令 TP, FP, TN, FN 分别表示其对应的样例数，则显然有 $TP + FP + TN + FN = \text{样例总数}$ ，分类结果的“混淆矩阵”如表：

表 10 混淆矩阵概念表

真实情况	预测结果	
	正例	反例
正例	TP (真正例)	FN (假正例)
反例	FP (假正例)	TN (真正例)

查准率 P 和查全率 R 的定义分别为：

$$P = \frac{TP}{TP + FP} \quad (30)$$

$$R = \frac{TP}{TP + FN} \quad (31)$$

查准率和召回率是一对矛盾的指标，一般说，当查准率高时，召回率一般很低；召回率高时，查准率一般很低。

(3) $F1$ 分数 ($F1score$) 为了结合查准率和召回率的结果，我们引入了 $F1$ 分数这个指标来解决类别不平衡的问题。

$$F1 = \frac{2 \times P \times R}{P + R} = \frac{2 \times TP}{\text{样例总数} + TP + TN} \quad (32)$$

(4) $ROC - AUC$ 值 $ROC - AUC$ 值，我们根据学习器的预测结果对样例进行排序，按此顺序逐个把样本作为正例进行预测，每次计算出两个重要量的值，分别以它们为横、纵坐标作图，就得到了“ ROC 曲线”。 ROC 曲线的纵轴是“真正例率”，横轴是“假正例率”，两者分别定义为

$$TPR = \frac{TP}{TP + FN} \quad (33)$$

$$FPR = \frac{FP}{TN + FP} \quad (34)$$

AUC 是 ROC 曲线下的面积，假定 ROC 曲线是坐标为 $\{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$ 的点按序连接而形成 ($x_1 = 0, x_m = 1$)，则 AUC 可估算为

$$AUC = \frac{1}{2} \sum_{i=1}^{m-1} (x_{i+1} - x_i) \cdot (y_i + y_{i+1}) \quad (35)$$

ROC 曲线可以用于比较不同的分类模型，通过比较 AUC 值来评估模型的性能。一般来说， AUC 值越接近 1，表示分类器的性能越好。此外， ROC 曲线还可以用于调整模型参数，以提高分类性能。以下是对模型的指标评估过程，对于验证集样本，我们对其进行路面类别进行预测并与其原始标签进行比对，得到如下图所示的热力图：




图 32 CNN 模型热力图

根据上图可知， CNN 模型表现良好。为了进一步分析该模型的性能，我们计算了其准确率 ($Accuracy$)、查准率 ($Precision$)、召回率 ($Recall$)、 $F1$ 分数并如下表所示：

表 11 CNN 模型指标展示表

Model	Accuracy	Precision	Recall	F1 分数
CNN	0.898	0.961	0.925	0.943

由上表可知，CNN 模型在准确率、查准率、召回率、F1 分数这四项指标上表现良好，可以考虑用作甲骨文原始拓片的文字识别任务的模型。为了更进一步的评估该模型的性能，我们绘制了其 ROC 曲线，如下图所示：




图 33 CNN 模型 ROC 曲线图

由上图可知， $AUC = 0.94 > 0.9$ ，说明 CNN 模型在文字识别任务中分类效果良好，可以考虑用作甲骨文原始拓片的文字识别任务的模型。

八、基于 MobileNet 的文字识别模型

8.1 模型的建立

MobileNetV2 是一个基于流线型的构架，它利用深度可分离的卷积去构建轻量级的深层神经网络。引入两个全局超参数，该模型能够有效平衡延迟度和准确度两者。卷积神经网络随着深度学习的发展变得逐渐普遍，而 MobileNetV2 模型相较于其他模型具有轻量级、低延迟、较为精确的优势。MobileNet2 模型是基于深度可分离卷积，是一种分解卷积的形式。这种形式将标准卷积分解为一个深度卷积和一个称为逐点卷积的 1×1 的卷积，这种分解可以很有效的减少计算量和模型大小。

8.1.1 深度可分离卷积

深度可分离卷积应该由两个部分组成，即深度卷积和逐点卷积。用下图直观进行表示：




图 34 深度可分离卷积概念图

标准卷积的操作：输入是 1 个 $D_F * D_F$ 大小的图片，有 M 个通道，卷积核大小为 $D_K * D_K * M$ ，有 N 个卷积核，那么经过卷积后输出特征图的大小为 $D_F * D_F$ ，个数为 N 。




图 35 标准卷积操作概念图

其中，卷积核的尺寸是 $D_K * D_K * M$ ，一共有 N 个，所以标准卷积的参数量是 $D_K * D_K * M * N$ ；每一个都要进行 $D_F * D_F$ 次运算，所以标准卷积的计算量是 $D_K * D_K * M * N * D_F * D_F$ 。

(1) 深度卷积：相比于标准卷积，深度卷积的卷积核为单通道模式，对输入的每一个通道进行卷积，得到与输入特征图通道数一致的输出特征图：




图 36 深度卷积操作概念图

其中, channel input 表示输入特征图通道数, filters 表示卷积核个数, maps 表示输出特征图个数. 深度卷积的卷积核尺寸 $D_K * D_K * 1$, 个数为 M , 所以参数量为 $D_K * D_K * M$, 每个都要做 $D_F * D_F$ 次乘加运算, 所以计算量为 $D_K * D_K * M + M * N$. (2) 逐点卷积: 为了防止深度卷积后使得得到特征图个数少影响信息的有效性, 我们需要进行逐点卷积. 其实质就是用 $1 * 1$ 的卷积核进行升维. 我们将上一步得到的 3 个特征图, 卷积核大小为 $1 * 1 * 3$, 卷积核个数为 4, 卷积后得到 4 个特征图.




图 37 逐点卷积操作概念图

其中, 逐点卷积的卷积核尺寸为 $1 * 1 * M$, 个数为 N , 参数量为 $M * N$, 因此深度可分离卷积的参数量为 $D_K * D_K * M + M * N$, 每个都要做 $D_F * D_F$ 次乘加运算, 所以计算量为 $M * N * D_F * D_F$, 因此深度可分离卷积的参数量为 $D_K * D_K * M * D_F * D_F + M * N * D_F * D_F$. 得到了标准卷积和深度可分离卷积的参数量和计算量, 我们用它们的比值做一些比较: 一般的, N 较大, $\frac{1}{N}$ 可忽略不计, D_K 表示卷积核的大小, 若 $D_K = 3$, $\frac{1}{D_K^2} = \frac{1}{9}$. 即我们若使用常见的 $3 * 3$ 的卷积核, 那么使用深度可分离卷积的参数量和计算量下降到原来的九分之一左右. 参数量比值和计算量比值可得:

$$\frac{D_K * D_K * M + M * N}{D_K * D_K * M * N} = \frac{1}{N} + \frac{1}{D_K^2} \quad (36)$$

$$\frac{D_K * D_K * M * D_F * D_F + M * N * D_F * D_F}{D_K * D_K * M * N * D_F * D_F} = \frac{1}{N} + \frac{1}{D_K^2} \quad (37)$$

8.1.2 MobileNetV2

MobileNetV2 模型相比于传统 *MobileNet* 模型拓展了两个功能：Linear bottlenecks 和 Inverted residual blocks. 在 Linear bottlenecks 方面，其将部分 *Relu* 函数（图中标黄部分）替换成线性激活函数，以解决两大问题：一方面是深度卷积中卷积核容易报废的问题，另一方面是低维度下信息容易丢失的问题。




图 38 Linear bottlenecks 概念图

在 Inverted residual blocks 方面，传统的残差结构使用的是卷积降维到卷积，再到卷积升维；本文用到的 *MobileNetV2* 中，采用的是倒残差结构，其结构是卷积升到卷积，再到卷积降维。V2 先升维是为了利用 *Relu* 激活函数来降低信息的丢失。




图 39 Inverted residual blocks 概念图

8.1.3 Adam 优化器

其中，模型训练我们结合运用到 Adam 优化器，使用 Adam 优化器时，参数改变量 $\Delta\theta$ 近似受到全局学习率 α 的限制且 $|\Delta\theta_{t,k}| < \approx \alpha$ ，其中：“ $< \approx$ ”表示小于或约等于， $\Delta\theta_{t,k}$ 是 $\Delta\theta_t$ 第 k 个分量。在实际应用中，根据 α 的数量级可以大致推测出参数逼近最优解所需的更新次数；也可以将 α 看作 $|\Delta\theta_{t,k}|$ 的置信区间的上限，当参数变化量远大于 α 时，可以判断该样本为噪声点或此轮更新不具有价值。分别计算 g_t 的一阶矩和三阶矩的估计量

m_t 和 u_t

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (38)$$

$$u_t = \beta_2 u_{t-1} + (1 - \beta_2) g_t^2 \quad (39)$$

其中, $\beta_1, \beta_2 \in [0, 1)$ 是衰减常数. 建议设置为 $\beta_1 = 0.9, \beta_2 = 0.999$, 初始化 m_0 和 u_0 均为 d 维零向量. 分别对 m_t, u_t 的偏差进行修正:

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \hat{u}_t = \frac{u_t}{1 - \beta_2^t} \quad (40)$$

Adam 的参数更新公式为

$$\theta_{t+1} = \theta_t - \frac{\alpha}{\sqrt{\hat{u}_t} + \varepsilon} \odot \hat{m}_t \quad (41)$$

8.2 模型的训练

本文通过调用 *tensorflow* 实现了 *MobileNet*, 其对数据集的训练过程如下:

表 12 *MobileNet* 对数据集的训练过程图

算法: 对数据集的训练过程
Input: 训练集数据
Step1: 对数据做归一化的处理
Step2: 设置主干模型
Step3: 对主干模型的输出进行全局平均池化
Step4: 通过全连接层映射到最后的分类数目上
Step5: 模型训练的优化器为 adam 优化器, 模型的损失函数为交叉熵损失函数
Step6: 设置训练轮数 Epoch=30
Step10: 设置训练轮数 Epoch=30
Output: 一个 MobileNet

与此同时, 我们使用 Netron 软件实现对 MobileNet 模型的可视化, 如下图所示:




图 40 训练得到的 MobileNet 网络架构图

在 MobileNet 的训练过程中，我们分别记录了训练集（train）和验证集（val）在每一个 Epoch 中的 Loss 以及 Accuracy，如下表所示：

表 13 *MobileNet* 训练过程展示表

Epoch	Training Accuracy	Validation Accuracy	Training Loss	Validation Loss
1	0.826	0.898	0.535	0.288
2	0.930	0.966	0.193	0.154
3	0.967	0.966	0.108	0.113
4	0.992	0.966	0.070	0.096
5	0.992	0.966	0.057	0.088
...	...	...	...	...
26	1.0	0.983	0.007	0.061
27	1.0	0.983	0.006	0.061
28	1.0	0.983	0.006	0.060
29	1.0	0.983	0.006	0.060
30	1.0	0.983	0.006	0.061

与此同时，为了进一步探究 MobileNet 模型的详细训练过程，我们分别训练集（train）和验证集（val）的相关指标做了如下图所示的可视化：




图 41 MobileNet 训练过程曲线图

由上图可知，随着训练轮数 Epoch 的增加，但不论是训练集还是验证集，其 Accuracy 都呈现着稳定的增加趋势，Loss 都呈现着稳定的减少趋势，说明着 MobileNet 模型在不断地进行着优化。当训练轮数 Epoch=30 时，训练效果达到了最佳，在训练集上其 Accuracy=1.0，Loss=0.006，在验证集上其 Accuracy=0.983，Loss=0.061。都足以说明该模型的训练效果优异。

8.3 模型的评估

首先，对于验证集样本，我们对其进行路面类别进行预测并与其原始标签进行比对，得到如下图所示的热力图：




图 42 Mobile 模型热力图

根据上图可知，MobileNet 模型表现良好。为了进一步分析该模型的性能，我们计算了其准确率（Accuracy）、查准率（Precision）、召回率（Recall）、F1 分数以及 ROC-AUC 值并如下表所示：

表 14 MobileNet 模型指标展示表

Model	Accuracy	Precision	Recall	F1 分数
CNN	0.983	0.981	1	0.990

由上表可知，MobileNet 模型在准确率、查准率、召回率、F1 分数这四项指标上的性能表现良好，可以考虑用作甲骨文原始拓片的文字识别任务的模型。为了更进一步的评估该模型的性能，我们绘制了其 ROC 曲线，如下图所示：




图 43 MobileNet 模型 ROC 曲线图

由上图可知, $AUC = 0.99 > 0.9$, 说明 *MobileNet* 模型在甲骨文原始拓片的文字识别任务中分类效果优异, 可以考虑用作甲骨文原始拓片的文字识别任务的模型。

九、测试集的图片识别预测

9.1 模型选择

对于训练集而言, *CNN* 模型以及 *MobileNet* 模型在图像识别任务上都呈现出较好的表现, 二者在验证集上的各项评估指标如下表所示:

表 15 两个模型的指标对比表

Model	Accuracy	Precision	Recall	F1 分数	AUC
CNN	0.898	0.961	0.925	0.943	0.94
MobileNet	0.983	0.981	1	0.99	0.99

由上表可知, *MobileNet* 模型在各项评估指标上都优于 *CNN* 模型, 为了进一步判断二者在性能方面是否存在显著性差异, 现对二者在训练集准确率 *acc*、验证集准确率 *val_acc*、训练集损失值 *loss*、验证集损失值 *val_loss* 四个指标方面做统计学分析。成对 *t* 检验 (*Pairedt-test*) 是一种统计学方法, 用于比较两个相关样本的均值是否存在显著差异。这种方法通常用于研究在相同个体或组别中, 经过不同时间或不同处理后的观察结果是否存在差异。成对 *t* 检验的公式是:

$$t = \frac{\mu_1 - \mu_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \quad (42)$$

成对 *t* 检验的假设检验是:

$$H_0 : \mu_1 = \mu_2 \quad (43)$$

$$H_1 : \mu_1 \neq \mu_2 \quad (44)$$

如果得到的 *t* 值大于临界值, 则拒绝 H_0 , 认为两个样本的均值存在显著差异; 如果得到的 *t* 值小于临界值, 则不能拒绝 H_1 , 认为两个样本的均值没有显著差异。现对 *MobileNet* 模型及 *CNN* 模型在训练集准确率 *acc*、验证集准确率 *val_acc*、训练集损失值 *loss*、验证集损失值 *val_loss* 四个指标方面做成对 *t* 检验, 得到如下表所示的结果:

表 16 成对 *t* 检验结果

指标	acc	val_acc	loss	val_loss
P 值	$3.4 * 10^{-17}$	$4.3 * 10^{-9}$	$5.3 * 10^{-12}$	$6.0 * 10^{-16}$

9.2 预测结果

对于用 MobileNet 模型预测的结果，由于篇幅受限，现仅展示 w01815.jpg 的结果：




图 44 w01815 的文字识别结果图

十、模型的评价与推广

10.1 模型的优点

(1) 计算量小：相对于传统的深度神经网络，该深度学习模型具有更少的参数量和计算量，这使得它能够在资源受限。

(2) 资源需求小：该深度学习模型能够在资源受限的设备上运行。

(3) 快速准确：该深度学习模型能够实时地对图像进行快速准确的分割与识别。

(4) 可移植性强：该深度学习模型可以轻松移植到其他的图像识别任务上。

10.2 模型的缺点

(1) 数据需求量大：深度学习模型需要大量数据进行训练，如果没有足够的训练数据，模型可能会过拟合或无法达到预期性能。

(2) 可解释性较差：与传统的机器学习算法相比，该深度学习模型很难解释。

(3) 较难解决复杂问题：该深度学习模型采用轻量级的设计，在一些复杂场景下的准确率可能相对较低。

10.3 模型的推广

本文建立的甲骨文原始拓片的单字分割与识别模型，能够广泛应用于甲骨文智能识别领域中的分割与识别问题，并且在其他的图像分割与识别问题上也具有一定的参考价值和现实意义。

参考文献

- [1] 周志华. (2016). 机器学习. 清华大学出版社, 北京.
- [2] 阿斯顿·张李沐. 动手学深度学习. 人民邮电出版社.
- [3] 毛亚菲. 基于卷积神经网络的甲骨文字识别研究 [D]. 哈尔滨工程大学,2023.
- [4] 高旭. 基于卷积神经网络的甲骨文识别研究与应用 [D]. 吉林大学,2021.
- [5] 邢济慈. 基于深度卷积神经网络的甲骨文字检测技术研究 [D]. 郑州大学, 2020 .
- [6] 范恒帅. 基于改进 YOLOv5 的拥挤场景行人检测研究 [D]. 安庆师范大学,2023.
- [7] 黎爱闽. 基于 MobileNet V2 参数迁移学习的作物病虫害识别研究 [D]. 宁夏大学, 2023 .