

队伍编号	MC2404229
题号	B

基于深度学习的甲骨文原始拓片单字自动分割与识别研究

摘 要

甲骨文拓片图像分割一直是甲骨文研究中重要的研究内容，任务是从甲骨拓片中找到甲骨字符并提取独立的文字区域，这是字形破译的前提。然而，甲骨文拓片图像分割常受点状噪声、人工纹理和固有纹理干扰，使得现有传统图像分割方法误分割率较高，难以有效区分文字目标与各类干扰元素。针对这一难点，本文提出了一种基于深度学习的甲骨文单字自动分割与识别方法。

针对问题一，基于附件一所提供的三张图片，分析得到图像的主要干扰因素包括**字符过小、图像质量差异大、字形破损和噪声干扰**。为尽量解决以上因素带来的干扰，设计了一种**Laplace变换—稀疏表示和低秩逼近去噪—同态滤波—高斯滤波**的甲骨文原始拓片**图像预处理模型**，通过**边缘增强、对比度增强、图像去噪**等方法实现图像质量的提升，使字符特征更加突出，为后续字符分割提供可靠的图像数据支持。

针对问题二，通过任务分析可知，甲骨文原始拓片图像的自动单字分割任务**不仅具有图像分割的基本特性，还融合了目标检测的元素**，所以我们采用了目标检测领域应用最广泛的**YOLO 算法**来实现字符的检测与分割。首先对**数据集图像进行预处理**；接着针对数据集给出的标签，将其**转化成适用于 YOLO 算法的标注格式**；然后在**不同划分比例的数据集下**，选择不同的**YOLO 版本和不同的网络模型**进行训练与效果对比，并且针对训练中存在的微小字符难以识别的问题，引入了**SIOU 损失函数**来提高小字符检测精。最后通过对比评估得出，在训练集与验证集的比例为 8: 2 的条件下，引入 SIOU 损失函数后的**YOLOv8m** 网络模型既达到了最高的检测精度又权衡了模型复杂度。并且在验证网络模型时，我们发现**部分原始标注存在偏移误标现象**，这在很大程度上制约了网络精度的进一步提升。

针对问题三，我们选择问题二中训练精度最高的**改进 YOLOv8m 网络模型**来实现自动单字检测并分割，最终分割结果保存于 Test_results.xlsx 文件中。

针对问题四，根据给定的 76 种甲骨文汉字原始数据，建立甲骨文拓片图像分类识

别模型。在分类识别模型中，采用**卷积神经网络**与 **YOLOv8 分类网络**两种方法实现图像的分类训练和验证，数据集划分比例为 7:3。通过观察测试集文字特征，建立了**原始数据集扩充模型**，加入“王”字构建了 77 种甲骨文汉字数据集，分类任务变为 77 分类。卷积神经网络采用 **AlexNet**、**VGG16**、**GoogleNet**、**ResNet18-50-152** 六类模型，通过对比选取分类精度最高的 **GoogleNet 模型**与 **YOLOv8 分类网络**用于测试集文字识别。考虑到每张测试集图片并非单个文字，因此又建立了**图像分割模型**，该模型用问题而的目标检测模型对拓片进行分割。最后使用 **GoogleNet 模型**与 **YOLO 算法**分别对测试图片进行文字识别，保存结果，发现两种方法分类精度相当，YOLOv8 分类精度可达 **94.5%**，**GoogleNet** 可达 **93.7%**，最终预测结果表明，**YOLOv8 能够更好地挖掘甲骨文图像的深层次特征**，文字识别效果更好。

关键词：甲骨文字分割；卷积神经网络；YOLO 算法；图像预处理；数据增强。

目录

一、问题重述	1
1.1 问题背景	1
1.2 问题描述	1
二、模型假设及符号说明	2
2.1 模型假设	2
2.2 符号说明	2
三、问题分析	3
3.1 问题一的分析	3
3.2 问题二的分析	3
3.3 问题三的分析	4
3.4 问题四的分析	4
四、问题一的模型建立与求解	5
4.1 甲骨文原始拓片图像主要干扰因素及噪声分析	5
4.2 基于稀疏表示和低秩逼近的去噪算法	5
4.3 甲骨文原始拓片图像预处理模型的建立	10
4.3.1 同态滤波图像增强	10
4.3.2 图像边缘增强	11
4.3.3 甲骨文原始拓片图像预处理模型	12
4.4 甲骨文原始拓片图像预处理	13
4.4.1 图像预处理评价指标	13
4.4.2 图像预处理与结果分析	14
五、问题二的模型建立与求解	16
5.1 基于 YOLOv5 的甲骨文字符分割模型	16
5.1.1 YOLOv5 网络模型	16
5.1.2 YOLOv5 网络结构及关键技术	17
5.2 基于 YOLOv8 的甲骨文字符分割模型	21
5.2.1 YOLOv8 网络模型	21
5.2.2 YOLOv8 较 YOLOv5 的网络改进	21

5.3 基于 YOLO 网络的甲骨文图像分割	22
5.3.1 甲骨文图像分割流程	22
5.3.2 数据预处理	23
5.3.3 模型训练	25
5.3.4 模型的对比与评估	26
六、问题三的模型建立与求解	33
七、问题四的模型建立与求解	35
7.1 基于卷积神经网络的甲骨文字符识别模型	35
7.1.1 卷积神经网络	35
7.1.2 典型卷积神经网络	35
7.2 甲骨文字符识别	39
7.2.1 数据集扩充	39
7.2.2 基于卷积神经网络的甲骨文字符识别	40
7.2.3 基于 YOLOv8 的甲骨文字符识别	44
7.2.4 训练模型测试	45
八、模型的评价	50
8.1 模型优点	50
8.2 模型缺点	50
参考文献	51
附录	52

一、问题重述

1.1 问题背景

甲骨文是我国目前已知的最早成熟的文字系统，它是一种可在龟甲或兽骨上的古老文字。甲骨文具有极其重要的研究价值，不仅对中国文明的起源具有重要意义，也对世界文明的研究有着深远影响。在我国政府的大力推动下，甲骨文研究已经进入一个全新的发展阶段。人工智能和大数据技术被应用于甲骨文全息性研究及数字化工程建设，成为甲骨文信息处理领域的研究热点^[1]。

甲骨文拓片图像分割是甲骨文数字化工程的基础问题，其目的是利用数字图像处理和计算机视觉技术，在甲骨文原始拓片图像的复杂背景中提取出特征鲜明且互不交叠的独立文字区域。它是甲骨文修复、字形复原与建模、文字识别、拓片叠合等处理的技术基础^[2]。然而，甲骨拓片图像分割往往受到点状噪声、人工纹理和固有纹理三类干扰元素的严重影响^[3]。且甲骨文图像来源广泛，包括拓片、拍照、扫描、临摹等，不同的图像来源，其干扰元素的影响是不同的。由于缺乏对甲骨文字及其干扰元素的形态先验特征的特殊考量，通用的代表性图像分割方法目前尚不能对甲骨文原始拓片图像中的文字目标和点状噪声、人工纹理、固有纹理进行有效判别，其误分割率较高，在处理甲骨拓片图像时均有一定局限性。如何从干扰众多的复杂背景中准确地分割出独立文字区域，仍然是一个亟待解决的具有挑战性的问题。

1.2 问题描述

现希望通过对已标记的甲骨文图像进行分析、特征提取和建模，从而实现对一张新的甲骨文图像进行单个文字的自动分割和识别。具体任务如下：

问题 1:对于附件 1(Pre test 文件夹)给定的三张甲骨文原始拓片图片进行图像预处理，提取图像特征，建立甲骨文图像预处理模型，实现对甲骨文图像干扰元素的初步判别和处理。

问题 2:对甲骨文原始拓片图像进行分析，建立一个快速准确的甲骨文图像分割模型，实现对不同的甲骨文原始拓片图像进行自动单字分割，并从不同维度进行模型评估。其中附件 2(Train 文件夹)为已标注分割的数据集。

问题 3:利用建立的甲骨文图像分割模型对附件 3(Test 文件夹)中的 200 张甲骨文原始拓片图像进行自动单字分割，并将分割结果放在“Test results.xlsx”中，此文件单独上传至竞赛平台。

问题 4:基于前三问对甲骨文原始拓片图像的单字分割研究，请采用合适的方法进行

甲骨文原始拓片的文字识别，附件 4(Recognize 文件夹)中给出了部分已标注的甲骨文字形(不限于此训练集，可自行查找其他资料，如使用外部资料需在论文中注明来源)，请对测试集中的 50 张甲骨文原始拓片图像进行文字自动识别，并以适当结果呈现。

二、模型假设及符号说明

2.1 模型假设

1. 我们认为，所有的数据来源于权威的原始数据，并且这些数据都是真实可靠的。
2. 假设在神经网络预测中，输入变量作为网络的第一层合理有效。

2.2 符号说明

符号	含义
Y_i	甲骨文图像矩阵
X_i	图像低秩公共部分
E_i	图像稀疏差异部分
N_i	图像噪声部分
$\ \cdot\ _{w,*}$	加权核范数
w	矩阵 X 中第 i 个奇异值所对应的权重向量
$\sigma_i(X_i)$	X_i 的第 j 个奇异值
σ_n^2	图像噪声方差
θ	残差块标准差
H_w	Wiener 滤波器
$i(x,y)$	照射分量
$r(x,y)$	反射分量
D_0	理想高通滤波器的截止频率

三、问题分析

3.1 问题一的分析

对于问题一，即对给定的三张甲骨文原始拓片图像进行图像预处理，实现对甲骨文图像干扰元素的判别和处理。首先需要利用所给三张甲骨文图像，分析出甲骨文原始拓片图像存在的常见干扰情况及图像噪声类型。原始拓片图像中可能包含各种噪声，如灰尘、划痕等，需要通过适当的降噪技术减少这些影响。同时，由于拍摄条件和拓片材质的差异，图像的亮度和对比度可能不均匀，需进行调整以便更好地突出文字信息。甲骨上还可能存在非文字的干扰。针对以上不同情况，基于数字图像处理相关方法进行图像的去噪和增强，去除图像中的干扰元素，实现图像的去噪和增强。

3.2 问题二的分析

问题二聚焦于甲骨文原始拓片图像的自动单字分割任务，旨在构建一种高效且精确的甲骨文图像分割模型。这一任务本质上属于图像分割的范畴，但与传统的图像分割任务相比，它呈现出不同的任务需求。

传统的图像分割任务侧重于识别并区分图像中的不同部分，如人物、汽车等对象。从技术层面分析，这要求算法能够根据不同语义信息将像素点进行归类，以区分出具有相同语义的区域。然而，在甲骨文图像分割任务中，情况有所不同。根据题目所提供的训练集与对应的标注框信息，如图所示，我们发现这些标注框均为平行矩形框，这与目标检测任务中的边界框（bounding box）类似。因此，本任务的要求也更倾向于目标检测，即不仅需要检测到甲骨文的存在，还需确认其是否属于甲骨文，并给出相应的检测框，以确保文字能够完整地分割出来。



图 1 字符分割示例

综上，甲骨文原始拓片图像的自动单字分割任务不仅具有图像分割的基本特性，还融合了目标检测的元素，对模型的准确性和效率提出了更高的要求。因此，构建一个能够适应这些要求的模型是本文的主要研究目标。鉴于甲骨文原始拓片图像的特点，决定采用目标检测领域中表现出色且经广泛验证的 YOLOv5 算法来解决本问题中的甲骨文

图像分割任务。YOLOv5 算法以其出色的性能、高准确性和实时处理能力而著称，能够很好地适应甲骨文图像分割的需求。

3.3 问题三的分析

问题三需要采用问题二中建立模型对附件中的甲骨文原始拓片图像进行单字分割。我们在问题二中已经完成了对网络模型的训练，只需要将图像输入网络即可获得甲骨文字符的坐标，再将 YOLO 的标注格式转化成所需格式，即可得到字符分割结果。

3.4 问题四的分析

问题四需要利用训练集中已经标注的 76 类甲骨文字形实现对测试集中 50 张甲骨文原始拓片图像的自动识别。在利用问题二和问题三所建立的甲骨文字符分割模型对拓片图像进行分割后，字符的识别任务转化为字符的分类任务。

因此，选择多种不同卷积神经网络模型进行字符分类，并对比分类精度；再利用 YOLO 网络实现甲骨文字符识别，对比并分析两种网络模型的性能。

本文的解题思路如下图所示：




图 2 本文解题思路思维导图

四、问题一的模型建立与求解

4.1 甲骨文原始拓片图像主要干扰因素及噪声分析

根据附件一中给出的三幅甲骨文原始拓片图像，可以分析出影响甲骨文图像分割和文字识别的主要影响因素有以下 4 点：

1.文字目标小^[4]。三幅图像均为大尺寸图片，包含了一整片较大的龟甲或兽骨，长和宽均为 300 像素以上，其中共计包含 50 余个字符目标，每一个字符均为几十个像素的小目标。这造成甲骨文符所占区域相对较小，且小目标居多，会带来检测困难。

2.图像条件差异较大。由于甲骨文图像的来源广泛，图像获取的手段不同，造成甲骨文图像的直方图差异较大。

3.字形缺损。由于掩埋环境与私掘等原因，有许多出土的甲骨片已经破碎，存在较大裂痕仍，而部分裂痕经过甲骨文字符，使字形变得残缺，具体如图 3 的(a)。除此之外，许多甲骨片表面出现磨损，字形变得较难辨认，例子如图 3 的(b)所示。另外，由于年代久远等原因，甲骨片表面出现许多类似甲骨文字的痕迹，这种划痕容易与甲骨文字混淆，导致错误检测，具体样例如图 3 的(c)所示。

4.噪点干扰。由于灰尘、甲骨自身不平整或破损，导致甲骨图像中存在大量噪点，影响字符的识别。




图 3 甲骨文图像噪声及干扰因素示例

4.2 基于稀疏表示和低秩逼近的去噪算法

对于图像 y 中的一个图像块 y_i ，利用块匹配算法可以找到与 y_i 具有非局部自相似性

的图像块集合，然后将这些集合叠加成一个相似性矩阵 Y_i ，则样本图像可表示为^[5]：

$$Y_i = X_i + N_i \quad (1)$$

其中 X_i 和 N_i 分别为无噪图像和噪声相应块集合组成的矩阵。在噪声较大的情况下，可能会得到不太相似的块作为相似块。由于噪声的影响，本来较远的图像块可能被错误地归为相似块并分到同一组，而本应接近的相似块却因噪声扰动而被错误地认为是不相似，因此排除在相似集合之外。因此，这些匹配的块之间存在一些差异，并非完全相似。当噪声较大时可能获得不太相似的相似块。所以对于任意的甲骨文图像矩阵 $Y_i \in R^{m \times n}$ ，我们可以将其分解成低秩公共部分 $X_i \in R^{m \times n}$ ，稀疏差异部分 $E_i \in R^{m \times n}$ 和噪声部分 $N_i \in R^{m \times n}$ ，即：

$$Y_i = X_i + E_i + N_i, \text{rank}(X_i) \leq \min(m, n) \quad (2)$$

核范数最小化（NNM）模型有效地近似了低秩矩阵^[6]，作为其扩展，加权核范数最小化（WNNM）模型则被进一步提出：

$$\hat{X}_i = \arg \min_{X_i} \frac{1}{\sigma_n^2} \|Y_i - X_i\|_F^2 + \|X_i\|_{w,*} \quad (3)$$

$$\|X\|_{w,*} = \sum_i |w_i \sigma_i(X)| \quad (4)$$

式中， $\|X\|_{w,*}$ 矩阵 X 的加权核范数， $w = [w_1, \dots, w_n]^T$ ($w_i \geq 0$) 为矩阵 X 中第 i 个奇异值所对应的权重向量，显然，求解模型的关键在于对权重向量 w 的计算。一般，奇异值越大可以被认为更加接近无噪图像，所以对于 X_i 的第 j 个奇异值的权重应与其自身的大小成反比：

$$w_j = c\sqrt{n} / (\sigma_j(X_i) + \varepsilon) \quad (5)$$

$$\hat{\sigma}_j(X_i) = \sqrt{\max((\sigma_j^2(Y_i)) - n\sigma_n^2, 0)} \quad (6)$$

其中， $c > 0$ 和 ε 为常数， n 是 Y_i 中相似块的数目， $\sigma_i(X_i)$ 是 X_i 的第 j 个奇异值， $\sigma_i(Y_i)$ 是 Y_i 的第 j 个奇异值， σ_n^2 是图像噪声方差。

在实验中发现，相似图像块多存在于图像的平滑区域（如甲骨文原始拓片图像的非字符区域），因为其结构简单，采用上述低秩逼近方法能够有效去除平滑区域中的噪声。但非平滑区域（如甲骨文原始拓片图像的字符区域）结构复杂，仅采用 WNNM 算法会

造成图像原始信息的较大损失。所以，首先对所有图像块进行高斯去噪，将原始图像块与高斯去噪图像块作差获得残差图，并利用以下公式对图像块进行分类：

$$y = \text{sgn}(\sqrt{\sigma^2 + 16} - \theta) \quad (7)$$

其中， θ 是残差块标准差。若 $y \neq 1$ ，则说明该图像块为熵较小的平滑块， $y=1$ 为熵较大的含有纹理特征的非平滑块。

对于非平滑块，还需要对其中存在的稀疏差异部分 $E_i \in R^{m \times n}$ 进行计算。假设 H_w 是 Wiener 滤波器，对于一个一维离散的含噪模型，有：

$$v(i) = u(i) + n(i), 1 \leq i \leq N \quad (8)$$

其中 N 为信号长度，则估计为 $\hat{u} = H_w v$ ，即使 $MSE = E(\|u - \hat{u}\|_2^2)$ 最小。

$$\begin{cases} H_w = \arg \min E \{ \|H_w v - u\|_2^2 \} \\ MMSE = \min E \{ \|\hat{u} - u\|_2^2 \} \end{cases} \quad (9)$$

假设噪声是均值为 0 的加性高斯噪声，求解上述优化问题可最终得到：

$$H_w = \frac{\sigma_u^2}{\sigma_u^2 + \sigma_n^2} \quad (10)$$

按照 $S_i = U_s \Sigma_s V_s^T$ 将相似性矩阵 $S_i = [s_{i,1}, \dots, s_{i,n}] \in R^{m \times n}$ 进行奇异值分解：

$$S_i = [u_1, \dots, u_m] \begin{bmatrix} D_{m \times n} & 0_{m \times (n-m)} \end{bmatrix} [v_1, \dots, v_n]^T = \sum_{j=1}^m W^j \quad (11)$$

$$W^j = \sigma_j(S_i) Z^j$$

式中 $\sigma_j(S_i)$ 表示矩阵 S_i 的第 j 个奇异值，且在字典下 $Z_j = u_j v_j^T \in R^{m \times n}$ 的表示系数。由于奇异值可以表征相似性矩阵相应特征的强弱，而且具有很强的能量集中特性，通过 Frobenius 范数计算信号在方向上 Z_j 的能量分布：

$$\|W^j\|_F^2 = \langle W^j, W^j \rangle = (\sigma_j(S_i))^2 \langle Z^j, Z^j \rangle = (\sigma_j(S_i))^2 \quad (12)$$

同时将 S_i 按列展开：

$$s_{i,k} = \sum_{j=1}^m W_k^j = \sum_{j=1}^m c_{j,k} u_j, c_{j,k} = \sigma_j(S_i) v_{k,j} \quad (13)$$

上式中 $\{u_1, \dots, u_j\}$ 是一组正交基， $c_{j,k}$ 表示第 k 个样本在 u_j 方向上的投影系数。由于信号与噪声是非相关的，可以通过以下方式对无噪信号方差进行估计：

$$\sigma_0^2 = (\sigma_s^2 - \sigma_n^2)_+ \quad (14)$$

式中 σ_s^2 表示含噪图像方差, σ_n^2 表示噪声方差。当减去均值后, 相似图像块 $s_{i,k}, k=1, \dots, n$ 在方向 $\{u_1, \dots, u_j\}$ 上的投影系数 $\{c_{j,k} = \sigma_j(S_i) v_{k,j}\}_{k=1}^n$ 服从均值为 0、方差为 $\sigma_{j,s}^2$ 的高斯分布, 则:

$$\sigma_{j,s}^2 = \frac{\sum_{k=1}^n (c_{j,k} - \bar{c}_j)^2}{n} = \frac{(\sigma_j(S_i))^2 \sum_{k=1}^n (v_{k,j})^2 + n(\bar{c}_j)^2}{n} = \frac{(\sigma_j(S_i))^2}{n} + (\bar{c}_j)^2 \quad (15)$$

已知 $\bar{c}_j = 0$, 我们采用相应的维纳滤波器^[4]:

$$w(j) = \frac{(\sigma_{j,s}^2 - \sigma_n^2)_+}{\sigma_{j,s}^2} = \frac{((\sigma_j(S_i))^2 - n\sigma_n^2)_+}{(\sigma_j(S_i))^2} \quad (16)$$

综上, 对于任意甲骨文原始拓片图像, 进行非局部块匹配, 在搜索窗内寻找 y_i^n k 个最相似的图像块, 即得到集合 $\{y_{ij}^n, j=1, \dots, k\}$, 建立相似性矩阵 S_i 。将相似性矩阵 S_i 分解成 3 部分: $S_i = A_i + M_i + N_i$, 其中 A_i 是低秩公共部分, M_i 是稀疏差异部分, N_i 是对应噪声。当图像块为非平滑块时, 利用 WNNM 算法提取最平滑的公共低秩部分 A_i , 然后将获得的具有结构信息的残差矩阵 $S_i - A_i$ 进 PCA 变换, 得到系数集合 $\{a_{ij}^n, j=1, \dots, k\}$, 之后对 PCA 系数进行式 (16) 所示的阈值收缩, 得到逼近真实信息的 PCA 系数, 并对获得的稀疏系数进行逆变换, 得到逼近差异矩阵 M_i 的组估计, 即得到不含噪声的相似集合数据的差异信息, 最后将低秩去噪结果与差异信息融合, 得到非平滑块的去噪结果。

基于稀疏表示和加权核范数的甲骨文图片去噪算法流程如图 4 所示:




图 4 基于稀疏表示和加权核范数的甲骨文图片去噪算法

4.3 甲骨文原始拓片图像预处理模型的建立

在 4.1 中,我们分析了甲骨文原始拓片图像预处理过程中需要解决的四个主要问题,即文字目标小、图像条件差异较大、字形缺损和噪点干扰。4.2 中所提出的算法主要解决了由于甲骨表面磨损等造成的图像噪声,但经过实验发现,经过处理的图像仍然存在图像亮度过低、字符边缘模糊、部分笔画间断等情况,如图 5 所示,因此还需要进行进一步的图像处理。




图 5 甲骨文图像去噪后对比

4.3.1 同态滤波图像增强

为了解决图像亮度过低问题,我们采用同态滤波^[8]实现灰度图像的增强。同态滤波是在频域对图像增强的方法,利用滤波算法减弱低频部分,增强高频部分,来减少光照变化和使边缘锐化、细节突出。对于图像 $f(x,y)$ 可由照射分量 $i(x,y)$ 和反射分量 $r(x,y)$ 的乘积表示,即:

$$f(x,y) = i(x,y)r(x,y) \quad (17)$$

其中, $i(x,y)$ 表示照射分量,代表描述景物照度的信息,变化较慢,可以看作是图像的低频部分; $r(x,y)$ 表示反射分量,代表景物细节的信息,变化较快,可以看作是图像的高频部分。因为 $i(x,y)$ 和 $r(x,y)$ 是相乘的关系,首先需要对 f 进行对数运算,分离出与 $i(x,y)$ 和 $r(x,y)$ 的相关分量,从而才能对其进行傅里叶变换和频域处理。即令:

$$z(x,y) = \ln f(x,y) = \ln i(x,y) + \ln r(x,y) \quad (18)$$

对 $z(x,y)$ 进行傅里叶变换可以得到:

$$Z(u,v) = F_i(u,v) + F_r(u,v) \quad (19)$$

然后对 $Z(u,v)$ 进行高通滤波处理，在频域即为 $Z(u,v)$ 与高通滤波函数 $H(u,v)$ 相乘：

$$\begin{aligned} S(u,v) &= H(u,v)Z(u,v) \\ &= H(u,v)F_i(u,v) + H(u,v)F_r(u,v) \end{aligned} \quad (20)$$

由于高通滤波器会抑制低频部分，则滤波后会提取出高频部分 $r(x,y)$ 对应的对数频域分量，再进行傅里叶逆变换，有：

$$s(x,y) = IDFT(S(u,v)) \quad (21)$$

最后利用指数运算可以得到图像 $g(x,y)$ ，即为处理后的图像：

$$g(x,y) = e^{s(x,y)} = i_0(x,y) + r_0(x,y) \quad (22)$$

其中 $i_0(x,y)$ 和 $r_0(x,y)$ 分别为处理后的图像的照射分量和入射分量。

同态滤波的基本流程如下图所示：




图 6 同态滤波算法示意图

4.3.2 图像边缘增强

针对图像去噪后边缘模糊的问题，我们采取在去噪前后分别使用 Laplace 算子和理想高通滤波对图像中的边缘信息进行增强，实现图像的锐化。

(1) 基于 Laplace 算子的图像增强

图像 Laplace 变换是基本图像增强算法,原始图像通过 Laplace 变化后会增强图像中灰度突变处的对比度,使图像中的细节部分得到增强并保留了图像的背景色调,图像的细节比原始图像更加清晰。图像 Laplace 变换的基本理论依据是 Laplace 算子。Laplace 算子是最简单的各项同性微分算子,具有旋转不变性。一个二维图像的 Laplace 算子是各项同性的二阶导数,定义为：

$$\nabla^2 f(x,y) = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2} \quad (23)$$

该方程的离散形式为：

$$\nabla^2 f(x,y) = [f(x+1,y) + f(x-1,y) + f(x,y+1) + f(x,y-1)] - 4f(x,y) \quad (24)$$

Laplace 算子的实现模板如下:

0	1	0
1	-4	1
0	1	0

我们在图像进行去噪操作前,先对其进行 Laplace 变换,以减小去噪过程对边缘信息的影响。

(2) 理想高通滤波

高通滤波器的功能是让高频率通过而滤掉或衰减低频,其作用是使图像得到锐化处理,突出图像的边界。一般情况下,高通滤波对噪声没有任何抑制作用,而理想高通滤波器甚至有可能在图像增强的过程中将噪声放大。因此,我们在图像去噪后使用理想高通滤波器对图像进行滤波,实现对图像边缘信息的进一步增强。

理想高通滤波器的产生公式为:

$$H(u,v)=\begin{cases} 0, D(u,v)\leq D_0 \\ 1, D(u,v)> D_0 \end{cases} \quad (25)$$

其中 D_0 为理想高通滤波器的截止频率。

4.3.3 甲骨文原始拓片图像预处理模型

针对 4.1 中提出的甲骨文原始拓片图像的主要干扰因素和噪声,我们在 4.2 节去噪算法的基础上,建立甲骨文原始拓片图像预处理模型,如图所示:




图 7 甲骨文原始拓片图像预处理模型

对于获得的甲骨文原始拓片图像，首先进行 Laplace 变换，对其边缘信息进行增强；然后采用基于稀疏表示和加权核范数最小化的去噪算法，对图像进行去噪处理；针对去噪后带来的图像对比度减弱和边缘模糊的问题，进行同态滤波和高斯滤波进行补偿，最终得到预处理后的甲骨文图像。

4.4 甲骨文原始拓片图像预处理

4.4.1 图像预处理评价指标

图像质量的评价方法主要分为主观评价方法和客观评价方法：

(1) 主观评价方法

主观评价法，是基于人眼直接观察预处理后的图像的主观意见对图像质量做出好和差的区分。由于人眼是一个复杂且特殊的成像系统，其对于所观察到的颜色、形状、空间位置等有较强的捕捉力，因此，通过主观评价能够判断出图像间以上方面存在的差异。

(2) 客观评价方法

客观评价方法是通过设计特定的算法计算预处理后图像的一些指标，定量的计算出评价值。所采用的指标，一般均是基于模拟仿真人眼视觉的数学模型所设计的。在计算

时完全采用数学方式，与主观评价依赖观察者不同，因此可信度较高，并可以通过计算机实现高效准确的处理。

我们在这里采用归一化均方误差（NMSE）和峰值信噪比（PSNR）两个指标对预处理后图像进行评价。

归一化均方误差是一种基于能量归一化的测量方法，它相对均方误差是将分母的大小变成了原始图像的各个像素的平方和，其值越小表示图像质量越好，表达式为：


$$NMSE = \frac{\sum_{i=1}^M \sum_{j=1}^N [g(i, j) - \hat{g}(i, j)]^2}{\sum_{i=1}^M \sum_{j=1}^N [g(i, j)]^2} \quad (26)$$

峰值信噪比用于表示图像最大可能像素值（255）与影响其表示的保真度的破坏噪声的功率之间的比率，其值越大代表图像质量越好，表达式为：

$$PSNR = 10 \lg \left[\frac{255^2 \times M \times N}{\sum_{i=1}^M \sum_{j=1}^N [g(i, j) - \hat{g}(i, j)]^2} \right] \quad (27)$$

4.4.2 图像预处理与结果分析

利用 4.3 节中建立的图像预处理模型，对附件一中的三幅甲骨文图像进行预处理，得到的结果如图所示：



(a)



2060

(b)



(c)



(d)



(e)



(f)

图 8 甲骨文原始拓片图像预处理结果

从图中可以明显看出,三幅图像中所存在的白色噪声点得到了有效去除,同时,字符的笔画结构更加清晰。表中给出了三幅图像预处理后的指标。

表 1 甲骨文原始拓片图像预处理指标对比

	NMSE	PSNR
H02060.jpg	0.0239	18.2727
w01637.jpg	0.0193	19.2477
w01870.jpg	0.0122	20.7986

五、问题二的模型建立与求解

5.1 基于 YOLOv5 的甲骨文字符分割模型

5.1.1 YOLOv5 网络模型

目标检测算法中以深度学习为基准的主要有两大类：

（1）基于区域策略的两阶段（two-stage）目标检测算法是一种分阶段的检测方法，其核心思想是将检测任务分解为粗略提取候选框和精细化的检测过程。该方法的代表性算法包括 RCNN 系列。

（2）基于回归框架的检测与识别算法属于一种直接从卷积神经网络输出预测边界框及对象类别概率的一阶段（one stage）目标检测算法。这类算法的出现显著提升了检测速度。其中，主要代表包括 YOLO 系列和 SSD。

YOLO（You Only Look Once）^[9]是首个基于深度学习的一阶段检测器，由 R. Joseph 等人于 2015 年提出。与以往的“提案检测+验证”方式不同，YOLO 将输入图像分割成多个区域，并同时预测每个区域的边界框和类别概率。这种端到端的检测方法实现了每秒 45 帧的检测速度，具备高度实时性，可用于视频检测。

YOLOv5 网络是近年来在目标检测领域引起广泛关注的一种实时目标检测算法。它继承了 YOLO 系列算法的核心思想，即通过一个单独的神经网络来直接预测目标物体的边界框和类别概率，实现了高效的检测速度和优秀的检测精度。

YOLOv5 网络在架构设计上进行了多项创新。它采用了更加先进的特征提取网络，通过引入深度残差连接和注意力机制等技巧，有效提升了网络对复杂特征的提取能力。同时，YOLOv5 还引入了多尺度特征融合策略，使得网络能够更好地适应不同尺寸的目标物体，提高了检测的准确性。

在训练和优化方面，YOLOv5 也做出了诸多改进。它采用了更加高效的损失函数，能够更好地平衡分类损失和定位损失，使得网络在训练过程中能够更快地收敛到最优解。此外，YOLOv5 还采用了数据增强和模型剪枝等技术，进一步提升了网络的泛化能力和计算效率。




图 9 YOLOv5 网络模型

5.1.2 YOLOv5 网络结构及关键技术

5.1.2.1 输入端

(1) Mosaic 数据增强

YOLOv5 在输入端采用了 Mosaic 数据增强，Mosaic 数据增强算法将多张图片按照一定比例组合成张图片，使模型在更小的范围内识别目标。Mosaic 数据增强只算法参考 CutMix 数据增强算法 CutMix 数据增强算法使用两张图片进行拼接，而 Mosaic 数据增强算法一般使用四张进行拼接，但两者的算法原理是非常相似的。

Mosaic 数据增强的主要步骤为：

- 随机选取图片拼接基准点坐标(xc, yc)，另随机选取四张图片；
- 四张图片根据基准点，分别经过尺寸调整和比例缩放后，放置在指定尺寸的大图的左上，右上，左下，右下位置；
- 根据每张图片的尺寸变换方式，将映射关系对应到图片标签上；
- 依据指定的纵横坐标，对大图进行拼接。处理超过边界的检测框坐标；

采用 Mosaic 数据增强的方式可以实现丰富数据集、增强模型鲁棒性、加强批归一化层(Batch Normalization)的效果，有利于提升小目标检测性能。

（2）自适应锚框计算

在 YOLOv5 中，每次训练开始之前，都会根据不同的数据集来自适应计算不同训练集中的最佳锚框值。自适应的计算具体过程如下：

- a. 获取数据集中所有目标的宽和高；
- b. 将每张图片中按照等比例缩放的方式到指定大小，保证宽高中的最大值符合指定大小；
- c. 将 bboxes 从相对坐标改成绝对坐标，这里乘以的是缩放后的宽高；
- d. 筛选 bboxes，保留宽高都大于等于两个像素的 bboxes；
- e. 使用 k-means 聚类三方得到 n 个 anchors；
- f. 使用遗传算法随机对 anchors 的宽高进行变异。倘若变异后的效果好，就将变异后的结果赋值给 anchors；如果变异后效果变差就跳过，默认变异 1000 次。这里是使用 anchor_fitness 方法计算得到的适应度 fitness，然后再进行评估。

（3）自适应图片缩放

在目标检测算法中，不同的图片的长宽都不相同，因此常用的方式是将原始图片统一缩放到一个标准尺寸，再送入检测网络中。

原始的缩放方法存在着一些问题，在实际的使用中的很多图片的长宽比不同，缩放填充之后，两端的黑边大小都不相同，然而如果填充的过多，会存在大量的信息冗余，从而影响整个算法的推理速度。为了进一步提升 YOLOv5 的推理速度，自适应图片缩放能够自适应的添加最少的黑边到缩放之后的图片中。

5.1.2.2 骨干网络(Backbone)

（1）Focus 结构

Focus 模块是在图片进入 Backbone 前，对图片进行切片操作，具体操作是在一张图片中每隔一个像素取一个值，类似于邻近下采样，这样可以得到四张图片，四张图片互补，但是没有信息丢失。这样，将 W、H 信息就集中到了通道空间，输入通道扩充了 4 倍，即拼接起来的图片相对于原先的 RGB 三通道模式变成了 12 个通道，最后将得到的新图片再经过卷积操作，得到没有信息丢失情况下的二倍下采样特征图。

（2）CSP 结构

CSPNet 主要是将 feature map 拆成两个部分，一部分进行卷积操作，另一部分和上一部分卷积操作的结果进行联接。在 YOLOv5 中，设计了两种 CSP 结构，以 YOLOv5s 网络为例，CSP1_X 结构应用于 Backbone 主干网络，而 CSP2_X 结构则应用于 Neck 中。

5.1.2.3 颈部网络 (Neck)

YOLOv5 的颈部网络（Neck）采用 FPN+PAN 的结构，使用 CSPNet 设计的 CSP2 结构，从而加强了网络特征融合能力。FPN-PAN 结构如下图所示，FPN 层自顶向下传达强语义特征，而 PAN 塔自底向上传达定位特征：




图 10 FPN-PAN 结构图

5.1.2.3 头部网络（Head）

（1）Bounding box 损失函数

YOLOv5 采用 CIOU_LOSS 作为 bounding box 的损失函数，图 11 损失函数相关概念中给出了损失函数的相关概念。





图 11 损失函数相关概念

CIOU_LOSS 的表达式为:

$$\begin{aligned} CIOU_Loss &= 1 - CIOU \\ &= 1 - \left(IOU - \frac{Distance_2^2}{Distance_C^2} - \frac{v^2}{(1 - IOU) + v} \right) \end{aligned} \quad (28)$$

$$IOU = \frac{A}{B} \quad (29)$$

$$v = \frac{4}{\pi^2} \left(\arctan \frac{w_g}{h_g} - \arctan \frac{w_p}{h_p} \right)^2 \quad (30)$$

其中, v 是衡量长宽比一致性的参数, w_g, h_g 是真实框的宽和高, w_p, h_p 是预测框的宽和高。CIOU_Loss 将重叠面积、中心点距离, 长宽比这三个目标框回归函数需要考虑的重要几何因素全部体现在损失函数的计算中, 使得损失函数具有更强的鲁棒性。

(2) NMS 非极大值抑制

NMS 的本质是搜索局部极大值, 抑制非极大值元素。非极大值抑制, 主要就是用来抑制检测时冗余的框。在目标检测中, 在同一目标的位置上会产生大量的候选框, 这些候选框相互之间可能会有重叠, 所以需要利用非极大值抑制找到最佳的目标边界框,

消除冗余的边界框。其主要步骤如下：

- 对所有预测框的置信度降序排序；
- 选出置信度最高的预测框，确认其为正确预测，并计算他与其他预测框的 IOU；
- 根据步骤 2 中计算的 IOU 去除重叠度高的， $\text{IOU} > \text{threshold}$ 阈值就直接删除；
- 剩下的预测框返回第 1 步，直到没有剩下的为止。

5.2 基于 YOLOv8 的甲骨文字符分割模型

5.2.1 YOLOv8 网络模型

图 12 中给出了 YOLOv8 的网络结构，从中可以看出，其延用了 YOLOv5 的网络结构思想，包括基于 CSP(紧凑和分离)的骨干网络(backbone)和 Neck 部分的设计，以及对于不同尺度模型的考虑。




图 12 YOLOv8 网络模型

5.2.2 YOLOv8 较 YOLOv5 的网络改进

相较于 YOLOv5，YOLOv8 在网络结构上的改进主要在以下几个方面：

(1) Backbone 的改进:使用 C2f 模块代替 C3 模块，进一步轻量化，同时保持了 CSP 的思想，并采用了 SPPF 模块；

(2) PAN-FPN 的改进：保留了 PAN 的思想，但删除了上采样阶段中的卷积结构，同时将 C3 模块替换为 C2f 模块；

(3) Decoupled-Head 的引入：采用了 Decoupled-Head 的思想，使得网络的训练和推理更加高效；

(4) Anchor-Free 的思想：抛弃了 Anchor-Base，采用了 Anchor-Free 的思想；

(5) 损失函数的改进：采用 VFLLOSS 作为分类损失，同时使用 DFLLoss 和 CIOU Loss 作为回归损失；

(6) 样本匹配方式的改进：采用了 Task-Aligned Assigner 匹配方式。

这些改进使得 YOLOv8 在目标检测方面具有更高的精度和更快的速度，同时保持了轻量化的特点。具体来说，YOLOv8 的 Backbone 部分使用了 C2f 模块来替代了 YOLOv5 中的 C3 模块，实现了进一步的轻量化。同时，它也保留了 YOLOv5 等架构中使用的 SPPF(空间金字塔池化)模块。在 PAN-FPN(路径聚合网络-特征金字塔网络)部分，虽然 YOLOv8 依旧采用了 PAN 的思想，但是在结构上，它删除了 YOLOv5 中 PAN-FPN 上采样阶段中的卷积结构，并将 C3 模块替换为了 C2f 模块。这些改进使得 YOLOv8 在保持了 YOLOv5 网络结构优点的同时，进行了更加精细的调整和优化提高了模型在不同场景下的性能。

5.3 基于 YOLO 网络的甲骨文图像分割

5.3.1 甲骨文图像分割流程

对于甲骨文字符分割任务，我们首先对附件二中的所有甲骨文原始拓片图像采用第四章中所提出的图像预处理模型进行图像去噪和增强；然后为了运用 YOLO 网络实现甲骨文字符的检测，需要将附件二中所给标注转化为 YOLO 标注格式；接下来，将所给数据划分成训练集和验证集，并将数据送入 YOLO 网络进行训练；最终，我们将会得到训练好的甲骨文字符检测模型，输出结果为检测框位置；我们再根据检测框对每一幅图像进行分割，即可完成甲骨文的分割任务，具体流程在图 13 中给出：




图 13 甲骨文字符分割流程

5.3.2 数据预处理

5.3.2.1 图像预处理

(1) 无标注图像清理

在将图片送入网络进行训练前，数据集的预处理是很关键的一步。预处理的效果直接影响着网络模型的学习能力与最终的训练效果。首先，我们通过对数据集中的图像及其对应的标注进行检查得知，图像与标注文件的数量存在不一致的情况，部分图像缺乏相应的标注信息，这导致这些无标注的图像无法送入网络进行训练。

为了构建图像与标注严格对应的数据集，我们使用 Python，查找出数据集中那些无标注的图像，并对这些图像进行删除操作。通过这一步骤，我们确保了数据集中每一幅图像都拥有与之匹配的标注信息，保证了后续有效的网络训练。Python 程序的删除过程

如图 14 所示：

```
Deleted ../1/images\b026886J.jpg
Deleted ../1/images\b02870F.jpg
Deleted ../1/images\b02878F.jpg
Deleted ../1/images\b02883.jpg
Deleted ../1/images\b03727.jpg
Deleted ../1/images\b04000F.jpg
Deleted ../1/images\b04002F.jpg
Deleted ../1/images\b04022F.jpg
Deleted ../1/images\b04053F.jpg
Deleted ../1/images\b04059F.jpg
Deleted ../1/images\b04061F.jpg
Deleted ../1/images\b040876J.jpg
Deleted ../1/images\b04088.jpg
Deleted ../1/images\b04095.jpg
```

图 14 无标注图像删除过程

(2) 图像数据去噪增强

数据集中甲骨文原始拓片图像的质量参差不齐，包含有大量噪声、划痕、裂痕的干扰，严重影响了 YOLO 网络对于字符的检测。因此，在将图像数据送入网络前，对所有图像按照图 7 模型中的流程进行去噪增强操作，为后续的工作提供有利条件。

5.3.2.2 标注转化

本文中所给出的标注为平行矩形框，并且每个框用两个坐标表示（矩形的左上顶点和右下顶点）。它的标注 json 文件如下：`{"img name":"w01906","ann":[[111.0,1970,152.0,257.0,1.0], [108.0,283.0,157.0335.0,1.0]]}`。其中“img name”表示标注对应的图像，“ann”表示图像上的标注。“ann”中前四个数字为对应的坐标；末位为校验位，表示其是否为甲骨字：“1.0”表示为甲骨文，“0.0”表示其不是甲骨文。

而我们要将甲骨文图像送入 YOLO 网络进行训练，就需要将标注转化为 YOLO 标注格式，这种格式将每个目标表示为一个矩形边界框，并提供与该边界框相关的类别信息。标注数据通常存储在文本文件中，每行对应一个目标，并包含以下信息：

1.类别标签（Class Label）：每个目标对象所属的类别，用整数表示。这些整数通常从 0 开始递增，对应于数据集中不同类别的索引。

2.边界框坐标（Bounding Box Coordinates）：边界框的位置和大小信息，通常采用相对于图像尺寸的归一化坐标表示。这些归一化坐标包括边界框中心的 x 和 y 坐标，以及边界框的宽度和高度。例如，(x_center, y_center, width, height)。


在 YOLO 标注格式中，每个目标对象的标注数据通常以一行文本的形式存储，不同

值之间用空格或逗号分隔。

所以我们使用 python 首先进行标注文件的转化,程序如附录所示;首先,使用 Python 中的 PIL 库来获取图像的宽度和高度信息。这个步骤非常重要,因为后续的 YOLO 格式需要将边界框的位置信息进行归一化处理,而归一化的计算需要用到图像的宽度和高度。

接下来,我们定义了一个函数 `convert_to_yolo`,用于将原始的标注信息转换为 YOLO 格式。在这个函数中,我们遍历每个目标对象的标注信息,包括目标对象的边界框坐标 (`x_min`、`y_min`、`x_max`、`y_max`) 以及类别索引。然后,我们根据 YOLO 格式的要求,计算出边界框的中心坐标 (`x_center`、`y_center`) 以及宽度和高度 (`bbox_width`、`bbox_height`),并将这些信息组织成一个列表,并添加到 YOLO 格式的标注列表中。

最后,我们遍历存储标注信息的 JSON 文件夹中的所有文件,并读取每个文件中的标注信息。然后,我们调用 `convert_to_yolo` 函数将原始的标注信息转换为 YOLO 格式,并将结果保存为 txt 文件。每个 txt 文件的命名与对应的图像文件相同,以便于后续的模型训练和评估。YOLO 标注的 txt 文件如图 15 所示:



```
b02698.txt - 记事本
文件(F) 编辑(E) 格式(O) 查看(V) 帮助(H)
0 0.2 0.39272030651340994 0.14246575342465753 0.2950191570881226
0 0.3561643835616438 0.3103448275862069 0.12054794520547946 0.13793103448275862
0 0.38493150684931504 0.5421455938697318 0.14520547945205478 0.28735632183908044
0 0.5095890410958904 0.42911877394636017 0.1095890410958904 0.3524904214559387
0 0.5328767123287671 0.6781609195402298 0.0958904109589041 0.038314176245210725
```

图 15 YOLO 标注文件示例

5.3.2.3 数据集划分

我们首先将数据集划分为训练集和验证集,由于模型的构建过程中也需要检验模型的配置,以及训练程度是过拟合还是欠拟合,所以会将训练数据再划分为两个部分,一部分是用于训练的训练集,另一部分是进行检验的验证集。

训练集用于训练得到神经网络模型,然后用验证集验证模型的有效性,挑选获得最佳效果的模型。验证集可以重复使用,主要是用来辅助我们构建模型的。最后,当模型“通过”验证集之后,我们再使用测试集测试模型的最终效果,评估模型的准确率,以及误差等。

在问题二中由于数据集数量较少,在大部分训练时未设置单独的测试集,训练集和验证的比例分别设置为“8: 2”,“7: 3”,在经过完整训练后我们将验证集看作测试集,最后测试一遍训练出模型的精度。

5.3.3 模型训练

我们选择了广泛应用的 YOLOv5 网络与最新提出的 YOLOv8 网络,针对 v5 网络,

选择了其中最为先进的 v5x 模型，针对 v8 网络，则综合考虑了不同复杂度和性能的模式，最终选择了 v8n、v8m 以及 v8l 这三个网络模型。针对选择的不同的模型，我们在划分好的不同比例的数据集上训练，并且通过不断调整超参数来优化训练效果，具体的训练的软件和硬件环境如表 2 所示：

表 2 训练环境	
软件或硬件	技术参数
操作系统	Windows 10
处理器（CPU）	Intel Xeon Silver 6226R
显卡（GPU）	NVIDIA GeForce 4090
内存（Memory）	128G
Python	Python 3.9.17
Pytorch	Pytorch 1.12.1

5.3.4 模型的对比与评估

5.3.4.1 8：2 数据集下模型的对比与评估

首先我们选择了 v5x 模型来进行训练。未经图像预处理的情况下，模型就达到了较高的训练精度。然而，此时模型参数量巨大，达到了 220GFLOPs，这导致了训练时间的显著增长。此外，模型占用的存储空间也达到了 140mb，一定程度上限制了该模型在资源有限环境中的应用。

为了寻求参数量与性能之间的平衡，选择了更为先进的 v8 网络系列，选择了参数量较少的 v8n 模型。虽然相较于 v5x 模型，v8n 的精度略有下降，但其参数量大幅减少至 8.7GFLOPS，模型占用空间也缩减至仅 17.9mb。在保持一定性能的同时，显著降低了模型的复杂度和资源占用。

此外，我们还尝试了参数量更大的 v8l 模型，其效果与 v8n 相近，但参数量有所增加。这进一步验证了 v8 网络系列在参数量与性能之间的灵活调整能力。

在之前的实验中，我们统一选择了 640 作为网络图像的输入大小。这是因为在训练 YOLO 模型时，需要确保输入图像具有一致的尺寸。然而，为了更深入地探索网络精度与输入甲骨文图像大小之间的关系，我们尝试增加网络的复杂度同时降低网络输入图像大小为 320。结果显示，在选择 v8m 模型时，精度降低到只有 0.85 左右，效果较差。但当输入图像大小增加至 640 时，精度又回升至 0.89 附近。这表明，输入图像大小为 640 时既保证了检测精度，又确保了网络不会过于复杂。

由于我们的甲骨文字在拓片图像中呈现出小目标的特性，所以我们引入针对小目标检测的损失函数 SIOU 来提高小目标检测精度。SIOU (Smoothed Intersection over Union)

函数是一种用于目标检测任务中评估检测框预测的精确度的方法。它基于 IoU (Intersection over Union) 度量，但引入了平滑因子以提高对小目标的鲁棒性。通常情况下，对于小目标，由于其尺寸较小，预测的检测框可能与真实框之间的重叠区域相对较小，这可能导致 IoU 度量的不稳定性。SIOU 函数通过引入平滑因子，对 IoU 进行平滑处理，从而在一定程度上减少了这种不稳定性，提高了对小目标的检测性能。

由训练精度图可以看到在经过图像预处理与损失函数改进后，所训练模型 **v8m-640-pro-siou** 的精度达到了 0.90，效果最佳。图 16 展示了上述模型的训练精度：




图 16 网络训练精度

表 3 网络参数量对比

网络模型	模型参数量(GFLOPs)	权重大小(Mb)
v5x-640	220.4	140.0
v8n-640	8.7	17.9
v8l-640	165.2	85.5
v8m-320	78.9	50.7
v8m-640	78.9	50.7
v8m-640-pro	78.9	50.7
v8m-640-pro-siou	78.9	50.7

图 17 和图 18 展示了 v5x 模型与预处理并添加损失函数后的 v8m 模型在部分验证集上的检测结果，可以看到在 b03239.jpg 图像上，针对左侧的半损的甲骨文图像，**v8x** 展现了更好的检测质量；并且在 b03759.jpg 图像上，也检测到了 v5x 未识别的甲骨文字。

在 b02656.jpg 上，v8m 与 v5x 检测到的模型数量相同，检测区域也近似，但在置信度上，v8m 模型检测的置信度更高，检测质量也更精确。



图 17 v5x-640 模型测试结果




图 18 v8m-640-pro-siou 测试结果

5.3.4.2 7：3 数据集下模型的对比与评估

为进一步探究训练精度停滞在 0.89 附近的原因，我们推测是否是训练集划分比例过大，导致训练模型过拟合，所以在验证集上的精度表现不高，对此我们进一步划分数据集，训练集与验证集比例增大至 7：3，并选择了 5.3.4.1 中权衡了精度与参数量的 v8m 模型，继续使用 SIOU 损失函数，并对图像进行预处理。从训练精度图 19 中可以看到，精度达到了 0.906，相较于 5.3.4.1 有了大概 0.01 的提升。




图 19 7: 3 数据集网络训练精度

图 20 为验证集原始甲骨文标注图像，图 21 为训练模型测试结果图，可以看到针对大部分甲骨文字，实现了准确的检测，并未出现误检的情况。然而，在图 **b03887.jpg** 与 **b04723.jpg** 中，我们注意到原始标注存在偏移现象。因为验证集的标注框是由转换后的 YOLO 格式进行标注的，为进一步验证是转化错误的问题还是原始标注的问题，我们编写 python 程序进行了验证。




图 20 验证集原始标注




图 21 模型测试结果

我们使用 python 程序读取了原始图片与原始标注点，并在图片上绘制出了相应的标注框，结果显示是数据集的标注出现了错误，所以我们推测我们训练模型精度无法进一步大幅度提高的原因可能是受到了原始标注错误的影响。




图 22 标注错误情况示例

5.3.4.3 7：2：1 数据集下模型的对比与评估

最后为了排除测试集未设置对训练精度提升可能产生的影响，我们按 7：2：1 的比例划分了训练集、验证集与测试集，从训练精度图中可以看出，相较于 5.3.4.2 中的训练结果，网络精度下降了 0.1 左右。




图 23 7： 2： 1 数据集网络训练精度

从模型测试结果图中可以看到，我们发现模型在大多数情况下能够准确检测出甲骨文字。然而，在针对图 b02752.jpg 中带有偏旁的文字时，模型却将一个字错误地检测成了两个字，这显示出模型在部分复杂情况下的拟合程度仍然欠佳。鉴于这一情况，我们在本小节中排除了测试集对训练精度提升可能产生的影响。




图 24 验证集原始标注





图 25 模型测试结果

六、问题三的建立模型与求解


在经过问题二的模型训练后，我们选择出权衡了精度与模型参数量的 v8m-640-pro-siou 网络模型，对第三问给出测试集的图像进行检测分割并给出相应的分割框，最终给出分割框的形式如图 26 所示，1 代表了类别，后边四位为 YOLO 标注格式的(x_center, y_center, width, height)，我们需要将分割框转化成左上角顶点坐标与右下角顶点坐标的形式，我们编写了相应的 python 程序（附录所示）实现了该功能。附件三中字符检测结果如图 27 所示。




(a)标注格式转换前


(b)标注格式转换后

图 26 标注格式转换






(d)



(e)



(f)

图 27 附件三中字符检测结果示例

七、问题四的模型建立与求解

针对第四问中甲骨文原始拓片图像文字自动识别任务，采用两种方法进行训练和验证，分别是基于卷积神经网络的图像分类算法和基于 YOLOv8 算法的图像分类方法。要完成对测试集中 50 张图片的自动文字识别，利用第二问和第三问中建立的 YOLOv8 目标检测模型对测试集图像文字进行检测，同时分割出对应的图片。通过观察测试集样本，对训练集样本进行了适当的扩充。用两种方法各自训练好的网络模型对测试集文字进行识别，并保存结果。整体思路如所示。




图 28 问题四处理流程

7.1 基于卷积神经网络的甲骨文字符识别模型

7.1.1 卷积神经网络

CNN，即卷积神经网络（Convolutional Neural Network），是一种常用于图像和视频处理的深度学习模型。与传统神经网络相比，CNN 有着更好的处理图像和序列数据的能力，因为它能够自动学习图像中的特征，并提取出最有用的信息。

CNN 的一个核心特点是卷积操作，它可以在图像上进行滑动窗口的计算，通过滤波器（又称卷积核）和池化层（Max Pooling）来提取出图像的特征。卷积操作可以有效地减少权重数量，降低计算量，同时也能够保留图像的空间结构信息。池化层则可以在不改变特征图维度的前提下，减少计算量，提高模型的鲁棒性。CNN 的典型结构包括卷积层、池化层、全连接层等。同时，为了防止过拟合，CNN 还会加入一些正则化的技术，如 Dropout 和 L2 正则等。

7.1.2 典型卷积神经网络

（1）AlexNet

AlexNet 由 Alex Krizhevsky 等人于 2012 年提出，是第一个在 ImageNet 图像分类比赛中取得优异成绩的卷积神经网络模型。它采用了多个卷积层和池化层，使用了 ReLU 激活函数和 Dropout 正则化技术。AlexNet 主要具有以下特点：

- 更深的网络结构;
- 使用层叠的卷积层，即卷积层+卷积层+池化层来提取图像的特征;
- 使用 Dropout 抑制过拟合;
- 使用数据增强 Data Augmentation 抑制过拟合;
- 使用 Relu 替换之前的 sigmoid 的作为激活函数;
- 多 GPU 训练。

AlexNet 的网络结构如图 29 所示:





图 29 AlexNet 网络结构

(2) VGG-16

VGG 由 Karen Simonyan 和 Andrew Zisserman 于 2014 年提出，其主要贡献是提出了使用更小的卷积核（3x3）来代替较大的卷积核。这种设计使得网络更深，而且参数量更少，从而提高了效率和准确率。VGG-16 包含了 16 个卷积层和池化层，这些层都采用了相同的卷积核大小和步长。VGG 主要具有以下特点：

- 结构简洁，其网络结构如



图

30 所示;




图 30 VGG-16 网络结构

- b. 小卷积核和连续的卷积层;
- c. 小池化核, 使用的是 2×2 ;
- d. 通道数更多, 特征度更宽;
- e. 层数更深;
- f. 全连接转卷积。

(3) GooleNet

GooleNet 是由谷歌的工程师设计的一种先进的深度神经网络结构。这种设计的显著特点是其网络不仅深度显著, 还在横向上展现出了“宽度”。此外, GooleNet 采用了一种称为 Inception 的核心子网络结构来增强其处理能力, 有效地优化了计算资源的利用, 并提高了识别精度。




图 31 Inception 子网络结构示意图

GooleNet 网络是 Inception v1 网络的一种，共有 22 层，采用全局平均池化层来代替后面的全连接层，在最后的参数变得更少，其网络结构如图 32 所示：




图 32 GooleNet 网络结构

GooleNet 的特点主要体现在以下几个方面：

- 引入 Inception 结构。引入的 Inception 融合了不同尺度的特征信息，能得到更好的特征表征，更意味着提高准确率，不一定需要堆叠更深的层或者增加神经元个数等，可以使用更稀疏但是更精密的结构达到很好的效果；
- 使用 1x1 的卷积核进行降维映射处理，降低了维度也减少了参数量；
- 添加两个辅助分类器帮助训练，可以有效避免梯度消失，用于向前传导梯度，也有一定的正则化效果，防止过拟合；
- 使用全局平均池化。用全局平均池化代替全连接层大大减少了参数量；
- 使用 1*n 和 n*1 卷积核并联代替 n*n 卷积核。在不改变感受野同时减少参数的情况下，采用 1*n 和 n*1 的卷积核并联来代替 n*n 的卷积核，这能够有效发掘特征图的高的特征，以及特征图的宽的特征。

(4) ResNet

虽然 GoogleNet 已经达到了较好的效果，但是网络太深无法很好训练的问题还是没有得到解决，直到在 2015 年，何恺明推出 ResNet 在 ISLVR 和 COCO 上超越所有选手，获得冠军。该网络在网络结构上做出了一大创新，即采用残差网络结构，而不是简单的堆积层数。残差网络的核心思想是：经过两个连续的卷积层得到输出，同时输入时绕到下一层去，如图 33 所示：




图 33 残差结构示意图

通过引入 Shortcut, Identity 恒等映射，相当于一个梯度高速通道，可以更容易地避免梯度消失的问题，所以，可以得到很深的网络。现有的 ResNet 网络结构如图 34 所示：

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	7×7, 64, stride 2				
		3×3 max pool, stride 2				
conv2_x	56×56	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$
conv3_x	28×28	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 8$
conv4_x	14×14	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 23$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 36$
conv5_x	7×7	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$
	1×1	average pool, 1000-d fc, softmax				

图 34 ResNet 网络结构

7.2 甲骨文字符识别

7.2.1 数据集扩充

问题四中训练数据共有 76 类，通过观察测试集发现，50 张甲骨文原始拓片图像中较高频次出现了“王”字，但是训练集 76 种汉字中并没有“王”这个字。因此针对第四问，我们在给定的原始训练集基础上进行了数据扩充，加入了“王”字甲骨文拓片图像。甲骨文数据集以及网页可搜索到的“王”字甲骨文数据图片，共 40 张图片^[10]。

将整个原始数据集划分为训练集和验证集，比例为 7: 3。新添加的“王”字甲骨文拓片图像训练集和验证集展示如下图 35 所示。




图 35 扩充的“王”字甲骨文拓片图像

7.2.2 基于卷积神经网络的甲骨文字符识别

整个卷积神经网络训练+验证原始数据并对测试集进行预测的流程如图 36 所示：




图 36 卷积神经网络方法处理流程图

在实验前，首先对原始训练数据进行预处理，详细预处理信息如表 4 所示。为了探究训练集与验证集的划分比例对分类精度的影响，在此选用 AlexNet 网络，分别在训练集：验证集比例为 7:3 和 8:2 时进行对比实验。训练精度、验证精度、训练损失以及验证损失对比结果如图 37 所示。

表 4 数据集信息

数据集	76 种甲骨文图像数据集
图像位深	24
数据集划分比例	随机 7:3
训练集数据量	28419
测试集数据量	12225
图片统一尺寸	[112,112]
输送入网络前预处理	标准化预处理




图 37 不同数据集划分比例分类性能对比。(a) 分类精度对比；(b) 分类损失对比。


详细的分类精度和损失函数值见表 5。

表 5 数据集信息

数据集划分比例	7:3	8:2
训练精度	1	1
验证精度	0.8245	0.8199
训练损失	0	0
验证损失	0.7496	0.7638

由图 37 和表 5 可得，当数据集比例为 7:3 时，分类精度更高，因此选取的数据集划分比例为 7:3。

选定好数据集比例后，选取六种网络进行训练+验证，对比分类精度选取一个分类性能最好的网络模型。六种网络分别是，AlexNet、VGG16、GoogleNet、ResNet18、ResNet50 和 ResNet152。得到的分类精度结果如图 38 所示。






图 38 不同网络分类性能对比。(a) 训练精度对比；(b) 训练损失对比；(c) 验证精度对比；(d) 验证损失对比。

详细的分类精度和损失函数值见表 6。

表 6 数据集信息

数据集划分比例	AlexNet	VGG16	GoogleNet	ResNet18	ResNet50	ResNet152
训练精度	1	1	0.9994	0.9998	0.9997	0.9996
验证精度	0.8245	0.9256	0.9372	0.9097	0.9148	0.9167
训练损失	0	0.000149	0.0031	0.00247	0.00236	0.00326
验证损失	0.7496	0.3601	0.2796	0.3929	0.3703	0.3503

由图 38 和表 6 可得，发现在传统的经典卷积网络中，VGG16、GoogleNet、ResNet18、ResNet50 和 ResNet152 网络均能实现较高精度的分类任务，验证集分类精度都在 0.9 以上。特别是 GoogleNet，分类精度可达 0.9372，达到了一个较好的性能。因此选用 GoogleNet 对测试集进行文字自动识别。

前面介绍到数据集扩充问题，第四问中训练数据共有 76 类，通过观察测试集发现，50 张甲骨文原始拓片图像中较高频次出现了“王”字，但是训练集 76 种汉字中并没有“王”这个字。因此针对第四问，我们在给定的原始训练集基础上进行了数据扩充，加入了“王”字甲骨文拓片图像，共 40 张图片。同样，将整个原始数据集划分为训练集和验证集，比例为 7: 3。扩充数据集详细信息见表 7。

表 7 扩充数据集信息

数据集	77 种甲骨文图像数据集
图像位深	24
数据集划分比例	随机 7:3
训练集数据量	28447
测试集数据量	12237
图片统一尺寸	[112,112]
输送入网络前预处理	标准化预处理

为了探究扩充数据集后对分类精度的影响，在此选用分类精度最好的 **GoogleNet** 网络，分别在原始 76 类数据集和扩充后的 77 类数据集上时进行对比实验。训练精度、验证精度、训练损失以及验证损失对比结果如图 39 所示。




图 39 同数据集分类性能对比。(a) 分类精度对比；(b) 分类损失对比。

详细的分类精度和损失函数值见表 8。

表 8 数据集信息

数据集	原始 76 类	扩充 77 类
训练精度	0.9994	0.9995
验证精度	0.9372	0.9353
训练损失	0.0031	0.0038
验证损失	0.2796	0.2978

由图 39 和表 8 可得，发现在扩充数据集后，**GoogleNet** 网络仍然能实现较高精度的分类任务，相比于 76 类分类任务，验证精度有点降低，但是仍然高达 0.9353，达到了一个较好的性能。因此选用 **GoogleNet** 对测试集进行文字自动识别。

7.2.3 基于 YOLOv8 的甲骨文字符识别

在 YOLO 算法中不仅可以实现目标检测任务，还可以实现分类任务，我们分别针对原始数据集与扩充后的数据集进行训练，训练结果如图所示，可以看到 YOLOv8 的分类精度较高与上一小节的卷积神经网络，在 76 类数据集上达到了 0.945 的验证精度，在 77 类数据集上达到了 0.946 的训练精度，均为最优。




图 40 数据集分类性能对比

7.2.4 训练模型测试

7.2.4.1 卷积神经网络测试

测试集中的一张原始甲骨文拓片并不是单个文字，而是包含多个文字，因此无法直接将整个拓片图像放进训练好的网络中预测。因此必须对测试集中的原始拓片进行分割处理。在此选用第二问中所训练好的 **YOLO** 分割模型，对图片进行分割处理。一共 50 张甲骨文原始拓片，针对每一张图片建立一个文件，每个文件里是分割后的单个文字图片集合。建立的目录图片如图 41 所示。在此用 0、1 和 2 文件夹中分割后的图像与原始拓片进行对比展示。如图 42(a)(b)(c)所示。






图 41 图像分割测试机目录



(a)



(b)



(c)

图 42 分割后图像与原始拓片对比图

将分割后的图像测试集输送到网络中识别，得到文字识别结果。在此展示文件夹 0、1 和 2 对应的预测结果。通过 Python 编程直接将结果保存在对应文件夹下的.txt 文件。具体程序详见附录问题 4。预测结果如图 43(a)(b)(c)所示。(77 类文字标签 0-75 对应汉字为：'北'，'宾'，'丙'，'并'，'乘'，'束'，'从'，'夙'，'夫'，'福'，'光'，'何'，'化'，'获'，'及'，'吉'，'艰'，'降'，'焦'，'介'，'今'，'口'，'老'，'立'，'寮'，'令'，'鹿'，'帽'，'门'，'莫'，'牡'，'木'，'牧'，'逆'，'牝'，'羌'，'丘'，'囚'，'取'，'人'，'入'，'若'，'丧'，'生'，'爽'，'巳'，'田'，'兔'，'万'，'往'，'微'，'涎'，'兄'，'

央', '羊', '伊', '衣', '疑', '以', '艺', '亦', '翌', '翼', '印', '雍', '余', '御', '元', '允', '灾', '旻', '旨', '陟', '穉', '祝', '宗', '王')



图 43 部分结果预测图

卷积神经网络全部预测结果如下表 9 所示：

表 9 卷积神经网络预测结果

0	59:艺 19:介 50:微
1	12:化 54:羊 63:印 21:口 33:逆
2	59:艺 20:今 13:获 33:逆 3:并
3	65:余 39:介
4	32:牧 20:王 54:羊 20:王 39:人 25:令 63:印
5	25:令 59:艺 14:及 25:令 74:祝 13:获 14:及 56:衣
6	14:及 21:口 5:束 74:祝 54:羊 1:宾 12:化
7	32:牧 25:令 33:逆 20:王 7:凤 35:羌 12:化 44:爽 38:取 25:令

8	32:牧 32:牧 74:祝 13:获 50:微 40:入 33:逆 44:爽 54:羊 25:令 54:羊 7:凤 54:羊 13:获 13:获 60:亦 54:羊 14:及
9	59:艺 54:羊 33:逆 32:牧 54:羊 13:获
10	25:令 65:余 6:从 12:化 56:衣
11	32:牧 14:及 54:羊 21:口 35:羌 25:令 74:祝 40:入
12	32:牧 54:羊 33:逆 14:及 59:艺 12:化 25:令 20:王 35:羌
13	32:牧 56:衣 62:翼 54:羊 35:羌
14	25:令 12:化 13:获 12:化 32:牧 12:化
15	14:及 54:羊 59:艺 25:令 20:王 35:羌 54:羊
16	35:羌 54:羊 52:兄 35:羌 50:微 20:王 32:牧
17	33:逆 39:人 20:今 70:昃 25:令 14:及 45:巳 13:获 44:爽 14:及 32:牧 35:羌
18	12:化 20:王 54:羊 32:牧
19	5:束 35:羌 58:以 20:王 33:逆 54:羊
20	35:羌 27:帽 20:王
21	54:羊 30:牡 35:羌 32:牧
22	25:令 38:取 74:祝 54:羊 32:牧 25:令 74:祝
23	14:及 13:获 25:令 20:王
24	32:牧 20:王 13:获 38:取
25	59:艺 20:王 12:化 13:获 12:化
26	44:爽 33:逆 32:牧 13:获
27	54:羊 12:化 14:及 14:及 14:及 3:并
28	13:获 19:介 14:及 65:余 35:羌 25:令 63:印
29	32:牧 14:及 74:祝 13:获 13:获
30	74:祝 13:获 35:羌 14:及 63:印
31	56:衣 32:牧 59:艺 42:丧 13:获 54:羊 33:逆
32	32:牧 13:获 30:牡 63:印 25:令
33	39:人 33:逆 32:牧 13:获 54:羊 13:获 13:获 13:获 14:及 21:口 38:取
34	31:木 35:羌 65:余 13:获 50:微
35	32:牧 20:王 13:获 63:印 33:逆
36	32:牧 35:羌 13:获 30:牡 35:羌
37	32:牧 35:羌 33:逆 14:及 56:衣 14:及
38	20:王 13:获 59:艺 56:衣 33:逆 25:令 65:余
39	0:北 33:逆 12:化 14:及
40	20:王 13:获 12:化 13:获
41	20:王 13:获 30:牡
42	13:获 33:逆 54:羊 20:王 32:牧
43	63:印 33:逆 12:化
44	38:取 13:获 21:口 13:获 12:化 13:获 37:囚 54:羊 14:及 35:羌
45	59:艺 13:获 20:王 35:羌
46	12:化 74:祝 14:及 54:羊 13:获 33:逆 14:及
47	45:巳 76:王 35:羌 20:令 39:人 35:羌

八、模型的评价

8.1 模型优点

(1) 在分析了甲骨文原始拓片图像的特点后，总结出了主要干扰因素和噪声源，提出了甲骨文图像的去噪模型，能够有效地处理由于人为或自然因素造成的甲骨文图像质量下降，提升后续字符分割和识别的效率。

(2) 采用 YOLO 系列网络对甲骨文字符进行先检测后分割，利用 YOLO 网络的目标检测能力实现对甲骨文字符的精准检测，提高分割精度。

(3) 卷积神经网络能够对已知甲骨文字符进行较好的识别，同时根据所给图像，新增“王”这一字符类别，扩充训练数据，进一步提升检测精度。

8.2 模型缺点

(1) 在图像预处理的过程中仍然会造成一部分甲骨文字符笔画的缺失。

(2) 基于深度学习的甲骨文字符分割和识别需要大量的标注数据做训练。

参考文献

- [1] 高旭.基于卷积神经网络的甲骨文识别研究与应用[D].吉林大学,2021.[2] [3]
- [2] Yabing S. Manifold and splendid: 120 Years of research on the oracle bone inscriptions and Shang history[J]. Chinese Studies in History, 2020, 53(4): 351-368.
- [3] 宋传鸣,乔明泽,洪飏.边缘梯度协方差引导的甲骨文字修复算法[J].辽宁师范大学学报(自然科学版),2023,46(02):194-207.
- [4] 王浩彬.基于深度学习的甲骨文检测与识别研究[D].华南理工大学,2019.
- [5] 王成钢,孔斌,张彩露.基于稀疏表示与加权核范数最小化的图像去噪算法[J].软件导刊,2019,18(06):75-79.
- [6] ISHMANOV FARRUH, MALIK AAMIR SAEED, KIM SUNG WON, et al. Trust management system in wireless sensor networks: design considerations and research challenges [J] . Transactions on Emerging Telecommunications Technologies, 2015, 26 (2) : 107-130.
- [7] 印新棋, 吴军, 莫伟伟, 等. WMNs 中基于节点可信度的机会路由改进算法 [J] . 计算机科学, 2017, 44 (8) : 151-156.
- [8] https://blog.csdn.net/qq_44111805/article/details/126331664?ops_request_misc=%257B%2522request%255Fid%2522%253A%2522171300344616777224443355%2522%252C%2522scm%2522%253A%252220140713.130102334..%2522%257D&request_id=171300344616777224443355&biz_id=0&utm_medium=distribute.pc_search_result.none-task-blog-2~all~top_click~default-1-126331664-null-null.142^v100^control&utm_term=%E5%90%8C%E6%80%81%E6%BB%A4%E6%B3%A2%E5%A2%9E%E5%BC%BA%E5%9B%BE%E5%83%8F&spm=1018.2226.3001.4187
- [9] Redmon J, Divvala S, Girshick R, et al. You Only Look Once: Unified, Real-Time Object Detection[C]// Computer Vision & Pattern Recognition. IEEE, 2016.
- [10] https://download.csdn.net/download/weixin_44906759/86780029?utm_source=bbsseo