

队伍编号	MC2402447
题号	(C)

基于 LSTM-ARIMA 和整数规划的货量预测与人员排班模型

摘要

随着电商物流的发展，网络购物等活动的兴起，分拣中心作为物流运输的关键一环，提高其管理效率对降低运营成本，提高物流行业的运作效率，提升总体竞争力有着至关重要的作用。本文根据不同问题的信息与约束条件，运用一系列方法，得到了较合理的货量预测及人员排班结果。

对于问题一，预测 57 个站点未来 30 天每天及每小时的货量，我们针对附件 1 和附件 2 的时间序列数据的特点，分别建立了 **LSTM 神经网络模型**与 **ARIMA 模型**。先对附件 1 的数据进行了数据预处理，利用 **LSTM 神经网络模型**，对每个站点货量进行预测，得到未来 30 天的货量预测，详见结果表 1。再对附件 2 的数据进行数据处理，利用 **ARIMA 模型**对每个站点货量进行预测，得到未来 30 天每小时的货量预测，详见结果表 2。

对于问题二，在问题 1 预测的数据基础上，通过对变化运输路线的分析，将变化路线上的货量按比例向相关分拣中心进行重新分配，获得对应货量**变化率**，依据货量变化率对分拣中心的**货量预测模型**进行优化。根据优化后的模型得到各分拣中心未来 30 天每天和每时的货量预测结果，详见结果表 3 和结果表 4。

对于问题三，基于问题 2 的预测数据，根据**整数规划**对各分拣中心的人员排班最优问题建立数学模型，设立目标为**最小化总人天数**。建立处理货物量约束、人员优先使用约束、小时人效均衡性约束等**约束条件**，对目标进行分析，利用简单的**任务分配算法**对该整数线性规划模型进行求解，得到未来 30 天各分拣中心每个班次正式工和临时工的出勤人数，详见结果表 5。

对于问题四，在问题 2 的货量预测基础上，分析特定分拣中心 SC60，依据**多目标规划**对 SC60 的人员排班最优问题建立数学模型，设立两个子目标为最小化总人天数和均衡正式工出勤率。建立处理货物量约束、出勤率约束、连续出勤天数约束等**约束条件**，对两个子目标进行分析，利用**遗传算法**得到 SC60 未来 30 天的正式工和临时工出勤计划，详见结果表 6。

关键词：LSTM、ARIMA、整数规划、多目标规划、遗传算法

目录

一、问题重述	1
1.1 背景知识	1
1.2 问题描述	1
二、问题分析	2
2.1 对问题一的分析	2
2.2 对问题二的分析	2
2.3 对问题三的分析	2
2.4 对问题四的分析	3
三、模型假设	3
四、符号说明	4
五、问题一模型的建立与求解	4
5.1 数据预处理	4
5.2 基于 LSTM 的日货量预测模型	6
5.3 日货量预测模型的求解	7
5.4 基于 ARIMA 的时货量预测模型	9
5.5 时货量预测模型的求解	11
六、问题二模型的建立与求解	12
6.1 数据匹配	12
6.2 变化路线的分析	13
6.3 货量变化率的计算	15
6.4 货量预测模型的修正	17
七、问题三模型的建立与求解	19
7.1 数据可视化	19
7.2 基于整数规划的人员排班模型	19
7.3 人员排班模型的求解	21
八、问题四模型的建立与求解	22
8.1 基于遗传算法的多目标规划模型	22
8.2 多目标规划模型的求解	24
九、模型评价与推广	26
9.1 模型的优点	26
9.2 模型的缺点	26
9.3 模型的推广	26
十、参考文献	27
十一、附录	28

一、问题重述

1.1 背景知识

面对消费者对快递服务的巨大需求和更高的服务质量的要求，我国快递企业面临着成本升高和服务质量不能满足需求的问题，发展遇到了一些瓶颈^[1]。这表明，当前快递企业分拣中心的管理满足不了日益增长的业务需求，必须予以优化和改造。而随着物流行业及社会需求的不断发展，商品的多元化、交换频率及流通周期的快速化趋势明显，其中包含大规模的电子商务^[2]。在电子商务物流网络中，分拣中心的作用至关重要。一方面，分拣中心需要处理大量来自供应商的货物，并根据目的地、优先级等不同要求进行分类和分发；另一方面，分拣中心还需要处理消费者端的退货和换货，这些要求使得分拣中心需要具备高效和准确的操作能力。

在电商物流网络的分拣中心，货量预测和人员排班的优化至关重要。准确的货量预测可以帮助企业有效安排运输资源、减少库存成本，并提高服务水平。同时，优化人员排班需要考虑员工的技能水平、工作时间、工作量等因素，既要提高工作效率，又要降低成本，并确保分拣中心的正常、高效运转。预测货量、优化和改进人员排班管理，是帮助电商物流网络提高运营效率、减少耗费成本、提升服务质量的有效途径^[3]。因此，建立合适的模型来处理这些问题，对于电商物流行业具有重要意义。

1.2 问题描述

问题 1：建立一个货量预测模型，用于预测 57 个分拣中心未来 30 天每天和每小时的货量。将预测结果记录在结果表 1 和表 2 中。

问题 2：附件 3 展示了过去 90 天各分拣中心之间的各运输线路平均货量情况。如果未来 30 天分拣中心之间运输线路的变化（具体见附件 4），利用附件 1-4 的数据，对 57 个分拣中心未来 30 天每天和每小时的货量进行预测，并将预测结果记录在结果表 3 和表 4 中。

问题 3：假设每个分拣中心有 60 名正式工，在人员安排时优先使用正式工，如果额外需要人员时使用临时工。请基于问题 2 的预测结果建立模型，给出在未来 30 天内，每个分拣中心每个班次的出勤人数，并记录在结果表 5 中。要求在每天货量处理完成的前提下，尽量减少安排的人天数（例如 30 天每天出勤 200 名员工，总人天数为 6000），并确保每天的实际小时人效尽量均衡。

问题 4：针对 SC60 分拣中心的排班问题的排班问题，假设分拣中心 SC60 目前有 200 名正式工，基于问题 2 的预测结果建立模型，确定未来 30 天每名正式工和临

时工的班次出勤计划。具体来说，即给出未来 30 天每天六个班次中，每名正式工将在那些班次出勤，每个班次需要雇佣多少临时工，并记录在结果表 6 中。每名正式工的出勤率（出勤天数除以总天数 30）不超过 85%，且连续出勤天数不超过 7 天。在保证每日货量处理完成的前提下，尽量减少安排的人天数，并且保持每天的实际小时人效和正式工的出勤率尽量均衡。

二、问题分析

2.1 对问题一的分析

将数据按分拣中心进行分组，提取历史数据中的特征，如每日货量、每小时货量、运输线路情况等，同时考虑其他可能影响货量的因素，如节假日、促销活动等，进行数据清洗。由于需要预测的两个量：日货量和时货量有不同的特征，我们使用不同的模型来求解。对于日货量预测，由于其具有时间序列的周期性与依赖性，我们使用 LSTM 时间序列预测模型，将附件 1 中过去 4 个月的每天货量数据和附件 2 中过去 30 天的每小时货量数据作为训练数据对模型进行训练，评估检验每个模型的性能，然后利用训练好的模型对每个分拣中心分别预测未来 30 天的日货量；对于小时货量预测，由于其具有短时间的季节性与周期性，我们使用 ARIMA 模型，再通过选择合适的模型参数分别预测未来 30 天的时货量。

2.2 对问题二的分析

根据附件 3 和附件 4 中的数据，考虑过去 90 天各分拣中心之间的运输线路情况及未来 30 天分拣中心之间的运输线路的变化，分析线路变化对货量的潜在影响。基于问题一中建立的货量预测模型，对每个分拣中心继续使用时序预测模型。在模型中加入考虑运输线路变化对货量预测的影响，调整模型参数以适应新的线路情况。对于某条线路货量的变化，调整相关分拣中心的货量以反映这一变化。利用新旧路线货量的数据，我们计算出变化率，根据变化率对预测结果进行修正，以此实现对 57 个分拣中心未来 30 天每天货量和每小时货量的预测。

2.3 对问题三的分析

设计一个整数线性规划模型，目标函数是最小化总人天数，即所有决策变量的总和。以最大化分拣中心的效率为目的，并满足每个分拣中心的出勤限制。使用历史数据和附件 2 中的每小时货量数据，以及 57 个分拣中心的正式工、临时工人数为

决策变量，确定目标函数系数，同时考虑每个分拣中心的人员出勤情况、员工效率和工作时间等约束条件。根据历史数据和员工情况，确定每个分拣中心的最佳排班方案。

2.4 对问题四的分析

基于问题二的预测结果，计算 SC60 每个班次的货量需求。考虑正式工和临时工的最高小时人效标准，以及出勤率和连续出勤天数的限制条件，建立排班模型。在问题三的基础上，用正式工出勤率方差作为新约束条件，设计优化算法，通过模拟和调整参数，优化排班模型，以确保每天货量都能处理完成，且安排的人天数尽可能少。同时还要确保每天的实际小时人效尽量均衡，正式工出勤率尽量均衡，并满足连续出勤天数和出勤率的限制条件，从而得出未来 30 天每天六个班次中，每名正式工将在哪些班次出勤，每个班次需要雇佣多少临时工的排班计划。

三、模型假设

本文将作如下假设，以便于模型的建立与求解：

- 1、假设所给的历史货物数据均为真实数据。
- 2、假设货量的变化受历史货量、物流网络配置等内部因素和促销活动、节假日等外部因素的影响。
- 3、假设对数据中缺失值的处理方式不会对预测结果造成太大的误差。
- 4、假设历史数据符合时间序列，存在一定的季节性和周期性。
- 5、假设货量预测与运输线路的变化相关，且这种关系可通过历史数据量化。
- 6、假设每名正式工和临时工的工作效率在一定范围内波动，但都在最高小时人效标准内。
- 7、假设每名正式工和临时工每天只能出勤一个班次，且工作时间为 8 小时。
- 8、假设每个分拣中心都可以根据需求调整正式工和临时工的人数。

四、符号说明

符号	说明
r_j	货量变化率
x_{ijk}	第 <i>i</i> 个分拣中心第 <i>j</i> 天第 <i>k</i> 班次出勤的正式工人数
y_{ijk}	第 <i>i</i> 个分拣中心第 <i>j</i> 天第 <i>k</i> 班次出勤的临时工人数
D_{iJK}	第 <i>i</i> 个分拣中心第 <i>j</i> 天第 <i>k</i> 个班次的货量
a_{itk}	第 <i>i</i> 名正式工在第 <i>t</i> 天第 <i>k</i> 个班次的出勤状态
b_{itk}	第 <i>i</i> 名临时工在第 <i>t</i> 天第 <i>k</i> 个班次的出勤状态
$\min(X)$	原始样本数据的最小值
$\max(X)$	原始样本数据的最大值

五、问题一模型的建立与求解

5.1 数据预处理

对附件 1 中各个分拣中心的日货量变化情况进行可视化处理，部分分拣中心的变化情况如图 5.1 所示。




图 5.1 部分分拣中心的日货量变化情况

我们发现在 11 月初和 11 月 11 日前后货物总量急剧增加，之后又迅速回降，这种情况符合当时“双十一”的电商节活动。对于此类异常值，我们通过箱线图和三倍标准差法将其剔除，避免出现预测精度降低、过拟合等可能会影响预测结果的问题。我们将处理前后的日货量变化情况进行对比，发现处理后的数据变化幅度明显

减小。部分分拣中心的对比情况如图 5.2 所示。




图 5.2 处理前后部分分拣中心的日货量对比图

我们再把附件 2 中各个分拣中心 24 小时内每个小时的货物量进行求和，以此得到时货量，将各个分拣中心的时货量变化情况进行可视化处理，如图 5.3 所示。




图 5.3 各个分拣中心的时货量变化情况

由上图可知，在 24 小时内，货量最低值通常出现于早上 6 时—8 时，之后时货量呈上升趋势，并在下午 14 时前后和晚上 21 时前后达到最高值，达到最高值后开始下降。

5.2 基于 LSTM 的日货量预测模型

观察图 5.2，考虑到日货量具有时间序列的依赖性和长期性，我们选择 LSTM 模型对未来的日货量进行预测。

LSTM（长短时记忆网络）模型，本质上是一种特定形式的 RNN（循环神经网络）模型。LSTM 模型在 RNN 模型的基础上通过增加门限来解决 RNN 短期记忆的问题，使得循环神经网络能够真正有效地利用长距离的时序信息。LSTM 在 RNN 的基础结构上增加了输入门限、输出门限、遗忘门限 3 个逻辑控制单元，且各自连接到了一个乘法元件上，通过设定神经网络的记忆单元与其他部分连接的边缘处的权值控制信息流的输入、输出以及细胞单元的状态^[4]。其具体结构如图 5.4 所示。




图 5.4 LSTM 模型具体结构

LSTM 主要是利用门控机制来控制信息积累的速率，其中包含选择性地添加新的信息和选择性遗忘先前积累的信息，从而提高了 RNN 也就是时间序列数据的长期依赖性，减轻了长序列训练期间的梯度消失^[5]。LSTM 适合处理具有时间序列特性的货量数据，其网络参数表如表 5.1 所示：

表 5.1 LSTM 网络参数

参数	含义	参数	含义	参数	含义
x_t	当前时刻的输入	f_t	遗忘门控制信号	C_{t-1}	上一时刻记忆单元
$\tilde{C}_t$	信息的候选状态	i_t	输入门控制信号	C_t	当前时刻记忆单元
h_{t-1}	上一时刻外部状态	o_t	输出门控制信号	h_t	当前时刻外部状态

LSTM 神经网络共有三个门：“遗忘门”、“输入门”和“输出门”。

(1)遗忘门 f ：

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

(2)输入门 i ：

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

(3)输出门 o :

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$

(4)候选记忆细胞计算:


$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c)$$

$$C_t = f_t \times C_{t-1} + i_t \times \tilde{C}_t$$

$$h_t = o_t \cdot \tanh(C_t)$$

5.3 日货量预测模型的求解

根据上述已建立的日货物预测模型，在 Matlab 系统中使用 LSTM 工具箱进行编程求解，以时间为横轴，货量为纵轴，以图 5.5 的形式展示了分拣中心在过去 8-11 月内的货量变化情况，并对未来一个月的货量进行了预测。






图 5.5 日货量变化情况及预测图

利用 LSTM 模型，我们得到了未来一个月各个分拣中心日货量的变化情况，观察图 5.5 我们可以看出波动较明显，符合生活中的实际情况，也反映了未来的货量可能受不确定因素的影响。通过进一步地训练和优化模型，我们得出了未来 30 天的日货量预测值，预测结果填入在结果表 1 中，部分分拣中心的预测结果如表 5.2 所示。

表 5.2 部分分拣中心日货量预测结果

分拣中心	时间	预测货量	分拣中心	时间	预测货量
SC1	2023/12/1	43750	SC10	2023/12/1	38829
SC1	2023/12/2	43695	SC10	2023/12/2	38323
SC1	2023/12/3	43585	SC10	2023/12/3	37830
SC1	2023/12/4	43437	SC10	2023/12/4	37348
SC1	2023/12/5	43268	SC10	2023/12/5	36879
SC1	2023/12/6	43090	SC10	2023/12/6	36424
SC1	2023/12/7	42909	SC10	2023/12/7	35975
SC1	2023/12/8	42731	SC10	2023/12/8	35526
SC1	2023/12/9	42556	SC10	2023/12/9	35070
SC1	2023/12/10	42385	SC10	2023/12/10	34601
SC1	2023/12/11	42220	SC10	2023/12/11	34112
SC1	2023/12/12	42060	SC10	2023/12/12	33597
SC1	2023/12/13	41906	SC10	2023/12/13	33052
SC1	2023/12/14	41759	SC10	2023/12/14	32471
SC1	2023/12/15	41617	SC10	2023/12/15	31848
SC1	2023/12/16	41483	SC10	2023/12/16	31177
SC1	2023/12/17	41356	SC10	2023/12/17	30449
SC1	2023/12/18	41237	SC10	2023/12/18	29657
SC1	2023/12/19	41127	SC10	2023/12/19	28792
SC1	2023/12/20	41026	SC10	2023/12/20	27842
SC1	2023/12/21	40934	SC10	2023/12/21	26801
SC1	2023/12/22	40853	SC10	2023/12/22	25661
SC1	2023/12/23	40782	SC10	2023/12/23	24420
SC1	2023/12/24	40722	SC10	2023/12/24	23085
SC1	2023/12/25	40674	SC10	2023/12/25	21671
SC1	2023/12/26	40637	SC10	2023/12/26	20207
SC1	2023/12/27	40611	SC10	2023/12/27	18729
SC1	2023/12/28	40597	SC10	2023/12/28	17279
SC1	2023/12/29	40595	SC10	2023/12/29	15900
SC1	2023/12/30	40603	SC10	2023/12/30	14624

5.4 基于 ARIMA 的时货量预测模型

对于图 5.3 呈现的时货量的变化情况，我们发现其具有时间序列的季节性和周

期性，故选择 ARIMA 模型对未来的时货量进行预测。

ARIMA（差分自回归移动平均）模型，是一种时间序列预测方法。其基本模型有三种：自回归（AR）模型；移动平均（MA）模型以及差分自回归移动平均（ARIMA）模型。其模型结构如下：

$$(1 - B^d)W_t = \mu + \frac{1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q}{1 - \varphi_1 B - \varphi_2 B^2 - \dots - \varphi_p B^p} a_t$$

其中， $\{W_t\}$ 为研究的时间序列， p 为自回归阶数， $\varphi_1, \varphi_2, \dots, \varphi_p$ 为其参数； q 为移动平均阶数， $\theta_1, \theta_2, \dots, \theta_p$ 其参数； d 为时间序列 W_t 成为平稳之前所做的差分次数； a_t 为白噪声，表示独立扰动或称为随机误差； μ 是均值项； B 是延迟算子，即 $BW_t = W_{t-1}$ [6]。

ARIMA 模型流程如图 5.6 所示。




图 5.6 ARIMA 流程图

根据流程图知，在进行 ARIMA 预测前，我们需要将数据平稳化，若数据不平稳，则对其进行差分运算，直至数据达到平稳后再进行下一步。想要检验数据的平稳性，我们既可以直接直接观察差分后的折线图，也可以通过 ADF 单位根检验。对数据进行单位根检验，差分序列在 1% 的显著性水平下是平稳的^[7]。经检验发现 p 值过高，不符合平稳的状态，故进行差分运算，然后再次检验，发现 p 值远小于 0.01，则历史数据可以使用。

平稳性检验通过后还要进行白噪声检验，如果是白噪声，那么数据彼此之间没有任何相关性，也就意味着是一个没有记忆的序列，历史数据对未来的预测没有丝毫影响，没有分析价值，故停止分析^[8]。代入系统发现，在各阶 BP 和 LP 检验下，

p 值都小于 0.05，也就是说明检验的白噪声假设是错误的，数据为非白噪声序列，可对其进行 ARIMA 预测。

5.5 时货量预测模型的求解

基于 AIC 信息准则自动寻找最优参数，得出结果为 ARIMA (24,0,0) 模型，使用此模型进行训练和预测，得出各个分拣中心未来 30 天中每个小时的货量预测情况，如图 5.7 所示。




图 5.7 各个分拣中心未来 30 天中的时货量预测情况

部分分拣中心在选定的一天中每个小时货量预测结果如表 5.3 所示。

表 5.3 部分分拣中心一天中的时货量预测结果

中心	日期	小时	货量	中心	日期	小时	货量
SC10	2023/12/10	0	3377	SC14	2023/12/11	0	19
SC10	2023/12/10	1	2862	SC14	2023/12/11	1	8
SC10	2023/12/10	2	2497	SC14	2023/12/11	2	3

SC10	2023/12/10	3	2248	SC14	2023/12/11	3	6
SC10	2023/12/10	4	1999	SC14	2023/12/11	4	9
SC10	2023/12/10	5	1640	SC14	2023/12/11	5	13
SC10	2023/12/10	6	1088	SC14	2023/12/11	6	20
SC10	2023/12/10	7	534	SC14	2023/12/11	7	31
SC10	2023/12/10	8	285	SC14	2023/12/11	8	49
SC10	2023/12/10	9	400	SC14	2023/12/11	9	67
SC10	2023/12/10	10	713	SC14	2023/12/11	10	78
SC10	2023/12/10	11	982	SC14	2023/12/11	11	89
SC10	2023/12/10	12	987	SC14	2023/12/11	12	99
SC10	2023/12/10	13	682	SC14	2023/12/11	13	109
SC10	2023/12/10	14	213	SC14	2023/12/1	14	118
SC10	2023/12/10	15	0	SC14	2023/12/11	15	117
SC10	2023/12/10	16	0	SC14	2023/12/11	16	113
SC10	2023/12/10	17	147	SC14	2023/12/11	17	106
SC10	2023/12/10	18	1199	SC14	2023/12/11	18	97
SC10	2023/12/10	19	2479	SC14	2023/12/11	19	87
SC10	2023/12/10	20	3578	SC14	2023/12/11	20	72
SC10	2023/12/10	21	4159	SC14	2023/12/11	21	57
SC10	2023/12/10	22	4175	SC14	2023/12/11	22	44
SC10	2023/12/10	23	3858	SC14	2023/12/11	23	31

六、问题二模型的建立与求解

6.1 数据匹配

匹配附件 3 和附件 4 中的数据，确定哪些运输线路将会发生变化。对于每一条变化的线路，我们需要计算其对应的总货量。设变化的线路为 L_i ，对应的平均货量为 $Q_{i,j}$ ，则总货量 $Q_{total,i}$ 可以通过以下公式计算：

$$Q_{total,i} = \sum_{j=1}^n Q_{i,j} \quad (6.1)$$

其中 n 是线路 L_i 上分拣中心的数量， $Q_{i,j}$ 是线路 L_i 上从分拣中心 j 出发的平均货量。在附件 3 与附件 4 中使用 for 循环进行查找，寻找相同的路线并将重新匹配后删除的路线与新增的路线进行汇总。重新匹配后删除的路线如表 6.1 所示，重新匹配后新增的路线如表 6.2 所示。

表 6.1 重新匹配后删除的路线


始发分拣中心	到达分拣中心	货量	始发分拣中心	到达分拣中心	货量
SC61	SC10	228	SC28	SC4	8
SC19	SC15	336	SC36	SC47	133
SC4	SC15	15	SC24	SC5	138
SC51	SC15	12	SC18	SC51	14
SC2	SC19	356	SC39	SC60	119
SC54	SC25	182	SC55	SC7	128
SC1	SC25	254	SC36	SC8	97


表 6.2 重新匹配后新增的路线

始发分拣中心	到达分拣中心
SC5	SC4
SC38	SC6

6.2 变化路线的分析

我们发现新增路线较少，对预测结果影响较小；SC19 这个分拣中心只有单条路线，且 SC4 作为到达分拣中心和始发分拣中心各有一条线路发生变化，对预测结果影响较小，故不进行考虑；被删除的路线上对应的到达分拣中心：SC10、SC15、SC25、SC47、SC5、SC51、SC60、SC7、SC8。计算出当分拣中心的运输路线发生变化时，对应路线上其他相关路线的占比变化，如图 6.1 所示。









图 6.1 不同分拣中心对应路线上货量的占比情况

6.3 货量变化率的计算

根据图 6.1 及修正后的比例，得出不同路线分配货量后对比情况如图 6.2 所示。






图 6.2 不同路线分配货量后对比情况

由以前的货量和分配后的货量，我们可以设过去每个分拣中心的平均货量为 $Q_{p,j}$ ，其变化率 r_j 可以通过以下公式计算：

$$r_j = \frac{Q_{n,j}}{Q_{p,j}} - 1 \quad (6.2)$$

其中 $Q_{n,j}$ 是分配后的货量总和， $Q_{p,j}$ 是过去分拣中心 j 的平均货量。计算得出分拣中心及对应的货量变化率如表 6.3 所示：

表 6.3 分拣中心以及对应的变化率

分拣中心	变化率（增）
SC8	0.0467
SC5	0.1167
SC4	0.013
SC47	0.047

SC15	0.6697
SC51	0.0543
SC10	0.6264
SC25	0.485
SC7	0.0676
SC9	0.862
SC60	0.2059

6.4 货量预测模型的修正

将求得的变化率 r_j 代入到问题一中的预测结果中，得到修正后的预测结果。设分拣中心 j 原始的预测结果为 $P_{o,j}$ ，修正后的预测结果为 $P_{a,j}$ ，则 $P_{a,j}$ 可以通过以下公式计算：

$$P_{a,j} = P_{o,j} \times (1 + r_j) \quad (6.3)$$

由此得出修正后 57 个检货中心对应 30 天及每天 24 个小时的货量变化情况，部分预测结果如表 6.4 和表 6.5 所示。

表 6.4 修正后部分分拣中心对应日货量预测结果

分拣中心	时间	修正后货量预测结果
SC10	2023/12/1	38829
SC10	2023/12/2	38323
SC10	2023/12/3	37830
SC10	2023/12/4	37348
SC10	2023/12/5	36879
SC10	2023/12/6	36424
SC10	2023/12/7	35975
SC10	2023/12/8	35526
SC10	2023/12/9	35070
SC10	2023/12/10	34601
SC10	2023/12/11	34112
SC10	2023/12/12	33597
SC10	2023/12/13	33052
SC10	2023/12/14	32471
SC10	2023/12/15	31848
SC10	2023/12/16	31177
SC10	2023/12/17	30449
SC10	2023/12/18	29657
SC10	2023/12/19	28792
SC10	2023/12/20	27842

SC10	2023/12/21	26801
SC10	2023/12/22	225661
SC10	2023/12/23	24420
SC10	2023/12/24	23085
SC10	2023/12/25	21671
SC10	2023/12/26	20207
SC10	2023/12/27	18729
SC10	2023/12/28	17279
SC10	2023/12/29	15900
SC10	2023/12/30	14624

表 6.5 修正后部分分拣中心对应时货量预测结果

分拣中心	日期	小时	修正后货量预测结果
SC10	2023/12/2	0	3320
SC10	2023/12/2	1	2334
SC10	2023/12/2	2	1857
SC10	2023/12/2	3	1609
SC10	2023/12/2	4	1779
SC10	2023/12/2	5	1878
SC10	2023/12/2	6	851
SC10	2023/12/2	7	79
SC10	2023/12/2	8	0
SC10	2023/12/2	9	93
SC10	2023/12/2	10	802
SC10	2023/12/2	11	1352
SC10	2023/12/2	12	1012
SC10	2023/12/2	13	769
SC10	2023/12/2	14	453
SC10	2023/12/2	15	0
SC10	2023/12/2	16	0
SC10	2023/12/2	17	119
SC10	2023/12/2	18	1128
SC10	2023/12/2	19	2876
SC10	2023/12/2	20	4448
SC10	2023/12/2	21	4756
SC10	2023/12/2	22	4266
SC10	2023/12/2	23	4033

七、问题三模型的建立与求解

7.1 数据可视化

以月为单位对数据进行可视化处理，得到 57 个分拣中心点对应的货量汇总统计情况及不同月份的货量占全部总货量的占比情况，如图 7.1 和图 7.2 所示。




图 7.1 57 个分拣中心点对应的货量汇总统计情况




图 7.2 不同月份的货量占全部总货量的占比情况

由上图，我们从整体上大致掌握了不同分拣中心对应的总货量情况和不同时间的货量占比情况，这一可视化处理有助于后面约束条件的设置等步骤。

7.2 基于整数规划的人员排班模型

根据题目已知条件，我们需要最小化总人天数，即最小化所有分拣中心在 30 天内安排的总人数，我们通过启发式算法对这个问题进行求解。

1、确定决策变量

设 x_{ijk} 为第 i 个分拣中心第 j 天第 k 个班次的正式工数， y_{ijk} 为第 i 个分拣中心

第 j 天第 k 个班次的临时工数，其中 $i = 1, \dots, 57$; $j = 1, \dots, 30$; $k = 1, \dots, 6$ 。

2、确定目标函数

最小化总人天数为：

$$\min\{\sum_{i=1}^{57}\sum_{j=1}^{30}\sum_{k=1}^6(x_{ijk} + y_{ijk}) + \lambda\sum_{i=1}^{57}\sum_{j=1}^{30}\sum_{k=1}^6|e_{ijk} - \bar{e}_{ij}|\} \quad (7.1)$$

其中 λ 为权重系数，用以平衡总人数和小时人效均衡性，当某个班次小时人效偏离平均值过多时，我们可以增加目标函数值。 e_{ijk} 是第 i 个分拣中心第 j 天第 k 个班次的实际小时人效， $\bar{e}_{ij}$ 是第 i 个分拣中心在所有天数的平均小时人效，且有：

$$e_{ijk} = \frac{\text{班次内总货量}}{\text{总出勤人数} \times \text{班次}} \quad (7.2)$$

3、确定约束条件

(1) 完成每个时间段的货量处理：

$$x_{ijk} \times 25 + y_{ijk} \times 20 \geq \frac{D_{ijk}}{8}, \quad \forall i, j, k \quad (7.3)$$

其中 D_{ijk} 为第 i 个分拣中心第 j 天第 k 个班次的包裹量。

(2) 优先使用正式工：

$$\begin{cases} y_{ijk} = 0, \sum \left\{ \text{roundup} \left(\frac{D_{ijk}}{25 \times 8} \right) \right\} \leq 60 \\ y_{ijk} > 0, \sum \left\{ \text{roundup} \left(\frac{D_{ijk}}{25 \times 8} \right) \right\} > 60 \end{cases}, \quad \forall i, j, k \quad (7.4)$$

(3) 正式工每天不超过 60 人：

$$\sum_{k=1}^6 x_{ijk} \leq 60, \quad \forall i, j \quad (7.5)$$

(4) 正式工每天最多出勤一个班次：

$$\sum_{k=1}^6 (x_{ijk} + y_{ijk}) \leq 60 + \max y_{ijk} \quad \forall i, j \quad (7.6)$$

(5) 员工人数非负：

$$x_{ij} \geq 0, y_{ij} \geq 0, \quad \forall i, j \quad (7.7)$$

(6) 决策变量为整数：

$$x_{ijk}, y_{ijk} \in Z^+, \quad \forall i, j, k \quad (7.8)$$

4、建立排班模型

综上，基于整数规划的人员排班模型为：

$$\min\{\sum_{i=1}^{57}\sum_{j=1}^{30}\sum_{k=1}^6(x_{ijk} + y_{ijk}) + \lambda\sum_{i=1}^{57}\sum_{j=1}^{30}\sum_{k=1}^6|e_{ijk} - \bar{e}_{ij}|\} \quad (7.9)$$

$$\text{s.t.} \begin{cases} x_{ijk} \times 25 + y_{ijk} \times 20 \geq \frac{D_{ijk}}{8} \\ y_{ijk} = 0, \sum \left\{ \text{roundup} \left(\frac{D_{ijk}}{25 \times 8} \right) \right\} \leq 60 \\ y_{ijk} > 0, \sum \left\{ \text{roundup} \left(\frac{D_{ijk}}{25 \times 8} \right) \right\} > 60 \\ \sum_{k=1}^6 x_{ijk} \leq 60 \\ \sum_{k=1}^6 (x_{ijk} + y_{ijk}) \leq 60 + \max y_{ijk} \\ x_{ijk}, y_{ijk} \in Z^+ \end{cases} \quad (7.10)$$

7.3 人员排班模型的求解

根据上述模型，使用 Matlab 进行编程求解，调用整数线性规划求解器 intlinprog 来获取所需最优解，遍历每个分拣中心、每天、每个班次，最后输出安排的正式工和临时工出勤人数。部分分拣中心安排的出勤人数如表 7.1 所示。

表 7.1 分拣中心正式工人与临时工人数

分拣中心	日期	班次	正式工人数	临时工人数
SC4	2023/12/1	00:00-08:00	10	10
SC4	2023/12/1	05:00-13:00	10	10
SC4	2023/12/1	08:00-16:00	10	10
SC4	2023/12/1	12:00-20:00	10	10
SC4	2023/12/1	14:00-22:00	10	10
SC4	2023/12/1	16:00-24:00	10	10
SC4	2023/12/2	00:00-08:00	10	11
SC4	2023/12/2	05:00-13:00	10	11
SC4	2023/12/2	08:00-16:00	10	11
SC4	2023/12/2	12:00-20:00	10	11
SC4	2023/12/2	14:00-22:00	10	11
SC4	2023/12/2	16:00-24:00	10	11
SC4	2023/12/3	00:00-08:00	10	11
SC4	2023/12/3	05:00-13:00	10	11
SC4	2023/12/3	08:00-16:00	10	11
SC4	2023/12/3	12:00-20:00	10	11
SC4	2023/12/3	14:00-22:00	10	11
SC4	2023/12/3	16:00-24:00	10	11
SC4	2023/12/4	00:00-08:00	10	10
SC4	2023/12/4	05:00-13:00	10	10
SC4	2023/12/4	08:00-16:00	10	10
SC4	2023/12/4	12:00-20:00	10	10
SC4	2023/12/4	14:00-22:00	10	10
SC4	2023/12/4	16:00-24:00	10	10

八、问题四模型的建立与求解

8.1 基于遗传算法的多目标规划模型

根据题目已知条件，我们运用遗传算法和多目标整数规划进行求解。

遗传算法是一个多点并行的迭代过程，在每次迭代过程中将一组以一定的形式描述的候选解进行复制、交叉和变异操作，并对个体的适应环境能力进行评价，选取与产生后代的候选解重复上述过程^[9]。

遗传算法主要由几个部分组成：编码方式、适应度函数、遗传操作、算法终止条件。它能有效的利用历史信息来推测下一代的期望性能有所提高的寻优点集，这样反复进行，最后收敛到一个最优解^[10]。其基本流程如图 8.1 所示。




图 8.1 遗传算法基本流程

1、确定决策变量

a_{itk} 为第 i 名正式工，在第 t 天第 k 个班次的出勤状态，则：

$$\begin{cases} a_{itk} = 1, & \text{出勤} \\ a_{itk} = 0, & \text{不出勤} \end{cases} \quad (8.1)$$

b_{itk} 为第 i 名临时工，在第 t 天第 k 个班次的出勤状态，则：

$$\begin{cases} b_{itk} = 1, & \text{出勤} \\ b_{itk} = 0, & \text{不出勤} \end{cases} \quad (8.2)$$

其中 $i = 1, \dots, 200$; $t = 1, \dots, 30$; $k = 1, \dots, 30$ 。

2、确定目标函数

(1) 最小化总人天数:

$$\min\{\sum_{i=1}^{200} \sum_{t=1}^{30} \sum_{k=1}^6 a_{itk} + \sum_{i=1}^{200} \sum_{t=1}^{30} \sum_{k=1}^6 b_{itk}\} \quad (8.3)$$

(2) 均衡正式工出勤率:

$$\min(\text{var}(P_i)) \quad (8.4)$$

$$P_i = \left\{ \frac{\sum_{t=1}^{30} a_{1tk}}{30}, \frac{\sum_{t=1}^{30} a_{2tk}}{30}, \dots, \frac{\sum_{t=1}^{30} a_{200tk}}{30} \right\} \quad (8.5)$$

其中 P_i 为正式工出勤率的集合。

3、确定约束条件

(1) 完成每个班次的货量:

$$\sum_{i=1}^{200} a_{itk} \times 25 \times 8 + b_{itk} \times 20 \times 8 \geq D_{tk}, \forall t, k \quad (8.6)$$

其中 D_{tk} 为第 t 天第 k 个班次的货量。

(2) 出勤率不高于 85%:

$$\frac{\sum_{t=1}^{30} a_{itk}}{30} \leq 0.85, \forall i, k \quad (8.7)$$

(3) 连续出勤不超过 7 天:

$$\sum_{t=m}^{m+6} a_{itk} \leq 7, \forall i, k \quad (8.8)$$

(4) 每天最多出勤一个班次:

$$\sum_{k=1}^6 a_{itk} \leq 1, \forall i, t \quad (8.9)$$

4、建立规划模型

综上, 基于遗传算法的多目标规划模型为:

$$\min\{\sum_{i=1}^{57} \sum_{j=1}^{30} \sum_{k=1}^6 (x_{ijk} + y_{ijk}) + \lambda \sum_{i=1}^{57} \sum_{j=1}^{30} \sum_{k=1}^6 |e_{ijk} - \bar{e}_{ij}|\} \quad (8.10)$$

$$\min(\text{var}(P_i)) \quad (8.11)$$

$$\text{s.t.} \begin{cases} \sum_{i=1}^{200} a_{itk} \times 25 \times 8 + b_{itk} \times 20 \times 8 \geq D_{tk} \\ \frac{\sum_{t=1}^{30} a_{itk}}{30} \leq 0.85 \\ \sum_{t=m}^{m+6} a_{itk} \leq 7 \\ \sum_{k=1}^6 a_{itk} \leq 1 \\ b_{tk} \in Z^+ \\ 0 \leq \sum_{i=1}^{200} \sum_{k=1}^6 a_{itk} \leq 200 \end{cases} \quad (8.12)$$

8.2 多目标规划模型的求解

根据上述模型，使用 Matlab 进行编程求解，调用整数线性规划求解器 intlinprog 和染色体交叉编码策略来获取所需最优解^[11]，最后结合排班计划将优化结果转化为具体的排班表。分拣中心的部分正式工排班计划如表 8.1 所示。

表 8.1 分拣中心的部分正式工排班计划

分拣中心	日期	班次	出勤正式工
SC60	2023/12/9	16:00-24:00	5
SC60	2023/12/9	16:00-24:00	12
SC60	2023/12/9	16:00-24:00	21
SC60	2023/12/9	16:00-24:00	26
SC60	2023/12/9	16:00-24:00	27
SC60	2023/12/9	16:00-24:00	33
SC60	2023/12/9	16:00-24:00	40
SC60	2023/12/9	16:00-24:00	42
SC60	2023/12/9	16:00-24:00	43
SC60	2023/12/9	16:00-24:00	47
SC60	2023/12/9	16:00-24:00	54
SC60	2023/12/9	16:00-24:00	64
SC60	2023/12/9	16:00-24:00	65
SC60	2023/12/9	16:00-24:00	75
SC60	2023/12/9	16:00-24:00	77
SC60	2023/12/9	16:00-24:00	83
SC60	2023/12/9	16:00-24:00	88
SC60	2023/12/9	16:00-24:00	94
SC60	2023/12/9	16:00-24:00	107
SC60	2023/12/9	16:00-24:00	109
SC60	2023/12/9	16:00-24:00	126
SC60	2023/12/9	16:00-24:00	131
SC60	2023/12/9	16:00-24:00	133
SC60	2023/12/9	16:00-24:00	134
SC60	2023/12/9	16:00-24:00	140
SC60	2023/12/9	16:00-24:00	146
SC60	2023/12/9	16:00-24:00	152
SC60	2023/12/9	16:00-24:00	156
SC60	2023/12/9	16:00-24:00	165
SC60	2023/12/9	16:00-24:00	166
SC60	2023/12/9	16:00-24:00	180
SC60	2023/12/9	16:00-24:00	183

SC60	2023/12/9	16:00-24:00	198
SC60	2023/12/10	12:00-20:00	7
SC60	2023/12/10	12:00-20:00	30
SC60	2023/12/10	12:00-20:00	31
SC60	2023/12/10	12:00-20:00	34
SC60	2023/12/10	12:00-20:00	36
SC60	2023/12/10	12:00-20:00	37
SC60	2023/12/10	12:00-20:00	50
SC60	2023/12/10	12:00-20:00	53
SC60	2023/12/10	12:00-20:00	69
SC60	2023/12/10	12:00-20:00	87
SC60	2023/12/10	12:00-20:00	89
SC60	2023/12/10	12:00-20:00	91
SC60	2023/12/10	12:00-20:00	95
SC60	2023/12/10	12:00-20:00	106
SC60	2023/12/10	12:00-20:00	110
SC60	2023/12/10	12:00-20:00	111
SC60	2023/12/10	12:00-20:00	112
SC60	2023/12/10	12:00-20:00	113
SC60	2023/12/10	12:00-20:00	118
SC60	2023/12/10	12:00-20:00	123
SC60	2023/12/10	12:00-20:00	129
SC60	2023/12/10	12:00-20:00	150
SC60	2023/12/10	12:00-20:00	162
SC60	2023/12/10	12:00-20:00	181
SC60	2023/12/10	12:00-20:00	186
SC60	2023/12/10	12:00-20:00	190
SC60	2023/12/10	12:00-20:00	194

九、模型评价与推广

9.1 模型的优点

- 1、模型贴合实际，考虑到诸多重要因素，具有较高的推广应用价值。
- 2、模型结合了 LSTM 和 ARIMA 等多种预测技术，能够适应不同的数据类型，如依赖性和季节性，预测精度高。
- 3、模型考虑了运输线路变化对货量和人员安排的影响，对内外部环境的适应能力强，预测更加准确。
- 4、模型所提供的方案人力效率高、资源成本低，而且十分客观灵活。

9.2 模型的缺点

- 1、模型对于更复杂的时间序列数据，在处理时可能不够灵活和准确。
- 2、模型的计算成本较大，可能需要较长的时间才能获得所需要的数据。
- 3、模型对一些特定参数十分敏感，小的改动可能导致预测出现较大变化。

9.3 模型的推广

本文的货量预测模型及人员排班模型具有广泛的前景。我们可以将它们扩展到更大规模的电商物流网络中，或者其他行业的物流和供应链管理，特别是那些需要有效管理资源和提高效率的地方，可以起到很好的帮助作用。

例如在制造零售业中，可以利用模型来预测生产需求、优化生产计划以及提高生产效率，这对工厂企业的生产管理会有很大帮助^[12]；在医疗保健领域，可以利用模型来预测就诊量、优化医护人员排班以及提高医疗服务的效率，有助于医院、诊所等医疗机构的管理和运营；在交通运输领域，可以利用模型来预测客流量、优化交通资源分配以及提高交通运输效率，对于公交、地铁、航空等交通运输系统的管理和运营会非常实用；通过将这种模型推广到不同的领域和行业，可以帮助各种组织更好地管理资源、提高效率，从而实现更好的运营和服务质量。

我们可以开发相应的工具和界面，与行业内的相关企业建立合作关系，共同推广模型应用，扩大影响力和应用范围，同时也需要定期评估模型效果，根据具体行业特点和用户的意见反馈进行调整和优化，以确保模型的适用性和有效性。

十、参考文献

- [1] 张帆, 淳田, 肖锋. 基于 Flexsim 的快件分拣中心优化与仿真研究[J]. 物流技术, 2012(09):427-429.
- [2] 李利华, 胡列格, 符卓. 复杂物流网络区间规划模型及算法[J]. 系统工程, 2012(04):121-126.
- [3] 杨英俊, 王轶萍, 赵祥模. 基于遗传算法的城市客运出租汽车调度中心人员排班研究[J]. 公路交通科技, 2010(07):142-146.
- [4] Jason Brownlee. Multivariate Time Series Forecasting with LSTMs in Keras. <https://machinelearningmastery.com/multivariate-time-series-forecasting-lstms-keras/>, 2024. 04. 13.
- [5] 仙宫大牛. LSTM 神经网络介绍. https://blog.csdn.net/weixin_42973814/article/details/124501111, 2024. 04. 14.
- [6] 郑红云. ARIMA 模型在深圳人口与医疗需求预测的应用[J]. 山东轻工业学院学报(自然科学版), 2012(12):50-55.
- [7] 周美英. 基于 ARIMA 模型的湖北省 CPI 时间序列分析及预测[J]. 时代金融, 2011(05):66-67.
- [8] 马家丽, 胡雪梅. 半参数可加测量误差模型的白噪声检验[J]. 系统科学与数学, 2014(08):98-108.
- [9] 谢开贵, 魏延. 遗传算法[J]. 蒙自师范高等专科学校学报, 1999(04):17-22.
- [10] 金天坤, 高扬. 遗传算法的原理及组成浅析[J]. 科技视界, 2014(04):19-20.
- [11] 卢子甲, 韩义民, 张少卿. 基于遗传算法的配送中心拣选路径优化案例研究[J]. 物流技术, 2013(09):235-237.
- [12] 李智勇, 孙小英. ARIMA 模型在批发和零售贸易餐饮业预测中的应用[J]. 襄樊职业技术学院学报, 2006(11):30-31.