

队伍编号	MC2402456
题号	C

探讨物流网络分拣中心的货量预估及人员调度策略

摘 要

分拣中心作为电商物流订单履约的重要一环，负责对各环节的货物进行准确地分拣和分发。本文旨在通过建立时间序列预测模型，实现对分拣中心货量的有效预测，同时运用线性规划方法，对人员调度和排班进行科学合理的安排。

针对问题一，为预测未来 30 天各分拣中心的日、时货量，先对附件 1 中的数据进行**异常值处理**，同时鉴于实际物流配送的时间特性对附件 2 中的**缺失时间点**对应的货量赋予 0 值。基于 8、9、10 月的货量数据，利用 **ARIMA 模型**对货量进行初步预测。考虑到**双十一、双十二促销节**的特殊性，通过加权平均求得双十一活动期间货量**平均增长 70.45%**，通过比对两个促销节的销售额，可以得到双十二活动期间（12 月 8 日-12 月 13 日）货量为平时的 1.35 倍，由此可求得未来 30 天各分拣中心最终日货量。其中，SC20 分拣中心的平均货量最少，SC60 分拣中心的平均货量最多，其他数据详见结果表 1。同时，以 24 为季节性周期长度，通过构建 **SARIMA 模型**，得到未来 30 天各分拣中心的时货量，详见结果表 2。

针对问题二，为基于分拣中心的运输路线变化修正问题一的预测结果，先对过去 90 天的各分拣中心运输路径进行**拓扑结构图**展示，通过匹配前后路径数据发现新增了 2 条路线（SC5→SC4，SC31→SC9），削减了 14 条路线（见表 3）。对变化路线进行**货量分担（替代路径）**，比较同一到达分拣中心平均货量的变化率（见表 5），得到修正后的日货量，详见结果表 3。同时，对每小时的货量进行比例分配，求得修正后的时货量，详见结果表 4。

针对问题三，为使得分拣中心的人员排班人天数最小，对问题二的预测结果建立**线性整数规划模型**，其约束条件包括：每个分拣中心的正式工人数在 60 以内，每小时的处理量小于等于预测货运量且大于等于 0.9 倍的预测货运量，预测货运量小于等于最大处理量，以及一天最终实际处理量等于一天最终预测货运量。基于**分支定界法**可以得出未来 30 天的各分拣中心的人员安排情况，详见结果表 5。

针对问题四，建立**多目标整数规划**，并优先考虑正式工的排班，在问题三的模型基础上，加入额外的约束条件，分别得到正式工和临时工在不同时间段的排班情况，而且一周内出勤人数数据呈现出明显的日变化如周五周六休假员工较少等规律，并通过计算模型结果的变异系数等指标得到出勤率较为平衡。

关键词：ARIMA SARIMA 线性整数规划 多目标整数规划

目录

一、 问题重述	1
1.1 问题背景	1
1.2 问题提出	1
二、 问题分析	1
2.1 问题一的分析	1
2.2 问题二的分析	2
2.3 问题三的分析	2
2.4 问题四的分析	2
三、 模型假设	2
四、 符号说明	3
五、 模型的建立与求解	3
5.1 问题一模型的建立与求解	3
5.1.1 数据预处理	3
5.1.2 基于 ARIMA 模型的日货量预测	4
5.1.3 基于 SARIMA 模型的时货量预测	9
5.2 问题二模型的建立与求解	10
5.3 问题三模型的建立与求解	12
5.4 问题四模型的建立与求解	14
六、 模型的评价、改进与推广	15
6.1 模型的优点	15
6.2 模型的缺点	15
6.3 模型的改进	16
6.4 模型的推广	16
七、 参考文献	17
附录	18

一、 问题重述

1.1 问题背景

随着我国经济实力的不断增强和移动网络的迅速发展,电子商务也取得了长足发展。以物流服务来说,为实现高效便捷的购物体验,就要求提升物流配送效率^[1]。分拣中心作为物流的中转环节,是物流链中必不可少的一部分,是保障货物流通的关键节点^[2]。如何优化物流配送中心的运营效率,对于提高物流企业的整体运营绩效,以及降低物流成本,提高物流企业的竞争能力,有着重要的战略意义。

1.2 问题提出

该物流网络涵盖 57 个分拣中心,货量数据详实,包括过去 4 个月日货量(见附件 1)及过去 30 天时货量(见附件 2)。基于上述背景和货量数据建立数学模型解决以下问题:

问题一:构建模型以预测每个分拣中心未来 30 天的日货量和时货量,将结果填入结果表 1 和表 2 中。

问题二:基于附件 3 中过去 90 天平均货量数据与附件 4 中未来 30 天线路变化,预测 57 个分拣中心未来 30 天的日货量和时货量,并将结果填入结果表 3 和表 4。

问题三:基于问题 2 的货量预测,为每个分拣中心班次安排出勤人数。优先使用 60 名正式工,不足时增加临时工。在保障货量处理的同时,力求减少总人天数并均衡实际小时人效。将结果填入结果表 5。

问题四:以 SC60 分拣中心为例,基于问题 2 的预测结果,为其 200 名正式工制定未来 30 天的出勤计划。确保出勤率不超 85%,连续出勤不超 7 天。同时,优化人天数,均衡小时人效及正式工出勤率。确定每名正式工班次与临时工数量,并将结果填入结果表 6。

二、 问题分析

2.1 问题一的分析




图 1 问题一思路图

问题一要求对 57 个分拣中心在未来 30 天的日货量和时货量进行预测。

对于第一小问,要先对附件 1 中的 57 个分拣中心的货量进行异常值处理,并借助 Python 以 8-10 月的货量为 y ,对未来 30 天的日货量进行 ARIMA 预测。考虑双十一的特殊性,对双十一活动期间的货量增长情况进行加权求平均,进而得到双十一活

动期间货量的增长率，以此类比双十二活动期间的货量增长情况，对 ARIMA 预测的结果进一步优化。

对于第二小问，要先对附件 2 中缺失时点的货量赋值处理，并以 24 为周期长度建立 SARIMA 模型，预测 57 个分拣中心的未来 30 天的时货量。

2.2 问题二的分析

问题二要求基于分拣中心的运输路线变化对问题一的预测进行修正。

首先，要对过去 90 天的分拣路径进行可视化，并通过匹配附件 3 和附件 4 的前后路径找出新增路线和削减路线。

其次，对于新增路线，应对同一到达分拣中心的其他路线进行货量分担；对于削减路线，应对同一到达分拣中心的其他路线进行货量均分。

由此便得到新的分拣中心运输路线及货运量，通过比较前后数据即可得到变化率，进而对问题一中求得的日货量预测结果进行修正。

对于时货量修正，可通过对日货量修正进行时间点占比赋值，得到新日货量预测结果。

2.3 问题三的分析

问题三要求建立模型使得人员排班的人天数最小且实际小时人效均衡，可以使用线性整数规划对分拣中心的正式工和临时工排班。

此情况应以排班总人数的最小值为目标函数。由条件知，每个分拣中心的正式工人数在 60 人以内；为使实际人效尽可能均衡，要使每小时的处理量小于等于预测货运量且大于等于 0.9 倍的预测货运量；为完成每天的货运处理，应使预测货运量小于等于最大处理量，且一天的最终实际处理量等于一天最终预测的货运量。基于上述约束条件，可以得到人员安排情况。

2.4 问题四的分析

问题四需要预测分拣中心 SC60 未来 30 天每名正式工及临时工的班次出勤计划，并要求人效尽量均衡并且安排人天数尽可能少。

首先，引入三维变量和二维变量作为决策变量。

其次，为得到最优解建立多目标整数规划模型，引入不同的优先级以实现正式工和临时工的主次关系。

接着，在问题三的整数规划约束条件基础上，根据正式工人的出勤率不能高于 85% 等要求，引入约束条件。

由此便得到未来 30 天每名员工的班次出勤计划，并为更多的分拣中心提供更优的工人排班策略。

三、 模型假设

1. 假设对于数据中缺失值的处理方式不会对预测结果造成太大误差。
2. 假设分拣中心之间的运输路线变化与货量的增减存在直接关联，并且这种关联关系可以通过对历史数据的分析进行量化和预测。
3. 假设每名正式工和临时工每天只能出勤一个班次。
4. 假设每个分拣中心都可以按照需求对正式工和临时工的数量进行适当调节，并可在短期内对临时工进行调整。

四、 符号说明

符号	说明
$Q_{past,i}$	过去分拣中心 <i>i</i> 的平均货运量
$Q_{new,i}$	未来分拣中心 <i>i</i> 的平均货运量
r_i	变化率
$Q_{p,past,i}$	原日货量预测值
$Q_{p,new,i}$	现日货量预测值
t	时间点
p_t	分配比例
$Q_{p,new,i,t}$	现时货量预测值
x_i	第 <i>i</i> 班次正式工人数
y_i	第 <i>i</i> 班次临时工人数
k	小时
C_k	第 <i>k</i> 时实际处理量
D_k	第 <i>k</i> 时预测货运量
x_{kji}	第 <i>k</i> 名正式工第 <i>j</i> 天第 <i>i</i> 个班次出勤情况
y_{ji}	第 <i>j</i> 天第 <i>i</i> 个班次临时工人数

五、 模型的建立与求解

5.1 问题一模型的建立与求解

5.1.1 数据预处理

通过对数据的查看，可以发现部分数据值存在异常，且有些货量数据缺失，此类情况不仅可能影响后续的分析过程，还可能影响最终结果的准确性。为确保数据质量并提升分析的可靠性，要对数据进行预处理。

(1) 异常数据的修正




图 2 分类结果

考虑到附件 1 中分拣中心可能存在不同层级，统一去离群值存在极大误差，因此对 57 组分拣中心首先进行分类，分类结果如上图所示。




图 3 异常值箱线图

通过绘制箱线图对上述两类数据分别进行异常值清洗，并以中位数填充。

(2) 缺失数据的处理

通过对附件 2 数据的筛选，可以发现部分时点的货量没有显示，且缺失值在 1 点-7 点居多。鉴于实际物流配送的时间特性，我们可合理推断，在这些缺失的时点的货量应为零。因此，在后续的货量预测模型构建中，我们将这些缺失值视为零货量进行处理。

5.1.2 基于 ARIMA 模型的日货量预测

差分整合移动平均自回归模型（Autoregressive Integrated Moving Average model，简称 ARIMA），又称整合移动平均自回归模型，是常用的时间序列预测分析方法^[3]。ARIMA 模型包括自回归模型和移动平均模型^[4]。AR 模型描述了当前值和滞后值之间的关系，并用历史数据预测未来值。MA 模型利用过去残差项的线性组合来观察未来残差^[5]。ARIMA (p, d, q) 中，p 为自回归项数，q 为滑动平均项数，d 为使之成为平稳序列所做的差分次数（阶数）。ARIMA 预测模型可以写成下面的公式：

$$(1 - \sum_{i=1}^p \phi_i L^i)(1 - L)^d X_t = (1 + \sum_{i=1}^q \theta_i L^i) \varepsilon_t, \quad (1)$$

其中 L 是滞后算子（Lag operator）， $d \in \mathbb{Z}, d > 0$ 。

通常 ARIMA 模型的建立过程为^[6]：

Step1: 获取原始的时间序列数据；

Step2: 数据预处理，包括空缺值填充、数据类型转换、异常值的检查和处理等；

Step3: 数据去尖锐化抽样；

Step4: 使用绘图函数对样本时间序列数据绘图，观测绘图判断数据是否平稳。如果数据为非平稳数据，需要进行 d 阶差分运算，获取 d 值；

Step5: 对于平稳的样本时间序列数据，分别应用自相关系数 ACF 和偏自相关系数 PACF，通过对比获得自回归系数 p 和滑动平均项数 q；

Step6: 使用 p、d、q 三个关键参数建立 ARIMA 模型；

Step7:对创建好的 ARIMA 模型进行拟合操作;
Step8:对 ARIMA 模型进行检验。




图 4 ARIMA 模型建立的步骤图

基于本题情况，在综合考虑各种时间序列分析模型后，本文选择 ARIMA 模型对日货量进行分析，并给出未来 30 天的预测估计。由于篇幅限制，本文仅针对 SC16 分拣中心进行预测，其他分拣中心预测步骤同理。

考虑到双 11 活动对货量的影响，本文选取 2023 年 8 月-10 月的货量数据作为研究对象，并对其进行 ADF 平稳性检验，结果如下表所示。

表 1 ADF 检验结果

变量	差分阶数	t	P	AIC	临界值		
					1%	5%	10%
货量	0	-2.665	0.080*	1214.13	-3.511	-2.897	-2.585
	1	-3.32	0.014**	1205.459	-3.511	-2.897	-2.585
	2	-9.325	0.000***	1199.348	-3.511	-2.897	-2.585

注：***、**、*分别代表 1%、5%、10%的显著性水平

由上表可以看出，在差分为 1 阶时，显著性 P 值为 0.014**，水平上呈现显著性，因此拒绝原假设，该序列为平稳的时间序列。

然后通过最小化评估标准 AIC 获得 ARIMA 模型。最终 ARIMA 模型的参数选择为 (2, 1, 3)，且模型拟合优度 R^2 为 0.6，模型表现较好。

对残差进行自相关检验和正态性检验，检验结果如下图所示：




图 5 残差自相关检验




图 6 残差正态性检验

通过检验结果可以看出，模型残差为白噪声序列，这表明模型成功地提取了数据中的有用信息，且未包含未被模型解释的部分。因此，可以断定该模型具有良好的建立效果。基于此，初步对未来 30 天的日货量进行预测，结果如下表所示。

表 2 日货量初步预测结果

分拣中心	日期	货量
SC16	2023 年 12 月 1 日	3350.375601
SC16	2023 年 12 月 2 日	2987.17102
SC16	2023 年 12 月 3 日	3245.983388
SC16	2023 年 12 月 4 日	3562.886487
SC16	2023 年 12 月 5 日	3111.997239
SC16	2023 年 12 月 6 日	3096.758357
SC16	2023 年 12 月 7 日	3365.079886
SC16	2023 年 12 月 8 日	3330.467485
SC16	2023 年 12 月 9 日	3124.932083
SC16	2023 年 12 月 10 日	3242.918779
SC16	2023 年 12 月 11 日	3337.978622
SC16	2023 年 12 月 12 日	3229.612373
SC16	2023 年 12 月 13 日	3189.821183
SC16	2023 年 12 月 14 日	3286.159057
SC16	2023 年 12 月 15 日	3278.783861
SC16	2023 年 12 月 16 日	3214.116597
SC16	2023 年 12 月 17 日	3239.812498
SC16	2023 年 12 月 18 日	3279.11974
SC16	2023 年 12 月 19 日	3246.377373
SC16	2023 年 12 月 20 日	3229.613457
SC16	2023 年 12 月 21 日	3258.556294
SC16	2023 年 12 月 22 日	3261.146323
SC16	2023 年 12 月 23 日	3239.130184
SC16	2023 年 12 月 24 日	3244.866883
SC16	2023 年 12 月 25 日	3258.750255
SC16	2023 年 12 月 26 日	3249.963155
SC16	2023 年 12 月 27 日	3242.851628
SC16	2023 年 12 月 28 日	3251.65332
SC16	2023 年 12 月 29 日	3253.788234
SC16	2023 年 12 月 30 日	3246.714213

考虑到双十二也是网络促销节，因此要对该时间段进行特殊处理。

首先，对 2023 年 11 月份的货量数据进行可视化处理，以便直观地展示其变化趋势。结合双十一活动日期，可以观察到在 11 月 1 日至 11 月 13 日期间，货量较平时显著增加。鉴于物流运输的延迟，货量在 11 月 11 日-11 月 13 日达到了高峰。这一现象符合双十一购物节期间消费者购买需求增加的市场规律。




图 7 11 月货量趋势

为了量化双十一时货量的增长情况，对双十一期间的时货量增长率数据进行了加权求平均处理。经过计算，得出双十一时货量平均增长率为 70.45%。

同时，考虑到双十二促销活动相较于双十一在规模和交易量上的差异，本文进一步对比了两者的销售额数据。通过比对分析，发现双十二期间的销售额虽然也有所增长，但增长幅度小于双十一。因此，可以大致推断在 12 月 8 日至 12 月 13 日双十二活动期间，货量将为正常时期的 1.35 倍。

基于 ARIMA 模型的预测数据，对数据保留整数位数，可得 SC16 未来 30 天的最终货量，结果如下图所示。




图 8 日货量最终预测结果

由于篇幅限制，57 组未来 30 天的货量见结果表 1。

5.1.3 基于 SARIMA 模型的时货量预测

季节性自回归积分滑动平均模型（SARIMA）在自回归积分滑动平均(ARIMA)模型的基础上增加了季节因素提取参数，用于处理具有明显季节性变化的时间序列数据^[7]。在 SARIMA 模型中，季节性因素的提取和整合使得模型能够更精确地刻画时间序列的季节性波动模式，从而提高了预测和分析的准确性。SARIMA 模型可以写成下列公式：

$$\begin{aligned} (1 - \varphi_1 B - \varphi_2 B^2 - \dots - \varphi_p B^p)(1 - \Phi_1 B^s - \Phi_2 B^{2s} - \dots - \Phi_P B^{Ps})(1 - B)^d(1 - B^s)^D X_t \\ = (1 + \theta_1 B + \theta_2 B^2 + \dots + \theta_q B^q)(1 + \Theta_1 B^s + \Theta_2 B^{2s} + \dots + \Theta_Q B^{Qs}) \varepsilon_t, \end{aligned} \quad (2)$$

其中， $\varphi_1, \varphi_2, \dots, \varphi_p$ 是自回归系数， $\Phi_1, \Phi_2, \dots, \Phi_P$ 是季节性自回归系数， $\theta_1, \theta_2, \dots, \theta_q$ 是移动平均系数， $\Theta_1, \Theta_2, \dots, \Theta_Q$ 是季节性移动平均系数， B 是差分算子， d 是差分次数， D 是季节性差分次数， s 是季节性周期长度， X_t 是时间点 t 的观测值， ε_t 是误差项。

为兼顾不同日期同一时点的物流配送时间特性和时点左右两端数据对其的影响，本文选择对附件 2 缺失值处理后的数据进行深入分析，并基于这些数据建立 SARIMA 模型。在此模型中，我们设定季节性周期长度为 24，以准确捕捉物流配送中的日周期性变化。

SARIMA 模型的建立步骤与 ARIMA 类似，如下所示：

Step1:通过差分处理，确保用于时间序列的数据具有平稳性；

Step2:对季节项和周期项去除；

Step2:根据 AIC 准则，确定 SARIMA 模型的阶数 p, q, P, Q ；

Step3:对残差进行白噪声检验；

Step4:根据模型公式进行相关预测。

通过建立模型，可以得到如下图所示的 SC16 的时货量预测结果。其他分拣中心的日时货量预测结果见结果表 2。




图 9 时货量预测结果

5.2 问题二模型的建立与求解

首先对附件 3 中过去 90 天各分拣中心之间的运输路线图进行可视化，如下图所示。从图中可以初步观察到分拣中心之间存在多个不同级别，并且这些分拣中心之间形成了多条复杂的运输路径。




图 10 运输路线拓扑结构图

已知未来 30 天分拣中心之间的运输路线发生了变化，通过比对线路数据，发现附件 4 减少了 14 条运输路线，增加了 2 条运输路线，具体路径如下表所示。

表 3 削减路线

始发分拣中心	到达分拣中心	始发分拣中心	到达分拣中心
SC61	SC10	SC28	SC4
SC19	SC15	SC36	SC47
SC4	SC15	SC24	SC5
SC51	SC15	SC18	SC51
SC2	SC19	SC39	SC60
SC1	SC25	SC55	SC7
SC54	SC25	SC36	SC8

表 4 新增路线

始发分拣中心	到达分拣中心	始发分拣中心	到达分拣中心
SC5	SC4	SC31	SC9

对于削减的路线，其货运量将均分给同一到达分拣中心的其他路径。特殊地，从 SC2 到 SC19 的到达分拣中心只有一条路径，因此其货运量将均分于其他以 SC2 为始发分拣中心的路径，如 SC4、SC47、SC5、SC51、SC7、SC8 等始发分拣中心到 SC19

的路线。

对于新增的路线，将为同一到达分拣中心的路线中货运量最多的路线平均分担物流。

由此可得到新的各分拣中心之间各运输路线的货运量数据。现将同一到达分拣中心的路线求平均货运量。设过去分拣中心 i 的平均货运量为 $Q_{past,i}$ ，未来分拣中心的平均货运量为 $Q_{new,i}$ ，则变化率 r_i 可通过如下公式计算：

$$r_i = \frac{Q_{new,i} - Q_{past,i}}{Q_{past,i}} \quad (3)$$

最终计算得到分拣中心的平均货运量变化率如下表所示：

表 5 分拣中心及对应的平均货运量变化率

分拣中心	变化率	分拣中心	变化率
SC1	0.00%	SC47	9.06%
SC10	25.00%	SC5	9.09%
SC15	60.00%	SC51	20.00%
SC19	0.00%	SC53	0.00%
SC2	0.00%	SC57	0.00%
SC25	33.33%	SC6	0.00%
SC3	0.00%	SC60	33.33%
SC31	0.00%	SC7	11.86%
SC35	0.00%	SC8	12.10%
SC4	14.31%	SC9	-33.33%
SC44	0.00%		

因此，可以通过如下公式对问题一的日货量预测进行修正：

$$Q_{p,new,i} = Q_{p,past,i} \times (1 + r_i) \quad (4)$$

式中， $Q_{p,past,i}$ 表示原日货量预测值， $Q_{p,new,i}$ 表示现日货量预测值。

对于时货量，通过比较附件 2 中同一时点货运量可得从 0 点到 23 点分配的比例依次为 0.0625、0.0625、0.0625、0.0625、0.046875、0.015625、0.015625、0.015625、0.03125、0.03125、0.03125、0.03125、0.03125、0.03125、0.03125、0.03125、0.03125、0.03125、0.046875、0.046875、0.0625、0.0625、0.0625。

因此，可基于如下公式对时货量预测进行修正：

$$Q_{p,new,i,t} = Q_{p,new,i} \times p_t \quad (5)$$

其中， t 表示时间点， p_t 表示分配比例， $Q_{p,new,i,t}$ 表示现时货量预测值。

因此，通过上述公式，可以得到基于路线变化的对未来 30 天分拣中心的日货量和时货量的预测结果。为了更直观地展示数据分布和趋势，本文对修正的结果进行可视化展示，具体数据详见结果表 3 和结果表 4。




图 11 日货量预测结果修正




图 12 时货量预测结果修正

5.3 问题三模型的建立与求解

本题为最小化排班的人天数，需要构建一个优化模型。鉴于目标函数旨在寻求最小值，且该目标函数与约束条件之间呈现线性关系，同时考虑到所有相关变量均为整数，因此应建立线性整数规划模型以有效解决这一问题^[8]。此模型能够确保在满足各

项运营需求的前提下,实现排班人天数的最小化,从而提高运营效率并降低人工成本。
线性规划的一般步骤如下:

Step1:线性规划基本模型为

$$\min z = \sum_j c_j x_j \quad (6)$$

$$s.t. \begin{cases} \sum_{j=1}^n a_{ij} x_j = b_i, i=1,2,\dots,m \\ x_j \geq 0, j=1,2,\dots,m \end{cases} \quad (7)$$

(1) 为目标函数,使其达到最小值的解为最优解;

(2) 为约束条件,满足约束条件的解为可行解。

Step2:计算比例系数与常数项,待入目标函数。

Step3:建立约束条件的不等式。

针对此题,设 00: 00-08: 00、05: 00-13: 00、08: 00-16: 00、12: 00-20: 00、14: 00-22: 00、16: 00-24: 00 等 6 个班次所分配的正式工人数为 $x_i (i=1,2,\dots,6)$, 临时工人数为 $y_i (i=1,2,\dots,6)$, 第 k 时实际处理量为 $C_k (k=0,1,\dots,23)$, 第 k 时预测货运量为 $D_k (k=0,1,\dots,23)$ 。由此可得到如下表所示数据。(本文仅展示部分,其他详见附录 5。)

表 6 变量对应情况

小时	正式工个数	临时工个数	最大处理量	实际处理量	预测货运量
0	x_1	y_1	$25x_1 + 20y_1$	C_0	D_0
1	x_1	y_1	$25x_1 + 20y_1$	C_1	D_1
2	x_1	y_1	$25x_1 + 20y_1$	C_2	D_2
3	x_1	y_1	$25x_1 + 20y_1$	C_3	D_3
4	x_1	y_1	$25x_1 + 20y_1$	C_4	D_4
5	x_1	y_1	$25x_1 + 20y_1$	C_5	D_5
6	$x_1 + x_2$	$y_1 + y_2$	$25(x_1 + x_2) + 20(y_1 + y_2)$	C_6	D_6
7	$x_1 + x_2$	$y_1 + y_2$	$25(x_1 + x_2) + 20(y_1 + y_2)$	C_7	D_7
8	$x_1 + x_2$	$y_1 + y_2$	$25(x_1 + x_2) + 20(y_1 + y_2)$	C_8	D_8
9	$x_2 + x_3$	$y_2 + y_3$	$25(x_2 + x_3) + 20(y_2 + y_3)$	C_9	D_9

易知目标函数为:

$$\min \sum_{i=1}^6 (x_i + y_i) \quad (8)$$

由信息可知,每个分拣中心的正式工人应在 60 人以内,为使实际人效尽可能均衡,本文使每小时的处理量应小于等于预测货运量且大于等于 0.9 倍的预测货运量,同时为完成每天的货运处理,应使预测货运量小于等于最大处理量($AX + BY$),且一天的最终实际处理量等于一天最终预测的货量。因此,上述约束条件可表示为如下公式:

$$s.t. \left\{ \begin{array}{l} \sum_{i=1}^6 x_i \leq 60 \\ 0.9 \cdot \sum_{n=1}^k D_n \leq \sum_{n=1}^k C_n \leq \sum_{n=1}^k D_n, k=1,2,\dots,24 \\ AX + BY \geq C_k \\ \sum_{k=1}^{24} C_k = \sum_{k=1}^{24} D_k \end{array} \right. \quad (9)$$

利用 Matlab 编写代码可得出人员安排情况，详见结果表 5。同时对 SC16 组数据进行可视化展示，如下图所示。




图 13 人员分工安排

5.4 问题四模型的建立与求解

根据问题需求，建立多目标整数规划模型，多目标整数规划是一个涉及多个目标函数在给定区域上最优化的问题，其决策变量被限制为整数值。目标函数向量包含了需要优化的所有目标函数，而整数约束条件则限制了决策变量的取值范围。

多目标整数规划模型的基本步骤为：

Step1:明确目标和约束

设 $(f_1(x), f_2(x), \dots, f_n(x))$ 为 n 个目标函数，其中 x 是决策变量向量。为每个目标函数分配权重， $(w_1, w_2, \dots, w_n)$ 并确定约束条件。

Step2:构建加权目标函数

建立加权目标函数，使用权重将多个目标函数合并为一个单一的目标函数。

Step3:选择并应用优化算法

根据问题的特性和规模，选择适合的整数规划算法，如分支定界法或割平面法。使用选定的算法求解加权目标函数 $F(x)$ 的最优解，同时确保满足所有约束条件。

对于多目标组合优化的求解，通常使用启发式算法寻求其 Pareto 最优解集^[9]。但该方法往往依赖初值选取，且计算速度不够快^[10]。本文通过分级加权的方式，对目标函数进行求解。

易得目标函数为：

$$P_1 \sum_{k=1}^{200} \sum_{j=1}^{30} \sum_{i=1}^6 x_{kji} + P_2 \sum_{j=1}^{30} \sum_{i=1}^6 y_{ji} \quad (10)$$

其中， x_{kji} 即第 k 名正式工第 j 天第 i 个班次出勤情况 ($k=1,2,\dots,200; j=1,2,\dots,30; i=1,2,\dots,6$)， y_{ji} 是第 j 天第 i 个班次临时工人数 ($j=1,2,\dots,30; i=1,2,\dots,6$)； P_1 和 P_2 为不同的优先级，这里假设 P_1 为 1000， P_2 为 1； x_{kji} 是 0-1 变量，定义如下：

$$x_{kji} \begin{cases} 0, \text{未出勤} \\ 1, \text{出勤} \end{cases} \quad (11)$$

由信息可知，每名正式工人的出勤率不能高于 85%，且连续出勤天数不能超过 7 天，货量处理情况仍需日清。因此，上述约束条件可表示为如下公式：

$$s.t. \begin{cases} \sum_{j=1}^{30} x_{kji} \leq 85\% \times 30 \\ \sum_{j=a}^{a+7} x_{kji} \leq 7, a \in [0, 23] \\ \sum_{i=1}^6 x_{kji} = 1 \\ A \sum_{k=1}^{20} x_{kji} + B y_{ji} \geq C_k \\ 0.9 \cdot \sum_{n=1}^i D_n \leq \sum_{n=1}^i C_n \leq \sum_{n=1}^i D_n, i=1,2,\dots,6 \end{cases} \quad (12)$$

基于上述目标函数和约束条件利用 SPSSPro 可得到未来 30 天的班次出勤计划，详见结果表 6。

六、模型的评价、改进与推广

6.1 模型的优点

本文在进行异常值处理时，由于数据方差较大，本文使用 K-means++ 算法对数据分类，并针对不同类别的数据内使用不同形式的异常值识别方法。

在时间序列预测时，考虑到双十一促销节的特殊性，对 ARIMA 模型的预测结果进行修正。对于时货量预测时，采用 SARIMA 这种模型通过引入季节性参数，以更好地捕捉和预测数据的季节性模式，除此之外，还对不同的预测方法如 ARIMA 和 LSTM 进行对比，得出预测最准确的算法。

6.2 模型的缺点

在确定多目标规划问题的优先级指标大小时，由于没有充足的结论支持，判断方法带有主观成分。

6.3 模型的改进

在建立整数规划模型时，因为有关实际处理量的约束条件较少，可能由非线性方式计算，得出的最优解可能不准确，如果加入遗传算法及一些启发式算法会解决现实问题中更复杂的情况。

6.4 模型的推广

考虑到实际运输网络中不同噪声的影响和各种参数的不确定性，比如由天气、道路状况、运输工具故障等多种因素，可能给物流运输带来很大的不确定性和危险性，考虑将随机因素进行指标评价，引入整数规划模型，形成随机整数规划。通过使用概率论和随机优化方法，可以处理具有随机参数的整数规划问题，提高决策的稳健性。

七、 参考文献

- [1] 张潘丽.基于订单预测的电商快消品前置仓仓储量优化研究[D].华北电力大学,2020.
- [2] 林芳,钟震驱.基于层次分析法的快运分拣中心物流装备选用[J].装备机械,2023,04:24-29+51.
- [3] 王燕.应用时间序列分析[M].北京:中国人民大学出版社 2005.
- [4] Makridakis S, Spiliotis E, Assimakopoulos V,et al.The M4 Competition: 100.000 timeseries and 61 forecasting methods[J].International Journal of Forecasting,2020,36(1):54-74.
- [5] 庄晓天等, 智能供应链:预测算法理论与实战[M], 电子工业出版社, 2023.9
- [6] 李玲玲,辛浩.时序模型 ARIMA 在数据分析中的应用.福建电脑(04),2024,25-29.
- [7] 宋英华,徐亚安,张远进.基于 SARIMA-SVM 模型的季节性 PM_{2.5}预测研究.计算机工程 1-11.
- [8] 张博.基于整数线性规划的物流配送优化模型与求解算法研究.中国储运 (03),2024,151-153.
- [9] 夏添,沈欣炜 & 尚宇炜.基于混合整数规划的配电网检修多目标优化决策及其灵敏度分析.电网技术 1-10.
- [10] 郇嘉嘉.电网设备状态检修策略的研究[D].广州:华南理工大学, 2012.