



第0章 引言




武汉大学数学与统计学院 胡捷

最优化问题

- 研究如何判断以及找到解决问题的最优方案
- 应用广泛：神经网络、人工智能、工程设计、资源分配、生产计划、城市规划、农业规划、军事指挥等等
- 重要的数学分支，为如上问题的解决提供理论基础和求解方法

最优化问题分类



示例一：生产计划问题

设某工厂用4种资源生产3种产品，每单位第 j 种产品需要第 i 种资源的数量为 a_{ij} ，可获利润为 c_j ，第 i 种资源总消耗量不能超过 b_i ，由于市场限制，第 j 种产品的产量不超过 d_j ，试问如何安排生产才能使总利润最大？

解 设3种产品的产量分别为 x_1, x_2, x_3

决策变量

$$\max \sum_{j=1}^3 c_j x_j$$

目标函数——总利润

$$\text{s.t.} \sum_{j=1}^3 a_{ij} x_j \leq b_i, \quad i = 1, \dots, 4$$

约束条件——资源限制

$$x_j \leq d_j, \quad j = 1, 2, 3$$

约束条件——销量限制

$$x_j \geq 0, \quad j = 1, 2, 3$$

约束条件——非负限制


- 示例一属于线性规划问题。

第0章 引言

示例二：结构设计问题

以两个构件组成的对称桁架为例。

已知桁架的跨度 $2L$ ，高度 x_2 的上限 H ，承受负荷 $2P$ ，钢管的厚度 T ，材料比重 ρ ，纵向弹性模量 E 及容许应力 σ_y 。试确定钢管的平均直径 x_1 及桁架的高度 x_2 ，使桁架的重量最小。



解 桁架的重量： $G = 2\pi\rho T x_1 (L^2 + x_2^2)^{\frac{1}{2}}$

空间限制： $x_2 \leq H$

容许应力限制： $\frac{P(L^2 + x_2^2)^{\frac{1}{2}}}{\pi T x_1 x_2} \leq \sigma_y$

临界应力限制： $\frac{P(L^2 + x_2^2)^{\frac{1}{2}}}{\pi T x_1 x_2} \leq \frac{\pi^2 E (T^2 + x_1^2)}{8(L^2 + x_2^2)}$

min $G = 2\pi\rho T x_1 (L^2 + x_2^2)^{\frac{1}{2}}$

s.t. $x_2 \leq H, \frac{P(L^2 + x_2^2)^{\frac{1}{2}}}{\pi T x_1 x_2} \leq \sigma_y,$

$\frac{P(L^2 + x_2^2)^{\frac{1}{2}}}{\pi T x_1 x_2} \leq \frac{\pi^2 E (T^2 + x_1^2)}{8(L^2 + x_2^2)} \quad x_1, x_2 \geq 0$

第0章 引言

示例三：选址问题

设有 n 个市场，第 j 个市场的位置为 (a_j, b_j) ，对某种货物的需要量为 q_j ($j = 1, \dots, n$)。现计划建立 m 个货栈，第 i 个货栈的容量为 c_i ($i = 1, \dots, m$)。试确定货栈的位置，使各货栈到各市场的运输量与路程乘积之和最小。

min $\sum_{i=1}^m \sum_{j=1}^n W_{ij} \sqrt{(x_i - a_j)^2 + (y_i - b_j)^2}$

s.t. $\sum_{j=1}^n W_{ij} \leq c_i, \quad i = 1, \dots, m$

货栈容量限制

$\sum_{i=1}^m W_{ij} = q_j, \quad i = 1, \dots, m$

需求量满足

$W_{ij} \geq 0, \quad j = 1, 2, 3$

供给量非负

解 设第 i 个货栈的位置为 (x_i, y_i) ，第 i 个货栈供给第 j 个市场的货物量为 W_{ij} 。第 i 个货栈到第 j 个市场的距离为 d_{ij} 。

● 示例二、三都属于非线性规划问题。

第0章 引言

示例四：肺功能的测定

在医学上，患者肺功能的好坏是通过测定患者的血氧分压 PO_2 来确定。以前测量 PO_2 的方式是使用插管术，这种方式既容易引起感染，又是病人不舒服。后来人们发明了血氧仪，该仪器通过检测人体末梢组织，如手指或耳垂等部位，根据不同波长的红光和红外光的吸光度变化率，推算出组织的动脉血氧饱和度 SO_2 。我们只要建立起 SO_2 与 PO_2 的关系，就可以根据测得的 SO_2 计算 PO_2 。1979年，Severinghaus给出一组患者的 SO_2 与 PO_2 数据，其中 t_i 表示患者的 PO_2 ， y_i 表示患者的 SO_2 。

$t_i/\%$	y_i/torr	$t_i/\%$	y_i/torr	$t_i/\%$	y_i/torr
4	2.56	22	37.60	40	74.69
6	4.37	24	43.14	42	77.29
8	6.68	26	48.27	44	79.55
10	9.58	28	53.16	46	81.71
12	12.96	30	57.54	48	83.52
14	16.89	32	61.69	50	85.08
16	21.40	34	65.16	52	86.59
18	26.76	36	68.63	54	87.70
20	32.132	38	71.96	...	...

第0章 引言

1984年，Du Toit 和 Gonin 给出这样的模型：

$$\tilde{f}(x; t) = C_5 C_1^{C_2^{1-C_3^{tC_4}}}$$

其中 $C_i = \frac{1}{1+e^{x_i}}$ ($i = 1, 2, 3$)， $C_4 = 1 + e^{x_4}$ ， $C_5 = x_5$ 。在这个模型中， t 表示 PO_2 ， $\tilde{f}$ 表示 SO_2 。如果我们能够根据测定的数据，确定 x_i ($i = 1, \dots, 5$)的值，就可以根据上式求出反函数 $t(\tilde{f})$ 。

建立最优化问题：

$$\text{min } f(x) = \sum_{i=1}^{46} [y_i - \tilde{f}(x; t_i)]^2$$

其中 t_i, y_i ($i = 1, \dots, 46$)通过测定给出。

问题是： 确定 x_i 使 $\tilde{f}(x; t)$ 在点 t_i 处与 y_i ($i = 1, \dots, 46$)的差的平方和最小。

● 示例四属于最小二乘问题。

第0章 引言

示例五：稀疏优化问题

考虑线性方程组求解问题：

$$Ax = b,$$

其中向量 $x \in \mathbb{R}^n$, $b \in \mathbb{R}^m$, 矩阵 $A \in \mathbb{R}^{m \times n}$, $m < n$, 方程组是欠定的, 存在无穷多个解。

在信号传输问题中, 假设通过接收到长度为 m 的数字信号精确重构原始信号, 那么上述方程组中大部分解是无用的, 真正有用的是原始信号中有较多零元素的“稀疏解”。

因此, 如果原问题的解 u 满足某些条件, 求解这类信号传输问题中的“压缩感知”问题, 就可以通过求解稀疏优化问题来恢复全部信息。

即: u 是如下 ℓ_0 范数优化问题的最优解:

$$\begin{aligned} \min \quad & \|x\|_0 \\ \text{s.t.} \quad & Ax = b \end{aligned}$$

NP-难

定义 $\|x\|_1 = \sum_i |x_i|$

$$\begin{aligned} \min \quad & \|x\|_1 \\ \text{s.t.} \quad & Ax = b \end{aligned}$$

ℓ_1 范数优化问题 (基追踪问题)

u 是唯一最优解, 问题易解

● 示例五属于稀疏优化问题。

第0章 引言

● LASSO (Least absolute shrinkage and selection operator) 问题:

$$\begin{aligned} \min \quad & \|x\|_1 \\ \text{s.t.} \quad & Ax = b \end{aligned}$$

$$\begin{aligned} \min \quad & \mu \|x\|_1 + \frac{1}{2} \|Ax - b\|_2^2 \\ \text{s.t.} \quad & x \in \mathbb{R}^n \end{aligned}$$

- 这是带 ℓ_1 范数正则项的优化问题, 其中 μ 是给定的正则化参数, 调控模型复杂度.
- 最小二乘损失函数 (二次罚函数) 中加入 ℓ_1 正则项 (回归系数的绝对值之和).
- 传统线性回归在高维数据中易出现多重共线性和过拟合问题, ℓ_1 正则化能自动进行特征选择.
- 应用: 机器学习 (特征选择、模型压缩、时间序列分析)

信号处理 (压缩感知、信号近似)

生物信息学 (性状点位检测)

精算模型 (数据噪声处理)

● LASSO问题属于无约束优化问题。


第0章 引言

本课程的主要内容

- 最优性条件
- 算法基本概念
- 无约束优化算法:
 - 梯度下降方法、次梯度算法、
 - 牛顿类算法、拟牛顿类算法、
 - 信赖域方法、最小二乘法
- 约束优化算法
 - 罚函数法、增广拉格朗日方法、
 - 可行方向法、二次规划
- 复合优化算法
 - 原始-对偶算法、近似点算法、
 - 交替方向乘法

第0章 引言

开始优化之旅吧! ~





第一章 基本概念



武汉大学数学与统计学院 胡捷

向量范数

定义1: 若实值函数 $\|\cdot\|: \mathbb{R}^n \rightarrow \mathbb{R}$ 满足下列条件:

- (1) 正定性: $\|x\| \geq 0, \forall x \in \mathbb{R}^n$; $\|x\| = 0$ 当且仅当 $x = 0$;
- (2) 齐次性: $\|\alpha x\| = |\alpha| \cdot \|x\|, \forall \alpha \in \mathbb{R}, \forall x \in \mathbb{R}^n$;
- (3) 三角性: $\|x + y\| \leq \|x\| + \|y\|, \forall x, y \in \mathbb{R}^n$.

则称 $\|\cdot\|$ 为 **向量范数**, 其中 $\mathbb{R}^n$ 表示 n 维向量空间.

- 设 $x = (x_1, x_2, \dots, x_n)^T \in \mathbb{R}^n$.
 - $\mathcal{L}_1$ 范数: $\|x\|_1 = \sum_{j=1}^n |x_j|$.
 - $\mathcal{L}_2$ 范数: $\|x\|_2 = \left(\sum_{j=1}^n x_j^2\right)^{\frac{1}{2}}$.
 - $\mathcal{L}_\infty$ 范数: $\|x\|_\infty = \max_j |x_j|$.
 - $\mathcal{L}_p$ 范数: $\|x\|_p = \left(\sum_{j=1}^n |x_j|^p\right)^{\frac{1}{p}}, \text{ 对 } 1 \leq p < \infty$.
 - 由正定矩阵 A 诱导的范数: $\|x\|_A = \sqrt{x^T A x}$

命题1(柯西不等式): 设 $a, b \in \mathbb{R}^n$, 则 $|a^T b| \leq \|a\|_2 \cdot \|b\|_2$, 等式成立当且仅当 a 与 b 线性相关.

矩阵范数

定义2: 设 $A \in \mathbb{R}^{m \times n}$, **诱导的矩阵范数** 定义为: $\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|}$

- 若 A 可逆, 则定义矩阵 A 的 **条件数** 为: $\text{cond}(A) = \|A\| \cdot \|A^{-1}\|$
- 设 $A = (a_{ij}) \in \mathbb{R}^{m \times n}$, 则有:

➢ $\mathcal{L}_1$ 范数: $\|A\|_1 = \sum_{i=1}^m \sum_{j=1}^n |a_{ij}|$.

➢ $\mathcal{L}_2$ 范数(Frobenius范数): $\|A\|_F = \text{tr}(\sqrt{A A^T}) = \sqrt{\sum_{i,j} a_{ij}^2}$

或 $\|A\|_2 = \max_{x \in \mathbb{R}^n, \|x\|_2=1} \|Ax\|_2$

衡量矩阵“好坏”的指标

第一章 基本概念

梯度

定义2: 给定函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, 且 f 在点 $\mathbf{x}$ 的一个邻域内有意义, 若存在向量 $\mathbf{g} \in \mathbb{R}^n$ 满足

$$\lim_{p \rightarrow 0} \frac{f(\mathbf{x} + p) - f(\mathbf{x}) - \mathbf{g}^T p}{\|p\|} = 0$$

其中 $\|\cdot\|$ 是任意的向量范数, 就称 f 在点 $\mathbf{x}$ 处可微. 此时称为 f 在点 $\mathbf{x}$ 处的梯度, 记做 $\nabla f(\mathbf{x})$. 如果对区域 D 上的每一个点 $\mathbf{x}$ 都有 $\nabla f(\mathbf{x})$ 存在, 则称 f 在 D 上可微. 通常有:

$$\nabla f(\mathbf{x}) = \left[\frac{\partial f(\mathbf{x})}{\partial x_1}, \frac{\partial f(\mathbf{x})}{\partial x_2}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_n} \right]^T$$

第一章 基本概念

Hesse矩阵

定义3: 如果函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 在点 $\mathbf{x}$ 处的二阶

偏导数 $\frac{\partial^2 f(\mathbf{x})}{\partial x_i \partial x_j}$ 都存在, 则:

当 $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 是向量值函数时, 定义

Jacobi矩阵 $J(\mathbf{x}) \in \mathbb{R}^{m \times n}$, 第 i 行是分量

$f_i(\mathbf{x})$ 梯度的转置, 即:

$$\nabla^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f(\mathbf{x})}{\partial x_1^2} & \dots & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_n} \\ \vdots & \frac{\partial^2 f(\mathbf{x})}{\partial x_i \partial x_j} & \vdots \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_1} & \dots & \frac{\partial^2 f(\mathbf{x})}{\partial x_n^2} \end{bmatrix}$$

$$J(\mathbf{x}) = \begin{bmatrix} \frac{\partial f_1(\mathbf{x})}{\partial x_1} & \frac{\partial f_1(\mathbf{x})}{\partial x_2} & \dots & \frac{\partial f_1(\mathbf{x})}{\partial x_n} \\ \frac{\partial f_2(\mathbf{x})}{\partial x_1} & \frac{\partial f_2(\mathbf{x})}{\partial x_2} & \dots & \frac{\partial f_2(\mathbf{x})}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_m(\mathbf{x})}{\partial x_1} & \frac{\partial f_m(\mathbf{x})}{\partial x_2} & \dots & \frac{\partial f_m(\mathbf{x})}{\partial x_n} \end{bmatrix}$$

称为 f 在点 $\mathbf{x}$ 处的Hesse矩阵.

$\Rightarrow \nabla f(\mathbf{x})$ 的Jacobi矩阵就是 $f(\mathbf{x})$ 的Hesse矩阵.

第一章 基本概念

例1: 对于二次函数 $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} + \mathbf{b}^T \mathbf{x} + c$, 其中 $\mathbf{A}$ 是 n 阶对称矩阵, $\mathbf{b}$ 是 n 维列向量, c 是常数.

■ 梯度 $\nabla f(\mathbf{x}) = \mathbf{A} \mathbf{x} + \mathbf{b}$

Hesse矩阵 $\nabla^2 f(\mathbf{x}) = \mathbf{A}$

- 二次函数的Hesse阵为常数矩阵 (与 $\mathbf{x}$ 无关).
- 若 $\mathbf{A}$ 正定, 则 $f(\mathbf{x})$ 为凸函数, 全局最小值在 $\nabla f(\mathbf{x})=0$ ($\mathbf{x}^* = \mathbf{A}^{-1} \mathbf{b}$) 处取得.

第一章 基本概念

例2: 设函数 $g(\mathbf{x}) = \exp(\sum_{i=1}^n a_i x_i^2)$, 其中 $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{a} = (a_1, \dots, a_n)^T \in \mathbb{R}^n$ 为参数向量.

■ 梯度 $\nabla g(\mathbf{x}) = 2g(\mathbf{x}) \begin{pmatrix} a_1 x_1 \\ \vdots \\ a_n x_n \end{pmatrix}$

$$\text{Hesse矩阵 } \nabla^2 g(\mathbf{x}) = 2g(\mathbf{x}) \left(\begin{bmatrix} 2a_1^2 x_1^2 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & 2a_n^2 x_n^2 \end{bmatrix} + \begin{bmatrix} a_1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & a_n \end{bmatrix} \right)$$

- 非凸性: 当某些 $a_i < 0$ 时, Hesse阵可能不定.
- 临界性: 梯度为零当且仅当 $\mathbf{x} = \mathbf{0}$ (若所有 $a_i \neq 0$).
- 应用场景: 加权最小二乘、高斯过程回归中常有类似的结构.

第一章 基本概念



导数→梯度→Jacobi矩阵→Hesse阵

- 函数在某个点附近是如何变化的?
- 导数：一维坡度，告诉你前后方向（指南针）
- 梯度：多维坡度，指明最快下山的方向
- Jacobi矩阵：多人坡度总表，记录每个输出（队员）随输入（队长）变化的速率
- Hesse阵：坡道弯曲图，描述曲率和凹凸，更快找到谷底

第一章 基本概念

定义4： 给定可微函数 f ，若存在 $L > 0$ ，对任意 $x, y \in \text{dom} f$ 有

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|,$$

则称 f 是**梯度Lipschitz连续的**， L 为Lipschitz 常数。或简称为**梯度L-Lipschitz连续**或**L-光滑**。

➤ 如果函数 $f(x)$ 满足梯度Lipschitz连续，说明其梯度 $\nabla f(x)$ 的变化可以被自变量 x 的变化控制。

引理(二次上界)： 设可微函数 $f(x)$ 的定义域 $\text{dom} f = \mathbb{R}^n$ ，且为梯度L-Lipschitz连续，则函数有二次上界：

$$f(y) \leq f(x) + \nabla f(x)^T(y - x) + \frac{L}{2}\|y - x\|^2, \quad \forall x, y \in \text{dom} f.$$

➤ 说明函数 $f(x)$ 可被一个二次函数上界所控制，即函数的增长速度不超过二次。

第一章 基本概念

Taylor展开式

- 函数 $f \in C^1(S)$, $S \subset \mathbb{R}^n \rightarrow \mathbb{R}$ ，给定点 $\bar{x} \in S$ ：

➤ f 在点 $\bar{x}$ 的**一阶**Taylor展开式为：

$$f(x) = f(\bar{x}) + \nabla f(\bar{x})^T(x - \bar{x}) + o(\|x - \bar{x}\|)$$

➤ f 在点 $\bar{x}$ 的**二阶**Taylor展开式为：

$$f(x) = f(\bar{x}) + \nabla f(\bar{x})^T(x - \bar{x}) + \frac{1}{2}(x - \bar{x})^T \nabla^2 f(\bar{x})(x - \bar{x}) + o(\|x - \bar{x}\|^2)$$

第一章 基本概念

引理(二次上界)： 设可微函数 $f(x)$ 的定义域 $\text{dom} f = \mathbb{R}^n$ ，且为梯度L-Lipschitz连续，则函数有二次上界：

$$f(y) \leq f(x) + \nabla f(x)^T(y - x) + \frac{L}{2}\|y - x\|^2, \quad \forall x, y \in \text{dom} f.$$

第一章 基本概念

推论: 设可微函数 $f(x)$ 的定义域为 $\mathbb{R}^n$ 且存在一个全局极小点 x^* , 若 $f(x)$ 为梯度 L -Lipschitz 连续, 则对任意的 x 有: $\frac{1}{2L} \|\nabla f(x)\|^2 \leq f(x) - f(x^*)$.

➤ 说明可以用二次函数上界来估计 $f(x) - f(x^*)$ 的大小, 即判断最优解的方法.

第一章 基本概念

序列的极限

定义3: 设 $\{x^{(k)}\}$ 是 $\mathbb{R}^n$ 中的一个向量序列, $\bar{x} \in \mathbb{R}^n$, 如果对每个任给的 $\epsilon > 0$ 存在正整数 K_ϵ , 使得当 $k > K_\epsilon$ 时有 $\|x^{(k)} - \bar{x}\| < \epsilon$, 则称**序列收敛到 $\bar{x}$** , 或称序列以 $\bar{x}$ 为极限, 记作: $\lim x^{(k)} = \bar{x}$.

定义4: 设 $\{x^{(k)}\}$ 是 $\mathbb{R}^n$ 中的一个向量序列, 如果存在一个子序列 $\{x^{(k_j)}\}$, 使得 $\lim x^{(k_j)} = \bar{x}$, 则称 $\bar{x}$ 是序列 $\{x^{(k)}\}$ 的一个**聚点**.


定义5: 设 $\{x^{(k)}\}$ 是 $\mathbb{R}^n$ 中的一个向量序列, 如果对任意给定的 $\epsilon > 0$, 总存在正整数 K_ϵ , 使得当 $m, l > K_\epsilon$ 时, 有 $\|x^{(m)} - x^{(l)}\| < \epsilon$, 则称 $\{x^{(k)}\}$ 为**Cauchy序列**.

定理1: 设 $\{x^{(i)}\} \subset \mathbb{R}^n$ 为Cauchy序列, 则 $\{x^{(i)}\}$ 的聚点必为极限点.

第一章 基本概念

几个基本概念

- **可行点:** 满足约束条件的点.
- **可行集 (可行域):** 全体可行点组成的集合 S .
 - 无约束问题的可行集是整个空间.
- **全局极小点:** 若对每个 $x \in S$, 都有 $f(x) \geq f(\bar{x})$, 则称 $\bar{x}$ 为函数 $f(x)$ 在 S 上的全局极小点.
- **局部极小点:** 若存在 $\bar{x} \in S$ 的邻域 $N(\bar{x}, \epsilon) = \{x \mid \|x - \bar{x}\| < \epsilon\}$, 使得对每个 $x \in S \cap N(\bar{x}, \epsilon)$ 都有 $f(x) \geq f(\bar{x})$, 则称 $\bar{x}$ 为函数 $f(x)$ 在 S 上的局部极小点.



第一章 基本概念

凸集

定义6: 设 S 是 $\mathbb{R}^n$ 中的一个集合, 如果对 S 中任意两点 $x^{(1)}, x^{(2)}$ 及每个实数 $\lambda \in [0, 1]$, 都有

$$\lambda x^{(1)} + (1 - \lambda)x^{(2)} \in S,$$

则称 S 为**凸集**.

- $\lambda x^{(1)} + (1 - \lambda)x^{(2)}$ 称为 $x^{(1)}$ 和 $x^{(2)}$ 的**凸组合**.
- 集合 S 中点所有可能的凸组合构成的集合称为 S 的**凸包**, 记做 $\text{conv } S$.




第一章 基本概念

例如 1.1: 验证超平面 $H = \{x \mid p^T x = \alpha\}$ 是凸集,
其中 p 为 n 维列向量, α 为实数.

1.2: 验证半空间 $H^- = \{x \mid p^T x \leq \alpha\}$ 是凸集.

1.3: 验证射线 $L = \{x \mid x = x^{(0)} + \lambda d, \lambda \geq 0\}$
是凸集, 其中 d 是给定的非零向量, $x^{(0)}$ 为
定点, 也称为射线的顶点.



第一章 基本概念

凸集的性质

- 设 S_1 和 S_2 是 $\mathbb{R}^n$ 中的两个凸集, β 是实数, 则:
 - ① $\beta S_1 = \{\beta x \mid x \in S_1\}$ 为凸集;
 - ② $S_1 \cap S_2$ 为凸集;
 - ③ $S_1 + S_2 = \{x^{(1)} + x^{(2)} \mid x^{(1)} \in S_1, x^{(2)} \in S_2\}$ 为凸集;
 - ④ $S_1 - S_2 = \{x^{(1)} - x^{(2)} \mid x^{(1)} \in S_1, x^{(2)} \in S_2\}$ 为凸集;

第一章 基本概念


凸锥

定义7: 设有集合 $C \subset \mathbb{R}^n$, 如果对 C 中每一点 x , 当 λ 取任何非负数时, 都有 $\lambda x \in C$, 则称 C 为锥, 又若 C 为凸集, 则称为凸锥.

例如 1.4: 向量集 $\alpha^{(1)}, \alpha^{(2)}, \dots, \alpha^{(k)}$ 的所有非负线性组合构成的集合

$$\{\sum_{i=1}^k \lambda_i \alpha^{(i)} \mid \lambda_i \geq 0, i = 1, \dots, k\}$$

 为凸锥.




第一章 基本概念

多面集

定义8: 有限个半空间的交 $\{x \mid Ax \leq b\}$ 称为多面集, 其中 A 为 $m \times n$ 矩阵, b 为 m 维向量.

例如 1.5: 集合 $S = \{x \mid x_1 + 2x_2 \leq 4, x_1 - x_2 \leq 1, x_1 \geq 0, x_2 \geq 0\}$
 为多面集.

- 若 $b = 0$, 则多面集 $\{x \mid Ax \leq 0\}$ 也是凸锥, 称为多面锥.




第一章 基本概念

极点、极方向


适用于紧凸集

定义9: 设 S 为非空集合, $x \in S$, 若 x 不能表示成 S 中两个不同点的严格凸组合; 或者, 若假设 $x = \lambda x^{(1)} + (1 - \lambda)x^{(2)}$ ($\lambda \in (0, 1)$), $x^{(1)}, x^{(2)} \in S$, 必有 $x = x^{(1)} = x^{(2)}$, 则称 x 是凸集 S 的**极点**.



第一章 基本概念

例如 1.6: 对集合 $S = \{(x_1, x_2) | x_2 \geq |x_1|\}$, $(1, -1)^T$ 和 $(-1, 1)^T$ 是 S 的两个极方向, 其他方向都能表示成这两个方向的正线性组合.



1.7: 设 $S = \{x | Ax = b, x \geq 0\}$ 为非空集合, d 是非零向量. 证明 d 为 S 的方向的充要条件是 $d \geq 0$ 和 $Ad = 0$. (留待后面章节证明)

约束问题的可行方向

第一章 基本概念

极点、极方向

适用于无界集

定义10: 设 S 为 $\mathbb{R}^n$ 中的闭凸集, d 为非零向量, 若对 S 中的每一个 x , 都有射线 $\{x + \lambda d | \lambda \geq 0\} \subset S$, 则称向量 d 为 S 的**方向**.

又设 $d^{(1)}$ 和 $d^{(2)}$ 是 S 的两个方向, 若对任何正数 λ , 有 $d^{(1)} \neq \lambda d^{(2)}$, 则称 $d^{(1)}$ 和 $d^{(2)}$ 是两个不同的方向.

若 S 的方向 d 不能表示成该集合的两个不同方向的正的线性组合, 则称 d 为 S 的**极方向**.

• 通俗理解, 极方向是从极点出发的特殊方向。

第一章 基本概念

多面集的代表定理

定理2: 设 $S = \{x | Ax = b, x \geq 0\}$ 为非空多面集, 则有:

- (1) 极点集非空, 且存在有限个极点 $x^{(1)}, \dots, x^{(k)}$.
- (2) 极方向集为空集的充要条件是 S 有界. 若 S 无界, 则存在有限个极方向 $d^{(1)}, \dots, d^{(l)}$.

(3) $x \in S$ 的充要条件是: $x = \sum_{j=1}^k \lambda_j x^{(j)} + \sum_{j=1}^l \mu_j d^{(j)}$

迭代算法的基本原理


$$\sum_{j=1}^k \lambda_j = 1$$

$$\lambda_j \geq 0, j = 1, \dots, k; \mu_j \geq 0, j = 1, \dots, l$$

第一章 基本概念

凸函数

定义11: 设 S 为 $\mathbb{R}^n$ 中的非空凸集, f 是定义在 S 上的实函数. 如果对任意的 $x^{(1)}, x^{(2)} \in S$ 及每个数 $\lambda \in (0,1)$, 都有 $f(\lambda x^{(1)} + (1-\lambda)x^{(2)}) \leq (\leq) \lambda f(x^{(1)}) + (1-\lambda)f(x^{(2)})$, 则称 f 是 S 上的(严格)凸函数. 若 $-f$ 是凸函数, 那 f 是凹函数.



第一章 基本概念

定理3: 设 f 是定义在凸集 S 上的凸函数, 实数 $\lambda \geq 0$, 则 λf 也是定义在凸集 S 上的凸函数.

定理4: 设 f_1, f_2 是定义在凸集 S 上的凸函数, 则 $f_1 + f_2$ 也是定义在凸集 S 上的凸函数.

推论: 设 $f_1, f_2, \dots, f_k$ 是定义在凸集 S 上的凸函数, 实数 $\lambda_1, \lambda_2, \dots, \lambda_k \geq 0$, 则 $\sum_{i=1}^k \lambda_i f_i$ 也是定义在凸集 S 上的凸函数.

~作业~

第一章 基本概念

定理5: 设 S 是 $\mathbb{R}^n$ 中的非空凸集, f 是定义在凸集 S 上的凸函数, α 是一个实数, 则 $(\alpha\text{-下})$ 水平集 $S_\alpha = \{x \mid x \in S, f(x) \leq \alpha\}$ 是凸集.

证明 对于任意的 $x^{(1)}, x^{(2)} \in S_\alpha$, 根据 S_α 的定义, 有 $f(x^{(1)}) \leq \alpha, f(x^{(2)}) \leq \alpha$. 由于 S 为凸集, 因此对每个数 $\lambda \in [0,1]$, 必有

$$\lambda x^{(1)} + (1-\lambda)x^{(2)} \in S.$$

又由于 $f(x)$ 是 S 上的凸函数, 则有


$$\begin{aligned} f(\lambda x^{(1)} + (1-\lambda)x^{(2)}) &\leq \lambda f(x^{(1)}) + (1-\lambda)f(x^{(2)}) \\ &\leq \lambda \alpha + (1-\lambda)\alpha = \alpha. \end{aligned}$$

因此 $\lambda x^{(1)} + (1-\lambda)x^{(2)} \in S_\alpha$, 故 S_α 为凸集.

- 如果下水平集 S_α 非空, 意味着 $f(x)$ 的全局极小点 (若存在) 一定落在 S_α 中.

第一章 基本概念

引理2: 设 S 是 $\mathbb{R}^n$ 上的凸集, f 是定义在 S 上的函数, 则 f 是一个凸函数当且仅当其上图 $\text{epi} f = \{(x, y) \mid x \in S, y \in \mathbb{R}^1, f(x) \leq y\}$ 是一个凸集.



第一章 基本概念

凸函数重要性

定理6: 设 S 是 $\mathbb{R}^n$ 中的非空凸集, f 是定义在凸集 S 上的凸函数, 则 f 在 S 上的局部极小点是全局极小点, 且极小点的集合为凸集.

凸优化 (凸规划) 问题最优解的判定定理

证明 设 $\bar{x}$ 是 f 在 S 上的局部极小点, 即存在 $\bar{x}$ 的 $\epsilon > 0$ 邻域 $N_\epsilon(\bar{x})$, 使得对每一点 $x \in S \cap N_\epsilon(\bar{x})$, 成立 $f(x) \geq f(\bar{x})$.

假设 $\bar{x}$ 不是全局极小点, 则存在 $\hat{x} \in S$, 使 $f(\hat{x}) < f(\bar{x})$. 由于 S 是凸集, 因此对每一个数 $\lambda \in [0, 1]$, 有 $\lambda\hat{x} + (1-\lambda)\bar{x} \in S$. 由于 $\hat{x}$ 与 $\bar{x}$ 是不同的两点, 可取 $\lambda \in (0, 1)$. 又由于 f 是 S 上的凸函数, 因此有

$$\begin{aligned} f(\lambda\hat{x} + (1-\lambda)\bar{x}) &\leq \lambda f(\hat{x}) + (1-\lambda)f(\bar{x}) \\ &< \lambda f(\bar{x}) + (1-\lambda)f(\bar{x}) \\ &= f(\bar{x}). \end{aligned}$$

当 λ 取得充分小时, 可使

$$\lambda\hat{x} + (1-\lambda)\bar{x} \in S \cap N_\epsilon(\bar{x}),$$

这与 $\bar{x}$ 为局部极小点矛盾. 故 $\bar{x}$ 是 f 在 S 上的全局极小点.

由以上证明可知, f 在 S 上的极小值也是它在 S 上的最小值. 设极小值为 α , 则极小点的集合可以写作

$$\Gamma_\alpha = \{x \mid x \in S, f(x) \leq \alpha\}.$$

根据 **定理 5**, Γ_α 为凸集.

第一章 基本概念

强凸函数

定义12: 若存在常数 $m > 0$, 使得 $g(x) = f(x) - \frac{m}{2}\|x\|^2$ 为凸函数, 则称 f 为**强凸函数**, m 是**强凸参数**, 或称 f 为 m -**强凸函数**.

定义12': 若存在常数 $m > 0$, 使得对任意 $x, y \in \mathbb{R}^n$ 以及 $\lambda \in (0, 1)$, 有

$$f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y) - \frac{m}{2}\lambda(1-\lambda)\|x-y\|^2$$

则称 f 为**强凸函数**, m 是**强凸参数**.

定理7: 设 f 是强凸函数, 且存在最小值, 那么函数 f 的最小值点唯一.

第一章 基本概念

函数的方向导数

定义12: 设 S 为 $\mathbb{R}^n$ 中的一个集合, f 是定义在 S 上的实函数, $\bar{x} \in \text{int } S$, d 是非零向量, f 在 $\bar{x}$ 处沿方向 d 的**方向导数**定义为下列极限:


$$Df(\bar{x}; d) = \lim_{\lambda \rightarrow 0} \frac{f(\bar{x} + \lambda d) - f(\bar{x})}{\lambda}$$

- 如果 f 在 $\bar{x}$ 可微, 则 f 在 $\bar{x}$ 处沿任何方向的方向导数是有限的:

$$Df(\bar{x}; d) = d^T \nabla f(\bar{x})$$

其中 $\nabla f(\bar{x})$ 是 f 在 $\bar{x}$ 的梯度.

注: 同理可定义右侧导数和左侧导数.



第一章 基本概念

凸函数的判别


定理7: 设 S 是 $\mathbb{R}^n$ 中的非空开凸集, $f(x)$ 是定义在 S 上的可微函数, 则 $f(x)$ 为凸函数的充要条件是对任意两点 $x^{(1)}, x^{(2)} \in S$, 都有

$$f(x^{(2)}) \geq f(x^{(1)}) + \nabla f(x^{(1)})^T (x^{(2)} - x^{(1)}),$$

而 $f(x)$ 为严格凸函数的充要条件是对任意互不相同的 $x^{(1)}, x^{(2)} \in S$, 都有

$$f(x^{(2)}) > f(x^{(1)}) + \nabla f(x^{(1)})^T (x^{(2)} - x^{(1)}),$$

可微函数为凸函数的一阶充要条件



• 定理7的几何意义

第一章 基本概念

证明 先证必要性. 设 $f(x)$ 为凸函数. 根据凸函数的定义, 对任意的 $x^{(1)}, x^{(2)} \in S$ 及每个数 $\lambda \in (0, 1)$, 有

$$f(\lambda x^{(2)} + (1-\lambda)x^{(1)}) \leq \lambda f(x^{(2)}) + (1-\lambda)f(x^{(1)}), \quad (1.4.28)$$

将 (1.4.28) 式右端的 $f(x^{(1)})$ 移至左端, 两端除以 λ , 得到

$$\frac{f(\lambda x^{(2)} + (1-\lambda)x^{(1)}) - f(x^{(1)})}{\lambda} \leq f(x^{(2)}) - f(x^{(1)}). \quad (1.4.29)$$

令 $\lambda \rightarrow 0^+$, 则由 (1.4.29) 式的左端得到 $f(x)$ 在 $x^{(1)}$ 处沿方向 $x^{(2)} - x^{(1)}$ 的右侧导数, 即

$$D^+ f(x^{(1)}; x^{(2)} - x^{(1)}) = \lim_{\lambda \rightarrow 0^+} \frac{f(x^{(1)} + \lambda(x^{(2)} - x^{(1)})) - f(x^{(1)})}{\lambda},$$

从而得出

$$D^+ f(x^{(1)}; x^{(2)} - x^{(1)}) \leq f(x^{(2)}) - f(x^{(1)}). \quad (1.4.30)$$

由于 $f(x)$ 可微, 根据 (1.4.27) 式和 (1.4.30) 式, 则有

$$\nabla f(x^{(1)})^T (x^{(2)} - x^{(1)}) \leq f(x^{(2)}) - f(x^{(1)}),$$

即

$$f(x^{(2)}) \geq f(x^{(1)}) + \nabla f(x^{(1)})^T (x^{(2)} - x^{(1)}).$$

第一章 基本概念

再证充分性. 设对任意的 $x^{(1)}, x^{(2)} \in S$, 有

$$f(x^{(2)}) \geq f(x^{(1)}) + \nabla f(x^{(1)})^T (x^{(2)} - x^{(1)}).$$

令 y 是 $x^{(1)}$ 与 $x^{(2)}$ 连线上某一点, 即对某一个 $\lambda \in (0, 1)$, 有

$$y = \lambda x^{(2)} + (1-\lambda)x^{(1)}. \quad (1.4.31)$$

由于 S 为凸集, 则 $y \in S$. 根据假设, 对于点 $x^{(1)}, x^{(2)}, y \in S$, 下列两式成立:

$$f(x^{(1)}) \geq f(y) + \nabla f(y)^T (x^{(1)} - y), \quad (1.4.32)$$

$$f(x^{(2)}) \geq f(y) + \nabla f(y)^T (x^{(2)} - y), \quad (1.4.33)$$

用 $(1-\lambda)$ 乘 (1.4.32) 式两端, 并用 λ 乘 (1.4.33) 式两端, 再把得到的两个不等式相加, 则

$$\begin{aligned} (1-\lambda)f(x^{(1)}) + \lambda f(x^{(2)}) &\geq f(y) + \nabla f(y)^T [(1-\lambda)(x^{(1)} - y) + \lambda(x^{(2)} - y)] \\ &= f(y) + \nabla f(y)^T [\lambda x^{(2)} + (1-\lambda)x^{(1)} - y] \\ &= f(y). \end{aligned}$$

即

$$f(y) \leq \lambda f(x^{(2)}) + (1-\lambda)f(x^{(1)}).$$

注意到 (1.4.31) 式, 上式即

$$f(\lambda x^{(2)} + (1-\lambda)x^{(1)}) \leq \lambda f(x^{(2)}) + (1-\lambda)f(x^{(1)}).$$

由凸函数的定义可知 $f(x)$ 是凸函数。

第一章 基本概念

关于定理 1.4.14 的后半部, 严格凸函数充分条件的证明与上面的证明类似, 这里不再重复. 现在证明严格凸函数的必要条件.

设 $f(x)$ 是严格凸函数, 自然 $f(x)$ 也是凸函数. 对于任意两个不同点 $x^{(1)}, x^{(2)} \in S$, 我们取一点 $y = \frac{1}{2}(x^{(1)} + x^{(2)})$, 显然 $y \in S$. 根据本定理的前半部, 必有

$$f(y) \geq f(x^{(1)}) + \nabla f(x^{(1)})^T (y - x^{(1)}). \quad (1.4.34)$$

又根据严格凸函数的定义, 有

$$f(y) = f\left(\frac{1}{2}x^{(1)} + \frac{1}{2}x^{(2)}\right) < \frac{1}{2}f(x^{(1)}) + \frac{1}{2}f(x^{(2)}). \quad (1.4.35)$$

由 (1.4.34) 式和 (1.4.35) 式得到

$$\frac{1}{2}f(x^{(1)}) + \frac{1}{2}f(x^{(2)}) > f(x^{(1)}) + \nabla f(x^{(1)})^T (y - x^{(1)}),$$

经整理得出

$$f(x^{(2)}) > f(x^{(1)}) + \nabla f(x^{(1)})^T (x^{(2)} - x^{(1)}).$$