



第二章 无约束优化问题解的结构



武汉大学数学与统计学院 胡捷



最优化问题

- 无约束最优化问题:

$$\min f(x) \quad (\star)$$

其中 $x \in \mathbb{R}^n$, $f(x) \in \mathbb{R}$ 称为**目标函数**; 问题的解称为**最优解**, 记为 x^* , 该点的函数值 $f(x^*)$ 称为**最优值**.

- 约束最优化问题:

$$\begin{aligned} \min f(x) \\ \text{s.t. } c_i(x) = 0, i \in E \quad (\star\star) \\ c_i(x) > 0, i \in I \end{aligned}$$

其中 $c_i(x) = 0$ 称为**等式约束**; $c_i(x) > 0$ 称为**不等式约束**, 它们合称为**约束条件**; $c_i(x) \in \mathbb{R}$ 称为**约束函数**.




- 无约束优化问题的最优性条件 (解是什么?)
- 无约束优化问题的算法结构 (如何求解?)



无约束优化问题最优解的类型

- 全局最优解**: 若对任意 $x \in \mathbb{R}^n$, 都有 $f(x) \geq (>)f(x^*)$, 则称 x^* 为问题 $(\star)$ 的(严格)全局最优解.
- 局部最优解**: 对 $x \in \mathbb{R}^n$, 若存在 $\varepsilon > 0$, 当 $\|x - x^*\| < \varepsilon$ 时, 有 $f(x) \geq (>)f(x^*)$, 则称 x^* 为 $(\star)$ 的(严格)局部最优解.



第二章 解的结构




- 墨西哥草帽函数——处处都是局部极小点



第二章 解的结构



- 墨西哥草帽函数——处处都是局部极小点



第二章 解的结构



无约束优化问题的最优性条件

定理2.1(一阶必要条件): 设函数 $f(x) \in \mathbb{C}^1$, x^* 为 $f(x)$ 的一个局部极小点, 则:
$$g(x^*) = \nabla f(x^*) = 0.$$

第二章 解的结构



无约束优化问题的最优性条件

定理2.2(二阶必要条件): 设函数 $f(x) \in \mathbb{C}^2$, x^* 为 $f(x)$ 的一个局部极小点, 则 $G(x^*) = \nabla^2 f(x^*)$ 半正定.



无约束优化问题的最优性条件

定理2.3(二阶充分条件): 设函数 $f(x) \in \mathbb{C}^2$, 在点 x^* 有 $g(x^*) = 0$, 则当 $G(x^*)$ 正定时, x^* 是 $f(x)$ 的严格局部极小点.



例: 考虑问题 $\min f(x) = \frac{3}{2}x_1^2 + \frac{3}{2}x_1x_2 + x_2^2 - x_1 - 2x_2$ 在点 $x = (-\frac{4}{15}, \frac{6}{5})^T$ 处是否为极小点.



无约束优化问题的最优性条件

定理2.4(一、二阶方向导数的计算): 若函数 $f(x) \in \mathbb{C}^1$, 则它在点 x 处沿方向 $d \neq 0$ 的一阶方向导数可表示为

$$\frac{\partial f(x)}{\partial d} = \frac{1}{\|d\|} g(x)^T d;$$

若 $f(x) \in \mathbb{C}^2$, 则它在点 x 处沿方向 $d \neq 0$ 的二阶方向导数可表示为

$$\frac{\partial^2 f(x)}{\partial d^2} = \frac{1}{\|d\|^2} d^T G(x) d.$$

~作业~



无约束优化问题的最优性条件

定理2.5(一阶必要条件): 设函数 $f(x) \in \mathbb{C}^1$, x^* 为 $f(x)$ 的一个局部极小点, 则 $f(x)$ 在 x^* 处沿任意方向的一阶方向导数为零.


定理2.6(二阶充分条件): 设函数 $f(x) \in \mathbb{C}^2$, $f(x)$ 在点 x^* 处沿任意方向的一阶方向导数为零, 则当 $f(x)$ 在点 x^* 处沿任意方向二阶方向导数为正时, x^* 是 $f(x)$ 的严格局部极小点.

第二章 解的结构

方法特性

➤ 等高线：函数恒取常数值得到的一族曲线。

例：考虑Rosenbrock函数 $f(x) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$ ，其极小点为 $x^* = (1, 1)^T$ 。



第二章 解的结构

方法特性

➤ 稳定点：满足 $g(x) = 0$ 的点称为稳定点。

- 函数的极小(大)点一定是稳定点，反之不一定；
- 既非极小点又非极大点的稳定点为鞍点。





图 2.3 有极小点、极大点和鞍点的函数图形及其等高线

第二章 解的结构

方法结构

迭代算法的基本结构



“某种策略”

- 导数型
- 直接型

第二章 解的结构

方法结构

线搜索方法

算法2.1 (无约束最优化算法的基本结构)

- 步1: 给定初始点 $x_0 \in \mathbb{R}^n$, $k := 0$;
- 步2: 若在 x_k 点满足终止准则, 则输出有关信息, 停止迭代; 否则转步3;
- 步3: 确定 $f(x)$ 在 x_k 点的下降方向 d_k ;
- 步4: 确定步长 α_k , 使 $f(x_k + \alpha_k d_k)$ 较之 $f(x_k)$ 有某种意义的下降;
- 步5: 令 $x_{k+1} := x_k + \alpha_k d_k$, $k := k + 1$, 转步2.



下降方向: $f(x_k) > f(x_k + \alpha d) = f(x_k) + \alpha g_k^T d + O(\|\alpha d\|^2) \Rightarrow g_k^T d < 0$

第二章 解的结构

方法结构

➤ 最优化算法类型:

- 线搜索方法: 先在 x_k 点求得下降方向 d_k , 再沿确定步长 α_k
- 信赖域方法: 先限定步长的范围, 再同时确定下降方向 d_k 和步长 α_k

第二章 解的结构

方法结构

算法2.1 (无约束最优化算法的基本结构)

- 步1: 给定初始点 $x_0 \in \mathbb{R}^n$, $k := 0$;
- 步2: 若在 x_k 点终止准则满足, 则输出有关信息, 停止迭代;
- 步3: 确定 $f(x)$ 在 x_k 点的下降方向 d_k ;
- 步4: 确定步长 α_k , 使 $f(x_k + \alpha_k d_k)$ 较之 $f(x_k)$ 有某种意义的下降;
- 步5: 令 $x_{k+1} := x_k + \alpha_k d_k$, $k := k + 1$, 转步2.

常用终止准则: 1. $\|g(x_k)\| < \varepsilon$; 2. $\|x_k - x_{k+1}\| < \varepsilon$ 或 $\|f(x_k) - f(x_{k+1})\| < \varepsilon$.

第二章 解的结构

方法性质

➤ 收敛性: 若一个算法产生的点列 $\{x_k\}$ 在某种范数意义下满足

$$\lim_{k \rightarrow \infty} \|x_k - x^*\| = 0$$

则称该算法收敛.

如果从任意初始点出发, $\{x_k\}$ 都能收敛到 x^* , 那么算法具有全局收敛性;

但是, 仅当初始点与 x^* 充分接近时, $\{x_k\}$ 才能收敛到 x^* , 那么算法具有局部收敛性.

第二章 解的结构

方法性质

➤ 收敛速度: 判断算法运行快慢的指标.

例: (收敛速度的比较)

• 线性收敛: 若 $\lim_{k \rightarrow \infty} \frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} = a$ ($0 < a < 1$);

假定当前迭代点 x_k 满足 $\|x_k - x^*\| \leq 0.003$, 当 k 足够大时, 分别有

• 超线性收敛: 若 $\lim_{k \rightarrow \infty} \frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} = 0$

$$\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} \approx \frac{1}{2} \text{ 和 } \frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|^2} \approx \frac{1}{2}$$

• 次线性收敛: 若 $\lim_{k \rightarrow \infty} \frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} = 1$


问: 若要达到 $\|x_k - x^*\| \leq 10^{-9}$ 的精度, 当 k 足够大时, 分别采用具有线性收敛速度和二阶收敛速度的算法, 各需多少次迭代?

• 二阶收敛: 若 $\lim_{k \rightarrow \infty} \frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|^2} = a$ ($a > 0$)



方法性质

➤ **收敛速度**: 判断算法运行快慢的指标.



方法性质

➤ **二次终止性**: 对于一个算法, 如果它对任意正定二次函数, 从任意初始点出发, 可以经有限步迭代求得极小点, 就称该算法具有二次终止性.

- 利用正定二次函数的具有唯一极小点的特点, 检验算法的好坏.




线搜索准则

➤ **线搜索问题 (一维搜索问题)** —— 求步长 α_k 的问题:

✓ 满足怎样的准则, 步长可被接受?

✓ 有了合适的准则, 满足该准则的步长如何求?



线搜索准则——精确搜索

➤ **精确线搜索**: 求使 $f(x)$ 沿方向 d_k 关于步长 α 的极小值

$$\min_{\alpha} f(x_k + \alpha d_k)$$

若问题的解为 α_k , 则 $x_{k+1} = x_k + \alpha_k d_k$, 即可得:

$$g_{k+1}^T d_k = 0$$




线搜索准则——非精确搜索

➤ **非精确线搜索**：充分下降 $f(x_k + \alpha_k d_k) < f(x_k)$

例 (未充分下降实例) $\min f(x) = x^2$

$x^* = 0, f(x^*) = 0$, 初始点 $x_1 = 2$

迭代方法	①	②
	$\alpha_k = 2 + \frac{2k+1}{k(k+1)}$	$\alpha_k = \frac{1}{k(k+1)}$
	$d_k = (-1)^k$	$d_k = -1$
	$x_k = (-1)^k(1 + \frac{1}{k})$	$x_k = (1 + \frac{1}{k})$
聚点: -1, 1		聚点: 1




线搜索准则——非精确搜索

➤ **非精确线搜索**：充分下降 $f(x_k + \alpha_k d_k) < f(x_k)$

例 (未充分下降实例) $\min f(x) = x^2$

$x^* = 0, f(x^*) = 0$, 初始点 $x_1 = 2$

迭代方法	①	②
	$\alpha_k = 2 + \frac{2k+1}{k(k+1)}$	$\alpha_k = \frac{1}{k(k+1)}$
	$d_k = (-1)^k$	$d_k = -1$
	$x_k = (-1)^k(1 + \frac{1}{k})$	$x_k = (1 + \frac{1}{k})$
聚点: -1, 1		聚点: 1




线搜索准则——非精确搜索

➤ **非精确线搜索——Armijo准则 (充分下降条件)**

$$f(x_k + \alpha d_k) \leq f(x_k) + \rho g_k^T d_k \alpha$$

$\rho \in (0, 1)$

✓ α 取值范围: $(0, \beta_4] \cup [\beta_5, \beta_6]$



线搜索准则——非精确搜索


➤ **非精确线搜索——Goldstein准则**

$$f(x_k + \alpha d_k) \leq f(x_k) + \rho g_k^T d_k \alpha$$

$$f(x_k + \alpha d_k) \geq f(x_k) + (1 - \rho) g_k^T d_k \alpha$$

$\rho \in (0, \frac{1}{2})$

✓ α 取值范围: $[\beta_7, \beta_4] \cup [\beta_5, \beta_6]$





线搜索准则——非精确搜索


非精确线搜索——Wolfe准则

$$\begin{aligned} f(x_k + \alpha d_k) &\leq f(x_k) + \rho g_k^T d_k \alpha \\ g(x_k + \alpha d_k)^T d_k &\geq \sigma g_k^T d_k \quad (\text{曲率条件}) \end{aligned}$$

σ 可以取 0 吗?

✓ α 取值范围: $[\beta_7, \beta_4] \cup [\beta_8, \beta_9] \cup [\beta_{10}, \beta_6]$

$(1 > \sigma > \rho > 0)$



线搜索准则——非精确搜索


非精确线搜索——“强”Wolfe准则

$$\begin{aligned} f(x_k + \alpha d_k) &\leq f(x_k) + \rho g_k^T d_k \alpha \\ |g(x_k + \alpha d_k)^T d_k| &\leq -\sigma g_k^T d_k \quad (\text{曲率条件}) \end{aligned}$$

$(1 > \sigma > \rho > 0)$

✓ α 取值范围: ?

✓ 如何控制 α 不要太小: 给定 α_k 的一个下界.




例 (Wolfe和强Wolfe准则的区别)

$$\min f(x) = x_1^2 + 4x_2^2,$$

$$x^{(0)} = (0.5, 0.3)^T$$

$$d^{(0)} = (-1, -2.4)^T$$

$$\rho = 0.1, \sigma = 0.5$$



线搜索准则——非精确搜索

非精确线搜索步骤——以Armijo线搜索为例: $f(x_k + \alpha_k d_k) \leq f(x_k) + \rho \alpha_k g_k^T d_k \quad (*)$

步0: 若 $\alpha_k = 1$ 满足式 (*), 则取 $\alpha_k = 1$, 否则转步1;

步1: 给定常数 $\beta > 0$, $\sigma \in (0, 1)$, 令 $\alpha_k = \beta$;

步2: 若 α_k 满足式 (*), 停止, 得到步长 α_k , 否则, 转步3;

步3: 令 $\alpha_k = \sigma \alpha_k$, 转步2.



例 (Armijo准则步长计算实例) $\min f(x) = \frac{1}{2}x_1^2 + x_2^2$

设 $x^{(0)} = (1, 1)^T$, 验证 $d^{(0)} = (1, -1)^T$ 是函数在 $x^{(0)}$ 处的下降方向, 并用Armijo线性搜索确定步长 $\alpha_0 = 0.5^l$, 使得

$$f(x^{(0)} + \alpha_0 d^{(0)}) \leq f(x^{(0)}) + 0.9\alpha_0 (g^{(0)})^T d^{(0)}$$



线搜索准则——非精确搜索

➤ 非精确线搜索的可行性:

- ✓ 满足非精确线搜索准则的 α_k 存在吗?
- ✓ 采用非精确线搜索准则方法的收敛性可以保证吗?



线搜索准则——非精确搜索

定理2.7(非精确线搜索步长的存在性): 设 $f(x_k + \alpha d_k)$ 在 $\alpha > 0$ 时有下界, 并且 $g_k^T d_k < 0$, 则必存在 α_k , 在点 $x_k + \alpha_k d_k$ 处满足Wolfe准则或Goldstein准则.

定理2.8(非精确线搜索方法的收敛性): 设在水平集 $\{x | f(x) \leq f(x_0)\}$ 上, $f(x)$ 有下界, $g(x)$ 一致连续, 算法2.1的方向 d_k 与 $-g_k$ 之间的夹角 θ_k 一致有界, 即对某一 $\mu > 0$, 有

$$0 \leq \theta_k \leq \frac{\pi}{2} - \mu, \quad \forall k,$$

若Wolfe准则对任给的 k 都成立, 则或者存在 N , 使 $g_N = 0$, 或者 $g_k \rightarrow 0, k \rightarrow \infty$.



线搜索求步长

$$\min \Phi(\alpha) = f(x_k + \alpha d_k) \quad \alpha > 0$$

- 求满足搜索准则的步长, 一般分两个阶段:
 - ✓ 确定初始区间, 包含 $\Phi(\alpha)$ 的极小点;
 - ✓ 二分或者插值, 在区间内求出近似满足精确搜索准则的步长.



线搜索求步长

➤ 0.618法: 先区间, 在步长

算法2.2 (进退法求初始搜索区间)

- 步1: 给定初始点 $\alpha_0 \in [0, \infty)$, $\gamma_0 > 0$, $t > 0$, $i := 0$.
- 步2: 计算 $\alpha_{i+1} = \alpha_i + \gamma_i$, 若 $\alpha_{i+1} \leq 0$, 则令 $\alpha_{i+1} := 0$, 转步4;
若 $\Phi(\alpha_{i+1}) \geq \Phi(\alpha_i)$, 则转步4.
- 步3: 令 $\gamma_{i+1} = t\gamma_i$, $\alpha := \alpha_i$, $\alpha_i := \alpha_{i+1}$, $i := i + 1$, 转步2.
- 步4: 若 $i = 0$, 令 $\gamma_i := -\gamma_i$, $\alpha := \alpha_{i+1}$, 转步2; 否则

$$a = \min\{\alpha, \alpha_{i+1}\}$$

$$b = \max\{\alpha, \alpha_{i+1}\}$$
 输出 a, b , 迭代停止.

定义: (单峰函数)

称 $\Phi(\alpha)$ 是区间 $[a, b]$ 上的单峰函数, 若存在 $\alpha^* \in [a, b]$, 使 $f(x)$ 在 $[a, \alpha^*]$ 上单调下降, 在 $[\alpha^*, b]$ 上单调上升.



线搜索求步长


➤ 0.618法: 先区间, 在步长

算法2.3 (求一维函数 $\Phi(\alpha)$ 近似极小点)

- 步1: 给定 $a_0 > 0$, $b_0 > 0$, $\varepsilon > 0$, $\tau := 0.618$, $i := 0$.
- 步2: 若 $b_i - a_i < \varepsilon$, 则 $\alpha^* = \frac{b_i + a_i}{2}$, 输出 α^* , 停止线搜索;
- 步3: 计算

$$\alpha_i^l := a_i + (1 - \tau)(b_i - a_i),$$

$$\alpha_i^r := a_i + \tau(b_i - a_i).$$
- 步4: 若 $\Phi(\alpha_i^l) < \Phi(\alpha_i^r)$, 则令 $a_{i+1} := a_i$, $b_{i+1} := \alpha_i^r$; 否则
 $a_{i+1} := \alpha_i^l$, $b_{i+1} := b_i$, $i := i + 1$, 转步2.



- 区间 $[a_0, b_0]$ 经过 m 次迭代后, 区间长度变为 $\tau^m(b_0 - a_0)$.