

分类号 C93-0

密级

UDC 005.2

编号

中南财经政法大学

硕士学位论文

基于 GCN 算法的共享单车潮汐点的预测研究

研究生姓名：李春晖

指导教师姓名、职称：万少华副教授

申请者类别：普通硕士

学科门类：管理学

专业名称：管理科学与工程

研究方向：信息安全管理

入学时间：二零一九年九月

二零二二年六月一日

***Research on tidal point prediction of
shared bicycles based on GCN
algorithm.***

Li Chunhui

2022.06.01.

摘要

伴随着我国城市化建设进程的推进和经济的飞速发展,城市居民环境友好型交通模式也步入高速发展阶段。共享单车的出行方式被越来越多市民所接受,并成为市民固定的出行选择后,随之出现了重点起点区域共享单车数量不够、市民无车可用的问题,其中尤以早晚高峰时段,共享单车的“一车难寻”、“无处停放”的潮汐问题最为突出,且人类的活动存在白天工作、晚上休息的客观规律,加之办公时段、办公区域集中分布,潮汐现象无法回避。公共交通站点及办公场所附近单车数量出现饱和,大量单车停放堆积也造成一定的城市道路侵占和拥堵现象,以及城市交通安全相关事故伴随发生。

因此,针对共享单车在分布区域和骑行需要中具备的明显的潮汐特性,挖掘区域内共享单车骑行数据和停放数据,对共享单车数据综合分析,识别和预测出城市潮汐现象最为严重的区域,研究跨空间跨区域的集中式有效预测,缓解共享单车潮汐点的供需矛盾,解决市民日常出行的用车和停放困扰,优化市民的用车体验。从政府规划和交通监管水平角度,营造高效有序的交通管理环境,解决共享单车在城市出行中所造成停放不当、道路堆积等管理问题,提高共享单车运营车辆使用率,缓解单车区域内过量堆积所造成的资源浪费问题,完善城市基础管理,以期为城市管理部门和共享单车运营方提供预测的有益探索和尝试。

挖掘共享单车出行数据建立街道流量聚合模型,通过提取停车点位电子围栏数据,用 Geohash 库来对订单中出现的经纬度为主编码,依据停车点经纬度范围计算停车点位面积。在实际数据划分中采用聚类思想划分数据簇,完成街道单车量聚合。用 K-Nearest Neighbor 算法和 Geohash 算法两种算法完成区域内留存单车密度计算,识别出工作日早高峰时段潮汐现象最突出的区域,选择精度值较高的分类算法作为潮汐区域分类指标,在实际空间距离计算时将常用欧氏距离(Euclidean Distance)替换为精度值更高的球面余弦函数变换公式(Haversine),完成区域分类数据使近似数值分析,能减少多个不相关因素造成的实验误差,进一步实现交通预测方案。

在选择预测模型时,建立线性回归模型和随机森林模型作为预测,实验发现机器学习模型在预测中存在一些不足,因此考虑选择深度学习模型,建立图卷积神经网络模型(Graph Convolutional Network, GCN),提出将图卷积的方法应用在共享单车车量预测领域。图卷积神经网络模型上进行改进,提出了一种基于融合区域分类、地铁距离数值和区域间动态车流的多权重图卷积神经网络模型。提出了提取多图节点和图的融合算法进行卷积实验,以便图卷积神经网络可以同时应用于异质的站点间空预测。由于图卷积神经网络能在图结构中确定更为相关的邻域节点,因此多图融合的图卷积神经网络模型更适合提取时空依赖性,聚合邻居节点的信息来动态更新,并利

用相关邻域节点信息来更新节点特征，其聚合器能更好地挖掘空间信息。通过对单车分布点网络建构图结构，利用图结构将空间局部特征进行有效的挖掘和提取，使得需求量预测准确率大幅提高；然后采用时空图卷积神经网络来完成对于历史时空出行订单数据的处理，并关联区域内地体站点相关性等外部因素进行多图卷积，动态计算不同数据图的权重，提取多图节点实现图的融合并进一步进行卷积实验，以便图卷积神经网络可以同时应用于异质的站点空间预测，进一步捕捉共享单车时空特性，以此提升实际预测精度。

最后，分别对以上选用相应的数据集进行实验与分析，在评价模型时采用 RMSE、MSE、MAE 等预测评价指标评估模型的效率。结果表明多图卷积神经网络模型能够在预测值上表现出明显优越性。

识别潮汐区域并预测出区域内的用车需求量，将有效的解决共享单车时空无序性分布问题，缓解市民实际生活中的日常短途出行的供需矛盾。研究跨空间跨区域的集中式有效预测，从居民日常出行效率和服务体验的角度出发，提供共享单车日常出行需求数据，为管理商在单车投放、运营和后期维护等多个阶段提供参考数据，合理分配区域间的共享单车数量，解决市民日常出行的用车和停放困扰，缓解公共交通压力，提高共享单车的使用效率，并对共享单车集群性能提供有益帮助。从政府规划和交通监管水平角度，预知共享单车潮汐区域和单车使用数量，掌握预测数据的情况下倒逼城市规划和管理，以此来营造高效有序的交通管理环境，解决共享单车在城市出行中所造成停放不当、道路堆积等管理问题，提高共享单车运营车辆使用率，缓解单车区域内过量堆积所造成的资源浪费问题，完善城市基础管理，为城市管理部门和共享单车运营方提供预测的有益探索和尝试。

关键词：共享单车需求量预测；K-Nearest Neighbor；深度学习；图卷积神经网络

Abstract

Along with the rapid urbanisation and economic advancement of China, green transportation for urban residents has also entered a rapid development stage. After the shared bicycle has been accepted by more and more citizens and become their regular travel choice, the problem of insufficient number of shared bicycles in the key starting point areas and the lack of bicycles available to the public has emerged, especially in the morning and evening peak hours when shared bicycles are "hard to find" and "nowhere to park". "The problem of tidal wave is the most prominent, and the objective existence of the law of human activity of working during the day and resting at night, coupled with the concentration of office hours and office areas, the tidal wave phenomenon cannot be avoided. The number of bicycles near public transportation stations and offices appears to be saturated, and a large number of bicycle parking piles also lead to a certain phenomenon of urban road encroachment and urban traffic safety accidents accompanying the occurrence.

Therefore, in view of the tidal characteristics of the distribution and riding of shared bicycles, mining of shared bicycle riding data and parking data in the region, comprehensive analysis of shared bicycle data, identification and prediction of the most serious urban tidal phenomenon, research on cross-space cross-regional centralised effective prediction, alleviate the contradiction between supply and demand of shared bicycle tidal points, solve the daily travel of the public's bicycle use and parking troubles, and optimise the public's The study will help to solve the problem of bicycle use and parking, and optimise the public's bicycle experience. From the perspective of government planning and traffic regulation level, it creates an efficient and orderly traffic management environment, solves the management problems of inappropriate parking and road accumulation caused by shared bicycles in urban travel, improves the utilization rate of shared bicycle operation vehicles, alleviates the waste of resources caused by excessive accumulation of bicycles in the area, and improves urban basic management, with a view to providing useful exploration and experimentation of forecasting for urban management departments and shared bicycle operators. The project aims to provide a useful exploration and experiment for city management and bicycle sharing operators.

In this thesis, we mine shared bicycle travel data to establish street traffic aggregation model, and use Geohash library to encode the occurrence latitude and longitude in the order by extracting electronic fence data of parking spots, and calculate the area of parking

spots based on the latitude and longitude range of parking spots. The clustering idea is used to divide the data clusters in the actual data division to complete the aggregation of street single vehicle volume. Two algorithms, K-Nearest-Neighbor algorithm and Geohash algorithm, are used to complete the calculation of the density of retained bicycles in the area, identify the most prominent areas of the tidal phenomenon during the morning peak hours of weekdays, select the classification algorithm with higher accuracy value as the tidal area classification index, and replace the commonly used Euclidean Distance in the actual spatial distance calculation. In the actual spatial distance calculation, the commonly used Euclidean distance (Euclidean Distance) is replaced by the spherical cosine function transformation formula (Haversine) with higher accuracy value to complete the approximate numerical analysis of regional classification data, which can reduce the experimental error caused by multiple unrelated factors and further realize the traffic prediction scheme.

When choosing a prediction model, a linear regression model and a random forest model were established as predictions. Experiments revealed some shortcomings of machine learning models in prediction, so a deep learning model was considered and a Graph Convolutional Neural Network (GCN) model was established, proposing to apply the method of graph convolution to the field of bike-sharing volume prediction. The graph convolutional neural network model is improved on, and a multi-weighted graph convolutional neural network model is proposed based on fusing region classification, metro distance values and dynamic traffic flow between regions. As the graph convolutional neural network can identify more relevant neighbourhood nodes in the graph structure, the multi-graph fused graph convolutional neural network model is more suitable for extracting spatio-temporal dependencies, aggregating information from neighbouring nodes to update dynamically, and using relevant neighbourhood node information to update node features with aggregators that can better mine spatial information. By constructing a graph structure for the single vehicle distribution point network, the spatial local features are effectively mined and extracted using the graph structure, making the accuracy of demand prediction significantly improved; then the spatio-temporal graph convolutional neural network is used to complete the processing for the historical spatio-temporal travel order data and correlate external factors such as regional inland body site relevance for multi-graph convolution, dynamically calculating the weights of different data graphs and extracting multi-graph nodes. The graph fusion and further convolution experiments are carried out so that the network can be simultaneously applied to heterogeneous inter-site spatial prediction and further capture the spatial and temporal

characteristics of shared bicycles, thereby improving the actual prediction accuracy.

At last, the above selected corresponding datasets were experimented and analysed respectively, and the efficiency of the model was assessed using prediction evaluation metrics such as RMSE, MSE and MAE in evaluating the model. The results show that the multigraph convolutional neural network model is able to show significant superiority in prediction values.

Identifying tidal areas and predicting the demand for bicycles in the areas will effectively solve the problem of spatio-temporal disorderly distribution of shared bicycles and alleviate the contradiction between supply and demand for daily short-distance trips in the actual lives of citizens. The study of centralised and effective forecasting across space and regions provides data on the daily travel demand for shared bicycles from the perspective of residents' daily travel efficiency and service experience, provides reference data for managers at multiple stages of bicycle launch, operation and post-maintenance, reasonably distributes the number of shared bicycles between regions, solves the daily travel and parking troubles of the public, eases the pressure on public transport, and improves the It also provides useful assistance to the performance of bicycle sharing clusters. From the perspective of government planning and the level of traffic regulation, anticipating the tidal areas of shared bikes and the number of bikes in use, and having the predicted data to push back urban planning and management, as a means of creating an efficient and orderly traffic management environment, solving management problems such as inappropriate parking and road piling caused by shared bikes in urban travel, increasing the utilisation rate of shared bikes operating vehicles, alleviating the problem of excessive piling in bicycle areas caused by The project is a useful exploration and attempt to improve the basic management of the city and provide predictions for the city management and bicycle sharing operators.

Key Words: bike-sharing demand prediction; K-Nearest Neighbor; deep learning; graph convolutional neural network

目 录

第一章 绪论.....	1
第一节 研究背景与意义.....	1
一、研究背景.....	1
二、研究意义.....	3
第二节 国内外研究现状.....	4
一、共享单车的需求预测研究现状.....	5
二、卷积神经网络的预测研究现状.....	6
三、问题提出.....	7
第三节 论文研究内容.....	8
一、研究目标.....	8
二、技术路线.....	8
三、拟解决的主要问题及创新点.....	10
第四节 论文组织结构.....	11
第二章 相关理论与技术	13
第一节 机器学习理论.....	13
一、Geohash 算法.....	13
二、K-Nearest Neighbor 分类算法.....	14
三、线性回归算法.....	15
四、随机森林算法.....	16
第二节 深度学习理论.....	18
一、卷积神经网络.....	18
二、图卷积神经网络.....	19
第三节 空间距离度量方法.....	24
一、欧氏距离.....	24
二、余弦距离.....	24
三、Haversine 距离	24
第四节 评价指标.....	25
一、MSE.....	25
二、RMSE.....	25
三、MAE.....	25
第五节 本章小结.....	26
第三章 基于 KNN 潮汐区域分类识别模型.....	27
第一节 车流量潮汐问题可视化分析	27
第二节 数据预处理.....	28

第三节 潮汐区域分类识别模型	29
一、技术路线图	29
二、基于空间距离计算的方法改进	30
三、Geohash 算法模型	31
四、K-Nearest Neighbor 改进模型	36
第四节 本章小结	38
第四章 基于 GCN 共享单车流量预测模型	39
第一节 车流量时空特性可视化分析	39
一、空间特征	39
二、时间特性	41
第二节 机器学习预测模型	42
一、线性回归预测模型	44
二、随机森林算法模型	45
第三节 基于多权重图卷积神经网络模型	48
一、多权重卷积图生成	49
二、多权重图卷积计算	52
三、模型结构及指标评价	53
第四节 实验结果及分析	54
第五节 本章小结	55
第五章 总结与展望	57
第一节 研究总结	57
第二节 对策与建议	57
第三节 不足与展望	58
参考文献	60

第一章 绪论

第一节 研究背景与意义

一、研究背景

公安部发表数据显示,近十年以来我国机动车及汽车保有量保持逐年递增态势,疫情期间增速滞缓,疫情后机动车消费市场明显反弹,截至2020年9月,我国的机动车保有量超过3.65亿辆,机动车保有量中汽车数量达2.75亿辆;机动车驾驶人数量连年递增,目前已超过4.5亿人次,其中汽车驾驶人次约为4.1亿。机动车保有量在全国各城市均有增长,国内已有69个城市的汽车保有量超过100万辆,其中有12个城市的汽车保有量突破300万辆。随着机动车日益普及以及汽车私有率的提高,居民交通出行获得了诸多便利。机动车便捷出行方便人们生活的同时也带来不少城市隐患。常见的问题如产生交通堵塞,对环境造成污染破坏和对油气资源浪费等,机动车引发的一系列城市问题引起社会高度关注。为了解决机动车保有量提高而造成的交通问题,政府倡导发展绿色交通,不断推动城市公共交通发展,号召市民绿色出行。因此共享单车作为典型的绿色交通工具出现在人们生活中,共享单车借助共享经济发展的东风^[1],创新了传统自行车的骑行形式,凭借灵活便捷、绿色环保、物美价廉的特点获得广泛市场前景,灵活方便的优势使其异军突起,为居民日常交通出行提供了新的选择,并越来越成为助力城市绿色经济与绿色交通发展的代表之一。共享单车在全球多个城市广泛运用,助力城市系统发展朝着绿色化、便捷化、高效化发展。

共享单车作为环境友好型的出行交通工具,因其在消费模式上创新采用共享型经济,实际应用中拥有便捷灵活,操作简易及环保节能等诸多优势,共享单车不仅在一定程度上为市民的短途出行提供诸多便利,成为日常代步工具,更作为连接各公共交通站点上有益方式。因此共享单车延伸了城市交通网的脉络^[2],切实解决了出行者日常出行中面临的“最后一公里问题”,现已成为城市交通中不可或缺的环节。

根据中国报告网统计结果,2019年我国共享单车市场规模发展达到154.71亿元,同比增长速度约为16%;我国共享单车使用规模超过2.56亿人次,同比增长速度约为19%。2020年共享单车的市场规模已经达169.9亿元,同比增长速度为10%,使用规模人数突破2.8亿人。日渐突出的城市交通管理问题和城市交通安全问题加快推进了共享单车的建设速度,共享单车在我国的城市普及度较高,用户使用规模同比不断增加,市民对于共享单车的使用接受度不断提高,共享单车发展拥有广阔市场。




图 1-1 2016-2020 年我国共享单车用户人次统计图

据 iiMedia Research 统计，2020 年我国现有的使用人群中有占比 31.7% 的用户一周使用共享单车频率次数达 3 次及以上，另有 30.4% 的使用人群一周使用共享单车的频率为 1-2 次。由数据可知市民在日常生活中选择共享单车作为交通工具的频率较高，共享单车已日益成为我国居民短距出行的重要交通方式之一。




图 1-2 2020 年我国共享单车用户使用频率统计

二、研究意义

2016 年国家发展改革委和国家交通运输部联合发布的《推进“互联网+”便捷交通促进智能交通发展的实施方案》中明确提到,要充分认识推进“互联网+”便捷交通发展和助力智能交通发展的重要意义。伴随着我国城市化建设和经济飞速发展,城市人口数量和规模不断扩增,城市居民绿色交通出行也步入高速发展阶段。而目前我国人口基数总量大,共享单车的出行方式被越来越多市民所接受并成为其固定的出行选择后,随之出现了重点起始区域共享单车数量不够、市民无车可用的问题,其中尤以早高峰和晚高峰时段共享单车“一车难寻”、“无处停放”的潮汐问题最为突出。由于人类白天工作、晚上休息的活动存在客观规律性^[3],且工作时段较为集中,潮汐现象中出现的供需矛盾客观存在,难以回避。且公共交通站点及办公场所附近单车数量出现饱和,大量单车停放堆积也导致一定的城市道路侵占现象,城市交通安全事故伴随发生,增加了城市交通的管理难度。

城市空间分布多以用地功能划分,住宅区与商业区、工业区往往依据功能性质聚集分布,彼此间相距较远。^[4]共享单车的分布区域、起始点位、骑行路径具备较为明显的潮汐特性,例如早高峰时段将有大量的共享单车从各居民区驶出,最终密布在地铁站等公共交通站点以及写字楼等办公场所出入口,堆积现象凸显,严重影响城市管理秩序和公共交通安全,与此同时在住宅区、居民区等地方则是一车难寻。^[5]单车区域预测跨度大,依据现有研究的算法策略需依托城市管理机构 and 单车供应商的第三方进行预测,跨职能区的预测成本较高,且需要投入一定的人力资源,综合管理难度大。骑行者的素质参差不齐,停车时常伴随违规现象,在马路中间或公园草坪等无序停放,影响城市秩序的同时,造成单车资源浪费,为管理方增加管理难度。

共享单车早高峰时段潮汐点的预测研究,立足于居民日常生活中息息相关的交通出行领域,贯彻落实《推进“互联网+”便捷交通促进智能交通发展的实施方案》,因势利导,有利于促进城市交通和互联网技术的深度融合,全面深化城市交通与大数据技术向着广泛化、智慧化和深度化的密切融合^[6],助力我国交通智慧化发展,为我国交通发展现代化搭建发展的桥梁。坚持以居民日常出行中的实际问题为导向,着眼于课题研究中所包含的实际针对性、指导性,加速移动互联网大数据和现代交通领域的融合,推动便捷交通与智能交通新业态的快速兴起和发展。

据 iiMedia Research 统计,2020 年共享单车使用人群中有接近半数的用户在选择共享单车出行时主要关注的因素是费用问题,即共享单车在单位时长的收费情况;其次,路程的远近是用户选择共享单车的重要因素,有 45.2%的用户在使用时会考虑出行距离;使用人群中有 44.3%的用户在选择共享单车时会考虑应用是否便利,另外有 37.8%的使用者则主要关注的是共享单车出行是否安全。统计结果中显示,关注共享单车操作便捷程度和当地交通管制情况的用户数量相对持平,保持在 26%至 28%之

间。可以看出，目前大部分单车使用者主要考虑的是单车的价格标准、出行路程长短和出行便捷程度。因此，从企业运营管理角度，共享单车运营商需要从定价策略、技术安全、管理运营以及用户体验四个方面来完善共享单车行业管理体系，完善单车智能运行管理，改进共享单车管理设计，提高服务水平，改善用户体验。以此来加快共享单车的市场渗透率，发挥共享单车在其性能和系统上的优势和效率。




图 1-3 2019 年影响我国共享单车用户选择主要因素统计图

本文希望通过对共享单车进行综合性和全面性的分析，对早高峰时间段内的城市潮汐区域进行准确定位。根据单车骑行路径和停放区域等，识别潮汐现象严重的区域及单位面积内共享单车停放密度较大的区域，后期进一步预测早高峰时间段共享单车的需求量，对缓解共享单车在城市潮汐区域的供需矛盾提供数据支持。研究跨空间跨区域的集中式有效预测，从居民日常出行效率和服务体验的角度出发，提供共享单车日常出行需求数据，为管理商提供投放和运营的参考数据，解决市民日常出行的用车和停放困扰，优化市民的用车体验，为居民提供多样化、高效率的出行选择，提升城市居民绿色出行的幸福感。从政府规划和交通监管水平角度，预知共享单车潮汐区域和单车使用数量，掌握预测数据的情况下倒逼城市规划和管理，以此来营造高效有序的交通管理环境，解决共享单车在城市出行中所造成停放不当、道路堆积等管理问题，提高共享单车运营车辆使用率，缓解单车区域内过量堆积所造成的资源浪费问题，完善城市基础管理，为城市管理部门和共享单车运营方提供预测的有益探索和尝试。

第二节 国内外研究现状

本章节首先介绍目前共享单车需求量预测的研究现状及调度方案，分析现有研究

方法中存在的对于数据时空特性,介绍地铁轨道以及各交通空间无法进行有效提取的问题。然后针对现有的预测方法中应用的机器学习算法和深度学习算法对比介绍。本文提出运用聚类算法捕捉共享单车在日常骑行中的时空信息,获取到的时空规律特征生成图的结构并应用到图卷积神经网络,提取区域内的空间关联性,因此本章将概述图卷积神经网络的研究和应用现状。

一、共享单车的需求预测研究现状

种颖珊、韩晓明^[7]通过将共享单车系统的出行路径数据、骑行轨迹和实地天气情况等引入平台,构建了一种基于随机森林算法的需求量预测,该模型通过训练可预测某天内分时段的单车需求量情况。谢青成、毛嘉莉等^[8]研究城市路况后依据交通信息提出了离线建模和在线调度结合的调度方法,构建线上线下融合的共享单车实时调度框架,调度方案呈现阶段式,第一阶段是依照历史骑行轨迹的数据作为调度基础实行聚类统计,训练历史数据后捕捉不同时间段的使用热点区域;第二阶段则是构建调度的优化算法,依据时段进行实时变化,其采用 ROT 方法使得调度效率更优化。杨梓东^[9]通过大数据挖掘公共自行车的骑行特征,建立管理信息系统训练获取数据,建立预测模型并在预测模型的基础上进行实验优化。王玉全、刘燕涛等^[10]则是落脚于实地,针对北京市市民对于交通工具的选择进行数据调研,通过调研分析出影响居民选择交通方式的因素,在影响因素的基础上构建了一种基于 Logit 算法的预测模型。徐国勋、张伟亮等^[11]分析了共享单车具有的多种不同的种类和特性,为使共享单车在地域分布上实现平衡,提出了一种整数规划的算法模型,融合混合禁忌搜索算法解决了共享单车在地区分布上的不均衡问题。宋鹏、黄同愿等^[12]则是选择了支持向量机算法,实验对比了支持向量机在数据拟合预测上效果更优,构建了基于不同核函数的 SVM 算法预测模型,建立仿真实验代入数据验证模型的预测效果。杨军、赵继新等^[13]构建了 BP 神经网络算法,在 BP 神经网络的预测中分别建立 Identify 函数、Tanh 函数、Rule 函数、Logistic 函数的预测模型,通过模型实验对比,得到 Tanh 函数下的 BP 神经网络模型预测结果更接近于真实数据,在预测中具备更好地性能。李颖宏、马勇等^[14]是对共享单车出行规律进行分析,进一步提取了单车在使用中具有时空特性,构建了基于 LSTM 的线性回归算法,预测模型实际投入到城市共享单车需求量的应用中。

Liu J、Sun L 等^[15]分析了交通网点和单车使用时间存在的相关性,构建了一种单车在网格点间的过渡模型,采用加权 k 近邻算法,完成对各个交通站点的单车应用量预测。Caggiani L、Camporeale R 等^[16]研究分析时间和空间变化是影响共享单车需求量的重要因素,针对时空特性提出了一种基于求解动态区域聚类的模型,计算出在各个交通站点最优投放数量。Vogel 等^[17]针对共享单车在区域分配上不均衡,各区域间单车数量存在较大分配差别的问题,捕捉共享单车系统在使用中存在的规律性数据,建立了需求预测模型。Y Sun、B Leng^[18]提出了以小波支持向量机为基础的算法,通

过 SVM 方法学习训练小波向量机用来解析高低频信息, 并计算得到待预测时间内的需求预测量。Froehlich J E、Neumann J 等^[19]分析了各个交通站点随着时间推移其站点存在单车数量的变化情况, 基于贝叶斯算法建立了预测各交通站点的单车需求量模型。P Jiao、R Li^[20]在贝叶斯算法和非参数回归算法的基础上进行合理研究, 构建了一种改进式的卡尔曼滤波算法, 其模型能够对当下时段的客流量与历史数据进行偏测对比, 以此来对原始数据的波动性进行舒缓。

二、卷积神经网络的预测研究现状

张琳^[21]构建了 LSTM 和卷积神经网络的融合模型, 通过 Teradata 构建大数据平台对于北京未来某时间地铁人流量进行了有效的预测。何必胜、朱永俊等^[22]提出了一直基于捕捉时空特征构建图神经网络的高速铁路车站预测模型, 该模型经够实验对比发现在对于高速铁路的短期客流预测上取得较好的预测结果。李邦鹏^[23]在实验中发现将来某时段的客流数据与历史客流数据具有一定相关性, 因此构建了基于卷积神经网络和长短时记忆神经网络的算法模型, 该模型能够有效捕捉时空关联性特征, 抓取多个地域范围的客流时空特征并带入模型, 依据时空序列规律来完成对未来某一时段的客流量预测。付俐哲^[24]提出了一种基于时空聚类 and LSTM 神经网络模型, 来对共享单车在某一时段的单车需求进行预测。王佳琳^[25]提取了城市轨道交通中进站客流量和断面客流量数据作为输入特征, 基于两种数据分别构建了 RF-LSTM 的预测模型和 CNN-LSTM 的预测模型, 两种模型分别对轨道交通进站人流量和断面人流量做出预测, 实验验证了模型在预测上具有一定的准确性。徐先峰、黄刘洋等^[26]构建了一种基于卷积神经网络和双向长短期记忆网络的预测模型, 融合模型采用一维卷积对于捕捉交通流所具有的时空数据具有显著的优越性, 挖掘交通序列中具有长时效依赖关系进行训练, 学习时空序列所具有的时间特征, 其预测模型取得良好的预测效果。但在构建时没有把时空序列中的空间路网结构纳入模型, 因此模型不具备路网间客流预测效果。

图的卷积神经网络 (Graphical Convolutional Network, GCN) 是由 Bruna J、Zaremba W 等^[27]人首次提出, 图卷积神经网络模型是把卷积层投入到图数据中应用, 加入图数据后卷积神经网络能够更高效的处理网络空间关联性。图卷积神经网络能在遍历图的拓扑结构中提取图的信息, 将无序化数据进行规律性链接, 因此被用作交通流预测领域。F. Monti、D. Boscaini 等^[28]则是定义了除谱域外另外一种图的卷积方法, 也就是基于空间域的图卷积方法, 空间域的图卷积就是把图片上的信息点架构成为网格形状, 在依照固有的卷积神经网络方法进行卷积计算生成卷积模型。GraphSAGE^[29]则是确定了空间域方法上的图卷积方法的常规结构。图卷积神经网络目前应用方向是捕捉时空特征, 并克服了时空数据中的空间关联性问题。Y. Li、R. Yu 等^[30]建立了扩散卷积递归神经网络 (Diffusion Convolutional Recurrent Neural Network, DCRNN),

DCRNN 模型构建了加权有向双向图, 来获取图中包含的双向随机游走的空间关联性, 加之包含调度采样特性的编码器来对时空特性进行挖掘和分析。Y. Seo、M. Defferrard 等^[31]创新建立了图卷积递归网络的方法(Graph Convolutional Recurrent Networks, GCRN), 图卷积递归模型通过获取了长短时记忆网络在时间上具有的较强相关性, 利用门控循环网络对信息的依赖性进行了有效挖掘, 在提取信息的高效性能和对空间结点上表现出较强的优越性, 从而完成在空间域中按照时空关系的建模。Y. Li、Z. He 等^[32]建立了时空图卷积模型(Spatial-temporal GraphConvolutional Networks, STGCN), 时空卷积模型是用基于空间域里的图卷积方法解决空间相关性, 用卷积神经网络方法来解决时间相关性, 时空卷积建模来对视频中的数据进行处理, 时空卷积模型能够获取视频中人体动作的特征信息。Defferrard、Xavier Bresson 等人^[33]则是在时空卷积模型进行了新的创新, 采用快速局部卷积来加速计算过程。

在图卷积神经网络的应用上, 梁强升、许心越等^[34]建立了循环门控单元的时空图卷积神经网络融合模型(Graph Convolutional GRU, GCGRU), 循环门控单元能够完成对时间信息的高效捕捉, 这一特性被有效的应用于城市公共交通人流量的实时预测领域, 获取短时间内的信息来进行对各站点客流的时空特征规律性挖掘, 预测值能够贴近实际人流数据。康雁、谢思宇等^[35]提出了一种基于双路信息构造时空图结构, 利用双路信息图实现图卷积网络预测模型的架构设计。Diao Z、Wang X 等^[36]建立了图注意力网络和循环神经网络的算法模型, 用以捕获网络的时间和空间的关联系, 完成对将来交通流量的多步预测工作。Defferrard M、Bresson x 等^[37]提出了将立体图卷积算法无缝贴合到地铁公共站点人流量应用中, 立体图卷积将挖掘地铁公共交通网格中存在的无序性的时空依赖特征, 并能够把待预测人流和历史时段人流、每日人流和每周人流量之间的关系计算汇总作为总预测值。

三、问题提出

目前对待此类问题常用的解决方法是建立机器学习模型, 在机器学习模型中通过对于参数和各个指标的控制来完成对输入数据的训练, 挖掘客流量中的特征规律, 以此来不断提高预测精度。然而目前现有的研究大多侧重于探讨城市中公共自行车的需求量预测。城市自行车在城市规划中拥有固定的停车点位, 使用区域固定在停车闸点区域, 日常使用时借还车范围固定, 所以其面临最多的问题是停车闸点区域分布不均衡、公共自行车投放数量设置不合理导致的该区域需求难以匹配的问题, 公共自行车的优化预测的设计多基于单车停放的已知区域。而共享单车灵活便捷, 具有随骑随走的优势, 借还车地点多样, 没有固定的停车桩点限制, 还车地点分散, 其面临的问题是城市内停车区域未知, 公共交通站点处故障车多, 借还车供需矛盾突出。因此目前需求量在时空特性上仍存在一定研究缺陷, 单一特征提取已无法实现准确预测, 对于共享单车具有的未知时空特征有待于进一步提取分析。

综上,共享单车需求量预测从随机森林预测算法、支持向量机预测算法等机器学习算法,到果蝇优化算法、粒子群算法等各种算法不断提出,随着算法的改进对实际需求预测精度逐渐提升。其中,共享单车数据作为城市管理中的一环,其具有很多潜在的信息节点,可以考虑转化为承载信息值的图的结构。为了满足其具有的时空特征,考虑将神经网络算法模型应用到包含图的结构中计算。且共享单车数据在形式上表现出非规则性、非线性、不具有几何关系、受时空特征制约,可以将其转化为节点结构图,因此针对此类问题提出图卷积神经网络(Graph Convolution Network, GCN),图卷积神经网络对非欧几里得结构的数据进行有效处理,卷积层投入到图数据中,将图的形式与卷积神经网络相融合,高效的提取拓扑图的结构来作为训练。在现有研究中利用图卷积神经网络算法,对于在共享单车时空特征进行同图卷积模型,以及以地铁闸机进出人流量、研究空间关系来进行图卷积的预测研究欠缺,因此需要进一步研究并且完善预测模型,实现对预测精度的有效提高。

第三节 论文研究内容

一、研究目标

本课题研究目标根据现有共享单车投放和使用情况,挖掘区域内共享单车骑行数据和停放数据,计算单位时间内该区域面积中停放单车进出数量计算区域单车停放密度,识别出城市潮汐现象最为严重的区域和时间点进行标记,针对单车停放密度提出一种区域分类算法。

在区域分类后,对单位时间内区域单车总体进出量建立跨区域预测模型作为智能预测。在分类阶段对区域融合和筛选的条件进行预测量计算并分别建立机器学习模型和深度学习模型,选取指标表现最优的模型作为预测模型,从而预测出共享单车在实际生活中需求量,解决供需矛盾,按需投放区域内的共享单车数量,减少第三方调度成本开销和城市管理难度,提高共享单车集群性能。

二、技术路线

图 1-4 展示了本文的技术路线和共享单车需求量预测模型的构建路径。




图 1-4 技术路线图

（一）数据输入：为有效掌握城市早高峰时间段内潮汐现象的变化规律和变化趋势，使用 PyCharm Community Edition 2020 进行数据导入，爬取城市共享单车订单数据，挖掘城市 6:00-10:00 早高峰时段的共享单车数据。

（二）数据处理：在近十万数量级的共享单车数据中对骑行起点和终点信息进行有效提取，进行数据预处理。包括数据清洗、剔除缺失值和剔除异常值等对数据预处理。调用 Geohash 库来对经纬度进行编码，进行坐标系经纬度的匹配校准，给定数据边界，删除缺失值和重复值，剔除路径异常、开关锁异常、日期异常等一系列异常数据，完成数据归一化处理。

（三）潮汐区域分类识别：对数据中对应的经纬度实际匹配后，完成每一具体的区域内的共享单车流量统计，即统计不同时段中某一区域的流量，包括区域入流量和区域出流量，以此计算该区域内的单车留存数量。街道流量聚合后，用 K-Nearest Neighbor 算法和 Geohash 算法两种算法计算区域内留存单车密度，识别出工作日早高峰时段潮汐现象最突出的区域，选择精度值较高的分类算法作为潮汐区域分类指标。将数据处理和不同的可视化方法相结合，使用各类统计图、卫星图、热力图、轨迹分布图等不同可视化方法，对连接公共交通站点的日常骑行路径、骑行行程的骑行量时间变化，共享单车停车点位分布以及同区域内的出入流量进行可视化分析，分析挖掘潜在规律来进一步设计预测策略。

（四）模型构建：通过线性回归算法、随机森林算法建立机器学习预测模型和深度学习模型。由于共享单车停放和移动具有复杂性和随机性，机器学习模型在数据处理和预测精度上表现欠佳。因此构建图卷积神经网络模型，多图卷积神经网络模型利用区域间异质空间相关性，进行区域内共享单车流量预测，并综合测试模型结果：计算每种预测模型的方差（Variance）、均方误差（Mean Squared Error）、平均绝对误差（Mean Absolute Error），测试预测模型的预测值同真实值差异。

三、拟解决的主要问题及创新点

由于共享单车即停即走的特性，在方便生活的同时也带来了潜在的管理问题和需求矛盾。导致在实际生活中出现借还车地点随机性大，还车地点分散，城市区域间迁移跨度大等问题。并且在办公区域与居住区域间存在大面积单车迁移，具有严重的潮汐现象，造成公共交通站点处堆放，借还车供需矛盾突出。因此需要对城市潮汐区域进行识别并完成单车需求量预测。本文以厦门市共享单车城市数据为例，数据集包括共享单车订单数据（包括订单编号、单车编号、开关锁时间、经纬度定位值、用户编码等）。

解决潮汐问题，实际上是在研究中实际面临的问题城市内停车区域未知所带来的问题，对于生活单车潮汐区域的识别和预测显得极为重要。因此本文提取停车点位电子围栏数据，用 Geohash 库来对订单中的出现经纬度编码，依据停车点经纬度范围计算停车点位面积。验证 K-Nearest Neighbors 分类算法和 Geohash 算法分类的合理性和可行性，寻找精度最高的数据处理方法。在计算各个区域内留存单车密度的同时以街道作为分类依据，使用 K-Nearest Neighbors 测量出不同特征值之间的距离进行街道分

类,单位面积内留存单车数量最多的街道则被标记为热点区域,以此识别出工作日早高峰时段潮汐现象最突出的区域。

在选取空间距离公式作为潮汐区域识别的计算方法时,对传统的 K-Nearest Neighbors 算法中常用的空间距离方法进行改进。传统模型在计算时多采用欧氏距离 (Euclidean Distance) 或余弦距离来作为空间距离度量公式。当选取的单车点为一对长度差距大,坐标内容相近的值时,样本在特征空间中的表现出的欧氏距离计算数据值较大。而余弦相似度在计算时考虑两坐标夹角,其特征间的相似度高。因此,本文在计算时选用 Haversine 距离公式,在地理空间距离计算方法时代入球面模型,使得距离计算时贴近真实地球,计算精度较高,消除两点位间的绝对值和方向差异带来的误差,减少实际误差值,提高预测精度。

实验发现机器学习模型在预测中存在一些不足,因此提出了一种基于融合区域分类、地铁距离数值和区域间动态车流的多权重图卷积神经网络模型。通过对单车分布点网络建构图结构,利用图结构将空间局部特征进行有效的挖掘和提取,使得需求量预测准确率大幅提高;然后采用时空图卷积神经网络来完成对于历史时空出行订单数据的处理,并关联区域内地铁站点相关性等外部因素进行多图卷积,动态计算不同数据图的权重,提取多图节点实现图的融合并进一步进行卷积实验,以便图卷积神经网络可以同时应用于异质的站点间空预测,进一步捕捉共享单车时空特性,以此提升实际预测精度。在比较训练集数据和新预测集数据值,引入 RMSE、MSE、MAE 等预测评价指标评估模型的效率,在选定的预测模型模型上不断优化。

第四节 论文组织结构

本文共计五个章节,每个章节的组织和内容如下:

第一章:绪论。主要对本文的选题背景进行了综合概述,首先介绍了关于共享单车行业相关研究背景和研究意义,阐释预测模型所解决的问题、需求量预测研究对社会生活的意义;介绍交通需求量预测的应用方法,对国内外研究现状进行综述,并对目前研究中所运用的相关机器学习算法和深度学习算法进行介绍,其中对图卷积神经网络在国内外研究进行梳理。最后概述本文的主要研究内容和组织结构,布置各章节内容。

第二章:相关理论研究与技术介绍。首先对分类算法的理论知识进行介绍,列举了本文涉及到的 K-Nearest Neighbor 分类算法和 Geohash 算法有关技术,引入了算法相似性度量方法和空间地理距离计算量度量公式。随后介绍预测模型中采用的机器学习模型(线性回归模型、随机森林模型)和深度学习模型(图卷积神经网络模型)相关理论,引入相关评价指标。最后探索了主要深度学习方法与技术,以及深度学习在推荐系统中的应用。介绍了图卷积神经网络在国内外发展的相关理论和技术。

第三章：基于 KNN 的潮汐区域分类识别模型研究。本章针对共享单车时空跨度大及无序性分布分散等稀疏问题，在实际数据划分中采用聚类思想划分数据簇，重点介绍了分类实验设置与分析。采用 K-Nearest Neighbor 分类算法和 Geohash 算法对基础数据进行分类，并比较两种分类算法在处理数据分类值上的差异。其中对模型中时空距离计算公式进行检验，创新提出将传统欧式距离计算公式替换为精度更高的 Haversine 距离计算公式，选择目标问题中表现结果更优的 K-Nearest Neighbor 分类算法完成分类数据簇的聚类划分，最后做出总结。

第四章：基于图卷积神经网络的共享单车流量预测模型。本章在分类数据簇基础上，针对需求量实际值建立预测模型。在比较线性回归模型、随机森林模型预测结果后，为了更好地提取深度特征，基于卷积神经网络算法，提出一种基于多图卷积的神经网络模型。介绍融合多种图的实验方法，基于地铁距离数值和空间客流数据进行分析，研究其时空特征并作特征提取，以便图卷积神经网络可以同时应用于异质的站点间空间相关性实验设置与分析，最后做出总结。

第五章：总结与展望。对本文的主要工作进行回顾和总结，从单车运营商和政府管理的角度提出相关管理建议，优化现行管理对策，同时分析了现有工作的不足之处和接下来需要改进的地方，指出本文所提模型存在的问题，并对下一步的工作进行了探讨。

第二章 相关理论与技术

第一节 机器学习理论

一、Geohash 算法

GeoHash 是一种地址编码的计算方法，原理是将二维的空间上的经纬度坐标数据编码转换为字符串。GeoHash 具有用字符串表示经度和纬度坐标值，在数据库中实现某一系列数值的应用索引的功能。值得注意的是，GeoHash 表示为一特定矩形区域，矩形区域范围内所有经纬度坐标点将共用同一 GeoHash 字符串，因此 GeoHash 并非代表单一坐标点。

GeoHash 计算步骤为：

地球经纬度区间划分为 $[-90, 90]$ ，地球经度区间为 $[-180, 180]$ 。假设其区间内某一地点的经纬度坐标为 $(39.923203, 116.390705)$ ，将纬度区间进行二分形成左右区间，比较地标坐标纬度和区间值，可得到纬度的二进制序列，序列的长度和设定的计算区间划分次数存在相关性。迭代上述计算过程纬度值总是属于二分区间 $[a, b]$ 。随着迭代次数增加则迭代区间 $[a, b]$ 缩小并无限趋近 39.923203。因此，对纬度 39.923203 进行逼近编码可得。

表 2-1 GeoHash 二分区间

Latitude	Delineated interval 1	Delineated interval 2	bit
$(-90, 90)$	$(-90, 0)$	$(0, 90)$	1
$(0, 90)$	$(0, 45)$	$(45, 90)$	0
$(0, 45)$	$(0, 22.5)$	$(22.5, 45)$	1
$(22.5, 45)$	$(22.5, 33.75)$	$(33.75, 45)$	1
$(33.75, 45)$	$(33.75, 39.375)$	$(39.375, 45)$	1
$(39.375, 45)$	$(39.375, 42.1875)$	$(42.1875, 45)$	0
...	...	...	...

续表 表 2-1 GeoHash 二分区间

Latitude	Delineated interval 1	Delineated interval 2	bit
(39.9243164062 5,39.9353027343 75)	(39.92431640625, 39.9298095703125)	(39.9298095703125, 39935302734375)	0

经度同样进行编码可得到二进制序列，将得到经纬度序列进行奇偶位合并，依照 base32 位编码表编码，合并后二进制编码后结果为：wx4g0ec1。GeoHash 编码中的前缀可以表达为更大的区域。例如编码号为 wx4g0ec1，前缀 wx4g0e 表达的含义是包含编码 wx4g0ec1 在内的进一步扩大的范围，编码特性有效的应用于临近地点搜索。

表 2-2 Base32 位编码表

Decimal	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
Base32	0	1	2	3	4	5	6	7	8	9	b	c	d	e	f	g
Decimal	16	17	18	19	20	21	22	23	24	25	26	27	28	29	30	31
Base32	h	j	k	m	n	p	q	r	s	t	u	v	w	x	y	z

二、K-Nearest Neighbor 分类算法

K-Nearest Neighbor 分类算法是通过测量不同特征值之间的距离，依据距离间距进行分类。K-Nearest Neighbor 分类的基本研究问题是在初始状态下，假设已存在具有完整分类标签的样本集，给定一个未知且无明显数据分类标签样本，K-Nearest Neighbor 则是研究如何根据现有的分类样本集，来将未知样本分类到所属类别并确定预测标签。分类思路是计算待确定样本同样本周围所距离的“邻居”样本的远近，来通过距离来判断与其相似度来确定待分类样本的所属分类。因此 KNN 算法思想实际上就是由待检测样本和其距离该样本最近的 K 个相邻样本的分类来决定，分类时在 K 个邻居中按照少数服从多数的原则，从拥有最多数量的分类中投票选出并设定为待测样本的分类。




图 2-1 KNN 算法示意

即通过对样本数据的特性以及与训练集中对应的特性进行比较，从特征空间中最相邻的前 K 个或最接近的样本中划分到集合，所以该样本就属于这个集合。分类过程主要是通过统计样本数据和各个训练数据的间距，并将间距的递增关系作为排序基础，最后选择间距最近的 K 个点并统计以确定此 K 个点在分类出现的频次高低，最后返回分类频次最大的数据集作为预测结果。在 K-Nearest Neighbor 中 K 值的选取十分关键，因为 K 值选取过大会造成训练数据中欠模拟合，而 K 值选取太小则会造成过模拟合。K 值选择的范围过大会导致算法在计算时包含远距离的样本，导致过多值的总体误差增大；K 值选择过小，K 在计算中出现的噪声数据则会影响预测值，同样会使误差增大。




图 2-2 KNN 算法示意

三、线性回归算法

线性回归算法是依据一个或多个自变量与因变量之间的关系来进行建模。线性回

归由一个或多个回归系数的模型参数组成,计算自变量和因变量间的关系时把目标值预期作为输入变量,代入求算其具有的线性关系,而多元线性回归则是包含了两个或多个变量的回归算法。




图 2-3 线性回归原理示意

假设现存在 n 组数据,自变量 X 取值为 $(X_1, X_2, X_3, X_4, \dots, X_n)$,因变量 $Y(Y_1, Y_2, Y_3, Y_4, \dots, Y_n)$,假设自变量之间存在一定的关系为 $f(x)=ax+b$ 。那么线性回归算法在计算时目的就是如何缩小 $f(x)$ 和 y 之间的差异性,即研究 a 和 b 在取值时取何值使 $f(x)$ 和 y 最为接近。因此在实际计算中判定 $f(x)$ 和 y 之间的差异性就是解决问题所在。在应用线性回归的分析问题中,均方误差是线性回归中常用的度量指标。

四、随机森林算法

随机森林算法 RF (Random Forest) 通过结合 bagging 算法以 CART 决策树作为弱学习器组合。结点和有向边两部分组成了决策树,结点表示类别又分为内部结点和叶结点,其中内部结点表达特征或属性,叶结点则表示一个分类。叶结点对应决策结果,其他每个结点则分别对应于一个属性测试。随机森林算法从原始的数据集中进行有放回的采样,使得子数据集和原始数据集数量相同,采样数据则是构成了一个子数据集。子决策树是建立在子数据集的基础上,每个子决策树中包含子数据集的每个数据,使得每个子决策树都能生成一个结果输出。新的数据需要通过随机森林得到分类结果,就可以依照对子决策树的判断结果的投票得到随机森林的输出值。bagging 算法则是建立多个分类或者回归模型,最后通过计算平均值来生成最终的预测值。因为每轮采用得到的样本子集并不完全相同,导致训练模型得到相关性会随之降低。通过对训练数据随机采样,能更好地减少相关性对模型造成的影响。

使用 CART(Classification and regression tree)决策树当作模型的弱学习器,在 n 个样本特征中把最优特征作划分决策树左右子树的依据,对节点上的样本特征进行随机采样,保证采样得到的特征数字小于 n ,假设其是 n_{sub} ,在随机得到 n_{sub} 个样本特征中选择最优的特征作为划归左右树枝的节点,以此来提高模型的泛化能力。假设 $n_{sub}=n$, n_{sub} 和训练集的拟合程度呈现一定的相关性, n_{sub} 越小那么训练集的拟合程度随之降低。因此随着 n_{sub} 的减小,模型的方差会随之减小,但偏倚会随之扩大,因此需要利用交叉验证的方法来调取适当参数,直到获得更为合适的 n_{sub} 的值。输入为样本集 $D = \{(z, 91), (2, 32), \dots (T_m, 9m)\}$, 设置弱分类器中的迭代次数为 T , 最后输出的强分类器定义为 $f(x)$ 。对于 $t = 1, 2, 3 \dots T$, 将训练集进行第 t 次的随机抽样,总共的采样数为 m 次,将得到采样集 D_t , 采样集合 D_t 中包含 m 个样本;用采样集 D_t 训练第 t 个决策树模型 $G_t(x)$ 。在针对决策树模型的节点进行练习的时候,于节点上包含的全部样本特征中进行随机选择,随机抽取的部分样本特征中选择最优的一个特征来作为决策树的左右子树划归依据。

基尼指数表示在样本分类集合里随机选中的的样本被错误的进行分类的概率。基尼指数与样本概率成负相关,也就是指数越大则集合里被选中的样本发生错误的概率越高,高概率的错误样本组成集合的纯度越低;反之基尼指数越小则表示集合里被选中的样本发生错误的概率越低,那么集合纯度则会越高。当集合中所有样本分类为一个类别时,基尼指数计算值为 0。

$$G(P) = \sum_{K=1}^K P_K(1 - P_K) = 1 - \sum_{K=1}^K P_K^2 \quad (2-1)$$

其中随机森林分类强度是评价模型中分类器总体分类值的量。其值为随机森林在边缘函数中的期望值:

$$mr(X, Y) = P(T_K(X) = Y) - \max_{J \neq Y} P(T_K(X) = J) \quad (2-2)$$

$P(T_K(X) = Y)$ 为正确类别的概率, $\max_{J \neq Y} P(T_K(X) = J)$ 为分类错误概率的最大值, J 则表示不正确的分类向量。

决策树在构建随机森林的计算过程中,存在已知的初始数据集和未被抽取的待分类数据集。将未抽取的待预测数据集定义为 $O_K(X)$ 。 $Q_K(X_i, Y_j)$ 为随机向量 x 在 $O_K(X)$ 数据集中分类类别为 Y_j 的比例。

$$Q(X, Y_j) = \frac{\sum_{K=1}^K I(T_K(X)=Y_j; X, Y \in O_K(X))}{\sum_{K=1}^K I(T_K(X); X, Y \in O_K(X))} \quad (2-3)$$

分子是待抽取数据集 $O_K(X)$ 中决策树分类对应正确的数量加和的个数,分母为所有代抽取数据的个数。

$$s = E(\text{mr}(X, Y)) = E(P(T_K(X) = Y) - \text{MAX}_{j \neq Y} P(T_K) = j)) \quad (2-4)$$

$$S = \frac{1}{N} \sum_{i=1}^N (Q(X_i, Y) - \text{MAX}_{j \neq Y} Q(X_i, j)) \quad (2-5)$$

因此分类器的强度在具体到随机森林中的决策树实际个数而言,分类强度数值越大则 RF 越佳。

第二节 深度学习理论

一、卷积神经网络

卷积神经网络(Convolutional Neural Networks, CNN)是在 MLP (多层感知机 MLP, Multi-Layer Perceptron) 的基础上进一步优化发展的深度神经网络,其包含卷积层和能够进行深度学习的前馈神经网络计算结构。最早的运用是 LeNet 网络通过调用 CNN 算法来完成对于手写体的辨别和录入,这一方法比其他固有的算法运算更加优化且真实拟合。2012 年随着 AlexNet 网络提出,以卷积神经网络为关键技术的深度学习算法逐渐得到发展。因为 Convolutional Neural Networks 在辨别二维结构数据上具有优良性状,而图像结构在建模时通常被看作一组包含二维信息的数据,所以 CNN 在图像的分类、识别上广泛应用。

卷积神经网络以此包括输入层、卷积层、池化层、全连接层和输出层,并最终完成对特定应用场景的分类等功能,卷积运算实际上是一种数学运算,通过提取输入数据并将输入数据进行维度的压缩,经卷积、池化后捕获到全局特征和局部特征,卷积网络运算的核心就是在多个空间中共享参数。

卷积神经网络的运算步骤为:

(一) 输入层:输入层进行对输入的原始数据进行筛选、过滤、去噪、归化等步骤数据预处理。

(二) 卷积层:完成数据特征的提取,形成局部感知。卷积神经网络算法对每层网络进行卷积计算,每层网络含有卷积核、步长和填充。而卷积过程实际上是一种数学运算,预算过程是把卷积核上包含的所有的权重分别和对应元素相乘之后再相加,最后输出结果。

(三) 池化层:对数据降维。完成对特征高效获取后,卷积特征图被输入到池化层,在池化层中利用特定的池化函数把卷积图中顶点结果转换为临近范围的特征统计量,完成信息选择和过滤输出。一般情况下最大池化和均值池化是最常用研究选择。

(四) 全连接层:特征聚集。全连接层在运算中通过卷积矩阵向量乘积实现。卷积层、池化层和激活函数层等前步运算是把初始数据投射到隐层特征空间中去,全连接层则会把训练得到的分布式特征表示方法传递到样本标记空间,将前两层的提取的

特征进行非线性组合得到输出。全连接层中会失掉特征图的多维结构，依据高阶特征训练，将特征图转为向量输入。全连接层在卷积神经网络中担当的是分类处理器的功能，全连接层与传统前馈神经网络中的隐含层作用相同。

（五）输出层：输出结果。输出层连接在全连接层之后，实现对结果输出，与传统神经网络的输出层功能相同。

二、图卷积神经网络

由于卷积神经网络中包含的卷积核大小为二维矩阵，所以卷积神经网络在计算时受到欧氏空间距离的限制，对于输入数据具有一定的要求，例如图片、音频、视频进行数据处理时，要求影音网格结构的数据拥有相对稳定的几何数量关系。然而实际计算时存在非线性非规律非稳定且不具有几何关系的空间结构，因此针对非稳定无序性结构提出图卷积神经网络(Graph Convolution Network, GCN)，图卷积神经网络有效处理了非欧几里得结构的数据，将图的形式和卷积神经网络相融合，能够高效的提取拓扑图的空间特征，完成对图结构的卷积学习。




图 2-4 CCN 与 GCN 算法示意

（一）图论

图(Graph)是构建数据结构和进行计算时的强大的基础框架。图的结构可以承载大量信息并广泛应用于各个领域。无论是交通联通路网、人际交流网还是信息通讯传输，都表现出具有网格结构，个体与个体之间存在联通的结构。假如运用顶点的形态来表示网格中的个体，那么个体与个体之间具有的相互联通性和传递性，顶点之间的联系通过边的形式串联，将边与点相连即可得到关系图中连接的总和，也就是形成了完整拓扑结构图。

目前，现实生活中绝大多数数据可以转化为承载信息值的图的结构，因此许多研

究者开始将神经网络算法模型应用到包含图的结构中计算。传统的卷积神经网络在计算预测值中取得不错的效果，卷积计算通过矩阵状空间格的卷积核在图像上平移，采用卷积的方式完成对数据的特征提取。

图的形式是描述个体与个体之间相互关系并且承载事务所具有信息的一种结构，通常由具体顶点和顶点之间相互连结的边来构成数据集。顶点抽象化表示待研究个体的形式，边则表示研究个体与个体之间的相互关系，因此个体间具有连通性。

图通常可以用 $G(V, E)$ 来进行表示，其中， G 表示单位数量的一个图， $V = \{V_1, V_2, V_3, V_4, \dots, V_n\}$ 表示点的集合， V 是图 G 中包含的点值， V_n 表示具有的第 n 个顶点， n 表示图中包含的顶点数量数量。 $E = \{e_1, e_2, e_3, e_4, \dots, e_m\}$ ，其中 E 为图 G 中连边的集合， m 表示图中相连边的数量，表示顶点 V_i 和顶点 V_j 之间的连通性。根据图中的边有无明确方向，可以将图分为有向图和无向图。




图 2-5 有序图与无序图示意

图的神经网络是一种连接类模型，通过图中节点之间的消息传递来获取图的相关性。通过对多阶邻居的信息聚合，更新中心的节点。

（二）矩阵

图的存储形式多种多样，常见的存储表示方法有邻接矩阵、关联矩阵。其中，邻接矩阵使用最为广泛且在计算中易于结合矩阵的运算存储方式。

1、邻接矩阵 $A \in R^{n \times n}$ ，当顶点 i 与顶点 j 之间存在连边 e_{ij} 时， A_{ij} 对应的元素为 1，否则为 0。其定义为：

$$A_{ij} = \begin{cases} 1, & e_{ij} \in E \\ 0, & \text{otherwise} \end{cases} \quad (2-6)$$

2、图的度矩阵为顶点的度构成的对角矩阵。对角线上的元素表示对应的顶点的度数，即 $D_{ij} = \sum_j A_{ij}$ ， D 为图的度矩阵。

3、图的拉普拉斯矩阵在对称归一化的拉普拉斯矩阵一般定义为：

$$L = I_N - D^{-\frac{1}{2}} * A * D^{-\frac{1}{2}} = D^{-\frac{1}{2}} * (D - A) * D^{-\frac{1}{2}} \quad (2-7)$$

I_N 表示单位矩阵， A 为图的邻接矩阵和 D 表示度矩阵。由于拉普拉斯矩阵 L 是实对称矩阵。所以拉普拉斯矩阵 L 可以进一步分解为：

$$L = U\Lambda U^T \quad (2-8)$$

其中， U 表示拉普拉斯矩阵的特征向量构成的矩阵， Λ 则表示对角线上的元素代表拉普拉斯矩阵的特征值。

$\begin{bmatrix} 3 & 0 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 & 0 \\ 0 & 0 & 2 & 0 & 0 \\ 0 & 0 & 0 & 4 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix}$	$\begin{bmatrix} 0 & 1 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 1 & 1 & 0 & 1 \\ 0 & 0 & 0 & 1 & 0 \end{bmatrix}$	$\begin{bmatrix} 3 & -1 & -1 & -1 & 0 \\ -1 & 2 & 0 & -1 & 0 \\ -1 & 0 & 2 & -1 & 0 \\ -1 & -1 & -1 & 4 & -1 \\ 0 & 0 & 0 & -1 & 0 \end{bmatrix}$
度矩阵	邻接矩阵	拉普拉斯矩阵

图 2-6 矩阵示意

（三）图卷积方法

图卷积神经网络在处理图数据上具有明显的优越性，图卷积神经网络能捕捉图结构特征依据图结构特征来进行深度学习。在输入层输入一张包含拓扑数据的图，在输入层进行数据归化并对图的拓扑结构进行特征提取，捕获到特征后传入卷积层，图的卷积神经网络算子对图各个层次的网络节点进行卷积方法运算，在进行多层的图卷积计算之后，图中的节点数据采用了广度优先等若干遍历方法进行了全图遍历，遍历图结构的全部节点完成对图结构全部特征的提取。遍历提取得到每个图中两点间具有的关系数据，图的卷积能够在除了捕获到某一节点所具备的全部信息后，又运用临界矩阵完成对该节点邻近区域范围内其他节点的信息。因此，图卷积方法网络会因为卷积方法的深度提高而更加详细的学习，精准学习到全部节点的特征，从而能将数据传递到所有具备拓扑结构的数据中去。

GCN 的训练网络图例的主要框架如图 2-7。




图 2-7 GCN 训练网络图例

图的卷积方法主要分为谱域方法和空间域方法。

谱域方法是基于谱域的图卷积方法是在在谱空间定义图卷积，可以看作是空间域的子集形式，卷积定理为：

$$X * GY = U((U^T X) \odot (U^T Y)) \quad (2-9)$$

谱域的主要工作为捕捉图中节点信号投影到谱域，在谱域完成域的卷积后使用傅里叶逆变换返回到空间域，具体实现为：

$$X * GY = U g \theta U^T X, X \in R^n \quad (2-10)$$

图谱理论基于卷积理论，经过损失函数调用基于梯度优化的方法完成对卷积核参数的优化，第 L 层的定义为：

$$X_j^{l+1} = \sigma(U \sum_i^p C_{ij}^l U^T X_i^l), j = 1, \dots, q \quad (2-11)$$

其中， $X^1 \in R^{n \times p}$ 、 $X^{l+1} \in R^{n \times p}$ 表示的是第 L 层图卷积的输入矩阵和输出矩阵， p 表示输入矩阵的特征数量， q 表示第 L 层图卷积输出矩阵的特征数量； σ 等于非线性激活函数； U^T 表示对图拉普拉斯矩阵进行特征分解后得到的向量转置矩阵； $C \in R^{p \times q}$ 表示卷积核参数；但谱域方法存在一些局限性，由于在计算中依赖拉普拉斯矩阵，转置矩阵 U^T 只适用性局限于聚合图中的节点，缺乏对图的拓扑结构处理，因此不满足空间不变性，在进行聚合操作时，每个节点在运算时会对其他非邻近值的特征造成一定程度上的聚合操作。此外图卷积操作矩阵转置信号复杂度高，运行时计算代价昂贵。

为了解决谱域卷积神经网络的局部性特征，研究者建立了切比雪夫图卷积 ChebNet1 方法和 GCN 计算方法。GCN 为将图的拉普拉斯矩阵的最大近似值等于 2，

则拉普拉斯矩阵可表示为式 (2-12)。

$$X^{l+1} = \sigma((\alpha_0 + \alpha_1(L - I_N))X^l) \quad (2-12)$$

其中 $\alpha_0 \in \mathbb{R}$, $\alpha_1 \in \mathbb{R}$ 表示参数; $X^l \in \mathbb{R}^N$ 表示第 L 层图卷积的输入的信号值, 若令 $\alpha_0 - \alpha_1 = 0$, 则可得到式 (2-13)。

$$X^{l+1} = \sigma(\alpha \tilde{D}^{-\frac{1}{2}} \hat{A} \tilde{D}^{-\frac{1}{2}} X^l) \quad (2-13)$$

其扩展形式为式 (2-14)。

$$X^{l+1} = \sigma(\tilde{D}^{-\frac{1}{2}} \hat{A} \tilde{D}^{-\frac{1}{2}} X^l \theta) \quad (2-14)$$

其中 X^l 是第 L 层输出, $\hat{A} = A + I_N$, $\tilde{D} = \sum_j \hat{A}_{ij}$ 代表的是度矩阵, $\theta \in \mathbb{R}^{C \times C}$ 表示卷积核的参数, σ 表示非线性 sigmoid 函数 (隐藏层神经元输出)。

空间域方法则是将卷积神经网络在空间上的节点卷积运用到图数据上, 其原理是定义图中的每个节点, 确定并完成每个节点的邻近区域的数据聚合, 为邻域定序, 根据不同节点的邻域节点自行选择并适应后卷积操作, 实现邻域间的信息共享, 完成图的卷积操作。

$$X_v^{l+1} = \sum_{u \in Nb(v)} X_u^l \quad (2-15)$$

式中 X_u^l 等于在第 L 层的特征, $Nb(v)$ 象征着节点上 v 的邻域内的节点集合。

目前常用的空间域计算图卷积方法其中之一为注意力网络算法(Graph Attention Network, GAT), 注意力网络是给图中随机某个节点和全部邻域节点进行注意力打分, 并采用测算的注意力分数对邻域特征完成聚合, 其聚合公示如式 (2-16) 至 (2-18) 所示。

$$e_{ij} = \text{Leaky ReLU}(a^T [W_{hi} \parallel W_{hj}]) \quad (2-16)$$

$$a_{ij} = \text{soft max}_j(e_{ij}) = \frac{\exp(e_{ij})}{\sum_{vk \in N(v_i)} \exp(e_{ik})} \quad (2-17)$$

$$a_{ij} = \frac{\exp(\text{Leaky ReLU}(a^T [W_{hi} \parallel W_{hj}]))}{\sum_{vk \in N(v_i)} \exp(\text{Leaky ReLU}(a^T [W_{hi} \parallel W_{hj}]))} \quad (2-18)$$

式中 $\parallel$ 表达为拼接操作, 也就是拼接 W_{hi} 和 W_{hj} 两个矩阵。 $X \in \mathbb{R}^{C \times C}$ 为进行了线性变换的矩阵, 也就是 $hi = W_{hi}$, $\exp$ 表示指数运算; 节点 V_j 表示节点 V_i 的邻域, $N(V_i)$ 表示包含节点 V_i 的邻域集合; 集合; $\alpha \in \mathbb{R}^{C \times C}$ 代表的是注意力机制的所设定的参数; Leaky ReLU 表示非线性激活函数。

第三节 空间距离度量方法

一、欧氏距离

欧氏距离 (Euclidean Distance) 也称欧几里得距离, 是最常见的空间距离度量公式, 欧氏距离是衡量多维空间中各个点之间的绝对距离, 即两点的直线距离。指在 m 维空间中两个点相距的实际距离, 或者向量本身的自然长度, 也就是即该点到原点的相距距离, 即平面上两点的直线距离。

Euclidean Distance:

$$\text{dist}(A, B) = \sqrt{\sum_{i=1}^n (A_i - B_i)^2} \quad (2-19)$$

二、余弦距离

余弦距离是在向量空间中依据两个向量点之间夹角的余弦值作为评价两个点之间差异的度量单位。假如两个向量点的方向保持一致, 其夹角则会接近于零, 那么这两个向量具有一定的相近性。余弦定理的夹角则是用来计算不同向量间方向是否具有 consistency。余弦距离关注的是空间向量的夹角, 除两点间的距离外更侧重关注在方向上的差异性。假设 A 点保持位置不动, B 点依照原有运动方向远离坐标轴原点, 则其两点间的夹角没有变化, 则余弦距离不发生变化。

$$\text{dist}(A, B) = \cos(\theta) = \frac{\sum_{i=1}^n (A_i B_i)}{\sqrt{\sum_{i=1}^n (A_i)^2} \sqrt{\sum_{i=1}^n (B_i)^2}} \quad (2-20)$$

三、Haversine 距离

Haversine 公式本质是球面余弦函数的数学变换形式, 在使用球面余弦公式进行计算时, 当系统的浮点运算精确度低的时候, 在计算较近的两个点间相距的距离时含有 $\cos$ 项会造成一定误差, Haversine 公式计算时经过数学变换从而消除了 $\cos$ 项, 因有效解决了在系统计算精度低的时候对短程距离计算的误差问题。假设地球上有点 $A(\alpha_A, \beta_A)$, $B(\alpha_B, \beta_B)$ 两点, 其中 α 和 β 分别表示是 A 和 B 的经纬度。则 A 和 B 两点间的球面距离等于点 A 和点 B 所对应的弧长, 根据经度纬度位置和地球的半径 R , 把 A 、 B 两点对应的经纬度坐标代入计算并转换为球体里的三维坐标, 在计算出 A 、 B 两点的三维坐标后代入余弦定理求出 A 和 B 到地球球心 O 的夹角 AOB , 则 AB 弧

长= $R \times \text{角 AOB}$ ，其计算公示如式（2-21）至（2-23）所示。

$$h(\theta) = \sin^2\left(\frac{\theta}{2}\right) = \frac{1 - \cos(\theta)}{2} \quad (2-21)$$

$$h(\theta) = h\left(\frac{d}{R}\right) = h(\Delta\beta) + \cos(\beta_1) \cos(\beta_2) h(\Delta\alpha) \quad (2-22)$$

$$\cos(\theta) = \sin(\beta_1) \sin(\beta_2) + \cos(\beta_1) \cos(\beta_2) \cos(\Delta\alpha) \quad (2-23)$$

第四节 评价指标

在评价预测模型的性能，采用有均方误差 MSE（Mean Squared Error）、均方根误差 RMSE（Root Mean Square Error）、平均绝对误差 MAE（Mean Absolute Error）指标来进行评价。

一、MSE

MSE（Mean Squared Error）均方误差。是用来反映估计值和被估计值中存在的差异程度的度量指标，常被称为损失函数。是指参数估计值与参数真值之差平方的期望值。均方误差的范围取值为 $[0, +\infty)$ ，当预测值与真实值不存在差异时等于 0，即被称为是完美模型；当预测值与真实值之间的误差越大，那么取得的均方误差值越大。其公式如下，其中， m 为测量次数， $y_i - \hat{y}_i$ 为测量值与真值之间的误差。

$$\text{MSE} = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2 \quad (2-24)$$

二、RMSE

RMSE（Root Mean Squard Error）均方根误差亦称标准误差。均方根误差的范围取值为 $[0, +\infty)$ ，当预测值与真实值不存在差异时等于 0，即被称为是完美模型；当预测值与真实值之间的误差越大，则取得的均方误差值越大。其公式如下。其中， m 为测量次数， $y_i - \hat{y}_i$ 为测量值与真值之间的误差。

$$\text{RMSE} = \sqrt{\frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2} \quad (2-25)$$

三、MAE

MAE（Mean Absolute Error）平均绝对误差，又叫平均绝对离差，是计算待观测

值与其算术平均值的偏差中绝对值的平均数。MAE 可以避免误差之间相互抵消的问题，从而可以准确反映实际计算中预测误差的大小。平均绝对误差的范围 $[0, +\infty)$ ，当预测值与真实值不存在差异时等于 0，即被称为是完美模型；误差越大，平均绝对误差值越大。其中， m 为测量次数， $|y_i - \hat{y}_i|$ 为测量值与真值之间的误差绝对值。

$$MAE = \frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i| \quad (2-26)$$

第五节 本章小结

本章介绍了本文所涉及的机器学习理论、卷积神经网络理论、图卷积神经网络理论、空间距离度量理论。首先提出了在潮汐区域识别时应用的机器学习理论，随后介绍了在车流量预测模型中建立的机器学习理论和深度学习理论，并给出在实际计算中应用的空间计算公式，给出在本文中应用到的评价指标，为后文模型建构提供了理论基础。

第三章 基于 KNN 潮汐区域分类识别模型

第一节 车流量潮汐问题可视化分析

共享单车的共享特性以及其方便特性决定了其位置移动的随机性,且由于人类活动存在“日出而作,日落而息”的客观规律,并且工作时间段较为集中,作为短途接驳工具,共享单车在使用中极易出现潮汐现象。城市内共享单车的投放数量有限,因此在使用中出现的供需矛盾客观存在,其中尤以早晚高峰时段共享单车“一车难寻”、“无处停放”的潮汐问题最为突出。

调用 folium 挖掘订单中 GPS 位置数据、轨迹数据,提取某一早高峰段的区域内单车停放密度数据与停车点位数据,通过热力图可视化直观反映出区域内单车潮汐现象。

如图 3-1 共享单车在停放点位上某些区域潮汐现象严重,如图 3-2 某些区域不具有潮汐现象,潮汐现象集中在功能区附近,体现其部分区域具有明显的聚集效应。因此在重点功能区域共享单车停放位置反映出其停放点位随机性,还车地点分散性,功能区域间迁移跨度性大的特点。热力图中颜色表示为具体停车位置的热度,点位是具体停车点的停放位置(即 LOCK_STATUS =1 时对应的具体位置)。




图 3-1 停车点潮汐区域热度图




图 3-2 停车点位非潮汐区域热度图

第二节 数据预处理

抓取城市一段时间内共享单车的订单数据，以厦门市共享单车城市数据为例，数据集包括共享单车订单数据（包括订单编号、单车编号、开关锁时间、经纬度定位值、用户编码等）。

经过数据比较，共享单车在一天内订单量突增多集中在早高峰时段，早高峰为上班通勤时间，共享单车订单使用量在短时间内激增，因此选定实验数据集的时间段为早高峰时段。对原始数据进行数据预处理，提取一周时间内，每天 6:00-10:00 时段的共享单车数据，时间数值精确到以秒为单位，作为订单中研究的时间数据。在近万数量级的共享单车数据中进行数据筛选，去除冗杂且信息含量较低的信息标签，去除空白数据，对骑行订单、骑行起点、终点信息、单车定位经纬度、单车开关锁时间等数据进行有效提取，完成数据预处理。

数据预处理见图 3-3。




图 3-3 原始数据集

第三节 潮汐区域分类识别模型

一、技术路线图

解决潮汐问题，实际上是在研究中实际面临的问题城市内停车区域未知所带来的问题，对于生活单车潮汐区域的识别和预测显得极为重要。因此本文提取停车点位电子围栏数据，用 Geohash 库来对订单中的出现经纬度编码，依据停车点经纬度范围计算停车点位面积。验证 K-Nearest Neighbors 分类算法和 Geohash 算法分类的合理性和可行性，寻找精度最高的数据处理方法。计算各个区域内留存单车密度的同时以街道作为分类依据，使用 K-Nearest Neighbors 测量出不同特征值之间的距离进行分类，识别出工作日早高峰时段潮汐现象最突出的区域。技术路线图 3-4 如下：




图 3-4 潮汐街道识别技术路线图

二、基于空间距离计算的方法改进

在空间距离计算的方法选取上，对传统的机器学习模型中的计算方法进行改进，具体改进如下：

传统模型在计算时多采用欧氏距离（Euclidean Distance）或余弦距离来作为空间距离度量公式。由于欧氏距离时是在各维度特征的绝对数值的基础上来进行计算，因此欧氏距离在计算时应确保各维度指标在一样的刻度级别。而余弦距离公式计算的是空间向量的夹角，除两点间的距离外更侧重的是表现在方向上的差异。假如保持 A 点的位置不动，B 点依照原有方向运动且远离坐标轴原点，则其两点间的夹角没有变化，那么余弦距离的值仍然不变，然而实际上 A、B 两点的距离是发生了变化的。

在空间距离的公式选择上，当选取的单车点为一对长度差距大，坐标内容相近的值时，样本在特征空间中的表现出的欧氏距离计算数据值较大。而余弦相似度在计算时考虑两坐标夹角，因此其特征间的相似度高。在计算空间内的目标对象时，特征维度较高，余弦相似度在高维计算的时候具有“相同时等于 1，正交时等于 0，相反时等于-1”的计算性质，但是欧氏距离的数值则会受制于维度的影响，计算范围不明确，在含义表达上定义较为模糊。欧氏距离在计算时会在数值上表现出绝对差异，而余弦距离在计算时会在方向上表现出相对差异。例如，在计算两单车停车点位时，用户 A 的位置向量为（0，1），用户 B 的位置向量为（1，0），那么此时二者在计算相距距离时的余弦距离差值很大，相反欧氏距离差值很小。因此为了体现用户停车点位的相对差异，选取余弦函数作为计算更为合适。如图 3-5 所示。




图 3-5 欧式距离与余弦距离示意

Haversine 距离计算是在地理空间距离计算方法时代入球面模型，使得球面模型最贴近真实地球，计算精度较高。球面余弦公式中有三角函数的 $\cos(\alpha_A - \alpha_B)$ 项，当系统设定的浮点运算精度低的时候，在求算经纬度跨度较小的两点间的距离将产生一定大的误差，Haversine 方法进行了数学变换从而消除了 $\cos(\alpha_A - \alpha_B)$ 项，因此降低了短距离求算时对系统计算精度误差。因此，本文在计算时选用 Haversine 距离公式来减少实际误差值，提高预测精度。




图 3-6 欧式距离与余弦变换示意

三、Geohash 算法模型

（一）经纬度编码

调用 GeoHash 算法将二维的空间上的经纬度坐标数据编码转换为字符串，通过

逼近编码得到经纬度的二进制序列, 序列的长度和对计算区间进行的划分次数有一定的相关性。以经度纬度的坐标值实现在数据库中实现某一系列数值的应用索引的功能。




图 3-7 GeoHash 二进制

GeoHash 的精度编码越长, 代表计算时迭代次数多, 其在计算中表示的范围区间越小, 位置值表示时越精确。因此在建立模型时可通过比较 GeoHash 匹配的位数来判断两两坐标值之间的距离值。GeoHash 精度数值表示为:

表 3-1 GeoHash 精度数值

Geohash length	Lat bits	Lng bits	Lat error	Lng error	Km error
1	2	3	± 23	± 23	± 2500
2	5	5	± 2.8	± 5.6	± 630
3	7	8	± 0.70	± 0.70	± 78
4	10	10	± 0.087	± 0.18	± 20
5	12	13	± 0.022	± 0.022	± 2.4
6	15	15	± 0.0027	± 0.0055	± 0.61
7	17	18	± 0.00068	± 0.00068	± 0.076
8	20	20	± 0.000085	± 0.00017	± 0.019

(二) 计算区域范围

通过 GeoHash 编码计算得到特定矩形区域, 以字符串编码来表示经度和纬度组成的地点坐标, 矩形区域范围内所有经纬度坐标点将共用同一 GeoHash 字符串。

表 3-2 GeoHash 区域划分

	FENCE_LOC	MIN_LAT ITUDE	MAX_LAT ITUDE	MIN_LON GITUDE	MAX_LO NGITUDE
1	[[118.103198, 24.527338] [118.103224, 24.527373] [118.103236, 24.527366] [118.103209, 24.527331] [118.103198, 24.527338]]	24.527331	24.527373	118.103198	118.10323
2	[[118.103231, 24.527386] [118.103257, 24.527421] [118.10327, 24.527413] [118.103244, 24.527378] [118.103231, 24.527386]]	24.527378	24.527421	118.103231	118.10327
3	[[118.103257, 24.527421] [118.103282, 24.527455] [118.103295, 24.527447] [118.10327, 24.527413] [118.103257, 24.527421]]	24.527413	24.527455	118.103257	118.10329
4	[[118.102948, 24.527003] [118.102979, 24.527046] [118.102992, 24.527038] [118.102961, 24.526995] [118.102948, 24.527003]]	24.526995	24.527046	118.102948	118.10299 2
...	...	...	...	...	...
14069	[[118.115202, 24.44032356] [118.1152037, 24.44044408] [118.1152185, 24.44044397] [118.1152175, 24.44032345] [118.1152026, 24.4403235]]	24.440323 45	24.4404440 8	118.115202 6	118.11521 86
14070	[[118.1157293, 24.43916106] [118.1155904, 24.43916263] [118.1155906, 24.43917642] [118.1157295, 24.43917485] [118.1157293, 24.4391610]]	24.439161	24.4391764	118.115590	118.11572

其中 Geohash 编码的前缀表达的含义是包含更大的范围。例如,ws7gn7,它的前缀 ws7gn 表示包含编码 ws7gn7、ws7gnu 等在内的更大范围。范围包容特性可以应用到附近地点的搜索任务中。根据用户当前坐标计算 Geohash (例如 ws7gn7),然后选择前缀输入并进行查询 (SELECT * FROM place WHERE geohash LIKE 'ws7gn%'),可得到附近的全部地点,完成目标地区的街道流量聚合,如图 3-8 所示。




图 3-8 Geohash 区域潮汐图

（三）计算单位面积留存车辆密度

通过 Geohash 将经纬度编码为一个字符串，调整 precision 控制编码精度，precision 与定点位置强相关。提取停车点位电子围栏数据，计算停车点经纬度范围，根据停车点范围计算具体面积。

按照天数进行单车流量统计，提取街道信息，计算每个街道不同停车点的留存车辆，然后计算密度。这里我们需要计算每个街道不同停车点的留存车辆，即统计某一范围内存在关锁车辆数大于开锁车辆数，计算该区域内平均每天的单车留存数量，并注意设置不能重复统计。其中，inflow 表示区域内的进车数量（以关锁时间点为准），outflow 表示区域内出车数量（以开锁时间点为准），bike fence 表示街道停车区域总面积。

$$bike\ fence[Geohash] = bike\ fence[fence_center] \tag{3-1}$$

$$bike\ density = \frac{inflow - outflow}{bike\ fence} \tag{3-2}$$

将区域内停车密度按照降序排列，识别早高峰时段潮汐现象最突出的区域：

表 3-3 Geohash 测算潮汐区域密度

	Street	density
0	新丰路（火炬路至火炬北路）	264.109027
1	金榜西路 0	261.504821
2	市政 19	196.202314
3	市政 2	192.822917
4	市政 1	192.085638
...	...	...
889	环岛干道	0.000000
990	后滨东路	0.000000
991	火炬二路	0.000000
992	龙虎西二里	0.000000
993 rows * 2 columns		

四、K- Nearest Neighbor 改进模型

（一）经纬度编码

用 Geohash 库来对订单中的出现经纬度编码，进行坐标系经纬度的匹配校准，定义数据边界，删除重复值，并剔除骑行日期异常、开关锁异常等一系列缺失数据，完成数据归一化处理，提取相关数据值做可视化分析，完成数据特征分析，分析挖掘潜在规律来进一步设计预测策略。调整 precision 控制编码精度，precision 与定点位置强相关。提取停车点位电子围栏数据，计算停车点经纬度范围，根据停车点范围计算具体面积。

（二）车辆流量聚合

K-Nearest Neighbor 分类算法是依据测量出不同特征值间的距离长度作为分类依据。选取 k 值中应用的关键指标是 SSE(sum of the squared errors, 误差平方和)。随着聚类数 k 值的不断增加，划归样本子集便会越加精细，每个数据簇的聚类程度将会提高时，误差平方和 SSE 会随其逐渐缩小。当真实聚类数大于 k 值时，则会因为 k 值的增大导致增加了每个数据簇的聚合程度，所以 SSE 会大幅下降，而当真实聚类数接近并到达 k 值时，再聚合程度会因为增加 k 值而迅速减小，所以 SSE 的下降程度会大幅减少，并将伴随 k 值的持续增大而逐渐走向平缓。

$$SSE = \sum_{i=1}^k \sum_{p \in C_i} |p - m_i|^2 \quad (3-3)$$

其中， C_i 表示第 i 个簇，p 为 C_i 中的样本点， m_i 为 C_i 的质心也就是 C_i 中所有样本的均值。

计算 SSE 来选择最优的 K 值，观察图 3-9 可得 $K=15$ 。




图 3-9 K 值选取

即单车位置的特征与训练集中对应的特征进行相互比较，在划定的街道内选择邻

近的前 15 个最相似的位置样本，将临近点位的单车位置划分到同一数据簇，则该样本也属于这个数据簇。分类步骤为计算样本数据和每个训练数据间的空间距离，并把空间距离的递增关系作为排序依据，选取与样本距离最近的 15 个点并计算确定前 15 个点所在分类中频率高低，返回最高出现频率的数据集来作为最终预测结果。

```
def fence_recommend1(fence_id):  
    fence_center      =      bike_fence.loc[bike_fence['FENCE_ID']==fence_id,  
'FENCE_CENTER'].values[0]  
    fence_dir = fence_id.split('_')[1]  
    dist, index = knn.kneighbors([fence_center], n_neighbors=15)
```

（三）计算单位面积留存车辆密度

街道流量聚合后，使用 K- Nearest Neighbor 并设置 haversine 距离。计算时由于地点匹配数据过多，经纬度差值计算数据量较大，用 hnswlib 做近似值搜索，计算各个区域内留存单车密度的同时，可以提高运算速度。将区域内停车密度按照降序排列，识别出工作日早高峰时段潮汐现象最突出的区域。按照天数进行单车流量统计，提取街道信息，计算每个街道不同停车点的留存车辆，然后计算密度。这里我们需要计算每个街道不同停车点的留存车辆，即统计某一范围内存在关锁车辆数大于开锁车辆数，计算该区域内平均每天的单车留存数量，并设置不能重复统计。

表 3-4 K- Nearest Neighbor 测算潮汐区域密度

	Street	density
0	观日路（望海路至会展路段） 0-R-1	36.277178
1	象屿路 0-R-1	26.081268
2	象屿路 0-R-2	18.760222
3	望海路 0-R-2	18.665856
	Street	density
4	云顶北路	13.912339
...	...	...
14067	龙虎山路-R-11	0.000000

续表 表 3-4 K- Nearest Neighbor 测算潮汐区域密度

	Street	density
14068	龙虎山路-R-7	0.000000
14069	龙虎山路-R-6	0.000000
14070	龙虎西二里	0.000000
14071 rows * 2 columns		

第四节 本章小结

将基础数据按照临近值分类，采用 Geohash 算法和 K- Nearest Neighbor 算法两种不同的空间区域分类方法，分析采用两种不同分类方法的合理性和可行性，寻找目标最优的计算方法。在聚合街道单车流量时，最常见的方法为使用欧氏距离作为空间距离计算公式，而欧氏距离计算的是多维空间中每个位置之间的绝对距离，余弦相似度在计算时考虑两坐标夹角，因此在计算中存在的一定的测量误差，使得计算值对于实际距离有所偏离。本文在空间距离计算时创新引用公式，在求算经纬度跨度较小的两点间的距离时会产生大的误差，Haversine 进行数学变换后消除三角函数项，因此降低了短距离求算时面对的系统计算精度误差。

计算各个区域内留存单车密度作为街道分类依据，做区域间的邻近值搜索，按照降序识别出潮汐严重的街道区域。经过结果比较，选择分类数据更为细化的 K- Nearest Neighbor 作为最优分类方法。

第四章 基于 GCN 共享单车流量预测模型

第一节 车流量时空特性可视化分析

解决共享单车目前存在的区域分布不均衡和供需矛盾等问题,需要挖掘现有的共享单车使用信息进行规律性特征提取,从而完成对共享单车运用的优化。而从实用性角度来考虑,共享单车分布在城市各处,用户使用共享单车在一定程度上反映出城市交通情况和人员流动情况,共享单车系统记录下的具有一定研究意义的信息,能够真实反映出市民的出行行为和出行需求。因此,通过大数据和数据挖掘技术分析轨迹信息将能更高效、合理地挖掘共享单车的时空特性。在区域分类后,对单位时间内区域单车总体进出量建立跨区域预测模型作为智能预测。在分类阶段对区域融合和筛选的条件进行预测量计算并分别建立机器学习模型和深度学习模型,选取指标表现最优的模型作为预测模型,从而提高共享单车的使用效率和功能优化。

一、空间特征

导入共享单车订单数据,生成共享单车厦门市卫星遥感分布图。(图中仅以 2020 年 12 月 21 日厦门市共享单车订单数据为例作为展示)。共享单车订单使用具有区域分布不均衡、地域跨度大的现象,单车订单量由市中心向郊区数量递减,单车订单广泛集中于经济较为发达的市区,郊区内共享单车零散分布。



图 4-1 厦门市共享单车订单数据卫星

以单车的起点和终点为数据基础,匹配单车位置点生成单车的骑行路径。共享单车骑行路径分布于软件园及公交站点,验证共享单车作为短途出行工具,具有衔接公

交站点的代步属性。由图 4-2 可见，共享单车的行车路线短、行车轨迹稳定，行车路线集中在办公区符合早高峰时段的用户通勤需要。




图 4-2 部分订单路径

共享单车停车点位（电子围栏）数据为规范共享单车停车秩序，统一划定共享单车停放区域。将共享单车关锁地点及区域内停放车点位经纬度进行匹配，展示居民日常停车点位分布。居民用车区域多集中于办公区、居民区等具有明显生活属性地段。




图 4-3 部分停车点位置分布图

可见，共享单车在骑行与停放中具有明显空间特性，所处的空间点位对于预测值具备关联性，因此在研究中提取数据集中的空间数据作为特征向量。

二、时间特性

提取同站点的共享单车出入流量进行直观展示,早高峰时段区域内进车数量高于出车数量,单车停放堆积现象存在。使用透视表提取每个区域范围内不同时间段的入流量和出流量作为统计数据。

其中 LOCK_STATUS=1 为订单关锁状态可看作为停放在该区域,即进入区域的单车数量,LOCK_STATUS=0 为订单开锁状态可看作是骑出该区域的单车流量。DAY_HOUR 即为提取不同日期的不同时段数据。

```
bike_inflow = pd.pivot_table(bike_order[bike_order['LOCK_STATUS'] == 1],
                             values='LOCK_STATUS', index=['geohash'],
                             columns=['DAY_HOUR'], aggfunc='count',
                             fill_value=0 )

bike_outflow = pd.pivot_table(bike_order[bike_order['LOCK_STATUS'] == 0],
                              values='LOCK_STATUS', index=['geohash'],
                              columns=['DAY_HOUR'], aggfunc='count',
                              fill_value=0 )
```




图 4-4 A 区域出入车流量对比折线图




图 4-5 B 区域出入车流量对比折线图

由图可知共享单车需求量时段分布不均，区域内出入车流量存在差异，无法在一定时间内能维持进出平衡，单位区域内的车辆密度不具有明显的回归关系，时间段内出入流量存在明显差异。共享单车在区域范围内出入流量在不同时间段内表现出不同的特性，因此提取数据集中的时间数据作为特征向量。

第二节 机器学习预测模型

基于潮汐点严重的区域进一步设计预测方案，将数据集按照 7: 3 的比例划分为训练集样本和预测集样本，其中训练集样本包含 409704 条数据，训练集样本包含 175588 条数据。

```

bike_train, bike_test = train_test_split(bike_order, test_size=0.3,
                                         random_state=0)

print('Descriptive statistics of the training set: ')
print(bike_train.describe().round(2))

print('Validation set descriptive statistics: ')
print(bike_test.describe().round(2))

```

表 4-1 训练集描述性统计

Descriptive statistics of the training set					
	latitude	longitude	Lock-status	hour	minter
count	409704	409704	409704	409704	409704
mean	24.49	118.13	0.38	7.74	30.99
std	0.02	0.03	0.49	0.83	17.29
min	24.43	118.06	0.00	6.00	0.00
25%	24.48	118.10	0.00	7.00	17.00
50%	24.49	118.12	0.00	8.00	31.00
75%	24.51	118.15	1.00	8.00	46.00
max	24.56	118.20	1.00	9.00	59.00

表 4-2 验证集描述性统计

Validation set descriptive statistics					
	latitude	longitude	Lock-status	hour	minter
count	175588	17558	175588	175588	175588
mean	24.49	118.13	0.39	7.75	30.93
std	0.02	0.03	0.49	0.83	17.29
min	24.43	118.06	0.00	6.00	0.00
25%	24.48	118.10	0.00	7.00	16.00
50%	24.49	118.12	0.00	8.00	31.00
75%	24.51	118.15	1.00	8.00	46.00
max	24.56	118.20	1.00	9.00	59.00

依照不同的算法模型计算出预测值，对比训练集数据和新预测集数据值，引入 RMSE、MSE、MAE 等预测评价指标评估模型的效率。

RMSE: `np.sqrt(metrics.mean_squared_error(y_test, y_pred))`

MSE: `metrics.mean_squared_error(y_test, y_pred)`

MAE: `metrics.mean_absolute_error(y_test, y_pred)`

一、线性回归预测模型

经过数据分析,考虑到单车的使用量与区域位置、时间段等因素相关,因此将订单数据中经纬度、时段等看作是线性回归算法的自变量,区域内的单车使用数量为线性回归算法的因变量,多个自变量与因变量之间的回归关系来进行建模分析,计算出不同变量对于目标结果的回归系数,判定不同变量对于结果影响的强弱相关度,由多个回归系数的模型参数组成,目标值预期则为输入变量的线性组合,以向量的方式来表示预测值与特征变量之间的关系。

基于共享单车在骑行与停放中的明显空间特性,提取数据集中的 `latitude`、`longitude`、`lock-status` 作为特征向量。其中 `latitude` 表示每辆共享单车对应的纬度位置,`longitude` 表示每辆共享单车对应的经度位置,`lock-status` 则是在对应经纬度位置上的开关锁状态,即表示骑行与停放状态。基于共享单车在区域范围内出入流量在不同时间段内的时间特性,提取数据集中的 `hour`、`minter` 作为特征向量。其中 `hour` 表示每辆共享单车订单记录的时段,`minter` 则是精确到订单记录的分钟。除空间和时间特征外,特征选择上引入地铁在区域内的位置作为特征向量,作为短期接驳工具,地铁站距离区域的远近将会对共享单车的骑行和停放存在一定的影响,`distance` 则表示共享单车距离最近一处地铁站的距离。`passager` 则表示搜索到的在同一时段内地铁站闸机记录的进出站的人流量。

表 4-3 线性回归模型相关系数

	latitude	longitude	Lockstatus	hour	minter	distance	passenger	Pred
latitude	1.00000	0.35260	-0.0485	0.00087	0.00091	0.00342	0.00026	0.05416
longitude	0.35260	1.00000	0.04175	0.00688	0.00743	0.01571	0.02721	0.00810
Lockstatus	-0.0485	0.04175	1.00000	-0.2356	0.00328	0.04179	0.00593	0.03636
hour	0.00087	0.00688	-0.2356	1.00000	0.00635	0.02453	0.00641	0.02914
minter	0.00091	0.00743	0.00328	0.00635	1.00000	0.00592	0.00417	0.02642
distance	0.00342	0.01571	0.04179	0.02453	0.00592	1.00000	0.00362	0.00413
passenger	0.00026	0.02721	0.00593	0.00641	0.00417	0.00362	1.00000	0.05253
Pred	0.05416	0.00810	0.03636	0.02914	0.02642	0.00413	0.05253	1.00000

其中 `latitude`、`longitude`、`lock-status`、`hour`、`minter`、`distance`、`passenger` 为线性回归算法中的自变量,`pred` 为线性回归算法中的因变量,即单车订单数量算法中需要预测的值。

根据计算得出相关系数表，单车订单的 latitude、passenger 与订单 pred 的线性相关性最大，相关系数超过了 0.05；其次是单车订单生成时间段，相关系数均超过 0.02。但 latitude 与 longitude 间的相关关系超过了 0.03，distance 与 lock-status 的相关系数超过 0.4，即表示各影响自变量因素之间存在着多重共线性关系，不满足变量间相互独立的条件，该命题在理论上不适合进行线性回归分析。因此为了对比模型效果，仅保留该线性回归模型作为对照。

以不同的影响因素建立线性回归模型，其中 R^2 代表的是回归方程具有的整体拟合度，表示因变量和自变量具有的总体关系，即线性回归方程所能解释的因变量变异程度的百分比。回归误差可以对线性模型的拟合优度实现正面测量，该线性回归模型的拟合优度 R^2 仅为 0.005，即拟合效果不佳。自变量在显著性检验中($P>|t|$)均小于 0.05。

在进行模型评估时引入拟合优度 (R^2)、均方根差 (Mean Squared Error)、平均绝对误差 (Mean Absolute Error)、均方根误差 (Root Mean Squard Error)，得到线性回归模型的整体预测评价指标如表 4-4。

表 4-4 线性回归模型评价指标

	TRAIN	TEST
R^2	0.054711	0.056310
MSE	29.235231	29.235534
MAE	4.3608132	4.1959764
RMSE	5.4069613	5.4069893

二、随机森林算法模型

RF (Random Forest) 算法是 bagging 和 CART 树的组合。运用 bagging 方法来构建回归模型，依据投票或平均值的方法来确定最终预测值，以此来降低过拟合问题。在特征选择上运用平方误差最小的准则，将数据集 D 的平方误差进行定义。

$$D = \sum_{i=1}^{|D|} (Y_i - Y')^2 \quad (4-1)$$

其中， Y' 表示数据集 D 的平均值决策树分类上采用基尼指数最小化准则。




图 4-6 决策树模型运算示意

生成 CART 树并关注数据集 D 上包含的全部特征，遍历各个特征下包含的全部可能性的切分点或取值，将数据集 D 划归成 $D1$ 和 $D2$ 。分别计算 $D1$ 和 $D2$ 的平方误差之和，特征与分割点则采用相对应最小的平方误差，随之产生两个子节点。遍历生成的两个子节点递归调用和平方差计算，递归循环直到所有特征选择完毕，或分类到子节点数值极小以及平方误差小于阈值后停止，作为叶子节点并在其中训练回归模型当作预测值。

bagging 对训练样本选择 bootstrap 采样方法，进行 M 轮采用并分别构建决策树。因为每轮采集出的样本子集基本不具有相似性，训练的模型具有的相关性会降低。为了更好地降低模型彼此的相关性，每轮练习前对训练数据的选择进行随机采样，于决策树的每个 branch 来作为随机选择。

通过对单车订单的历史数据进行测算，对已有已知订单及潮汐区域等结果进行比对分析，寻找数据集中包含的特征，特征值包括订单数据中经纬度、时段等，实现对未来同时段内单车使用量的数据进行分类和预测。

```

X_train=bike_train.loc[:, features_tree]

y_train=bike_train.loc[:, 'LOCK_STATUS']

X_test=bike_test.loc[:, features_tree]

y_test=bike_test.loc[:, 'LOCK_STATUS']

from sklearn.tree import DecisionTreeRegressor

import matplotlib.pyplot as plt

tree = DecisionTreeRegressor(criterion='mse', max_depth=None,

                             max_features='sqrt', min_samples_split=2,

                             min_samples_leaf=1, random_state=0).fit(X_train, y_train)

y_tree=tree.predict(X_train)

```

通过 CART 树回归模型得到, latitude 与 passenger 对 pred 影响最大, 其重要性数为 0.4191, 高于其他影响因素, 与相关系数分析结果一致。

表 4-5 随机森林模型相关系数

Indicators	Indicator Factor
latitude	0.22031593
longitude	0.19090348
lock-status	0.03216671
hour	0.15779433
minter	0.1167032
distance	0.06540325
passenger	0.2167131




图 4-7 决策树模型影响因素条形图

在模型评估时引入拟合优度 (R^2)、均方差 (Mean Squared Error)、绝对误差 (Mean Absolute Error)、平均绝对误差 (Explained Variance Score) 作为评价随机森林模型质量标准, 得到决策树回归模型的预测评价指标如下。

表 4-6 随机森林模型评价指标

	TRAIN	TEST
R^2	0.695548	0.204112
MSE	24.165298	24.155216
MAE	4.1245247	4.1644531
RMSE	4.91582101	4.91479530

第三节 基于多权重图卷积神经网络模型

本文提出了一种基于融合区域分类、地铁距离数值和区域间动态车流的多权重图卷积神经网络模型。模型改进思路如下：

通过对单车分布点网络建构图结构，挖掘图结构将空间局部特征，然后采用时空图卷积神经网络来完成对于历史时空出行订单数据的处理，并关联区域内地体站点相关性等外部因素进行多图卷积，动态计算不同数据图的权重，提取多图节点实现图的融合并进一步进行卷积实验，以便图卷积神经网络可以同时应用于异质的站点间空预测，捕捉共享单车时空特性。

多权重图卷积神经网络包括输入层、卷积层、池化层、全连接层和输出层，卷积运算本质为数学运算，通过对输入数据特征提取并进行维度的压缩，经卷积、池化后捕获到全局特征和局部特征，卷积网络运算的核心就是在多个空间中共享参数。

多权重图卷积神经网络的运算步骤为：

（一）输入层：输入层进行对输入的原始图结构进行筛选、过滤、去噪、归化等步骤数据预处理。

（二）卷积层：完成图结构数据特征的提取，形成局部感知。多权重图卷积神经网络算法对每层网络进行卷积计算，每层网络含有卷积核、步长和填充。

（三）池化层：对数据降维。完成对特征高效获取后，卷积特征图被输入到池化层，在池化层中利用特定的池化函数把卷积图中顶点结果转换为临近范围的特征统计量，完成信息选择和过滤输出。一般情况下最大池化和均值池化是最常用研究选择。

（四）全连接层：特征聚集。全连接层在运算中通过卷积矩阵向量乘积实现。卷积层、池化层和激活函数层等前步运算是把初始数据投射到隐层特征空间中去，全连接层则会把训练得到的分布式特征表示方法传递到样本标记空间，将前两层的提取的特征进行非线性组合得到输出。全连接层中会失掉特征图的多维结构，依据高阶特征训练，将特征图转为向量输入。全连接层在卷积神经网络中担当的是分类处理器的功能，全连接层与传统前馈神经网络中的隐含层作用相同。

（五）输出层：输出结果。输出层连接在全连接层之后，实现对结果输出，与传

统神经网络的输出层功能相同。

一、多权重卷积图生成

在实际应用中存在非规则非线性且不具有几何关系的空间结构图,因此针对此类问题提出图卷积神经网络。将图与卷积神经网络相结合,有效处理了非欧几里得结构的数据,能够有效地提取拓扑图的空间特征进行学习。

计算中将数据转化为承载信息值的图的结构,再将神经网络算法模型应用到包含图的结构中计算,利用一个个矩阵空间格的卷积核在图像上平移,采用卷积的方式对数据进行特征提取。通过图中节点之间的消息传递来获取图的相关性,通过对多阶邻居的信息聚合,更新中心的节点。

图的多种存储表示方式中,邻接矩阵使用最为广泛且在计算中易于结合矩阵的运算存储方式。邻接矩阵 $A \in R^{n \times n}$, 当顶点 i 与顶点 j 之间存在连边 e_{ij} 时, A_{ij} 对应的元素为 1, 否则为 0。其定义为:

$$A_{ij} = \begin{cases} 1, & e_{ij} \in E \\ 0, & \text{otherwise} \end{cases} \quad (4-3)$$

(一) 区域图

本文中定义图的拓扑结构 $G=(V, E, A)$ 表示共享单车车流量网络, G 表示单位数量的一个图, $V = \{V_1, V_2, V_3, V_4, \dots, V_n\}$ 表示点的集合, 同一个区域中不同方向定义为不同的区域。依据经纬度位置将城市区域划分成 $i \times j$ 个大小的网格, 将网格中第 i 行和第 j 列对应的格子 (i, j) 定义为区域看作是区域 A_{ij} 。




图 4-8 区域拓扑图

V_n 表示具有的第 n 个顶点, n 表示图中包含的顶点数量数量。 $G=(V, E, A)$ 中

的 V 是 N 个节点数量的绝对值集合, 可看作 $N=|V|$, 表示不同线路上的流向区域。 E 为图 G 中连边的边集合, 表示每个节点之间的相互联通; m 表示图中相连边的数量, 表示顶点 V_i 和顶点 V_j 之间的连通性。 $A \in R^{n \times n}$ 代表着节点邻接矩阵, 当顶点 i 与顶点 j 之间存在连边 e_{ij} 时, 对应的元素为 1, 否则为 0。 A_{vivj} 表示顶点 V_i 和 V_j 之间的距离测量值。

在计算权重时考虑在动态分配具有流量模式的区域站点, 按照边缘进行权重关系分配。

(二) 距离权重图

特征选择上引入地铁在区域内的位置作为特征向量, 认为地铁站距离区域的远近将会对共享单车的骑行和停放存在一定的相关关系, 当地铁进站闸机所记录的人数越多时, 那么到达地铁站后在外停放的单车数量将一定比例的增加。反之, 当地铁出站闸机所记录的人数越多时, 那么出地铁站后选择共享单车作为出行工具, 即将地铁站外单车骑出指定区域的数量会越多。因此推测对于距离接近的的站点位置与区域内单车需求量存在相关性, 使用区域与地铁间的距离来构建站间图, 使用相距距离的倒数来标记两个站点之间的权重, 距离较近的区域将获得更高的权重。

$$G_{\text{distance}}(V, E): \text{WEIGHT} = \text{DISTANCE}^{-1} \quad (4-4)$$

$$A = \left\{ \begin{array}{ccccc} 0 & \frac{1}{\text{distance}_{0,1}} & \frac{1}{\text{distance}_{0,2}} & \cdots & \frac{1}{\text{distance}_{0,N-1}} \\ \frac{1}{\text{distance}_{1,0}} & 0 & \cdots & \cdots & \frac{1}{\text{distance}_{1,N-1}} \\ \frac{1}{\text{distance}_{2,0}} & \frac{1}{\text{distance}_{2,1}} & 0 & \cdots & \frac{1}{\text{distance}_{2,N-1}} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \frac{1}{\text{distance}_{N-1,0}} & \cdots & \cdots & \cdots & 0 \end{array} \right\} \quad (4-5)$$




图 4-9 距离权重示意图

(三) 关系图

历史骑行订单中记录了大量的位置关系变化的数据,在共享单车具有的空间定位信息可以提供区域间的关系分析。也就是说如果区域 A 和区域 B 之间存在大量的骑行订单记录,那么在两个区域间的单车迁移量将成一定的相关。在计算每个区域 A_{ij} 时考虑区域内的出入单车数量出流。定义在某个时间段 t 内,区域 A_{ij} 的进入量 X_{ij}^{in} 和输出量 X_{ij}^{out} 定义为

$$X_{ij}^{in} = \sum_{Tr \in p} |\{g_{t-1} \neq A_{ij}, g_t = A_{ij}\}| \quad (4-6)$$

$$X_{ij}^{out} = \sum_{Tr \in p} |\{g_t = A_{ij}, g_{t+1} \neq A_{ij}\}| \quad (4-7)$$




图 4-10 出入流量叠加示意


其中 Tr 是数据集中单车运行的一条轨迹, Tr 组成的轨迹数据集定义为 p , g_t 则代表着在第 t 个时间时共享单车轨迹所处的位置。

考虑到自行车流动量模型受到区域间的交互影响,因此根据历史骑行订单构建交互关系图。

$$G_{in}(V, E): WEIGHT = inflowRidingRecord \quad (4-8)$$

$$G_{out}(V, E): WEIGHT = outflowRidingRecord \quad (4-9)$$

$$A = \begin{Bmatrix} d_{0,0} & d_{0,1} & d_{0,2} & \dots & d_{0,N-1} \\ d_{1,0} & d_{1,1} & d_{1,2} & \dots & d_{1,N-1} \\ d_{2,0} & d_{2,1} & d_{2,2} & \dots & d_{2,N-1} \\ & & & \ddots & \vdots \\ & & & \dots & \vdots \\ d_{N-1,0} & \dots & \dots & \dots & d_{N-1,N-1} \end{Bmatrix} \quad (4-10)$$



$$\begin{Bmatrix} 0 & 500 & 220 & 200 \\ 500 & 0 & 180 & 150 \\ 220 & 180 & 0 & 300 \\ 200 & 150 & 300 & 0 \end{Bmatrix}$$

图 4-11 出入流量权重示意图

通过邻接矩阵 A 的归一化处理后, 利用 softmax 函数作为归一化运算, 并通过邻接矩阵将不同图层面的层面加权求和。其中, A' 为标准化后的邻接矩阵, 假设有 N 个图需要进行融合, 那么 W_1 到 W_N 为一条边上所代表的权重。o 为元素的积, F 等于图的融合结果。

$$A' = D^{-1}A + I \quad (4-11)$$

$$W_1, W_2, W_3, \dots, W_N = \text{softmax}(W_1, W_2, W_3, \dots, W_N) \quad (4-12)$$

$$F = \sum_{i=1}^N W_i \circ A'_i \quad (1 \leq i \leq N) \quad (4-13)$$

二、多权重图卷积计算

邻接矩阵 A 和特征矩阵 X 代入 GCN 模型中, 建立傅里叶域的一个过滤器。

$$U_i U_i^T \quad (1 \leq i \leq N) \quad (4-14)$$

将滤波器作用在图结构的每个节点上, 采用节点上的一阶邻域抓取节点之间具有的空间特征, 捕获到空间特征后通过叠加多层卷积层来建立 GCN 模型。GCN 将图的拉普拉斯矩阵的最大近似值等于 2, 则拉普拉斯矩阵可表示为式 (4-15)。

$$X^{l+1} = \sigma((\alpha_0 + \alpha_1(L - I_N))X^l) \quad (4-15)$$

其中 $\alpha_0 \in R$, $\alpha_1 \in R$ 表示参数; $X^l \in R^N$ 表示第 L 层图卷积的输入的信号值, 若令 $\alpha_0 - \alpha_1 = 0$, 则可得到式 (4-16), 其扩展形式为式 (4-17)。

$$X^{l+1} = \sigma(\alpha \tilde{D}^{-\frac{1}{2}} \hat{A} \tilde{D}^{-\frac{1}{2}} X^l) \quad (4-16)$$

$$X^{l+1} = \sigma(\tilde{D}^{-\frac{1}{2}} \hat{A} \tilde{D}^{-\frac{1}{2}} X^l \theta) \quad (4-17)$$

其中 X^l 是第 l 层输出, $\hat{A} = A + I_N$, $\tilde{D} = \sum_j \hat{A}_{ij}$ 代表的是度矩阵, $\theta \in R^{C \times C}$ 表示卷积核的参数, σ 表示非线性 sigmoid 函数 (隐藏层神经元输出)。

选择 2 层的 GCN 模型用来获取空间中的依赖关系, 可以表示为 (4-18)。

$$f(X, A) = \sigma(\hat{A} \text{ReLU}(\hat{A} X W_0) W_1) \quad (4-18)$$

其中 $\hat{A} = \tilde{D}^{-\frac{1}{2}} \hat{A} \tilde{D}^{-\frac{1}{2}}$ 为预处理步骤, $W_0 \in R^{P \times H}$ 代表输入层到输出层的权重矩阵, P 代表特征矩阵的长度, H 代表隐藏的单元数量, $W_1 \in R^{H \times T}$ 表示隐藏层到输出层的权重矩阵, ReLU 为深度神经网络的激活层。

卷积计算示意如图 4-12 所示。




图 4-12 图卷积神经网络计算示意图

三、模型结构及指标评价

图卷积神经网络模型结构如图 4-13 所示。




图 4-13 图卷积神经网络模型结构

在模型评估时引入拟合优度（ R^2 ）、均方差（Mean Squared Error）、绝对误差（Mean Absolute Error）、平均绝对误差（Explained Variance Score）作为评价图卷积网络模型质量标准，得到图卷积网络模型的预测评价指标如下。

表 4-7 图卷积神经网络模型评价指标

	TRAIN	TEST
R^2	0.7831578	0.8451317
MSE	19.316731	19.274292
MAE	3.7311842	3.6528610
RMSE	4.3950803	4.3902496

第四节 实验结果及分析

本章比较了线性回归模型、随机森林模型和图卷积神经网络模型在预测值中的表现。在模型实验中观察到基于多图融合的图卷积方法的方法能更好地在建模时提取特征，捕捉共享单车在实际需求中的非线性时空分布规律，其性能指标明显优于等传统机器学习方法。MSE 在反映估计值与被估计值之间差异程度，其值越大则预测值与真实值之间的误差越大，实验中机器学习模型所取得的均方误差值大于图卷积神经网络模型，其误差值效果为 $LR>RF>GCN$ ；MAE 是计算待测试值和其算术平均值的偏差中绝对值并计算平均数，MAE 能够有效减少误差之间相互抵消的问题，其值越大则预测值与真实值之间的误差越大，实验中机器学习模型所取得的平均绝对误差均大于图

卷积神经网络模型，反映实际计算中预测误差的大小关系为 $LR>RF>GCN$ ；RMSE 是反映预测值与真实值之间差异程度，实验中机器学习模型所取得的均方根误差大于图卷积神经网络模型，误差值大小关系为 $LR>RF>GCN$ 。

综上，由于图卷积神经网络能在图结构中确定更为相关的邻域节点，因此多图融合的图卷积神经网络模型更适合提取时空依赖性，聚合邻居节点的信息来动态更新，并利用相关邻域节点信息来更新节点特征，其聚合器能更好地挖掘空间信息，模型在实验中表现最优。

表 4-8 综合评价指标

		R^2	MSE	MAE	RMSE
LR	TRAIN	0.054711	29.235231	4.3608132	5.4069613
	TEST	0.056310	29.235534	4.1959764	5.4069893
RF	TRAIN	0.695548	24.165298	4.1245247	4.91582101
	TEST	0.204112	24.155216	4.1644531	4.91479530
GCN	TRAIN	0.7831578	19.316731	3.7311842	4.3950803
	TEST	0.8451317	19.274292	3.6528610	4.3902496

第五节 本章小结

通过建立机器学习模型进行模型训练，引入 RMSE、MSE、MAE 等预测评价指标评估模型的效率。线性回归模型中各影响自变量因素之间存在着多重共线性关系，不满足变量间相互独立的条件，该命题在理论上不适合进行线性回归分析。随机森林模型在评估指标上表现出的性能不佳。实验发现机器学习模型在预测中存在一些不足。

因此，提出了一种基于融合区域分类、地铁距离数值和区域间动态车流的多权重图卷积神经网络模型。应用 GCN 构建图的卷积模型训练时，提出将多种指标转换为图的拓扑结构进行多图融合卷积，设定动态权重指标进行测算的方法在模型实测中具有优越性，能有效的应用于异质的区域预测。

多权重图卷积神经网络模型通过对单车分布点网络建构图结构，利用图结构将空

间局部特征进行有效的挖掘和提取,使得需求量预测准确率大幅提高;然后采用图卷积神经网络来完成对于历史时空出行订单数据的处理,并关联区域内地体站点相关性等外部因素进行多图卷积,动态计算不同数据图的权重,提取多图节点实现图的融合并进一步进行卷积实验,以便图卷积神经网络可以同时应用于异质的站点间空预测,进一步捕捉共享单车时空特性,以此提升实际预测精度。确定图卷积神经网络算法,在空间特征提取和挖掘上具备最优性能。

第五章 总结与展望

第一节 研究总结

本文针对共享单车在分布区域和骑行需要中具备的明显的潮汐特性展开，解决潮汐问题，实际上是在研究中实际面临的问题城市内停车区域未知所带来的问题。为了解决共享单车时空跨度大及无序性分布分散等稀疏问题，对于单车潮汐区域进行聚类识别和预测。

本文提取了停车点位电子围栏数据，用 Geohash 库来对订单中的出现经纬度编码，依据停车点经纬度范围计算停车点位面积。在实际数据划分中采用聚类思想划分数据簇，介绍了分类实验设置与分析。采用 K-Nearest Neighbor 分类算法和 Geohash 算法对基础数据进行分类，在比较两种分类算法在处理数据分类值上的差异后，选择目标问题中表现结果更优的 K-Nearest Neighbor 分类算法完成分类数据簇的聚类划分。其中对模型中时空距离计算公式进行检验，创新提出将传统欧式距离计算公式替换为精度更高的 Haversine 距离计算公式。聚类划分后计算各个区域内留存单车密度的同时以街道作为分类依据，识别出潮汐现象严重的街道区域。

在分类数据簇基础上，针对需求量实际值建立预测模型，比较了线性回归模型、随机森林模型、图卷积神经网络模型在数据集上的优越性。其中，在建立图卷积神经网络算法模型时，提出一种基于多图融合的动态权重卷积神经网络模型（Dynamic weights Graph Convolutional Network）。在模型中融合区域分类、地铁距离数值和区域间动态车流数据的图的节点，提出了提取多图节点和图的融合算法进行卷积实验，以便图卷积神经网络可以同时应用于异质的站点间空预测。在实验比较后，多图卷积神经网络呈现性能更优，对于深度特征的提取效果最好，完成实验预测。

第二节 对策与建议

本文探究了时空特征和地铁站点等特征向量对共享单车使用量的关系，完成对早高峰时间段内城市潮汐区域的定位。根据单车骑行路径和停放区域等，识别潮汐现象严重的区域及单位面积内共享单车停放密度较大的区域，后期进一步设计早高峰时间段共享单车的需求量预测实验，对缓解共享单车在城市潮汐区域的供需矛盾提供预测数据支撑。

单车运营商依据跨空间跨区域的集中式有效预测数据，调整管理策略。一是合理摸排共享单车在不同区域间的不同出行需求，运营商可以按需分配区域内单车数量，

设置区域内投放单车的最大阈值,合理投放功能区内的单车数量,满足用户的用车需求,缓解单车区域内过量堆积所造成的资源浪费问题。二是依据地域间的不同用户需求分配人员管理,科学地进行后期调度和运营维护,避免平均分配造成的区域内管理人手短缺,或是人员冗杂造成的人力浪费。保障共享单车运营车辆使用率,提高人员管理效率。此外,运营商可以采取自主管理和强制停放这两种方式,引导市民正确停放共享单车。例如采取减免骑行费用、赠送积分、赠送会员卡等鼓励方式,依托大数据技术,在市民计划将单车停放在潮汐区域时,规划骑行路线,推荐市民前往临近的非潮汐区域停车;而在车流量较大的道路主干道、交通事故高发路段等,易引发交通安全事故,加剧交通行驶压力的区域,远程锁定共享单车自带素锁扣,限制单车停放,从而缓解市民日常出行的用车和停放困扰,优化市民的用车体验,保障用户骑行安全。

从政府规划和交通监管水平角度,预知共享单车潮汐区域和单车使用数量,掌握预测数据的情况下倒逼城市规划和管理,对共享单车流动量大的区域加以引导,合理规划非机动车停放区域,不断完善城市基础建设。例如在地铁站、公交站点、办公区等出行需求量较大的区域附近划分停放点位,设置停放引导志愿者,注重城市温度,解决共享单车在城市出行中所造成停放不当、道路堆积等管理问题。在安全事故多发路段和共享单车迁移量较大的区域设置警示牌、警示标语,提醒市民安全有序出行。增强城市管理水平,为居民提供多样化、高效率的出行选择,提升城市居民绿色出行的幸福感,以此来营造高效有序的城市管理环境。

第三节 不足与展望

本文存在挖掘生活区域内共享单车车流量的区域间的流动性、空间关联性进行了研究,但仍存在一些不足之处:

(1) 本文仅对地铁站位置与区域间的关系进行了分析,没有去探讨各个地铁站点、公交站点等公共交通站点之间的相关性,站点间相关性因素也会对预测结果产生影响。

(2) 在实验中提取早高峰时段内的某一时刻 t 的数据作为模型数据输入, t 时刻的数据可能存在偶发性,无法应用于所有时段,不能实现动态测算。

(3) 受制于所用数据集量的限制,实际预测共享单车需求量时还应考虑节假日、天气情况、收费情况等外部因素影响。如果能将实际生活中的外部因素提取至模型中训练,预测结果将更贴近真实情况。

(4) 图卷积神经网络由于其矩阵特性,只能计算局部特征作为卷积数据节点,大规模卷积计算代价高,因此实验结果具有一定的局限性。将来研究工作的重点则是针对图卷积神经网络模型进行剪枝优化,通过不断调整来提高模型的预测效率,使模

型预测结果真实拟合。

综上所述,本文以实现共享单车需求量为目标,识别出潮汐现象严重的街道区域。并对当前较为流行的图卷积神经网络模型做了研究,并基于融合区域分类、地铁距离数值和区域间动态车流数据等特征设计了多图融合的卷积预测模型,通过实验对比了该算法的实际效果。本文的研究成果对共享单车出行车流量预测提供了一种新的思路,通过预测获取单车预测数据来作为共享单车城市管理的数据依据,合理调配来解决共享单车在城市出行中所造成停放不当、供需不足等问题,缓解单车区域内过量堆积所造成的资源浪费情况,从而提高共享单车的使用效率,完成共享单车在区域分配上的均衡性,优化共享单车的出行功能,提高共享单车的集群性能,为市民出行提供实用价值, 以期为城市管理部门和共享单车运营方提供预测的有益探索和尝试。

参考文献

- [1]Muhammad Asif. 共享消费的影响因素以及感知持续性与趋势导向的中介作用：中国情境下共享房屋和共享单车的比较研究[D].东北财经大学,2018.
- [2]艾毅. 共享单车的出行行为、耐受特征及时空分布研究[D].西南交通大学,2018.
- [3]刘勇. 城市居民共享单车出行的多阶段行为研究[D].成都理工大学,2020.
- [4]申犁帆. 基于城市轨道交通通勤的职住关系研究[D].武汉大学,2018.
- [5]张璇. 共享单车区域管理以及跨区域调节模型分析[D].上海交通大学,2018.
- [6]黎潇阳.大数据技术在治理共享单车问题中的应用分析[J].时代金融,2018(20):303+307.
- [7]种颖珊,韩晓明.基于随机森林与时空聚类的共享单车站点需求量预测[J].科学技术与工程,2018,18(32):89-94.
- [8]谢青成,毛嘉莉,刘婷.城市共享单车的动态调度策略[J].华东师范大学学报(自然科学版),2019(06):88-102.
- [9]杨梓东. 数据驱动的公共自行车系统分析建模与优化[D].浙江大学,2019.
- [10]王玉全,刘燕涛. 北京市共享单车停车需求预测[J].交通与运输,2019,35(02):14-18.
- [11]徐国勋,张伟亮,李妍峰.共享单车调配路线优化问题研究[J].工业工程与管理,2019,24(01):80-86.
- [12]宋鹏,黄同愿,刘渝桥.基于 SVM 的共享单车需求预测[J].重庆理工大学学报(自然科学),2019,33(07):187-194.
- [13]杨军,赵继新,易安军,等. 基于 BP 神经网络算法的共享单车需求预测[J].西部交通科技,2019(02):155-158.
- [14]李颖宏,马勇.基于 LSTM 的共享单车需求预测[J]. 智能城市,2019,5(05):1-4.
- [15] Liu J, Sun L, Chen W, et al. Rebalancing Bike Sharing Systems: A Multi -source Data Smart Optimization[C]. Knowledge Discovery and Data Mining, 2016: 1005-1014.
- [16] Caggiani L, Camporeale R, Ottomanelli M, et al. A dynamic clustering method for relocation process in free-floating vehicle sharing systems[J]. Transportation research procedia, 2017: . 278-285.
- [17] Vogel P, Mattfeld D C. Strategic and Operational Planning of Bike -Sharing Systems by Data Mining - A Case Study[J]. Computational Logistics, 2011(01):127-141.
- [18]Y. Sun,B. Leng,and W. Guan. A novel wavelet-SVM short-time passenger flow prediction in Beijing subway system[J]. Neurocomputing,vol.166, pp. 109-121,Oct.2015.
- [19] Froehlich J E, Neumann J, Oliver N, et al. Sensing and predicting the pulse of the city

through shared bicycling[C]. International Joint Conference on Artificial Intelligence, 2009:1420- 1426.

[20]P.Jiao, R.Li, T. Sun,Z.Hou, and A. Ibrahim. Three Revised Kalman Filtering Models For Short-Term Rail Transit Passenger Flow

Prediction[J].Math.Probl.Eng.,vol.2016,pp.1-10,Oct.2016.

[21]张琳.基于深度神经网络的地铁客流预测系统研究[D].北京交通大学,2019.

[22]何必胜,朱永俊,陈路锋,闻克宇.基于时空图神经网络的高速铁路车站短期客流预测方法[J/OL].铁道学

报:1-10[2021-11-29].<http://kns.cnki.net/kcms/detail/11.2104.u.20211123.1848.002.html>.

[23]李邦鹏.基于深度学习的室内时空客流预测[D].浙江大学,2017.

[24]付俐哲. 基于时空聚类与 LSTM 神经网络的共享单车需求预测模型[D].西北师范大学,2021.DOI:10.27410/d.cnki.gxbfu.2021.001767.

[25]王佳琳,基于深度学习模型的城市轨道交通短时客流预测方法研究[D].北京交通大学,2020.

[26]徐先峰,黄刘洋,龚美.基于卷积神经网络与双向长短时记忆网络组合模型的短时交通流预测[J].工业仪表与自动化装置,2020(01):13-18.

[27] Bruna J, Zaremba W, Szlam A , et al. Spectral Networks and Locally Connected Networks on Graphs[J]. Computer Science, 2013.

[28] F. Monti, D. Boscaini, J. Masci, E. Rodola, J. Svoboda, and M. M.

Bronstein.Geometric deep learning on graphs and manifolds using mixture model: CNNs[C]. in .Proceedings - 30th IEEE Conference on Computer Vision and Pattern Recognition. CVPR 2017, Nov.2017, vol. 201 7-January, pp.5425- 5434.

[29] Hamilton W, Ying Z, Leskovec J. Inductive representation learning on large graphs[C].Advances in neural information processing systems. 2017: 1024-1034.

[30] Y. Li, R. Yu, C. Shahabi, and Y. Liu. Diffusion Convolutional Recurrent Neural Network: Data-Driven Traffic Forecasting[J].In: International Conference on Learning Representations,2017.

[31] Y. Seo, M. Defferrard, P. Vandergheynst, and X. Bresson. Structured Sequence Modeling with Graph Convolutional Recurrent Networks[J].vol.2018. pp. 362-373, 2018.

[32]Y. Li, Z. He, X. Ye, Z. He, K.J E. J. on I. Han, and V. Processing. Spatial temporal graph convolutional networks for skeleton-based dynamic hand gesture recognition[J].vol.2019,pp.17-26, 2019.

[33]Defferrard, Xavier Bresson, and Pierre Vandergheynst.In D. D. Lee, M.Sugiyama, U. V. Luxburg, I. Guyon, and R. Garnett, editors, Advances in Neural Information Processing Systems 29, pages 3844-3852.Curran Associates, Inc., 2016.

- [34]梁强升,许心越,刘利强.面向数据驱动的城市轨道交通短时客流预测模型[J].中国铁道科学,2020,41(4):153-162.
- [35]康雁,谢思宇,王飞,寇勇奇,徐玉龙,吴志伟,李浩.基于双路信息时空图卷积网络的交通预测模型[J].计算机科学,2021,48(S2):46-51+62.
- [36] Diao Z, Wang X, Zhang D, et al. Dynamic spatial-temporal graph convolutional neural networks for traffic forecasting[C].Proceedings of the AAAI Conference on Artificial Intelligence,2019,33:890-897.
- [37] Defferrard M, Bresson x, Vandergheynst P. Convolutional Neural Networks on Graphs with Fast Localized Spectral Filtering[M].Proceedings of the 30th International Conference on Neural Information Processing Systems. Barcelona, Spain; Curran Associates, Inc. 2016:3844-3852,2016.
- [38]陈植元,林泽慧,金嘉栋,李建斌.基于时空聚类预测的共享单车调度优化研究[J/OL].管理工程学报:1-13[2021-11-29].<https://doi.org/10.13587/j.cnki.jieem.2022.01.013>.
- [39]肖梅,张颖,黄洪滔,郝艳军.基于 LSTM 网络的浮动单车需求量预测[J/OL].武汉理工大学学报(交通科学与工程版):1-10[2021-11-29].<http://kns.cnki.net/kcms/detail/42.1824.U.20210930.1516.008.html>.
- [40]孙胜男,方润涛,叶波.基于出行需求的共享单车总量预测分析[J].西部交通科技,2021(09):169-171.DOI:10.13282/j.cnki.wccst.2021.09.048.
- [41]张徐,聂文惠.基于改进随机森林算法的共享单车需求量预测[J].计算机与数字工程,2021,49(09):1860-1865.
- [42]金高铭,刘安,孙玉娥,于金刚.区域-道路时空图网络:一种基于图神经网络的流量预测模型[J/OL].小型微型计算机系统:1-7[2021-11-29].<http://kns.cnki.net/kcms/detail/21.1106.tp.20210906.1412.006.html>.
- [43]刘丹,蒲自源,许晓晴,伍佳妮.基于机器学习-优化混合算法的离散交通网络双层规划模型[J].系统工程,2018,36(08):114-122.
- [44]杨忠.基于 GIS 的共享单车站点最优选择查询系统设计[J].计算机测量与控制,2018,26(07):233-237.
- [45]杨永崇,柳莹,李梁.利用共享单车大数据的城市骑行热点范围提取[J].测绘通报,2018(08):68-73.
- [46]索源.基于出行需求波动的共享单车停放点选址规划研究[D].北京交通大学,2018.
- [47]史迪超,史晓明,方芳.浅谈地理信息技术在共享单车中的应用[J].地理空间信息,2018,16(01):46-47+7-8.
- [48]刘克澜.共享单车的物联网定位技术[J].电子技术与软件工程,2017(23):21.
- [49]邓力凡,谢永红,黄鼎曦.基于骑行时空数据的共享单车设施规划研究[J].规划师,2017,33(10):82-88.

- [50]程政,陈贤富.基于随机森林模型的短时交通流预测方法[J].微型机与应用,2016,35(10):46-49.
- [51]吕麦霞,刘艳妮.基于地铁接驳的公共自行车系统研究[J].城市道桥与防洪,2016(09):79-81.
- [52]周强,吴戈,孙瀚.作为地铁接驳手段的公共自行车使用特性分析[J].交通运输系统工程与信息,2015,15(03):179-184.
- [53]郭彦茹,罗志雄,王家川,何方.数据驱动的共享单车停放区规划方法研究[J/OL].交通运输系统工程与信息:1-13[2021-11-29].<http://kns.cnki.net/kcms/detail/11.4520.U.20211117.1500.031.html>.
- [54]徐悦甦,周奕杉,黄健斌,李莹,黑蕾.面向共享单车服务调度的流程规划算法[J/OL].计算机集成制造系统:1-12[2021-11-29].<http://kns.cnki.net/kcms/detail/11.5946.TP.20211115.1653.002.html>.
- [55]夏雪,盖靖元.基于 K-Means 聚类算法的城市轨道交通站点分类及客流特征分析[J].现代城市轨道交通,2021(04):112-118.
- [56]叶廷宇,叶军,王晖,王磊.结合人工蜂群优化的粗糙 K-means 聚类算法[J/OL].计算机科学与探索:1-10[2021-06-26].
- [57]陈伟栋,邓翠珠,谭启祥.共享单车的业务识别特征及质量指标研究与实践[J].电信工程技术与标准化,2018,31(08):71-75.
- [58]陶璐.基于深度学习的路网短时交通流预测研究[D].北京交通大学,2021.DOI:10.26944/d.cnki.gbfju.2021.002104.
- [59]夏蕊(Sana Ashraf).结合图卷积和循环神经网络的交通状态预测[D].北京交通大学,2021.DOI:10.26944/d.cnki.gbfju.2021.000864.
- [60]柯其学.基于 CNN 和 GCN 的交通流预测算法研究及实现[D].北京邮电大学,2021.DOI:10.26969/d.cnki.gbydu.2021.001263.
- [61]傅碧天.城市共享交通行为的公众偏好、影响因素及碳减排潜力研究[D].华东师范大学,2018.
- [62]朱玮,汪方心怡,杨楷雯,尹海鑫.共享单车推荐驻车点与用户引导策略规划方法[J/OL].工业工程与管理:1-10[2021-06-26].<http://kns.cnki.net/kcms/detail/31.1738.T.20210616.1329.004.html>.
- [63]宋瑞蓉,王斌君,仝鑫,刘文懋.基于改进果蝇的混合小波神经网络交通流预测[J].科学技术与工程,2021,21(15):6394-6401.
- [64]郭娅婷.基于 GCN 的城市轨道交通站点短时客流预测[D].兰州理工大学,2021.DOI:10.27206/d.cnki.ggsgu.2021.000459.
- [65]江世雄.城市公共交通系统可达性评价与优化方法[D].北京交通大学,2019.
- [66]戴群.共享单车调度和回收路径优化问题研究[D].大连海事大学,2019.

- [67]刘泽雷. 移动群智感知下的动态激励机制与分布式数据处理的研究[D].吉林大学,2019.
- [68]Cuauhtemoc Anda,Alexander Erath,Pieter Jacobus Fourie,宗晶.大数据时代的交通模型[J].城市交通,2019,17(03):53-66+74.
- [69]马勇. 基于共享单车轨迹数据的需求预测及智能调度方法研究[D].北方工业大学,2019.
- [70]甘维德. 基于数据挖掘的城市共享单车出行分析及区域需求量预测[D].广东工业大学,2019.
- [71]王立. 基于机器学习的共享单车需求量预测模型研究[D].长安大学,2019.
- [72]李伟,张凤梅.基于 K-Means 的无线传感网络节能算法研究[J].传感器与微统,2021,40(04):41-44.
- [73]高得,朱春帅,赵媛媛,王凌锋,唐维燕.基于 RFID 技术的共享单车无桩定点停车系统设计[J].信息系统工程,2019(02):125+128.
- [74]刘冬旭. 公共自行车系统时空域划分方法及进化分形调度研究[D].浙江工业大学,2019.<http://kns.cnki.net/kcms/detail/11.5602.TP.20210407.1618.002.html>.
- [75]Linlin Luo, Li Lin. Improved Model Structure based on GCN[J]. International Core Journal of Engineering,2021,7(7).
- [76]Yanyan Fang,Zhiyu Jin,Zhenhua Cui,Qiaowen Yang,Tianyi Xie,Bo Hu. Modeling human-human interaction with attention-based high-order GCN for trajectory prediction[J]. The Visual Computer,2021(prepublish).
- [77]Byeonghyeop Yu,Yongjin Lee,Keemin Sohn. Forecasting road traffic speeds by considering area-wide spatio-temporal dependencies based on a graph convolutional neural network (GCN)[J]. Transportation Research Part C,2020,114(C).
- [78]Yanran Li,Lingteng Qiu,Li Wang,Fangde Liu,Zhao Wang,Sebastian Iulian Poiana,Xiaosong Yang,Jianjun Zhang. Densely connected GCN model for motion prediction[J]. Computer Animation and Virtual Worlds,2020,31(4-5).
- [79]Dianhui Mao,Zhihao Hao,Yalei Wang,Shuting Fu. A Novel Dynamic Dispatching Method for Bicycle-Sharing System[J]. ISPRS International Journal of Geo-Information,2019,8(3).
- [80]Hans-Martin Zademach,Annika-Kathrin Musch. Bicycle-sharing systems in an alternative/diverse economy perspective: a sympathetic critique[J]. Local Environment,2018,23(7).
- [81]Ana Clara Duran,Esther Anaya-Boig,Joshua Daniel Shake,Leandro Martin Totaro Garcia,Leandro F3rnias Machado de Rezende,Thiago H3rick de S3. Bicycle-sharing system socio-spatial inequalities in Brazil[J]. Journal of Transport & Health,2018,8.

- [82]Yang Yang,Tiezhu Li,Tao Zhang,Wanyu Yang. Understanding the Utilization Characteristics of Bicycle-Sharing Systems in Underdeveloped Cities: A Case Study in Xuchang City, China[J]. Transportation Research Record,2017,2634(1).
- [83]Ahmadreza Faghih-Imani,Naveen Eluru. Examining the impact of sample size in the analysis of bicycle-sharing systems[J]. Transportmetrica A: Transport Science,2017,13(2).
- [84]Ahmed Abdelmoumene Kadri,Imed Kacem,Karim Labadi. A branch-and-bound algorithm for solving the static rebalancing problem in bicycle-sharing systems[J]. Computers & Industrial Engineering,2016,95.
- [85]Ahmadreza Faghih-Imani,Naveen Eluru. Analysing bicycle-sharing system user destination choice preferences: Chicago's Divvy system[J]. Journal of Transport Geography,2015,44.
- [87]P.Jiao,R.Li,T. Sun,Z.Hou, and A. Ibrahim. Three Revised Kalman Filtering Models For Short-Term Rail Transit Passenger Flow Prediction[J].Math.Probl.Eng.,vol.2016,pp.1-10,Oct.2016.