



Numerical Analysis

组织：School of Mathematics and Statistics, Wuhan University

时间：August 24, 2022



前言

华罗庚先生曾经用“宇宙之大，粒子之微，火箭之速，化工之巧，地球之变，生物之谜，日用之繁，无处不用数学”来形象地描述数学在科学技术中的重要作用。在将数学理论应用于科技领域的核心工具及方法中，电子计算机及其相应的科学计算方法发挥了极其重要的作用。计算数学便是通过研究算法，将基础数学理论与现实世界应用相融合，为解决科学工程问题搭建了桥梁。随着计算机硬件与高性能计算方法的不断进步，计算数学所提供的工具，依托于各种物理及工程模型，催生了众多数值计算方法。因此，“计算”已成为研究复杂系统规律和性质的重要手段，它是与理论研究和实验研究并列的第三种研究方法。

数值分析作为计算数学的基础研究领域之一，关注于一些基础共性问题的计算方法。它通过对问题近似建模，提出解决方案，并将这些方案在计算机上实现成程序，同时对算法进行理论分析。作为计算数学专业的基础课程，《数值分析》致力于培养学生设计、分析及提升算法的能力。本书即是笔者在武汉大学讲授《数值分析》课程时的讲义基础上整理并扩充而成，适宜作为计算数学专业本科生的课程教材，建议授课时长为 48-64 学时（含上机实践）。

全书共分为六章。第一章介绍了数值计算的误差来源、科学计算中常用的 IEEE 浮点数系统、算法的复杂度及其收敛速度等基础知识。第二章详细讲解了求解非线性方程及方程组的迭代方法，包含二分法、不动点迭代、牛顿迭代、割线法等，以及非线性方程组求解中的牛顿迭代和 Broyden 拟牛顿迭代等算法。第三章深入探讨了多项式插值，涵盖了 Lagrange 插值的计算方法和误差估计、插值节点对多项式插值误差的影响、包含导数信息的 Hermite 插值、分段多项式的 Lagrange 与 Hermite 插值法、样条插值方法等。第四章阐述了多项式逼近的理论及算法，内容包括正交多项式的定义与性质、最佳一致逼近及其性质与算法、最佳平方逼近的算法及其误差估计等。第五章讲述了数值微分与积分，其中数值微分部分包括一阶导数的向左、向右、中心差分近似方法、二阶导数的中心差分、多项式插值近似、Richardson 外推法等，并分析了数值微分的不适定性问题；数值积分部分则介绍了 Newton-Cotes 积分公式及其误差估计、复化梯形公式、Romberg 积分算法以及高斯积分方法等。第六章介绍了常微分方程的数值方法，包括算法的相容性、稳定性、收敛性的概念；展示了显式 Euler 法、隐式 Euler 法、Crank-Nicolson 方法、Runge-Kutta 方法等求解常微分方程初值问题的标准数值算法；探讨了刚性常微分方程组的绝对稳定性和 A-稳定性，并为各种常用算法的稳定区域提供了详细说明；介绍了求解常微分方程两点边值问题的打靶法、有限差分方法、Galerkin 方法等，并具体阐述了两种主要的 Galerkin 方法实现：有限元方法和谱方法。

本书的内容以多项式近似为核心线索，涵盖从多项式插值和逼近到数值微分、积分，再到常微分方程数值解的应用。在内容编排上，旨在带领学生深入理解在明确的数学目标指引下，如何设计、高效实施算法，并识别及解决算法实践中的问题。通过对本课程的学习，学生们将掌握计算数学方法的基础科研技能，并为他们后续的课程学习和研究工作奠定坚实的基础。特此感谢武汉大学陈秋豪、张柳颖、吴迪、屈洋、戴力澄等同学在输入、排版和校对等方面的大力协助，以及陈秋豪、魏佳磊、熊廷恩同学为正文中大多数算例提供的程序代码。

2024 年 1 月于珞珈山

目录

前言	i
第 1 章 基础知识	1
1.1 数值分析的对象和特点	1
1.2 数值计算的误差	2
1.3 IEEE 浮点数系统	4
1.4 计算复杂性和收敛速度	5
1.5 练习题	6
第 1 章 练习	6
第 2 章 非线性方程(组)的数值求解	7
2.1 单个方程求解问题	7
2.1.1 二分法	7
2.1.2 不动点迭代	10
2.1.3 Newton 法	11
2.1.4 割线法	14
2.1.5 试错法	17
2.2 非线性方程组求解	19
2.2.1 不动点迭代	19
2.2.2 Newton 法	21
2.2.3 拟牛顿法	25
2.3 知识拓展	28
第 2 章 练习	28
第 3 章 多项式插值	31
3.1 Lagrange 插值	31
3.2 等距节点高阶多项式插值的不稳定性	41
3.2.1 龙格现象	43
3.2.2 数值不稳定性	44
3.2.3 Chebyshev 节点的 Lagrange 插值	47
3.3 Hermite 插值	51
3.4 分片线性和分片三次 Hermite 插值	54
3.5 三次样条插值	56
3.6 B 样条	61

3.7 知识拓展	69
第 3 章 练习	70
第 4 章 多项式逼近	71
4.1 正交多项式	71
4.2 最佳一致逼近	78
4.2.1 最佳一致逼近的存在唯一性	78
4.3 最佳平方逼近	86
4.3.1 离散最佳平方逼近	91
4.4 知识拓展	92
第 4 章 练习	92
第 5 章 数值微分与数值积分	94
5.1 数值微分	94
5.1.1 一阶导数的差分格式	94
5.1.2 数值微分的不适定性	95
5.1.3 差分模板方法	97
5.1.4 数值微分的整体估计方法	98
5.1.5 Richardson 外推法	100
5.2 Newton 求积公式	101
5.2.1 Newton-Cotes 公式	104
5.2.2 复化 Newton-Cotes 公式	107
5.2.3 Romberg 算法	109
5.3 Gauss 型积分	109
5.4 知识拓展	113
第 5 章 练习	114
第 6 章 常微分方程数值解	116
6.1 初值问题的数值方法	116
6.1.1 Euler 方法和 Crank-Nicolson 方法	117
6.1.2 相容性、收敛性、稳定性	121
6.1.3 Runge-Kutta 法	124
6.1.4 刚性问题求解	128
6.2 边值问题求解	131
6.2.1 打靶法	132
6.2.2 有限差分法	136
6.2.3 Galerkin 方法	138
6.3 知识拓展	142

第 6 章 练习	142
参考文献	144

第1章 基础知识

在本章中，我们对实际问题的解决过程中可能出现的误差来源进行了详细的介绍。首先，我们讨论了模型误差、观测误差、截断误差和舍入误差。这些误差来源可能会对我们的计算结果产生重大影响，因此需要在计算过程中加以考虑和控制。

特别是舍入误差，我们引入了 IEEE 浮点数系统的相关概念，以更加详细地阐述其特点。IEEE 浮点数系统是一种广泛使用的浮点数表示方法，它使用有限位数来表示实数，并且对于不同的数值范围采用了不同的位数和精度。在实际计算中，我们需要注意舍入误差的产生，并采取一些措施来减小其影响，例如增加位数或采用更加精确的算法。

然而，仅仅保证算法具有高精度是不够的。为了衡量我们设计的迭代算法收敛到某一真实解的速率，我们对线性收敛、超线性收敛、平方收敛等概念进行了明确的定义。这些概念可以帮助我们评估算法的收敛性能，并从误差大小和收敛速度两个方面全面考虑，设计出一个优良的算法。这也是数值方法的核心思想，即在保证结果精度的同时，尽可能提高计算效率。

1.1 数值分析的对象和特点

计算数学是一个研究通过计算机解决各种数学问题的数值计算方法、理论以及软件实现的数学分支。它在解决现实生活中的科学技术问题方面扮演着重要的角色，通常需要经历以下几个步骤：将一个复杂的实际问题抽象为数学问题，即进行数学建模；通过数学模型确定数值计算方法；根据计算方法编写程序并在计算机上实现，从而得出结果。这个过程可以用图 1.1 所示的流程图来表示。



图 1.1: 解决科学技术问题的基本流程。先将一个复杂的实际问题抽象到一个数学问题，再设计一个算法解决该数学问题，最后在计算机上实现该算法从而解决问题。

因为计算数学在实际问题的解决中具有如此重要的作用，数值分析课程作为计算数学专业的基础课程对数学的应用也显得极为重要。在数值分析课程中，同学们将学习到最基本和最常用的数值计算方法以及它们的理论。其中，解非线性方程组、多项式插值、数值微分和数值积分等是数值分析中最为基础的内容。在课程学习过程中，同学们需要深入理解这些数值计算方法的原理和性质，并掌握如何使用计算机实现这些方法。

对于数值算法的设计和应用，算法的评估和优化是非常重要的一环。在实际问题中，有时候我们需要比较不同算法的性能或者对某个算法进行优化和改进，这就需要对算法进行评

估。而算法的评估通常需要从多个方面进行，如算法的时间复杂度、空间复杂度、稳定性和精度等等。通过对算法进行综合评估，我们可以更好地了解算法的性能和优缺点。

另外，理论分析对于算法的设计和应用也是非常重要的。通过理论分析，我们可以深入理解算法的原理和性质，并预测算法在不同场景下的行为和性能。在算法设计中，理论分析可以帮助我们选择更加有效和高效的算法。在算法应用中，理论分析可以帮助我们理解算法为什么在某些问题中有效或者在某些问题中出现问题，并对算法进行改进和优化。

数值分析课程将涵盖非线性方程组、多项式插值与逼近、数值微分和数值积分、常微分方程数值解等各典型问题。对于每个问题，课程将提供相应的数值计算方法和理论，并通过具体的实例和案例，让学生了解算法的设计、理论分析和实践应用。对于非线性方程（组）的求解，同学们将学习到 Newton 迭代法、割线法、Broyden 拟牛顿法等经典算法，并了解它们的理论分析和应用。对于多项式插值与逼近，同学们将学习到 Lagrange 插值法、分片多项式插值、最佳一致逼近、最佳平方逼近等算法，并学会如何根据实际问题选择合适的插值和逼近方法。对于数值微分和数值积分，同学们将学习到数值微分和数值积分的基本原理和方法，包括中心差分、Richardson 外推、Newton-Cotes 公式、Romberg 公式、高斯积分公式等，并学会如何通过误差分析和复杂度分析来评估算法的性能。对于常微分方程数值解，学生将学习到初值问题的 Euler 方法、Runge-Kutta 方法等经典算法，了解刚性方程组和边值问题的算法，并了解它们的理论分析和应用。通过数值分析课程的学习，学生将获得对数值计算方法和理论的深入了解，并掌握如何应用这些方法解决实际问题，培养出良好的数学思维和计算能力，为日后从事科学研究和工程实践打下坚实的基础。

1.2 数值计算的误差

数值计算的误差是指在数值计算过程中，得到的结果与实际真实结果之间的差异。当我们遵循图1.1所示的流程解决实际问题时，将会遇到四种主要的误差类型，它们分别是模型误差、观测误差、截断误差和舍入误差。

- 模型误差。模型误差源于数学模型无法精确描述实际问题。在将实际问题抽象为数学模型的过程中，这些模型往往只能近似实际情况，并不能完全准确地表达。例如，在描述高速运动的物体时，如果使用牛顿第二定律，就可能引入模型误差；即使物理方程本身是精确的，通过实验数据拟合得到的材料参数也可能不够精确，这同样会导致模型误差。
- 观测误差。观测误差来自于测量实际物理量时的不确定性。在构建数学模型时，我们需要测量某些物理量来完善模型，但这些测量值本身可能包含误差。例如，测量温度时，仪器的精度限制可能会导致结果的不准确。观测误差受测量工具的灵敏度影响，而对测量数据的数学后处理有助于减少这种误差。
- 截断误差。当数学模型无法得到精确解而采用数值方法求得近似解时，将产生截断误差。这类误差发生在近似解与实际解之间，被称为截断误差或方法误差。例如，在进行无穷级数求和时，由于实际计算仅包含有限数量的项，便会引发截断误差，详细情况可参见例题 1.1。

- 舍入误差。舍入误差是由计算机数字表示的有限精度造成的。在数学建模和算法设计完成后，我们常常需要用计算机来进行数值计算。但是，计算机在运算过程中只能表示有限数量的位数，从而导致舍入误差。例如，计算无理数的近似值时，由于计算机只能处理有限位的小数，因此会产生舍入误差，具体情况可见例题 1.2。舍入误差与计算机处理实数的近似方法相关，最常见的是 IEEE 浮点数表示法，将在后续章节详细讨论。此外，原始数据转换为二进制数时产生的初始误差也归于舍入误差。

在数值计算的过程中，我们会遇到多种类型的误差，每一种误差都与图 1.1 中展示的基本流程的不同环节相对应。在建模阶段，模型误差源于数学模型无法完全精确描述实际问题；在数据采集环节，仪器和采集方法的限制会导致观测误差的产生；在算法设计阶段，采用数值近似方法对数学模型求解时，会产生截断误差；最终，在算法实现过程中，计算机浮点数系统的有限精度会引入舍入误差。

误差估计在数值计算中扮演着重要的角色，它帮助我们评估数值计算结果的精度是否达到了预定的标准。在数值分析的学习中，我们通常会假设数学模型的准确性并忽略模型误差，而且大多数情况下也会假定观测误差为零，主要关注截断误差和舍入误差。截断误差通常与算法的迭代方法相关，舍入误差则与计算机的浮点数系统以及数值计算的实现方式有关。下面，我们将通过一些简单的例子来阐释截断误差和舍入误差的不同及其影响。

例题 1.1 (1) 多项式计算通常较为简单，我们可以设计一个算法：用光滑函数 $f(x)$ 的 Taylor 多项式 $P_n(x)$ 来近似 $f(x)$ ，其中

$$P_n(x) = f(0) + \frac{f'(0)}{1!}x + \frac{f''(0)}{2!}x^2 + \cdots + \frac{f^{(n)}(0)}{n!}x^n, \quad (1.1)$$

那么该数值方法的截断误差就是

$$R_n(x) = f(x) - P_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!}x^{n+1}, \quad \text{其中 } \xi \text{ 在 } 0 \text{ 与 } x \text{ 之间。} \quad (1.2)$$

(2) 考虑使用梯形公式求解定积分 $\int_0^1 e^x dx$ 的近似值。梯形公式是将积分区间分成若干段等长度的小区间，然后在每个小区间内用梯形面积近似代替曲线下面积（细节可以参考第五章中数值积分的内容）。具体地，梯形公式的近似值为：

$$\int_0^1 e^x dx \approx \frac{1}{2}[e^0 + e^1] \approx 1.85914$$

然而，这个近似值并不完全准确，存在截断误差。实际上，精确值为 $e - 1 \approx 1.71828$ 。我们可以通过计算两者之间的差异来评估近似值的误差大小。

例题 1.2 (1) 为了方便计算，我们用 3.14159 近似代替 π ，这就会产生舍入误差

$$R = \pi - 3.14159 = 0.0000026 \cdots \quad (1.3)$$

(2) 考虑计算表达式 $\sqrt{2} - \sqrt{3} + \sqrt{5} - \sqrt{7}$ 的值。如果我们使用计算机进行计算，那么由于计算机的浮点数系统的有限精度，就会产生舍入误差。具体地，如果我们使用双精度浮点数（具体定义参考下一节）表示每个数，那么计算结果为 -0.79128784747792 。然而精确值是无法用有限的小数表示的，我们只能使用无限小数表示精确值，这之间的误差就是舍入误差。

我们不妨将图 1.1 中左侧实际问题的解称为真实解记作 x^* ；图 1.1 中右侧程序实现后得到

的解称为计算解，记作 x 。在大多数情况下我们不能精确得到 x^* ，因而把计算解 x 作为 x^* 的一个近似估计。那么为了衡量计算解 x 的好坏，非常自然地，我们需要一个度量来衡量计算解 x 与真实解 x^* 之间的距离。这里我们分别给出绝对误差和相对误差的定义：

定义 1.1

我们把 $e = |x - x^*|$ 称为计算解 x 的绝对误差，简称误差。



绝对误差越小，计算解 x 越接近真实解 x^* 。然而当真实解 x^* 太大或者太小时，绝对误差并不能很好地反映出计算解 x 对于真实解 x^* 的近似程度，因此我们还需要考虑相对误差的概念。相对误差则不仅考虑误差了的大小，还考虑到真实解 x^* 本身的大小。

定义 1.2

我们把计算解的误差 e 与真实解 x^* 的比值

$$\left| \frac{e}{x^*} \right| = \left| \frac{x - x^*}{x^*} \right|$$

称为计算解 x 的相对误差。



在实际计算中，由于我们并不知道真实解 x^* 的大小，通常需要用一定的近似方法来计算绝对误差或者相对误差，具体案例可以参考后续章节中的练习。

1.3 IEEE 浮点数系统

日常生活中我们通常使用十进制数进行计算，但是使用电子计算机进行计算时，一般采用二进制数。类似于常见的十进制数的科学计数法，二进制数也有科学计数法，即任意一个实数 x 可以表达为

$$x = \pm 1.d_1d_2 \cdots \times 2^k, \quad (1.4)$$

其中 $d_i \in \{0, 1\}$, $k \in \mathbf{Z}$ 。一般的实数在二进制科学计数法中具有无限位数字，由于计算机表达能力的限制，只能使用有限的存储空间在进行近似。



图 1.2: 浮点数的计算机存储

IEEE 浮点系统（即 IEEE-754）是由电气和电子工程师学会（Institute of Electrical and Electronics Engineers, 简称为 IEEE）于 1985 年制定的浮点系统标准，是当今计算机上实数的最常见表示形式。IEEE 浮点数有三个基本组成部分（参见图 1.2）：

- 符号位，占用一个字节，0 表示正数，1 表示负数。
- （偏置）指数位，表示(1.4)中指数 k 的大小。因为指数字段需要表示正指数和负指数，在存储指数中添加偏置以获得实际的指数。

- 尾数位, 表示(1.4)中截断后的小数部分。尾数是科学计数法或浮点数中的一个数字部分, 由其有效数字组成。在这里我们只有两个数字可能的选择即 0 和 1。

一般来说, 符号位仅仅占用一个字节, 根据指数位、尾数位占用字节数的不同 (分别令其为 (e, m) , 以及指数位偏置数字 (令其为 $bias$) 的不同, 可以给定一个二进制浮点数系统, 在计算机中的表示参考图 1.2。在 IEEE 浮点数系统中, 最常见的两类浮点数是 Float 类型和 Double 类型, 即单精度浮点数和双精度浮点数, 我们有

- 单精度: $e = 8, m = 23, bias = -127$,
- 双精度: $e = 11, m = 52, bias = -1023$ 。

对 $\forall x \in \mathbb{R}$, 它总可以写成

$$x = \pm 1.d_1 \cdots d_m d_{m+1} \cdots \times 2^k.$$

记 x 在一个浮点数系统 $\mathbb{F}$ 中的表示为 $fl(x)$ 。一般来说, $fl(x)$ 只是 x 的某种近似。常用的近似方法有两种: 一种是截断 (chop); 另一种是舍入 (round to nearest)。较为常见的近似为舍入 (即四舍五入), 于是有

$$\left| \frac{fl(x) - x}{x} \right| \leq 2^{-m}.$$

这就是实数的浮点数表示所产生的误差。我们把常数 2^{-m} 称为机器精度 $\varepsilon_{\text{mach}}$, 例如双精度系统中 $\varepsilon_{\text{mach}} = 2^{-52}$ (具体计算可以找到非零的最小浮点数, 这就是机器精度)。

当计算中都是正常浮点数时, 浮点运算可以理解为正常实数运算符合一次舍入运算, 由于舍入运算的非线性性质, 导致了对浮点数的精准分析比较困难。在现在常用的双精度 (单精度) 浮点数系统中, 由于机器精度为约为 $1e^{-16}$ ($1e^{-7}$), 可以看到每次的舍入误差非常之小, 所以绝大部分的应用可以忽略舍入误差而不会对解造成肉眼可见的错误, 但是这一结论在特定的问题上并不成立。在一些问题中, 选择不合适的模型、不恰当的算法、代码没有合理优化都有可能造成舍入误差的累计从而对数值结果造成巨大的错误, 具体的例子可以参考第三章和第四章中多项式插值和逼近部分。

1.4 计算复杂性和收敛速度

数值计算方法追求计算的精度和速度, 即要求算的又快又准, 而这两点通常是密不可分的。绝大部分进行算法分析的理论都暂时忽略舍入误差的影响, 这时算法大致可以分为直接法和迭代法, 其中直接法是指可在有限步得到计算问题之精确解的算法, 迭代法则是指采取逐次逼近的方法来逼近问题的精确解, 而在任意有限步都不能得到其精确解的算法。

实际应用中的计算速度依赖许多变量, 例如计算资源的软硬件环境如芯片指令集、缓存大小、编译器优化选择、数据存储和传输情况等, 不过在数值分析的层面上我们主要关注算法的计算复杂度, 即完成给定精度的计算结果, 需要完成多少次浮点数运算。注意到 20 世纪 90 年代之前的数值分析教科书中, 计算运算量时通常只计算乘除运算的次数, 这是因为当初的计算机乘除运算要比加减运算慢的缘故。进入 90 年代以后, 由于计算机的芯片架构调整, 在运算速度大幅度地提高的同时, 加减运算与乘除运算的速度已相差甚微, 因此现在是将一

个算法的所有浮点数运算次数的总和作为总体计算复杂度, 注意到计算复杂度通常只计算到首项, 例如某一算法共需作 $3n^3 + 10n^2 + 50n + 100$ 次加、减、乘、除运算, 则通常略去低阶项而说该算法的计算复杂度为 $3n^3$, 或者记为 $O(n^3)$ 。

对于迭代法, 除了对每步所需的运算量进行分析外, 还需对其收敛速度进行分析, 从而确定所需要的迭代步数。

定义 1.3

设某一迭代法产生的序列 $\{x_k\}$ 收敛于 x , 而且假定对于某个正数 $r \in [1, +\infty)$, 极限

$$\lim_{k \rightarrow \infty} \frac{\|x_k - x\|}{\|x_{k-1} - x\|^r} = c_r$$

存在。如果 $0 < c_r < +\infty$, 则称该算法是 r 次收敛的。显然 r 越大, 收敛越快。最常见的是 $r = 1, 2, 3$ 的情形:

- 当 $r = 1$ 时, $0 < c_r < 1$, 称为线性收敛, 而且 c_r 越小越好, 当 $c_r = 1$ 时, 称为次线性收敛;
- 当 $r = 2$ 时, 称为平方收敛 (有时也称为二次收敛);
- 当 $r = 3$ 时, 称为立方收敛 (有时也称为三次收敛)。



此外, 若

$$\lim_{k \rightarrow \infty} \frac{\|x_k - x\|}{\|x_{k-1} - x\|} = 0,$$

则称该算法是超线性收敛的。显然, 对于任意的 $r > 1$, r 阶收敛必然是超线性收敛的。

1.5 练习题

第 1 章 练习

1. 设 $x > 0$, 已知 x 的相对误差为 δ , 求 $\ln x$ 的误差.
2. 已知 $e = 2.7182818 \cdots$, 求以下近似值 x_A 的相对误差, 并说明它们各有多少位有效数字.
 - (1) $x = e, x_A = 2.7$;
 - (2) $x = e, x_A = 2.718$;
 - (3) $x = \frac{e}{100}, x_A = 0.027$;
 - (4) $x = \frac{e}{100}, x_A = 0.02718$.
3. 求解方程 $x^2 - 56x + 1 = 0$ 的两个根, 并且使其至少有四位有效数字, 计算中要求用 $\sqrt{783} \approx 27.982$.

第2章 非线性方程（组）的数值求解

本章我们将给出非线性方程或者非线性方程组的数值求解方法。不同于线性问题，一般来说不存在一个通用的方法来求解非线性方程和非线性方程组，因此非线性问题大都需要通过迭代法进行近似求解。接下来的内容，我们将会分别介绍单个非线性方程和非线性方程组这两类问题，并给出求解非线性方程和非线性方程组的迭代格式以及其对应的收敛性分析。

在介绍具体算法之前，我们需要注意到将实际问题转化为非线性方程或方程组求解时。待求的非线性方程（组）并不一定具有简单的显式表达式，它可能是具有输入参数的动力系统，输入给定参数后经过复杂的过程得到输出，因此计算方程（组）的导数甚至方程（组）本身都是非常不容易的，一个典型的例子是第六章中的打靶法。另外需要强调一点，我们这里所讨论的问题都假设为良态的，即对方程本身的微小扰动不会造成解的巨大变化。若某些问题的数值解呈现出不稳定的形态，读者除了需要检查算法的适用性和程序的正确性外，可能还需要分析方程求解问题本身的稳定性。

2.1 单个方程求解问题

2.1.1 二分法

我们先从一类最简单的算法：二分法开始。从数学分析中连续函数的性质我们知道，如果一个连续函数在某个区间内变号，则其必然有零点，更一般的，我们有如下的介值定理。

定理 2.1 (介值定理)

令连续函数 $f(x)$ 在两个端点处函数值不同，不妨设 $f(a) < f(b)$ ，任给常数 c 满足 $f(a) < c < f(b)$ ，则 $f(x)$ 在区间 (a, b) 中至少存在一个点使得 $f(x) = c$ 。



证明 虽然该定理的证明在任何一本数学分析教科书上都能找到，但是因为基于区间套的证明（特别是二分区间）方法可以直接导出二分法这一重要的算法，我们在这里仍然给出证明细节。整体的证明思路比较简单，即不断地将区间二等分，构造出一系列区间套，然后利用区间套定理和连续函数的性质，可以得到最终结论。具体细节如下：我们定义两个数列 a_n 和 b_n ，使得 a_n 递增， b_n 递减，并且 $a_n < b_n$ 。同时，定义区间 $I_n = [a_n, b_n]$ ，显然有 $I_1 = [a, b]$ 。我们下面考虑如何迭代构造这两个数列和区间。

首先，令 x_1 是 $[a, b]$ 的中点，即 $x_1 = \frac{a+b}{2}$ 。如果 $f(x_1) = c$ ，则我们已经找到了一个 x ，满足 $f(x) = c$ 。否则，我们考虑以下两种情况：

- 如果 $f(x_1) > c$ ，那么我们令 $a_2 = a_1$ ， $b_2 = x_1$ ，于是 I_2 仍然满足 $f(a_2) < c < f(b_2)$ 的条件；
- 如果 $f(x_1) < c$ ，那么我们令 $a_2 = x_1$ ， $b_2 = b_1$ ，于是 I_2 仍然满足 $f(a_2) < c < f(b_2)$ 的条件。

我们重复上述步骤，对于每个 $n \geq 1$ ，令 $x_n = \frac{a_n+b_n}{2}$ 。如果 $f(x_n) = c$ 则停止，如果 $f(x_n) > c$ ，我们令 $a_{n+1} = a_n$ ， $b_{n+1} = x_n$ ，否则，我们令 $a_{n+1} = x_n$ ， $b_{n+1} = b_n$ 。如果该过程有限步终止则我们找

到了 $f(x) = c$ 的解, 如果不能有限步终止, 我们得到一个闭区间套 $I_1 \supseteq I_2 \supseteq \cdots \supseteq I_n \supseteq \cdots$ 。

由于每个 I_n 都是闭区间, 并且区间长度逐次减半, 根据闭区间套定理, 存在唯一的实数 x , 满足 $x \in \bigcap_{n=1}^{\infty} I_n$ 。因此, 我们只需要证明 $f(x) = c$ 。注意到 $x = \lim_{n \rightarrow \infty} a_n = \lim_{n \rightarrow \infty} b_n$, 又因为 $f(a_n) < c < f(b_n)$, 同时 $f(x)$ 是连续函数, 于是

$$\begin{aligned} f(x) &= \lim_{n \rightarrow \infty} f(a_n) \leq c, \\ f(x) &= \lim_{n \rightarrow \infty} f(b_n) \geq c. \end{aligned}$$

因此, $f(x)$ 既不大于 c , 也不小于 c , 所以 $f(x) = c$ 。这样我们找到了一个 $x \in [a, b]$, 使得 $f(x) = c$, 证毕。

只要取 $c = 0$, 介值定理的证明思路就给出了一条非常清楚的算法: 二分法, 我们把算法伪代码放在算法1中。

Algorithm 1: 二分法伪代码

```

1: 输入初始端点  $a, b (a < b)$ , 需满足  $f(a)f(b) < 0$ , 误差限  $\epsilon > 0$ 
2:  $a_0 = a, b_0 = b$ 
3: for  $k = 0, 1, 2, 3, \dots$  do
4:   记  $x_{k+1} = (a_k + b_k)/2$ 
5:   如果  $f(x_{k+1}) = 0$ , 输出  $x_{k+1}$  程序中止
6:   如果  $f(x_{k+1}) \cdot f(a_k) < 0$ , 让  $a_{k+1} = a_k, b_{k+1} = x_{k+1}$ 
7:   否则  $a_{k+1} = x_{k+1}, b_{k+1} = b_k$ 
8:   检查停机准则  $|f(x_{k+1})| \leq \epsilon$  or  $|a_k - b_k| \leq \epsilon$ 
9: end for
10: 输出  $x_{k+1}$ 

```

一般情况下要让一个迭代法真正工作, 需要三个部分: 选取初始猜测, 设定迭代过程, 给出停机准则。对于二分法而言, 选取初始猜测和设定迭代过程都非常自然, 在算法1中我们采用函数值很小作为停机条件, 这个条件可以修改为选取区间的长度很小或者由最大迭代步数来控制停机。如果选择区间长度或者迭代步数作为停机准则, 我们有下面的误差估计结果。

定理 2.2 (二分法的误差估计)

$f(x)$ 为连续函数且满足 $f(a)f(b) < 0, a < b$ 。令二分法第一次迭代的点为 $x_1 = (a+b)/2$, 经过 k 次迭代后 $x_{k+1} = (a_k + b_k)/2$, 则一定存在 $f(x)$ 的一个零点 x 使得

$$|x_{k+1} - x| \leq \frac{b-a}{2^{k+1}}.$$

特别的如果方程 $f(x)$ 在 (a, b) 之间仅有一个零点 x^* , 则有

$$|x_{k+1} - x^*| \leq \frac{b-a}{2^{k+1}}.$$



证明 由二分法的迭代过程可以知道, 每一次迭代的区间长度减半, 而且区间端点函数值异号, 因此 k 次迭代得到的区间 $[a_k, b_k]$ 满足:

$$b_k - a_k = \frac{b-a}{2^k},$$

且 $[a_k, b_k]$ 中存在一个函数 $f(x)$ 的零点。于是由 x_{k+1} 的定义可以得到第一个不等式。第二个结论由第一个不等式可以直接得出。

例题 2.1 用二分法求解函数 $f(x) = \cos x - x$ 在区间 $[0, 1]$ 上的解, 精确到小数点后 6 位。

解 首先要确定需要多少次二分才能达到我们所需要的精度。定理 2.2 给出了二分法的误差上界, 我们知道经过 n 次迭代得到的解的误差为 $(b-a)/2^{n+1} = 1/2^{n+1}$ 。参考精确到小数点后 p 位的定义, 我们需要满足

$$1/2^{n+1} < 0.5 \times 10^{-6}$$

$$n > 6/\log_{10} 2 \approx 6/0.301 = 19.9.$$

因此, 需要 $n = 20$ 步的迭代。最终得到的结果精确到小数点后 6 位的估计值为 0.739085。具体的计算流程留给读者完成。

例题 2.2 利用二分法在区间 $[0, 1]$ 上找到函数 $f(x) = x^3 + x - 1$ 的解。

解 确认 $f(a_0)f(b_0) = -1 < 0$, 则在这个区间存在解。区间中点为 $x_0 = 1/2$ 。第一步, 计算函数值 $f(1/2) = -3/8$, $f(1/2)f(1) < 0$, 因此新区间选择 $[a_1, b_1] = [1/2, 1]$ 。第二步, 计算 $f(x_1) = f(3/4) = 11/64 > 0$, 则新区间选择 $[a_2, b_2] = [1/2, 3/4]$ 。继续运算得到以下的一系列区间:

i	a_i	$f(a_i)$	x_i	$f(x_i)$	b_i	$f(b_i)$	$ x_i - x^* $
0	0.0000	-	0.5000	-	1.0000	+	0.1823
1	0.5000	-	0.7500	+	1.0000	+	0.0677
2	0.5000	-	0.6250	-	0.7500	+	0.0573
3	0.6250	-	0.6875	+	0.7500	+	0.0052
4	0.6250	-	0.6562	-	0.6875	+	0.0261
5	0.6562	-	0.6719	-	0.6875	+	0.0105
6	0.6719	-	0.6797	-	0.6875	+	0.0026
7	0.6797	-	0.6836	+	0.6875	+	0.0013
8	0.6797	-	0.6816	-	0.6836	+	0.0007
9	0.6816	-	0.6826	+	0.6836	+	0.0003

从上表中可知, 函数的解是在 $a_9 \approx 0.6816$ 和 $x_9 \approx 0.6826$ 之间, 区间中点 $x_{10} \approx 0.6821$ 即是我们最终得到的根的最佳估计值。虽然我们的目标是找到根的位置, 但是实际得到的是一个含有根的区间 $[0.6816, 0.6826]$, 我们只能在这个区间内选择一个估计值。当然, 如果需要更高的精度, 通过增加二分法的迭代次数就能实现。

我们可以使用二分法进行 33 次迭代从而得到了一个更精确的解 $x^* = 0.6823(278038064018)$, 通过上面的定理 2.2 我们知道, 该解与真解的误差在 2^{-33} 以内。以 x^* 作为参照物 (真解), 我们可以观察随着迭代次数的增加, 二分法得到解的误差是怎么变化的, 具体如图 2.1 所示。不难发现, 二分法的解的误差并不是总是下降的。

从二分法的算法流程中, 我们会发现二分法具有算法操作过程简单, 停机准则、误差估计都很精确, 对方程的要求很少 (仅仅需要函数连续, 每次也只需要估计函数值而不需要求导等




图 2.1: 二分法求解 $f(x) = x^3 + x - 1$.

更加复杂的运算），其收敛速度也比较快。但是因为算法中利用了实数的序结构，所以其无法推广到方程组的情况；另外为了让算法能够正常运行，需要找到使得方程取值异号的初始区间，这一要求在某些问题中并不显然。

2.1.2 不动点迭代

为了得到一类可以推广到非线性方程组的方法，我们来介绍不动点迭代算法。首先将方程 $f(x) = 0$ 改写成等价的不动点方程 $x = \phi(x)$ 的形式（注意到改写方式并不唯一，一般来说改写成不动点方程后通常只能保证局部和原方程的等价性），然后做不动点迭代：

$$x_{k+1} = \phi(x_k).$$

关于不动点迭代，我们有非常著名的压缩映射原理。

定理 2.3 (压缩映射原理)

令 $\phi(x) : [a, b] \rightarrow [a, b]$ ，满足 $|\phi(x) - \phi(y)| \leq \rho|x - y|$ ，其中 $\rho \in (0, 1)$ 。则有

- (1) $\phi(x)$ 在 $[a, b]$ 中有唯一的不动点 x^* ，即满足不动点方程 $\phi(x^*) = x^*$ 。
- (2) $\forall x_0 \in [a, b]$ ，定义迭代序列 $x_{k+1} = \phi(x_k)$ 。则 x_k 至少线性收敛到 x^* 。



证明 我们可以借助介值定理来证明一维方程的情况，对于高维方程组的情形我们将在下一节给出更为一般的证明方法。构造辅助函数 $g(x) = \phi(x) - x$ ，则由函数 $\phi(x)$ 的值域范围得出 $g(a) \geq 0, g(b) \leq 0$ 。于是介值定理可以知道 $\exists x^*$ 满足 $\phi(x^*) = x^*$ ，存在性得证。下证唯一性：假设存在两个不动点 x^*, x^{**} ，那么 $|\phi(x^*) - \phi(x^{**})| = |x^* - x^{**}| \leq \rho|x^* - x^{**}|$ ，立得 $\therefore x^* = x^{**}$ ，唯一性得证，这就证明了 (1)。

为了证明 (2)，我们选取任意的 $x_0 \in [a, b]$ ，由 $\phi(x)$ 的值域范围可知不动点迭代 $x_{k+1} =$

$\phi(x_k)$ 是有意义的。由压缩映射的性质可知

$$|x_{k+1} - x^*| = |\phi(x_k) - \phi(x^*)| \leq \rho |x_k - x^*| \leq \rho^{k+1} |x_0 - x^*|,$$

这就证明了收敛性和至少线性收敛性, 于是 (2) 证毕。

在能够找到满足压缩映射条件的区间 $[a, b]$ 后, 压缩映射原理给出了一个相对大范围的收敛性算法, 即任意 $[a, b]$ 中的初值都可以保证收敛性, 而且算法的停机条件可以非常自然的设置成 $x_{k+1} - x_k = \phi(x_k) - x_k$ 小于某个给定的小量。当然如何选取区间 $[a, b]$ 通常不是一件容易的事情。另外从压缩映射原理的证明中, 只能得到线性收敛性。事实上对于性质较好的 $\phi(x)$, 是有可能获得更好的收敛性的, 下面我们进一步估计收敛速度。利用 Lagrange 中值定理可知

$$|x_{k+1} - x^*| = |\phi'(\xi_k)| \cdot |x_k - x^*|,$$

其中 ξ_k 在 x^* 和 x_k 之间, 于是 $\xi_k \rightarrow x^*$ 。如果 $\phi(x)$ 具有连续的一阶导数, 则可以看出当 $|\phi'(x^*)| < 1$ 时不动点迭代可以在某个小区间内收敛, 而且当 $|\phi'(x^*)|$ 越靠近 0 收敛越快。然而只要 $\phi'(x^*) \neq 0$, 不动点迭代只能得到线性收敛速度。如果我们希望得到更快的收敛速度, 一个必须的条件是 $\phi'(x^*) = 0$ 。

下面我们寻找这样的 ϕ 。因为我们希望 $f(x) = 0 \iff \phi(x) = x$, 一个自然的选择是 $\phi(x) = f(x)\psi(x) + x$ 。于是

$$\phi'(x^*) = f(x^*)\psi'(x^*) + f'(x^*)\psi(x^*) + 1 = f'(x^*)\psi(x^*) + 1 = 0 \Rightarrow \psi(x^*) = \frac{-1}{f'(x^*)}.$$

这样对于 ψ 的一个最简单的选择是 $\psi(x) = -\frac{1}{f'(x)}$, 这时候 $\phi(x) = x - \frac{f(x)}{f'(x)}$ 。此时不动点迭代就等价于非常重要的 Newton 迭代:

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}. \quad (2.1)$$

下一节中, 我们将详细讨论对 Newton 迭代的另外一种理解和它的各种优势与劣势。

2.1.3 Newton 法

上一节结尾, 我们得到 Newton 法的迭代格式, 下面我们从另外一个角度来理解 Newton 法。我们假设 x_k 已经比较好地近似 x^* 了, 于是在 x_k 处做如下线性展开

$$0 = f(x^*) = f(x_k) + (x^* - x_k)f'(x_k) + O((x_k - x^*)^2) \approx f(x_k) + (x^* - x_k)f'(x_k) \quad (2.2)$$

当 $f(x)$ 具有较好的光滑性时, 局部线性近似是一种非常合理和有效的工具, 在局部线性近似的前提下, 我们得到 Newton 迭代格式, Newton 法的算法参考算法 2。Newton 迭代可以用下面的

Algorithm 2: Newton 法伪代码

- 1: 输入初始猜测 x_0 , 误差限 $\epsilon > 0$
 - 2: **for** $k = 0, 1, 2, 3, \dots$ **do**
 - 3: $x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$
 - 4: 检查停机准则 $|f(x_{k+1})| \leq \epsilon$ 或 $|x_{k+1} - x_k| \leq \epsilon$
 - 5: **end for**
 - 6: 输出 x_{k+1}
-

示意图??来表达。




图 2.2: Newton 迭代

例题 2.3 用 Newton 法求解 $f(x) = x^3 - 3x + 2$ 的一个根 $x = -2$ ，选取初值 $x_0 = -3$ 。

解 取精度 $\epsilon = 10^{-16}$ ，迭代初值 $x_0 = -3.0$ ， $f'(x) = 3x^2 - 3$ ，则 Newton 法的迭代公式为

$$x_{k+1} = x_k - \frac{x_k^3 - 3x_k + 2}{3x_k^2 - 3}.$$

计算结果如表所示。

k	x_k	$E_k = x_k - x $	$\frac{E_k}{E_{k-1}^2}$
0	-3.0	1.0	
1	-2.3333333333333335	0.3333333333333335	0.3333333333333335
2	-2.0555555555555554	0.0555555555555554	0.4999999999999981
3	-2.0019493177387915	0.0019493177387915	0.6315789473684497
4	-2.000002528297975	0.000002528297975	0.6653696497827224
5	-2.0000000000042615	0.0000000000042615	0.6666624271442666
6	-2.0	0.0	

通过观察表格中的收敛速度，可发现经过迭代后的误差与上一步迭代误差有一定的比例关系，即：

$$|x_{k+1} - x| \approx \frac{2}{3}|x_k - x|^2$$

同时,在图 2.3 中我们比较了 Newton 法和二分法的收敛速度。非常明显地,我们可以得到 2 个信息。第一,Newton 法比二分法收敛速度更快,或者说 Newton 法是超线性收敛的,这个结果与我们理论结果是一致的;第二,不同于二分法收敛曲线的动荡,Newton 法的收敛更加顺滑。




图 2.3: 二分法求解 $f(x) = x^3 - 3x + 2$. 其中黑色的点是 Newton 法的结果,蓝色的是二分法的结果。

从上面的例子可以看出 Newton 法的收敛速度很快。一般来说,如果 $f(x)$ 具有一定的光滑性,并且初值选取在某个零点的附近,Newton 法具有二次收敛性。

定理 2.4 (Newton 法的局部二次收敛性)

令 x^* 为 $f(x)$ 的单根 (即 $f(x^*) = 0$ 且 $f'(x^*) \neq 0$), $f(x)$ 在 x^* 的邻域内二次连续可微。则存在 x^* 的邻域 $U = B(x^*, \epsilon)$, 使得 $\forall x_0 \in U$, 其 Newton 法均有意义, 且其产生的序列 x_k 至少二次收敛到 x^* 。



证明 按照 Newton 迭代的定义, $x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$, 在方程左右两边同时减去 x^* , 得到

$$\begin{aligned} x_{k+1} - x^* &= x_k - x^* + \frac{f(x^*) - f(x_k)}{f'(x_k)} \\ &= x_k - x^* + \frac{f'(x_k)(x^* - x_k) + \frac{1}{2}f''(\eta_k)|x^* - x_k|^2}{f'(x_k)}, \end{aligned}$$

其中 η_k 在 x_k 和 x^* 之间。于是有

$$|x_{k+1} - x^*| = \frac{|f''(\eta_k)|}{2|f'(x_k)|} |x^* - x_k|^2.$$

因为 $f(x)$ 在 x^* 附近二次连续可微且 $f'(x^*) \neq 0$, 则存在 x^* 的小邻域 $B(x^*, \epsilon_1)$, 对其中的任意 x 均有

$$2|f'(x)| \geq |f'(x^*)| \triangleq d, \quad |f''(x)| \leq L,$$

进一步令 $\epsilon = \min\{\epsilon_1, \frac{d}{2L}\}$, 则当 $x_k \in B(x^*, \epsilon)$ 时, 我们有

$$|x_{k+1} - x^*| = \frac{|f''(\eta_k)|}{2|f'(x_k)|} |x^* - x_k|^2 \leq \frac{L}{d} |x^* - x_k|^2 \leq \frac{1}{2} |x^* - x_k|.$$

由归纳法立刻得到只要初值 $x_0 \in B(x^*, \epsilon)$, 则 Newton 法都有意义 (即分母不为 0), 所产生的迭代序列 $\{x_k\} \subset B(x^*, \epsilon)$, 且至少线性收敛到 x^* 。进一步由

$$|x_{k+1} - x^*| \leq \frac{L}{d} |x^* - x_k|^2$$

可以证明二次收敛性。

2.1.4 割线法

我们在上一节知道 Newton 迭代具有二次收敛性, 但在实际应用中, 每一步都要计算导数的值。计算导数对于某些复杂问题非常困难或者无法计算, 当导数计算不可行时, 我们可以采用差商近似导数的想法, 引入下面的割线方法, 其示意图可以参考图 2.4。




图 2.4: 割线法

算法的基本思想是使用 x_{k-1} 和 x_k 两个点的函数值来近似 $f'(x_k)$, 即

$$f'(x_k) \approx \frac{f(x_k) - f(x_{k-1})}{x_k - x_{k-1}},$$

从而得到如下割线法

$$x_{k+1} = x_k - \frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})} f(x_k), \quad k = 1, 2, \dots \quad (2.3)$$

需要注意到不同于 Newton 迭代, 割线法需要两个初值。由于没有用到精确的导数信息, 我们不能期待割线法具有局部二次收敛的性质。

Algorithm 3: 割线法伪代码

```

1: 输入初始端点  $x_1, x_0$ , 误差限  $\epsilon > 0$ 
2: for  $k = 1, 2, 3 \dots$  do
3:    $x_{k+1} = x_k - \frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})} f(x_k)$ 
4:   检查停机准则  $|f(x_{k+1})| \leq \epsilon$  或  $|x_{k+1} - x_k| \leq \epsilon$ 
5: end for
6: 输出  $x_{k+1}$ 

```

例题 2.4 用割线法求解 $f(x) = x^3 - 3x + 2$ 的一个根 $x = -2$ 。

解 取精度 $\epsilon = 10^{-16}$, 迭代初值 $x_0 = -3.0, x_1 = -4.0$, 则割线法的迭代公式为

$$x_{k+1} = x_k - \frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})} f(x_k).$$

这里我们直接将结果展示在图 ?? 中。直观地, 我们可以发现割线法的收敛速度介于二分法和 Newton 法之间, 同时满足超线性收敛。




图 2.5: 割线法求解 $f(x) = x^3 - 3x + 2$. 其中黑色的点是 Newton 法的结果, 蓝色的是二分法的结果, 红色的是割线法的结果。

事实上我们可以证明割线法具有局部超线性收敛性, 更准确地说是局部 $\frac{\sqrt{5}+1}{2}$ 次收敛。

定理 2.5 (割线法的局部超线性收敛)

设 $f(x)$ 在其零点 x^* 的某个邻域内二阶连续可微, 且 $f'(x^*) \neq 0$, 如果初值 x_0, x_1 充分接近 x^* , 则迭代序列 2.3 超线性收敛于 x^* , 且收敛速率为 $\frac{1+\sqrt{5}}{2}$.



证明 类似 Newton 法的证明, 我们先定义 x^* 的邻域如下: 找到 δ_1 使得 $B(x^*, \delta_1)$ 中的每个点 x

都满足 $|f'(x)| \geq \frac{1}{2}|f'(x^*)|$ 且 $f(x)$ 在其内二阶连续可微, 令

$$M = \max_{x \in B(x^*, \delta_1)} |f''(x)| / \left(2 \min_{x \in B(x^*, \delta_1)} |f'(x)| \right).$$

取 $\delta = \min \{ \delta_1, \frac{1}{2M} \}$, 以后将在 $B(x^*, \delta)$ 中考虑问题, 即 $x_i \in B(x^*, \delta), i = 0, 1$. 此时任给 x_0, x_1 为 $B(x^*, \delta)$ 中不同的两个点, 立刻得到 $f(x_0) \neq f(x_1)$ (反证法利用 $B(x^*, \delta_1)$ 的定义可得).

我们考虑一步迭代过程. 当 $x_{k-1} \neq x_k$ 在 $B(x^*, \delta)$ 时, 我们记经过 $(x_{k-1}, f(x_{k-1}))$ 和 $(x_k, f(x_k))$ 两个点的直线为 P_1 , 这条直线也是 $f(x)$ 的线性插值函数. 我们可以利用一次多项式插值的 **Lagrange** 误差估计 (一般的结论可以参考第三章 **Lagrange** 插值的章节, 为了本定理证明的完整性, 这里我们重新证明如下估计):

$$\forall x \in B(x^*, \delta), \quad \exists \xi \in B(x^*, \delta), \quad \text{s.t.}, f(x) - P_1(x) = \frac{1}{2} f''(\xi) (x - x_k) (x - x_{k-1}). \quad (2.4)$$

若 $x = x_k$ 或 $x = x_{k-1}$, 上述结论显然成立, 下面我们考虑一般的 $x \neq x_i, i = k-1, k$. 为证明上述估计式, 考虑余项函数 $R(x) = f(x) - P_1(x)$, 其有 x_{k-1} 和 x_k 两个零点, 于是 $R(x) = h(x) (x - x_k) (x - x_{k-1})$. 对于 $x \neq x_i, i = k-1, k$, 我们构造辅助函数

$$F(t) = f(t) - P_1(t) - h(x) (t - x_k) (t - x_{k-1}),$$

显然 $F(t)$ 有三个零点 x_{k-1}, x_k, x , 于是应用两次罗尔中值定理可以得到

$$0 = F''(\xi) = f''(\xi) - 2h(x),$$

将 $h(x) = \frac{1}{2} f''(\xi)$ 带入余项函数的定义中即可得到(2.4)的结论.

$f(x)$ 的线性插值函数 $P_1(x)$ 具有表达式

$$P_1(x) = f(x_k) - \frac{f(x_k) - f(x_{k-1})}{x_k - x_{k-1}} (x_k - x),$$

于是将 x^* 带入其中并整理得到

$$\frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})} = \frac{x_k - x^*}{f(x_k) - P_1(x^*)}.$$

于是割线法的迭代过程可以得到

$$\begin{aligned} x_{k+1} - x^* &= x_k - x^* - \frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})} f(x_k) \\ &= x_k - x^* - \frac{x_k - x^*}{f(x_k) - P_1(x^*)} f(x_k) \\ &= - \frac{x_k - x^*}{f(x_k) - P_1(x^*)} P_1(x^*). \end{aligned}$$

由插值余项估计(2.4)和 **Lagrange** 中值定理可以得到

$$\begin{aligned} P_1(x^*) &= -\frac{1}{2} f''(\xi_1) (x^* - x_k) (x^* - x_{k-1}), \quad \xi_1 \in B(x^*, \delta), \\ \frac{x_k - x^*}{f(x_k) - P_1(x^*)} &= 1/f'(\xi_2) \quad \xi_2 \in B(x^*, \delta). \end{aligned}$$

我们令 $e_k = |x_k - x^*|$, 则有

$$e_{k+1} = \left| \frac{f''(\xi_1)}{2f'(\xi_2)} \right| e_k e_{k-1} \leq M\delta \cdot e_k < \frac{1}{2} e_k.$$

从上述的证明, 利用归纳法我们可以说明在割线法没有找到零点停机之前 (即 $f(x_k) \neq 0$), 割

线法保证 $x_{k+1} \neq x_k$ 且误差至少线性减少, 于是 $x_k \rightarrow x^*$ 。最后我们去证明收敛速度为 $\frac{\sqrt{5}+1}{2}$ 。由前面的证明过程可以知道

$$e_{k+1} = C_k e_k e_{k-1}, \quad C_k \rightarrow \left| \frac{f''(x^*)}{2f'(x^*)} \right|. \quad (2.5)$$

对方程(2.5)取对数后得

$$\ln e_{k+1} = \ln e_k + \ln e_{k-1} + \ln C_k.$$

$$\text{令 } a_k = \begin{pmatrix} \ln e_{k+1} \\ \ln e_k \end{pmatrix}, M = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}, \quad b_k = \begin{pmatrix} \ln C_k \\ 0 \end{pmatrix}, \quad \text{则有} \\ a_k = M a_{k-1} + b_k.$$

对 M 进行特征值解得到 $M = P^{-1} \Lambda P$, 其中

$$\Lambda = \begin{pmatrix} \frac{\sqrt{5}+1}{2} & 0 \\ 0 & \frac{1-\sqrt{5}}{2} \end{pmatrix}, \quad P = \begin{pmatrix} \frac{\sqrt{5}+1}{2} & 1 \\ \frac{1-\sqrt{5}}{2} & 1 \end{pmatrix}.$$

于是有 $P a_k = \Lambda P a_{k-1} + P b_k$ 。记 $\tilde{a}_k = P a_k, \tilde{b}_k = P b_k$, 我们有

$$\tilde{a}_{k,2} = \lambda_2 \tilde{a}_{k-1,2} + \tilde{b}_{k,2}, \quad \lambda_2 = \frac{1-\sqrt{5}}{2}. \\ \tilde{a}_{k,2} = \frac{1-\sqrt{5}}{2} \ln e_{k+1} + \ln e_k, \quad \tilde{b}_{k,2} = \frac{1-\sqrt{5}}{2} \ln C_k.$$

由 $C_k \rightarrow \left| \frac{f''(x^*)}{2f'(x^*)} \right|$ 可以得到 $\tilde{b}_{k,2} \rightarrow \frac{1-\sqrt{5}}{2} \ln \left| \frac{f''(x^*)}{2f'(x^*)} \right|$ 。由递推公式可以计算出

$$\tilde{a}_{n+k,2} = \lambda_2^k \tilde{a}_{n,2} + \tilde{b}_{n+k,2} + \lambda_2 \tilde{b}_{n+k-1,2} + \cdots + \lambda_2^{n-1} \tilde{b}_{n+1,2},$$

采用 $\epsilon - N$ 语言, 用定义不难证明

$$\tilde{a}_{k,2} \rightarrow \frac{1}{1-\lambda_2} \frac{1-\sqrt{5}}{2} \ln \left| \frac{f''(x^*)}{2f'(x^*)} \right| \triangleq C$$

于是有 $\frac{1-\sqrt{5}}{2} \ln e_{k+1} + \ln e_k \rightarrow C$, 即得到

$$\lim_{k \rightarrow \infty} \frac{e_{k+1}}{e_k^{\frac{\sqrt{5}+1}{2}}} = \text{Constant}.$$

2.1.5 试错法

上一节中我们介绍了割线法。与 Newton 迭代法相比, 割线法不用计算导函数的值, 对函数的要求降低了; 其收敛速度比 Newton 迭代法稍慢, 但仍是超线性的。但是割线法仍然只能保证局部收敛性, 对初值的要求比较高。本节中我们综合割线法和二分法的思想, 得到下面的 Regula Falsi (又称为 False Position, 或者试错法) 算法。该算法需要初始猜测两端函数符号相反, 然后再使用割线法选择区间内的点, 并且进一步要求下一个区间两端函数符号相反, 这样可以保证全局收敛性。算法的示意图参考 2.6。下面先介绍 Regula Falsi 的算法:

试错法一般来说具有线性收敛性, 下面的定理证明了在特殊情形下的结论。

Algorithm 4: 试错法 (Regula Falsi) 伪代码

```

1: 输入初始端点  $a, b (a < b)$ , 需满足  $f(a)f(b) < 0$ , 误差限  $\epsilon > 0$ 
2:  $a_0 = a, b_0 = b$ 
3: for  $k = 0, 1, 2, 3, \dots$  do
4:   记  $x_{k+1} = a_k - f(a_k) \frac{b_k - a_k}{f(b_k) - f(a_k)}$ 
5:   如果  $f(x_{k+1}) = 0$ , 输出  $x_{k+1}$  程序中止
6:   如果  $f(x_{k+1}) \cdot f(a_k) < 0$ , 让  $a_{k+1} = a_k, b_{k+1} = x_{k+1}$ 
7:   否则  $a_{k+1} = x_{k+1}, b_{k+1} = b_k$ 
8:   检查停机准则  $|f(x_{k+1})| \leq \epsilon$ 
9: end for
10: 输出  $x_{k+1}$ 

```

定理 2.6 (试错法的线性收敛性)

假设 $f(x)$ 在 $[a, b]$ 上为可微严格凸函数 (即 $f'(x)$ 严格单调递增), 且 $f(a) < 0 < f(b)$, 则 Regula Falsi 算法线性收敛到 $f(x)$ 的根。



证明 首先由 $f(x)$ 的严格凸和端点异号条件 $f(a) < 0 < f(b)$ 得到 $f(x)$ 在 $[a, b]$ 内有且只有一个零点 x^* (可以考虑最小的零点, 所有大于它的点, 导数值均为正数)。下面证明, 在 Regula Falsi 算法执行过程中, 区间右端点始终不变。由凸函数的性质可以知道经过 $(a, f(a)), (b, f(b))$ 的线段始终在 $f(x)$ 上方, 则对于该线段与 x 轴的交点 $x_1 = \frac{af(b)-bf(a)}{f(b)-f(a)}$ 来说, 有 $f(x_1) < 0$ 。于是下一次迭代的区间变成 $[x_1, b]$, 按照算法标记为 $[a_1, b_1], (a_1 = x_1, b_1 = b)$ 。重复上述过程可知每次迭代只有左端点会改变, 于是 a_n 是一个单调递增序列, 且天然有上界 b , 令其极限为 a^* , 不难证明 a^* 一定是 $f(x)$ 的零点, 由零点的唯一性知道 $a^* = x^*$, 于是我们得到了收敛性 $x_k \rightarrow x^*$, 下面证明线性收敛速度。迭代过程可以重写为

$$x_{k+1} = \frac{x_k f(b) - b f(x_k)}{f(b) - f(x_k)}.$$

同时减去 x^* 并做计算得到

$$\begin{aligned} x_{k+1} - x^* &= \frac{x_k f(b) - b f(x_k) - x^* f(b) + x^* f(x_k)}{f(b) - f(x_k)} \\ &= \frac{(x_k - x^*) f(b) + (x^* - b) (f(x_k) - f(x^*))}{f(b) - f(x_k)} \\ &= (x_k - x^*) \frac{f(b) + (x^* - b) f'(\xi_k)}{f(b) - f(x_k)} \end{aligned}$$

其中 $\xi_k \in (x_k, x^*)$ 。由 $x_k \rightarrow x^*$, 我们得到

$$\begin{aligned} \frac{f(b) + (x^* - b) f'(\xi_k)}{f(b) - f(x_k)} &\rightarrow \frac{f(b) + (x^* - b) f'(x^*)}{f(b)} \triangleq \rho, \\ \rho &= 1 - \frac{(b - x^*) f'(x^*)}{f(b) - f(x^*)} = 1 - \frac{f'(x^*)}{f'(\xi)}, \xi \in (x^*, b). \end{aligned}$$

于是 $0 < f'(x^*) < f'(\xi) \Rightarrow 0 < \rho < 1$, 这就证明了线性收敛性。




图 2.6: 试错法 (Regula Falsi) 示意图

2.2 非线性方程组求解

这一节我们考虑非线性方程组的求解, 其中非线性映射为 $F: \mathbb{R}^n \rightarrow \mathbb{R}^n$ 。相较于线性方程组和非线性方程而言, 非线性方程组的求解要困难得多, 例如有如下原因:

- 非线性方程组解的存在性、唯一性等没有一般的理论。
- $\mathbb{R}^n$ 没有全序结构, 导致使用了介值定理的算法在非线性方程组的情况都不再适用。
- 当 n 比较大时, 每一步迭代中如何快速求解是一个重要的问题。
- 一般情况下, 寻求适合大范围初值的算法, 或者多解问题的算法均非常困难。

2.2.1 不动点迭代

类似非线性方程, 不动点迭代是最基本的迭代方式, 而压缩映射原理是不动点迭代收敛的重要依据。这里需要注意的是: 压缩映射依赖于度量的定义, 某个函数完全可以在一个度量下是压缩映射, 而在另一个度量的定义下不是。

定理 2.7 (压缩映射原理)

令 $D \subset \mathbb{R}^n$ 为非空闭集, $F: D \mapsto D$ 在范数 $\|\cdot\|$ 下为压缩映射, 即

$$\|F(x) - F(y)\| \leq \rho \|x - y\|, \quad \rho \in (0, 1),$$

则 $F(x)$ 在 D 中存在唯一的不动点 x^* , 且任意给初始猜测 x_0 , 不动点迭代序列 $x_{k+1} = F(x_k)$ 至少线性收敛到 x^* 。



证明 先证明不动点的存在性, 即 $\exists x^* \in D$, s.t. $F(x^*) = x^*$. 我们任取 $x_0 \in D$, 并记不动点迭代序列为 $x_{k+1} = F(x_k)$. 利用压缩映射的定义可以得到

$$\begin{aligned}\|x_2 - x_1\| &= \|F(x_1) - F(x_0)\| \leq \rho \|x_1 - x_0\|, \\ \|x_3 - x_2\| &= \|F(x_2) - F(x_1)\| \leq \rho \|x_2 - x_1\| \leq \rho^2 \|x_1 - x_0\|, \\ \|x_{n+1} - x_n\| &= \|F(x_n) - F(x_{n-1})\| \leq \rho \|x_n - x_{n-1}\| \leq \cdots \leq \rho^n \|x_1 - x_0\|.\end{aligned}$$

于是有

$$\begin{aligned}\|x_n - x_m\| &\leq \|x_n - x_{n-1}\| + \cdots + \|x_{m+1} - x_m\| \\ &\leq \rho^{n-1} \|x_1 - x_0\| + \cdots + \rho^m \|x_1 - x_0\| \\ &\leq \frac{\rho^m}{1 - \rho} \|x_1 - x_0\|, \quad \forall m < n.\end{aligned}$$

由 Cauchy 列的定义我们得到 $\{x_n\}$ 是 Cauchy 列, 其有极限, 并记 $\lim_{n \rightarrow \infty} x_n = x^*$. 因为 D 为闭集故有 $x^* \in D$. 由压缩映射的定义知道 $F(x)$ 是 Lipschitz 连续的, 所以

$$x^* = \lim_{n \rightarrow \infty} x_{n+1} = \lim_{n \rightarrow \infty} F(x_n) = F(\lim_{n \rightarrow \infty} x_n) = F(x^*).$$

即 x^* 为不动点。下面证明唯一性, 假设存在两个不动点 x^*, x^{**}

$$\|x^* - x^{**}\| = \|F(x^*) - F(x^{**})\| \leq \rho \|x^* - x^{**}\| \Rightarrow \|x^* - x^{**}\| = 0 \Rightarrow x^* = x^{**}.$$

最后由 $\|x_k - x^*\| = \|F(x_{k-1}) - F(x^*)\| \leq \rho \|x_{k-1} - x^*\|$ 可以知道对任意初值都至少有线性收敛到 x^* 。

这里需要注意的是, 在分析学中, 除了最基本的压缩映射不动点定理外, 还有很多类似的不动点定理。例如 Brouwer 不动点定理: D 为非空凸紧集, 则自身到自身的连续映射存在不动点。这些不动点定理的条件较弱, 其可以保证不动点的存在性, 但是不能够保证迭代所产生的不动点序列可以收敛。

例题 2.5 给出一个 $\mathbb{R}^n$ 到自身映射的具体实例, 要求其在某种范数下是压缩的, 而在另外一种范数下不是。

解 考虑映射 $F(x) = Ax$, 其中

$$A = \rho \begin{pmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{pmatrix}, \rho = 0.9, \theta = \frac{\pi}{4}.$$

在 2-范数意义下, 我们可以得到

$$\begin{aligned}\|F(x) - F(y)\|_2 &= \|Ax - Ay\|_2 \\ &\leq \|A\|_2 \|x - y\|_2 \\ &= 0.9 \|x - y\|_2\end{aligned}$$

$F(x)$ 是压缩映射。然而在 1-范数意义下, $\|A\|_1 = \sqrt{2}\rho > 1$, 不是压缩映射。

2.2.2 Newton 法

Newton 法是求解非线性方程组最为重要的方法之一。为了给出 Newton 法的迭代格式, 我们首先定义 *Frechét* 导数, 即数学分析中所学的全微分。这里注意到 $\mathbb{R}^n$ 上的微分可以理解为线性函数来局部逼近一般的函数, 微分是取其线性主要部分。*Frechét* 导数的定义如下:

定义 2.1

令 $G: D \mapsto \mathbb{R}^{n \times n}$ 满足任意 $x \in \text{int} D$ 都有:

$$\lim_{\|h\| \rightarrow 0} \frac{\|F(x+h) - F(x) - G(x)h\|}{\|h\|} = 0,$$

则称 $F(x)$ 在 $\text{int} D$ 中 *Frechét* 可导, *Frechét* 导数为 $G = \nabla F$.



注意 *Frechét* 导数的定义并不依赖于线性空间 $\mathbb{R}^n$ 的基底, 其在欧氏空间标准基底下的表示又被称为 *Jacobi* 矩阵。和非线性方程的 Newton 法求解类似, 使用局部线性展开 (将零点 x^* 在其附近的 x_k 点进行一阶展开), 并利用 *Frechét* 导数的定义,

$$\begin{aligned} 0 = F(x^*) &= F(x_k) + \nabla F(x_k)(x^* - x_k) + o(\|x^* - x_k\|) \\ &\approx F(x_k) + \nabla F(x_k)(x^* - x_k) \end{aligned}$$

于是 Newton 迭代可以表示成: $x^* \approx x_{k+1} = x_k - \nabla F(x_k)^{-1} F(x_k)$ 。与非线性方程的 Newton 法类似, 在一定的光滑性假设下, 我们可以得到 Newton 法的局部二次收敛性。

定理 2.8 (局部二次收敛性)

令 x^* 为 $F(x)$ 的零点, 且在其邻域 $B(x^*, R)$ 中有

$$\|\nabla F(x^*)^{-1}\| \leq C, \quad \|\nabla F(x) - \nabla F(y)\| \leq L\|x - y\|,$$

则存在 $r = \min\{R, 1/(2CL)\}$, 使得当 $x_0 \in B(x^*, r)$ 时, Newton 迭代格式

$$x_{k+1} = x_k - \nabla F(x_k)^{-1} F(x_k), \quad \text{for } k = 0, 1, 2, \dots \quad (2.6)$$

有意义, 并且 x_k 收敛到 x^* 且

$$\|x_{k+1} - x^*\| \leq CL \|x_k - x^*\|^2.$$



证明 首先容易看到只需证明 $\nabla F(x_0)$ 可逆, 且满足 $\|x_1 - x^*\| \leq CL\|x_0 - x^*\|^2$, 即可以用数学归纳法证明对所有的 k 都有 Newton 迭代有意义且 $\|x_{k+1} - x^*\| \leq CL\|x_k - x^*\|^2$ 。由 Newton 迭代的定义, 我们知道

$$\nabla F(x_0)(x_1 - x_0) = -F(x_0),$$

暂时假定 $\nabla F(x_0)$ 可逆 (后面在证明 $\nabla F^{-1}(x_0)$ 范数估计的时候会同时证明其可逆), 两边乘以 $\nabla F^{-1}(x_0)$ 并同时减去 x^* 得到

$$x_1 - x^* = x_0 - [\nabla F(x_0)]^{-1} F(x_0) - x^* = -[\nabla F(x_0)]^{-1} (\nabla F(x_0)(x^* - x_0) + F(x_0)).$$

于是

$$\|x_1 - x^*\| \leq \|[\nabla F(x_0)]^{-1}\| \cdot \|F(x^*) - F(x_0) - \nabla F(x_0)(x^* - x_0)\|.$$

接下来我们分别估计 $\|[\nabla F(x_0)]^{-1}\|$ 和 $\|F(x^*) - F(x_0) - \nabla F(x_0)(x^* - x_0)\|$ 。对于第一项, 我们可以计算

$$[\nabla F(x_0)]^{-1} = [\nabla F^{-1}(x^*)\nabla F(x_0)]^{-1}\nabla F^{-1}(x^*),$$

令 $A = I - \nabla F^{-1}(x^*)\nabla F(x_0)$, 于是有

$$\begin{aligned} A &= I - \nabla F^{-1}(x^*)\nabla F(x_0) \\ &= \nabla F^{-1}(x^*)[\nabla F(x^*) - \nabla F(x_0)], \|A\| \leq C\|\nabla F(x^*) - \nabla F(x_0)\| \\ &\leq CL\|x^* - x_0\| \leq \frac{1}{2}. \end{aligned}$$

这就可以得到 $\|(I - A)^{-1}\| \leq \frac{1}{1 - \|A\|} \leq 2$ 。我们可以得到

$$\|\nabla F(x_0)^{-1}\| \leq \|(I - A)^{-1}\| \|\nabla F(x^*)^{-1}\| \leq 2C.$$

接下来估计 $\|F(x^*) - F(x_0) - \nabla F(x_0)(x^* - x_0)\|$, 我们将利用一维 Taylor 展开进行估计。注意到 $x^* = x_0 + \|x^* - x_0\| \frac{x^* - x_0}{\|x^* - x_0\|}$, 定义函数 $f(t) \triangleq F(x_0 + te)$, 其中 $t \in [0, \alpha]$, $\alpha = \|x^* - x_0\|$; $e = \frac{x^* - x_0}{\|x^* - x_0\|}$ 。于是有

$$f(0) = F(x_0), \quad f(\alpha) = F(x^*), \quad f'(t) = \nabla F(x_0 + te)e.$$

利用 Taylor 展开可以得到

$$\begin{aligned} \|F(x^*) - F(x_0) - \nabla F(x_0)(x^* - x_0)\| &= \|F(x^*) - F(x_0) - \alpha \nabla F(x_0)e\| \\ &= \|f(\alpha) - f(0) - f'(0)\alpha\| \\ &= \left\| \int_0^\alpha f'(t)dt - f'(0) \int_0^\alpha dt \right\| \\ &= \left\| \int_0^\alpha (f'(t) - f'(0))dt \right\| \\ &\leq \int_0^\alpha \|f'(t) - f'(0)\|dt \\ &\leq \int_0^\alpha \|\nabla F(x_0 + te) - \nabla F(x_0)\|dt \\ &\leq \int_0^\alpha Ltdt = \frac{L}{2}\alpha^2 = \frac{L}{2}\|x^* - x_0\|^2. \end{aligned}$$

综合上述两个估计, 便可得到最终结果。

由上述收敛性定理可以知道, Newton 法具有极快的计算效率, 如果能够找到一个好的初值。但是在实际问题中, 初值的选取是及其困难的一件事情。不过当初值不是非常靠近真解, 虽然没有理论上的收敛性, 我们仍然可以使用牛顿迭代, 但是要注意到算法不一定能够可行 (Jacobi 矩阵可能不可逆)。下面我们介绍一些 Newton 迭代可能带来的困难, 以及为了克服这些困难我们如何将 Newton 法做一些合理的变形。

- 每一步 Newton 迭代都需要求解线性方程组 (即 Jacobi 矩阵求逆), 这一步在计算上可能是比较昂贵的。一个可以使用的方法是 Samaski 技巧, 即每过 m 步再更新 Jacobi 矩阵 (将 Jacobi 矩阵的 LU 分解存储下来)。
- 对于很多大规模问题, 即使只做一次 LU 分解都可能很昂贵, 同时 Jacobi 矩阵经常具有特

定的结构(如矩阵是稀疏的),可以使用非精确 Newton: 使用迭代法(如 SOR 或者子空间迭代以及预处理方式)求解代数方程组,不过这里的困难是如何确定内循环的停机准则,可以在一般的非精确 Newton 的框架下进行算法设计和分析。

- 类似方程的问题, Jacobi 矩阵没有显式表达式, 或者没办法求解出精确的 Jacobi 矩阵时, 可以采用近似方法计算 Jacobi 矩阵, 例如使用差商代替导数, 这里的困难在于计算量可能非常大(计算 Jacobi 矩阵的每个元素需要计算一次函数值), 而且用什么样精度的差商更加合适, 以及会不会因为近似 Jacobi 矩阵带来计算上的不收敛等均没有简单的答案。
- Jacobi 矩阵在迭代过程中有可能出现奇异或病态, 导致 Newton 迭代不能被良好的定义, 这样的情况在不太精确的初值下是有可能发生的。为了让 Newton 迭代能够进行下去, 我们可以采用某些近似求解 Newton 迭代的方法, 最常见的是 Levenberg-Marquardt 方法, 该方法中有一个正则化参数需要随着迭代次数的增加而逐步减少, 但是如何选择这个参数是一个不太显然的问题, 在实践中经常选成某种几何递减级数。

$$LM(\text{Levenberg} - \text{Marquardt}) : \begin{cases} \Delta x_k = \arg \min \|\nabla F(x_k) \Delta x + F(x_k)\|^2 + \alpha_k \|\Delta x + x_k\|^2, \\ x_{k+1} = x_k + \Delta x_k. \end{cases}$$

例题 2.6 考虑如下非线性方程组

$$\begin{cases} e^{x_1^2+x_2^2} - 1 = 0, \\ e^{x_1^2-x_2^2} - 1 = 0. \end{cases}$$

我们已知该方程组有唯一解 $x_1 = x_2 = 0$, 下面我们使用 Newton 法来解该方程组。

解 如果给定初值 $\mathbf{x}^{(0)} = [0.1, 0.1]^T$, 经过 22 次迭代我们可以得到结果 $\mathbf{x}^{(22)} = [0.34 \times 10^{-9}, 0.34 \times 10^{-9}]^T$ 。该结果与方程组的真解很接近, 同时迭代步数也很少。但是, 当我们更换初值 $\mathbf{x}^{(0)}$, Newton 法的表现会发生剧烈变化。例如, 我们设定初值 $\mathbf{x}^{(0)} = [10, 10]^T$, 那么经过 220 步迭代才能获得结果 $\mathbf{x}^{(220)} = [0.26 \times 10^{-7}, 0.26 \times 10^{-7}]^T$ 。当我们设定初值 $\mathbf{x}^{(0)} = [20, 20]^T$, 可以发现 Newton 法是不收敛的。通过以上的结果, 我们可以得出结论, Newton 法对于初值的选择非常敏感。具体的计算过程留给读者自行完成, 下面我们提供一个算例。

例题 2.7 分别用 Newton 法和 Levenberg-Marquard 法求解如下方程:

$$\begin{aligned} x^2 &= y - x \cos(\pi x), \\ yx + e^{-y} &= x^{-1}. \end{aligned}$$

解 按照相同的思路, 我们先找到方程组对应的 Jacobi 矩阵, 接下来按照对应的算法求解该方程组。该方程组有真解 $x = 1, y = 0$, 我们所设定的初值为 $x_0, y_0 = (2, -1)$ 。对于 Levenberg-Marquard 法, 我们令阻尼因子 $\alpha_k = 1/5^{(k+10)}$, 其中 k 表示迭代步数。对比结果见图 2.7。

为了进一步研究阻尼因子 α_k 对算法的影响, 我们进一步对比了 Newton 法与 Levenberg-Marquard 法, 这里我们设置 Levenberg-Marquard 法的阻尼因子 $\alpha_k = \alpha_k = 1/a^{(k+10)}$, 其中 $a = 2, 4, 6, 8$ 。对比结果见图 2.8。




图 2.7: 求解非线性方程组. 其中黑色的点是 Newton 法的结果, 红色的是 Levenberg-Marquardt 法的结果。




图 2.8: Levenberg-Marquardt 法求解非线性方程组. 其中不同颜色的点表示不同阻尼因子的结果。

2.2.3 拟牛顿法

当目标函数的梯度没有显式表达式或者非常难以计算时，我们需要一些近似方法来进行计算。在一维非线性方程的时候我们介绍了割线法可以有效替代 Newton 法，但方程组的情况要更为复杂，需要采取更加精巧的策略。在上一节中我们提出可以利用差商代替导数，并得到 Jacobi 矩阵的一个近似，但是这一方法的计算量通常都极其巨大，特别是函数值的计算还比较耗时的情况。下面我们介绍一类拟牛顿方法，通过一些容易计算的量，来近似 Jacobi 矩阵，我们将以最容易理解的 Broyden 算法为例子来说明其中的思想。

拟牛顿方法最重要的一步是得到 Jacobi 矩阵的一类合理近似，对于 $\nabla F(x_k)$ ，做 Taylor 展开近似得到如下割线方程：

$$F(x_{k-1}) - F(x_k) \approx \nabla F(x_k)(x_{k-1} - x_k). \quad (2.7)$$

这个条件对于 Jacobi 矩阵是非常本质和重要的，于是我们要求近似矩阵 H_k 满足上面的割线方程。但是割线方程只提供了 n 个方程，不可能唯一确定出自由度为 n^2 的近似矩阵，需要额外的信息来确定之。一个非常合理的观测和假设是当前近似矩阵 H_k 和上一步的近似矩阵 H_{k-1} 相差很少，在这个前提下，有可能唯一确定近似矩阵。这里相差很少有两个含义：第一是 $H_k - H_{k-1}$ 在某种度量下最小（例如最常见的 Frobenius 范数的度量下很小，或者仅相差一个低秩矩阵），第二是 H_k 的逆可以比较容易的计算。很幸运的是这两点可以同时做到，这就是我们下面将要介绍的 Broyden 方法。

引理 2.1

令 $A \in \mathbf{R}^{n \times n}$ ，则所有满足 $A\mathbf{x} = \mathbf{b}$ 的矩阵中，具有最小 F -范数的矩阵为 $\frac{\mathbf{b}\mathbf{x}^t}{\|\mathbf{x}\|_2^2}$ 。



证明 原问题等价于求解如下的优化问题：记 $A = [\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n]^T$,

$$\min \|A\|_F^2 = \sum_{i=1}^n \|\mathbf{a}_i\|_2^2, \quad (2.8)$$

$$\text{subject to } \mathbf{a}_i^t \mathbf{x} = b_i \quad i = 1, 2, \dots, n. \quad (2.9)$$

很显然该问题可以被分解为 n 个独立的子问题来求解

$$\min \|\mathbf{a}_i\|_2^2, \quad (2.10)$$

$$\text{subject to } \mathbf{a}_i^t \mathbf{x} = b_i. \quad (2.11)$$

记 $\mathbf{x}$ 张成的空间为 $U = \text{span}\{\mathbf{x}\}$ ，其正交补空间为 V ，令 V 的一组标准正交基为 $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_{n-1}\}$ 。于是任意的向量可以将其表示为 $\mathbf{a}_i = \sum_{j=1}^{n-1} \lambda_j^i \mathbf{x}_j + \mu \frac{\mathbf{x}}{\|\mathbf{x}\|_2^2}$ 。在这个表示下，约束 $\mathbf{a}_i^t \mathbf{x} = b_i$ 可以转化为 $\mathbf{a}_i^t \mathbf{x} = \mu \Rightarrow \mu = b_i$ ，并将 2.10 改写成

$$\min \sum_{j=1}^{n-1} (\lambda_j^i)^2 + \frac{\mu^2}{\|\mathbf{x}\|_2^2}, \quad (2.12)$$

$$\text{subject to } \mu = b_i. \quad (2.13)$$

显然其最优解为 $\lambda_j^i = 0, \forall j = 1, 2, \dots, n-1, \forall i = 1, 2, \dots, n$ 。于是 $\mathbf{a}_i = b_i \frac{\mathbf{x}}{\|\mathbf{x}\|_2^2}, \forall i = 1, 2, \dots, n$,

即 $A = b^t \frac{x}{\|x\|_2^2}$ 。

从上面这个引理可以很容易得出 H_k 是 H_{k-1} 的秩一更新。将割线条件(2.7)带入引理的表达式中可以得到

$$H_k = H_{k-1} + \frac{b_{k-1} - H_{k-1}y_{k-1}}{y_{k-1}^t y_{k-1}} y_{k-1}^t, \quad b_{k-1} = F(x_k) - F(x_{k-1}), \quad y_{k-1} = x_k - x_{k-1}.$$

另一个要解决的问题是如何高效求解拟牛顿迭代的线性方程组。下面的引理表明在秩一更新下, 拟牛顿矩阵的逆是可以有显示表达式的。

引理 2.2 (Sherman-Morrison 公式)

令 A 为可逆矩阵, 且 $v^t A^{-1} u \neq -1$, 则 $A + uv^t$ 可逆, 且

$$(A + uv^t)^{-1} = A^{-1} - \frac{A^{-1}uv^t A^{-1}}{1 + v^t A^{-1}u}.$$



证明 令 $X = A + uv^t, Y = A^{-1} - \frac{A^{-1}uv^t A^{-1}}{1 + v^t A^{-1}u}$, 则只需证明 $XY = I$ 即可。经过计算可以得到:

$$\begin{aligned} XY &= (A + uv^t) \left(A^{-1} - \frac{A^{-1}uv^t A^{-1}}{1 + v^t A^{-1}u} \right) \\ &= AA^{-1} + uv^t A^{-1} - \frac{AA^{-1}uv^t A^{-1} + uv^t A^{-1}uv^t A^{-1}}{1 + v^t A^{-1}u} \\ &= I + uv^t A^{-1} - \frac{uv^t A^{-1} + uv^t A^{-1}uv^t A^{-1}}{1 + v^t A^{-1}u} \\ &= I + uv^t A^{-1} - \frac{u(1 + v^t A^{-1}u)v^t A^{-1}}{1 + v^t A^{-1}u} \\ &= I + uv^t A^{-1} - uv^t A^{-1} = I. \end{aligned}$$

于是引理的结果得证。

在更一般的拟牛顿法中, 低秩更新这个环节的秩不一定是一, 这时候可能需要 Sherman-Morrison 公式的推广: 即 Sherman-Morrison-Woodbury 公式。

引理 2.3 (Sherman-Morrison-Woodbury 公式)

给定一个 $n \times n$ 的可逆方阵 A , 一个 $n \times k$ 的矩阵 U , 一个 $k \times n$ 矩阵 V , 其中 $k < n$ 。记 B 为 $n \times n$ 矩阵定义为 $B = A + UV$ 。如果 $(I_k + VA^{-1}U)$ 可逆, 则我们有 B 可逆, 且其逆有显式表达式:

$$B^{-1} = A^{-1} - A^{-1}U(I_k + VA^{-1}U)^{-1}VA^{-1}.$$



证明 令 $Z = VA^{-1}U \in R^{k \times k}$, 则可计算出

$$\begin{aligned} &(A^{-1} - A^{-1}U(I + Z)^{-1}VA^{-1})(A + UV) \\ &= I - A^{-1}U(I + Z)^{-1}V + A^{-1}UV - A^{-1}U(I + Z)^{-1}VA^{-1}UV \\ &= I - A^{-1}U(I + Z)^{-1}V + A^{-1}U(I + Z)^{-1}(I + Z)V - A^{-1}U(I + Z)^{-1}ZV \\ &= I + A^{-1}U(I + Z)^{-1}[-I + I + Z - Z]V \\ &= I. \end{aligned}$$

于是原命题得证。

将上面的思想带入到非线性方程组求解中, 就可以得到 Broyden 算法。当 $\|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\|$ 很小时, 近似地有

$$\mathbf{f}(\mathbf{x}^{(k-1)}) \approx \mathbf{f}(\mathbf{x}^{(k)}) + \nabla \mathbf{f}(\mathbf{x}^{(k)}) (\mathbf{x}^{(k-1)} - \mathbf{x}^{(k)}),$$

将其写成方程组的形式, 得到割线方程为

$$\mathbf{A}^{(k)} \mathbf{y}^{(k-1)} = \mathbf{g}^{(k-1)}. \quad (2.14)$$

其中

$$\mathbf{y}^{(k-1)} = \mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}, \quad \mathbf{g}^{(k-1)} = \mathbf{f}(\mathbf{x}^{(k)}) - \mathbf{f}(\mathbf{x}^{(k-1)}), \quad \mathbf{A}^{(k)} \approx \nabla \mathbf{f}(\mathbf{x}^{(k)}).$$

假设 $\mathbf{A}^{(k-1)}$ 和 $\mathbf{A}^{(k)}$ 之间相差最小的 Frobenious 范数, 于是 $\mathbf{A}^{(k)}$ 与 $\mathbf{A}^{(k-1)}$ 之间只差一个秩 1 修正, 即

$$\mathbf{A}^{(k)} = \mathbf{A}^{(k-1)} + \mathbf{u}^{(k-1)} (\mathbf{y}^{(k-1)})^T \quad (2.15)$$

其中

$$\begin{aligned} \mathbf{g}^{(k-1)} &= \mathbf{A}^{(k)} \mathbf{y}^{(k-1)} = \mathbf{A}^{(k-1)} \mathbf{y}^{(k-1)} + \mathbf{u}^{(k-1)} (\mathbf{y}^{(k-1)})^T \mathbf{y}^{(k-1)}, \\ \mathbf{u}^{(k-1)} &= \frac{\mathbf{g}^{(k-1)} - \mathbf{A}^{(k-1)} \mathbf{y}^{(k-1)}}{(\mathbf{y}^{(k-1)})^T \mathbf{y}^{(k-1)}}. \end{aligned}$$

于是

$$\mathbf{A}^{(k)} = \mathbf{A}^{(k-1)} + \frac{\mathbf{g}^{(k-1)} - \mathbf{A}^{(k-1)} \mathbf{y}^{(k-1)}}{(\mathbf{y}^{(k-1)})^T \mathbf{y}^{(k-1)}} (\mathbf{y}^{(k-1)})^T$$

再利用引理 2.2 的结果, 我们可以推出 $\mathbf{A}^{(k)}$ 的逆与 $\mathbf{A}^{(k-1)}$ 的逆之间满足关系

$$\left(\mathbf{A}^{(k)}\right)^{-1} - \left(\mathbf{A}^{(k-1)}\right)^{-1} = - \frac{\left[\left(\mathbf{A}^{(k-1)}\right)^{-1} \mathbf{g}^{(k-1)} - \mathbf{y}^{(k-1)}\right] (\mathbf{y}^{(k-1)})^T \left(\mathbf{A}^{(k-1)}\right)^{-1}}{(\mathbf{y}^{(k-1)})^T \left(\mathbf{A}^{(k-1)}\right)^{-1} \mathbf{g}^{(k-1)}}$$

显然, 利用此公式由 $(\mathbf{A}^{(k-1)})^{-1}$ 计算 $(\mathbf{A}^{(k)})^{-1}$ 只需要作矩阵和向量的乘法。

Broyden 拟牛顿法和割线法类似, 在 Newton 法收敛性条件下, 如果初始拟牛顿矩阵是 Jacobi 矩阵一个良好的近似, 即满足 $\|\mathbf{H}_0 - \nabla \mathbf{F}(\mathbf{x}^*)\| \leq \epsilon$, 则 Broyden 算法具有超线性收敛。具体证明可以参考 “Some convergence properties of Broyden’s method”, SIAM Numer. Anal. 1977.

例题 2.8 用 Broyden 方法求解如下方程:

$$\begin{aligned} x^2 &= y - x \cos(\pi x), \\ yx + e^{-y} &= x^{-1}. \end{aligned}$$

解 在初始化阶段, 我们第一步直接使用了 Jacobi 矩阵作为初始化, 接下来就按照 Broyden 算法进行迭代。该方程组有真解 $x = 1, y = 0$, 我们所设定的初值为 $x_0, y_0 = (2, -1)$ 。与之对比的其他算法的超参设置见例题 2.7。对比结果见图 2.9。




图 2.9: 求解非线性方程组. 其中黑色的点是 Newton 法的结果, 红色的是 Levenberg-Marquardt 法的结果, 黄色的是 Broyden 算法的结果。

2.3 知识拓展

我们会发现许多的算法对于初值的要求都很高, 为了得到对初值依赖性比较弱的算法, 我们介绍如下的同伦法。同伦法的基本思路是引入一族函数 $H(x, \lambda) = \lambda F(x) + (1 - \lambda)G(x)$, 其中 G 是非常简单的函数例如 $G(x) = x$ 。将 λ 从 0 变化到 1, 并计算一系列的问题。对每一个子问题都用 Newton 法求解, 上一个子问题的解作为当前步的初始猜测, 这就是同伦-Newton 法。同伦法的数值计算是比较有效的, 但是理论分析比较复杂, 例如会有拓扑上的问题, 同伦曲线的分叉等涉及到多解的问题。即使同伦曲线性质很好, Newton 法的收敛性证明也比较困难。

我们这一章主要的方法都是求解单独一个解的情况, 但是如果希望一次性求解出多个解, 往往需要更多的方法。在一维的情况, 高阶多项式求根可以通过转化成恰当的矩阵特征值求解问题, 并调用如 QR 分解等方法高精度求解特征值的算法进行解决, 这也是许多科学计算软件中求根的方法。一般的非线性函数可以利用多项式逼近, 并求出多项式的根来近似。但是超过一维的问题, 情况变得非常复杂, 这里有许多未知的问题等待同学们进一步的探索。

第 2 章 练习

1. 试证: 对任意初值 x_0 , 由迭代公式

$$x_{n+1} = \cos x_n, \quad n = 0, 1, 2, \dots$$

所生成的序列 $\{x_n\}$ 都收敛于方程 $x = \cos x$ 的解。

2. 证明: 由 $G(x) = \ln(1 + e^x)$ 定义的函数 $G: \mathbb{R} \rightarrow \mathbb{R}$, 在任何闭区间 $[a, b]$ 上是压缩映像, 但没有不动点

3. 使用 Newton 迭代法求解非线性方程 $f(x) = 0$ 时要求在每个迭代步计算 $f(x)$ 的导数. 假如用常数 d 代替真实的导数值, 可以得到下面的迭代格式:

$$x_{k+1} = x_k - f(x_k)/d, \quad k = 0, 1, 2, \dots$$

- (1) 当 d 满足怎样的条件时, 上面的格式是局部收敛的?
- (2) 一般情况下, 上面的格式收敛速度如何?
- (3) 是否存在某个常数 d 使得上面的格式仍是二阶收敛的?

4. 设 $f(x)$ 充分光滑, x^* 是 $f(x)$ 的 m 重根, $m \geq 2$

- (1) 证明 Newton 迭代法是一阶局部收敛的;
- (2) 记 $g(x) = \frac{f(x)}{f'(x)}$, 证明对 $g(x)$ 的 Newton 迭代法至少二阶局部收敛于 x^* ;
- (3) 如果事先知道根的重数 $m(m \geq 2)$, 则迭代法

$$x_{k+1} = x_k - m \frac{f(x_k)}{f'(x_k)}, \quad k = 0, 1, 2, \dots$$

至少具有二阶局部收敛性.

5. 设 $f: \mathbb{R} \rightarrow \mathbb{R}$ 定义为 $f(x) = x^2 + x - 1$. 若同伦函数取

$$H(x, t) = tf(x) + (1-t)(x - x_0), \quad x_0 = 1$$

求方程 $H(x, t) = 0$ 的解曲线 $x = x(t)$, 作出它的图形, 并解释你的结果.

6. 假设 n 次实系数多项式 $P_n(x)$ 只有实根, 并记最大的实根为 x^* . 证明: $\forall$ 初始猜测 $x_0 > x^*$, Newton 法都收敛到 x^* .
7. 设序列 $x_\nu \in \mathbb{R}$ 收敛到 $x, x \neq x_\nu, \forall \nu \in \mathbb{N}$, 且序列 x_ν 满足

$$x_{\nu+1} - x = (q + \xi_\nu)(x_\nu - x), \quad \nu = 0, 1, \dots$$

其中 $|q| < 1, \xi_\nu \rightarrow 0, \nu \rightarrow \infty$. 证明: 对充分大的 ν ,

$$y_\nu = x_\nu - \frac{(x_{\nu+1} - x_\nu)^2}{x_{\nu+2} - 2x_{\nu+1} + x_\nu}$$

是良定义的, 并且

$$\lim_{\nu \rightarrow \infty} \frac{y_\nu - x}{x_\nu - x} = 0$$

i.e., 由 x_ν 产生的序列 y_ν 的收敛速度更快. (该方法被称为 Aitken 加速)

8. 设 $D \in \mathbb{R}$ 为一开集, $f: D \rightarrow \mathbb{R}, f \in C^2(D), x$ 是 $f(x)$ 的不动点. 证明 Steffensen 加速

$$x_{\nu+1} := x_\nu - \frac{[f(x_\nu) - x_\nu]^2}{f[f(x_\nu)] - 2f(x_\nu) + x_\nu}, \quad \nu = 0, 1, \dots$$

在 x 的某个邻域内是二次收敛到 x 的

9. 证明对方程

$$f(x) := \frac{\ln 2}{\pi} \sin \left(2\pi \frac{\ln x}{\ln 2} \right) + 1$$

使用 Newton 法时, 取初始猜测 $x_0 = 1$ 时可以收敛, 但不收敛到 $f(x)$ 的零点.

10. 求解特征值问题 $Ax = \lambda x$ 等价于求方程 $f(z)$ 的零点

$$f : \begin{pmatrix} x \\ \lambda \end{pmatrix} \mapsto \begin{pmatrix} Ax - \lambda x \\ xx^T - 1 \end{pmatrix}$$

推导该问题对应的 Newton 迭代格式

11. (编程实现) 求非线性方程 $\cos x + 1/(1 + e^{-2x}) = 0$ 的最小正根. 取初值 $x_0 = 3$, 分别考查下面的迭代格式:
- (1) $x_{k+1} = \arccos(-1/(1 + e^{-2x_k})), k = 0, 1, 2, \dots;$
 - (2) $x_{k+1} = 0.5 \ln(-1/(1 + 1/\cos x_k));$
 - (3) Newton 迭代法.

第3章 多项式插值

给定一个具体函数 f , 同时给定坐标 x , 我们可以通过将 x 带入函数 f 来求解在该点的函数值 $f(x)$. 那么现在将这个问题反过来, 如果我们只有函数在已知点 x 的值 $f(x)$, 那么我们能否将原函数 f 恢复或者近似恢复出来? 在实际中我们会遇到这样的问题, 已知定义在区间 $[a, b]$ 上的非线性一元函数 $f(x)$ 在若干点处的函数值, 需要我们求一个简单函数来近似函数 $f(x)$, 同时要求这个近似函数在给定函数值的点处和 $f(x)$ 的值精确相等。为了解决这个问题, 多项式插值就是一种经典的近似手段, 即用 (分片) 多项式函数去逼近一般的非线性函数。

这里我们使用多项式函数去做近似的原因主要有两个。一个是多项式函数的计算十分简单, 只需要有限次加, 减, 乘运算即可得出函数值, 这一点在计算机底层实现中尤其重要, 因为一般芯片的数学计算指令只会有加乘运算, 而不具备如三角函数等其他函数运算的功能。另外一个原因就是多项式函数与其他非线性函数关系十分密切, Weierstrass 第一逼近定理告诉我们任意连续函数都可以用多项式进行近似, 近似的误差可以任意小。

如何构造这样的近似多项式, 第一个选择来自于 Taylor 多项式展开。在微积分中我们知道当 $f(x)$ 在 $[a, b]$ 中的某一点 x_0 附近的各阶导数存在时, 在 x_0 的充分小邻域中, 可以构造 Taylor 展开多项式

$$p_n(x) = \sum_{k=0}^n \frac{f^{(k)}(x_0)}{k!} (x - x_0)^k \quad (3.1)$$

很好地逼近 $f(x)$ 。但是, Taylor 展开需要计算 $f(x)$ 在 x_0 处的各阶导数, 并且相对于插值多项式要求插值点的数据精确相等, Taylor 多项式只能在靠近 x_0 处保证精度, 不一定能在区间 $[a, b]$ 上保持相对精确的逼近结果。

在实践中, 函数值的获取要相对简单, 导数, 乃至高阶导数值的获取通常要昂贵的多, 甚至是不可能精确获得, 因此我们更加关注只利用函数值的方法。在本章中, 我们将介绍通过插值进行多项式近似的基本原理。

3.1 Lagrange 插值

这里我们首先给出 Lagrange 插值多项式的定义。

定义 3.1

设 $y = f(x)$ 是定义在区间 $[a, b]$ 上的函数, 给定 $n+1$ 个不同的点 $\{x_0, \dots, x_n\} \subset [a, b]$, 以及这些点处 $f(x)$ 的函数值为:

$$y_i = f(x_i), i = 0, 1, 2, \dots, n. \quad (3.2)$$

在区间 $[a, b]$ 上求一个多项式 $p(x)$ 使得

$$p(x_i) = y_i, i = 0, 1, 2, \dots, n \quad (3.3)$$

则 $p(x)$ 就称为 $f(x)$ 的插值多项式。



下面我们证明, 在特定条件下, 上述的插值多项式满足存在且唯一性。

定理 3.1

在上述定义的条件, 必存在唯一的次数不超过 n 的多项式 $P_n(x)$ 满足条件 (3.3)。



证明 用待定系数法, 记插值多项式

$$p_n(x) = a_n x^n + a_{n-1} x^{n-1} + \cdots + a_0. \quad (3.4)$$

由条件 (3.3), 我们知道 $p(x_i) = y_i, i = 0, 1, \dots, n$. 因此我们可以得到一个关于 $a_n, a_{n-1}, \dots, a_0$ 的 n 阶线性代数方程组:

$$\begin{pmatrix} 1 & x_0 & \cdots & x_0^n \\ 1 & x_1 & \cdots & x_1^n \\ \vdots & \vdots & & \vdots \\ 1 & x_n & \cdots & x_n^n \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{pmatrix} = \begin{pmatrix} y_0 \\ y_1 \\ \vdots \\ y_n \end{pmatrix}. \quad (3.5)$$

该线性方程组的系数矩阵为一个 $n+1$ 阶 Vandermonde 矩阵, 通过计算它的行列式可以得到:

$$\begin{vmatrix} 1 & x_0 & \cdots & x_0^n \\ 1 & x_1 & \cdots & x_1^n \\ \vdots & \vdots & & \vdots \\ 1 & x_n & \cdots & x_n^n \end{vmatrix} = \prod_{i>j} (x_i - x_j) \equiv \prod_{j=0}^{n-1} \left[\prod_{i=j+1}^n (x_i - x_j) \right]. \quad (3.6)$$

由于 x_i 是互不相同的点, 因此系数矩阵的行列式不为 0. 所以系数矩阵非奇异, 线性方程组 (3.5) 的解 $a_n, a_{n-1}, \dots, a_0$ 是存在且唯一的。

尽管我们可以通过求解 (3.5) 得到插值多项式的解 $a_0, a_1, \dots, a_n$, 但是这种方法并不可靠。下面我们给出一个具体的例子来说明这种不可靠性。

例题 3.1 在定义 3.1 中考虑均匀格点的情况, 不妨设待近似的区间为 $[0, 1]$, 则 $x_i = \frac{i}{n}, i = 0, 1, 2, \dots, n$, 其对应点处函数值记为 $y_0, y_1, \dots, y_n$ 。我们不妨假设目标函数 $f(x) = x^9 + x^5 + x$ 。我们下面说明用待定系数法计算 Vandermonde 行列式的方法不适用于求解 Lagrange 插值函数。

解 回到线性方程组 (3.5) 中, 我们可以将 $x_0, x_1, \dots, x_n$ 的值带入从而得到 Vandermonde 矩阵的表达式。为了度量矩阵求逆的稳定性, 条件数是常见的工具, 然而更为准确的描述是矩阵的奇异值, 关于奇异值更加具体的内容可以见参考文献 [6]。当矩阵的最小奇异值非常接近于 0 时, 意味着右端项微小的扰动会被放大, 放大的倍数约为最小奇异值的倒数。我们可以计算出最小奇异值的大小情况见表 3.1。同时在图 3.1 中, 我们将在不同 n 的情况下, 相应的 Vandermonde 矩阵的奇异值分布图表示出来。

我们可以发现随着插值点数目 n 的增加, 最小奇异值呈指数衰减, 从而可能会导致数值结果的不稳定。我们以 $n = 20$ 为例, 理论上来说插值函数应该和被插值函数完全一样。但是通过 Vandermonde 矩阵求逆后, 我们发现得到的插值多项式如表 3.2。

n	最小奇异值	MSE
5	$4.351e-03$	$6.855e-04$
10	$2.971e-07$	$1.522e-31$
20	$5.699e-16$	$5.292e-27$
30	$3.144e-16$	$1.756e-21$
40	$3.401e-16$	$6.346e-16$
50	$1.692e-16$	$3.368e-10$
60	$1.591e-16$	$1.767e-04$

表 3.1: 随着均匀插值点数量 n 的变化, 最小奇异值也发生变化.




图 3.1: 在不同均匀插值点数量 n 的情况下, 该均匀插值点集合对应的 Vandermonde 矩阵的奇异值分布图. 横坐标表示奇异值的索引, 纵坐标表示对应的奇异值 (经过对数处理).

插值多项式基底	系数
1	0
x	$+1.000e + 00$
x^2	$+4.155e - 10$
x^3	$-1.177e - 08$
x^4	$+1.947e - 07$
x^5	$+1.000e + 00$
x^6	$+1.651e - 05$
x^7	$-9.445e - 05$
x^8	$+4.095e - 04$
x^9	$+9.986e - 01$
x^{10}	$+3.573e - 03$
x^{11}	$-7.308e - 03$
x^{12}	$+1.172e - 02$
x^{13}	$-1.465e - 02$
x^{14}	$+1.412e - 02$
x^{15}	$-1.027e - 02$
x^{16}	$+5.456e - 03$
x^{17}	$-1.994e - 03$
x^{18}	$+4.478e - 04$
x^{19}	$-4.661e - 05$

表 3.2: 在 $[0, 1]$ 等距选取 $n = 20$ 个插值点, Lagrange 插值得到的插值多项式. 为了合理表示该插值多项式并与原函数 $f(x) = x^9 + x^5 + x$ 对比, 我们选取左边一列标准基作为基函数, 右边一列表示插值多项式在不同基函数下对应的系数. 通过对比可以发现, 插值多项式与原函数 $f(x)$ 并不相同。




图 3.2: 在不同均匀插值点数量 n 的情况下, Mean Squared Error (MSE) 分布图 (log scale). 我们记 $f(x)$ 和 $p_n(x)$ 分别为目标函数和插值多项式, 均方误差 (MSE) 的定义为 $\int_{\mathcal{X}} |f(x) - p_n(x)|^2 dx$. 其中 $\mathcal{X}$ 表示为了计算 MSE 我们所选择的定义域区间. 理论上, 我们希望选取 $\mathcal{X} = [0, 1]$ 作为计算区间. 但是在实际操作中, 由于区间 $[0, 1]$ 中有无穷多个点, 我们通常采用数值方法近似这个积分. 在本例中, 我们选取 $\mathcal{X}$ 为 10000 个在区间 $[0, 1]$ 上的等距节点并进行加权求和 (采用复化梯形公式) 来计算 MSE.

描述插值方法好坏的重要依据是泛化误差, 即非插值节点上函数的近似程度. 我们在 $[0, 1]$ 上均匀选取 10000 个点, 分别计算被插值函数和插值函数的误差, 具体见图 3.2.

从上面的例子中, 我们发现 Vandermonde 矩阵求逆是一个数值上不稳定的求解方法. 事实上 Lagrange 插值本身是一个好的稳定的问题, 造成这种数值不稳定的原因是因为我们选取了单项式这种相关性极强的基底 (关于单项式不是高次多项式的稳定表示, 还有一个非常有名的例子, 即 Wilkinson 多项式的根, 细节可以参考见 [6]). 一个自然的问题是, 有没有可能通过改变多项式空间的基底表达, 找到求解 Lagrange 插值的数值稳定的方法. 为了做到这一点, 我们首先从抽象的角度来理解 Lagrange 插值.

当给定了互不相同的插值节点 $\{x_i\}_{i=0}^n$ 后, 由定理 3.1 知道, Lagrange 插值定义了从欧几里得空间 $\mathbb{R}^{n+1}$ 到多项式空间 $\mathbb{P}_n$ 的一个双射, 从定理的证明中进一步不难看出, 这个映射是线性的 (令这个映射为 $\mathcal{L}$). 欧几里得空间 $\mathbb{R}^{n+1}$ 有一个天然的标准正交基 $\{\mathbf{e}^i\}_{i=0}^n$, 那么在多项式空间 $\mathbb{P}_n$ 中就有一个自然的基底为 $\{l_i(x) = \mathcal{L}\mathbf{e}^i\}_{i=0}^n$, 这组基底被称为 Lagrange 基底.

定义 3.2 (Lagrange 基函数)

我们希望在线性空间 $\mathbb{P}_n$ 中找到一组满足条件

$$l_i(x_j) = \delta_{ij} = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}$$

的基函数 $\{l_i(x)\}_{i=0}^n$. 通过简单的计算可以得到, $l_i(x)$ 的表达式为:

$$l_i(x) = \frac{\prod_{j \neq i} (x - x_j)}{\prod_{j \neq i} (x_i - x_j)}. \quad (3.7)$$

直接计算就可以验证 $\{l_i(x)\}_{i=0}^n$ 满足上述条件。



有了基函数, n 次插值多项式 $P_n(x)$ 就可以表示为:

$$P_n(x) = \sum_{i=0}^n y_i \cdot l_i(x). \quad (3.8)$$

该式也被称作 Lagrange 插值, 可以验证 Lagrange 插值满足条件 (3.3). 这里我们想要强调的是, 基函数并不唯一, 但是 n 次插值多项式 $P_n(x)$ 是唯一的. 同时, Lagrange 插值有如下的误差估计:

定理 3.2

给定 $n+1$ 个不同的点 $x_0, \dots, x_n \in [a, b]$, 令 $f(x) \in C^{n+1}[a, b]$, $p_n(x)$ 为其 n 次插值多项式。则对任意 $x \in [a, b]$ 有 $f(x) = p_n(x) + R(x)$, 其中余项为:

$$R(x) = \frac{f^{(n+1)}(\eta)}{(n+1)!} \prod_{i=0}^n (x - x_i). \quad (3.9)$$

其中 η 位于包含 $x_0, x_1, \dots, x_n, x$ 的最小闭区间的内部。



证明 首先, 当 $x = x_i$ 时, $R(x_i) = 0$, 所以可设

$$R(x) = u(x) \prod_{i=0}^n (x - x_i), \quad (3.10)$$

下面只需要确定 $u(x)$ 的表达式, 考察辅助函数:

$$\psi(t) = R(t) - u(x) \prod_{i=0}^n (t - x_i) \quad (3.11)$$

$$= f(t) - p_n(t) - u(x) \prod_{i=0}^n (t - x_i), t \in [a, b]. \quad (3.12)$$

由定理条件可知 $\psi^{(n+1)}(t)$ 在 $[a, b]$ 上存在, 且当 $t = x_0, x_1, \dots, x_n, x$ 时, 有 $\psi(t) = 0$, 于是连续运用 Rolle 定理可得至少在 (a, b) 内存在一点 η 使得

$$\psi^{(n+1)}(\eta) = 0,$$

其中, η 位于包含 $x_0, x_1, \dots, x_n$ 的最小闭区间内, 即

$$f^{(n+1)}(\eta) - u(x)(n+1)! = 0.$$

从而有

$$u(x) = \frac{f^{(n+1)}(\eta)}{(n+1)!}.$$

代入 (3.10), 从而定理得证。

在给定一组插值点时, 构造 Lagrange 基函数是非常自然的, 不过每添加一个插值点, 所有的插值基函数要全部重新计算。事实上, 我们可以使用另外一种基函数, 称为 Newton 基函数, 并用它来表达 Lagrange 插值多项式, 一般的也称这种插值为 Newton 插值 (再次强调 Newton 插值所得到的多项式和 Lagrange 插值多项式完全相同, 只是表达的基底不同)。Newton 插值的基本思想是用归纳, 假设有 $n+1$ 个插值点, 我们构造一组 $\mathbb{P}_n$ 的基函数, 每添加一个插值点

时, 只需要添加一个新的函数构成 $\mathbb{P}_{n+1}$ 的基函数。此时, 基函数最自然的选择就是:

$$\{t_0(x) = 1, t_1(x) = x - x_0, \dots, t_k(x) = \prod_{i=0}^{k-1} (x - x_i), \dots\} \quad (3.13)$$

容易证明 $t_0(x), t_1(x), \dots, t_n(x)$ 线性无关 (因为它们均为首一多项式, 且彼此之间的次数都不同), 因此可以构成 $\mathbb{P}_n$ 的一组基函数。

下面考虑 Newton 插值公式。给定 $n+1$ 个插值点 $\{x_i\}_{i=0}^n$, 不妨设函数 $f(x)$ 的 n 次插值多项式为:

$$p_n(x) = \sum_{i=0}^n C_i \cdot t_i(x) \quad (3.14)$$

将插值条件 $p_n(x_i) = f(x_i), i = 0, 1, \dots, n$ 代入 (3.14), 可以得到一个关于 $\{C_i\}_{i=0}^n$ 的线性方程组:

$$\begin{pmatrix} 1 & 0 & \dots & 0 \\ 1 & x_1 - x_0 & \dots & 0 \\ 1 & x_2 - x_0 & \dots & 0 \\ \vdots & \vdots & & \vdots \\ 1 & x_n - x_0 & \dots & \prod_{i=0}^{n-1} (x_n - x_i) \end{pmatrix} \begin{pmatrix} C_0 \\ C_1 \\ C_2 \\ \vdots \\ C_n \end{pmatrix} = \begin{pmatrix} f(x_0) \\ f(x_1) \\ f(x_2) \\ \vdots \\ f(x_n) \end{pmatrix} \quad (3.15)$$

方程组 (3.15) 的系数矩阵为下三角阵, x_i 互不相同, 系数矩阵非奇异, 所以该方程组有唯一解:

$$\begin{cases} C_0 = f(x_0), \\ C_1 = \frac{f(x_1) - f(x_0)}{x_1 - x_0}, \\ C_2 = \left(\frac{f(x_2) - f(x_0)}{x_2 - x_0} - \frac{f(x_1) - f(x_0)}{x_1 - x_0} \right) / (x_2 - x_1), \\ \dots, \end{cases} \quad (3.16)$$

为了更加清楚的描述 Newton 插值下面我们引入差商来表示解 $C_0, C_1, \dots, C_n$.

定义 3.3 (差商)

$f[x_0] = C_0 = f(x_0)$, 称为 $f(x)$ 在 $x = x_0$ 处的零阶差商;

$f[x_0, x_1] = C_1 = \frac{f(x_1) - f(x_0)}{x_1 - x_0}$, 称为 $f(x)$ 在 $x = x_0, x_1$ 处的一阶差商;

$f[x_0, x_1, x_2] = C_2 = \frac{f[x_0, x_2] - f[x_0, x_1]}{x_2 - x_1}$, 称为 $f(x)$ 在 $x = x_0, x_1, x_2$ 处的二阶差商;

.....

$f[x_0, x_1, \dots, x_n] = \frac{f[x_0, \dots, x_{n-2}, x_n] - f[x_0, \dots, x_{n-1}]}{x_n - x_{n-1}}$, 称为 $f(x)$ 在 $x = x_0, x_1, \dots, x_n$ 处的 n 阶差商.



则我们有如下定理

定理 3.3

Newton 插值公式 (3.14) 的解可以被表示为:

$$p_n(x) = \sum_{i=0}^n f[x_0, \dots, x_i] \cdot t_i(x). \quad (3.17)$$



证明 我们使用归纳法证明该结论。首先对于 $n = 1, 2, 3$ 时, 直接计算可以得到结论成立。对于一般的 n , 由下三角方程组得到

$$\begin{aligned} C_n &= \frac{f(x_n) - f(x_0) - \cdots - \prod_{i=0}^{n-2} (x_n - x_i) C_{n-1}}{\prod_{i=0}^{n-1} (x_n - x_i)} \\ &= \frac{\frac{f(x_n) - f(x_0) - \cdots - \prod_{i=0}^{n-3} (x_n - x_i) C_{n-2}}{\prod_{i=0}^{n-2} (x_n - x_i)} - C_{n-1}}{x_n - x_{n-1}}. \end{aligned}$$

注意到采用 $x_0, \dots, x_{n-2}, x_n$ 这 n 个点进行 Newton 插值时, 首项系数即为 $\frac{f(x_n) - f(x_0) - \cdots - \prod_{i=0}^{n-3} (x_n - x_i) C_{n-2}}{\prod_{i=0}^{n-2} (x_n - x_i)}$, 于是由归纳法和差商的定义立刻得到 $f[x_0, \dots, x_n] = C_n$ 。

同时差商有如下的性质:

性质 3.1 函数 $f(x)$ 在互异的 $n+1$ 个点 $\{x_i\}_{i=0}^n$ 上的 n 阶差商可由函数值 $\{f(x_i)\}_{i=0}^n$ 线性表出:

$$f[x_0, \dots, x_n] = \sum_{j=0}^n \frac{f(x_j)}{\prod_{i \neq j} (x_j - x_i)}.$$

证明 因为 n 阶 Lagrange 插值多项式是唯一的, 因此我们比较 Lagrange 插值公式和 Newton 插值公式, 即可得解。由 Lagrange 插值公式有:

$$p_n(x) = \sum_{i=0}^n l_i(x) f(x_i) = \sum_{j=0}^n \frac{f(x_j)}{\prod_{i \neq j} (x_j - x_i)} \prod_{i \neq j} (x - x_i).$$

另一方面, 在这 $n+1$ 个点处 Newton 插值多项式为:

$$p_n(x) = \sum_{i=0}^n f[x_0, \dots, x_i] N_i(x),$$

由插值多项式的唯一性, 比较两式 x^k 的系数即得:

$$f[x_0, \dots, x_n] = \sum_{j=0}^n \frac{f(x_j)}{\prod_{i \neq j} (x_j - x_i)}. \quad (3.18)$$

性质 3.2 函数 $f(x)$ 在互异的 $n+1$ 个点 $\{x_i\}_{i=0}^n$ 上的 n 阶差商对节点的排列次序无关, 具有对称性, 即

$$f[x_0, \dots, x_n] = f[\tilde{x}_0, \dots, \tilde{x}_n],$$

其中 $\{\tilde{x}_0, \dots, \tilde{x}_n\}$ 是 $\{x_0, \dots, x_n\}$ 的一个重排。

证明 根据性质 3.1 中 $f[x_0, \dots, x_n]$ 的线性表达式, 重新排列节点后的 $f[\tilde{x}_0, \dots, \tilde{x}_n]$ 仍可以用 $f(x)$ 的函数值线性表出, 只是累加项的次序发生了改变, 其值不变, 故:

$$f[x_0, \dots, x_n] = f[\tilde{x}_0, \dots, \tilde{x}_n].$$

该结论也可以由性质 3.1 立刻得出。

性质 3.3 Newton 插值余项为 $f(x) - p_n(x) \triangleq R(x) = \omega_{n+1}(x) f[x_0, \dots, x_n, x]$, $\omega_{n+1}(x) = \prod_{i=0}^n (x - x_i)$ 。

证明 将 x 看作第 $n+2$ 个插值点 x_{n+1} , 考虑:

$$f(x_{n+1}) - p_n(x_{n+1}) = \omega_{n+1}(x_{n+1}) f[x_0, \dots, x_n, x_{n+1}], \quad (3.19)$$

$n+1$ 阶插值函数为：

$$p_{n+1}(x) = \sum_{i=0}^{n+1} f[x_0, \dots, x_i] \cdot h_i \quad (3.20)$$

$$= p_n(x) + f[x_0, \dots, x_{n+1}] \prod_{i=0}^n (x - x_i) \quad (3.21)$$

$$= p_n(x) + f[x_0, \dots, x_{n+1}] \omega_{n+1}(x) \quad (3.22)$$

将 x_{n+1} 代入上式, 有:

$$p_{n+1}(x_{n+1}) = p_n(x_{n+1}) + f[x_0, \dots, x_{n+1}] \omega_{n+1}(x_{n+1}) \quad (3.23)$$

又因为 $p_{n+1}(x) = f(x_{n+1})$, 从而得到 (3.19), 又因为 x_{n+1} 是任意的, 得到余项估计。

事实上, 通过差商的方法构造出 Newton 插值的表达式, 能够更加准确的分析插值误差, 从而对数值计算中的现象做出更加准确的解释。有些比较简单的函数, 我们可以精确计算出其高阶差商的表达式。

例题 3.2 $f(x) = \frac{1}{x+C}$, 计算 $f(x)$ 的 n 阶差商 $[x_0, x_1, \dots, x_n]$.

解

$$f[x_0] = \frac{1}{x_0 + C} \quad (3.24)$$

$$f[x_0, x_1] = \frac{f(x_1) - f(x_0)}{x_1 - x_0} = \frac{-1}{(x_0 + C)(x_1 + C)} \quad (3.25)$$

$$f[x_0, x_1, x_2] = \frac{1}{(x_0 + C)(x_1 + C)(x_2 + C)} \quad (3.26)$$

由归纳法, 可得:

$$f[x_0, x_1, \dots, x_n] = (-1)^n \frac{1}{\prod_{i=0}^n (x_i + C)}. \quad (3.27)$$

下面我们考虑 Lagrange 基底插值、Newton 插值的计算复杂度, 不失一般性讨论 $n+1$ 个插值节点的情况。首先是 Lagrange 基底插值的计算复杂性: 对每个 $l_i(x) = \frac{\prod_{j \neq i} (x - x_j)}{\prod_{j \neq i} (x_i - x_j)}$, 其复杂度为 $O(n)$, 所以计算每一个 $p_n(x)$ 的复杂度是 $O(n^2)$ 。下面考虑 Newton 插值的计算复杂性: 首先得到系数矩阵的复杂性为 $O(n^2)$, 后带求解也是 $O(n^2)$, 得到系数后, 计算每一个 $p_n(x)$ 的复杂度是 $O(n)$, 并且添加一个点后求解系数的复杂度增加 $O(n)$ 。于是面临计算 N 个点上的函数值时 ($N \geq n$), Lagrange 基底插值的复杂性为 $O(n^2 N)$, 而 Newton 插值的计算复杂性为 $O(n^2 + nN)$ 。从计算复杂性来看, 好像 Newton 插值是一个不错的方法, 但是如果仅仅看计算复杂性的话, 求解 Vandermonde 矩阵的方法好像也不算很差, 特别是 $N \geq n^2$ 时, 因为在已知多项式系数的前提下利用秦九韶算法的复杂度为 $O(n)$, 这样加上求解线性方程组其总体复杂度为 $O(n^3 + nN)$ 。但是因为求解 Vandermonde 矩阵的不稳定性导致该方法并不实用。

而我们现在 Newton 插值的求解中, 也需要求解下三角方程组, 只要需要求解方程组, 我们就需要关心其数值稳定性。类似分析 Vandermonde 矩阵的性质, 我们仍然考虑 $\{x_i\}_{i=0}^n$ 为 $[0, 1]$ 区间上的等距节点, Newton 插值中产生的下三角矩阵的最小奇异值随着插值点数的增加迅速衰减到 0, 具体见图 3.3(由图可见呈指数衰减)。这个事实告诉我们虽然 Newton 插值看起来是一个有效的算法, 但是其实它并不是数值稳定的。




图 3.3: Newton 插值方法在不同均匀插值点数量 n 的情况下, 对应下三角矩阵最小奇异值分布图 (log scale).

在实践中我们希望能够找到一个计算公式, 具有良好的数值稳定性, 同时计算复杂度希望和 Newton 插值类似。而我们仔细观察 Lagrange 基底插值公式时, 会发现通过合理的安排计算顺序和存储一些中间数值, 有很多重复计算可以省略, 从而达到减少计算量的效果, 下面我们介绍重心公式, 这是计算 Lagrange 插值的有效且数值稳定的方法。首先令

$$\omega_{n+1}(x) = \prod_{i=0}^n (x - x_i), \quad (3.28)$$

于是 Lagrange 基函数可以写成

$$l_j(x) = \omega_{n+1}(x) \frac{\omega_j}{x - x_j}, \quad (3.29)$$

其中 ω_j 为常数:

$$\omega_j = \frac{1}{\prod_{k \neq j} (x_j - x_k)}. \quad (3.30)$$

于是插值多项式可以表示为如下第一类重心公式:

$$p_n(x) = \omega_{n+1}(x) \sum_{j=0}^n \frac{\omega_j}{x - x_j} y_j. \quad (3.31)$$

注意到这种格式, 只需要预先计算并存储 ω_j 就可以 (很多特殊节点有简单的表达式), 于是即使重新加入新点, 计算起来仍然只需要 $O(n)$ 的运算复杂度。在 N 个节点上进行计算时, 总体的计算复杂度为 $O(n^2 + nN)$ 。

我们可以对第一类重心公式进一步变形, 得到另外一个等价的第二类重心公式 (该公式可以看出什么叫做重心公式), 这是实际中用的更多的方法。注意到

$$1 = \sum l_j(x) = \omega_{n+1}(x) \sum \frac{\omega_j}{x - x_j}, \quad (3.32)$$

于是

$$p_n(x) = \frac{\sum_{j=0}^n \frac{\omega_j}{x - x_j} y_j}{\sum_{j=0}^n \frac{\omega_j}{x - x_j}}. \quad (3.33)$$

事实上这种算法不仅有对称性, 还有数值稳定性, 即使当 $x \rightarrow x_j$ 时, 分子分母同时都很大, 这也会抵消不稳定性。

例题 3.3 前面我们已经讨论了多项式插值的唯一性，同时给出了几组基函数用于构造插值多项式。这里我们主要从算法实现的角度，讨论如何高效快速地构造插值多项式。我们假设目标函数 $f(x) = \sin(x)$ ，在 $x \in [0, 1]$ 区间范围内做提取 N 个等距节点。在不同插值节点 $N = \{10, 20, 30, 40, 50, 60\}$ 的条件下，我们比较用 Lagrange 基底和第二类重心公式分别实现多项式插值所对应的泛化误差和时间消耗。其中泛化误差指的是插值多项式 $P(x)$ 在定义域 $[0, 1]$ 区间范围内与目标函数 $f(x)$ 的距离，我们采取 Mean Squared Error 作为该距离度量 $\int_{x=0}^1 (P(x) - f(x))^2 dx$ 。我们在定义域 $[0, 1]$ 区间范围内等距挑选 10^3 个点，通过求这 10^3 个点的 MSE 均值来近似这个积分，从而计算得到对应的泛化误差。

解 我们将对应的结果总结在下表中，该表格可以展示使用重心公式插值的优点在于较低的时间复杂度。可以看出当插值节点 $N > 20$ 后，重心公式方法所消耗的时间都小于 Lagrange 方法。值得注意的是，为了方便，我们使用了 $[0, 1]$ 区间范围内 10^3 个点来计算 MSE。如果读者希望更精确地计算这个 MSE，可以选择更多节点来近似它。那么这个时候两种方法的时间损耗会被进一步拉大，从而使得重心公式方法的优势更明显。

N	Lagrange		barycentric	
	MSE	Time	MSE	Time
10	$1.459e - 30$	0.041	$4.440e - 31$	0.069
20	$3.491e - 26$	0.162	$2.279e - 25$	0.180
30	$1.889e - 20$	0.363	$6.731e - 21$	0.322
40	$2.208e - 15$	0.674	$7.250e - 16$	0.512
50	$4.115e - 09$	0.985	$2.169e - 09$	0.747
60	$1.510e - 03$	1.495	$2.485e - 02$	1.005

下面我们就上表中的 MSE 项进行简要分析，我们将重心公式对应的插值结果展示在图 3.4 中。可以发现，伴随着插值点 N 的增长，出现了相应的数值不稳定性，即 MSE 会变大。我们将在下一节中仔细讨论这种数值不稳定性。

3.2 等距节点高阶多项式插值的不稳定性

前面的定理 3.2 给出了 Lagrange 余项的误差估计。直观上看，插值节点的数量 n 越多，余项可能越小，从而多项式逼近的越精确。但实际中，随着 n 的增大，我们会得到一个次数很高的多项式 $p_n(x)$ ，这个多项式虽然在很多点处与真实函数 $f(x)$ 严格相等，但从整体上看效果并不一定好。

这一节中我们考虑等距节点中 Lagrange 插值所具有的不稳定性（并补充有非等距插值的部分相关内容），主要从以下两个方面来讲。第一，龙格现象是在一组等距节点上使用高阶多项式进行插值时出现的区间边缘处的震荡问题，在定理 3.4 中我们给出特定 Runge 函数的插值多项式 p_n 的不收敛性；第二，从数值的角度来讲，我们引入 Lebesgue 常数来描述样本点集合所带来的误差放大倍数，从而解释了等距样本点集合的数值不稳定性。此外，我们在最后一小节中介绍了 Chebyshev 点，通过数值实验展示了非等距样本点集合的优势。




图 3.4: 重心公式插值图. 目标函数为 $\sin(x)$, $x \in [0, 1]$, $N = 60$.

3.2.1 龙格现象

经典的魏尔斯特拉斯第一逼近定理(Stone–Weierstrass theorem)表明,对于定义在区间 $[a, b]$ 上的任意连续函数 $f(x)$, 存在一组多项式函数 $\{P_n | n = 0, 1, 2, \dots\}$ (其中 P_n 表示至多 n 阶的多项式), 随着 n 趋于无穷, 能够一致收敛地逼近 $f(x)$, 即 $\lim_{n \rightarrow \infty} (\max_{a \leq x \leq b} |f(x) - P_n(x)|) = 0$ 。考虑到定义3.1和定理3.1, 我们希望用至多 n 阶的多项式 $P_n(x)$ 对函数 $f(x)$ 的 $n+1$ 个等距样本点进行插值。很自然地, 根据魏尔斯特拉斯逼近定理, 人们可能认为使用更多的样本点会导致更加精确的目标函数 $f(x)$ 的重建。然而, 这组特定的多项式函数 $P_n(x)$ (如上一节的 Lagrange 插值函数和 Newton 插值函数) 并不能保证一致收敛的特性; 此外, 该定理仅说明存在一组多项式函数, 而没有提供找到该函数的一般方法。

伴随着 n 的增加, 我们通过插值得到的 $P_n(x)$ 实际上可能偏离 $f(x)$, 从而在区间边缘处存在震荡问题, 我们将该现象称作龙格现象 (Runge's phenomenon)。一个关于龙格现象的算例可以见图3.5, 随着等距样本量 n 的增加, $P_n(x)$ 逐渐偏离 $f(x)$, 并最终在区间边缘产生强烈震荡。




图 3.5: 图中我们令 $x \in [-5, 5]$, 同时对龙格函数 $f(x) = 1/(1+x^2)$ 的等距样本点进行插值。其中绿色曲线表示我们的目标函数, 即龙格函数; 黑色的圆点表示在 $[-5, 5]$ 区间等距取样得到的样本点, 样本点的数量与子图的标题 n 相对应, 在图中我们取 $n = 2, 4, 8, 16, 32, 64$ 。蓝色曲线表示通过多项式插值得到的函数 $P_n(x)$ 。

定理 3.4

定义 Runge 函数 $f(x) = \frac{1}{1+x^2}$, $x \in [-5, 5]$ 。Runge 函数的等距节点插值函数 $P_n(x)$ 在区间 $[-r, r]$ 外不收敛到 $f(x)$, 其中 $r \approx 3.63$ 。



证明 首先我们需要先计算余项 $R_n(x) = f(x) - P_n(x)$, 根据性质3.1我们知道

$$R_n(x) = \omega_{n+1}(x)f[x_0, \dots, x_n, x],$$

其中 $\omega_{n+1}(x) = \prod_{i=0}^n (x - x_i)$. 同时由例题3.2我们可知当 $f(x) = \frac{1}{x+C}$, 我们有

$$f[x_0, x_1, \dots, x_n] = (-1)^n \frac{1}{\prod_{j=0}^n (x_j + C)}.$$

而现在的 $f(x) = \frac{1}{1+x^2}$, 根据 $\frac{1}{x^2+1} = \frac{1}{2i} \left(\frac{1}{x-i} - \frac{1}{x+i} \right)$ 以及差商运算的线性性, 我们可以得到:

$$f[x_0, \dots, x_n, x] = \frac{(-1)^{n+1}}{2i} \left[\frac{1}{\prod_{j=0}^n (x_j - i)(x - i)} - \frac{1}{\prod_{j=0}^n (x_j + i)(x + i)} \right] \quad (3.34)$$

当 $n = 2r$ 时, $x_j = -x_{n-j}$, 则

$$\frac{1}{\prod_{j=0}^n (x_j - i)(x - i)} = \frac{(-1)^r i}{\prod_{j=0}^r (x_j - i)(x_j + i)(x - i)} \quad (3.35)$$

此时,

$$f[x_0, \dots, x_n, x] = \frac{(-1)^{r+1}}{\prod_{j=0}^r (x_j^2 + 1)} \cdot \frac{x}{x^2 + 1}. \quad (3.36)$$

同理我们可以得到 $n = 2r + 1$ 的情况, 总结下来可以得到

$$f[x_0, \dots, x_n, x] = (-1)^{r+1} f(x) \cdot \frac{1}{\prod_{j=0}^r (x_j^2 + 1)} \cdot \begin{cases} 1, & n = 2r + 1, \\ x, & n = 2r. \end{cases} \quad (3.37)$$

另外

$$w_{n+1}(x) = \prod_{j=0}^n (x - x_j) = \prod_{j=0}^r (x^2 - x_j^2) \cdot \begin{cases} 1, & n = 2r + 1, \\ 1/x, & n = 2r. \end{cases} \quad (3.38)$$

于是 $R_n(x) = (-1)^{r+1} f(x) \cdot g_n(x)$, 其中 $g_n(x) = \prod_{j=0}^r \frac{x^2 - x_j^2}{1 + x_j^2}$. 现在我们只需要考虑 $g_n(x)$ 在 $[0, 5]$ 上的收敛性即可, 我们可以对 $g_n(x)$ 取对数然后乘以等距节点间距 h , 即得到

$$h \ln |g_n(x)| = \sum_{j=0}^r \ln \left| \frac{x^2 - x_j^2}{1 + x_j^2} \right| h, \quad (3.39)$$

固定 x 后我们取极限令 $h \rightarrow 0$ 得到 $q(x) = \int_0^5 \ln |x^2 - \xi^2| - \ln(1 + \xi^2) d\xi$. 估计此积分

$$q(x) = \int_0^x \ln(x - \xi) d\xi + \int_x^5 \ln(\xi - x) d\xi + \int_0^5 (\ln(x + \xi) - \ln(1 + \xi^2)) d\xi \quad (3.40)$$

$$= (5 + x) \ln(5 + x) + (5 - x) \ln(5 - x) - 5 \ln 26 - 2 \arctan 5. \quad (3.41)$$

于是可以计算出此函数仅有一个零点, 且在零点左边为负, 右边为正, 并近似计算出零点约为 3.63. 即当 $r > 3.63$, 余项发散. 故而得到结论。

3.2.2 数值不稳定性

龙格现象说明了当函数的性态不够好 (即使无穷次光滑也不行), 等距节点的高次多项式插值在边界附近会产生剧烈的震荡从而导致误差急剧增长, 但是这并不是故事的全部。我们可以看下面这个例子, 令被插值函数 $g(x) = \sin x$, 于是按照 Lagrange 余项的误差估计我们立

刻得到理论上有 $|R_n| \leq 1/(n+1)!$ ，看起来应该随着插值次数的增加，插值多项式应该越来越接近真实的被插值函数。但是在数值实验中我们会发现当插值多项式的次数比较高时，误差会变得非常大。具体如下表格，

n	MSE
10	$4.440e-31$
20	$2.279e-25$
30	$6.731e-21$
40	$7.250e-16$
50	$2.169e-09$
60	$2.485e-02$

这里的 MSE 估计方法和例题 3.3 中的一致，即等距选择 1000 个点，计算这些点的平均误差。这里数值不稳定的原因来自于舍入误差的影响，即按照插值的要求 $P_n(x_i) = y_i$ ，但是计算机上舍入误差带来的结果是 $P_n(x_i) = y_i + \epsilon_i$ ，这里 ϵ_i 可以被机器精度 (10^{-16}) 控制住。具体的插值图如图 3.4 所示。

为了分析算法的稳定性，特别的解释上述插值方法的数值不稳定性，我们需要引入 Lebesgue 常数的概念：

定义 3.4

考虑 X 为 $[a, b]$ 上 $n+1$ 个插值点的集合，定义 Lebesgue 常数 $\Lambda_n(X) = \|\sum_0^n |l_i(x)|\|_{C[a,b]}$ ，其中 $l_i(x)$ 为 Lagrange 插值基函数。



下面这两个定理给出了 Lebesgue 常数的等价定义。

定理 3.5

$\Lambda_n(x) = \sup_{|y_i| \leq 1} \|p_n\|_{C[a,b]}$ ，其中 p_n 为满足插值条件 $p_n(x_i) = y_i$ 的插值多项式。



证明 这里我们不妨新建两个记号：

$$\Lambda_n^{(1)}(X) = \max_{x \in [a,b]} \sum_{i=0}^n |l_i(x)|, \quad (3.42)$$

$$\Lambda_n^{(2)}(X) = \sup_{|y_i| \leq 1} \max_{x \in [a,b]} |p_n(x)|. \quad (3.43)$$

更具体地， $\Lambda_n^{(1)}(X)$ 表示上述定义中的 $\|\sum_0^n |l_i(x)|\|_{C[a,b]}$ ， $\Lambda_n^{(2)}(X)$ 是将本定理中的 $\sup_{|y_i| \leq 1} \|p_n\|_{C[a,b]}$ 换了一种写法。由于 $\sum_{i=0}^n |l_i(x)|$ 为连续函数， $\exists c \in [a, b]$ ，

$$\text{s.t. } \max_{x \in [a,b]} \sum_{i=0}^n |l_i(x)| = \sum_{i=0}^n |l_i(c)| = \sum_{i=0}^n s_i l_i(c), \text{ 其中 } s_i = \text{sgn } l_i(c). \quad (3.44)$$

回顾式 (3.8)，在给定基函数 $\{l_i(x)\}$ 和观测 $\{y_i\}$ 后，我们可以确定插值多项式 $p_n(x) = \sum y_i l_i(x)$ 。

于是我们取 $y_i = s_i$, 则 $p_n(x) = \sum_{i=0}^n s_i l_i(x)$,

$$\Lambda_n^{(1)}(X) = \sum_{i=0}^n s_i l_i(c) = p_n(c) \leq \max_{x \in [a,b]} |p_n(x)| \leq \Lambda_n^{(2)}(X). \quad (3.45)$$

反过来, $\forall \{y_i\}_{i=0}^n \subseteq [-1, 1]$, 令其产生的插值多项式 $p_n(x)$ 在 $c \in [a, b]$ 上取到最大模。则 $|p_n(c)| = |\sum_{i=0}^n y_i l_i(c)| \leq \sum_{i=0}^n |y_i| |l_i(c)| \leq \sum_{i=0}^n |l_i(c)| \leq \Lambda_n^{(1)}(X)$ 。于是有 $\max_{x \in [a,b]} |p_n(x)| \leq \Lambda_n^{(1)}(X)$, 注意到这一不等式对所有的 $\{y_i\}_{i=0}^n \subseteq [-1, 1]$ 都成立, 于是有 $\Lambda_n^{(2)}(X) \leq \Lambda_n^{(1)}(X)$, 证毕。

定理 3.6

证明 $\sup \frac{\|p_n\|_{C[a,b]}}{\|f\|_{C[a,b]}} = \sup_{|y_i| \leq 1} \|p_n\|_{C[a,b]}$.



证明 显然有 $\text{LHS} = \sup_{\|f\|_{C[a,b]} \leq 1} \|p_n\|_{C[a,b]} \leq \sup_{|y_i| \leq 1} \|p_n\|_{C[a,b]} = \text{RHS}$ 。下面我们只需要证明 $\text{LHS} \geq \text{RHS}$, 我们采用一个构造性的证明, 这里我们提供一种简单的构造 f 的方式。定义一个分段线性函数 f , 使得 $f(a) = f(x_0) = y_0, f(x_1) = y_1, \dots, f(b) = f(x_n) = y_n$, 即函数 f 相邻插值节点之间都是线性函数。例如由点 (x_i, y_i) 和 (x_{i+1}, y_{i+1}) 构成的一条线段即为函数 f 的一个片段。这样我们构造出来的函数 f 满足一个性质, 即函数 f 的极值一定在端点才能取到。那么满足 $\|f\|_{C[a,b]} = \max |y_i| \leq 1$ 。易证 $\text{LHS} \geq \text{RHS}$ 。证毕。

Lebesgue 常数的不同定义下, 描述了不同的性质, 其直观意义都比较明确。在区间 $[a, b]$ 上给定一组插值节点 X 后, 原始定理可以直接用来计算 Lebesgue 常数。在其等价定义 (定理 3.6) 下, Lebesgue 常数描述了多项式插值函数 p_n 与真实函数 f 在范数 $\|\cdot\|_{C[a,b]}$ 意义下的比值上确界, 这样 Lebesgue 常数能够非常自然地描述插值的不稳定性。在定理 3.5 的定义中, Lebesgue 常数可以理解成算子范数的大小。即给定一组插值节点 X 后, 将 Lagrange 插值看成从 $\mathbb{R}^{n+1}$ 到 $\mathbb{P}_n$ 上的线性映射。这个线性映射在 $(\mathbb{R}^{n+1}, \|\cdot\|_\infty)$ 到 $(\mathbb{P}_n, \|\cdot\|_{C[a,b]})$ 这两个范数下的算子范数就是 Lebesgue 常数, 这个定义也描述了误差放大的倍数。

综上, 我们给出了 Lebesgue 常数的三种等价定义, 第三种理解是非常本质的, 而在数值计算中 Lebesgue 常数则描述了误差的放大倍数。下面的定理显示了等距节点是一种非常不稳定的选择。

定理 3.7

令 $X = \{\frac{i}{n} : i = -n, \dots, 0, \dots, n\}$ 。则其对应的 Lebesgue 常数有如下估计: $\Lambda_{2n}(X) \geq \frac{4^{n-2}}{n^2}$ 。



证明 显然 $\Lambda_{2n}(X) = \max_{x \in [-1, 1]} \sum_{i=-n}^n |l_i(x)| \geq |l_0(1 - \frac{1}{2n})|$, 其中

$$l_0(x) = \frac{\prod_{j \neq 0} (x - x_j)}{\prod_{j \neq 0} (x_0 - x_j)}, x_j = \frac{j}{n}, j = -n, \dots, 0, \dots, n \quad (3.46)$$

于是我们有:

$$\begin{aligned} \left| l_0 \left(1 - \frac{1}{2n} \right) \right| &= \left| \frac{\left(1 - \frac{1}{2n} - 1 \right) \left(1 - \frac{1}{2n} - \frac{n-1}{n} \right) \cdots \left(1 - \frac{1}{2n} - \frac{1}{n} \right) \left(1 - \frac{1}{2n} + \frac{1}{n} \right) \cdots \left(1 - \frac{1}{2n} + 1 \right)}{(0-1) \left(0 - \frac{n-1}{n} \right) \cdots \left(0 - \frac{1}{n} \right) \left(0 + \frac{1}{n} \right) \cdots \left(0 + \frac{n-1}{n} \right) (0+1)} \right| \\ &= \frac{(4n-1)!!}{2^{2n}(n!)^2(2n-1)} = \frac{(4n)!}{4^{2n}(2n)!(n!)^2(2n-1)}. \end{aligned} \quad (3.47)$$

由 Stirling 公式: $n! = e^{\theta_n} \sqrt{2n\pi} \left(\frac{n}{e}\right)^n$, 其中 $\theta_n \in \left(\frac{1}{12n+1}, \frac{1}{12n}\right)$ 得到

$$\Lambda_{2n}(X) \geq \frac{1}{e^{5/24n}} \cdot \frac{4^{4n} \left(\frac{n}{e}\right)^{4n} \sqrt{8\pi n}}{4^{2n} 2^{2n} \left(\frac{n}{e}\right)^{4n} 2\pi n \sqrt{2\pi 2n} (2n-1)} \geq \frac{\sqrt{2} 4^n}{e^{5/24} 4\pi n^2} > \frac{4^{n-2}}{n^2} \quad (3.48)$$

证毕。

从上面的估计式可以发现, 当区间等距选取 70 个左右的插值点时, Lebesgue 常数会大到 10^{16} 以上, 从而将机器误差放大到肉眼清晰可见的不同, 这也解释了本节一开始给出的插值图像, 只有当 n 大于 60 以上才有可能看到插值的误差。

3.2.3 Chebyshev 节点的 Lagrange 插值

至此我们可以稍微总结一下等距节点高次多项式插值可能带来的困难: 首先如果函数本身的性态不够好, 其多项式插值经常会带来 Runge 现象; 即使函数本身性态非常好, 但是由于不可避免的浮点误差, 当插值点过多时, Lebesgue 常数将会把浮点误差放大至肉眼可见的地步。为了克服等距节点高次多项式插值所面临的困难, 我们可以由多种不同的解决思路。

- 1 选择非等距节点进行插值
- 2 选择分片低次多项式进行插值
- 3 将插值改为其他近似方法 (如最佳平方逼近等)
- 4 其他策略 (如将多项式空间改为其他函数空间)

本节中我们介绍第一种方式来避免插值的不稳定性, 即选择特定的非等距节点进行插值。在非等距节点的选择中, Chebyshev 节点是最常见和重要的一类, 我们首先给出 Chebyshev 点的基本定义。

定义 3.5

对于任意一个给定的正整数 n , 在区间 $[-1, 1]$ 的第一类 Chebyshev 点为:

$$x_k = \cos \left(\frac{2k+1}{2n+2} \pi \right), \quad k = 0, \dots, n. \quad (3.49)$$

对于任意区间 $[a, b]$, 我们只需要复合一个仿射函数即可得到:

$$x_k = \frac{1}{2}(a+b) + \frac{1}{2}(b-a) \cos \left(\frac{2k+1}{2n+2} \pi \right), \quad k = 0, \dots, n. \quad (3.50)$$

第一类 Chebyshev 节点不包含区间的左右端点, 下面的第二类 Chebyshev 点则包含区间的两个端点:

$$x_k = \cos \left(\frac{k}{n} \pi \right), \quad k = 0, \dots, n. \quad (3.51)$$

类似的, 任意区间上的第二类 Chebyshev 点可以通过复合仿射函数得到:

$$x_k = \frac{1}{2}(a+b) + \frac{1}{2}(b-a) \cos\left(\frac{k}{n}\pi\right), \quad k=0, \dots, n. \quad (3.52)$$



Chebyshev 节点和 Chebyshev 多项式密切相关, n 次 Chebyshev 多项式定义为

$$T_n(x) = \cos n \arccos x, \quad x \in [-1, 1]. \quad (3.53)$$

对于绝对值大于 1 的 x , $T_n(x)$ 按照多项式的表达式进行延拓即可, Chebyshev 多项式和 Chebyshev 点的几个基本性质我们罗列在下面, 更多的性质将在下一章正交多项式部分给出。

命题 3.1

- (1) 公式(3.53)定义了一个 n 次多项式, 并且首项系数为 2^{n-1} 。
- (2) 第一类 Chebyshev 节点是 $T_{n+1}(x)$ 的全部零点, 第二类 Chebyshev 节点是 $T_n(x)$ 在区间 $[-1, 1]$ 中的全部最值点, 同时也是多项式 $T_{n+1}(x) - T_{n-1}(x)$ 的全部零点。



证明 我们首先使用归纳法来证明 (1), 令 $x = \cos t$, 则 $T_n(x) = \cos nt$ 。当 $n=0, 1$ 时结论显然成立, 不妨设 $n \leq k$ 时 (1) 都成立, 则对于 $n=k+1$ 我们利用和差化积公式得到

$$\cos(k+1)t = 2 \cos kt \cos t - \cos(k-1)t \Rightarrow T_{k+1}(x) = 2xT_k(x) - T_{k-1}(x), \quad (3.54)$$

这就证明了性质 (1)。下面来证明性质 (2), 由第一类 Chebyshev 点的定义和 $T_{n+1}(x)$ 的定义立刻得到 $x_i = \cos \frac{2i+1}{2n+2}\pi$ 是 $T_{n+1}(x)$ 的零点, 再由 $n+1$ 次多项式的零点数目不超过 $n+1$ 得到第一类 Chebyshev 节点是 $T_{n+1}(x)$ 的全部零点, 类似的方法可以证明第二类 Chebyshev 节点是多项式 $T_{n+1}(x) - T_{n-1}(x)$ 的全部零点 (利用公式(3.54)即可)。最后我们来证明第二类 Chebyshev 节点是 $T_n(x)$ 在区间 $[-1, 1]$ 中的全部最值点。在区间 $[-1, 1]$ 中, Chebyshev 多项式 $T_n(x) = \cos nt$, 其中 $t = \arccos x \in [0, \pi]$, 则其最大最小值分别为 ± 1 。于是 $nt \in [0, n\pi]$, 利用余弦函数的定义可以知道仅当 $\xi_i = i\pi$ 时, $\cos \xi_i$ 才能取到最大 (小) 值, 这些点所对应的 x 就是第二类 Chebyshev 节点。

在后面的叙述中, 如果没有特定指明, 所有的 Chebyshev 点均默认为区间 $[-1, 1]$ 上的第一类 Chebyshev 点。对于 Chebyshev 节点插值, 我们有如下的逼近定理, 证明因较为复杂超出了本书的范围, 可以参考 [8] 以及其所列的参考文献。

定理 3.8

若 $f \in C[-1, 1]$ 为 s 次可导的函数, 其中第 s 阶的导数可以是分片定义的, 且其 s 阶导数具有有界变差, 变差为 V 。我们有

$$\|f - p_n\|_{C[-1, 1]} \leq \frac{4V}{\pi s(n-s)^s},$$

其中 p_n 为 f 在 Chebyshev 节点上的插值多项式。如果 f 在 $[-1, 1]$ 上实解析, 则存在 $\rho > 1$ 使得

$$\|f - p_n\|_{C[-1, 1]} \leq C\rho^{-n}.$$



我们对该逼近定理进行简单的解释。首先该定理说明只要被插值函数 f 具有非常微弱的光滑性，则在 Chebyshev 节点上进行插值，就可以保证插值多项式 p_n 随着插值点数的增加会一致收敛到目标函数。而且，目标函数的光滑性越好，收敛速度越快，如果目标函数是实解析的，则以几何速度收敛。

该定理保证了理论上（即没有计算误差的情况下），Chebyshev 节点进行插值不会产生 Runge 现象等类似不稳定的情况。为了保证该方法的数值稳定性，还需要考虑在输入有扰动的情形，得到插值函数的误差大小（即对于 Chebyshev 节点的 Legesgue 常数的大小）。我们同样的不加证明给出一个估计式，证明可以参考 [8]。

定理 3.9

对于 $[-1, 1]$ 上 $(n+1)$ 个 Chebyshev 节点构成的点组 X ，我们有 $\Lambda_n(X) \leq \frac{2}{\pi} \log(n+1) + 1$ 。♥

从上述定理我们会发现，随着插值节点的增加，Lebesgue 常数确实会发散到无穷大，但是在合理的计算范围内（如十万阶或者百万阶多项式插值），Chebyshev 节点的 Lebesgue 常数都不会超过 20，这就意味着如果不考虑舍入误差的累计（即仅考虑初始插值点数据的舍入误差这一简化模型），则精度的损失几乎可以忽略。在实践的意义下，Chebyshev 节点进行插值也是数值稳定的。

最后我们还要考虑实际程序操作上，Chebyshev 节点是否具有高效稳定的特点。由前面的章节我们知道，Vandermonde 矩阵求逆（单项式基底）和 Newton 插值方法（Newton 基底）都是数值不稳定的算法，而重心公式通常具有较好的数值稳定性。回顾重心公式如下：插值多项式 $p_n(x)$ 可以表示为

$$p_n(x) = \frac{\sum_{j=0}^n \frac{\omega_j}{x-x_j} y_j}{\sum_{j=0}^n \frac{\omega_j}{x-x_j}},$$

其中仅依赖于插值点的常数

$$\omega_i = \frac{1}{\prod_{j \neq i} (x_i - x_j)}$$

需要预先计算。当 n 非常之大（如 10^6 ）时，计算 ω_i 可能会产生上溢/下溢（超过浮点数能够表示的范围）。通过下面的定理，我们发现在选择 Chebyshev 节点时，是可以通过很简单的归一化方法来避免这种情形发生的。

命题 3.2

对于第一类和第二类 Chebyshev 节点，重心公式中的系数 ω_i 具有如下的解析表达式。

- (1) 令 $x_i = \cos \frac{2i+1}{2n+2}\pi, i = 0, \dots, n$ 为第一类 Chebyshev 节点，则 $\omega_i = (-1)^i \frac{2^n}{n+1} \sin \frac{2i+1}{2n+2}\pi, j = 0, 1, \dots, n$ 。
- (2) 令 $x_i = \cos \frac{i}{n}\pi, i = 0, \dots, n$ 为第二类 Chebyshev 节点，则 $\omega_i = \frac{2^{n-1}}{n} (-1)^i, 1 \leq i \leq n-1$ ，当 $i = 0, n$ 时，系数为内部表达式的一半即 $\omega_i = \frac{2^{n-1}}{2n} (-1)^i$ 。

证明 对于任意的节点组 $\{x_i\}_{i=0}^n$ ，通过定义首项系数为一的 $n+1$ 次多项式

$$\omega_{n+1}(x) = \prod_{i=0}^n (x - x_i),$$

都不难观测出 $\omega_i = \frac{1}{\omega'_{n+1}(x_i)}$, 下面我们分别证明 (1) 和 (2)。对于 (1) 由 3.1 知道第一类 Chebyshev 点 $x_j = \cos \frac{2j+1}{2n+2}\pi$, $j = 0, \dots, n$ 是 Chebyshev 多项式 $T_{n+1}(x)$ 的全部零点, 且通过比较首项系数得到

$$\omega_{n+1}(x) = \frac{1}{2^n} T_{n+1}(x).$$

引入变量替换 $x = \cos t$, 则 $T_{n+1}(x) = \cos(n+1)t$, 于是有

$$2^n \omega'_{n+1}(x_i) = T'_{n+1}(x_i) = \frac{d}{dt} \cos(n+1)t \frac{dt}{dx} \Big|_{x_i} = (n+1) \frac{\sin(i+0.5)\pi}{\sin \frac{2i+1}{2n+2}\pi} = (-1)^i \frac{n+1}{\sin \frac{2i+1}{2n+2}\pi},$$

得到 $\omega_i = (-1)^i \frac{2^n}{n+1} \sin \frac{2i+1}{2n+2}\pi$.

下面来证明 (2)。由 ω_i 的定义知道其为 $T_n(x)$ 的极值点, 并且为 $T_{n+1} - T_{n-1}$ 的根 (见 3.1)。考察首项系数后得到

$$\omega_{n+1}(x) = \frac{1}{2^n} (T_{n+1}(x) - T_{n-1}(x)).$$

通过变量替换 $x = \cos t \Rightarrow -\sin t dt = dx$, 对于所有的 $1 \leq j \leq n-1$, 我们有

$$T'_{n+1}(x_j) - T'_{n-1}(x_j) = -2 \frac{d(\sin nt \sin t)}{dt} \frac{dt}{dx} \Big|_{x_j} = -2(n \cos nt \sin t + \sin nt \cot t) \frac{dt}{dx} \Big|_{x_j} = 2n \cos(nt_j) = (-1)^j 2n$$

其中 $t_j = \arccos x_j$ 。注意到上述证明对 $j = 0, n$ 是不成立的, 因为在两个端点处 $\sin nt_j = 0$ 从而 $\frac{dt}{dx} \Big|_{x_j} = \infty$, 此时不能使用简单的链式法则, 我们可以考虑极限过程。不妨设 $j = 0$, 即 $x_j = 1, t_j = 0$ 的情况。由函数的连续性得到

$$\begin{aligned} T'_{n+1}(1) - T'_{n-1}(1) &= \lim_{x \rightarrow 1^-} -2 \frac{d(\sin nt \sin t)}{dt} \frac{dt}{dx} \\ &= \lim_{x \rightarrow 1^-} -2(n \cos nt \sin t + \sin nt \cot t) \frac{dt}{dx} \Big|_x \\ &= \lim_{t \rightarrow 0^+} \frac{2(n \cos nt \sin t + \sin nt \cot t)}{\sin t} \\ &= 4n. \end{aligned}$$

类似可以得到 $j = n$ 的情形, 最后再次利用 $\frac{1}{\omega_i} = \omega'(x_i)$ 可以证明结论,

从上面几个定理中, 我们可以发现将等距节点改为特定的非等距节点如 Chebyshev 点, 从理论上的收敛性、数值稳定性、程序实现三个方面均可以有效的解决多项式插值问题。当然解决等距节点插值不稳定性方法还可以从修改高次整体多项式插值为低次分片多项式插值、将多项式插值改为多项式逼近等不同的方法, 我们在后面的章节中将分别进行探讨。

下面以 Runge 函数为例, 观测 Chebyshev 点进行插值的数值结果 (见图 3.6)。随着非等距样本量 n 的增加, $P_n(x)$ 逐渐逼近 $f(x)$, 这里我们使用的目标函数 $f(x)$ 和样本量 n 都与图 3.5 中的相同, 但是基于 Chebyshev 点构成的非等距样本点避免了龙格现象。我们将这两种插值节点对应的多项式插值 MSE 结果展示在如下表格中, 可以清晰观察到非等距插值的优势, 关于 MSE 收敛阶的描述具体见图 3.7。

n	MSE (Chebyshev interpolation)	MSE (Isometric interpolation)
2	$1.211e-01$	$1.366e-01$
4	$6.711e-02$	$5.935e-02$
8	$1.406e-02$	$1.058e-02$
16	$5.465e-04$	$2.538e-01$
32	$9.383e-07$	$1.195e+04$
64	$2.817e-12$	$2.267e+14$




图 3.6: 图中我们令 $x \in [-5, 5]$, 同时对龙格函数 $f(x) = \frac{1}{1+x^2}$ 的非等距样本点 (Chebyshev 点) 进行插值。其中橙色曲线表示我们的目标函数, 即龙格函数; 黑色的圆点表示在 $[-5, 5]$ 区间等距取样得到的样本点, 样本点的数量与子图的标题 n 相对应; 蓝色曲线表示通过多项式插值得到的函数 $P_n(x)$ 。

3.3 Hermite 插值

Hermite 插值是另一种多项式插值方法, 可以看作是 Lagrange 插值的一种拓展。如果一个插值问题在给定节点处, 不仅要求函数值相等, 还要导数值 (或者高阶导数值) 相等, 满足这种要求的插值多项式便是 Hermite 插值。值得注意的是, 从实用性的角度来看 Hermite 插值在工程中不太会单独使用, 因为一般来说导数值的精确测量都是不太容易的事情。我们本节主要通过一个典型的例子来理解 Hermite 插值: 令插值条件为

$$p(x_i) = f(x_i), \quad p'(x_i) = f'(x_i), \quad i = 0, 1, \dots, n. \quad (3.55)$$




图 3.7: 横坐标代表插值点的个数, 同时也对应插值多项式的阶数。纵坐标表示对应的对数规模下的 MSE 误差。

后面不做特殊说明时 Hermite 插值均表示满足上述插值条件。因为上述插值条件(3.55)给出了 $2n + 2$ 个方程, 于是自然的我们会要求插值多项式 $p(x) \in \mathbb{P}_{2n+1}$ 。类似 Lagrange 插值多项式的存在唯一性结论, 对于 Hermite 插值多项式我们也有如下的存在唯一性定理。

定理 3.10

当 x_i 互不相同, 对于任意的 $f(x)$, 存在唯一的 $p_{2n+1}(x) \in \mathbb{P}_{2n+1}$, 满足插值条件(3.55), 我们称 p_{2n+1} 为 Hermite 插值多项式。



如果采用类似 Lagrange 插值的方式证明 Hermite 插值的存在唯一性 (即选择单项式基底, 构造线性系统满足插值条件并证明线性方程组解的存在唯一性), 则可以发现线性方程组为合流-Vandermonde (Confluent Vandermonde) 矩阵, 需要额外花一些力气去证明其可逆性。更重要的是我们知道单项式基底的相关性导致 Confluent Vandermonde 矩阵的求解也是不稳定的, 所以这一思路并不适合用来计算插值多项式。

我们沿着另外一条道路来思考, 首先 Hermite 插值 (如果存在的话) 很自然的是一个从 $\mathbb{R}^{2n+2}$ 到 $\mathbb{P}_{2n+1}$ 的线性算子, 那么 $\mathbb{P}_{2n+1}$ 就有一个自然的基底, 即 $\mathbb{R}^{2n+2}$ 空间中的标准基底的像 (类似 Lagrange 基底的构造方法)。于是我们可以通过构造性的证明, 说明 Hermite 插值多项式的存在性。

证明 与 Lagrange 插值基函数的构造类似, 先构造 Hermite 基函数。需要注意的是, 由于多出导数值相等的要求, 基函数需要分为两类。第一类基函数 $H_{1,i}(x)$ 满足 $H_{1,i}(x_j) = \delta_{ij}$, $H'_{1,i}(x_j) = 0$; 第二类基函数 $H_{2,i}(x)$ 满足 $H_{2,i}(x_j) = 0$, $H'_{1,i}(x_j) = \delta_{ij}$ 。我们首先证明函数 $H_{1,i}(x) \in \mathbb{P}_{2n+1}$ 和 $H_{2,i}(x) \in \mathbb{P}_{2n+1}$ 都是存在性。

对于第一类基函数, 我们可以构造 $H_{1,i}(x) = \frac{(x-c_i) \prod_{j \neq i} (x-x_j)^2}{(x_i-c_i) \prod_{j \neq i} (x_i-x_j)^2}$, 其中 c_i 待定, 将通过条件 $H'_{1,i}(x_i) = 0$ 解得。对 $H_{1,i}(x)$ 求对数得到 $\ln |H_{1,i}(x)| = \ln |x - c_i| + 2 \sum_{j \neq i} \ln |x - x_j|$. 从而 $\frac{H'_{1,i}(x)}{H_{1,i}(x)} = \frac{1}{x-c_i} + 2 \sum_{j \neq i} \frac{1}{x-x_j}$, 代入 x_i 即得 $c_i = x_i + \frac{1}{2 \sum_{j \neq i} \frac{1}{x_i-x_j}}$ (当 $\sum_{j \neq i} \frac{1}{x_i-x_j} \neq 0$ 时。如果 $\sum_{j \neq i} \frac{1}{x_i-x_j} = 0$, 我们发现 $H_{1,i}(x) = \frac{\prod_{j \neq i} (x-x_j)^2}{\prod_{j \neq i} (x_i-x_j)^2}$ 可以满足所有的插值条件。于是综合上述推

导, 我们得到

$$H_{1,i}(x) = \begin{cases} \frac{(x-c_i) \prod_{j \neq i} (x-x_j)^2}{(x_i-c_i) \prod_{j \neq i} (x_i-x_j)^2} \text{ with } c_i = x_i + \frac{1}{2 \sum_{j \neq i} \frac{1}{x_i-x_j}}, & \sum_{j \neq i} \frac{1}{x_i-x_j} \neq 0 \\ \frac{\prod_{j \neq i} (x-x_j)^2}{\prod_{j \neq i} (x_i-x_j)^2}, & \sum_{j \neq i} \frac{1}{x_i-x_j} = 0. \end{cases}$$

对于第二类基函数, 我们可以构造 $H_{2,i}(x) = d_i(x-x_i) \prod_{j \neq i} (x-x_j)^2$. 求导可以发现 $H'_{2,i}(x) = d_i \prod_{j \neq i} (x-x_j)^2 + d_i(x-x_i)(\prod_{j \neq i} (x-x_j)^2)'$. 代入 $x = x_i$ 得到 $d_i = \frac{1}{\prod_{j \neq i} (x_i-x_j)^2}$, 于是第二类基函数为

$$H_{2,i}(x) = \frac{(x-x_i) \prod_{j \neq i} (x-x_j)^2}{\prod_{j \neq i} (x_i-x_j)^2}.$$

从 $H_{1,i}(x) \in \mathbb{P}_{2n+1}$ 和 $H_{2,i}(x) \in \mathbb{P}_{2n+1}$ 的构造中, 我们很容易证明它们满足各自的插值条件. 下面首先证明一般的 Hermite 插值多项式的存在性. 定义

$$p(x) = \sum_{i=0}^n f(x_i) H_{1,i}(x) + \sum_{i=0}^n f'(x_i) H_{2,i}(x),$$

容易验证 $p(x) \in \mathbb{P}_{2n+1}$ 及满足插值条件(3.55). 最后来证明唯一性. 令 $p(x), q(x) \in \mathbb{P}_{2n+1}$ 使得 $p(x_i) = q(x_i) = f(x_i), p'(x_i) = q'(x_i) = f'(x_i)$ 对 $i = 0, \dots, n$ 成立. 令 $h(x) = p(x) - q(x) \in \mathbb{P}_{2n+1}$, 从而 $h(x_i) = 0, h'(x_i) = 0$ 对 $i = 0, \dots, n$ 成立. 故 $h(x) = c \prod_{i=0}^n (x-x_i)^2 \in \mathbb{P}_{2n+1}$, $c = 0$.

类似 Lagrange 插值的 Lagrange 型误差估计, 对于 Hermite 插值, 我们同样也给出它的 Lagrange 型误差估计:

定理 3.11 (Hermite 插值的误差估计)

若 $f(x) \in C^{2n+2}[a, b]$, 则 Hermite 插值误差为

$$R(x) = f(x) - p(x) = \frac{f^{(2n+2)}(\eta)}{(2n+2)!} \prod_{i=0}^n (x-x_i)^2, \text{ for some } \eta \in [a, b].$$



证明 该定理的证明思路与 Lagrange 插值类似. 首先由插值点处函数值与导数值均为零可知插值点都是余项函数 $R(x)$ 的重根, 于是得到

$$R(x) = u(x) \prod_{i=0}^n (x-x_i)^2.$$

因为 $x = x_i$ 的情形是平凡的, 我们仅考虑 $x \neq x_i$ 的情形. 构造辅助函数

$$l(t) = f(t) - p(t) - u(x) \prod_{i=0}^n (t-x_i)^2.$$

则根据定义有 $l(x_i) = 0, l'(x_i) = 0$ 对于 $i = 0, \dots, n$ 成立, 且 $l(x) = 0$. 于是在重根的意义下函数 $l(t)$ 有 $2n+3$ 个零点, 且其 $2n+2$ 次连续可微. 利用 Rolle 中值定理, 我们发现 $l'(t)$ 共有 $2n+2$ 个零点, 于是反复使用 Rolle 中值定理可知, 存在 $\eta \in [a, b]$ 使得 $l^{(2n+2)}(\eta) = 0$. 于是我们可以得到

$$l^{(2n+2)}(\eta) = f^{(2n+2)}(\eta) - u(x) \cdot (2n+2)! \Rightarrow u(x) = \frac{f^{(2n+2)}(\eta)}{(2n+2)!}.$$

在本节的最后, 我们给出一个常用的三次 Hermite 插值多项式供读者参考, 这样的三次

Hermite 插值多项式将在三次样条插值中出现,

例题 3.4 考虑 $H(x) \in \mathbb{P}_3$, $H(x_0) = a$, $H(x_1) = b$, $H'(x_0) = c$, $H'(x_1) = d$, 给出 $H(x)$ 的表达式并计算 $H''(x_0)$ 。

解 对 $H(x)$ 进行恰当的表示可以更加方便的计算。首先我们令 $H(x)$ 为 $H(x) = \alpha(x - x_0)^3 + \beta(x - x_0)^2 + \gamma(x - x_0) + \eta$, 则求导得到 $H'(x) = 3\alpha(x - x_0)^2 + 2\beta(x - x_0) + \gamma$, 代入 x_0 处的函数值与导数值可以立即得到 $\eta = a, \gamma = c$ 。我们用类似的方法计算 $H(x_1)$ 和 $H'(x_1)$ 可以得到如下方程:

$$\begin{bmatrix} (x_1 - x_0)^3 & (x_1 - x_0)^2 \\ 3(x_1 - x_0)^2 & 2(x_1 - x_0) \end{bmatrix} \begin{bmatrix} \alpha \\ \beta \end{bmatrix} = \begin{bmatrix} b - a - c(x_1 - x_0) \\ d - c \end{bmatrix}.$$

解出 α, β 的值即得到相应的插值多项式, 具体计算结果留给读者完成, 我们在三次样条插值时会回到这一计算结果。

3.4 分片线性和分片三次 Hermite 插值

在实际应用中, 为了得到更好的插值精度, 人们需要利用更多的插值节点函数信息。但是就如同我们在 3.2.3 节中所总结的那样, 如果采用等距节点 Lagrange 多项式插值时, 随着多项式次数的增加会有理论上的不稳定性 (如 Runge 现象) 和数值不稳定性 (如观测或者舍入误差被放大 Lebesgue 常数倍) 等。虽然采用一些特殊的插值点 (如 Chebyshev 点) 插值可以避免这些问题, 但是在实际应用中, 这种处理方法也有其自身的局限性: 例如测量数据点并不能自由选择, 导致无法选择特定的 Chebyshev 节点进行测量和插值; 或者目标函数的整体光滑性并不好甚至某些地方不连续, 这样采用整体多项式插值的误差较大, 不能很好的利用目标函数局部光滑性。为了在任意给定节点上进行插值, 可以采用分片低次多项式函数进行插值, 本节中我们主要介绍分片线性插值和分片三次 Hermite 插值及其误差分析。

分片多项式插值中最简单的是分片线性插值。考虑区间 $[a, b]$ 中给定了 $n + 1$ 个插值节点: $a = x_0 < \dots < x_n = b$, 分片线性插值函数将每 2 个节点之间的目标函数用线性函数近似。例如在区间 $[x_i, x_{i+1}]$ 上, 构造线性插值多项式, 得到

$$p_i(x) = f(x_i) \frac{x - x_{i+1}}{x_i - x_{i+1}} + f(x_{i+1}) \frac{x - x_i}{x_{i+1} - x_i}.$$

这样, 整个插值曲线是个分段函数

$$g(x) = p_i(x), x \in [x_i, x_{i+1}].$$

分片插值的示意图见图 3.8。从上述的构造过程中显然看出分片线性插值是存在唯一的, 事实上这一结论可以放在一般的样条函数空间中进行说明, 具体的细节留到后面的 B 样条这一章节中统一说明, 我们先不加证明的给出分片线性函数空间的定义和其基函数。令 $a = x_0 < x_1 < \dots < x_n = b$, 定义

$$S_{1,n} = \{p(x) \in C[a, b] : p(x)|_{[x_i, x_{i+1}]} \in \mathbb{P}_1, i = 0, \dots, n - 1\}.$$

于是 $S_{1,n}$ 是一个维度为 $n + 1$ 的线性空间, 其基函数共 $n + 1$ 个, 两端是半边帽子函数, 中间




图 3.8: 分片线性插值示意图。

是帽子函数, 具体如图 3.9 所示。




图 3.9: 帽子函数与半帽子函数示意图。

对于分片线性插值, 我们有如下的误差估计。

定理 3.12

令 $h = \max_i(x_i - x_{i-1})$, 被插值函数 $f \in C^2[a, b]$, $p_n(x) \in S_{1,n}$ 为, 则有

$$\|f(x) - p_n(x)\|_{C[a,b]} \leq \frac{h^2}{8} \|f''(x)\|_{C[a,b]}. \quad (3.56)$$

证明 注意到 $p_n(x)$ 在每一个小区间 $[x_i, x_{i+1}]$ 上都是线性插值, 由 Lagrange 插值误差估计可知, 对于任意的 $x \in [x_i, x_{i+1}]$, 存在 $\xi \in [x_i, x_{i+1}]$, 使得 $f(x) - p_n(x) = \frac{f''(\xi)}{2!} (x - x_i)(x - x_{i+1})$ 。记 $h_i = x_{i+1} - x_i$, $i = 0, 1, \dots, n-1$, 则有

$$\|f(x) - p_n(x)\|_{C[x_i, x_{i+1}]} \leq \frac{\|f''\|_{C[x_i, x_{i+1}]}}{2} \frac{h_i^2}{4} \leq \frac{h^2}{8} \|f''(x)\|_{C[a,b]}.$$

最后对所有的区间取最大值即可得到定理的结论。

从定理的证明中我们可以发现 h_i 的选择是可以根据被插值函数 f 的光滑性进行调整, 因为其误差估计中有 $\|f''\|_{C[x_i, x_{i+1}]} h_i^2$, 也就是说为了达到给定的精度 (在最大模的意义下), 为了节约取点的数目, 应该在 f'' 大的地方减少 h , 而在 f'' 小的地方增加 h , 直观来说就是光滑的地方少撒点, 震荡的地方多撒点。

分片线性插值可以简单的推广到分片高次 Lagrange 插值, 即在每个小区间中使用 $k+1$ 个插值点 (包括两个端点) 得到分片 k 次多项式。其误差估计也是 Lagrange 插值的自然推广 (计算时更复杂一些, 需要计算 $|\omega(x)|$ 的最大值)。而且可以将分片 Lagrange 插值的思路推广到分片 Hermite 插值, 我们下面给出分片三次 Hermite 插值的描述和误差估计。给定 $a = x_0 < \dots < x_n = b$, 找到分片三次多项式使得函数值和导数值都等于所给定的函数, 则我们称其为分片三次 Hermite 插值。类似的可以给出分片三次 Hermite 插值的函数空间和基函数 (这一结

果留作练习), 关于误差我们有如下估计。

定理 3.13

令 $h = \max_i(x_i - x_{i-1})$, 被插值函数 $f \in C^4[a, b]$, $H_n(x)$ 为分片三次 Hermite 插值, 则有

$$\|f(x) - H_n(x)\|_{C[a,b]} \leq \frac{h^4}{384} \|f^{(4)}(x)\|_{C[a,b]}. \quad (3.57)$$



上述定理的证明过程与分片线性插值的误差估计证明过程类似, 只需注意到 $4!4^2 = 384$ 即可。

除了理论上的误差估计, 我们还可以进一步分析分片线性插值的数值稳定性, 即在插值数据具有微小扰动的时候, 插值出来的函数是否具有数值稳定的特点。换言之, 我们将分片线性插值看成 $\mathbb{R}^{n+1}$ 到线性空间 $S_{1,n}$ 的线性映射 $\mathcal{P}$, 考虑该线性算子在特定度量下的算子范数: $\mathcal{P}: (\mathbb{R}^{n+1}, \|\cdot\|_{\ell^\infty}) \mapsto (S_{1,n}, \|\cdot\|_{C[a,b]})$ 。利用线性函数在任意闭区间中都在其端点处取到最大/最小值这一特点, 我们很容易证明如下定理。

定理 3.14

给定 $\{y_i\}_{i=0}^n$ 满足 $\max_i |y_i| \leq 1$, 则对应的分片线性插值函数 $p_n \in S_{1,n}$, $p_n(x_i) = y_i$, 满足 $\|p_n\|_{C[a,b]} \leq 1$ 。



证明 我们只需要证明 $\|p_n\|_{C[x_i, x_{i+1}]} \leq 1$ 对所有的 $i = 0, \dots, n-1$ 都成立即可。而在任意一个小区间 $[x_i, x_{i+1}]$ 中, $p_n(x)$ 是一个线性函数, 在左右端点分别取值为 y_i, y_{i+1} 。如上面所述, 利用线性函数在任意闭区间中都在其端点处取到最大/最小值这一性质, 我们立刻得到

$$\|p_n\|_{C[x_i, x_{i+1}]} \leq \max\{|y_i|, |y_{i+1}|\} \leq 1.$$

从上述定理可以看出, 分片线性插值不仅具有数值稳定性, 而且其插值函数的误差会被测量点的误差控制。对于一般的分片 Lagrange 插值或者分片 Hermite 插值, 我们很难期待误差不增的特性, 不过仍然可以分析其数值稳定性, 特别的我们会观测到误差的放大倍数仅仅依赖分片多项式的次数, 而不会依赖插值点的总个数, 从而说明其数值稳定性。

3.5 三次样条插值

在工程应用中, 分片 Lagrange 插值和分片 Hermite 插值都有其不足之处。例如不管是几次的分片 Lagrange 插值, 都不能保证插值函数导数的连续性, 而分片 Hermite 插值不仅需要用到导数的信息, 而且同样不能保证插值函数二次导数的连续性等。在许多工程应用问题, 对于替代函数(插值函数)的光滑性是有要求的, 同时(高阶)导数却非常难以测量, 这就提出了如何只用函数值的信息, 来构建一个分片多项式函数进行插值, 使得目标函数具有足够的光滑性。人们提出了样条函数的概念, 并利用样条函数进行插值, 满足实际工程需求。样条函数空间的定义如下:

定义 3.6

样条函数给定 $a = x_0 < x_1 < \cdots < x_n = b$ 是区间 $[a, b]$ 上的插值点, $m \in \mathbb{N}$ 。定义样条函数空间 $S_{m,n}$ 为

$$S_{m,n} = \{S(x) \in C^{m-1}[a, b] : S(x)|_{[x_i, x_{i+1}]} \in \mathbb{P}_m, i = 0, 1, \dots, n-1\}.$$



从定义3.6中可以看出样条函数 $S(x)$ 在 $[a, b]$ 上 $m-1$ 次连续可微, 并且若将 $S(x)$ 限制在任意一个子区间 $[x_i, x_{i+1}]$ 中, $S(x)$ 是一个次数至多为 m 的多项式。我们称映射 $S : [a, b] \rightarrow \mathbb{R}$ 为 m 次样条函数。当 $S(x)$ 限制在任意一个子区间 $[x_i, x_{i+1}]$ 都是一个次数至多为 m 的多项式且 $S(x)$ 并非一个整体多项式, 那么一般来说我们最多能够期待 $S(x) \in C^{m-1}[a, b]$ 。这是因为如果 $S(x) \in C^m[a, b]$, 则可以对 $S(x)$ 求 m 次导数, 因为其在每个区间中都是次数至多为 m 的多项式则其 m 次导数为分片常数, 但是因为 $S(x)$ 的 m 次导数连续, 则只能是一个常数, 这就证明了此时 $S(x) \in \mathbb{P}_m$ 。这一结论可以描述为下面的命题。

命题 3.3

如果一个函数 $S(x) \in C^m[a, b]$, 且 $S(x)$ 限制在任意一个子区间 $[x_i, x_{i+1}]$ 都是一个次数至多为 m 的多项式, $i = 0, 1, \dots, n-1$, 则 $S(x) \in \mathbb{P}_m$ 。



一般来说样条插值的定义是: 给定 $a = x_0 < \cdots < x_n = b$ 为插值点, 找到一个分片 m 次多项式使得满足插值条件且 $S \in C^{m-1}$ (即 $S \in S_{m,n}$)。样条函数插值的好处是只用了函数值的信息, 但是可以保证最高的光滑性, 特别的我们注意到分片线性插值就是 1 次样条插值。对于一般的样条函数, 我们将在下一节中进行讨论, 本节中, 我们主要关注实际应用最为广泛的一类样条插值: 三次样条插值。

按照通常的做法, 我们需要我们先检查三次样条插值的存在性、唯一性、以及如何求解等基本问题。按照不太严格的讨论, 我们先简单数一下为了确定一个分片三次多项式所需要的自由度的个数, 以及通过样条插值所能提供的方程个数。因为区间被分为 n 个小区间, 则 n 个三次多项式的总自由度为 $4n$; 样条插值所能提供的方程个数为: 在每一个区间上左右端点满足插值条件得到 $2n$ 个方程、在所有内部节点上一次导数和二次导数均连续, 得到 $2(n-1)$ 个方程, 于是共有 $4n-2$ 个方程, 为了得到唯一解缺少两个方程。为了保证三次样条插值的唯一性, 需要提供两个额外的条件。在应用中, 边界的信息相对比较容易获得, 常见的主要有如下几种边界条件:

- (1) 固支边界条件 (即给定左右边界的一阶导数信息): $S'(a) = m_0, S'(b) = m_n$.
- (2) 简支边界条件 (即给定左右边界的二阶导数信息): $S''(a) = M_0, S''(b) = M_n$. 当均为 0 时成为自然边界条件。
- (3) 周期边界条件 (假设函数本身是周期函数): $S'(a) = S'(b), S''(a) = S''(b)$.
- (4) 非扭结边界条件 (Not-a-Knot, 函数在离左右边界最近的两个内部节点上三次连续可微):

$$S(x)|_{[x_0, x_2]} \in \mathbb{P}_3, S(x)|_{[x_{n-2}, x_n]} \in \mathbb{P}_3.$$

在这里我们仅仅对第二种边界条件: 简支边界条件下的三次样条插值进行推导和证明, 其他不同边界条件下的推导留给读者自行完成。我们先给出三次样条插值函数的构造方法而把

存在唯一性的证明后移，事实上从构造方法中我们可以直接得到三次样条插值函数的存在唯一性。为了求解出满足简支边界条件的三次样条插值函数，我们需要给出三次样条函数的表达，并构建方程组进行求解。在前面的分析中，很自然的可以把三次样条函数在每一个小区间中的三次多项式系数作为未知的表达参数，这样一共有 $4n$ 个未知数，通过求解一个 $4n \times 4n$ 的线性系统，我们就可以构造出三次样条插值，并且该线性系统的可逆性（如果能证明的话）就足以保证三次样条插值的存在唯一性。这么做是可行的，但是计算复杂性比较高，在实践中我们通常采用两步走的策略进行求解。具体而言：首先我们注意到为了确定每个小区间上的三次多项式，我们可以利用 Hermite 插值的方法，即给定小区间两个端点处的函数值和二阶导数值（因为我们天然给定了 a, b 两个点的二阶导数，如果是固支边界条件，也可以使用一阶导数信息），就能够唯一确定一个三次多项式，而且求解的计算代价是 $O(1)$ 的。这样我们就把三次样条插值函数的自由度缩减到了 $n-1$ ：只需要计算出 $S(x)$ 在所有内部节点的二次导数值即可，区间端点处的函数值和 a, b 两个点的二阶导数值均由插值条件给出。

令 $S''(x_i) = M_i$, $i = 0, \dots, n$, 在区间 $[x_i, x_{i+1}]$ 上满足 $S(x_i) = y_i$, $S''(x_i) = M_i$ 的三次多项式可以采用如下表示

$$S(x) = a_0 + a_1(x - x_i) + a_2(x - x_i)^2 + a_3(x - x_i)^3, \quad \text{in } [x_i, x_{i+1}].$$

下面的推导不做特别说明都是在区间 $[x_i, x_{i+1}]$ 中。对 $S(x)$ 求两阶导数得到 $S''(x) = 2a_2 + 6a_3(x - x_i)$ 。分别带入 $S''(x_i) = M_i$ 和 $S''(x_{i+1}) = M_{i+1}$ ，并利用插值条件 $S(x_i) = y_i$ 得到

$$S(x) = y_i + a_1(x - x_i) + \frac{M_i}{2}(x - x_i)^2 + \frac{M_{i+1} - M_i}{6(x_{i+1} - x_i)}(x - x_i)^3.$$

带入 $S(x_{i+1}) = y_{i+1}$ 后得到 $a_1 = \frac{y_{i+1} - y_i}{x_{i+1} - x_i} - \frac{M_{i+1} + 2M_i}{6}(x_{i+1} - x_i)$ ，而我们观测到 $S'_+(x_i) = a_1$ ，最后的加号表示对于整体 $S(x)$ 而言，这是它在 x_i 点的右导数。为方便起见我们引入记号 $h_i = x_{i+1} - x_i$ ，由对称性可以给出

$$S'_+(x_i) = \frac{y_{i+1} - y_i}{h_i} - \frac{M_{i+1} + 2M_i}{6}h_i, \quad S'_-(x_i) = \frac{y_{i-1} - y_i}{-h_i} + \frac{M_{i-1} + 2M_i}{6}h_i.$$

利用一阶导数的连续性即 $S'_+(x_i) = S'_-(x_i)$ 并进行整理得到如下方程

$$h_{j-1}M_{j-1} + 2(h_j + h_{j-1})M_j + h_jM_{j+1} = \frac{6}{h_j}(y_{j+1} - y_j) - \frac{6}{h_{j-1}}(y_j - y_{j-1}).$$

将上述方程组装成方程组，得到

$$A \triangleq \begin{pmatrix} 2h_0 + 2h_1 & h_1 & \dots & 0 \\ h_1 & 2h_1 + 2h_2 & \dots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & \dots & 2h_{n-3} + 2h_{n-2} & h_{n-2} \\ 0 & \dots & h_{n-2} & 2h_{n-2} + 2h_{n-1} \end{pmatrix} \begin{pmatrix} M_1 \\ M_2 \\ \vdots \\ M_{n-2} \\ M_{n-1} \end{pmatrix} = \begin{pmatrix} r_1 \\ r_2 \\ \vdots \\ r_{n-2} \\ r_{n-1} \end{pmatrix}, \quad (3.58)$$

其中右端项为

$$\begin{pmatrix} r_1 \\ r_2 \\ \vdots \\ r_{n-2} \\ r_{n-1} \end{pmatrix} = \begin{pmatrix} \frac{6}{h_1}(y_2 - y_1) - \frac{6}{h_0}(y_1 - y_0) - M_0 h_0 \\ \frac{6}{h_2}(y_3 - y_2) - \frac{6}{h_1}(y_2 - y_1) \\ \vdots \\ \frac{6}{h_{n-2}}(y_{n-1} - y_{n-2}) - \frac{6}{h_{n-3}}(y_{n-2} - y_{n-3}) \\ \frac{6}{h_{n-1}}(y_n - y_{n-1}) - \frac{6}{h_{n-2}}(y_{n-1} - y_{n-2}) - M_n h_{n-1} \end{pmatrix}.$$

线性方程组(3.58)是一个 $(n-1) \times (n-1)$ 的方阵，于是在简支边界条件下三次样条插值函数的存在唯一性就依赖于(3.58)中矩阵 A 的性质，我们有如下定理。

命题 3.4

在方程(3.58)中矩阵 A 是一个严格对角占优的矩阵，从而线性系统(3.58)具有唯一的解，并且简支边界条件下三次样条插值函数是存在唯一的。



按照定义可以很简单的证明上述结论，我们进一步观测到矩阵 A 事实上是一个三对角矩阵，其求解代价为 $O(n)$ ，加上通过三次样条函数的节点函数值和二次导数值估计每一个小区间上三次多项式的系数的计算代价也是 $O(n)$ ，这就意味着这种算法的整体计算代价为 $O(n)$ 。

如果我们考虑均匀的插值点分布，即 $h_i = h = \frac{b-a}{n}$ ，那么方程(3.58)中的矩阵 A 可以简化为 hB ，其中

$$B \triangleq \begin{pmatrix} 4 & 1 & \dots & 0 \\ 1 & 4 & \dots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & \dots & 4 & 1 \\ 0 & \dots & 1 & 4 \end{pmatrix}.$$

这个特殊的三对角矩阵（主对角线为常数、次对角线为另外一个常数）在计算数学的许多相关算法中频繁出现，因为 $6I - B$ 对应到二阶微分算子的标准离散形式（在常微分方程两点边值问题中我们会再次看到这一矩阵）。而对于矩阵 B （或 $6I - B$ ），我们可以给出其特征值系统。

命题 3.5

对于 $(n-1) \times (n-1)$ 的三对角方阵 B 如上所示，则矩阵 B 有 n 个互不相同的特征值 $\lambda_i = 6 - 4\sin^2 \frac{i\pi}{2n}$ ，其对应的特征向量为 $x_i = \{\sin \frac{ij\pi}{n}\}_{j=1}^{n-1}$ ，对于 $i = 1, \dots, n-1$ 。



证明 我们只需要验证 (λ_i, x_i) 是矩阵 B 的特征系统，通过计算不难看出对所有的 $i = 1, \dots, n-1$ ，我们都有

$$\begin{aligned} (Bx_i)_j &= \sin \frac{i(j-1)\pi}{n} + 4\sin \frac{ij\pi}{n} + \sin \frac{i(j+1)\pi}{n} = 4\sin \frac{ij\pi}{n} + 2\sin \frac{ij\pi}{n} \cos \frac{i\pi}{n} \\ &= (4 + 2\cos \frac{i\pi}{n}) \sin \frac{ij\pi}{n} = (6 - 4\sin^2 \frac{i\pi}{2n}) \sin \frac{ij\pi}{n}, \end{aligned}$$

这就验证了 λ_i 是矩阵 B 的特征值，对应的特征向量为 x_i ，且这是矩阵 B 的全部特征系统。

对于三次样条插值 (满足相容的简支边界条件或者固支边界条件), 都有如下的误差估计。

定理 3.15

令 $f(x) \in C^4[a, b]$, x_i 为 $[a, b]$ 上的等距节点, 即 $h_i = h = \frac{b-a}{n}$, 则对于两类三次样条插值 $S_1(x)$ 和 $S_2(x)$ 满足

(1) 固支边界条件: $S_1(x_i) = f(x_i)$, $S_1'(a) = f'(a)$, $S_1'(b) = f'(b)$,

(2) 简支边界条件: $S_2(x_i) = f(x_i)$, $S_2''(a) = f''(a)$, $S_2''(b) = f''(b)$ 。

则 S_1 和 S_2 分别满足 $\|S_i(x) - f(x)\|_{C[a,b]} \leq Ch^4 \|f^{(4)}\|_{C[a,b]}$.



该定理可以参考 [RichardBurdenNumericalAnalsis] 及其引用的文献, 那里对于一般的网格 x_i 也有类似的结论。

我们下面来研究对于三次样条插值, 如果观测误差有一定的误差时, 所得到的数值解不会有稳定性 (即对应的 Lebesgue 常数会不会有界), 为简单起见, 我们仍然以等距节点的简支边界条件为例。

引理 3.1

在一个长度为 h 的小区间 (不妨令其为 $[0, h]$) 上, 如果三次多项式 $p(x)$ 满足

$$\max\{|p(0)|, |p(h)|, |p''(0)|h^2/12, |p''(h)|h^2/12\} \leq \epsilon,$$

则有 $\|p(x)\|_{C[0,h]} \leq 2.5\epsilon$.



证明 利用在推导三次样条插值求解过程中得到的三次 Hermite 插值的计算公式, 我们有

$$p(x) = p(0) + \left(\frac{p(h) - p(0)}{h} - \frac{p''(h) + 2p''(0)}{6}h \right)x + \frac{p''(0)}{2}x^2 + \frac{p''(h) - p''(0)}{6h}x^3.$$

进一步化简得到

$$\begin{aligned} |p(x)| &\leq \left| \frac{h-x}{h}p(0) + \frac{x}{h}p(h) \right| + \left| p''(0)\left(\frac{x^2}{2} - \frac{hx}{3} - \frac{x^3}{6h}\right) + p''(h)\left(\frac{x^3}{6h} - \frac{hx}{6}\right) \right| \\ &\leq \epsilon + \frac{12\epsilon}{h^2} \left| \frac{x^2}{2} - \frac{hx}{2} \right| \leq \frac{5}{2}\epsilon. \end{aligned}$$

其中倒数第三个不等式是由于 $\frac{x^2}{2} - \frac{hx}{3} - \frac{x^3}{6h}$ 与 $\frac{x^3}{6h} - \frac{hx}{6}$ 在区间 $[0, h]$ 上都是非正数。

现在我们可以给出三次样条插值误差的传播估计。

定理 3.16

令 x_i 为 $[a, b]$ 上的等距节点, 考虑三次样条插值 $S(x)$ 满足

$$\max_{0 \leq i \leq n} \{|S(x_i)|, |S''(a)|h^2/12, |S''(b)|h^2/12\} \leq \epsilon,$$

则有 $\|S(x)\|_{C[a,b]} \leq 2.5\epsilon$.



证明 令 $M_i = S''(x_i)$, 我们只需要证明

$$\max_{0 \leq i \leq n} \{|S(x_i)|, |S''(x_i)|h^2/12\} \leq \epsilon,$$

即可从上面的引理中得到结论。也就是只需要证明 $M = \max_{1 \leq i \leq n-1} \{|M_i|\} \leq \frac{12\epsilon}{h^2}$, 不妨设 M_i

取到了最大值 M ，注意到如果 $2 \leq i \leq n-2$ 时有

$$|h(M_{i-1} + 4M_i + M_{i+1})| \leq \frac{24\epsilon}{h} \Rightarrow M \leq \frac{12\epsilon}{h^2},$$

当 $i = 1, n-1$ 时也类似可证。

上面的两个定理给出了三次样条插值的误差估计和数值稳定性，而对于三次自然样条插值（即左右端点的二阶导数为零），我们有如下的力学性质：

定理 3.17

令 $S(x)$ 为三次自然样条插值，对任意 $\phi(x) \in C^2[a, b]$ 满足同样插值条件，有

$$\int_a^b |\phi''(x)|^2 dx \geq \int_a^b |S''(x)|^2 dx.$$

等号成立当且仅当 $\phi = S$ 。



证明 通过左右两者相减，利用分步积分公式以及样条的三次导数为常数等性质得到。具体计算如下（注意到恒等式 $z^2 - y^2 = (z - y)^2 + 2(z - y)y$ ）

$$\begin{aligned} \int_a^b |\phi''(x)|^2 - |S''(x)|^2 dx &= \int_a^b |\phi'' - S''|^2 + 2S''(\phi'' - S'') dx \geq 2 \sum_i \int_{x_i}^{x_{i+1}} S''(\phi'' - S'') \\ &= 2 \sum_i (S''(\phi' - S')|_{x_i}^{x_{i+1}} - c_i \int_{x_i}^{x_{i+1}} (\phi' - S') dx) = 0. \end{aligned}$$

等式当且仅当 $\phi'' = S''$ ，即 $S - \phi$ 为线性函数，注意到插值条件则有 $\phi = S$ 。

上面的能量不等式可以重新描述为

$$S(x) = \arg \min_{\phi \in C^2[a, b], \phi(x_i) = f(x_i)} \int_a^b |\phi''(x)|^2 dx,$$

即在一个无穷维的函数空间中求解特定能量泛函极小点的问题，一般来说无穷维空间的能量最小点并不能保证存在性。但是令人吃惊的事实是样条函数经常是这类问题中的最小点，例如对于固支边界条件或者周期边界条件也有类似结果，只需要把函数空间加上一些约束（如对固支边条件加上 $S'(a) = \phi'(a)$, $S'(b) = \phi'(b)$ 以及周期边界条件中 $\phi'(a) = \phi'(b)$ 和 $\phi''(a) = \phi''(b)$ 成立），具体的证明过程和三次自然样条非常类似，留给读者自行完成。

例题 3.5 使用固定边界条件，自然边界条件，周期边界条件对 Runge 函数进行三次样条插值并观察对应的收敛阶。

解 固定边界条件中我们令 $m_0 = m_n = 1$ ，这里实验的超参数与图 3.5 中一致。具体的收敛结果见图 3.10。特别的我们注意到虽然没有给出准确的边界条件，但是得到的解仍然可以到达一个较高的精度。

3.6 B 样条

虽然三次样条插值可以满足许多工程问题的要求，但是在一些需要精细控制的场景，插值函数或许需要更高的光滑性。这一节我们介绍一般的样条函数空间，并给出样条函数空间中一组计算上非常有效的基底：B-样条基底。首先我们回顾上一节中所给出的一般样条函数




图 3.10: 三次样条插值示意图。

的定义, 并证明样条函数空间是一个线性空间。

定理 3.18

$S_{m,n}$ 是一个维数为 $m+n$ 的线性空间。



证明 显然 S_m^n 是一个线性空间, 因为 $C^{m-1}[a, b]$ 和分片 P_m 函数都是线性空间, 样条函数是这两个线性空间的交集。我们下面通过构造出 $S_{m,n}$ 空间的一组基底来证明空间的维数。引入如下记号:

$$x_+^m := \begin{cases} x^m & x \geq 0, \\ 0 & x < 0. \end{cases}$$

那么对于任意的 $m \in \mathbb{N}$, 构造 $m+n$ 个函数

$$\begin{aligned} u_k(x) &:= (x - x_0)^k, \quad k = 0, \dots, m, \\ v_k(x) &:= (x - x_k)_+^m, \quad k = 1, \dots, n-1. \end{aligned} \quad (3.59)$$

下面我们去证明两个事实,

- (1) 方程(3.59)中的 $m+n$ 个函数线性无关,
- (2) 由(3.59)中这 $m+n$ 个函数张成的空间就是 $S_{m,n}$ 。

先证明 (1), 为证明这一点, 令

$$\sum_{k=0}^m \alpha_k u_k + \sum_{k=1}^{n-1} \beta_k v_k = 0. \quad (3.60)$$

我们按照顺序分别考虑 $[x_0, x_1], [x_1, x_2], \dots, [x_{n-1}, x_n]$ 这 n 个区间。首先 $\forall x \in [x_0, x_1], \sum_{k=1}^{n-1} \beta_k v_k \equiv 0$, 于是 $\sum_{k=0}^m \alpha_k u_k$ 是一个 m 次多项式, 且在区间 $[x_0, x_1]$ 上恒为零, 那么只可能是零多项式, 所以 $\alpha_k = 0 \quad \forall k = 0, \dots, m$ 。然后考虑区间 $[x_1, x_2]$, 注意到此时 (3.60) 化简为 $\sum_{k=0}^m \alpha_k u_k + \beta_1 v_1 = 0$, 而我们已知 $\alpha_k = 0 \quad \forall k = 0, \dots, m$, 于是 $\beta_1 = 0$ 。后面由归纳法可以得到 $\beta_k \equiv 0 \quad \forall k = 1, \dots, n-1$ 。这就说明了 (3.60) 成立时当且仅当所有系数 α_k, β_k 都为零, 故 (1) 得证。

接下来需要证明 (2), 即证明, $\forall s(x) \in S_{m,n}$, 存在一组系数 $\alpha_0, \dots, \alpha_m, \beta_1, \dots, \beta_{n-1}$ 使得 $s(x)$ 能写成

$$s(x) = \sum_{k=0}^m \alpha_k u_k(x) + \sum_{k=1}^{n-1} \beta_k v_k(x). \quad (3.61)$$

我们仍然使用归纳法, 并构造出这样一组系数。首先对于区间 $[x_0, x_1]$, 由于 $s|_{[x_0, x_1]} \in \mathbb{P}_m$, 故必定存在一组 $\alpha_0, \dots, \alpha_m$ 使得 $s(x)|_{[x_0, x_1]} = \sum_{k=0}^m \alpha_k u_k(x)$ 。注意到 $v_k(x)$ 在区间 $[x_0, x_1]$ 上恒为零, 所以 (3.61) 在区间 $[x_0, x_1]$ 上成立。下一步考虑区间 $[x_1, x_2]$, 后续的区间通过归纳类似可得。我们选择 $\beta_1 = \frac{s(x_2) - \sum_{k=0}^m \alpha_k u_k(x_2)}{(x_2 - x_1)^m}$, 简单的计算得到 $r(x) = s(x) - \sum_{k=0}^m \alpha_k u_k(x) - \sum_{k=1}^{n-1} \beta_k v_k(x)$ 满足 $r^{(j)}(x_1) = 0 = r(x_2)$, 其中 $j = 0, \dots, m-1$ 。注意到 $r(x)|_{[x_1, x_2]} \in \mathbb{P}_m$, 不难证明满足 $m+1$ 个插值条件的不超过 m 次的多项式只有零, 于是 $r(x)|_{[x_1, x_2]} = 0$, 也就证明了 (3.61) 在区间 $[x_0, x_2]$ 上成立, 即完成了 (2) 的证明

我们在前面的章节中介绍过两类最常见的样条函数: 一次样条 (分片线性函数) 和三次样条, 特别的使用三次样条插值时需要给定两个额外的边界条件来保证唯一性。对于一般的样条函数插值, 因为样条函数空间是一个 $m+n$ 维的线性空间, 而 $x_0, \dots, x_n$ 这 $n+1$ 个插值点不足以唯一确定一个样条函数 ($m > 1$ 时), 因此我们需要在两个端点 $x_0 = a$ 和 $x_n = b$ 处设置额外 $m-1$ 个边界条件。为方便讨论, 我们仅考虑 m 为奇数的情况。下面定理给出了特定边界条件下样条函数的能量不等式 (带固支边界条件三次样条插值能量不等式的推广)。

引理 3.2

设 $m = 2l - 1, l \in \mathbb{N}, l \geq 2, f \in C^l[a, b]$ 。令 $s \in S_{m,n}$ 是 f 的一个 m 样条插值函数满足插值条件

$$s(x_j) = f(x_j), \quad j = 0, \dots, n,$$

和如下边界条件

$$s^{(j)}(a) = f^{(j)}(a), s^{(j)}(b) = f^{(j)}(b), \quad j = 1, \dots, l-1.$$

那么下面等式成立

$$\int_a^b [f^{(l)}(x) - s^{(l)}(x)]^2 dx = \int_a^b [f^{(l)}(x)]^2 dx - \int_a^b [s^{(l)}(x)]^2 dx,$$

并且很容易看出 $\int_a^b [f^{(l)}(x)]^2 dx \geq \int_a^b [s^{(l)}(x)]^2 dx$ 。



证明 类似三次样条能量不等式的证明过程, 首先观察到

$$\int_a^b [f^{(l)}(x) - s^{(l)}(x)]^2 dx = \int_a^b [f^{(l)}(x)]^2 dx - \int_a^b [s^{(l)}(x)]^2 dx - 2R,$$

其中

$$R = \int_a^b [f^{(l)}(x) - s^{(l)}(x)] s^{(l)}(x) dx.$$

考虑到 $f \in C^l[a, b]$, $s \in C^{m-1}[a, b]$, 反复使用分部积分得

$$\begin{aligned} R &= [f^{(l-1)}(x) - s^{(l-1)}(x)]s^{(l)}(x) \Big|_a^b - \int_a^b [f^{(l-1)}(x) - s^{(l-1)}(x)]s^{(l+1)}(x)dx \\ &= - \int_a^b [f^{(l-1)}(x) - s^{(l-1)}(x)]s^{(l+1)}(x)dx \\ &\quad \vdots (\text{重复 } l-2 \text{ 次}) \\ &= (-1)^l \int_a^b [f^{(l)}(x) - s^{(l)}(x)]s^{(m-1)}(x)dx. \end{aligned}$$

再利用积分可加性, 将区间 $[a, b]$ 拆分成 $[x_0, x_1], \dots, [x_{n-1}, x_n]$ n 个小区间并在每个小区间上使用分部积分公式得到

$$\begin{aligned} R &= (-1)^l \sum_{j=0}^{n-1} \left[(f'(x) - s'(x))s^{(2l-1)}(x) \Big|_{x_j}^{x_{j+1}} - \int_{x_j}^{x_{j+1}} [f'(x) - s'(x)]s^{(2l-1)}(x)dx \right] \\ &= (-1)^l (f'(x) - s'(x))s^{(2l-1)}(x) \Big|_a^b + (-1)^{l-1} \sum_{j=0}^{n-1} [f(x) - s(x)]s^{(2l-1)}(x) \Big|_{x_j}^{x_{j+1}} = 0. \end{aligned}$$

当 $m = 1$ 时, 类似的我们有如下的分片线性插值能量模不等式。

推论 3.1 (分片线性插值的能量模不等式)

令 $f \in C^1[a, b]$, $s(x)$ 为分片线性插值 (一次样条), 则成立如下不等式:

$$\int_a^b [f'(x)]^2 dx \geq \int_a^b [s'(x)]^2 dx,$$

其中 $s'(x)$ 是在分片的意义下定义的。



该结论的证明留给读者作为练习。另外从引理3.2中能量不等式的证明中不难发现: 如果将边界条件3.6替换成

$$s^{(l+j)}(a) = s^{(l+j)}(b) = 0, \quad j = 0, \dots, l-2,$$

或 f 是周期为 $b-a$ 的周期函数, 且

$$s^{(j)}(a) = s^{(j)}(b), \quad j = 1, \dots, m-1,$$

则对应的能量不等式仍然成立, 而证明中只需对分部积分的部分稍作改动即可, 同样的证明留给读者作为练习。在引理3.2的条件下, 我们非常容易证明样条插值的唯一性。

引理 3.3

在引理3.2的条件下, 若 $f(x) = 0$ 则 $s(x) = 0$, 从而得到样条插值的唯一性。



证明 由引理3.2可知

$$\int_a^b [s^{(l)}(x)]^2 dx = 0.$$

于是 $s \in \mathbb{P}_{l-1}$, 从而进一步说明 $s \equiv 0$ 。

最后我们取验证在引理3.2的条件下, 样条插值的存在性。

定理 3.19

设 $m = 2l - 1, l \in \mathbb{N}$ 且 $l \geq 2$, 那么给定 $n + 1$ 个插值点 $(x_0, y_0), (x_1, y_1), \dots, (x_n, y_n)$ 和 $m - 1$ 个实数 $a_1, \dots, a_{l-1}; b_1, \dots, b_{l-1}$, 能唯一确定一个样条函数 $s \in S_{m,n}$, 使得插值条件

$$s(x_j) = y_j, \quad j = 0, \dots, n \quad (3.62)$$

和边界条件

$$s^{(j)}(a) = a_j, \quad s^{(j)}(b) = b_j, \quad j = 1, \dots, l - 1. \quad (3.63) \quad \heartsuit$$

证明 我们已经知道样条函数空间的一组基底是(3.59)的形式, 即

$$s(x) = \sum_{k=0}^m \alpha_k u_k(x) + \sum_{k=1}^{n-1} \beta_k v_k(x). \quad (3.64)$$

那么满足(3.62)和(3.63)的 $s(x)$, 当且仅当 $m + n$ 个系数满足

$$\begin{aligned} \sum_{k=0}^m \alpha_k u_k(x_j) + \sum_{k=1}^{n-1} \beta_k v_k(x_j) &= y_j, \quad j = 0, \dots, n, \\ \sum_{k=0}^m \alpha_k u_k^{(j)}(a) + \sum_{k=1}^{n-1} \beta_k v_k^{(j)}(a) &= a_j, \quad j = 1, \dots, l - 1, \\ \sum_{k=0}^m \alpha_k u_k^{(j)}(b) + \sum_{k=1}^{n-1} \beta_k v_k^{(j)}(b) &= b_j, \quad j = 1, \dots, l - 1 \end{aligned} \quad (3.65)$$

成立。很显然这是一个方程个数和未知数个数相等线的性方程组, 而从引理3.3知道, 方程组(3.65)对应的齐次方程有且仅有零解, 故(3.65)有且仅有唯一解, 从而得到存在性。

虽然在理论上我们确实可以通过求解(3.65)来确定一个样条函数, 但由于这组基函数本身的高度相关性, (3.65)的求解在数值上可能并不稳定。为此, 我们希望找到一组具有紧支集的函数簇, 来张成 $S_{m,n}$ 。为了完成这一目标, 我们引入一种有效而且稳定的基底: B-样条。B-样条的原始定义是 **Basis Spline**, 现在也有一些文献把这个 **B** 解释为 **Bell-shape** (钟形)。我们将称之为 **B-样条**, 并将给出两种构造方法: 从低次到高次递归地构造; 以及基于差分的构造。

首先考虑递归的方法, 为了不特别区分区间的边界, 我们选择 $\dots < x_{-2} < x_{-1} < x_0 < \dots < x_n < x_{n+1} < x_{n+2} < \dots$, 其中下标不在 $[0, n]$ 之间的节点可以任意选择。我们基函数的下标是从 $-\infty$ 到 ∞ , 但是注意到我们只关注限制在区域 $[x_0, x_n]$ 的部分。我们从 $m = 0$ 开始逐次定义 m 次的 B-样条。

当 $m = 0$ 时, 定义 $B_{0,i}, i = -\infty, \dots, 0, \dots, \infty$, 为区间 $I_{[x_i, x_{i+1}]}$ 上的特征函数, 于是 $B_{0,i}$ 的支集为 $[x_i, x_{i+1}]$ 。然后构造 $B_{1,i}$

$$B_{1,i}(x) := \frac{x - x_i}{x_{i+1} - x_i} B_{0,i}(x) + \frac{x_{i+2} - x}{x_{i+2} - x_{i+1}} B_{0,i+1}(x), \quad i = -\infty, \dots, 0, \dots, \infty. \quad (3.66)$$

注意到 $B_{1,i}$ 的支集为 $[x_i, x_{i+2}]$ 。对于一般的 m 次样条函数

$$B_{m,i}(x) := \frac{x - x_i}{x_{i+m} - x_i} B_{m-1,i}(x) + \frac{x_{i+m+1} - x}{x_{i+m+1} - x_{i+1}} B_{m-1,i+1}(x), \quad i = -\infty, \dots, 0, \dots, \infty. \quad (3.67)$$

很容易看出来 $B_{m,i}$ 的支集为 $[x_i, x_{i+m+1}]$ 。

下面我们不加证明的给出几个关于函数 $B_{j,i}(x)$ 的性质, 证明留给有兴趣的同学作为练习。

性质 [B-样条的基本性质]

- (1) $\text{supp}\{B_{j,i}(x)\} = (x_i, x_{i+j+1})$ 。
- (2) 任意给定区间 $[x_i, x_{i+1}]$ 内, 至多有 $m+1$ 个 $B_{m,i}(x)$ 是非零的, 分别是 $B_{m,i-m}(x), \dots, B_{m,i}(x)$ 。
- (3) $B_{j,i}(x) \geq 0, \quad \forall i, j, x$ 。
- (4) $B_{j,i}(x)$ 是分片 j 次多项式, 它是 $j-1$ 次连续可微的。

上述性质可以通过归纳法来证明。现在我们利用这些性质, 可以得到如下结论。

定理 3.20

$B_{m,-m}(x), \dots, B_{m,n-1}(x)$ 限制到 $[x_0, x_n]$ 上构成样条空间 $S_{m,n}$ 的一组基。



性质 (4) 保证了这 $m+n$ 函数都在线性空间 $S_{m,n}$ 中。这样只需要证明这些函数的线性无关性, 而线性无关性的证明并不显然, 通常需要借用 Curry-Schoenberg 定理, 而这一定理的证明则需要采用下面给出 B 样条函数的另一种构造方法: 差分方法。

我们通过对截断多项式函数进行差分, 从上而下的构造。固定 x , 令 $g(t) = (t-x)_+^{k-1}$, 然后对其做 k 次差分得到

$$\tilde{B}_{k,i}(x) = (x_{i+k} - x_i)g[x_i, \dots, x_{i+k}] = (x_{i+k} - x_i) \sum_{j=0}^k \frac{(x_{i+j} - x)_+^{k-1}}{\prod_{l=0, l \neq j}^k (x_{i+j} - x_{i+l})}.$$

显然这是一个样条函数 (因其满足光滑性条件, 且限制在每个小区间内都是多项式)。剩下的任务是证明 $\tilde{B}$ 和 B 其实是一样的函数, 而这一点仅需要说明 $\tilde{B}_{k,i}$ 也满足自下而上的递推公式(3.66)即可。为了证明这一事实, 我们通过归纳法先去验证差商的 Leibniz 公式:

$$f = gh \Rightarrow f[x_0, \dots, x_n] = \sum_{j=0}^n g[x_0, \dots, x_j]h[x_j, \dots, x_n].$$

下面注意到 $g = g_k = g_{k-1} \times (t-x)$ 并对其利用 Leibniz 公式, 注意到一次多项式只有一次差商非零, 于是

$$g[x_i, \dots, x_{i+k}] = h[x_i, \dots, x_{i+k-1}] + h[x_i, \dots, x_{i+k}](x_{i+k} - x), \quad (3.68)$$

通过整理就可以验证 $\tilde{B}_{k,i}$ 满足递推公式(3.66), 最后反向应用(3.66)并归纳至 $m=0$ 可以得到此时 $B_{0,i}$ 在每个小区间内为常数 1, 这就说明了 $\tilde{B}_{k,i} = B_{k,i}$ 。这样就证明了 Curry-Schoenberg 定理, 于是我们可以得到 $B_{k,i}$ 的线性无关性。

最后我们考虑等距节点的情况。由于等距节点下节点具备平移不变性, 所以我们用 $B_i(x)$ 来表示 i -次的基准样条, 一般的基函数可以该基函数进行平移得到。令 0 次 B 样条为

$$B_0(x) := \begin{cases} 1 & |x| \leq 0.5, \\ 0 & |x| > 0.5. \end{cases}$$

然后利用递归的方法进行定义

$$B_{m+1}(x) := \int_{x-\frac{1}{2}}^{x+\frac{1}{2}} B_m(y) dy, \quad x \in \mathbb{R}, \quad m = 0, 1, \dots \quad (3.69)$$

容易看出, $B_m(x)$ 是一个 $m-1$ 次连续可微的、非负的、具有紧支集 $[-\frac{m}{2} - \frac{1}{2}, \frac{m}{2} + \frac{1}{2}]$ 的一组

函数, 且在任何一个子区间 $[i, i+1]$ (m 为奇) 或 $[i - \frac{1}{2}, i + \frac{1}{2}]$ (m 为偶) 上退化为多项式。按照上述递归的方法, 我们可以得到几个低次的 B 样条函数

$$B_1(x) = \begin{cases} 1 - |x| & |x| \leq 1, \\ 0 & |x| > 1, \end{cases}$$

$$B_2(x) = \frac{1}{2} \begin{cases} 2 - (|x| - 0.5)^2 - (|x| + 0.5)^2 & |x| \leq 0.5, \\ (|x| - 1.5)^2 & 0.5 \leq |x| \leq 1.5, \\ 0 & |x| \geq 1.5, \end{cases}$$

$$B_3(x) = \frac{1}{6} \begin{cases} (2 - |x|)^3 - 4(1 - |x|)^3 & |x| \leq 1, \\ (2 - |x|)^3 & 1 \leq |x| \leq 2, \\ 0 & |x| \geq 2. \end{cases}$$

这些样条函数的图像见图 3.11.




图 3.11: B 样条函数图像.

在一般节点上我们没有详细给出 B 样条函数线性无关的证明, 对于等距节点, 我们可以给出一个简略的证明。

定理 3.21

$m \in \mathbb{N} \cup \{0\}$, B-样条函数

$$B_m(x - k), \quad k = 0, \dots, m \quad (3.70)$$

在区间 $I_m := [\frac{m-1}{2}, \frac{m+1}{2}]$ 上线性无关。



证明 主要采用归纳法进行证明。 $m = 0, 1$ 时, 显然成立。假设对 $m - 1$ ($m \geq 2$) 也成立, 令

$$\sum_{k=0}^m \alpha_k B_m(x - k) = 0, \quad \forall x \in I_m. \quad (3.71)$$

由(3.69)知道, $B_m(x)$, $m \geq 2$ 是可导的, 对(3.71)求导得

$$\sum_{k=0}^m \alpha_k [B_{m-1}(x - k + \frac{1}{2}) - B_{m-1}(x - k - \frac{1}{2})] = 0, \quad x \in I_m.$$

注意到, $\text{supp}\{B_m(x)\} = [-1 - \frac{m}{2}, 1 + \frac{m}{2}]$, $\{B_{m-1}(x + \frac{1}{2})\} \cap \{B_{m-1}(x - m - \frac{1}{2})\} = \emptyset$, 故(3.71)可以进一步化简为

$$\sum_{k=1}^m [\alpha_k - \alpha_{k-1}] B_{m-1}(x - k + \frac{1}{2}) = 0, \quad x \in I_m$$

由归纳假设知 $\alpha_k = \alpha_{k-1}$, $\forall k = 1, \dots, m$ 。于是(3.71)化简为

$$\alpha_0 \sum_{k=1}^m B_m(x - k) = 0, \quad x \in I_m$$

等式两边在 I_m 上积分得

$$\alpha \int_{-\frac{m}{2}-\frac{1}{2}}^{\frac{m}{2}+\frac{1}{2}} B_m(x) dx = 0$$

由 $B_m(x)$ 的非负性得到 $\alpha_0 = 0$, 这也意味着 $\alpha_k = 0$, $k = 0, \dots, m$ 。

推论 3.2

考虑区间 $[a, b]$ 上的等距插值。记 $x_k = a + hk$, $k = 0, \dots, n$ 为 $n(n \geq 2)$ 个插值节点; $m = 2l - 1$, 则

$$B_{m,k}(x) := B_m(\frac{x - a - hk}{h}), \quad x \in [a, b], \quad k = -l + 1, \dots, n + l - 1 \quad (3.72)$$

构成了 $S_{m,n}$ 中的一组基。



这个推论给我们提供了另一种求解样条插值的新思路, 即以 B 样条为基底, 通过插值条件构造方程组找到 B 样条的系数。下面我们以 $m = 3$, 即三次样条函数为例。由 $B_3(x)$ 的定义知道

$$B_3(0) = 0, \quad B_3(\pm 1) = \frac{1}{6}, \quad B'_3(0) = 0, \quad B'_3(\pm 1) = \mp \frac{1}{2}$$

那么, 利用定理3.18和推论3.2, 三次样条函数必定可以写成

$$s(x) = \sum_{k=-1}^{n+1} \alpha_k B_3(\frac{x - x_k}{h}), \quad x \in [a, b] \quad (3.73)$$

将(3.63)带入得:

$$\begin{aligned} -\frac{1}{2}\alpha_{-1} + \frac{1}{2}\alpha_1 &= h\alpha_1, \\ \frac{1}{6}\alpha_{j-1} + \frac{2}{3}\alpha_j + \frac{1}{6}\alpha_{j+1} &= y_j, \quad j = 0, \dots, n \\ -\frac{1}{2}\alpha_{n-1} + \frac{1}{2}\alpha_{n+1} &= hb_1 \end{aligned} \quad (3.74)$$

将方程组写成矩阵-向量形式

$$\begin{pmatrix} -\frac{1}{2} & 0 & \frac{1}{2} & 0 & \cdots & 0 \\ \frac{1}{6} & \frac{2}{3} & \frac{1}{6} & 0 & \cdots & 0 \\ 0 & \frac{1}{6} & \frac{2}{3} & \frac{1}{6} & \cdots & 0 \\ 0 & 0 & \frac{1}{6} & \frac{2}{3} & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & \cdots & \frac{1}{2} \end{pmatrix} \begin{pmatrix} \alpha_{-1} \\ \alpha_0 \\ \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_{n+1} \end{pmatrix} = \begin{pmatrix} ha_1 \\ y_0 \\ y_1 \\ y_2 \\ \vdots \\ hb_1 \end{pmatrix} \quad (3.75)$$

系数矩阵是一个不可约且对角占优的，故可以通过求解方程组得到系数从而完成 B 样条的估计。

3.7 知识拓展

采用多项式去近似函数的思想可以追溯到 Weierstrass 第一逼近定理，即任意连续函数可以被多项式近似，且近似的程度可以任意小，用定理描述如下。

定理 3.22 (Weierstrass 第一逼近定理)

令 $f(x) \in C[a, b]$ ，则 $\forall \epsilon > 0$ ，我们都能够找到一个合适的多项式 p_{n_ϵ} ，使得

$$\|f(x) - p_{n_\epsilon}(x)\|_{C[a,b]} \leq \epsilon.$$



Weierstrass 第一逼近定理仅仅给出了多项式近似的可能性，并没有给出构造方式，也没有说明这样的近似多项式是否一定为插值多项式。下面的 Marcinkiewicz 定理则说明了我们可以把多项式限制为插值多项式，即

推论 3.3 (Marcinkiewicz)

对于任意连续函数，和任意正常数 ϵ ，存在 n 和插值节点 $\{x_n\}$ ，使得其插值多项式 p_n 满足： $\|p_n - f\|_{C[a,b]} \leq \epsilon$ 。



这个推论的证明需要用到最佳一致逼近的结果，我们将把证明留到多项式最佳一致逼近的章节中再次说明。

在关于 Lagrange 插值的稳定性讨论中，我们知道当插值点取成等距节点的时候，多项式插值的稳定性具有很大的问题，但是如果取成精心设计的非等距节点（例如 Chebyshev 点），在被插值函数具有一定的光滑性时，可以有效的避免 Runge 现象和 Lebesgue 常数带来的数值不稳定性。在数学的逼近性理论上来看（即不考虑浮点误差），Chebyshev 节点插值对于 C^1 的函数具有最大模意义下的收敛性，参考定理 3.8。但是如果我们把被插值函数放大到所有的连续函数，则不会有统一的收敛性结论，这一点可以从下面的 Faber 定理得到。

定理 3.23 (Faber)

对于任意给定的序列点 $\{x_j^n\}_{j=0}^n, n = 1, 2, \dots$, 都存在一个连续函数 $f(x)$, 使得插值多项式 $p_n(x)$ 在无穷模的意义下不会收敛到 $f(x)$, 即

$$\limsup \|f(x) - p_n(x)\|_{C[a,b]} > 0.$$



这个定理是泛函分析中共鸣定理和插值算子下界估计的推论, 证明超出本书的范围。

最后我们考虑 Lebesgue 常数带来的数值不稳定性。定理 3.9 给出了 Chebyshev 节点的 Lebesgue 常数的估计, 而关于 Lebesgue 常数还有下面一些非常精细的结论, 从这些结论中我们可以发现 Chebyshev 节点几乎取到了最小的 Lebesgue 常数。

定理 3.24 (Lebesgue 常数的估计)

给定区间 $I = [-1, 1]$, 我们将插值点限制在区间上, 则有

- 任给 I 上的 $n+1$ 个点构成插值点集合 X , 有 $\Lambda(X) \geq \frac{2}{\pi} \log(n+1) + C$, 其中 $C = \frac{2}{\pi} (r + \log \frac{4}{\pi})$, r 为 Euler 常数 $r \approx 0.577$ 。
- 对于 $(n+1)$ 个 Chebyshev 点构成 X 有 $\Lambda(X) \leq \frac{2}{\pi} \log(n+1) + 1$ 。
- 对于 I 上 $(n+1)$ 个等距节点构成 X 有 $\Lambda(X) \sim \frac{2^{n+1}}{en \log n}$ 。



第 3 章 练习

1. 已知函数 $P(x) = \frac{1}{2}x^2 - \frac{1}{2}x + 1$, 请利用 Lagrange 插值公式找到点 $(0, 1)$, $(2, 2)$ 和 $(3, 4)$ 的插值多项式. (可以检查与真实函数 $P(x)$ 是否一致)
2. 试证明多项式插值的唯一性: 令 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ 是平面中的 n 个点, 具有不同的 x_i 坐标, 则存在一个并且仅有一个 $n-1$ 次或者更低次的多项式 P 满足 $P(x_i) = y_i$, 对任意 $\forall i = 1, 2, \dots, n$. (提示: 代数的基本定理表明, 一个 d 次多项式最多具有 d 个过零点, 除非它本身就是恒等于零。)
3. 使用差商找出经过三个点 $(0, 1)$, $(2, 2)$ 和 $(3, 4)$ 的插值多项式. (可以检查与第一题中真实函数 $P(x)$ 是否一致)
4. 有多少个 d 阶多项式经过 $(-1, -5)$, $(0, -1)$, $(2, 1)$, $(3, 11)$? 请对于 $d = 3, 4, 5$ 分别进行讨论。
5. 对区间 $[-1, 1]$ 均匀分布点集和切比雪夫点集进行插值 $f(x) = 1/(1 + 12x^2)$ 。
6. 给定 $f(x) = x^{3/2}$, $x_0 = 1/4$, $x_1 = 1$, $x_2 = 9/4$, 试求三次 Hermite 插值多项式, 并求出余项表达式。

第4章 多项式逼近

回顾我们引入多项式插值的初衷，是希望用一些简单的函数如多项式或分片多项式去替代复杂的函数。上一章我们主要关注（分片）多项式插值，即要求所使用的简单函数能够精确经过每一个插值点。但是在实际问题中，这么做有几个明显的困难，首先插值点是通过测量得到的，而测量并不一定能够保证足够的精度，如何在不够精确的测量下还能找到相对精确的替代函数是一个不显然的问题（当然如果对测量误差不加任何假设，在最坏的情况下，再多不精确的测量也不能得到更加精确的结果，但是如果对误差有一定的假设，的确有可能从不精确的多次测量中得到高概率下更为精确的估计结果，参考多次测量长度求平均）；其次如果大量获得数据是容易的，但是全部数据用来插值就意味着替代函数空间维度很大，甚至维度比我们所期待的简单函数空间要大得多，这样在有测量误差的情况下不一定能够保证替代函数是一个好的选择（特别的插值点无法指定的时候，越多插值点通常意味着更大的 Lebesgue 常数，导致微小的测量误差甚至浮点误差会造成巨大的扰动）。另外在理论上多项式插值随着插值点的增加并不能保证误差的减少（取决于插值点的分布），特别的如果插值点是均匀排布的话，随着插值点的增加，误差反而可能快速发散，并且微小的扰动会被指数级放大。

为了避免多项式插值从理论、计算到实际应用中的障碍，这一节我们将探讨另外一种使用多项式函数替代复杂函数的方法：多项式逼近。具体而言，就是在多项式空间中，找到如下最小化问题的解。

$$\min_{p \in \mathbb{P}_n} \text{dist}(f, p),$$

其中 $\text{dist}(f, p)$ 是某种度量多项式 p 和复杂函数 f 之间距离的方法。很明显，不同的距离会给出截然不同的逼近多项式。本书中主要考虑三种不同的度量方法，分别是

- (1) $\text{dist}(f, p) = \|f - p\|_{C[a, b]}$ ，这里要求 $f \in C[a, b]$ 。这种度量方式下的逼近方法我们称为最佳一致逼近。
- (2) $\text{dist}(f, p) = \int_a^b \omega(x) |f(x) - p(x)|^2 dx$ ，这时候只需要 f 具有微弱的正则性（平方可积），在这种度量下我们称为最佳平方逼近。
- (3) $\text{dist}(f, p) = \sum_{i=1}^N w_i |f(x_i) - p(x_i)|^2$ ，这时候只需要 f 能够在给定的点集 $\{x_i\}_{i=1}^N$ 上进行测量，在这种度量下我们称为离散最佳平方逼近。

当然度量的方法有很多，例如使用绝对值积分或者其离散形式，在工程应用中，可以根据应用目标的不同而进行调整。在谈到多项式逼近的概念时，我们首先需要定义距离，接下来将从函数空间的度量入手，引出正交多项式的概念。

4.1 正交多项式

在引入正交多项式的定义之前，我们先回顾一下线性空间中范数和内积的定义。

定义 4.1

设 V 是数域 $\mathbb{R}$ (或 $\mathbb{C}$, 简单起见我们将考虑 $\mathbb{R}$) 上的向量空间, $\|\cdot\|$ 是 V 上的实值函数, 若任取 $x, y \in V$ 及 $k \in \mathbb{R}$, 满足以下三个条件:

- 正定性: $\|x\| \geq 0$, $\|x\| = 0$ 当且仅当 $x = 0$;
- 正齐性: $\|kx\| = |k|\|x\|$;
- 三角不等式: $\|x + y\| \leq \|x\| + \|y\|$,

则称 $\|\cdot\|$ 是 V 上的范数, 并称 $(V, \|\cdot\|)$ 为赋范线性空间。



范数给了线性空间 V 的拓扑结构, 这样可以在线性空间 V 中考虑类似极限、连续等分析的概念; 下面定义的内积则进一步给出线性空间中的几何结构。

定义 4.2

设 V 是数域 $\mathbb{R}$ 上的向量空间, 若映射 $\langle \cdot, \cdot \rangle : V \times V \rightarrow \mathbb{R}$ 满足:

- 正定性: $\langle v, v \rangle \geq 0$, 其为 0 当且仅当 $v = 0$;
- 线性性: 对任意固定 $x, y, z \in V, \alpha, \beta \in \mathbb{R}$, 有 $\langle \alpha x + \beta y, z \rangle = \alpha \langle x, z \rangle + \beta \langle y, z \rangle$;
- 对称性: 任取 $x, y \in V$, 成立 $\langle x, y \rangle = \langle y, x \rangle$,

则称 $\langle \cdot, \cdot \rangle$ 为 V 上的内积, 并称赋予内积的向量空间 V 为内积空间。



我们需要注意, 如果数域为复数 $\mathbb{C}$, 则第三条对称性需要修改为共轭对称, 即 $\langle x, y \rangle = \langle y, x \rangle^*$, 其中 $*$ 表示复共轭。向量空间的内积和范数之间存在一定的联系, 具体而言内积一定可以诱导出范数, 而范数满足一定的条件可以定义内积, 即如下定理。

性质 设 V 是一个内积空间, $x \in V$, 则 $\rho(x) = \sqrt{\langle x, x \rangle}$ 是 V 上的一个范数, 称其为内积诱导出的范数。反之如果范数 $\|\cdot\|$ 满足平行四边形法则:

$$\|x + y\|^2 + \|x - y\|^2 = 2(\|x\|^2 + \|y\|^2), \quad \forall x, y \in V,$$

则下面的公式也定义了一个内积: 对于任意的 $x, y \in V$,

$$\langle x, y \rangle = \frac{1}{2}(\|x + y\|^2 - \|x\|^2 - \|y\|^2).$$

证明 这些性质可以由内积和范数的定义证明出来, 我们先证明 $\rho(x) = \sqrt{\langle x, x \rangle}$ 定义了 V 上的一个范数。正定性、正齐性是显然的, 下面证明三角不等式。对于任意的 $x, y \in V$,

$$\begin{aligned} \rho(x + y)^2 &\leq (\rho(x) + \rho(y))^2 &\Leftrightarrow \langle x + y, x + y \rangle &\leq \langle x, x \rangle + \langle y, y \rangle + 2\rho(x)\rho(y) \\ &&\Leftrightarrow |\langle x, y \rangle| &\leq \rho(x)\rho(y) \\ &&\Leftrightarrow \langle x, y \rangle^2 &\leq \langle x, x \rangle \langle y, y \rangle. \end{aligned}$$

最后一个不等式就是著名的 Cauchy-Schwarz 不等式, 可以通过辅助函数 $g(t) = \langle x + ty, x + ty \rangle$ 的判别式非负得到。简单计算可以发现由内积所诱导出来的范数一定满足平行四边形法则, 我们下面证明其反面也成立, 即 $\langle x, y \rangle = \frac{1}{2}(\|x + y\|^2 - \|x\|^2 - \|y\|^2)$ 给出了一个内积。正定性和对称性都是显然的, 我们还需要证明线性性。由平行四边形法则我们发现 $\langle x, y \rangle = \frac{1}{4}(\|x + y\|^2 -$

$\|x - y\|^2$)。于是对于任意的 x, y, z ,

$$\langle x + y, z \rangle = \frac{1}{4}(\|x + y + z\|^2 - \|x + y - z\|^2),$$

$$\langle x, z \rangle + \langle y, z \rangle = \frac{1}{4}(\|x + z\|^2 - \|x - z\|^2 + \|y + z\|^2 - \|y - z\|^2).$$

分别对向量组 $(x + z, y), (x - z, y), (y + z, x), (y - z, x)$ 应用平行四边形法则得到

$$\|x + y + z\|^2 + \|x - y + z\|^2 = 2(\|x + z\|^2 + \|y\|^2),$$

$$\|x + y - z\|^2 + \|x - y - z\|^2 = 2(\|x - z\|^2 + \|y\|^2),$$

$$\|x + y + z\|^2 + \|x - y - z\|^2 = 2(\|y + z\|^2 + \|x\|^2),$$

$$\|x + y - z\|^2 + \|x - y + z\|^2 = 2(\|y - z\|^2 + \|x\|^2).$$

用上面的第一、三行两个等式相加减去第二、四行两个等式就得到了

$$\langle x + y, z \rangle = \langle x, z \rangle + \langle y, z \rangle.$$

还需要证明 $\langle \alpha x, y \rangle = \alpha \langle x, y \rangle$, 这个证明需要用到实数的构造和范数的连续性: 即按照顺序证明 α 为正整数、整数、有理数、实数时成立, 具体过程留给读者作为练习。

当给向量空间 V 定义了内积以后, 就可以引入向量的夹角, 即两个向量 x, y 的夹角 $\theta = \arccos \frac{\langle x, y \rangle}{\|x\| \|y\|}$, 并可以讨论向量的正交性 (即夹角为 $\frac{\pi}{2}$)。

我们本章所考虑的逼近函数类仍然是多项式, 然而就像我们在插值中提到的那样, 多项式空间中的自然基底 $(\{1, x, x^2, \dots\})$ 高度线性相关, 从而导致数值计算的不稳定性。因此为了提高数值稳定性并便于计算, 我们需要引入正交多项式。特别的我们后面的最佳平方逼近中可以看到, 通过引入正交多项式基底, 那么在区间 $[a, b]$ 内, 在比较微弱的条件下 $f(x)$ 可表示为某一正交多项式序列的线性组合, 即 $f(x) = \sum_{n=0}^{\infty} a_n \phi_n(x)$, 其中 $\phi_n(x)$ 为该正交多项式序列中的第 n 个多项式。那么我们可以通过计算 a_n 并进行有限项截断来逼近 $f(x)$ 。

正交多项式基底, 它们是一类非常特殊且重要的多项式函数, 在物理学、工程学、计算机科学等领域都有广泛的应用。在给出正交多项式的定义和构造方法之前, 我们首先定义多项式空间中的 (加权) 内积和范数, 注意到这样的内积和范数可以延拓到更加广泛的函数空间中。为了方便起见, 假设我们已经有了一个非负、可积且具有有限零点的权函数 $\omega(x)$ (如一个典型的权函数为常数 1)。然后我们定义如下的带权内积和带权范数:

定义 4.3

考虑区间 (a, b) 上的权函数 $\omega(x)$, 则对于任意两个多项式函数 $f, g \in \mathbb{P}_n$, 定义它们的带权内积为

$$\langle f, g \rangle_{\omega} := \int_a^b \omega(x) f(x) g(x) dx.$$

进一步, 定义带权 L_{ω}^2 范数为

$$\|f\|_{L_{\omega}^2} = \langle f, f \rangle_{\omega}^{\frac{1}{2}} = \sqrt{\int_a^b \omega(x) f(x) f(x) dx}.$$



不难验证 $\langle f, g \rangle_{\omega}$ 给出了多项式空间 $\mathbb{P}_n$ 上的一个内积, 在这一内积下我们可以定义多项

式函数的正交性：

定义 4.4

我们称两个函数 $f, g \in \mathbb{P}_n$ 是正交的，当且仅当它们的带权内积为零，即

$$\langle f, g \rangle_\omega = 0.$$



在一般的向量空间 V 中，如果给定一组基底 $\{v_i\}_{i=1}^n$ ，Grad-Schmidt 正交化过程如下

$$\begin{aligned}\phi_1 &= v_1, \\ \phi_2 &= v_2 - \frac{\langle v_2, \phi_1 \rangle}{\langle \phi_1, \phi_1 \rangle} \phi_1, \\ \phi_s &= v_s - \sum_{i=1}^{s-1} \frac{\langle v_s, \phi_i \rangle}{\langle \phi_i, \phi_i \rangle} \phi_i, \quad s = 2, 3, \dots, n.\end{aligned}$$

如果 $\{v_i\}_{i=1}^n$ 是线性无关的，则 Grad-Schmidt 正交化过程是有意义的，而且可以很容易验证所产生的向量组 $\{\phi_i\}_{i=1}^n$ 有如下特性

$$\langle \phi_i, \phi_j \rangle = 0, \quad \forall i \neq j,$$

$$\text{span}\{\phi_1, \dots, \phi_s\} = \text{span}\{v_1, \dots, v_s\}.$$

对于多项式函数空间而言，有一组自然的单项式基底 $\{1, x, \dots, x^n\}$ ，从这一组基底出发，通过 Grad-Schmidt 正交化过程，可以很容易产生一组新的正交基底 $\{p_i\}_{i=0}^n$ ，下面我们来详细说明这组正交多项式基底的基本性质。

定理 4.1

对于给定的权函数 $\omega(x)$ ，Grad-Schmidt 正交化过程所产生的正交多项式 $p_n(x)$ 具有如下性质：

1. $p_n(x)$ 的首项系数为一， $\text{span}\{p_0, \dots, p_n\} = \mathbb{P}_n$ ，且 $\langle p_n, q_{n-1} \rangle = 0$ ，其中 $q_{n-1} \in \mathbb{P}_{n-1}$ 为任意次数不超过 $n-1$ 的多项式。
2. $p_{-1}(x) = 0, p_0(x) = 1$ ，对于 $n \geq 0$ ，有三项递推公式

$$p_{n+1}(x) = (x - \alpha_n)p_n(x) - \beta_n p_{n-1}(x),$$

其中 $\alpha_n = \frac{\langle xp_n, p_n \rangle_\omega}{\langle p_n, p_n \rangle_\omega}, \beta_n = \frac{\langle p_n, p_n \rangle_\omega}{\langle p_{n-1}, p_{n-1} \rangle_\omega}$ 。

3. $p_n(x)$ 在区间 (a, b) 内有 n 个互不相同的实数根，并且 $p_n(x)$ 和 $p_{n+1}(x)$ 的根交替排列。



证明

- (1) 从 Grad-Schmidt 正交化过程的定义可以直接得到 p_n 是首一多项式，后面的两个结论是显然的。
- (2) 下面证明递推公式。首先 $x p_n(x)$ 是一个 $n+1$ 次多项式，可以表示为

$$x p_n(x) = b_0 p_0(x) + b_1 p_1(x) + \dots + b_{n+1} p_{n+1}(x),$$

注意到首一多项式的性质知 $b_{n+1} = 1$ 。将其与 $p_j (j = 0, \dots, n)$ 做内积得

$$\langle xp_n, p_j \rangle_\omega = b_j \langle p_j, p_j \rangle_\omega \Rightarrow b_j = \frac{\langle xp_n, p_j \rangle_\omega}{\langle p_j, p_j \rangle_\omega}.$$

当 $j = 0, \dots, n-2$ 时:

$$\langle xp_n, p_j \rangle_\omega = \langle p_n, xp_j \rangle_\omega = 0;$$

当 $j = n-1$ 时, xp_{n-1} 可表示为 $\sum_{i=0}^{n-1} b'_i p_i + p_n$, 从而

$$\langle xp_n, p_{n-1} \rangle_\omega = \langle p_n, xp_{n-1} \rangle_\omega = \langle p_n, p_n \rangle_\omega.$$

于是有

$$xp_n(x) = \frac{\langle p_n, p_n \rangle_\omega}{\langle p_{n-1}, p_{n-1} \rangle_\omega} p_{n-1}(x) + \frac{\langle xp_n, p_n \rangle_\omega}{\langle p_n, p_n \rangle_\omega} p_n(x) + p_{n+1}(x).$$

整理即得

$$p_{n+1}(x) = \left(x - \frac{\langle xp_n, p_n \rangle_\omega}{\langle p_n, p_n \rangle_\omega}\right) p_n(x) - \frac{\langle p_n, p_n \rangle_\omega}{\langle p_{n-1}, p_{n-1} \rangle_\omega} p_{n-1}(x).$$

(3) 由于 $p_n \perp p_0$, 则有

$$\int_a^b \omega(x) p_n(x) dx = 0.$$

因此 $p_n(x)$ 至少有一个实根。假设 $p_n(x)$ 在 (a, b) 上有 k 个实根, 则有

$$p_n(x) = (x - x_1) \cdots (x - x_k) g_{n-k}(x),$$

其中 $g_{n-k}(x)$ 在 (a, b) 上不变号。若 $k < n$, 则 $p_n \perp (x - x_1) \cdots (x - x_k) \in \mathbb{P}_k$, 即

$$\int_a^b \omega(x) (x - x_1)^2 \cdots (x - x_k)^2 g_{n-k}(x) dx = 0.$$

因此, $\omega(x) (x - x_1)^2 \cdots (x - x_k)^2 g_{n-k}(x) \equiv 0$, 产生矛盾, 则 $k = n$ 。

下证 p_n 的根互不相同。设 $p_n = (x - x_1)^2 (x - x_3) \cdots (x - x_n)$, 其中 x_1 为重根, 有 $p_n \perp (x - x_3) \cdots (x - x_n)$ 。由内积定义知

$$\int_a^b \omega(x) (x - x_1)^2 (x - x_3)^2 \cdots (x - x_n)^2 dx = 0.$$

但这与 $\omega(x)$ 的正性矛盾, 因此 p_n 的根互不相同。

接下来我们证明根相间性质。首先我们考虑 p_2 和 p_1 的根相间性质。由于 p_1 的根是单根, 即只有一个实根 $x_{1,1}$, 所以我们要验证 p_2 的实根只能在 $x_{1,1}$ 两侧, 记为 $x_{2,1} < x_{2,2}$ 。根据三项递推公式, p_2 在 $x_{1,1}$ 处的取值为

$$p_2(x_{1,1}) = -\beta_1 p_0(x_{1,1}) < 0,$$

而 $p_2(b) > 0$, 因此

$$x_{2,1} < x_{1,1} < x_{2,2},$$

即 p_2 的两个实根在 $x_{1,1}$ 两侧。接着我们考虑 p_3 和 p_2 的根相间性质。我们需要证明 p_3 的三个实根依次交替出现在 p_2 的两个实根之间, 记为 $x_{3,1} < x_{3,2} < x_{3,3}$ 。

注意到 p_1 在区间 $(x_{1,1}, b], [a, x_{1,1})$ 上分别取 $+, -$ 符号, 以及三递推公式和 $x_{2,1} < x_{1,1} <$

$x_{2,2}$ 的性质, 我们有 p_3 在 $x_{2,1}$ 处的取值为

$$p_3(x_{2,1}) = -\beta_2 p_1(x_{2,1}) > 0,$$

同样地 p_3 在 $x_{2,2}$ 处的取值为

$$p_3(x_{2,2}) = -\beta_2 p_1(x_{2,2}) < 0,$$

从而我们得到

$$x_{3,1} < x_{2,1} < x_{3,2} < x_{2,2} < x_{3,3}.$$

并且可以同时得到 $(x_{2,2}, b], (x_{2,1}, x_{2,2})[a, x_{2,1})$ 上取符号分别为 $+, -, +$ 。

由下图可以理解证明思路:

	-		$x_{1,1}$		+
p_1					
	+		$x_{2,1}$		+
p_2					
	-	$x_{3,1}$		$x_{3,2}$	-
p_3					
	+	-	+	-	+
p_4					

在接下来验证第 n 项的情况时, 我们可以使用类似的方法进行分析, 使用归纳法同时验证根的交错性质以及如下特性: $p_n(x)$ 在区间 $(x_{n,n}, b], (x_{n,n-1}, x_{n,n}), \dots, [a, x_{n,1})$ 上分别取 $+, -, +, \dots$ 的符号。

综上所述我们证明了正交多项式的主要基本性质: 递推关系以及实根互异和根的交替性。

下面给出一些常用的正交多项式。

Legendre 多项式 当把区间选为 $[-1, 1]$, 权函数 $\rho(x) = 1$, 所对应的正交多项式就是 Legendre 多项式, 它是最常见的正交多项式之一, 可以表示为:

$$L_k = \frac{1}{2^k} \sum_{j=0}^{\lfloor k/2 \rfloor} (-1)^j C_k^j C_{2k-2j}^k x^{k-2j} = \frac{1}{2^k k!} \frac{d^k (x^2 - 1)^n}{dx^n}$$

其中 C_k^j 表示组合数。Legendre 多项式对应的三递推公式为

$$L_{k+1} = \frac{2k+1}{k+1} x L_k - \frac{k}{k+1} L_{k-1}, \quad L_0 = 1, L_1 = x.$$

Legendre 多项式的内积为 $\langle L_k, L_m \rangle_\omega = \delta_{km} \frac{1}{k+1/2}$, 其中 δ_{km} 为 Kronecker 记号, 当 $k = m$ 时为 1, 否则为 0。另外从 Legendre 多项式的定义可以看出其首项系数为 $\frac{1}{2^n} C_{2n}^n$ 。

Chebyshev 多项式 当区间选为 $[-1, 1]$, 权函数 $\rho(x) = \frac{1}{\sqrt{1-x^2}}$ 时, 所得到的正交多项式就是 Chebyshev 多项式。它是定义在 $[-1, 1]$ 上的另一类常见的正交多项式, 我们前面所提到的 Chebyshev 节点和 Chebyshev 多项式有着密切的联系。Chebyshev 多项式可以表示为:

$$T_k(x) = \cos k \arccos x$$

同样的, Chebyshev 多项式对应的三项递推公式如下:

$$T_{k+1} = 2xT_k - T_{k-1}, \quad T_0 = 1, T_1 = x.$$

Chebyshev 多项式的首项系数为 2^{n-1} , 且有如下内积公式:

$$\langle T_n, T_n \rangle_\omega = \begin{cases} \pi/2, & n \neq 0, \\ \pi, & n = 0. \end{cases}$$

在 Chebyshev 多项式中, 注意到 $\|T_n\|_{C[-1,1]} = 1$, 且满足

$$\|2^{1-n}T_n\|_{C[a,b]} = \min_{p \in \mathbb{P}_n^1} \|p\|_{C[-1,1]},$$

其中 $\mathbb{P}_n^1$ 为首一多项式。最后这个性质是最佳一致逼近多项式的充分必要条件(下一节)的简单推论。

注 Legendre 和 Chebyshev 多项式都是 Jacobi 多项式的特例, Jacobi 多项式是权函数 $(1+x)^\alpha(1-x)^\beta$ 对应的正交多项式, 其中 α 和 β 均大于 -1 。当 $\alpha = \beta = 0$ 时, Jacobi 多项式就是 Legendre 多项式; 当 $\alpha = \beta = -1/2$ 时, Jacobi 多项式就是 Chebyshev 多项式。Jacobi 多项式在物理学、概率论、逼近论等领域都有广泛的应用。

Laguerre 多项式 当区间选为 $[0, +\infty)$, 权函数 $\rho(x) = e^{-x}$ 时, 所得到的正交多项式称为 Laguerre 多项式:

$$L_k(x) = \frac{e^x}{k!} \frac{d^k}{dx^k} (e^{-x} x^k).$$

Laguerre 多项式的正交性如下式:

$$\int_0^\infty e^{-x} L_i(x) L_j(x) dx = \delta_{i,j}.$$

Laguerre 多项式满足三项递推公式如下:

$$L_{k+1}(x) = (2k+1-x)L_k(x) - k^2 L_{k-1}(x) \quad L_0 = 1, L_1 = 1-x.$$

Laguerre 可以用于半无界区域上的积分估计, 并且在物理、统计等多个领域广泛应用。如它们在氢原子的量子力学模型中起到了重要作用; 在统计学中, Laguerre 多项式用于描述泊松分布和指数分布, 在应用概率论和数理统计中, Laguerre 多项式用于生成随机变量, 其中生成的随机变量具有指数分布或者在高斯过程中被用作核函数。

Hermite 多项式 当区间选为 $(-\infty, +\infty)$, 权函数 $\rho(x) = e^{-x^2}$ 时, 所得到的正交多项式称为 Hermite 多项式:

$$H_k(x) = (-1)^k e^{x^2} \frac{d^k}{dx^k} e^{-x^2}.$$

Hermite 多项式的正交性条件如下式:

$$\int_{-\infty}^\infty e^{-x^2} H_i(x) H_j(x) dx = \delta_{i,j} 2^n n! \sqrt{\pi}.$$

Hermite 多项式的三项递推公式如下:

$$H_{k+1}(x) = 2xH_k(x) - 2kH_{k-1}(x) \quad H_0 = 1, H_1 = 2x.$$

Hermite 多项式也有着广泛的应用，如在量子力学中是调和振动子的能量本征态；在概率论和统计学中也有着广泛的应用，它们可以用于描述正态分布的概率密度函数。

4.2 最佳一致逼近

这一节中我们考虑度量为 $\text{dist}(f, p) = \|f - p\|_{C[a, b]}$ ，即使用多项式函数一致的逼近一个连续函数，称其为最佳一致逼近。按照连续函数范数的定义，我们可以将最佳一致逼近重新改写为

$$\min_{p \in \mathbb{P}_n} \max_{x \in [a, b]} |f(x) - p(x)|.$$

在这种记号下，很明显最佳一致逼近问题也可以看成 *minimax* 问题。

4.2.1 最佳一致逼近的存在唯一性

对于最佳一致逼近问题，我们需要讨论这个问题在数学上时候有定义（解是否存在），解是否唯一，如何刻画或者求解它？我们首先考虑最佳一致逼近问题的存在性，即是否存在一致最佳逼近多项式 $p_n^* \in \mathbb{P}_n$ ，使得

$$\max_{x \in [a, b]} |p_n^*(x) - f(x)| = \inf_{p \in \mathbb{P}_n} \max_{x \in [a, b]} |f(x) - p(x)|.$$

沿着一般优化问题解存在性的证明思路，这个问题的答案是肯定的。

引理 4.1

（多项式最佳一致逼近的存在性）对于任意的连续函数 $f(x) \in C[a, b]$ ，在 $\mathbb{P}_n$ 上存在一致最佳逼近函数 p_n^* ，即

$$\|f - p_n^*\|_{C[a, b]} = \inf_{p \in \mathbb{P}_n} \|f - p\|_{C[a, b]}.$$



证明 定义最小偏差为 $E_n^* = \inf_{p \in \mathbb{P}_n} \max_{x \in [a, b]} |f(x) - p(x)|$ ，我们要证明存在 $p_n^* \in \mathbb{P}_n$ ，使得 $\max_{x \in [a, b]} |p_n^*(x) - f(x)| = E_n^*$ 。由 E_n^* 的定义可知，对于任意的 $\epsilon^k \rightarrow 0^+$ ，存在 $g^k(x) \in \mathbb{P}_n$ ，使得

$$E_n^* \leq \max_x |f(x) - g^k(x)| \leq E_n^* + \epsilon^k.$$

对于任意的 $g(x) = \sum_{i=0}^n c_i x^i$ ，我们可以定义 $\|g(x)\| = \sqrt{\sum_{i=0}^n c_i^2}$ ，即采用 $\{c_i\} \in \mathbb{R}^{n+1}$ 的欧几里得范数。不难验证上述定义给出了 $\mathbb{P}_n$ 的一个新的向量范数，注意到 $\mathbb{P}_n$ 是 $n+1$ 维的线性空间，其上的所有范数等价，即最大模范数等价于系数 $\{c_i\}$ 在 $\mathbb{R}^{n+1}$ 中的欧几里得范数。因此 g^k 在无穷范数意义下是有界的序列，同时其单项式系数在欧几里得范数意义下也是有界的序列。由此，根据 Bolzano-Weierstrass 定理，必然存在子列 $g_j^k(x)$ 使得其单项式系数都有极限。将这个极限多项式称为 p_n^* 并再次利用范数的等价性，我们得到 $\|g_j^k - p_n^*\|_{C[a, b]} \rightarrow 0$ 。于是我们有：

$$\|f - p_n^*\|_{C[a, b]} \leq \|f - g_j^k\|_{C[a, b]} + \|g_j^k - p_n^*\|_{C[a, b]} \leq E_n^* + \epsilon_j^k + \|g_j^k - p_n^*\|_{C[a, b]},$$

其中 $\epsilon_j^k \rightarrow 0$ 且 $\|g_j^k - p_n^*\|_{\infty} \rightarrow 0$ 。因此当 $j, k \rightarrow \infty$ 时， $\|f - p_n^*\|_{\infty} \rightarrow E_n^*$ ，定理得证。

最佳一致逼近问题的确有唯一性，但是其唯一性的证明并不简单。而如果将最佳一致逼

近问题看成一个抽象的最优化问题而忽略其多项式的结构，刻画最优解的充分必要性条件将变得非常复杂，也难以设计有效的算法。但是因为所有可能的备选函数为多项式，关于最佳一致逼近就有一个非常优美的结果，可以刻画出最佳一致逼近多项式的充分必要性条件，而且是（理论上）很容易验证的条件：最佳一致逼近的交错点列性质。

定理 4.2 (Chebyshev 震荡定理)

p_n^* 是最佳一致逼近多项式，当且仅当 $f - p_n^*$ 存在至少 $n + 2$ 个等高震荡最值 (Equioscillation) 点（称为交错点组或 alternate）。



首先解释一下 $n + 2$ 个高震荡最值点的数学定义，即如果 $g(x) \in C[a, b]$ 且 $\|g\|_{C[a, b]} = E$ ，则如果存在 $a \leq x_0 < x_1 < \cdots < x_{n+1} \leq b$ 使得 $g(x_i) = \pm(-1)^i E$ ，则称其为高震荡最值点组，公式最前面的 $\pm$ 表示第一个点是最大值点还是最小值点。

证明 首先证明充分性：($\Leftarrow$) 使用反证法进行证明。不失一般性，设 $\{x_i\}_{i=0}^{n+1}$ 为 $f - p_n^*$ 的交错点组。假设 p_n^* 不是最佳一致逼近，不妨设 $q \in \mathbb{P}_n$ 为最佳一致逼近多项式，即有 $\|f - q\|_{C[a, b]} < \|f - p_n^*\|_{C[a, b]}$ 。定义差函数 $g = p_n^* - q$ ，由于 $q \in \mathbb{P}_n$ ，则 $g \in \mathbb{P}_n$ 。

不妨设 $f(x_0) - p_n^*(x_0) = \|f - p_n^*\|_{C[a, b]}$ ，则 $f(x_i) - p_n^*(x_i) = (-1)^i \|f - p_n^*\|_{C[a, b]}$ ，从而

$$g(x_i) = p_n^*(x_i) - q(x_i) = f(x_i) - q(x_i) - (-1)^i \|f - p_n^*\|_{C[a, b]}.$$

于是

$$i \text{ 是偶数: } g(x_i) = -\|f - p_n^*\|_{C[a, b]} - [q(x_i) - f(x_i)] \leq \|f - q\|_{C[a, b]} - \|f - p_n^*\|_{C[a, b]} < 0$$

$$i \text{ 是奇数: } g(x_i) = \|f - p_n^*\|_{C[a, b]} + [q(x_i) - f(x_i)] \geq -\|f - q\|_{C[a, b]} + \|f - p_n^*\|_{C[a, b]} > 0,$$

从而 $\exists x_i^* \in (x_i, x_{i+1})$ ，使得 $g(x_i^*) = 0$ ，其中 $i = 0, \dots, n$ 。因此 $g(x) = 0$ 产生矛盾，由此得证。

接下来证明必要性：($\Rightarrow$) 仍然使用反证法。定义误差函数

$$e(x) = f(x) - p_n^*(x), E = \|f - p_n^*\|_{C[a, b]}.$$

记 $\max_x e(x) = E_1, \min_x e(x) = -E_2$ ，若 $E_1 \neq E_2$ ，不妨令 $E = E_1 > E_2$ ，则我们可以构造 $p(x) = p_n^*(x) + \frac{1}{2}(E_1 - E_2)$ ，其满足

$$\max_x f(x) - p(x) = \frac{1}{2}(E_1 + E_2),$$

$$\min_x f(x) - p(x) = -\frac{1}{2}(E_1 + E_2),$$

可以发现此时 $p(x)$ 是更好的逼近，和 p_n^* 为最佳一致逼近矛盾，因此


$$\max_x f(x) - p_n^*(x) = E$$

$$\min_x f(x) - p_n^*(x) = -E.$$

记

$$\begin{aligned} x_0 &= \arg \min x, \quad s.t. \quad |e(x)| = E, \\ x_1 &= \arg \min(x), \quad s.t. \quad x \geq x_0, e(x) = -e(x_0), \\ &\dots \\ x_i &= \arg \min(x), \quad s.t. \quad x \geq x_{i-1}, e(x) = -e(x_{i-1}). \end{aligned}$$

可得 $x_0 < x_1 < \dots < x_i$, 满足交错点组的性质 (等高震荡最值), 读者可结合如下示意图理解:



不失一般性我们可以假设 $e(x_0) = -E$ 。下证 $i \geq n+1$ 。假设 $i \leq n$, 并且 $\{x : x \geq x_i, e(x) = -e(x_i)\} = \emptyset$ 。我们选取

$$y_i \in [x_{i-1}, x_i], \quad y_i = \arg \max y \quad s.t. \quad e(y) = 0.$$

则可得 $x_0 < y_1 < x_1 < y_2 < x_2 < \dots < y_i < x_i$ 。补充定义 $y_0 = a, y_{i+1} = b$, 并且不妨设 $e(x_0) = -E$ 。则对 $\forall x \in [y_0, y_1]$, $e(x)$ 都没有取到最大值 E 。而 $\forall x \in [y_1, y_2]$, $e(x)$ 都没有取到最小值 $-E$ 。依此思路, 我们可以得到存在 $i+1$ 个正实数 $\epsilon_0, \dots, \epsilon_i$ 满足:

$$\text{偶数项情形: } \forall x \in [y_{2k}, y_{2k+1}], e(x) \leq E - \epsilon_{2k}$$

$$\text{奇数项情形: } \forall x \in [y_{2k-1}, y_{2k}], e(x) \geq -E + \epsilon_{2k-1}.$$

定义 $\omega(x) = (y_1 - x)(y_2 - x) \cdots (y_i - x) \in \mathbb{P}_n$, 只需选择 $p(x) = p^*(x) - t\omega(x) \in \mathbb{P}_n$, 其中

$$t = \frac{\epsilon}{2\|\omega\|_{C[a,b]}}, \quad \epsilon = \min_{0 \leq s \leq i} \epsilon_s.$$

记 $f(x) - p(x)$ 为 $\tilde{e}(x)$, 接下来说明 $p(x)$ 是一个更好的逼近函数。

首先考虑偶数项情形, 由于

$$\forall x \in [y_{2k}, y_{2k+1}], \quad e(x) \leq E - \epsilon_{2k},$$

故

$$\forall x \in [y_{2k}, y_{2k+1}], \quad \tilde{e}(x) \leq E - \epsilon_{2k} + \frac{1}{2}\epsilon \leq E - \frac{1}{2}\epsilon.$$

对 $\forall x \in (y_{2k}, y_{2k+1})$ 有

$$\tilde{e}(x) = e(x) + t \cdot (-1)^{2k} (x - y_1) \cdots (x - y_{2k}) (y_{2k+1} - x) \cdots (y_i - x) > e(x) \geq -E,$$

而 $\tilde{e}(y_{2k}) = e(y_{2k}) = 0$, $\tilde{e}(y_{2k+1}) = e(y_{2k+1}) = 0$, 从而 $\forall x \in [y_{2k}, y_{2k+1}]$ 有 $-E < \tilde{e}(x) < E$ 。


奇数项情形可以完全类似处理, 最终我们发现 $\forall x \in [a, b]$, $-E < \tilde{e}(x) < E$ 。

综上所述, 我们最终得到 $\|\tilde{e}\|_{C[a,b]} < E$, 得到矛盾。故假设不成立, 因此 $i \geq n+1$, 即至

少有 $n+2$ 个等高震荡最值点，定理得证。


例题 4.1 我们对 $|x|$ 进行最佳一致逼近，观察等高震荡最值点的个数。

解 我们分别画出原函数 f 和最佳一致逼近多项式 p_n^* 以及误差曲线 $f - p_n^*$ 的图。当 $n = 2$ 时：



此时，等高震荡最值点的个数为 5。

当 $n = 4$ 时：



此时, 等高震荡最值点的个数为 7。

根据 Chebyshev 震荡定理, 我们可以立即得到最佳一致逼近的唯一性。

推论 4.1

(唯一性) 最佳一致逼近是唯一的。



证明 本推论的证明基于 Chebyshev 震荡定理。我们首先定义 $E = \min_{p \in \mathbb{P}_n} \|f - p\|_{C[a,b]}$ 。令 $p(x)$ 和 $q(x)$ 分别为两个最佳一致逼近多项式, 即

$$\|p(x) - f(x)\|_{C[a,b]} = E = \|q(x) - f(x)\|_{C[a,b]}.$$

考虑它们的平均函数 $h(x) = \frac{1}{2}(p(x) + q(x))$, 由范数的三角不等式可得

$$\|h(x) - f(x)\|_{C[a,b]} \leq \frac{1}{2}\|p(x) - f(x)\|_{C[a,b]} + \frac{1}{2}\|q(x) - f(x)\|_{C[a,b]} = E.$$

即 $h(x)$ 也是最佳一致逼近多项式。由 Chebyshev 震荡定理可以得到 $\{x_i\}_{i=0}^{n+1}$ 为 $f(x) - h(x)$ 的交错点组, 不妨设

$$f(x_i) - h(x_i) = (-1)^i E, \quad i = 0, 1, \dots, n+1.$$

根据无穷范数的定义, 这意味着

$$f(x_i) - \frac{1}{2}(p(x_i) + q(x_i)) = (-1)^i E \Rightarrow \begin{cases} f(x_i) - p(x_i) = (-1)^i E \\ f(x_i) - q(x_i) = (-1)^i E \end{cases}.$$

因此, 我们有 $p(x_i) = q(x_i)$, $i = 0, 1, \dots, n+1$, 即两个最佳一致逼近多项式在 $n+2$ 个交错点处相等。由多项式零点数目可知 $p(x) = q(x)$, 即最佳一致逼近是唯一的。

在完成 Chebyshev 震荡定理后, 我们可以完成前面遗留的两个命题 (Marcinkiewicz 定理和 Chebyshev 多项式满足首一最小范数性) 的证明。首先来证明 Marcinkiewicz 定理, 即

推论 4.2 (Marcinkiewicz)

对于任意连续函数, 和任意正常数 ϵ , 存在一系列节点 x_n 使得其插值多项式 p_n 满足: $\|p_n - f\|_{C[a,b]} \leq \epsilon$.



证明 令 $E_n = \min_{p \in \mathbb{P}_n} \|f - p\|_{C[a,b]}$, 且 p_n^* 为最佳一致逼近多项式。根据 Weierstrass 第一逼近定理我们知道 $E_n \rightarrow 0$ 。下面我们说明 p_n^* 一定是插值多项式。因为 p_n^* 是最佳一致逼近, 由 Chebyshev 震荡定理得到存在至少 $n+2$ 个等高震荡最值点。不难看出在任意两个相邻的等高震荡最值点之间一定存在一个零点, 于是至少存在 $n+1$ 个点使得 $p_n^*(x)$ 和 $f(x)$ 取值相等, 这就意味着 p_n^* 一定是插值多项式, 证毕。

紧接着我们来证明在所有的首一多项式中, 具有最小范数的多项式必为 Chebyshev 多项式 (相差一个常数倍)。

推论 4.3

令 $\mathcal{V} = \{p \in \mathbb{P}_n : p - x^n \in \mathbb{P}_{n-1}\}$, 则我们有

$$\frac{1}{2^{n-1}} T_n = \arg \min_{p \in \mathcal{V}} \|p\|_{C[-1,1]}.$$



证明 我们考察如下的最佳一致逼近问题：多项式 x^n 在空间 $\mathbb{P}_{n-1}$ 上的最佳一致逼近。令

$$p_{n-1}^* = \arg \min_{p \in \mathbb{P}_{n-1}} \|x^n - p\|_{C[-1,1]},$$

且 $r^*(x) = x^n - p_{n-1}^*$ 。由 Chebyshev 震荡定理知道 $r^*(x)$ 存在至少 $n+1$ 个等高震荡最值点是 p_{n-1}^* 为最佳一致逼近的充分必要条件。从 Chebyshev 多项式的定义我们立刻发现 $\frac{1}{2^{n-1}}T_n$ 天然存在 $n+1$ 个等高震荡最值点，即

$$\frac{1}{2^{n-1}}T_n = r^*(x) = x^n - p_{n-1}^*.$$

于是对于任意的 $q(x) \in \mathcal{V}$ ，我们都有

$$\|q(x)\|_{C[-1,1]} = \|x^n - q_{n-1}(x)\|_{C[-1,1]} \geq \|x^n - p_{n-1}^*\|_{C[-1,1]} = \left\| \frac{1}{2^{n-1}}T_n \right\|_{C[-1,1]}.$$

根据 Chebyshev 震荡定理，我们可以得知最佳一致逼近一定是某种插值函数，但我们却无法确定这些插值点的具体位置。虽然前面我们已经给出了 Marcinkiewicz 定理的证明，但是计算最佳一致逼近仍然是一项非常困难的任务。

下面我们介绍一个经典的算法：Remez 算法，来计算多项式的最佳一致逼近问题。Remez 算法的基本思想是基于 Chebyshev 震荡定理的，即通过迭代法找到 $n+2$ 个等高震荡最值点组，从而找到最佳一致逼近多项式。算法的基本步骤如下：

1. 给定交错点组的初始猜测（通常是 Chebyshev 点）。
2. 对于给定的点组 $\{x_i\}_{i=0}^{n+1}$ ，找出多项式 $p_n(x) \in \mathbb{P}_n$ 和实数 E ，使得 $p_n(x_i) - f(x_i) = (-1)^i E$ 。
3. 更新节点组：在每个 x_i 的附近用一个 $f(x) - p_n(x)$ 局部极小值点或者局部极大值点 $\hat{x}_i$ 来代替（正值用极小，负值用极大），这样可以保证每个新的节点的误差都大于等于 E （通常可以采用 Newton 法或者任何其他求极值的方法）。
4. 计算残差 $|f(\hat{x}_i) - p_n(\hat{x}_i)|$ ，如果最大残差和最小残差的距离小于给定值，则停止迭代，否则返回第二步重新迭代。

命题 4.1 (Remez 算法第二步适定性)

对于任意给定的 $n+2$ 个单调递增点组 $\{x_i\}_{i=0}^{n+1}$ ，存在唯一的 $p_n(x) \in \mathbb{P}_n$ 和实数 E ，满足 $p_n(x_i) - f(x_i) = (-1)^i E$ ，因此 Remez 算法的第二步总是可以找到一组满足要求的多项式 $p_n(x)$ 和实数 E 。



证明 我们可以通过构造两个插值多项式来证明此定理。首先令 $p_n^1(x)$ 为前 $n+1$ 个点的插值多项式满足 $p_n^1(x_i) = f(x_i)$ ，令 $p_n^2(x)$ 为在前 $n+1$ 个点取值为 $(-1)^i$ 的插值多项式，则我们可以将要求的多项式表示为

$$p_n(x) = p_n^1(x) + E p_n^2(x),$$

其中 E 是一个实数。显然， $p_n(x)$ 满足条件 $p_n(x_i) - f(x_i) = (-1)^i E, i = 0, 1, \dots, n$ 。将最后一个点的条件带入后，我们有

$$p_n^1(x_{n+1}) + p_n^2(x_{n+1})E = f(x_{n+1}) + (-1)^{n+1}E.$$

因此求解上述方程我们得到

$$E = \frac{p_n^1(x_{n+1}) - f(x_{n+1})}{p_n^2(x_{n+1}) + (-1)^n}.$$

最后我们需要解释 E 的定义是有意义的, 即分母非零。注意到 $p_n^2(x)$ 在区间 (x_0, x_n) 中已经变号 n 次, 即 $p_n^2(x_{n+1})$ 和 $p_n^2(x_n)$ 同号, 即 $|p_n^2(x_{n+1}) + (-1)^n| > 1$, 这证明了 Remez 算法的第二步是可行的。

Remez 算法的思想十分巧妙, 它充分利用了多项式的特性, 但是算法的具体实现比较复杂, 对于有兴趣进一步了解该算法的读者, 我们推荐阅读参考文献 [4, 5, 9], 这些资料对 Remez 算法的细节和理论分析进行了深入的探讨。

最佳一致逼近虽然在理论上可以得到最小误差多项式 (在连续范数的意义下), 但是其计算过程比较复杂, 因为 Remez 算法中需要多次求解局部极值。另一方面, 在实际应用中我们只需要得到一个不错的逼近函数, 是否真正最佳经常没有很大的影响。下面我们介绍的接近最优逼近 (near best approximation) 就是一种较为实用的逼近方法, 其核心思想是在采用插值的方式来进行逼近, 同时让插值节点的 Lebesgue 常数尽可能地小。事实上对于在给定节点上的插值多项式, 其和最佳一致逼近多项式之间我们有如下的估计。

定理 4.3

假设插值点集 $X \subseteq [a, b]$, p_n 是 n 次插值多项式, $f \in C[a, b]$ 。则有

$$\|f - p_n\|_{C[a,b]} \leq (\Lambda_n(X) + 1)E_n^*(f, X),$$

其中 $E_n^*(f, X)$ 为 f 的 n 次最佳一致逼近多项式误差, $\Lambda_n(X)$ 为节点组 X 的 Lebesgue 常数。



证明 首先由三角不等式可知 $\|f - p_n\|_{C[a,b]} \leq \|f - p_n^*\|_{C[a,b]} + \|p_n - p_n^*\|_{C[a,b]}$, 其中 p_n^* 是 f 的 n 次最佳一致逼近多项式。

接下来我们只需要证明 $\|p_n - p_n^*\|_{C[a,b]} \leq \Lambda_n(X)\|f - p_n^*\|_{C[a,b]}$ 即可得到定理。注意到 $p_n - p_n^*$ 是 $f - p_n^*$ 的插值多项式, 因此根据 Lebesgue 常数的定义, 我们有 $\|p_n - p_n^*\|_{C[a,b]} \leq \Lambda_n(X)\|f - p_n^*\|_{C[a,b]}$, 将其代入前面的不等式即可得证。

上述定理告诉我们, 对于在给定插值点上进行插值, 所得到的插值多项式和最佳一致逼近多项式之间的差别完全可以由插值节点上的 Lebesgue 常数来控制。而我们在上一章中知道对于在区间 $[-1, 1]$ 上的任意点组 X , 其 Lebesgue 常数 $\Lambda_n(X)$ 的下界可以表示为

$$\Lambda_n(X) \geq \frac{2}{\pi} \ln(n+1) + c,$$

其中常数 $c = \frac{2}{\pi}(\gamma + \ln \frac{4}{\pi}) \approx 0.52124\dots$, $\gamma = \text{Euler's constant}$)。而对于 Chebyshev 点和等距点, 它们的 Lebesgue 常数有不同的估计。其中 Chebyshev 点的 Lebesgue 常数 $\Lambda_n(C)$ 的上界为

$$\Lambda_n(C) \leq \frac{2}{\pi} \ln(n+1) + 1,$$


等距点的 Lebesgue 常数 $\Lambda_n(E)$ 的下界为

$$\Lambda_n(E) \geq \frac{2^{n-2}}{n^2}.$$

这些事实说明了如果采用 Chebyshev 节点进行插值，我们的确可以得到几乎最佳一致逼近多项式，特别的当 $n = 10^6$ 时，这两者也只差不到十倍 (9.79...)。因此采用 Chebyshev 节点进行插值和最佳一致逼近具有相似的效果。但是如果采用等距节点进行插值，其和最佳一致逼近多项式之间的误差是随着节点数目的增加指数上升的。

例题 4.2 现在我们来观察对 $|x|$ 进行插值时，最佳一致逼近和 chebyshev 点插值得到的误差。

解 我们依次取 $n = [0, 2, 4, 10, 20, 40, 100, 200]$ ，观察 chebyshev 点插值 $\|f - p_n\|_\infty$ 和最佳一致逼近 $\|f - p_n^*\|_\infty$ 的大小。



我们计算出两者的比值 $\text{ratio} = \frac{\|f - p_n\|_\infty}{\|f - p_n^*\|_\infty}$ 如下表所示：

n	ratio
0	2.00000
2	2.00000
4	2.10234
10	2.12677
20	2.12968
40	2.13037
100	2.13056
200	2.13059

从 Chebyshev 震荡定理中我们知道存在 $n + 2$ 个等高震荡最值点是最佳一致逼近的充分必要条件，下面的定理描述了如果我们手上只有 $n + 2$ 个震荡点，则得到的多项式和最佳一致逼近多项式之间也有一个接近最优的性质，具体而言有如下的估计：

定理 4.4

设 $f \in C[a, b]$, $p_n(x)$ 是 n 次多项式。如果存在 $n+2$ 个单调递增点 $\{x_i\}_{i=0}^{n+1}$, 使得 $p_n(x) - f(x)$ 在这些点上的符号变号, 那么有

$$\|f - p_n\|_{C[a,b]} \leq CE_n^*,$$

其中 $C = \frac{\|f - p_n\|_{C[a,b]}}{\min_i |f(x_i) - p_n(x_i)|} \geq 1$, E_n^* 为 n 次多项式最佳一致逼近误差。



证明 证明思路主要是验证下面这个不等式:

$$\min_i |f(x_i) - p_n(x_i)| \leq E_n^*.$$

首先记 $p_n(x) - f(x)$ 在 $x_0, x_1, \dots, x_{n+1}$ 上的取值分别为 $\lambda_0, -\lambda_1, \dots, (-1)^{n+1}\lambda_{n+1}$, 其中不妨设 $\lambda_i > 0, i = 0, 1, \dots, n+1$ 。接下来我们用反证法, 假设下式成立:

$$\min_i \lambda_i > E_n^* = \|f - p_n^*\|_{C[a,b]},$$

其中 p_n^* 表示 n 次最佳一致逼近多项式。考虑 $h(x) := p_n(x) - p_n^*(x)$, 有

$$\text{当 } i \text{ 为奇数时: } p_n(x_i) - p_n^*(x_i) \geq \lambda_i - E_n^* > 0$$

$$\text{当 } i \text{ 为偶数时: } p_n(x_i) - p_n^*(x_i) \leq \lambda_i - E_n^* < 0.$$

即 $h(x)$ 在点列 $\{x_i\}_{i=0}^{n+1}$ 上的取值依次变号, 由介值定理可知 $h(x)$ 在 (x_0, x_{n+1}) 上至少有 $n+1$ 个零点, 按照定义我们知道 $h(x)$ 是一个 n 次多项式, 于是 $p_n(x) - p_n^*(x)$ 和 $\min_i \lambda_i > E_n^*$ 得到矛盾, 从而我们有

$$\min_i \lambda_i \leq E_n^*,$$

即可得定理成立。

4.3 最佳平方逼近

在讨论最佳平方逼近之前, 我们先回顾一下 Gibbs 现象: 即间断函数的 Fourier 级数在间断点附近会出现震荡现象, 并且无穷模误差在间断点附近不会随着 Fourier 级数次数的增加而减小。这种现象也被称为 Gibbs 现象, 类似的多项式插值和逼近也存在 Gibbs 现象。




图 4.1: (Gibbs 现象) 当选取的傅里叶级数的项数 N 增加时, 合成的波形虽然更逼近原函数, 但在不连续点附近会出现一个固定高度的过冲, N 越大, 过冲的最大值越靠近不连续点, 且在不连续点两侧呈现衰减振荡的形式。

即使使用非常特殊的插值点如 Chebyshev 点进行插值, 在间断点附近同样会出现类似 Gibbs 现象的震荡, 更重要的是无穷模误差也不会随着插值点数目的增加而减少(挖掉不连续点之后)。这表明对于不连续函数而言, 一致逼近这个方式并不一定是一个好的描述方法。当然间断函数本身就不属于连续函数空间, 要对它进行逼近, 需要换成另一个函数空间, 这一节中我们主要考虑最佳平方逼近和它的离散版本。具体而言, 我们考虑带权的 L_ω^2 空间, 其中 $\mathbb{P}_n$ 可以看成其上的有限维子空间。令度量误差的方式为

$$\text{dist}(f, p) = \int_a^b \rho(x) |f(x) - p(x)|^2 dx,$$

则由下面的证明, 我们发现最佳平方逼近问题等价于其在多项式空间的投影。利用带权范数 L_ω^2 的定义, 我们得到最佳平方逼近的表达方式即为求解 $\min p \in \mathbb{P}_n \|f - p\|_{L_\omega^2}^2$ 。这个问题的存在唯一性相对较为简单, 下面的定理不仅仅给出了最佳平方逼近的存在唯一性, 还给出了可用的算法进行求解。

定理 4.5

对于任意的 $f \in L_\omega^2$, 存在唯一的最佳平方逼近元 $p_n \in \mathbb{P}_n$, 且它可以表示为 $\{\phi_i\}_{i=0}^n$ 的线性组合 $p_n = \sum_{i=0}^n c_i \phi_i$, 其中 $\{\phi_i\}_{i=0}^n$ 为 $\mathbb{P}_n$ 的一组基函数, 系数 c_i 是线性方程组 $Mc = f$ 的解, 这里 M 是 $\{\phi_i\}_{i=0}^n$ 的 Gram 矩阵: 即 $M_{ij} = \langle \phi_i, \phi_j \rangle_\omega$; $f_i = \langle f, \phi_i \rangle_\omega$ 。



注 在最佳平方逼近的问题中, 系数 c_i 也称为投影系数, 它表示 f 在 $\{\phi_i\}_{i=0}^n$ 张成的有限维子空间 $\mathbb{P}_n$ 中的投影。

证明 我们令 $p_n = \sum_{i=0}^n c_i \phi_i$, 则简单的计算可以得到

$$\begin{aligned} \|f - p_n\|_{L_\omega^2}^2 &= \|f - \sum_{i=0}^n c_i \phi_i\|_{L_\omega^2}^2 \\ &= \sum_{i,j} c_i c_j \langle \phi_i, \phi_j \rangle_\omega - 2 \sum_i c_i \langle \phi_i, f \rangle_\omega + \langle f, f \rangle_\omega \\ &= c^\top M c - 2c^\top f + \text{const}. \end{aligned}$$

因此, 我们需要求解以下二次型问题:

$$\min c^\top M c - 2c^\top f.$$

由于 M 是对称的, 我们只需要证明它是正定的即可。对于任意非零向量 $v \in \mathbb{R}^{n+1}$, 我们有

$$v^\top M v = \sum_{i,j} v_i v_j \langle \phi_i, \phi_j \rangle_\omega = \left\langle \sum_{i=0}^n v_i \phi_i, \sum_{j=0}^n v_j \phi_j \right\rangle_\omega > 0.$$

因此 M 是对称正定的, 从而求解二次型的优化问题等价于线性方程组 $Mc = f$ (参考数值线性代数部分最速下降法和共轭梯度法部分), 证毕。

我们注意到最佳平方逼近有正交性质, 即残差垂直于 $\mathbb{P}_n$ 。对于数值求解最佳平方逼近, 一个关键的步骤是基函数的选择, 从而构建合理的 Gram 矩阵。以 $[0, 1]$ 区间上带着权函数




图 4.2: 在不同均匀插值点数量 n 的情况下, 该均匀插值点集合对应的 Gram 矩阵的奇异值分布图. 横坐标表示奇异值的索引, 纵坐标表示对应的奇异值 (经过对数处理).

1 的最佳平方逼近为例, 如果我们将基函数选成标准的单项式基底 x^i , 则 Gram 矩阵 $M_{i,j} = \int_0^1 x^{i+j} dx = \frac{1}{i+j+1}$, 这个矩阵是著名的 Hilbert 矩阵, 其奇异值具有快速衰减的性质, 导致求解的不稳定性。

例题 4.3 下面我们选择自然基底作为基函数 $\{x_i\}_{i=0}^n$ 来执行最佳平方逼近。我们不妨假设目标函数 $f(x) = x^9 + x^5 + x$ 。

解 在本例中, Gram 矩阵是一个规模为 $(n+1, n+1)$ 的方阵 G , 其矩阵元素 $G_{i,j} = 1/(i+j+1)$ 。观测向量 $f \in \mathbb{R}^{n+1}$, 其中元素由目标函数与相应的基底做内积可以得到。该 Gram 矩阵的奇异值分布可以见图 4.2, 可以观察到该 Gram 的最小奇异值很小 (该 Gram 的最大奇异值是 $O(1)$ 规模)。随着自然基底 n 数量的增加, 最小奇异值呈指数衰减, 因此求解该线性方程组很不稳定。

我们可以发现随着多项式次数 n 的增加, 最小奇异值呈指数衰减, 从而可能会导致数值结果的不稳定。我们以 $n = 19$ 为例, 理论上来说最佳平方逼近多项式应该和原函数完全一样。但是通过 Hilbert 矩阵求逆后, 我们发现得到的多项式如表 4.1。

类似插值问题, 我们也在 $[0, 1]$ 上均匀选取 1000 个点, 分别计算被最佳平方逼近多项式和原函数的误差, 平方和为 MSE, 具体见图 4.3。

从上述的例题中可以发现, 类似多项式插值的 Vandermode 矩阵, Hilbert 矩阵的数值稳定性也非常可疑, 这是由于采用了单项式基底这类数值相关性非常强的基底。为了避免因为基底选择造成的数值不稳定性, 我们可以选择正交多项式作为求解的基底。另外一方面, 如果

多项式基底	系数
1	$+8.488e-09$
x	$+1.000e+00$
x^2	$+1.004e-04$
x^3	$-2.146e-03$
x^4	$+2.394e-02$
x^5	$+8.435e-01$
x^6	$+6.331e-01$
x^7	$-1.611e+00$
x^8	$+2.523e+00$
x^9	$-1.399e+00$
x^{10}	$+2.188e+00$
x^{11}	$-4.605e+00$
x^{12}	$+8.196e+00$
x^{13}	$-6.633e+00$
x^{14}	$-4.140e-01$
x^{15}	$+4.776e+00$
x^{16}	$-2.877e+00$
x^{17}	$-1.105e-01$
x^{18}	$+6.532e-01$
x^{19}	$-1.749e-01$

表 4.1: 在 $[0, 1]$ 选取 20 个单项式基底得到的最佳平方逼近多项式。为了合理表示该插值多项式并与原函数 $f(x) = x^9 + x^5 + x$ 对比，我们选取左边一列单项式作为基函数，右边一列表示最佳平方逼近多项式在不同基函数下对应的系数。通过对比可以发现，最佳平方逼近多项式与原函数 $f(x)$ 差别很大。




图 4.3: 在不同基底数量 n 的情况下, Mean Squared Error (MSE) 分布图 (log scale). 我们记 $f(x)$ 和 $p_n(x)$ 分别为目标函数和插值多项式, 均方误差 (MSE) 的定义为 $\int_{\mathcal{X}} |f(x) - p_n(x)|^2 dx$. 其中 $\mathcal{X}$ 表示为了计算 MSE 我们所选择的定义域区间. 理论上, 我们希望选取 $\mathcal{X} = [0, 1]$ 作为计算区间. 但是在实际操作中我们选取 $\mathcal{X}$ 为 1000 个在区间 $[0, 1]$ 上的等距节点进行近似.

我们所选取的基底 ϕ_i 正好在 L_ω^2 中正交, 那么 Gram 矩阵 M 是一个对角矩阵, 从而最佳平方逼近多项式可以显式给出:

$$p_n^* = \sum_{i=0}^n \frac{\langle f, \phi_i \rangle_\omega}{\langle \phi_i, \phi_i \rangle_\omega} \phi_i. \quad (4.1)$$

这一结论可以描述为下面的定理

定理 4.6

设 $\phi_i(x)$ 是区间 $[-1, 1]$ 上的正交多项式序列, 对于任意 $f(x) \in L_\omega^2$, 定义其 Fourier 截断函数 $f_n(x) = \sum_{k=0}^n \tilde{f}_k \phi_k(x)$, 其中 $\tilde{f}_k = \frac{\langle f, \phi_k \rangle_\omega}{\langle \phi_k, \phi_k \rangle_\omega}$, 则 f_n 满足最佳平方逼近性质: 即 $f_n = \operatorname{argmin}_{p \in \mathbb{P}_n} \|f - p\|_{L_\omega^2}$.



如果我们让多项式的次数持续增长, 并引入类似 Fourier 级数的表示符号, 我们可以形式上用广义 Fourier 展开来表达任意的平方可积函数:

$$f \sim \sum_{i=0}^{\infty} \frac{\langle f, \phi_i \rangle_\omega}{\langle \phi_i, \phi_i \rangle_\omega} \phi_i. \quad (4.2)$$

注 事实上方程(4.2)在 L_ω^2 空间中可以写成等号, 即

$$\lim_{n \rightarrow \infty} \|f - f_n\|_{L_\omega^2} = 0.$$

这一结论的证明超过本课程的范畴, 我们简略给出证明的思路, 有兴趣的读者可以自行完成或者参阅调和分析或实分析等相关教科书。

- (1) 证明在 $L_\omega^2(a, b)$ 空间中, 多项式函数可以逼近任意连续函数 (Weierstrass 第一逼近定理的直接推论)
- (2) 证明在 $L_\omega^2(a, b)$ 空间中, 分片线性连续函数可以逼近任意分片常数函数 (构造性证明)
- (3) 证明在 $L_\omega^2(a, b)$ 空间中, 分片常数函数可以逼近任意平方可积函数 (构造性证明)
- (4) 通过 (1)-(3) 的证明, 得到稠密性, 然后由最佳平方逼近的定义可以得到收敛性
- (5) 收敛性的证明并不依赖正交多项式基底, 因为 f_n 是最佳平方逼近多项式, 其可以在不同的基底下进行表达。不过作为副产品, 我们可以证明 Parseval 等式 (即勾股定理的推广): 即在正交多项式基底下有 $\|f\|_{L_\omega^2}^2 = \sum_{i=1}^{\infty} \left\| \frac{\langle f, \phi_i \rangle_\omega}{\langle \phi_i, \phi_i \rangle_\omega} \phi_i \right\|_{L_\omega^2}^2$ 。

如果我们在区间 $[-1, 1]$ 中选择权重函数 $\omega(x) = \frac{1}{\sqrt{1-x^2}}$, 并且将多项式基底选为在 L_ω^2 中的正交多项式: Chebyshev 多项式, 则采用(4.2)中的记号, 我们有

$$f = \sum_{i=0}^{\infty} \frac{\langle f, T_i \rangle_\omega}{\langle T_i, T_i \rangle_\omega} T_i,$$

且其最佳平方逼近多项式 f_n 为 Chebyshev 截断多项式:

$$f_n = \sum_{i=0}^n \frac{\langle f, T_i \rangle_\omega}{\langle T_i, T_i \rangle_\omega} T_i.$$

和上一章中基于 Chebyshev 节点插值得到的插值多项式类似, Chebyshev 截断多项式逼近函数的误差也和函数的光滑性密切相关。当函数越光滑, 收敛速度越快。具体而言有如下的定理, 其证明可以参考 [8]。

定理 4.7

若 $f \in C[-1, 1]$ 为 s 次可导的函数，其中第 s 阶的导数可以是分片定义的，且其 s 阶导数具有有界变差，变差为 V 。我们有

$$\|f - f_n\|_{C[-1,1]} \leq \frac{2V}{\pi s(n-s)^s},$$

其中 f_n 为 f 的 Chebyshev 截断多项式。如果 f 在 $[-1, 1]$ 上实解析，则存在 $\rho > 1$ 使得

$$\|f - f_n\|_{C[-1,1]} \leq C\rho^{-n}.$$



我们比较上述定理 4.7 和上一章的定理 ?? 后可以发现，Chebyshev 截断近似多项式和 Chebyshev 节点插值得到的插值多项式具有非常类似的逼近结果。作为推论，我们立刻可以证明，对于任意的 Lipschitz 连续函数 $f(x)$ ，我们可以证明它的 Chebyshev 展开绝对一致收敛于自身，即 $f(x) = \sum_{k=0}^{\infty} a_k T_k$ ，其中 $a_k = 1/(2\pi) \langle f, T_k \rangle_{\omega}$ (a_0 需要乘以 2)。

4.3.1 离散最佳平方逼近

前面章节中所提到的最佳一致逼近或者最佳平方逼近，都建立在复杂函数已知的前提下，但是在实际应用中，如果已经知道该函数的表达式，则不一定需要做逼近（因为已经可以求出所有点的函数值）。在工程应用中，比较实用和常见的例子是：如果函数 $f(x)$ 只能在某些离散点上进行测量，如何构造一个简单的函数去近似未知函数 $f(x)$ ，从而可以给出 $f(x)$ 在所有未知点处函数值的近似。

如果我们使用多项式空间来近似未知函数，采用某种基底 $\{\phi_i(x)\}_{i=0}^n$ ，未知多项式表示为 $p_n(x) = \sum_{i=0}^n c_i \phi_i(x)$ ，则在所有离散测量点 $\{x_i\}_{i=0}^m$ ，其中 $m > n$ ，上形成了超定线性方程组

$$\sum_{i=0}^n c_i \phi_i(x_j) = f(x_j), \quad j = 0, \dots, m.$$

这样的超定线性方程组可以使用最小二乘（或者加权最小二乘）进行求解，这就给出了一种简单的求解方法。下面我们从另外一个角度来理解离散最佳平方逼近。首先令多项式为 $p(x) = \sum_{i=0}^n c_i \phi_i(x)$ ，给定权重系数 $\{\omega_i\}_{i=0}^m$ ，定义离散最佳平方逼近问题

$$\min_{p \in \mathbb{P}_n} \sum_{i=0}^m \omega_i |p(x_i) - f(x_i)|^2.$$

类似最佳平方逼近的计算公式，我们可以得到离散最佳逼近问题可以转化为 $Mc = b$ 的格式，其中离散 Gram 矩阵 M 和右端项 b 分别为

$$M_{j,k} = \sum_{i=0}^m \omega_i \phi_j(x_i) \phi_k(x_i), \quad b_k = \sum_{i=0}^m \omega_i \phi_k(x_i) f_i,$$

然后求解该线性方程组即可得到系数。在一定的假设下如何选择合适的权重 ω_i 和测量点位置都是值得考虑的问题，另外在一些特定的情形下，离散最佳平方逼近可以修改为离散最佳一致逼近或者离散最佳 L^1 逼近，但是数值求解算法会比较复杂。

4.4 知识拓展

这一章主要研究了光滑函数或者平方可积函数的最佳逼近问题，特别的在最佳平方逼近的框架下，可以通过引入正交多项式基底，将问题转化为广义 Fourier 展开并得到其收敛性。而这样的收敛性对光滑函数而言可以证明其在不同函数空间下的收敛速度。我们在这里列一些正交多项式的其他逼近性质（包括 Chebyshev 多项式和 Legendre 多项式等）。

我们先回顾一下第一类 Chebyshev 点和第二类 Chebyshev 点（也称为 Chebyshev-Lobatto 点） $(x_j, \bar{x}_j)$ 的定义：

$$x_j = -\cos \frac{(2j+1)\pi}{2(n+1)}, \bar{x}_j = -\cos \frac{j\pi}{n},$$

其中 $n+1$ 为节点个数， $j = 0, 1, \dots, n$ 。

对于第一类和第二类 Chebyshev 点的插值逼近，我们在 $L_\omega^2(-1, 1)$ 可以得到以下结论（这里 $\omega = \frac{1}{\sqrt{1-x^2}}$ ，证明参考 [6] 第 434 页）：

$$\|f - p_n^{CL}\|_\omega \leq Cn^{-s}\|f\|_{s,\omega}; \quad \|f - p_n^C\|_\omega \leq Cn^{-s}\|f\|_{s,\omega},$$

其中， p_n^{CL} 和 p_n^C 分别表示使用 Chebyshev-Lobatto 点和 Chebyshev 点插值所得的 n 次插值多项式， ω 是权重函数， $\|f\|_{s,\omega}$ 表示具有 s 阶导数和权重函数 ω 的函数 f 的 L^2 范数，其中 $s = 0$ 或者 $\omega = 1$ 时可以省略， C 是一个正常数。我们在上一章中给出了插值多项式在连续函数模下的估计，上面这个定理说明了 L_ω^2 度量下结论是类似的。

接下来我们考虑 Legendre 多项式，以及与其相关的 Legendre 点（Legendre 多项式的零点）和 Legendre-Lobatto 点（Legendre 多项式的极值点）的插值。根据 [6] 第 437 页的结论，我们可以得到如下结论：

$$\|f - p_n^{LL}\| + n^{-1/2} \|f - p_n^{LL}\|_{C[a,b]} \leq Cn^{-s}\|f\|_s; \quad \|f - p_n^L\| + n^{-1/2} \|f - p_n^L\|_{C[a,b]} \leq Cn^{-s}\|f\|_s,$$

其中 p_n^{LL} 和 p_n^L 分别表示使用 Legendre-Lobatto 点和 Legendre 点进行的插值。这个结论告诉我们 Legendre 点或者 Legendre-Lobatto 点进行插值能够得到和 Chebyshev 点类似的效果。此外我们还可以使用 DLT（Discrete Legendre Transform）来计算 Legendre-Lobatto 节点的插值函数和 Legendre 截断函数，这为 Legendre 多项式的计算提供了更大的灵活性。

第 4 章 练习

1. 证明 Chebyshev 多项式 $T_n(x)$ 满足微分方程

$$(1-x^2)T''(x) - xT'(x) + n^2T_n(x) = 0.$$

2. 求 $f(x) = x^4 + 2x^3 - 1$ 在区间 $[0, 1]$ 上的三次最佳一致逼近多项式。
3. 求 $f(x) = |x|$ ，在区间 $[-1, 1]$ 上求关于 $\Phi = \text{span}\{1, x^2, x^4\}$ 的最佳平方逼近。

4. 求 $f(x)$ 在指定区间上对于 $\Phi = \text{span}\{1, x\}$ 的最佳平方逼近多项式:

(1). $f(x) = \frac{1}{x}, [1, 3];$

(2). $f(x) = e^x, [0, 1];$

(3). $f(x) = \sin \pi x, [0, 1];$

(4). $f(x) = \ln x, [1, 2].$

第5章 数值微分与数值积分

在许多科学工程计算的问题中，经常会需要计算导数或者积分。但是直接测量导数或者积分一般来说很难做到，需要在仅仅测量函数值的前提下使用数值方法近似导数或者积分，这就是本章的主要内容。

5.1 数值微分

在很多工程问题中，实际测量时只能测量函数值，但是在设计算法时需要用到导数甚至高阶导数值，因此这个时候需要通过函数在某些点的函数值，给出该函数的一阶导数甚至高阶导数的近似值。一个典型的例子是第二章中 Newton 法求解非线性方程需要计算函数的导数值，而割线法就可以理解为使用两个点的函数值来近似该点的导数值。

5.1.1 一阶导数的差分格式

我们首先从导数的定义出发，给出最基本的几种差分方法来近似一阶导数。差分法是实际中运用最广泛的方法，按照所选取的近似点的位置，分为向前、向后以及中心差分法，选取 $h > 0$ 为一个小的正数，则有

(1) 向前差分法：

$$f'(x) \approx \frac{f(x+h) - f(x)}{h}; \quad (5.1)$$

(2) 向后差分法：

$$f'(x) \approx \frac{f(x-h) - f(x)}{-h}; \quad (5.2)$$

(3) 中心差分法：

$$f'(x) \approx \frac{f(x+h) - f(x-h)}{2h}; \quad (5.3)$$

定理 5.1

对于向前和向后差分法，当 $f(x) \in C^2[a, b]$ 时，可以得到一阶导数的误差估计

$$\left| \frac{f(x+h) - f(x)}{h} - f'(x) \right| \leq \frac{h}{2} \|f''\|_{C[a,b]}, \quad (5.4)$$

$$\left| \frac{f(x-h) - f(x)}{-h} - f'(x) \right| \leq \frac{h}{2} \|f''\|_{C[a,b]}; \quad (5.5)$$

对于中心差分法，当 $f(x) \in C^3[a, b]$ 时，可以得到一阶导数的误差估计

$$\left| \frac{f(x+h) - f(x-h)}{2h} - f'(x) \right| \leq \frac{h^2}{6} \|f^{(3)}\|_{C[a,b]}. \quad (5.6)$$



证明 对于向前和向后差分法, 首先进行 Taylor 展开, 可以得到:

$$f(x+h) = f(x) + hf'(x) + \frac{h^2}{2}f''(\xi), \quad (5.7)$$

$$f(x-h) = f(x) - hf'(x) + \frac{h^2}{2}f''(\eta), \quad (5.8)$$

则有

$$\frac{f(x+h) - f(x)}{h} - f'(x) = \frac{h}{2}f''(\xi), \quad (5.9)$$

$$\frac{f(x-h) - f(x)}{-h} - f'(x) = -\frac{h}{2}f''(\eta). \quad (5.10)$$

由上面的等式可知, 当 $f(x) \in C^2[a, b]$ 时我们有

$$\left| \frac{f(x+h) - f(x)}{h} - f'(x) \right| \leq \frac{h}{2} \|f''\|_{C[a, b]}, \quad (5.11)$$

$$\left| \frac{f(x-h) - f(x)}{-h} - f'(x) \right| \leq \frac{h}{2} \|f''\|_{C[a, b]}; \quad (5.12)$$

对于中心差分法, 进行 Taylor 展开, 可以得到:

$$f(x+h) = f(x) + hf'(x) + \frac{h^2}{2}f''(x) + \frac{h^3}{3!}f^{(3)}(\xi), \quad (5.13)$$

$$f(x-h) = f(x) - hf'(x) + \frac{h^2}{2}f''(x) - \frac{h^3}{3!}f^{(3)}(\eta). \quad (5.14)$$

结合上述两个等式可得到:

$$\frac{f(x+h) - f(x-h)}{2h} - f'(x) = \frac{h^2}{6} \frac{f^{(3)}(\xi) + f^{(3)}(\eta)}{2}. \quad (5.15)$$

即当 $f(x) \in C^3[a, b]$ 时,

$$\left| \frac{f(x+h) - f(x-h)}{2h} - f'(x) \right| \leq \frac{h^2}{6} \|f^{(3)}\|_{C[a, b]}. \quad (5.16)$$

注意到虽然中心差分的右端项我们用的是 $\|f^{(3)}\|_{C[a, b]}$, 但是这个误差几乎等于 $|f^{(3)}(x)|$, 向前和向后差分也有类似的结果。上述定理我们能看出向前和向后差分都是一阶收敛、中心差分具有二阶收敛性, 通常会有更高的精度 (在同样的网格尺寸下)。

5.1.2 数值微分的不适定性

下面我们用一个简单的例子来验证向前差分和中心差分的收敛阶。

例题 5.1 我们用差分方法估计目标函数 $f(x) = e^x$ 在 $x = 0$ 处的导数值, 已知精确解 $f'(0) = 1$ 。下面我们探索不同差分方法的误差随着 h 变化的趋势。

解 具体见图 5.1, 我们设定 $h = 10^i$, 这里 $i \in \{0, 1, \dots, 16\}$ 。注意误差是由绝对值函数度量的, 这里的横坐标和纵坐标都取了 $\log$ 规模。

从上图中很明显的看到, 当网格尺寸 h 不是非常小时, 误差严格按照线性、二次收敛 (分别对应于向前差分、中心差分), 但是当网格尺寸减小到一定程度后, 误差反而会增加。

为什么会发生这种现象? 因为在实际的数值计算中, 舍入误差时不可避免的, 这就意味着我们实际参与计算的数值并不是精确的 $f(x)$, 而是它的一个扰动。我们假设数据的扰动大




图 5.1: 后前差分法与中心差分法的误差分析。

小为 δ ，即

$$|f^\delta(x) - f(x)| \leq \delta,$$

则采用向前差分法估计一阶导数时，真正的误差变为：

$$\begin{aligned} \left| \frac{f^\delta(x+h) - f^\delta(x)}{h} - f'(x) \right| &= \left| \frac{f^\delta(x+h) - f^\delta(x)}{h} - \frac{f(x+h) - f(x)}{h} + \frac{h}{2} f''(\xi) \right| \\ &\leq \frac{1}{h} (|f^\delta(x+h) - f(x+h)| + |f^\delta(x) - f(x)|) + \frac{h}{2} |f''(\xi)| \\ &\leq \frac{2\delta}{h} + \frac{h}{2} |f''(\xi)|. \end{aligned}$$

其中第一项称为传播误差，第二项为逼近误差，我们在定理 5.1 仅考虑了逼近误差的估计。注意到这个例子中舍入误差 $\delta \approx 1e-16$ ，而当 $h \approx 1e-8$ 的时候，逼近误差和传播误差相当。在网格尺寸大于 $1e-8$ 时，逼近误差占主导地位，总误差是精确的线性递减；但是当网格尺寸小于 $1e-8$ 后，传播误差占据主导地位，这时候就取决于舍入误差的大小，所以总体误差上升但是并没有严格的线性增长。其中最优的网格尺寸是 $h \approx 2\sqrt{\frac{\delta}{|f''(\xi)|}}$ ，但因为 $f''(\xi)$ 一般是未知的，因此这一估计式并不能真正用于计算。

再以中心差分格式为例：

$$\frac{f(x-h) - f(x+h)}{2h} - f'(x) = \frac{h^2}{6} f^{(3)}(\xi). \quad (5.17)$$

在数据带有扰动时，用中心差分法估计一阶导数时产生的误差变为：

$$\left| \frac{f^\delta(x+h) - f^\delta(x-h)}{2h} - f'(x) \right| \leq \frac{\delta}{h} + \frac{h^2}{6} |f^{(3)}(\xi)|. \quad (5.18)$$

当网格尺寸取值为 $h \approx (\frac{6\delta}{|f^{(3)}(\xi)|})^{\frac{1}{3}} = O(\delta^{\frac{1}{3}})$ 时，中心差分法的最优误差为 $O(\delta^{\frac{2}{3}})$ 。

注意到对于任意的数值微分格式（包括我们下面章节中所提到的所有数值微分算法），均具有上面类似的结论，即在测量数据带有误差（如舍入误差）的前提下网格尺寸并不能无限限制减少，并且如果网格尺寸太小会导致算法的结果发散。这是因为在连续层面上，微分运算对 L^∞ 扰动是不适定的，在 L^∞ 下任意微小的扰动可能会造成目标函数不可导，或者导函数

任意大等后果，这是一个典型的不适定问题。这时候数值微分格式可以看成是一种离散正则化方法，而网格尺寸即正则化参数的选择需要非常仔细地设计。这部分内容的详细讨论超出了本书的范畴，有兴趣的读者可以参阅反问题的正则化方法等相关专业文献。

5.1.3 差分模板方法

向前、向后、中心差分都是非常简单自然的数值微分格式，但是如何系统的获取任意精度的数值微分方法，又如何给出任意阶导数的数值微分近似格式呢？一个自然的推广是采用差分模板来构造恰当的差分格式。具体而言，我们预先给定 $f(x)$ 附近若干个点的值（如 $f(x-2h)$, $f(x-h)$, $f(x)$, $f(x+h)$, $f(x+2h)$ 这五个点），然后将这些点进行合适的加权求和，可以得到恰当的数值微分格式，为了确定数值格式，我们可以采用待定系数法。还是以五个点为例，我们对每个点进行 Taylor 展开（对 $i = -2, -1, 0, 1, 2$ ）有

$$f(x+ih) = f(x) + ihf'(x) + \frac{(ih)^2}{2}f''(x) + \frac{(ih)^3}{3!}f'''(x) + \frac{(ih)^4}{4!}f^{(4)}(x) + \frac{(ih)^5}{5!}f^{(5)}(x) + O(h^6).$$

如果我们希望用这五个点的组合得到能近似 $f'(x)$ 的最高阶的格式，令其为 $\sum_{i=-2}^2 a_i f(x-ih)$ ，分别匹配系数后，得到（五个自由度自然的匹配五个方程）

$$\begin{aligned} \sum_{i=-2}^2 a_i &= 0, \\ \sum_{i=-2}^2 (ih)a_i &= 1, \\ \sum_{i=-2}^2 \frac{(ih)^2}{2}a_i &= 0, \\ \sum_{i=-2}^2 \frac{(ih)^3}{3!}a_i &= 0, \\ \sum_{i=-2}^2 \frac{(ih)^4}{4!}a_i &= 0. \end{aligned}$$

通过求解上面的方程组，可以得到

$$(a_{-2}, a_{-1}, a_0, a_1, a_2) = \frac{1}{h} \left(\frac{1}{12}, -\frac{2}{3}, 0, \frac{2}{3}, -\frac{1}{12} \right),$$

带入到 h^5 的公式中，得到该数值微分格式的误差阶为

$$\frac{1}{h} \left(\frac{f(x-2h)}{12} - \frac{2f(x-h)}{3} + \frac{2f(x+h)}{3} - \frac{f(x+2h)}{12} \right) = f'(x) + O(h^4).$$

利用差分模板的方法，可以统一给出各种数值微分的格式，即使是不等距节点上进行测量也可以给出恰当的估计式。

我们利用差分模板可以给出估计二阶导数的中心差分格式（具体过程留给读者自行完成），并且可以给出误差阶的估计：

$$f''(x) \approx \frac{f(x+h) + f(x-h) - 2f(x)}{h^2}. \quad (5.19)$$

命题 5.1

二阶导数的中心差分格式的误差估计：当 $f(x) \in C^4[a, b]$ 时，

$$\left| \frac{f(x+h) + f(x-h) - 2f(x)}{h^2} - f''(x) \right| \leq \frac{h^2}{12} \|f^{(4)}\|_{C[a,b]}. \quad (5.20)$$

证明 首先进行 Taylor 展开，可以得到：

$$f(x+h) = f(x) + hf'(x) + \frac{h^2}{2}f''(x) + \frac{h^3}{3!}f^{(3)}(x) + \frac{h^4}{4!}f^{(4)}(\xi), \quad (5.21)$$

$$f(x-h) = f(x) - hf'(x) + \frac{h^2}{2}f''(x) - \frac{h^3}{3!}f^{(3)}(x) + \frac{h^4}{4!}f^{(4)}(\eta), \quad (5.22)$$

将两个等式相加

$$f(x+h) + f(x-h) = 2f(x) + h^2f''(x) + \frac{h^4}{12} \frac{f^{(4)}(\xi) + f^{(4)}(\eta)}{2}. \quad (5.23)$$

则有

$$\left| \frac{f(x+h) + f(x-h) - 2f(x)}{h^2} - f''(x) \right| \leq \frac{h^2}{12} \|f^{(4)}\|_{C[a,b]}. \quad (5.24)$$

下面这个推论是显然的，我们将在下一节中利用这一结论给出数值微分的一种隐式求解方法。

推论 5.1

当 $f(x) \in C^5[a, b]$ 时，

$$\left| \frac{f'(x+h) + f'(x-h) - 2f'(x)}{h^2} - f^{(3)}(x) \right| \leq \frac{h^2}{12} \|f^{(5)}\|_{C[a,b]}. \quad (5.25)$$

5.1.4 数值微分的整体估计方法

在实际的问题中，有时候不仅仅需要估计某一个单点的导数，而需要同时计算处多个点的导数值，甚至是给出任意点的导数值，而且在可能的情况下，给出较高的数值精度，我们下面介绍一种隐式求解方法。首先假设我们能够给出区间 $[a, b]$ 上等距剖分的 $n+1$ 各点上的函数值 $f(x_i), i=0, \dots, n$ ，其中 $x_i = a + ih$ ， $h = \frac{b-a}{n}$ 。从 Taylor 展开我们得到

$$f(x+h) = f(x) + hf'(x) + \frac{h^2}{2}f''(x) + \frac{h^3}{3!}f^{(3)}(x) + \frac{h^4}{4!}f^{(4)}(x) + \frac{h^5}{5!}f^{(5)}(x) + \dots, \quad (5.26)$$

$$f(x-h) = f(x) - hf'(x) + \frac{h^2}{2}f''(x) - \frac{h^3}{3!}f^{(3)}(x) + \frac{h^4}{4!}f^{(4)}(x) - \frac{h^5}{5!}f^{(5)}(x) + \dots, \quad (5.27)$$

对上述两个等式进行相减后得到

$$\frac{f(x+h) - f(x-h)}{2h} = f'(x) + \frac{h^2}{3!}f^{(3)}(x) + \frac{h^4}{5!}f^{(5)}(x) + \frac{h^6}{7!}f^{(7)}(x) + \dots. \quad (5.28)$$

一个显然的事实上如果我们能够给出 $f^{(3)}(x)$ 好的估计，则可以对中心差分格式进行矫正得到更高精度的估计方法。当然一般来说 $f^{(3)}(x)$ 不可能显式给出，我们利用公式 (5.25)，可以发现

$$f^{(3)}(x) = \frac{f'(x+h) + f'(x-h) - 2f'(x)}{h^2} + O(h^2). \quad (5.29)$$




图 5.2: 隐式数值算法的统一理解。

将其代入(5.28)式, 可以得到

$$\frac{f(x+h) + f(x-h)}{2h} - f'(x) - \frac{f'(x+h) + f'(x-h) - 2f'(x)}{6} = O(h^4). \quad (5.30)$$

于是对于 $x = x_i$, $i = 1, \dots, n-1$, 我们均有则由前面给出的结论可知:

$$\frac{f(x_{i+1}) + f(x_{i-1}))}{2h} - f'(x_i) - \frac{f'(x_{i+1}) + f'(x_{i-1}) - 2f'(x_i)}{6} = O(h^4). \quad (5.31)$$

令 $m_i \approx f'(x_i)$, 且其满足如下线性方程组

$$\begin{cases} m_0 + 4m_1 + m_2 = \frac{3}{h}(f(x_2) - f(x_0)) \\ m_1 + 4m_2 + m_3 = \frac{3}{h}(f(x_3) - f(x_1)) \\ \dots \\ m_{n-2} + 4m_{n-1} + m_n = \frac{3}{h}(f(x_n) - f(x_{n-2})) \end{cases} \quad (5.32)$$

上面的线性方程组有 $n+1$ 个未知数, 但是只有 $n-1$ 个方程。假设我们在边界上可以做更多的测量, 从而给出 $f'(a)$ 和 $f'(b)$ 的两个好的近似 m_0 和 m_n , 那么可以求解方程组给出所有节点上的近似 $m_i \approx f'(x_i)$ 。如果 $m_0 - f'(a) = O(h^4)$, $m_n - f'(b) = O(h^4)$, 则不难证明 $m_i = f'(x_i) + O(h^4)$ 。

如何证明上面这个结论? 如果我们仔细观察上面的线性方程组, 会发现这种隐式求导方法等价于先使用固支边界条件进行三次样条插值然后求导。那么只需要利用线性方程组的强对角占优性质 (参考定理3.16的证明过程), 可以得到 $m_i = f'(x_i) + O(h^4)$ 。

上述这种隐式处理方法事实上给出了许多问题的数值算法一种统一的思路。考虑这样的问题: 如果给出了 $f(x)$ 在若干点上的函数值 $\{f(x_i)\}_{i=0}^n$, 需要计算出某些和 f 相关的数值 $H(f)$ (例如 f 的微分, 或者其积分值)。我们采用隐式处理方式, 即由 $\{f(x_i)\}_{i=0}^n$ 给出 $f(x)$ 的一个很好的近似 $p(x)$ (如多项式逼近、样条插值或逼近等), 然后对 $p(x)$ 直接计算出 $H(p)$ (因为 p 有很好的参数化表示, 这个任务通常较为简单), 并用 $H(p)$ 代替 $H(f)$ 。具体流程可以参考图片5.2, 这一思路在数值积分部分也将再次体现出来, 而且这一想法在其他不同的任务中也可以进行参考。

我们可以给出一个很简单的例子来对比一下显式差分法; 给定边界导数真值的隐式差分法以及用 Lagrange 插值直接求导的隐式法。我们还给出了对函数用 Lagrange 插值得到的结果。

例题 5.2 设待求函数为 $f = \frac{4}{1+x^2}$ ，计算上述三种方法如下：




图 5.3: 三种差分格式




图 5.4: Lagrange 插值拟合函数

5.1.5 Richardson 外推法

在这一节中，我们将介绍数值数学中一种重要的方法：Richardson 外推。Richardson 外推的基本思想是，如果知道一种相对简单的数值方法的误差渐近展开式，我们可以通过简单的组合（称其为外推）从而得到更高阶的数值算法。具体做法如下，假设我们所求的量 L 在某一个网格尺寸 h 下有近似值 L_h ，且误差估计为

$$L_h - L = C_1 h^{\alpha_1} + C_2 h^{\alpha_2} + C_3 h^{\alpha_3} + \dots, \quad (5.33)$$

其中 $0 < \alpha_1 < \alpha_2 < \dots$ 为已知的收敛阶， C_i 为和网格尺寸无关的未知常数（如依赖 f 某些高阶导数值）。将网格尺寸减少一半来计算 $L_{h/2}$ ，使用(5.33)估计得到

$$L_{h/2} - L = C_1 h/2^{\alpha_1} + C_2 h/2^{\alpha_2} + C_3 h/2^{\alpha_3} + \dots$$

将上式乘以 2^{α_1} 后减去(5.33)得到

$$\frac{2^{\alpha_1} L_{h/2} - L_h}{2^{\alpha_1} - 1} - L = C_2^1 h^{\alpha_2} + C_3^1 h^{\alpha_3} + \dots,$$

其中 $C_2^1 = C_2(2^{\alpha_1 - \alpha_2} - 1)$ 。于是通过简单的加权求和，我们就得到了更高阶的数值格式：从 α_1 阶到 α_2 阶。而且这一过程可以继续，例如令 $L_h^1 = \frac{2^{\alpha_1} L_{h/2} - L_h}{2^{\alpha_1} - 1}$ ，这就是一个新的计算格式，而且也有类似的误差分析，再次外推后可以将误差从 α_2 阶提升到 α_3 阶。

要特别注意的是使用 Richardson 外推对问题本身没有明显的限制，不过最重要的一点是要对已有算法有非常精确的误差估计。下面我们用中心差分为例，看看怎么从中心差分这一简单的算法出发，通过 Richardson 外推得到更高精度的方法。首先通过 Taylor 展开，当 $f(x)$

具有足够的光滑性时, 我们有

$$\frac{f(x+h) - f(x-h)}{2h} - f'(x) = C_1 h^2 + C_2 h^4 + C_3 h^6 + \dots$$

记

$$E_{0,h} = \frac{f(x+h) - f(x-h)}{2h}, \quad E_{0,h/2} = \frac{f(x+\frac{h}{2}) - f(x-\frac{h}{2})}{h},$$

则由于 $\alpha_1 = 2$, 我们使用 Richardson 外推得到

$$\frac{4E_{0,h/2} - E_{0,h}}{3} = f'(x) + C_{21}h^4 + C_{31}h^6 + \dots \quad (5.34)$$

记上式记为 $E_{1,h}$, 同理可计算 $E_{1,h/2}$ 。而对于 $E_{1,h}$, 利用 $\alpha_2 = 4$, 可以得到

$$\frac{2^4 E_{1,h/2} - E_{1,h}}{2^4 - 1} = f'(x) + C_{32}h^6 + C_{42}h^8 + \dots \quad (5.35)$$

将上式记为 $E_{2,h}$, 并重复这种做法就可以得到高精度近似, 而计算代价较小的数值格式。我们回过头来看一下 $E_{1,h}$ 的表达式到底是什么。按照定义

$$\begin{aligned} E_{1,h} = \frac{4E_{0,h/2} - E_{0,h}}{3} &= \left[4 \frac{f(x+\frac{h}{2}) - f(x-\frac{h}{2})}{h} - \frac{f(x+h) - f(x-h)}{2h} \right] / 3 \\ &= \frac{1}{6h} \left[-f(x+h) + 8f(x+\frac{h}{2}) - 8f(x-\frac{h}{2}) + f(x-h) \right], \end{aligned}$$

这一格式和差分模板得到的公式完全一样 (需要把 $2h$ 换成 h)。

最后作为 Richardson 外推的一个练习, 读者可以尝试使用外推方法利用割圆法的计算结果作为基准, 从而给出计算圆周率的一个高精度计算格式。

5.2 Newton 求积公式

这一节和下一节我们都讨论数值积分的任务: 即根据一些点上所测量得到的函数值, 来估计函数在区间上的定积分。虽然对于任何连续函数来说, 我们可以通过 Newton-Leibniz 公式计算出不定积分然后在两个端点算差得到定积分的数值, 但是在具体操作上会面临如下几个困难: 首先即使被积函数是初等函数, 具有简单的表达式, 其不定积分不一定是初等函数 (事实上绝大部分初等函数的原函数都不是初等函数), 导致积分虽然有一个形式上的表达式但是事实上并不能简单的代入公式进行计算, 一个常见的例子是椭圆积分。另外在实际问题中常常没办法精确知道被积函数的具体表达式, 只能通过测量得到一些点上的函数值, 这就意味着不能使用 Newton-Leibniz 公式, 只能通过某种数值方法来估算定积分的数值, 这就是数值积分的由来。在这里我们主要考虑有限区间上的积分, 无限区间上的积分将在高斯型积分中略微提及。

一般来说, 我们希望计算 $f(x)$ 在区间 $[a, b]$ 上的定积分, 令

$$I(f) = \int_a^b f(x) dx.$$

数值积分的方法是在区间 $[a, b]$ 上选择若干求积点, 计算这些求积点对应的函数值, 然后

选择适当的求积系数使得求积公式具有如下形式

$$\int_a^b f(x)dx = I(f) \approx I_n(f) = \sum_{i=0}^n c_i f(x_i), \quad (5.36)$$

其中 x_i 为求积节点, c_i 为求积系数, $i = 0, 1, \dots, n$ 。下面给出两种常见的积分公式:

(1) 中点公式:

$$R = (b-a)f\left(\frac{a+b}{2}\right),$$

即取区间 $[a, b]$ 中点 $c = \frac{a+b}{2}$ 的函数值 $f(c)$ 来近似平均函数值 $f(\xi)$ 。

(2) 梯形公式:

$$T = \frac{b-a}{2} (f(a) + f(b)), \quad (5.37)$$

即取两个端点函数值 $f(a)$ 与 $f(b)$ 的算术平均值作为平均函数值 $f(\xi)$ 的近似值。

虽然数值积分格式的黄金标准应该是估计 $I_n - I$ 的大小, 但是因为直接估计其误差比较困难, 而且有可能因为不知道被积函数的某些特性导致估计不准确。

为了在某种意义下度量数值积分格式的准确性, 我们考虑被积函数是多项式空间的情况, 并引入代数精度的概念。

定义 5.1

若某个求积公式对于次数小于等于 k 的多项式均能准确成立, 但对于 $k+1$ 次多项式不准确成立, 即 $I_n(x^i) = I(x^i), i = 0, 1, \dots, k, I_n(x_{k+1}) \neq I(x_{k+1})$, 则称求积公式 I_n 具有 k 次代数精度。



由代数精度的定义我们可以知道, 如果求积公式 5.36 具有 n 阶代数精度, 则意味着它对于 $f(x) = x^i, i = 0, 1, \dots, n$ 都能准确成立, 此时若有已知的 $n+1$ 个求积节点 $x_i, i = 0, 1, \dots, n$ 以及函数在这些节点上的值, 则理论上可通过求解如下方程组来确定唯一的求积系数 c_i :

$$\begin{bmatrix} 1 & 1 & \cdots & 1 \\ x_0 & x_1 & \cdots & x_n \\ & & \cdots & \\ x_0^k & x_1^k & \cdots & x_n^k \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \\ \cdots \\ c_k \end{bmatrix} = \begin{bmatrix} b-a \\ \frac{1}{2}(b^2-a^2) \\ \cdots \\ \frac{1}{k+1}(b^{k+1}-a^{k+1}) \end{bmatrix}$$

很显然这个矩阵是 **Vandermonde** 矩阵, 当 $k = n$ 时具有唯一的解。但是一方面这个求解并没有很显然的表达式, 另外数值上来看求解 **Vandermonde** 矩阵是一个极其不稳定的任务。我们下面通过插值的方法来给出计算求积系数的公式。

假设在区间 $[a, b]$ 上给定一组节点

$$a \leq x_0 < x_1 < \cdots < x_n \leq b$$

且已知函数 $f(x)$ 在这些节点上的值, 作 $f(x)$ 在节点 $\{x_i\}_{i=0}^n$ 上的插值函数 $p_n(x)$, 取 $I_n = \int_a^b p_n(x)dx$ 作为积分 $I = \int_a^b f(x)dx$ 的近似值, 则式中求积系数 c_i 可以通过对 **Lagrange** 插值

基函数 $l_i(x)$ 积分求出

$$\begin{aligned}
 I_n &= \int_a^b p_n(x) dx \\
 &= \int_a^b \sum_{i=0}^n f(x_i) l_i(x) dx \\
 &= \sum_{i=0}^n f(x_i) \int_a^b l_i(x) dx \\
 &= \sum_{i=0}^n c_i f(x_i)
 \end{aligned} \tag{5.38}$$

这样构造出的求积公式称为插值型求积公式。由插值余项定理可知, 插值型求积公式的余项为

$$R[f] = I - I_n = \int_a^b \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega(x) dx. \tag{5.39}$$

式中 ξ 与变量 x 有关, $\omega(x) = (x - x_0)(x - x_1) \cdots (x - x_n)$ 。如果求积公式(5.38)是插值型的, 由(5.39)可知, 当 $f(x)$ 的次数 $\leq n$ 时, 余项 $R[f]$ 等于 0, 这表明该求积公式至少具有 n 次代数精度。事实上我们可以证明如下定理

定理 5.2

给定互不相同的节点 $\{x_i\}_{i=0}^n$, 只有选择求积系数 $c_i = \int_a^b l_i(x) dx$, 即插值型求积公式, 所得到的求积公式具有最高的代数精度, 且代数精度至少为 n 。



证明只需上面的计算过程加上 Vandermonde 矩阵的可逆性即可。如果我们采用示意图 5.2 中的解释, 插值型求积公式可以理解为采用插值多项式 p_n 来近似原来的被积函数 f 。

例题 5.3 验证求积公式

$$I(f) = I_2(f) + R(\rho, f) = \frac{b-a}{6} (f(a) + 4f(\frac{a+b}{2}) + f(b)) + R(\rho, f)$$

具有 3 次代数精度。

解 当 $f(x) = 1$ 时, $I(f) = \int_a^b 1 dx = b - a$, 而

$$I_2(f) = \frac{b-a}{6} (1 + 4 + 1) = b - a,$$

有 $R(\rho, 1) = 0$. 当 $f(x) = x$ 时, $I(f) = \frac{b^2-a^2}{2}$, 而

$$I_2(f) = \frac{b-a}{6} (a + 2(a+b) + b) = \frac{b^2-a^2}{2},$$

有 $R(\rho, x) = 0$. 当 $f(x) = x^2$ 时, $I(f) = \frac{b^3-a^3}{3}$, 而

$$I_2(f) = \frac{b-a}{6} (a^2 + (a+b)^2 + b^2) = \frac{b^3-a^3}{3},$$

有 $R(\rho, x^2) = 0$. 当 $f(x) = x^3$ 时, $I(f) = \frac{b^4-a^4}{4}$, 而

$$I_2(f) = \frac{b-a}{6} (a^3 + \frac{(a+b)^3}{2} + b^3) = \frac{b^4-a^4}{4},$$

有 $R(\rho, x^3) = 0$. 当 $f(x) = x^4$ 时, $I(f) = \frac{b^5 - a^5}{5}$, 而

$$I_2(f) = \frac{b-a}{6} \left(a^4 + \frac{(a+b)^4}{4} + b^4 \right) \neq I(f),$$

即 $R(\rho, x^4) \neq 0$. 因此可知该求积公式具有 3 次代数精度。

5.2.1 Newton-Cotes 公式

如果我们将插值节点采用等距划分的节点 $x_i = a + ih, h = \frac{b-a}{n}, i = 0, 1, \dots, n$, 则对应的插值型求积公式称为 Newton-Cotes 公式。由于节点事先固定, Newton-Cotes 公式的求积系数可以预先计算好, 在使用的时候直接利用查表法得到求积系数然后简单求和。

接下来我们给出一般 Newton-Cotes 求积公式的推导过程。假设对积分区间 $[a, b]$ 进行 n 等分, 令求积节点为 $\{x_i\}_{i=0}^n$, 相邻节点的区间长度为 $h = \frac{b-a}{n}$ 。通过引入变量替换 $x = a + th$, 则有 $t = \frac{b-a}{h}, t \in [0, n]$ 。由 Lagrange 插值基函数可知

$$\begin{aligned} l_k(x) &= l_k(a + th) = \prod_{i=0, i \neq k}^n \frac{x - x_i}{x_k - x_i} = \prod_{i=0, i \neq k}^n \frac{t - i}{k - i} \\ &= \frac{(-1)^{n-k}}{k!(n-k)!} \prod_{i=0, i \neq k}^n (t - i). \end{aligned} \quad (5.40)$$

因此由(5.38)可知

$$\begin{aligned} c_k &= \int_a^b l_k(x) dx \\ &= \int_0^n \frac{(-1)^{n-k}}{k!(n-k)!} \prod_{i=0, i \neq k}^n (t - i) d(ht) \\ &= \frac{b-a}{n} \frac{(-1)^{n-k}}{k!(n-k)!} \int_0^n \prod_{i=0, i \neq k}^n (t - i) dt. \end{aligned}$$

我们将

$$C_{n,k} = \frac{(-1)^{n-k}}{k!(n-k)!} \int_0^n \prod_{i=0, i \neq k}^n (t - i) dt, k = 0, 1, \dots, n,$$

称为 Newton-Cotes 求积系数, 称如下形式的求积公式为 Newton-Cotes 公式:

$$I_n = (b-a) \sum_{k=0}^n C_{n,k} f(x_k). \quad (5.41)$$

注意到当 $n = 1$ 时, Newton-Cotes 公式即为本节一开始给出的梯形公式。

当 $n = 2$ 时, Newton-Cotes 公式又称为 Simpson 公式, 其表达式为:

$$I_2 = \frac{b-a}{6} \left(f(a) + 4f\left(\frac{a+b}{2}\right) + f(b) \right),$$

即取 $x_0 = a, x_1 = \frac{a+b}{2}, x_2 = b$ 为求积节点并作二次插值多项式。我们可以利用上面给出的 Newton-Cotes 公式直接计算出节点的 Cotes 求积系数再将系数带入公式 (5.41) 中即可得到 Simpson 公式。

由定理 5.2 可知, Newton-Cotes 公式至少具有 n 次代数精度。下面的定理给出了 Newton-

Cotes 积分精确的误差估计, 并从中发现 Newton-Cotes 公式的代数精度当 n 为偶数时会提高一阶。

定理 5.3

令 $h = \frac{b-a}{n}$, $f(x)$ 具有足够的光滑性。令 Newton-Cotes 的数值积分和精确积分的数值分别为 I_n 和 I , 则 Newton-Cotes 求积公式 $I_n = \sum_{i=0}^n c_i f(x_i)$ 的余项估计为:

$$I - I_n = \begin{cases} \frac{h^{n+2}}{(n+1)!} \int_0^n t(t-1)\dots(t-n)dt f^{(n+1)}(\eta), n = \text{奇数}, \\ \frac{h^{n+3}}{(n+2)!} \int_0^n t^2(t-1)\dots(t-n)dt f^{(n+2)}(\eta), n = \text{偶数}. \end{cases}$$

其中 η 为某一个中值。



证明 因为 Newton-Cotes 公式为插值型求积公式, 利用高阶差商等式可知其余项为

$$R(f) = I(f) - I_n(f) = \int_a^b [f(x) - P_n(x)]dx = \int_a^b f[x_0, x_1, \dots, x_n, x] \omega_{n+1}(x) dx,$$

其中 $\omega_{n+1}(x) = \prod_{i=0}^n (x - x_i)$ 。定义 $\Omega(x) = \int_a^x \omega_{n+1}(t) dt$, 即 $\Omega(x)$ 为 $\omega_{n+1}(t)$ 的原函数, 则我们不难证明如下两个性质 (具体证明留作习题)

(1) 当 n 为偶数时, 通过对称性我们可以知道 $\Omega(a) = \Omega(b) = 0, \Omega(x) > 0, \forall x \in (a, b)$ 。

(2) 当 n 为奇数时, $\Omega(a) = 0, \Omega(x) < 0, \forall x \in (a, b]$ 。

下面我们分别考虑奇数和偶数的情况。当 n 为偶数时, 有

$$\begin{aligned} \int_a^b \omega_{n+1}(x) f[x_0, x_1, \dots, x_n, x] dx &= \int_a^b f[x_0, x_1, \dots, x_n, x] d\Omega(x) \\ &= \Omega(x) f[x_0, x_1, \dots, x_n, x] \Big|_a^b - \int_a^b \Omega(x) df[x_0, x_1, \dots, x_n, x]. \end{aligned}$$

然后我们需要用到高阶差商的一些重要性质, 证明留做习题。

(1) 如果 f 有足够的光滑性, 则 $f[x_0, \dots, x_n, x]$ 和 $\frac{d}{dx} f[x_0, \dots, x_n, x]$ 也是连续函数。

(2) $\frac{d}{dx} f[x_0, \dots, x_n, x] \Big|_{x=\xi} = \frac{f^{(n+2)}(\eta(\xi))}{(n+2)!}$, 其中 ξ 和 $\eta(\xi)$ 是区间 $[a, b]$ 中两个点。

于是利用积分中值定理可以得到

$$\begin{aligned} R(f) &= - \int_a^b \Omega(x) df[x_0, x_1, \dots, x_n, x] \\ &= - \frac{d}{dx} f[x_0, \dots, x_n, x] \Big|_{x=\xi} \int_a^b \Omega(x) dx \\ &= - \frac{f^{(n+2)}(\eta(\xi))}{(n+2)!} \int_a^b \Omega(x) dx. \end{aligned}$$

而

$$\int_a^b \Omega(x) dx = x\Omega(x) \Big|_a^b - \int_a^b x\omega_{n+1}(x) dx.$$

最后使用变量代换可以得到误差估计。

下面考虑 n 为奇数的情况。记 $\omega_n(x) = \prod_{i=0}^{n-1} (x - x_i)$, 我们将积分区域分为两部分可以计算

出

$$\int_a^b \omega_{n+1}(x) f[x_0, x_1, \dots, x_n, x] dx = \int_a^{b-h} \omega_{n+1}(x) f[x_0, x_1, \dots, x_n, x] dx + \int_{b-h}^b \omega_{n+1}(x) f[x_0, x_1, \dots, x_n, x] dx.$$

因为第二个积分中 ω_{n+1} 在区间 $[b-h, b]$ 中不变号, 由积分中值定理可得

$$\int_{b-h}^b \omega_{n+1}(x) f[x_0, x_1, \dots, x_n, x] dx = f[x_0, x_1, \dots, x_n, \xi] \int_{b-h}^b \omega_{n+1}(x) dx = \frac{f^{(n+1)}(\eta_1)}{(n+1)!} \int_{b-h}^b \omega_{n+1}(x) dx.$$

最后这一步使用了高阶差分的性质:

$$f[x_0, x_1, \dots, x_n, x] = \frac{f^{(n+1)}(\xi(x))}{(n+1)!}, \quad \xi(x) \in (a, b).$$

下面我们处理第一个积分区域, 主要利用 n 为偶数的结论。

$$\begin{aligned} \int_a^{b-h} \omega_{n+1}(x) f[x_0, x_1, \dots, x_n, x] dx &= \int_a^{b-h} \omega_n(x) \{f[x_0, x_1, \dots, x_{n-1}, x] - f[x_0, x_1, \dots, x_{n-1}, x_n]\} dx \\ &= \int_a^{b-h} \omega_n(x) f[x_0, x_1, \dots, x_{n-1}, x] dx \\ &= -\frac{f^{(n+1)}(\eta_2)}{(n+1)!} \int_a^{b-h} \Omega_n(x) dx. \end{aligned}$$

下面我们来验证 $\int_a^{b-h} \Omega_n(x) dx = -\int_a^{b-h} \omega_{n+1}(x) dx$ 。注意到 $\omega_{n+1}(x) = (x-b) \frac{d}{dx} \Omega_n(x)$, 于是有

$$\begin{aligned} \int_a^{b-h} \omega_{n+1}(x) dx &= \int_a^{b-h} (x-b) \frac{d}{dx} \Omega_n(x) dx \\ &= (x-b) \Omega_n(x) \Big|_a^{b-h} - \int_a^{b-h} \Omega_n(x) dx \\ &= -\int_a^{b-h} \Omega_n(x) dx. \end{aligned}$$

然后利用导函数的介值性, 我们可以得到

$$\int_a^b \omega_{n+1}(x) f[x_0, x_1, \dots, x_n, x] dx = \frac{f^{(n+1)}(\eta)}{(n+1)!} \int_a^b \omega_{n+1}(x) dx.$$

最后作 $x = a + th$ 的变量代换即可得到结果。

作为推论, 我们可以得到下面估计式。

推论 5.2

对于 $n = 1, 2$, 我们有梯形公式的误差为 $\frac{h^3}{12} f''(\xi)$, Simpson 公式的误差为 $\frac{h^5}{90} f^{(4)}(\xi)$.



例题 5.4 用 Simpson 求积公式计算积分 $\int_{0.4}^{0.6} \frac{1}{x+1} dx$ 的近似值并估计误差。

解 已知 $n = 2$, 则有 $h = \frac{b-a}{2} = 0.1$. 根据 Simpson 求积公式可以得到积分的近似值

$$I_2(f) = \frac{0.6-0.4}{6} \left(\frac{1}{1+0.4} + 4 \frac{1}{1+\frac{1}{2}(0.4+0.6)} + \frac{1}{0.6} \right) \approx 0.1335317.$$

按照定理 5.2 给出的公式计算余项估计:

$$f^{(4)}(x) = \frac{24}{(x+1)^5},$$

$$|R(1, f)| = \left| -\frac{h^5}{90} f^{(4)}(\eta) \right| = \frac{h^5}{90} \frac{24}{(\eta+1)^5} \leq \frac{24}{90} (0.1)^5 \approx 0.27 \times 10^{-5}.$$

为了应用 Newton-Cotes 积分公式，我们需要计算出积分系数。下面的表格 5.1 给出了 $n = 1$ 到 $n = 8$ 的 Cotes 公式求积系数。

表 5.1: Cotes 求积公式系数

n	C_k^n								
1	$\frac{1}{2},$	$\frac{1}{2}$							
2	$\frac{1}{6},$	$\frac{4}{6},$	$\frac{1}{6}$						
3	$\frac{1}{8},$	$\frac{3}{8},$	$\frac{3}{8},$	$\frac{1}{8}$					
4	$\frac{7}{90},$	$\frac{16}{45},$	$\frac{2}{15},$	$\frac{16}{45},$	$\frac{7}{90}$				
5	$\frac{19}{288},$	$\frac{25}{96},$	$\frac{25}{144},$	$\frac{25}{144},$	$\frac{25}{96},$	$\frac{19}{288}$			
6	$\frac{41}{840},$	$\frac{9}{35},$	$\frac{9}{280},$	$\frac{31}{105},$	$\frac{9}{280},$	$\frac{9}{35},$	$\frac{41}{840}$		
7	$\frac{751}{17280},$	$\frac{3577}{17280},$	$\frac{1323}{17280},$	$\frac{2939}{17280},$	$\frac{2939}{17280},$	$\frac{1323}{17280},$	$\frac{3577}{17280},$	$\frac{751}{17280}$	
8	$\frac{989}{28350},$	$\frac{5888}{28350},$	$\frac{-928}{28350},$	$\frac{10496}{28350},$	$\frac{-4540}{28350},$	$\frac{10496}{28350},$	$\frac{-928}{28350},$	$\frac{5888}{28350},$	$\frac{989}{28350}$
...	...								

在实际问题中，高阶 Newton-Cotes 公式并不实用。这里的不实用可以从两个方面来理解，首先按照示意图 5.2 的解释，Newton-Cotes 积分格式等价于先对 $f(x)$ 在等距节点上进行多项式插值，然后用插值多项式的积分来替代原始函数的积分。而我们知道等距节点上多项式插值没有稳定性，如 Runge 现象或者舍入误差被放大 Lebesgue 常数倍等。另外一个方面，我们也会发现 Cotes 求积系数在高阶多项式中出现了负数，这就意味着在计算有误差的情况下，误差可能会被放大（这一现象和插值多项式对舍入误差敏感相互联系，都是数值稳定性的问题）。

为了得到稳定有效的数值积分格式，我们在下面的章节中分别考虑了复化 Newton-Cotes 积分（采用分段 Lagrange 插值函数替代原先的被积函数）和 Gauss 积分（选择恰当的插值点使得多项式插值是一个好的近似函数）。

5.2.2 复化 Newton-Cotes 公式

实际应用中，数值积分的节点 x_i 可能无法自由选择（例如最常见的给定等距节点），而我们已知高次多项式插值得到的 Newton-Cotes 积分没有稳定性，所以我们需要寻找更加稳定、精确的数值积分格式。为了得到高效的数值积分公式，我们先对积分区间分段，在每个区间中使用低阶多项式插值，然后再进行积分，这就是复化方法。从 Riemann 积分的定义（分割-求和-取极限）中我们可以自然的理解复化方法，注意到复化方法的代数精度并没有改变，但是

误差的大小会依赖分段的大小而发生相应的变化。下面我们主要在等距节点上考虑几种基本的复化积分方法。

设将积分区间 $[a, b]$ 等距划分为 n 个子区间, 区间长度为 $h = \frac{b-a}{n}$, 节点为 $x_i = a + ih, i = 0, 1, \dots, n$. 接着我们在每个子区间上使用低阶的 Newton-Cotes 公式来计算积分值 I_i , 然后用 $\sum_{i=0}^n I_i$ 来作为函数积分 I 的近似值, 最后得到的公式就是复化 Newton-Cotes 公式。几个不同阶数的复化求积公式如下:

(1) 复化梯形公式

$$\begin{aligned} T_n &= \sum_{i=0}^{n-1} \frac{h}{2} [f(x_i) + f(x_{i+1})] \\ &= \frac{h}{2} \left[f(a) + 2 \sum_{i=1}^{n-1} f(x_i) + f(b) \right] \end{aligned} \quad (5.42)$$

其余项估计为

$$|I(f) - T_n(f)| \leq \sum_{i=0}^{n-1} |I(f) - T_n^i(f)| \leq \sum_{i=0}^{n-1} \frac{h^3}{12} \|f''\|_{\infty} = \frac{(b-a)^3}{12n^2} \|f''\|_{\infty}$$

(2) 复化 Simpson 公式记子区间 $[x_i, x_{i+1}]$ 的中点为 $x_{i+\frac{1}{2}}$,

$$\begin{aligned} S_n &= \sum_{k=0}^{n-1} \frac{h}{6} \left[f(x_k) + 4f\left(x_{k+\frac{1}{2}}\right) + f(x_{k+1}) \right] \\ &= \frac{h}{6} \left[f(x_0) + 4 \sum_{k=0}^{n-1} f\left(x_{k+\frac{1}{2}}\right) + 2 \sum_{k=1}^{n-1} f(x_k) + f(x_n) \right]. \end{aligned} \quad (5.43)$$

其余项估计为

$$|I(f) - S_n(f)| \leq \sum_{i=0}^{n-1} |I(f) - T_n^i(f)| \leq \sum_{i=0}^{n-1} \frac{h^5}{2880} \|f^{(4)}\|_{\infty} = \frac{(b-a)^5}{2880n^4} \|f^{(4)}\|_{\infty}$$

例题 5.5 用复化 Simpson 求积公式计算 $\int_0^4 e^x dx$ 的近似值。

解 令 $n = 2$, 则有 $h = \frac{b-a}{n} = 2$, 由复化 Simpson 求积公式可知

$$S_2(f) = \frac{1}{3} (e^0 + 4e + 2e^2 + 4e^3 + e^4) \approx 54.436606.$$

令 $n = 3$, 则有 $h = \frac{b-a}{n} = \frac{4}{3}$, 由复化 Simpson 求积公式可知

$$S_3(f) = \frac{2}{9} \left(e^0 + 4e^{\frac{2}{3}} + 2e^{\frac{4}{3}} + 4e^2 + 2e^{\frac{8}{3}} + 4e^{\frac{10}{3}} + e^4 \right) \approx 54.035836.$$

对于复化梯形公式, 我们有非常精细的误差估计: Euler-MacLaurin 公式, 这一公式也是应用 Richardson 外推得到 Romberg 算法的基础。

定理 5.4 (Euler-MacLaurin 公式。)

令 $f(x) \in C^{2k+2}[a, b]$, $h = \frac{b-a}{m}$ 使用梯形公式逼近积分, 其误差可以表示为:

$$R(f) = I(f) - I_n(f) = \sum_{i=1}^k \frac{B_{2i}}{(2i)!} h^{2i} f^{(2i-1)} \Big|_a^b + \frac{B_{2k+2}}{(2k+2)!} h^{2k+2} (b-a) f^{(2k+2)}(\eta) \quad (5.44)$$

这里 $\eta \in (a, b)$, $B_{2j} = (-1)^{j-1} [2/(2n\pi)^{2j}] (2j)!$ 为 Bernoulli 数。



Euler-MacLaurin 公式的证明可以参考 [10]。该公式给出了复化梯形的渐进误差展开，这可以用来构造外推型算法。

从 Euler-MacLaurin 公式中我们有一个重要的推论：如果函数 f 是周期的，则复化梯形公式的误差完全取决于其光滑性，光滑性越高，误差阶越高，如果函数 f 是解析的，复化梯形公式可以达到谱精度。

另外复化中点公式（虽然没有给出其详细的表达式）和复化梯形公式具有类似的结论，证明过程也完全类似，可以参考 [3]。

5.2.3 Romberg 算法

Romberg 算法是一种结合了复化梯形求积公式和 Richardson 外推公式的算法。首先回顾在前面的小节给出的复化梯形求积公式：

$$T_n = \frac{b-a}{2n} \left[f(a) + 2 \sum_{i=1}^{n-1} f(x_i) + f(b) \right] \quad (5.45)$$

其余项估计为

$$I(f) - T_n(f) = C_1 n^{-2} + C_2 n^{-4} + C_3 n^{-6} + \dots$$

我们记 $T_n^{(1)} = T_n$ ，即通过复化梯形公式直接计算得到的数值。然后应用 Richardson 外推方法，

$$\begin{aligned} T_n^{(2)} &= \frac{4T_{2n}^{(1)} - T_n^{(1)}}{4-1}, \\ T_n^{(3)} &= \frac{4^2 T_{2n}^{(2)} - T_n^{(2)}}{4^2-1}, \\ T_n^{(4)} &= \frac{4^3 T_{2n}^{(3)} - T_n^{(3)}}{4^3-1}, \\ &\dots \end{aligned}$$

持续上述过程，我们可以得到误差为 $\int_a^b f(x)dx - T_n^{(k)} = O(n^{-2k})$ 。

在实际计算过程中，我们可以根据误差的需要确定迭代的次数，从而进一步确定计算复化梯形公式的点数，具体计算过程可以参考如下表格 5.2。

在本节的最后，我们给出应用复化 Newton-Cotes 公式中的梯形公式和 Romberg 算法（给定分点后只进行一步 Richardson 外推）来计算积分的例子

例题 5.6 取待求积分 $I(f) = \int_{-1}^1 \frac{4}{1+x^2} dx (= 2\pi)$ ，依次取节点数为 $n+1 = 3, 4, \dots, 7$ ，计算出 $|I(f) - T_n(f)|$ 如下：

5.3 Gauss 型积分

前面的章节中我们主要考虑给定求积节点 $\{x_i\}_{i=0}^n$ 的时候，如何选择合适的求积系数 c_i 使得数值积分格式能够具有较好的逼近性。这一逼近性可以从积分误差来理解（如复化梯形公式），也可以从具有最高的代数精度来理解（如 Newton-Cotes 积分）。有没有可能通过选择合

表 5.2: Romberg 方法的计算结果

h	$T_n^{(1)}$
$\frac{h}{2}$	$T_{2n}^{(1)}, T_n^{(2)}$
$\frac{h}{2^2}$	$T_{4n}^{(1)}, T_{2n}^{(2)}, T_n^{(3)}$
$\dots$	$\dots, \dots, \dots, \dots$
$\frac{h}{2^k}$	$T_{2^k n}^{(1)}, T_{2^{k-1}n}^{(2)}, T_{2^{k-2}n}^{(3)}, \dots, T_n^{(k+1)}$

表 5.3: 两种求积公式的计算误差

节点数 $(n+1)$	3	4	5	6	7
Newton-Cotes	2.832×10^{-1}	1.499×10^{-1}	8.3185×10^{-2}	5.3321×10^{-2}	3.7031×10^{-2}
Romberg	1.3672×10^{-2}	1.1684×10^{-3}	1.2538×10^{-4}	1.4565×10^{-5}	1.7565×10^{-6}

适的求积节点，使得数值积分格式能够同时具备较高的代数精度和数值精度，而且具有良好的数值稳定性？这类求积节点和对应的求积系数是存在的，我们这一节中就要推导这类数值积分格式，称为 Gauss 积分格式。

为了推导格式的可行性，我们将目标聚焦于代数精度：即假设 $f(x)$ 在区间 $[a, b]$ 上的近似求积公式为 $\sum_{i=0}^n c_i f(x_i)$ ，通过调整节点 x_i 和节点系数 c_i ，使得求积公式具有最高的代数精度，为了简单起见，不妨设积分区间 $[a, b] = [-1, 1]$ 。

我们从 $n = 0$ 开始，这时候 $I_0(f) = c_0 f(x_0)$ 。数值积分格式中有两个自由度 (c_0, x_0) ，可以期待当 $f(x)$ 为常函数和线性函数时都精确成立，即

$$f(x) \equiv 1, \quad c_0 f(x_0) = \int_{-1}^1 1 dx = 2 \Rightarrow c_0 = 2.$$

$$f(x) = x, \quad c_0 f(x_0) = \int_{-1}^1 1 x dx = 0 \Rightarrow x_0 = 0.$$

于是数值积分格式为 $I_0(f) = 2f(0)$ ，这时候等价于中点格式。

下一步考虑 $n = 1$ 时， $I_1(f) = c_0 f(x_0) + c_1 f(x_1)$ ，数值积分格式中有四个自由度。自然的我们可以期待当 f 为不超过 3 次多项式时，积分都精确成立，即

$$\begin{cases} f(x) = 1, & c_0 f(x_0) + c_1 f(x_1) = c_0 + c_1 = 2. \\ f(x) = x, & c_0 f(x_0) + c_1 f(x_1) = c_0 x_0 + c_1 x_1 = 0. \\ f(x) = x^2, & c_0 f(x_0) + c_1 f(x_1) = c_0 x_0^2 + c_1 x_1^2 = \frac{2}{3}. \\ f(x) = x^3, & c_0 f(x_0) + c_1 f(x_1) = c_0 x_0^3 + c_1 x_1^3 = 0. \end{cases}$$

通过初等数学的技巧, 不难得到

$$\begin{cases} c_0 = c_1 = 1 \\ x_0 = -\frac{1}{\sqrt{3}} \\ x_1 = \frac{1}{\sqrt{3}} \end{cases}$$

于是 $I_1(f) = f(-\frac{1}{\sqrt{3}}) + f(\frac{1}{\sqrt{3}})$, 这一积分格式并不显然。这种求解方法当 n 逐渐增加时, 需要求解规模庞大的非线性方程组, 其难度会快速增长, 事实上 $n = 2$ 已经很难通过初等方法计算得到。

为了得到一般的 n 时的积分点和积分系数, 我们首先回顾上一节的知识: 为了保证数值求积格式具有最高的代数精度, 其必须是插值型求积公式, 这时候代数精度至少为 n 。于是在给定求积节点 $\{x_i\}_{i=0}^n$ 后, 求积系数必须由 Lagrange 基底的积分给出, 即 $c_i = \int_{-1}^1 l_i(x)dx$, 这样剩下的任务就是确定求积节点 x_i 。从自由度上看, 求积节点加上求积系数一共 $2n + 2$ 个自由度, 找到具有 $2n + 1$ 次代数精度的方案是很自然和现实的。接下来我们希望选取一组合适的插值点 $\{x_i\}_{i=0}^n$, 使求积公式具有 $2n + 1$ 次代数精度, 即

$$\int_{-1}^1 f(x)dx = \sum_{i=0}^n c_i f(x_i), \quad \forall f(x) \in \mathbb{P}_{2n+1}. \quad (5.46)$$

对于 $f(x) \in \mathbb{P}_{2n+1}$, 令 $p_n(x)$ 为其在 $\{x_i\}_{i=0}^n$ 上的插值多项式, 于是由插值型积分公式的代数精度至少为 n 得到

$$\int_{-1}^1 p_n(x)dx = \sum_{i=0}^n c_i p_n(x_i) = \sum_{i=0}^n c_i f(x_i),$$

于是我们的目标变成了

$$\int_{-1}^1 p_n(x)dx = \int_{-1}^1 f(x)dx.$$

注意到 $f(x) - p_n(x)$ 是一个不超过 $2n + 1$ 次的多项式, 并且 $\{x_i\}_{i=0}^n$ 是它的零点。于是我们有

$$f(x) - p_n(x) = q_n(x)\omega_{n+1}(x),$$

其中 $\omega_{n+1}(x) = (x - x_0) \cdots (x - x_n)$, $q_n(x) \in \mathbb{P}_n$ 。这样我们的目标再次改变为

$$\int_{-1}^1 q_n(x)\omega_{n+1}(x)dx = 0.$$

由 q_n 的任意性, 我们发现 ω_{n+1} 须正交于 $\mathbb{P}_n$ 。这是完全可能做到的, 因为 $n + 1$ 次 Legendre 正交多项式就满足这个性质并且其根均位于 $(-1, 1)$ 。综上所述, 我们可以得到下面的定理:

定理 5.5

若选取 $\{x_i\}_{i=0}^n$ 为 $n + 1$ 次 Legendre 正交多项式的零点, 且 $\{c_i\}_{i=0}^n$ 选取为 Newton-Cotes 系数, 则数值积分具有 $2n + 1$ 次代数精度, 即

$$\int_a^b f(x)dx = \sum_{i=0}^n c_i f(x_i), \quad f(x) \in \mathbb{P}_{2n+1}. \quad (5.47)$$

称这种形式的求积公式成为 Gauss 型求积公式。



在讨论 Gauss 积分的误差之前,我们先考虑数值稳定性。为了证明数值稳定性,我们只需要证明求积系数均为正值即可。

推论 5.3

Gauss 型求积公式 $\sum_{i=0}^n c_i f(x)$ 的系数 $\{c_j\}_{j=1}^n$ 均为大于零的正数.



证明 不失一般性,只需要证明 $c_0 > 0$ 。令 $f(x) = \left[\prod_{j=1}^n (x - x_j) \right]^2$, 则有

$$f(x_i) = \begin{cases} 0, & i \neq 0, \\ \prod_{j=1}^n (x_0 - x_j)^2, & i = 0. \end{cases}$$

因为 $f(x) \in \mathbb{P}_{2n-2}$, 则求积公式对 $f(x)$ 精确成立, 即有

$$\int_a^b \prod_{j=1}^n (x - x_j)^2 dx = I(f) = \sum_{i=1}^n c_i f(x_i) = c_k \prod_{j=1, j \neq k}^n (x_k - x_j)^2.$$

由

$$\prod_{j=1, j \neq k}^n (x_k - x_j)^2 > 0,$$

以及

$$\int_a^b \prod_{j=1}^n (x - x_j)^2 dx > 0,$$

可知 $c_0 > 0$ 。

因为 Gauss 积分所有的求积系数均为正数, 很容易说明测量误差不会在数值计算中被放大, 从而说明了 Gauss 积分的数值稳定性。

在定理 5.5 中, 我们考虑的是有限区间上通常的数值积分, 所采用的积分点为 Legendre 多项式的零点, 这样的数值积分格式通常也称为 Gauss-Legendre 积分。关于 Gauss-Legendre 积分的误差估计, 利用上一章知识拓展中的结论, 再使用 Cauchy-Schwarz 不等式很容易说明

$$|I(f) - I_n(f)| \leq C \frac{\|f\|_s}{n^s}, \quad (5.48)$$

其中 $\|f\|_s = \sqrt{\sum_{i=0}^s \|f^{(i)}\|^2}$ 。

下面我们用一个简单的例子来验证当节点数 $n+1$ 变大时, 误差变小。

例题 5.7 取待求积分为 $I(f) = \int_{-1}^1 \frac{4}{1+x^2} dx (= 2\pi)$ 。我们依次取节点数为 $n+1 = 3, 4 \dots 7$, 计算出 $|I(f) - I_n(f)|$ 如下:

表 5.4: Gauss-Legendre 求积公式计算误差

节点数 ($n+1$)	3	4	5	6	7
误差	5.0148×10^{-2}	8.6755×10^{-3}	1.4994×10^{-3}	2.5848×10^{-4}	4.4506×10^{-5}

结合上一节中例题 5.6, 我们画出这三种方法随着节点数的增加, 误差减小的速率如上图。




图 5.5: 三种求积公式计算误差

从图中我们容易发现，就收敛速度而言：Romberg（给定分点后只进行一步 Richardson 外推）> Gauss-Legendre > Newton-Cotes。且前两种方法能很快达到所需要的精度。

5.4 知识拓展

上一章节中我们主要介绍了有限区间内正常定积分的计算，得到的 Gauss 积分格式为 Gauss-Legendre 求积公式。事实上我们可以考虑比较一般的带权的积分，即

$$\int_a^b \rho(x) f(x) dx \approx \sum_{i=0}^n c_i f(x_i). \quad (5.49)$$

通过完全类似的推导，Gauss 求积公式可以推广到带权的求积公式，即

$$\int_a^b \rho(x) f(x) dx = \sum_{i=0}^n c_i f(x_i). \quad (5.50)$$

如果积分区域为 $[-1, 1]$ ，权函数 $\rho(x) = \frac{1}{\sqrt{1-x^2}}$ ，可以发现求积节点为 Chebyshev 多项式的零点，这个积分称为 Gauss-Chebyshev 积分。另外半无界区间或者无界区间上的反常积分也可以通过改写为恰当的带权积分来进行数值逼近，即

$$\int_a^{+\infty} \rho(x) f(x) dx = \sum_{i=0}^n c_i f(x_i), \quad \int_{-\infty}^{+\infty} \rho(x) f(x) dx = \sum_{i=0}^n c_i f(x_i). \quad (5.51)$$

根据权函数的不同，可以采用 Laguerre 多项式或者 Hermite 多项式的零点作为积分点，对应的求积公式为 Gauss-Laguerre 积分或者 Gauss-Hermite 积分。

由于正交多项式的零点不在边界上，所得到的 Gauss 积分的求积点也都不在边界上。在很多实际问题里，边界上的函数值可以非常方便地得到精确值，为了合理利用这一信息，我们有两种 Gauss-Legendre 积分的变形：Gauss-Legendre-Lobatto 积分和 Gauss-Legendre-Radau 型积分。其中 Gauss-Legendre-Lobatto 型积分要求使用两个边界点，形式为

$$I_n(f) = c_0 f(a) + \sum_{i=1}^{n-1} c_i f(x_i) + c_n f(b). \quad (5.52)$$

而 Gauss-Legendre-Radau 型积分只要求使用左右边界点中地任意一个即可 (称为 Left-Radau 和 Right-Radau), 其形式为

$$I_n(f) = c_0 f(a) + \sum_{i=1}^n c_i f(x_i), \quad I_n(f) = \sum_{i=0}^{n-1} c_i f(x_i) + c_n f(b). \quad (5.53)$$

为了得到 Gauss-Legendre-Lobatto 积分或者 Gauss-Legendre-Radau 积分的积分点, 我们需要重新建立多项式空间 $\mathbb{P}_n$ 的子空间如

$$\mathbb{P}_{n,0} = \{p(x) \in \mathbb{P}_n, p(a) = p(b) = 0\}$$

上的正交多项式基底。具体的构造过程可以先从简单的单项式组合满足边界条件得到一组基底出发通过 Gram-Schmidt 正交化过程获得, 也可以将 Legendre 多项式进行线性组合后满足边界条件得到, 具体的过程读者可以查阅更加专业的书籍或者自行尝试完成。Gauss-Legendre-Lobatto 积分或者 Gauss-Legendre-Radau 积分具有和 Gauss-Legendre 积分类似的精度和性质。

第5章 练习

1. 设 $f(x) = e^x$.

(a) 步长分别为 $h = 0.1, h = 0.01$ 和 $h = 0.001$, 分别利用向前差分法、向后差分法和中心差分法计算 $f'(2.3)$ 的近似值。精度为小数点后 8 位或 9 位。

(b) 与值 $f'(2.3) = e^{2.3}$ 进行比较。

(c) 计算中心差分法的误差估计, 其中使用

$$|f^{(3)}(c)| \leq e^{2.4} \approx 11.02317638$$

2. 设 $f(x) = \sin(x)$, x 用弧度表示。

(a) 步长分别为 $h = 0.1$ 和 $h = 0.001$, 利用二阶导数的中心差分格式计算 $f'(0.8)$ 的近似值。精度为小数点后 8 位或 9 位。

(b) 与值 $f'(0.8) = \cos(0.8)$ 进行比较。

(c) 计算二阶导数的中心差分格式的误差估计, 其中使用

$$|f^{(4)}(c)| \leq \sin(1.0) \approx 0.8414709848$$

3. 利用梯形公式以及 Simpson 公式求

$$\int_1^2 \ln x dx$$

的近似。将近似值与真实值比较。如果可能, 求两种做法下的最大误差界限。

4. 若函数 $f(x)$ 在 $[a, b]$ 上可积, 试证明: 复化梯形公式以及复化 Simpson 求积公式的值, 当 $n \rightarrow \infty$ 时收敛于积分值 $\int_a^b f(x) dx$.

5. 应用 Simpson 公式来推导关于在矩形 $a \leq b, c \leq d$ 上的二重积分

$$\int_a^b dx \int_c^d f(x, y) dy$$

6. 确定求积系数 A_1, A_2 和求积节点 x_1, x_2 , 使求积公式

$$\int_0^1 \frac{1}{\sqrt{x}} f(x) dx = A_1 f(x_1) + A_2 f(x_2) + R(x), \quad R(x) \text{ 为误差估计}$$

成为 Gauss 型求积公式.

7. 阿基米德通过计算直径为 1 的圆的内接和外切正多边形的周长来近似 π . 一个内接 n 边形的周长按照 $p_n = n \sin(\pi/n)$ 计算, 外切的按照 $q_n = n \tan(\pi/n)$ 计算, 这些值分别提供了 π 值的下界和上界.

(1) 通过对 $\sin$ 和 $\tan$ 函数进行 Taylor 级数展开, 证明 p_n 和 q_n 可以分别表示成如下形式:

$$p_n = a_0 + a_1 h^2 + a_2 h^4 + \cdots$$

和

$$q_n = b_0 + b_1 h^2 + b_2 h^4 + \cdots,$$

其中 $h = 1/n$. a_0 和 b_0 的具体值是多少?

(2) 若算出 $p_6 = 3.0000$, $p_{12} = 3.1058$, 试使用 Richardson 外推公式给出一个对 π 的更好的近似. 类似地, 若给定 $q_6 = 3.4641$, $q_{12} = 3.2154$, 使用 Richardson 外推公式给出一个对 π 的更好的近似.

8. 验证求积公式

$$\int_{-\infty}^{+\infty} e^{-x^2} f(x) dx \approx \frac{\sqrt{\pi}}{6} (f(-\sqrt{\frac{3}{2}}) + 4f(0) + f(\sqrt{\frac{3}{2}})) + R(x), \quad R(x) \text{ 为误差估计}$$

对所有次数不超过 5 次的代数多项式精确成立.

9. 试证明定理 5.3 中的几个小引理:

(1) 我们已经给出 $\Omega(x)$ 的定义, 即 $\Omega(x) = \int_a^x w_{n+1}(t) dt$, 请证明 $\Omega(x)$ 的如下两个性质:

- 当 n 为偶数时, 通过对称性我们可以知道 $\Omega(a) = \Omega(b) = 0, \Omega(x) > 0, \forall x \in (a, b)$.
- 当 n 为奇数时, $\Omega(a) = 0, \Omega(x) < 0, \forall x \in (a, b]$.

(2) 利用高阶差商的性质, 证明:

- 如果 f 有足够的光滑性, 则 $f[x_0, \dots, x_n, x]$ 和 $\frac{d}{dx} f[x_0, \dots, x_n, x]$ 也是连续函数.
- $\frac{d}{dx} f[x_0, \dots, x_n, x]|_{x=\xi} = \frac{f^{(n+2)}(\eta(\xi))}{(n+2)!}$, 其中 ξ 和 $\eta(\xi)$ 是区间 $[a, b]$ 中两个点.

第6章 常微分方程数值解

在许多科学工程问题中都会通过常微分方程(组)进行数学建模,例如天体运动模型、传染病模型、弦振动模型等。常微分方程根据所给定解条件的不同,通常可以分为初值问题和边值问题,本章主要介绍一阶常微分方程(组)的初值问题和二阶常微分方程边值问题的数值解法。其中一阶常微分方程通常用下面的模型来描述

$$\begin{cases} \frac{dx(t)}{dt} = f(t, x(t)), & t > 0 \\ x(0) = x_0 \end{cases} \quad (6.1)$$

其中 f 是 x 和 t 的二元函数, x_0 是给定的初值。若 $x \in \mathbb{R}^n$ 为向量,则 f 相应的改为 $\mathbb{R}^+ \times \mathbb{R}^n$ 上的多元函数,初值也置为对应的向量即可。二阶常微分方程的边值问题则通常被描述为

$$\begin{cases} y'' = f(x, y, y'), & a \leq x \leq b, \\ y(a) = \alpha, & y(b) = \beta, \end{cases} \quad (6.2)$$

其中 $y = y(x)$, f 是给定的三元函数, α, β 为给定的常数。但是注意到如果将方程(6.2)中的定解条件 $y(b) = \beta$ 替换为 $y'(a) = \beta$, 则可以通过引入中间变量 $z = y'$, 从而将二阶微分方程改写为带着初值条件的一阶常微分方程组。关于常微分方程初值问题的数学理论,读者可以参考任意一本常微分方程的教科书,我们这里总是假设所给定的常微分方程初值问题在所求的时间范围内存在唯一的光滑解。

常微分方程数值方法涵盖的范围非常宽广,本书只选择了其中非常少量的内容进行介绍,例如在初值问题中我们仅仅介绍了有限时间问题的数值方法,而这些方法对于大时间的常微分系统可能完全不适用(我国著名计算数学专家冯康先生所提出的辛方法和辛格式就是专门针对大时间的哈密尔顿系统进行稳定的数值求解)。

6.1 初值问题的数值方法

这一节中我们主要关注初值问题的数值方法。对于初值问题,我们把数值方法集中在差分方法上:即先在时间区域 $[0, T]$ 上构造网格

$$0 = t_0 < t_1 < t_2 < \cdots < t_N = T,$$

然后再分别近似 $x(t_i) \approx x_i$, 如果需要估计非时间节点上的函数值,我们可以通过插值、逼近等方法进行进一步近似。通常情况下我们总是选择时间方向的等距节点,即 $\tau = \Delta t = \frac{T}{N}$, $t_i = i\tau$, 在后面的章节中,如果不做特殊说明我们总是假设时间方向进行等距剖分。

对数值方法进行分类的话,大致可以分为

- (1) 单步法: 通过 x_i 的数值可以计算出 x_{i+1} ,
- (2) 多步法: 通过 $x_{i-k}, \dots, x_i$ 的数值计算出 x_{i+1} ,
- (a) 显格式: 在计算 x_{i+1} 的过程中只涉及函数值计算,而不需要求解方程,

(b) 隐格式：需要求解方程来得到 x_{i+1} 的数值，

本书将主要关注单步法的格式；显格式在计算上看起来会比较简单，但是对于比较困难的问题（如刚性问题）可能会面临稳定性的困扰。

6.1.1 Euler 方法和 Crank-Nicolson 方法

推导初值问题数值格式最常用的方法有泰勒展开，或者数值积分的方法，我们分别用这两种方法推导最常见的三类最常见的数值方法：向前 Euler 方法、向后 Euler 方法及 Crank-Nicolson 方法。

首先我们来推导向前 Euler 方法。注意到初值问题 (6.1) 在每个网格点 t_i 上都成立，我们可以得到

$$\frac{dx}{dt}\bigg|_{t=t_i} = f(t_i, x(t_i)).$$

在等式的左边使用向前差分方法来近似，我们得到：

$$\frac{x(t_{i+1}) - x(t_i)}{\tau} \approx f(t_i, x(t_i)) \Rightarrow x_{i+1} \approx x_i + \tau f(t_i, x(t_i)).$$

我们再进行近似，即 $x_i \approx x(t_i)$ ，这就自然的得到了最基本的**向前 Euler 方法**：

$$x_{i+1} = x_i + \tau f(t_i, x_i), \quad i = 0, 1, 2, \dots, \quad (6.3)$$

其中 x_0 就是初始条件 $x(0)$ 。向前 Euler 方法的直观理解参见图 6.1，即在每个区间 $[t_j, t_{j+1}]$ 上，使用线性函数来近似 $x(t)$ ，这一线性函数由 t_j 点的函数值和导数值所唯一确定。很显然向前 Euler 方法是显格式（只需要计算函数值即可）。




图 6.1: 前向欧拉示意图。其中黑色虚线表示欧拉估计值和真实值之间的误差。

类似的，如果我们采用向后差分来近似 $\frac{dx}{dt}\big|_{t=t_i}$ ，就可以得到

$$\frac{x(t_i) - x(t_{i-1})}{\tau} \approx f(t_i, x(t_i)) \Rightarrow x_i \approx x_{i-1} + \tau f(t_i, x(t_i)).$$

再进一步进行近似 $x_{i-1} \approx x(t_{i-1})$ ，并用 $i+1$ 的记号代替 i ，我们就得到了**向后 Euler 方法**：

$$x_{i+1} = x_i + \tau f(t_{i+1}, x_{i+1}), \quad i = 0, 1, 2, \dots \quad (6.4)$$

注意到**向后 Euler 方法**(6.4)和**向前 Euler 方法**(6.3)的不同之处在于，**向后 Euler 方法**(6.4)的每一个迭代步都需要求解方程，并不能直接通过估计函数值得到，因此**向后 Euler 方法**是一种隐格式。

如果我们把上述推导过程应用到中心差分中，即

$$\frac{x(t_{i+1}) - x(t_{i-1}))}{2\tau} \approx f(t_i, x(t_i)) \Rightarrow x_{i+1} \approx x_{i-1} + \tau f(t_i, x(t_i)).$$

这样对应的数值格式就是

$$x_{i+1} = x_{i-1} + \tau f(t_i, x_i).$$

很明显上述的数值格式是多步法（需要两个初值来进行迭代），不属于本书讨论的范畴。

我们发现**向前 Euler 方法**和**向后 Euler 方法**都是一阶方法（使用了一阶差分近似，严格的定义在后面会给出），中心差分虽然是二阶近似但是我们并不准备讨论该格式，为了推导出最常见的二阶方法 **Crank-Nicolson 格式**，我们下面采用数值积分的思想。我们对常微分方程(6.1)两边进行积分，积分区间为 $[t_i, t_{i+1}]$ ，注意到 **Newton-Leibnitz 公式**我们有

$$x(t_{i+1}) - x(t_i) = \int_{t_i}^{t_{i+1}} f(t, x(t)) dt. \quad (6.5)$$

向前 Euler 方法和**向后 Euler 方法**都可以看成是对右端积分项的一种数值近似，其中**向前 Euler 方法**是采用左端点作为积分点进行数值积分，而**向后 Euler 方法**是采用右端点进行数值积分，权重都是插值型积分格式所确定的。我们在数值积分的章节中知道，梯形公式是一种基本的数值积分格式，如果我们对(6.5)的右端采用梯形公式进行数值积分，

$$x(t_{i+1}) = x(t_i) + \frac{\tau}{2}(f(t_i, x(t_i)) + f(t_{i+1}, x(t_{i+1}))), \quad i = 0, 1, 2, \dots$$

类似**向前 Euler 方法**，进一步用 $x_i \approx x(t_i)$ ，这样就得到了一种新的数值方法，称为 **Crank-Nicolson 格式**：

$$x_{i+1} = x_i + \frac{\tau}{2}(f(t_i, x_i) + f(t_{i+1}, x_{i+1})), \quad i = 0, 1, 2, \dots \quad (6.6)$$

为了分析数值方法得到的解和连续问题的解的差别，我们需要研究在离散时间节点上 $x(t_i)$ 和 x_i 之间的误差估计。特别的如果我们关注 $x(T)$ 点处的近似情况，可以用 $x(T) - x_N$ 的大小来度量，这里 $N = \frac{T}{\tau}$ 。我们称一个数值方法是收敛的，即数值格式的**收敛性**，如果有

$$\lim_{\tau \rightarrow 0^+} \|x(T) - x_N\| = 0, \quad (6.7)$$

这里 $\|\cdot\|$ 可以是任意向量范数，如果标量时用绝对值函数代替。在实践中更加重要的是**收敛速度（收敛阶）**，一个数值格式称为 p -阶收敛，如果满足

$$\|x(T) - x_N\| \leq C\tau^p, \quad (6.8)$$

其中常数 C 可能依赖于 x_0, f, T ，但是不依赖于时间步长 τ 。

下面我们用**向前 Euler 法**为例来估计算法的收敛性和收敛速度，我们有如下定理。

定理 6.1

令 x_i 为向前 Euler 法(6.3)所得到数值解, 并记每个时间节点上的误差为

$$e_i = \|x(t_i) - x_i\|.$$

如果常微分方程初值问题(6.1)在区间 $[0, T]$ 内存在唯一解 $x(t)$ 且导数有界, f 在区域 $[0, T] \times B_r$ 中是 Lipschitz 连续的, 其中 B_r 为 $\mathbb{R}^n$ 空间中半径为 r 的球, $r = \max_{0 \leq t \leq T} \|x(t)\|$, 即满足如下条件:

$$\max_{0 \leq t \leq T} \|x_t\| = M, \quad \|f(t_1, x) - f(t_2, x)\| \leq L_t |t_1 - t_2|, \quad \|f(t, x) - f(t, y)\| \leq L_x \|x - y\|.$$

则存在和 τ 无关的常数 C , 使得

$$\max_{0 \leq i \leq N} e_i \leq C\tau.$$



证明 注意到 $x(t_{i+1}) - x(t_i) = \int_{t_i}^{t_{i+1}} x_t(\eta) d\eta$, 于是我们有

$$\begin{aligned} e_{i+1} &= \|x(t_{i+1}) - x_{i+1}\| \\ &= \|x(t_{i+1}) - x(t_i) + x(t_i) - x_i + x_i - x_{i+1}\| \\ &\leq \left\| \int_{t_i}^{t_{i+1}} x_t(\eta) d\eta - \tau f(t_i, x_i) \right\| + e_i \\ &= e_i + \left\| \int_{t_i}^{t_{i+1}} [x_t(\eta) - x_t(t_i)] d\eta + \tau [f(t_i, x(t_i)) - f(t_i, x_i)] \right\| \\ &\leq e_i + \left\| \int_{t_i}^{t_{i+1}} [x_t(\eta) - x_t(t_i)] d\eta \right\| + \tau \|f(t_i, x(t_i)) - f(t_i, x_i)\| \\ &\leq (1 + \tau L_x) e_i + R_i, \end{aligned}$$

其中

$$\begin{aligned} R_i &= \left\| \int_{t_i}^{t_{i+1}} [f(\eta, x(\eta)) - f(t_i, x(t_i))] d\eta \right\| \\ &\leq \left\| \int_{t_i}^{t_{i+1}} [f(\eta, x(\eta)) - f(t_i, x(\eta))] d\eta \right\| + \left\| \int_{t_i}^{t_{i+1}} [f(t_i, x(\eta)) - f(t_i, x(t_i))] d\eta \right\| \\ &\leq L_t \int_{t_i}^{t_{i+1}} |\eta - t_i| d\eta + L_x \int_{t_i}^{t_{i+1}} \|x(\eta) - x(t_i)\| d\eta \\ &\leq (L_t + L_x \|x_t\|_\infty) \int_{t_i}^{t_{i+1}} |\eta - t_i| d\eta \\ &= \frac{\tau^2}{2} (L_t + L_x \|x_t\|_\infty) \triangleq R. \end{aligned}$$

利用上述不等式我们可以继续估计误差 e_i 。反复利用不等式 $e_{i+1} \leq (1 + \tau L_x) e_i + R$, 可以得

到对任意的 $i \leq N$, 都有

$$\begin{aligned}
 e_i &\leq (1 + \tau L_x) e_{i-1} + R \\
 &\leq (1 + \tau L_x)^i e_0 + R \sum_{k=0}^{i-1} (1 + \tau L_x)^k \\
 &\leq (1 + \tau L_x)^i e_0 + \frac{R}{h L_x} [(1 + \tau L_x)^i - 1] \\
 &\leq (1 + \tau L_x)^N e_0 + \frac{R}{h L_x} [(1 + \tau L_x)^N - 1].
 \end{aligned}$$

又由函数 $e^x - x - 1 (x \geq 0)$ 的单调性知

$$e^{\tau L_x} \geq 1 + \tau L_x.$$

于是有

$$e^{L_x T} \geq (1 + \tau L_x)^{T/\tau} \geq (1 + \tau L_x)^N.$$

因此我们有

$$e_i \leq e^{L_x T} e_0 + \frac{L_t + L_x \|x_t\|_\infty}{2L_x} e^{L_x T} \tau, \quad i = 1, 2, \dots, N. \quad (6.9)$$

因为初值 $e_0 = 0$, 于是选取常数 $C = \frac{L_t + L_x \|x_t\|_\infty}{2L_x} e^{L_x T}$ 和 τ 无关, 定理得证。

注 关于定理6.1的几点解释:

- (1) 定理6.1并没有考虑初值的测量误差, 以及实际计算中的舍入误差。如果在每一个计算过程中都引入舍入误差, 并且每一步总体舍入误差的上界为 ϵ , 则完全类似的分析, 只要将 e_{i+1} 和 e_i 之间的不等式改为

$$e_{i+1} \leq (1 + \tau L_x) e_i + R + \epsilon$$

即可。这时候得到的误差估计为

$$e_i \leq e^{L_x T} e_0 + \frac{L_t + L_x \|x_t\|_\infty}{2L_x} e^{L_x T} \tau + \frac{e^{L_x T}}{L_x} \frac{\epsilon}{\tau}, \quad i = 1, 2, \dots, N.$$


即舍入误差可能会随着步长的减少 (迭代步数的增加) 而增加。

- (2) 虽然常数 C 不会依赖于步长 τ , 但是在估计式中强烈的依赖于最大求解区间 T 和 Lipschitz 常数 L_x 。如果求解区间 T 比较大或者 Lipschitz 常数 L_x 非常大 (这一点在后面刚性问题求解中会有更加清晰的解释), 该定理的实用性将非常值得怀疑。

最后, 我们给出一个向前欧拉方法的例子。

例题 6.1 利用向前欧拉方法, 画出如下问题的近似解:

$$\begin{cases} \frac{dx(t)}{dt} = tx + t^3, & t \in [0, 1] \\ x(0) = 1 \end{cases}$$

图 6.2: 10 步, 步长大小为 $h = 0.1$

6.1.2 相容性、收敛性、稳定性

我们在证明向前 Euler 方法的收敛性时, 将每一步误差进行分解:

$$x(t_{i+1}) - x_{i+1} = x(t_{i+1}) - x(t_i) + x(t_i) - x_i + x_i - x_{i+1}.$$

这种方法将每一步的误差分解为算法在当前步引入的误差 (后面将其称为局部截断误差), 和前面误差的传播放大情况 (这里和后面要提到的零-稳定性密切相关), 对其他数值方法的分析也可以基于这种分解, 误差分解可以参考如下示意图。




图 6.3: 局部截断误差示意图

在这个分解的过程中引入了新的概念: **局部截断误差**。对于单步法 (本书所有的方法均为单步法), 局部截断误差描述了如果在时刻 t_i 处没有误差 (即 $x_i = x(t_i)$), 数值方法本身会带来多少误差 (即 $x(t_{i+1})$ 和 x_{i+1} 之间的误差)。对于 $x_i = x(t_i)$ 的前提, 我们引入记号

$$T_{\tau,i} = \frac{1}{\tau} \|x(t_{i+1}) - x_{i+1}\|, \quad T_{\tau} = \max_{0 \leq i \leq N-1} T_{\tau,i}, \quad (6.10)$$

这里 $T_{\tau,i}$ 是局部截断误差, T_{τ} 是整体截断误差。在不同的教科书上, 对于局部截断误差的定义不尽相同 (有些书采用 $T_{\tau,i} = \|x(t_{i+1}) - x_{i+1}\|$ 的定义方式, 我们这里采用教科书 [6] 中的定

义方法)。如果局部截断误差满足

$$\lim_{\tau \rightarrow 0^+} T_\tau = 0,$$

我们称该方法满足**相容性**，如果进一步有 $T_\tau = O(\tau^p)$ ，我们就称该方法 p -阶相容。对于向前 Euler 方法而言，使用 Taylor 展开可以得到

$$T_{\tau,i} = \left\| \frac{x(t_{i+1}) - x(t_i)}{\tau} - x_t(t_i) \right\| = \tau \|x_{tt}(\xi)\| = O(\tau),$$

于是向前 Euler 方法是一种一阶相容的方法。对于向后 Euler 或者 Crank-Nicolson 这类隐式格式而言，为了计算得到局部截断误差，我们需要假设每一步中的非线性方程只有唯一解，并且可以被精确解出（如果只能近似求解，那么我们可以将求解误差和舍入误差并在一起处理）。

引理 6.1

假设 $\tau L_x \leq \frac{1}{2}$ ，其中 L_x 是 f 关于第二个变量 x 的 Lipschitz 常数，则向后 Euler 方法和 Crank-Nicolson 方法都是适定的。



证明 对于向后 Euler 方法，每一步需要求解不动点方程（组）

$$G(x) = x, \quad G(x) = x_i + \tau f(t_{i+1}, x).$$

我们注意到

$$\|G(x) - G(y)\| = \tau \|f(t_{i+1}, x) - f(t_{i+1}, y)\| \leq \tau L_x \|x - y\| \leq \frac{1}{2} \|x - y\|.$$

类似的，Crank-Nicolson 格式每一步需要求解 Crank-Nicolson

$$G(x) = x, \quad G(x) = x_i + \frac{\tau}{2} [f(t_i, x_i) + f(t_{i+1}, x)].$$

这里的 G 满足

$$\|G(x) - G(y)\| \leq \frac{1}{4} \|x - y\|.$$

于是向后 Euler 方法和 Crank-Nicolson 方法在每一个迭代步中都存在唯一解，故该方法适定。

在 $\tau L_x \leq \frac{1}{2}$ 的前提下，我们来分析向后 Euler 方法和 Crank-Nicolson 方法的局部截断误差。对于向后 Euler 方法，使用 Taylor 展开得到

$$\begin{aligned} T_{\tau,i} &= \left\| \frac{x(t_{i+1}) - x(t_i)}{\tau} - f(t_{i+1}, x_{i+1}) \right\| \\ &\leq \left\| \frac{x(t_{i+1}) - x(t_i)}{\tau} - f(t_{i+1}, x(t_{i+1})) \right\| + \|f(t_{i+1}, x(t_{i+1})) - f(t_{i+1}, x_{i+1})\| \\ &\leq \tau \|x_{tt}(\xi)\| + L_x \tau T_{\tau,i} \\ &\Rightarrow T_{\tau,i} = O(\tau). \end{aligned}$$

对于 Crank-Nicolson 方法, 我们应用梯形公式的误差估计结果得到

$$\begin{aligned}
 T_{\tau,i} &= \frac{1}{\tau} \left\| \int_{t_i}^{t_{i+1}} f(t, x(t)) dt - \frac{\tau}{2} [f(t_i, x_i) + f(t_{i+1}, x_{i+1})] \right\| \\
 &\leq \frac{1}{\tau} \left\| \int_{t_i}^{t_{i+1}} f(t, x(t)) dt - \frac{\tau}{2} [f(t_i, x_i) + f(t_{i+1}, x(t_{i+1}))] \right\| + \frac{1}{2} \|f(t_{i+1}, x(t_{i+1})) - f(t_{i+1}, x_{i+1})\| \\
 &\leq \frac{\tau^2}{12} \left\| \frac{d^2}{dt^2} f(\xi, x(\xi)) \right\| + \frac{1}{2} L_x \tau T_{\tau,i} \\
 &\Rightarrow T_{\tau,i} = O(\tau^2).
 \end{aligned}$$

除了相容性和收敛性, 常微分方程数值方法还需要考虑**稳定性**, 稳定性描述了在某一个时刻微小的误差, 会不会导致最终计算结果完全错误。稳定性有许多种不同的定义, 在这里我们给出**零稳定性**的概念: 令某个数值方法产生的序列为 $\{x_i\}_{i=0}^N$, 在初值 x_0 进行微小的扰动后得到 y_0 并且随后的序列为 $\{y_i\}_{i=0}^N$, 如果存在一个不依赖于 τ 的常数 C , 使得

$$\max_{0 \leq i \leq N} \|x_i - y_i\| \leq C \|x_0 - y_0\|,$$

则称该方法具有零稳定性。注意这里的扰动 $\|x_0 - y_0\|$ 和步长 τ 都需要足够小, 常数 C 可能依赖于 T, f, x_0 。

如果我们给出抽象的单步法的描述: 在 t_i 时刻给定 x_i , 则可以通过某种方法求出 x_{i+1} , 将其写成如下的格式

$$x_{i+1} = x_i + \tau \Phi(t_i, x_i), \quad (6.11)$$

其中 $\Phi(t, x)$ 是抽象的增长函数, 可能需要通过解方程或者函数复合给出, 例如向前 Euler、向后 Euler、Crank-Nicolson 方法都是单步法。利用单步法的抽象格式(6.11), 我们可以重新审视相容性、稳定性、收敛性。

(1) 相容性。如果

$$\|x(t_{i+1}) - x(t_i) - \tau \Phi(t_i, x(t_i))\| = O(\tau^p),$$

则称单步法(6.11)是 p -阶相容的。

(2) 零稳定性。如果 Φ 对第二个变量是 Lipschitz 连续, 并且 Lipschitz 常数为 L_Φ , 则单步法(6.11)具有零稳定性:

$$\max_{0 \leq i \leq N} \|x_i - y_i\| \leq C \|x_0 - y_0\|,$$

其中常数 $C = e^{L_\Phi T}$ 。

(3) 收敛性。如果存在不依赖于 τ 的常数 C , 使得

$$\max_{0 \leq i \leq N} \|x(t_i) - x_i\| \leq C \tau^p,$$

则称单步法(6.11)具有 p -次收敛性。

定理 6.2

如果单步法(6.11)是 p -阶相容的, 并且 Φ 对第二个变量是 Lipschitz 连续, Lipschitz 常数为 L_Φ , 则单步法(6.11)具有 p -次收敛性。



证明 令 $e_i = \|x(t_i) - x_i\|$, 注意到

$$\begin{aligned} e_{i+1} &\leq \|x(t_{i+1}) - x(t_i) - \tau\Phi(t_i, x(t_i)) + x(t_i) + \tau\Phi(t_i, x(t_i)) - x_i - \tau\Phi(t_i, x_i)\| \\ &\leq e_i(1 + \tau L_\Phi) + C\tau^{p+1}. \end{aligned}$$

和向前 Euler 方法的估计类似, 我们从上面的不等式可以得出 $e_i = O(\tau^p)$, 命题得证。

6.1.3 Runge-Kutta 法

我们在前面的章节里主要介绍了向前 Euler, 向后 Euler, Crank-Nicolson 方法等三种不同的数值格式, 其中向前 Euler 法是显格式, 使用起来简单方便, 但是求解精度不高 (只有一阶精度); Crank-Nicolson 方法是二阶精度, 但是需要求解方程。一个自然的问题是, 能否构造显格式的单步法, 使其具有二阶甚至更高的精度? 本节主要就回答了这个问题, 答案是肯定的。

我们从预估-校正方法开始 (该方法也称为改进的 Euler 方法, 或者二级二阶 Runge-Kutta 方法), 先回顾一下 Crank-Nicolson 格式

$$x_{i+1} = x_i + \frac{\tau}{2}(f(t_i, x_i) + f(t_{i+1}, x_{i+1})),$$

求解的困难在于右端项含有 x_{i+1} 。如何避免在右端显式的依赖 x_{i+1} , 就给了一种预估-校正的思路, 即用一个简单的显式格式 (如向前 Euler) 求出的结果作为 x_{i+1} 的预估值, 再用 Crank-Nicolson 格式对预估值进行校正:

$$\text{STEP1(预估): } x_{i+1}^* = x_i + \tau f(t_i, x_i), \quad (\text{向前 Euler 方法}) \quad (6.12)$$

$$\text{STEP2(校正): } x_{i+1} = x_i + \frac{\tau}{2}(f(t_i, x_i) + f(t_{i+1}, x_{i+1}^*)) \quad (\text{Crank-Nicolson 方法}).$$

该方法可以看成是对向前 Euler 的改进, 故也称为改进的 Euler 方法。上述方法也可以写为如下的形式:

$$\begin{cases} x_{i+1} = x_i + \frac{\tau}{2}(K_1 + K_2), \\ K_1 = f(t_i, x_i), \\ K_2 = f(t_i + \tau, x_i + K_1\tau) \end{cases}$$

这种写法可以推广到更加一般的形式, 即 Runge-Kutta 方法。对于一般的 Runge-Kutta 方法有如下形式:

$$\begin{cases} x_{n+1} = x_n + \tau \sum_{i=1}^s b_i K_i, & n \geq 0, \\ K_i = f(t_n + c_i\tau, x_n + \tau \sum_{j=1}^s a_{i,j} K_j), & i = 1, 2, \dots, s. \end{cases} \quad (6.13)$$

这里 $b_i, c_i, a_{i,j}$ 均为待定的系数, 这些系数可以写成 Butcher 表格的形式:

c_1	a_{11}	a_{12}	$\dots$	a_{1s}
c_2	a_{21}	a_{22}		a_{2s}
$\vdots$	$\vdots$		$\ddots$	$\vdots$
c_s	a_{s1}	a_{s2}	$\dots$	a_{ss}
	b_1	b_2	$\dots$	b_s

如果当 $j \geq i$ 时 ($i = 1, 2, \dots, s$), 所有的 $a_{i,j} = 0$, 那么每个 K_i 都能显式的计算而不需要求解方程, 我们称这种情况下的 Runge-Kutta 方法为显式 Runge-Kutta 方法, 否则就称为隐式 Runge-Kutta 方法, 本节中我们主要关注显式 Runge-Kutta 方法, 以后在不引起混淆的情况下我们用 RK 方法来代指 Runge-Kutta 方法。我们称 RK 方法(6.13)为 s 级 p 阶的, 如果其局部截断误差为 $O(\tau^p)$ 。

RK 方法的推导通常基于 Taylor 展开, 为了确定 RK 方法中的待定系数 $b_i, c_i, a_{i,j}$, 将 (6.13) 左右两端各项在点 (t_n, x_n) 处展开成关于 τ 的级数, 并与微分方程的精确解 $x(t_{n+1})$ 在点 t_n 处的 Taylor 展开式相比较, 使两式中 τ 的次方不超过 $p+1$ 的项的系数相等, 由此得到确定 s 级显式 RK 方法中系数的代数方程组, 求解方程组即可得到系数 $b_i, c_i, a_{i,j}$ 的值, 且其局部截断误差为 p 阶。下面我们以二级二阶显式 RK 方法为例, 说明 RK 方法的推导过程。

在令 (6.13) 中令 $s = 2$, 并注意到 $a_{1,1} = a_{1,2} = a_{2,2} = 0$, 得到 2 级显式 RK 方法为:

$$\begin{cases} x_{n+1} = x_n + \tau(b_1 K_1 + b_2 K_2), \\ K_1 = f(t_n, x_n), \\ K_2 = f(t_n + c_2 \tau, x_n + a_{2,1} \tau K_1) \end{cases} \quad (6.14)$$

下面需要确定待定系数 $b_1, b_2, c_2, a_{2,1}$ 的值使得局部截断误差为 $O(\tau^2)$ 。按照局部截断误差的定义, 即考虑 $x_n = x(t_n)$, 将 K_2 在点 (t_n, x_n) 处展开为 Taylor 级数, 有:

$$\begin{aligned} K_2 &= f(t_n + c_2 \tau, x_n + a_{2,1} \tau K_1) \\ &= f(t_n, x_n) + c_2 \tau f_t(t_n, x_n) + a_{2,1} \tau K_1 f_x(t_n, x_n) + O(\tau^2), \end{aligned}$$

将 K_2 表达式代入(6.14)中, 得到

$$x_{n+1} = x_n + \tau f(t_n, x_n)(b_1 + b_2) + \tau^2 b_2 (c_2 f_t(t_n, x_n) + a_{2,1} f(t_n, x_n) f_x(t_n, x_n)) + O(\tau^3).$$

另一方面, 我们对精确解 $x(t_{n+1})$ 也同样在 t_n 处作 Taylor 展开并注意到 $x_t = f(t, x(t))$ 在所有的 t 点成立, 可以得到:

$$\begin{aligned} x(t_{n+1}) &= x(t_n) + \tau x_t(t_n) + \frac{1}{2} \tau^2 x_{tt}(t_n) + O(\tau^3) \\ &= x_n + \tau f(t_n, x_n) + \frac{1}{2} \tau^2 (f_t(t_n, x_n) + f_x(t_n, x_n) f(t_n, x_n)) + O(\tau^3). \end{aligned}$$

比较以上两式中的系数, 容易得到二级显式 RK 方法是二阶方法的充分必要条件为其系数满足:

$$\begin{cases} b_1 + b_2 = 1, \\ c_2 b_2 = \frac{1}{2}, \\ a_{2,1} b_2 = \frac{1}{2}. \end{cases}$$

很显然该方程组的解并不唯一, 这就说明显式二级二阶 RK 方法并不唯一, 较为常见的二级二阶显式 RK 方法有:

(1) 改进的 Euler 方法 (取 $b_2 = \frac{1}{2}, b_1 = \frac{1}{2}, c_2 = a_{2,1} = 1$) .

$$\begin{cases} x_{n+1} = x_n + \frac{\tau}{2}(K_1 + K_2), \\ K_1 = f(t_n, x_n), \\ K_2 = f(t_n + \tau, x_n + K_1\tau). \end{cases}$$

(2) 二阶 Heun 方法 (取 $b_2 = \frac{3}{4}, b_1 = \frac{1}{4}, c_2 = a_{2,1} = \frac{2}{3}$) .

$$\begin{cases} x_{n+1} = x_n + \tau(\frac{1}{4}K_1 + \frac{3}{4}K_2), \\ K_1 = f(t_n, x_n), \\ K_2 = f(t_n + \frac{2}{3}\tau, x_n + \frac{2}{3}\tau K_1). \end{cases}$$

(3) 中点方法 (取 $b_2 = 1, b_1 = 0, c_2 = a_{2,1} = \frac{1}{2}$) .

$$\begin{cases} x_{n+1} = x_n + \tau K_2, \\ K_1 = f(t_n, x_n), \\ K_2 = f(t_n + \frac{1}{2}\tau, x_n + \frac{1}{2}\tau K_1). \end{cases}$$

对于 $s = 3, 4$ 的情形, 可类似地推导出相应的高阶显式 RK 方法, 计算的过程会比较繁琐, 我们下面仅列举几个常见的 RK 方法, 具体的流程留给有兴趣的读者自行推导。

(4) 三级三阶 Kutta 方法

$$\begin{cases} x_{n+1} = x_n + \tau(\frac{1}{6}K_1 + \frac{2}{3}K_2 + \frac{1}{6}K_3), \\ K_1 = f(t_n, x_n), \\ K_2 = f(t_n + \frac{1}{2}\tau, x_n + \frac{1}{2}\tau K_1), \\ K_3 = f(t_n + \tau, x_n - \tau K_1 + 2\tau K_2). \end{cases}$$

(5) 三级三阶 Heun 方法

$$\begin{cases} x_{n+1} = x_n + \tau(\frac{1}{4}K_1 + \frac{3}{4}K_3), \\ K_1 = f(t_n, x_n), \\ K_2 = f(t_n + \frac{1}{3}\tau, x_n + \frac{1}{3}\tau K_1), \\ K_3 = f(t_n + \frac{2}{3}\tau, x_n + \frac{2}{3}\tau K_2). \end{cases}$$

(6) 四级四阶经典 RK 方法

$$\begin{cases} x_{n+1} = x_n + \frac{\tau}{6}(K_1 + 2K_2 + 2K_3 + K_4), \\ K_1 = f(t_n, x_n), \\ K_2 = f(t_n + \frac{1}{2}\tau, x_n + \frac{1}{2}\tau K_1), \\ K_3 = f(t_n + \frac{1}{2}\tau, x_n + \frac{1}{2}\tau K_2), \\ K_4 = f(t_n + \tau, x_n + \tau K_3). \end{cases}$$

(7) 四级四阶 Gill 方法

$$\begin{cases} x_{n+1} = x_n + \frac{\tau}{6} [K_1 + (2 - \sqrt{2})K_2 + (2 + \sqrt{2})K_3 + K_4] \\ K_1 = f(t_n, x_n), \\ K_2 = f(t_n + \frac{1}{2}\tau, x_n + \frac{1}{2}\tau K_1) \\ K_3 = f(t_n + \frac{1}{2}\tau, x_n + \frac{\sqrt{2}-1}{2}\tau K_1 + \frac{2-\sqrt{2}}{2}\tau K_2), \\ K_4 = f(t_n + \tau, x_n - \frac{\sqrt{2}}{2}\tau K_2 + \frac{2+\sqrt{2}}{2}\tau K_3). \end{cases}$$

一般来说, 在恰当地选择系数的情况下, s 越大, 越有可能得到更高的局部截断误差阶。事实上我们有如下结论: 任意 s 级显式 RK 方法不会高于 s 阶, 当 $s \geq 5$ 时, 任意 s 级显式 RK 方法不会高于 $s-1$ 阶, 这个结论也部分说明了为什么高于 4 级的 RK 方法很少使用。

例题 6.2 利用龙格库塔法, 求出如下问题的近似解:

$$\begin{cases} \frac{dx(t)}{dt} = t - x, & t \in [0, 1] \\ x(0) = 0 \end{cases}$$

解 我们求得该初值问题的精确解为 $y = x + \exp(-x) - 1$ 。我们画出精确解和近似解如下所示。




图 6.4: 10 步, 步长大小为 $h = 0.1$

例题 6.3 通过计算上一题的初值问题, 比较龙格库塔法和向前欧拉法的误差。

解 我们求得该初值问题的精确解为 $y = x + \exp(-x) - 1$ 。我们分别用两种方法的近似解与精确解相减，所得结果如下图所示。




图 6.5: 10 步，步长大小为 $h = 0.1$

6.1.4 刚性问题求解

前面的章节中我们主要关注了显式格式（如向前 Euler，改进 Euler，显式 RK 方法等），而隐式格式和显式格式相比较局部截断误差的阶类似但是求解更加复杂（需要求解方程或方程组），似乎没有太多的应用价值。但是在常微分方程组的求解中，特别是大规模问题（例如抛物型偏微分方程空间离散后得到的问题），隐式格式有其重要的应用价值。

这一节中我们就聚焦这样一类问题，物理过程是耗散系统（即能量会随着时间推移而逐渐减少），而且物理解中含有高频和低频部分，其中高频部分的能量很快的衰减，低频部分则耗散比较缓慢，我们称这类问题是刚性问题。为了明确刚性问题的概念，我们先考虑常系数线性常微分方程组

$$\frac{dx}{dt} = Ax(t) + \varphi(t), \quad (6.15)$$

其中 $A \in \mathbb{R}^{n \times n}$, $\varphi(t) \in \mathbb{R}^n$ ，并且假定 A 有 m 个特征值为 $\lambda_1, \lambda_2, \dots, \lambda_m$ ，相应的特征向量为 $v_1, v_2, \dots, v_m$ ，则上式的一般解为

$$x(t) = \sum_{j=1}^n C_j e^{\lambda_j t} v_j + \psi(t) \quad (6.16)$$

其中 $C_1, C_2, \dots, C_m$ 为常数， $\psi(t)$ 为方程组 (6.15) 的特解。为了保证能量耗散的性质，在本节中我们假定 $\operatorname{Re} \lambda_j < 0 (j = 1, 2, \dots, m)$ 。在刚性问题一般的定义中，如果 $\max_j |\operatorname{Re}(\lambda_j)| \gg \min_j |\operatorname{Re}(\lambda_j)|$ ，则称 (6.15) 为刚性常微分方程组，并且

$$s = \frac{\max_j |\operatorname{Re}(\lambda_j)|}{\min_j |\operatorname{Re}(\lambda_j)|}$$

为刚性比。如果是一般的非线性常微分方程组 $x' = f(t, x)$ ，我们可以通过线性化的方程 $z' =$

$J(t)z$ 来理解其刚性 (其中 $J(t) = \frac{\partial f}{\partial x}(t, \bar{x}(t))$), 此时 $\lambda_j (j = 1, 2, \dots, m)$ 为 Jacobi 矩阵

$$\frac{\partial f}{\partial x} = \begin{pmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \cdots & \frac{\partial f_1}{\partial x_m} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_2}{\partial x_m} \\ \vdots & \vdots & & \vdots \\ \frac{\partial f_m}{\partial x_1} & \frac{\partial f_m}{\partial x_2} & \cdots & \frac{\partial f_m}{\partial x_m} \end{pmatrix}$$

的特征值。

然而在实际问题中, 这样的定义有一些不足, 例如如果最小的 $|Re(\lambda_j)|$ 非常靠近零, 那么刚性比天然就非常小, 但是这样的问题经常不是刚性问题。在实际应用的时候, 当我们提到刚性常微分方程在, 我们经常讨论的是 $\max_j |Re(\lambda_j)| \gg 1$ 的情形, 一个典型的例子就是二阶抛物方程经过空间离散后得到的矩阵, 最大特征值通常为 $O(\frac{1}{h^2})$, 其中 h 表示空间网格尺寸。

下面我们回到刚性问题 (6.15) 问题的解 (6.16) 上来。则当 t 增长时, 我们有

$$\lim_{t \rightarrow +\infty} \sum_{j=1}^n C_j e^{\lambda_j t} v_j \rightarrow 0.$$

于是我们称 $\psi(t)$ 为稳态解, $\sum_{j=1}^n C_j e^{\lambda_j t} v_j$ 为瞬态解 (即当 t 有限时有意义), 其中瞬态解有快慢之分, 如 $|Re(\lambda_j)| \gg 1$ 所在的项即为快瞬态解。对于快瞬态解而言, 经过很短的时间, 其对应的能量就衰减到几乎为零的地步, 也就是说在物理上, 快瞬态解的在 $O(1)$ 的时间上对整体物理解几乎没有影响。但是在数值上, 这一点并不一定能够很好的被保持住 (即快瞬态解的离散解也能快速衰减到零)。

为了理解为什么快瞬态解为什么在数值上会带来额外的困难, 我们考虑这个模型问题

$$x'(t) = \lambda x(t), \quad Re\lambda \leq 0, \quad x(0) = x_0. \quad (6.17)$$

该问题的解为 $x(t) = x(0)e^{\lambda t}$, 于是当 $Re\lambda \ll 0$ 时, $x(t)$ 迅速衰减到 0。下面我们采用向前 Euler 方法进行求解:

$$x_{n+1} = x_n + \tau \lambda x_n = (1 + \tau \lambda) x_n.$$

于是只有当 $|1 + \tau \lambda| < 1$ 时 x_n 才有可能衰减到 0。如果 $Re\lambda \ll 0$ 例如 $\lambda = -10^{10}$, 这时候我们必须选择 $\tau = O(10^{-10})$ 才能使得数值解具有物理解衰减到零的性质。这里步长 τ 的限制来自于物理上稳定性的要求, 并非因为精度的原因。为了刻画刚性问题数值方法的这种特性, 我们先引入绝对稳定的概念。

定义 6.1 (绝对稳定)

考虑模型问题(6.17), 某一个数值方法得到的解为 x_n 。如果 $x_n \rightarrow 0$, 则称为该方法对模型问题(6.17)在步长 τ 下是绝对稳定的 (即误差逐步减少), 否则称为计算不稳定。称集合 $A = \{\lambda\tau\}$ 为该方法的绝对稳定区域, 其中问题(6.17)在步长 τ 下是绝对稳定的。



下面我们给出几类常见的数值方法如向前 Euler 法、向后 Euler 法、Crank-Nicolson 方法、改进的 Euler 方法等的绝对稳定区域作为例子。

(1) 向前 Euler 法。向前 Euler 方法的迭代过程为

$$x_{n+1} = x_n + \tau\lambda x_n = (1 + \tau\lambda)x_n.$$

于是绝对稳定区域是 $|1 + \tau\lambda| < 1$ 。

(2) 向后 Euler 法。向后 Euler 方法的迭代过程为

$$x_{n+1} = x_n + \tau\lambda x_{n+1} \Rightarrow x_{n+1} = (1 - \tau\lambda)^{-1}x_n.$$

于是绝对稳定区域为 $|1 - \tau\lambda| > 1$ 。

(3) Crank-Nicolson 法。Crank-Nicolson 方法的迭代过程可以写成

$$x_{n+1} = x_n + \frac{\tau}{2}\lambda(x_n + x_{n+1}) \Rightarrow x_{n+1} = \frac{1 + \frac{\tau\lambda}{2}}{1 - \frac{\tau\lambda}{2}}x_n.$$

于是绝对稳定区域为 $|\frac{1 + \frac{\tau\lambda}{2}}{1 - \frac{\tau\lambda}{2}}| < 1$ ，可以化简为 $Re(\tau\lambda) < 0$ 。


(4) 改进的 Euler 法。改进的 Euler 方法的迭代过程为

$$x_{n+1} = x_n + \frac{\tau}{2}(\lambda x_n + \lambda(x_n + \tau\lambda x_n)) = (1 + \tau\lambda + \frac{(\tau\lambda)^2}{2})x_n.$$


于是绝对稳定区域是 $|1 + \tau\lambda + \frac{(\tau\lambda)^2}{2}| < 1$ ，通过化简后可以得到

$$(1 + a)^2 + (a + \frac{a^2 + b^2}{2})^2 < 1, \quad (a, b) = (Re\tau\lambda, Im\tau\lambda).$$


其绝对稳定区域参见下图。在下面图像中我们给出上面四个数值格式的绝对稳定区域，其中 $X = \tau\lambda$ ，




(a) 向前 Euler 法



(b) 向后 Euler 法



(c) Crank-Nicolson 法



(d) 改进的 Euler 法

其他更加复杂的格式，如 3 级 3 阶、4 级 4 阶 Runge-Kutta 方法也可以类似推导出绝对稳定区域。如果我们对任意 λ 满足 $Re\lambda < 0$ 的时候，绝对稳定区域对步长均没有要求，这样就定义出另外一种更强的稳定性要求，即下面定义的 A-稳定性。

定义 6.2 (A- 稳定)

如果某方法的绝对稳定区域包括整个左半平面 $Re(\lambda\tau) < 0$, 则称该数值方法是 A- 稳定的。



从前面的几个例子可以知道, 向后 Euler 方法和 Crank-Nicolson 法都是 A- 稳定的, 而向前 Euler 方法和改进的 Euler 方法都不是 A- 稳定的。事实上我们可以证明如下结论: 任何线性显格式方法 (包括显式 Runger-Kutta 方法, 以及本书没有涉及的显式线性多步法) 都不可能是 A- 稳定的。

当所求解的问题为刚性常微分方程组, 则其特征值包含不同尺度的 λ 。为了让远离原点的 λ 所对应的分量满足稳定性要求, 必须选择很小的时间步长 τ , 但是物理上 $\lambda = O(1)$ 的分量才是能量集中的地方, 而精度的要求并不需要选择太小的时间步长。对于不是 A- 稳定的数值方法而言, 为了满足远离原点的 λ 的稳定性而选择非常小的时间步长造成计算资源的浪费严重, 而且会造成舍入误差的累积等问题。满足 A- 稳定的数值格式则可以任意选择时间步长都可以得到稳定的数值算法, 这时候时间步长的大小只影响精度, 可以根据精度的要求来选择合适的步长大小。

最常见的两种 A- 稳定的数值格式分别是向后 Euler 方法和 Crank-Nicolson 方法, 但是这两个方法也有自己的优缺点和适用范围。因为 Crank-Nicolson 方法是二阶格式, 其收敛速度天然要高于向后 Euler 方法, 但是向后 Euler 方法能够更好的符合物理过程, 特别是初值含有高频信息时, 向后 Euler 方法要优于 Crank-Nicolson 方法, 这一点可以从两者的迭代过程中看出来。我们仍然考察模型问题(6.17), 特别的我们假设 $\lambda \ll 0$, 而步长并没有特别小, 即 $\tau\lambda \ll 0$, 此时物理解、向后 Euler 方法和 Crank-Nicolson 方法的解分别为

$$\begin{aligned} x(t) &= x_0 e^{\lambda t}, \\ x_1 &= \frac{1}{1 - \lambda\tau} x_0, \\ x_1 &= \frac{1 + \frac{\tau\lambda}{2}}{1 - \frac{\tau\lambda}{2}} x_0. \end{aligned}$$

注意到在除零以外的任一离散时间点 (例如 $x(\tau)$), 其物理解均接近于零。对于向后 Euler 方法, x_1 也接近于零, 满足物理解的基本性质; 但是 Crank-Nicolson 方法则有 $x_1 \approx -x_0$, 其数值解会在每个时间节点上产生震荡。这一算例对应于刚性常微分方程组初始值具有高频信息 (即初值不光滑或者含有测量噪声) 等情形, 这时候通常需要先使用向后 Euler 方法对解进行磨光, 然后再使用 Crank-Nicolson 方法进行求解。

6.2 边值问题求解

本节讨论具有方程(6.2)中形式的二阶常微分方程边值问题:

$$y'' = f(x, y, y'), \quad a \leq x \leq b,$$

其中 $f(x, y, y')$ 为已知函数, 边界条件为

$$y(a) = \alpha, \quad y(b) = \beta.$$

注意到边界条件可能会根据不同的问题进行修改 (例如改为左右端点的导数值, 或者导数值和函数值的加权等)。边值问题的存在唯一性条件和初值问题略有不同, 除了要求 f 的光滑性 (如 Lip-连续) 以外, 还需要某些单调性条件, 下面的定理 (参见 [1]) 给出了边值问题 (6.2) 存在唯一解的一般性条件, 证明可以在许多常微分方程两点边值问题的教材中找到。

定理 6.3

设函数 $f(x, y, y')$ 及偏导数 $\frac{\partial f}{\partial y}$ 和 $\frac{\partial f}{\partial y'}$ 在区域

$$D = \{(x, y, y') \mid a \leq x \leq b, \quad -\infty < y < \infty, \quad -\infty < y' < \infty\}$$

内连续。若下列条件成立:

- (1) $\frac{\partial f}{\partial y} > 0, \quad \forall (x, y, y') \in D,$
- (2) 存在常数 $M > 0$, 使得 $|\frac{\partial f}{\partial y'}| \leq M, \quad \forall (x, y, y') \in D.$

则边值问题 (6.2) 的解存在且唯一。



如果 f 是关于 y, y' 的线性函数, 即存在函数 $p(x), q(x), r(x)$ 使得

$$f(x, y, y') = p(x)y' + q(x)y + r(x),$$

方程 (6.2) 可以重新改写为

$$y'' = p(x)y' + q(x)y + r(x), \quad a \leq x \leq b, \quad y(a) = \alpha, \quad y(b) = \beta. \quad (6.18)$$

对于上述二阶线性常微分方程边值问题, 解的存在唯一性定理可以简单表述为如下推论。

推论 6.1

设 $p(x), q(x), r(x)$ 在 $[a, b]$ 上连续, 且在 $[a, b]$ 内 $q(x) \geq 0$, 则线性问题 (6.18) 的解存在且唯一。



本节中我们介绍三种求解边值问题的数值方法: 打靶法、差分法、以及基于变分的 Galerkin 方法。

6.2.1 打靶法

打靶法的基本思想是我们假设给定其中一个端点的另外一个初值条件 (在 (6.2) 可以取为 $y'(a)$), 然后通过求解初值问题可以得到下面这样一个映射: $F: y'(a) \rightarrow y(b)$, 于是将另外一个端点 b 的边界条件作为约束, 通过求解方程 $F(c) = \beta$ 可以得到初值 $y'(a) = c$, 从而将边值问题转化为初值问题进行求解。对于线性边值问题, 映射 F 是仿射的, 我们可以直接给出表达式, 而非线性问题时, 只能通过数值方法求解非线性方程 $F(c) = \beta$ 来给出初始条件。

1. 线性边值问题

回顾线性边值问题(6.18):

$$y'' = p(x)y' + q(x)y + r(x), \quad a \leq x \leq b, \quad y(a) = \alpha, \quad y(b) = \beta,$$

我们利用线性问题的线性叠加原理, 可以将边值问题转化为如下两个初值问题的解:

$$\begin{cases} y'' = p(x)y' + q(x)y + r(x), & a \leq x \leq b, \\ y(a) = \alpha, \quad y'(a) = 0, \end{cases}$$

和

$$\begin{cases} y'' = p(x)y' + q(x)y, & a \leq x \leq b, \\ y(a) = 0, \quad y'(a) = 1, \end{cases}$$

记上述两个初值问题的解分别为 $y_1(x)$ 和 $y_2(x)$, 并假定 $y_2(b) \neq 0$ (事实上在 $q(x) \geq 0$ 的前提下 $y_2(b) \neq 0$ 是可以得到证明的, 利用唯一性结论即可), 定义

$$y(x) = y_1(x) + \frac{\beta - y_1(b)}{y_2(b)} y_2(x).$$

我们下面来验证 $y(x)$ 即为线性边值问题 (6.18) 的解。注意到对上式求导有:

$$y'(x) = y_1'(x) + \frac{\beta - y_1(b)}{y_2(b)} y_2'(x), \quad (6.19)$$

和

$$y''(x) = y_1''(x) + \frac{\beta - y_1(b)}{y_2(b)} y_2''(x). \quad (6.20)$$

将 $y_1''(x)$ 和 $y_2''(x)$ 的表达式代入上式, 有

$$\begin{aligned} y'' &= p(x)y_1' + q(x)y_1 + r(x) + \frac{\beta - y_1(b)}{y_2(b)} (p(x)y_2' + q(x)y_2) \\ &= p(x) \left(y_1' + \frac{\beta - y_1(b)}{y_2(b)} y_2' \right) + q(x) \left(y_1 + \frac{\beta - y_1(b)}{y_2(b)} y_2 \right) + r(x) \\ &= p(x)y'(x) + q(x)y(x) + r(x). \end{aligned}$$

另外

$$\begin{aligned} y(a) &= y_1(a) + \frac{\beta - y_1(b)}{y_2(b)} y_2(a) = \alpha + \frac{\beta - y_1(b)}{y_2(b)} \cdot 0 = \alpha, \\ y(b) &= y_1(b) + \frac{\beta - y_1(b)}{y_2(b)} y_2(b) = y_1(b) + \beta - y_1(b) = \beta. \end{aligned}$$

因此求解线性边值问题的打靶法就是将边值问题转化为求解两个初值问题在进行线性组合得到, 其中初值问题的解可以使用任意求解初值问题的数值方法 (如 Runge-Kutta 方法等)。

2. 非线性边值问题对于一般的非线性边值问题, 因为没有线性叠加原理, 针对线性问题的方法将不再适用, 不过求解非线性边值问题的基本思想与求解线性边值问题仍然类似, 只是非线性边值问题的解不再是两个初值问题解的线性组合, 而是由一系列包含参数 t 的初值问题的解来逼近, 如下所示:

$$\begin{cases} y'' = f(x, y, y'), & a \leq x \leq b, \\ y(a) = \alpha, \quad y'(a) = t_k, & k = 0, 1, 2, \dots \end{cases}$$

通过逐次选择参数 t_k , 使得 $y(x; t_k)$ 逐次逼近 (6.2) 的解 $y(x)$,

$$\lim_{k \rightarrow \infty} y(b; t_k) = y(b) = \beta,$$

其中 $y(x; t_k)$ 表示选择初值 $y'(a) = t_k$ 的初值问题的解。这种方法叫作打靶法, 是因为这个过程类似打靶, 通过逐次调整发射角 t_k ($k = 0, 1, 2, \dots$), 从而使得 $y(b, t_k)$ 足够近地“击中”目标 β , 如下图所示。




图 6.6: 打靶法示意图

如前面所描述的那样, 给定初值 $y'(a) = t$, 就可以求出 $y(b)$ 的函数值, 这就给出了一个从 $y'(a)$ 到 $y(b)$ 的映射, 令该映射为 F , 即

$$F: \mathbb{R} \mapsto \mathbb{R}, \quad F(t) = y(b; t).$$

于是求解边值问题 (6.2) 等价于求解非线性方程 $F(c) = \beta$ 。我们可以采用第二章中非线性方程的数值方法进行求解, 如二分法, 割线法, 试错法等不需要计算导数的算法, 只需要计算若干次初值问题的解即可。

因为 Newton 迭代是求解非线性方程 $F(c) = \beta$ 的一种主要且有效的方法, 在有可能的情况下我们也希望采用 Newton 迭代算法求解, 但是按照 Newton 算法, 我们需要计算 $F'(t)$ 从而完成如下的 Newton 迭代

$$t_{k+1} = t_k - \frac{F(t_k) - \beta}{F'(t_k)}, \quad k = 0, 1, 2.$$

为确定 $t = t_k$ 时 $F'(t_k)$ 的值, 首先注意到 $y(x; t)$ 满足如下的方程

$$\begin{cases} y(x; t)'' = f(x, y(x; t), y'(x; t)), & a \leq x \leq b, \\ y(a) = \alpha, \quad y'(a) = t, & k = 0, 1, 2, \dots \end{cases}$$

其中 y' 表示对 x 的导数。然后上述方程对 t 求偏导数得到

$$\frac{\partial y''}{\partial t}(x; t) = \frac{\partial f}{\partial t}(x, y(x; t), y'(x; t)) \quad (6.21)$$

$$= \frac{\partial f}{\partial y}(x, y(x; t), y'(x; t)) \frac{\partial y}{\partial t}(x; t) \quad (6.22)$$

$$+ \frac{\partial f}{\partial y'}(x, y(x; t), y'(x; t)) \frac{\partial y'}{\partial t}(x; t). \quad (6.23)$$

初始条件为

$$\frac{\partial y}{\partial t}(a; t) = 0, \quad \frac{\partial y'}{\partial t}(a; t) = 1.$$

下面记 $z(x; t) = \frac{\partial y}{\partial t}(x; t)$, 则通过求解如下初值问题:

$$\begin{cases} z''(x; t) = \frac{\partial f}{\partial y}(x, y, y') z(x; t) + \frac{\partial f}{\partial y'}(x, y, y') z'(x; t), & a \leq x \leq b, \\ z(a; t) = 0, \quad z(b; t) = 1, \end{cases}$$

可以得到 $F'(t_k) = z(b; t_k)$, 并由此继续 Newton 迭代方法。上面的分析过程在工程中通常成为敏感性分析 (即求出导数值), 每次 Newton 迭代过程需要求解两个二阶方程初值问题以得到 $y(b; t_k)$ 和 $z(b; t_k)$ 的值, 初值问题可以采用如 Runge-Kutta 方法等求解。

例题 6.4 下面我们用打靶法来求解边值问题:

$$\begin{cases} y'' = -\frac{x}{1-x}y' + \frac{1}{1-x}y + x - 1, & 0 \leq x \leq 1, \\ y(0) = 1, \quad y(1) = 2e, \end{cases}$$

解 我们设置 $t_0 = 2e$, 使用打靶法计算结果如下:




图 6.7: $n=10, h=0.1$

6.2.2 有限差分法

有限差分法是求解微分方程数值解的一种常用方法，求解边值的差分方法和求解初值问题的差分方法的基本思想类似，都是通过近似函数在格点上的值；采用的基本技巧用数值差分格式来近似导数，将微分方程转化为有限维的（非）线性代数方程组进行求解；通过求解代数方程组得到节点处函数的近似值后，如果希望进一步得到函数的近似，可以利用任何后处理技术（如插值、逼近）构造出近似函数。

为了更加聚焦差分方法的核心过程，下面我们考虑二阶线性边值问题(6.18)，

$$\begin{cases} y'' = p(x)y' + q(x)y + r(x), & a \leq x \leq b, \\ y(a) = \alpha, & y(b) = \beta, \end{cases}$$

其中 $p(x), q(x), r(x)$ 是 $[a, b]$ 上已知的连续函数， α, β 为已知常数。

进行网格划分，简单起见我们进行均匀剖分，即取一整数 $N > 0$ ，把区间 $[a, b]$ 等分成 N 等份，设节点为

$$x_i = a + ih, \quad i = 0, 1, 2, \dots, N,$$

其中 $h = \frac{b-a}{N}$ 为步长，在内部节点 $x_1, x_2, \dots, x_{N-1}$ 处，微分方程为

$$y''(x_i) = p(x_i)y'(x_i) + q(x_i)y(x_i) + r(x_i).$$

假设 $y(x) \in C^4[a, b]$ ，利用中心差分近似一阶、二阶导数，我们有

$$y'(x_i) = \frac{y(x_{i+1}) - y(x_{i-1}))}{2h} + O(h^2),$$

$$y''(x_i) = \frac{y(x_{i+1}) - 2y(x_i) + y(x_{i-1}))}{h^2} + O(h^2).$$

将中心差分近似公式代入方程中得到

$$\frac{y(x_{i+1}) - 2y(x_i) + y(x_{i-1}))}{h^2} = p(x_i) \left[\frac{y(x_{i+1}) - y(x_{i-1}))}{2h} \right] + q(x_i)y(x_i) + r(x_i) + O(h^2).$$

略去截断误差 $O(h^2)$ ，用 y_i 代替 $y(x_i)$ ，即得到边值问题的差分方程为

$$\begin{cases} \left(\frac{-y_{i+1} + 2y_i - y_{i-1}}{h^2} \right) + p(x_i) \left(\frac{y_{i+1} - y_{i-1}}{2h} \right) + q(x_i)y_i = -r(x_i), & i = 1, 2, \dots, N-1, \\ y_0 = \alpha, & y_N = \beta. \end{cases} \quad (6.24)$$

引入记号

$$\begin{cases} p_i = p(x_i), & q_i = q(x_i), & r_i = r(x_i), \\ a_i = -1 - \frac{h}{2}p_i, & b_i = 2 + h^2q_i, & c_i = -1 + \frac{h}{2}p_i, \end{cases}$$

从而 (6.24) 可简化为

$$\begin{cases} a_i y_{i-1} + b_i y_i + c_i y_{i+1} = -h^2 r_i, & i = 1, 2, \dots, N-1, \\ y_0 = \alpha, & y_N = \beta. \end{cases}$$

在上式中将 y_0 和 y_N 消去，可化简为一个 $N-1$ 阶三对角线性方程组

$$Ay = d,$$

其中

$$A = \begin{bmatrix} b_1 & c_1 & & & \\ a_2 & b_2 & c_2 & & \\ & a_3 & b_3 & c_3 & \\ & & \ddots & \ddots & \ddots \\ & & & a_{N-2} & b_{N-2} & c_{N-2} \\ & & & & a_{N-1} & b_{N-1} \end{bmatrix}, \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_{N-2} \\ y_{N-1} \end{bmatrix}, \quad d = \begin{bmatrix} -h^2 r_1 + a_1 \alpha \\ -h^2 r_2 \\ \vdots \\ -h^2 r_{N-2} \\ -h^2 r_{N-1} + c_{N-1} \beta \end{bmatrix}.$$

特别的, 如果 $p(x) = q(x) = 0$ (即 $p_i = q_i = 0$), 则矩阵 A 成为我们非常熟悉的三对角矩阵, 主对角线和次对角线分别为 $\frac{2}{h^2}$ 和 $\frac{-1}{h^2}$, 这个矩阵的特征值、特征向量我们在三次样条插值部分给出了精确表达式。事实上该矩阵可以理解为带 Dirichlet 边界条件 (即本书中 $y(a) = \alpha, y(b) = \beta$) 的二阶微分算子在均匀网格下的近似, 对于带有其他边界条件的二阶微分算子, 如 Neumann 条件 ($y'(a) = \alpha, y'(b) = \beta$)、Robin 条件 ($y'(a) + c_a y(a) = \alpha, y'(b) + c_b y(b) = \beta$)、周期边条件 ($y(a) = y(b), y'(a) = y'(b)$) 或者混合边条件 (左右端点不同类型条件) 等, 其在均匀网格下的离散近似矩阵略有不同 (同时也取决于边界条件的离散方式), 有兴趣的读者可以参阅微分方程差分方法的教科书或者专著。

例题 6.5 下面我们用有限差分法来求解边值问题:

$$\begin{cases} y'' = -\frac{x}{1-x}y' + \frac{1}{1-x}y + x - 1, & 0 \leq x \leq 1, \\ y(0) = 1, & y(1) = 2e, \end{cases}$$

解 我们使用有限差分法计算结果如下:




图 6.8: $n=10, h=0.1$

6.2.3 Galerkin 方法

在微分方程的理论研究中,同样的微分方程,在一定的条件下可以有形式上完全不同但是数学上等价的形式,不同的形式会给出研究微分方程理论的不同工具。例如我们以如下更加简单的二阶线性边值问题为例

$$\begin{cases} -y''(x) + q(x)y(x) = f(x), & 0 \leq x \leq 1, \\ y(0) = y(1) = 0, \end{cases} \quad (6.25)$$

其中 $q(x)$ 和 $f(x)$ 在 $[0, 1]$ 上连续,且 $x \in [0, 1]$ 时有 $q(x) \geq 0$ 。为了求解 (6.25),我们采用变分方法的思想,首先对方程 (6.25) 两边乘上测试函数 $z \in V = C_0^1[0, 1]$,并在区间 $[0, 1]$ 上积分得到:

$$\int_0^1 (-y'' + qy)z dx = \int_0^1 f z dx, \quad \forall z \in V.$$

利用分部积分公式以及 $z(0) = z(1) = 0$, 方程 (6.25) 可化为如下变分形式:

$$\int_0^1 y' z' dx + \int_0^1 q y z dx = \int_0^1 f z dx, \quad \forall z \in V.$$

因此若 $y \in C^2([0, 1])$ 满足二阶线性边值问题 (6.25), 则 y 也是如下弱形式边值问题的解:

$$\text{找到 } y \in V: \quad a(y, z) = (f, z), \quad \forall z \in V, \quad (6.26)$$

其中 $(f, z) = \int_0^1 f z dx$ 表示 $L^2(0, 1)$ 空间的内积,

$$a(y, z) = \int_0^1 y' z' dx + \int_0^1 q y z dx.$$

在理论上,证明方程 (6.26) 和方程 (6.25) 的等价性并不显然,事实上,真正使用的弱形式解需要扩大导数的定义(即弱导数),以及将测试函数空间 V 由 $C_0^1[0, 1]$ 也扩大为 Sobolev 空间 $H_0^1(0, 1)$:

$$H_0^1(0, 1) = \{z \in L^2(0, 1) : z' \in L^2(0, 1), z(0) = z(1) = 0\},$$

其中这里的导数都是弱导数的意义。不严格的说,弱导数可以理解为连续分片可微函数的导数, $H_0^1(0, 1)$ 则是边界为 0 的分片可微的连续函数,且其导数平方可积。关于弱导数、弱形式、弱解的严格定义、弱解和强解(方程(6.25)的解)的等价性均超出本书的范围,有兴趣的读者可以参阅泛函分析、广义函数和 Sobolev 空间、偏微分方程等更加专业的教科书。

我们将考虑近似变分形式(6.26)的弱解,其中 $V = H_0^1(0, 1)$ 。另外我们还可以证明求解上述方程也等价于求解如下最小值问题:

$$\min_{y \in H_0^1(0, 1)} \frac{1}{2} \int_0^1 (|y'|^2 + q|y|^2 - yf) dx. \quad (6.27)$$

为了描述算法的思想和基本流程,在没有给出空间 $H_0^1(0, 1)$ 的任何严密的定义和性质下,我们下面的叙述都暂时忽略其数学上的严格性。我们将给出的 Galerkin 方法和 Galerkin-Ritz 方法分别是基于变分形式(6.26)和优化形式(6.27)的。

如何理解差分方法和 Galerkin 方法的区别? 就像冯康先生曾经用“同一物理过程的各种等价的数学表述可能导致不等效的计算方法”来从本质上刻画计算数学和数学的不同那样,虽

然在数学上看来, 方程(6.25)、(6.26)、(6.27)都是等价的, 但是从这三个不同形式的方程出发, 所得到的最自然的计算方法是不同的。下面我们就介绍 Galerkin 方法或 Galerkin-Ritz 方法的基本思想。

空间 $H_0^1(0, 1)$ 是无穷维 Hilbert 空间, 假设其一组基底为 $\{\psi_i\}_{i=1}^\infty$, 那么求 $y \in H_0^1(0, 1)$ 使得 (6.26) 成立, 等价于求出 $y = \sum_{i=1}^\infty c_i \psi_i$ 中的系数 c_i , 使得对 $\forall j = 1, 2, 3, \dots$, 有下式成立:

$$\int_0^1 \sum_{i=1}^\infty c_i \psi_i' \psi_j' dx + \int_0^1 q \sum_{i=1}^\infty c_i \psi_i \psi_j dx = \int_0^1 f \psi_j dx.$$

然而求解无穷维线性系统在数值上是不可行的, Galerkin 方法的核心就是寻找合适的有限维空间代替无穷维空间。如果我们已经选取了特定的有限维空间 $V_h \subset H_0^1$ 来近似无穷维空间 H_0^1 , 则求解二阶线性边值问题的 Galerkin 方法如下:

$$\text{找到 } y_h \in V_h: \quad a(y_h, z_h) = (f, z_h), \quad \forall z_h \in V_h. \quad (6.28)$$

选定 V_h 的一组基 $\{\phi_1, \phi_2, \dots, \phi_N\}$, 则 $y_h = \sum_{i=1}^N c_i \phi_i$, 变分形式(6.28)可以写成

$$\begin{aligned} \int_0^1 y_h' z_h' dx + \int_0^1 q y_h z_h dx &= \int_0^1 f z_h dx, \quad \forall z_h \in V_h \\ \iff \sum_{i=1}^N (\int_0^1 c_i \phi_i' \phi_j' dx + \int_0^1 q c_i \phi_i \phi_j dx) &= \int_0^1 f \phi_j dx, \quad \forall j = 1, \dots, N \\ \iff A_h C &= f_h, \end{aligned}$$

其中 $A_h(i, j) = \int_0^1 \phi_i' \phi_j' dx + \int_0^1 q \phi_i \phi_j dx$, $f_h = (f_1, \dots, f_N)$, $f_i = \int_0^1 f \phi_i$, $C = (c_1, \dots, c_N)$ 为需要求解的未知系数, 从而求出边值问题的近似解 y_h 。

而求解上述方法的关键在于 V_h 空间的选取, 通过选择合适的有限维空间, 我们可以分析出最佳逼近性 (例如选择为多项式空间, 我们可以分析最佳平方逼近元的性质等), 也就是说 Galerkin 方法的解不可能超过最佳逼近元。下面的一些结论说明了, 在某种意义上, Galerkin 方法的解事实上和最佳逼近元的收敛性质是一样的。

我们假定 V 是 Hilbert 空间, 其范数记作 $\|\cdot\|_V$ 。给定的双线性算子 $a(\cdot, \cdot): V \times V \rightarrow \mathbb{R}$ 和线性算子 $f(\cdot) = (f, z): V \rightarrow \mathbb{R}$ 分别满足如下性质:

- (1) 双线性算子的有界性: $\exists M > 0$, 有 $|a(u, v)| \leq M \|u\|_V \|v\|_V \quad \forall u, v \in V$ 。
- (2) 双线性算子的强制性: $\exists \alpha_0 > 0$, 使得 $a(u, u) \geq \alpha_0 \|u\|_V^2 \quad \forall u \in V$ 。
- (3) 线性算子的有界性: $\exists K > 0$, 有 $|(f, z)| \leq K \|z\|_V, \quad \forall z \in V$ 。

根据泛函分析中的 Lax-Milgram 定理, 方程 (6.26) 存在唯一解 y 。类似的我们也可以说明 Galerkin 方法的离散解也是存在唯一的。下面的 Céa 定理给出了微分方程进行 Galerkin 离散后的近似解和最佳逼近元之间的逼近关系。

定理 6.4

(Céa) 令 V 为 Hilbert 空间, $V_h \subseteq V$ 是有限维子空间, $a(\cdot, \cdot)$ 是 V 上满足连续性和强制性的有界双线性算子, $f \in V'$ 。令 $y \in V$ 是问题 (6.25) 的解, y_h 是 Galerkin 方法 (6.26) 的解, 则有

$$\|y - y_h\|_V \leq \frac{M}{\alpha_0} \min_{w_h \in V_h} \|y - w_h\|_V$$



证明 首先令 $z = z_h \in V_h$, 将 (6.25) 和 (6.26) 两式相减得到:

$$a(y - y_h, z_h) = 0, \quad \forall z_h \in V_h.$$

根据算子 a 的连续性和强制性, 对 $\forall z \in V_h$ 我们都有

$$\begin{aligned} \alpha_0 \|y - y_h\|_V^2 &\leq a(y - y_h, y - y_h) \\ &= a(y - y_h, y - z) \\ &\leq M \|y - y_h\|_V \|y - z\|_V. \end{aligned}$$

从而得到

$$\|y - y_h\|_V \leq \frac{M}{\alpha_0} \|y - z\|_V.$$

因为 $z \in V_h$ 是任意的, 所以定理中的不等式成立。

另外根据上述定理, 我们有如下收敛性结果成立:

推论 6.2

令定理 (6.2.3) 中的假设成立, 且假设 $V_1 \subset V_2 \subset \cdots$ 是 V 的一系列有限维子空间, 并且满足:

$$\overline{\bigcup_{n \geq 1} V_n} = V.$$

那么 Galerkin 方法的解 $y_n \in V$ 收敛:

$$\lim_{n \rightarrow \infty} \|y - y_n\|_V = 0.$$



从 Céa 定理我们知道有限维子空间 V_h 对解 y 的逼近能力决定了离散误差的大小, 另外求解 y_h 需要求解 (6.28) 需要组装刚度矩阵 A_h 和右端项 f_h , 并求解线性代数方程组, 从计算复杂度上看, 有限维子空间 V_h 的选取需要能够给出合理的基底来保障有效的获取和求解线性代数方程组。最后我们给出两个典型的有限维子空间 V_h 来求解问题 (6.28): 有限元方法和谱方法。

有限元方法。虽然 Galerkin 在 1915 年就提出了基于弱变分原理的 Galerkin 方法, 但是真正落实在应用中的首推离散空间为分片多项式空间的有限元方法。有限元方法的优势主要体现在二维或者三维问题的求解上, 特别的如果问题具有比较复杂的几何结构。第二次世界大战期间, 对飞机内部结构设计提出了更高的要求, 工程师们需要解决复杂结构上的力学分析, 这一需求直接推动了有限元方法的发展, 并形成了各种软件包。在数学上, 有限元方法作为求解偏微分方程的一种数值方法, 在美国、苏联、中国得到了独立的发展。1965 年, 冯康先生在《基于变分原理的差分格式》中对于 Laplace 方程和弹性方程给出了有限元方法, 冯康的论文中给出了多种有限元空间, 包括四边形元, 并给出了收敛性证明。从那时候开始, 有限元的数学理论得到极大的发展。

中国的计算数学家们从有限元方法的起始就走在世界前列, 并且从理论上应用上都做出了卓越的成绩。1965 年, 冯康先生证明了 Laplace 方程和弹性方程有限元方法的收敛性; 1964 年初崔俊芝院士在解决刘家峡大坝的复杂应力分析问题, 研制出国内第一个平面问题通用

有限元程序；20 世纪 60 年代-70 年代，国内的有限元方法及有限元软件用于计算过数十个大型工程，应用于水利、电力、机械、航空、建筑等多个领域。

我们还是以两点边值问题为例来介绍有限元方法。有限元空间一般取为区间 $[0, 1]$ 中长度不超过 h 的子区间上的分段连续多项式，例如将区间 $[a, b]$ 划分为 n 个子区间 $I_j = [x_j, x_{j+1}]$ ，其中

$$0 = x_0 < x_1 < \cdots < x_{n-1} < x_n = 1, \quad (6.29)$$

区间长度为 $h_j = x_{j+1} - x_j$, $j = 0, \cdots, n-1$ 并且令 $h = \max_j(h_j)$ 。则 k -次有限元空间为：

$$V_h = \{v_h \in C^0([0, 1]), v_h|_{I_j} \in \mathbb{P}_k(I_j), v_h(0) = v_h(1) = 0, j = 0, 1, \cdots, n, k \geq 1\},$$

这里 $v_h(0) = v_h(1) = 0$ 对应于其次边界条件，如果是其他的边界条件则需要相应调整有限元空间的定义。

为简单起见我们仅考虑 $k = 1$ 时的有限元空间，其就是我们非常熟悉的分片线性连续函数空间（参考分片线性插值部分），它有一个形如帽子函数的自然基底 ϕ_i , $i = 1, \cdots, n-1$ ：

$$\phi_i(x) = \begin{cases} \frac{x-x_{i-1}}{x_i-x_{i-1}} & \text{for } x_{i-1} \leq x \leq x_i \\ \frac{x_{i+1}-x}{x_{i+1}-x_i} & \text{for } x_i \leq x \leq x_{i+1} \\ 0 & \text{elsewhere.} \end{cases}$$

则 $V_h = \text{span}\{\{\phi_i\}_{i=0}^{n-1}\}$ 。对于这种自然的基底，其支集都非常稀疏，这样构建刚度矩阵 A_h 和右端项 f_h 都只需要在很小的区间上（即基函数的支集）进行积分，而且刚度矩阵也是稀疏矩阵，这里的计算代价只是 $O(n)$ 。另外一方面所得到的线性系统是稀疏线性方程组，可以用很多高效的算法进行数值求解（例如子空间迭代，多重网格等）。

谱方法。有限元方法的特点是构造简单，刚度矩阵具有稀疏性，并且能够适合复杂的几何形状。但是因为其采用分片多项式函数，其逼近性不仅仅取决于目标函数的光滑性，还取决于分片多项式次数以及离散函数整体的光滑性指标。当目标函数特别光滑的时候，有限元方法不一定能够非常有效的利用这一潜在特性，而我们知道多项式空间逼近光滑函数的逼近性取决于目标函数的光滑性，目标函数越光滑，逼近性就越好。这就启发我们选择离散函数空间 V_n 为不超过 n 次的多项式函数空间，如

$$V_n = \{v_n \in \mathbb{P}_n, v_n(0) = v_n(1) = 0\}.$$

其中 $v_n(0) = v_n(1) = 0$ 来自于边界条件的要求。如果离散函数空间为三角多项式（或者 Fourier 函数），我们称该方法为 Fourier-谱方法；对于多项式空间作为离散函数空间，则需要选择合适的正交多项式基底，根据所选择基底的不同，我们把该方法称为 Legendre-谱方法、Chebyshev-谱方法等。谱方法的优势有两点：首先对于足够光滑的函数由于谱方法的逼近具有谱精度（解析函数的几何收敛速度），这就表示只需要很少的自由度就可以得到很高的精度；其次在组装刚度矩阵以及进行线性代数方程组求解时可以采用 FFT（快速 Fourier 变换）或者 FLT（快速 Legendre 变换）等快速变换算法来加速计算效率。

6.3 知识拓展

由于作者的偏好和篇幅的限制,有非常多重要的内容在本章中没有进行介绍或者展开。例如对于初值问题,线性多步法是一类行之有效的求解方法(如 BDF2),但是本书中没有涉及任何多步法;对于边值问题,我们没有明确区分测试函数空间(test function space)和试探函数空间(trial function space),事实上根据变分形式的不同,除了 Galerkin 方法,还有 Petrov-Galerkin 方法(测试函数空间不同于试探函数空间),或者配点法等。有兴趣的读者可以参阅其他专著来了解这些方法的更多性质和应用。

第 6 章 练习

1. 将下列方程化为一阶方程组:

$$(1) \begin{cases} y'' - 4y' + 3y = 0, \\ y(0) = 1, y'(0) = 1; \end{cases}$$

$$(2) \begin{cases} x^2 y'' - 2xy' + 2y = x^3 \ln x, \\ y(1) = 1, y'(1) = 0. \end{cases}$$

2. 将具有初值条件 $y(0) = 0, y'(0) = 1, z(0) = 1, z'(0) = 0$ 的方程组

$$\begin{cases} y'' = x^2 - y' - z^2 \\ z'' = x + z' - y^2 \end{cases}$$

改写成一阶方程组的初值问题.

3. 证明向后 Euler 法是一阶的.

4. 证明对于任意参数 α , 下列格式是二阶的:

$$\begin{cases} y_{n+1} = & y_n + \frac{1}{2}(k_1 + k_3), \\ k_1 = & hf(x_n, y_n), \\ k_2 = & hf(x_n + \alpha h, y_n + \alpha k_1), \\ k_3 = & hf(x_n + (1 - \alpha)h, y_n + (1 - \alpha)k_1). \end{cases}$$

5. 确定下列隐式单步法的阶:

$$y_{n+1} = y_n + \frac{1}{6}h[4f(x_n, y_n) + 2f(x_{n+1}, y_{n+1}) + hf'(x_n, y_n)].$$

6. 证明当用 Euler 方法求解 $[a, b]$ 上的初值问题

$$y' = f(x), \quad y(a) = y_0 = 0$$

时, 结果为

$$y(b) \approx \sum_{k=0}^{M-1} f(x_k)h$$

它是逼近区间 $[a, b]$ 上 $f(x)$ 的定积分的黎曼 (Riemann) 和.

7. 用 $N = 4$ 的 Runge-Kutta 方法求解微分方程:

$$\begin{cases} y' = -ty, \\ y(0) = 1, y(t) = e^{-t^2/2}. \end{cases}$$

(a) 令 $h = 0.2$, 手工计算 2 步; 再令 $h = 0.1$, 手工计算 4 步.

(b) 比较精确解 $y(0.4)$ 与 (a) 中的两个近似解.

(c) 当 h 减半时, (a) 中的最终全局误差是否和预期相符?

8. 证明函数 $x(t)$ 为边值问题的解.

(a) 在区间 $[1, 6]$ 上,

$$\begin{cases} x'' + \frac{1}{t}x' + (1 - \frac{1}{4t^2})x = 0, \\ x(1) = 1, x(6) = 0, \end{cases}$$

$$x(t) = \frac{0.2913843206 \cos(t) + 1.001299385 \sin(t)}{\sqrt{t}}$$

(b) 在区间 $[0.5, 4.5]$ 上,

$$\begin{cases} x'' - \frac{1}{t}x' + (\frac{1}{t^2})x = 1, \\ x(0.5) = 1, x(4.5) = 2, \end{cases}$$

$$x(t) = t^2 - 0.2525826491t - 2.528442297t \ln t$$

参考文献

- [1] Richard L Burden and J Douglas Faires. *Numerical analysis*. Cole publishing company Pacific Grove, CA, 1997.
- [2] G. H. Golub and C. F. V. Loan. *Matrix Computations*. Johns Hopkins University Press, 1996.
- [3] E. Isaacson and H.B. Keller. *Analysis of Numerical Methods*. Dover Books on Mathematics. Dover Publications, 1994. ISBN: 978-0-486-68029-3.
- [4] Ricardo Pachón and Nick Trefethen. “Barycentric- Remez algorithms for best polynomial approximation in the chebfun system”. In: (2008).
- [5] Michael James David Powell et al. *Approximation theory and methods*. Cambridge university press, 1981.
- [6] Alfio Quarteroni, Riccardo Sacco, and Fausto Saleri. *Numerical mathematics*. Vol. 37. Springer Science & Business Media, 2010.
- [7] Timothy Sauer. *Numerical analysis*. Addison-Wesley Publishing Company, 2011.
- [8] Lloyd N Trefethen. *Approximation Theory and Approximation Practice, Extended Edition*. SIAM, 2019.
- [9] L Veidinger. “On the numerical determination of the best approximations in the Chebyshev sense”. In: *Numerische Mathematik* 2.1 (1960), pp. 99–105.
- [10] 张平文, 李铁军. 数值分析. 北京: 北京大学出版社, 2007.